AIPE: seleção contextual de políticas de reposição por perfil e por aprendizado supervisionado

Matheus Inácio Batista Santos[a]

[a]*Instituto de Computação, Universidade Federal de Alagoas, Brasil*

Abstract

Escolher uma política de reposição exige relacionar a demanda às consequências de custo e atendimento. Apresentamos o Adaptive Inventory Policy Engine (AIPE), que integra caracterização, calibração de candidatas e seleção contextual. Seu Policy Selection Engine (PSE) admite associação entre perfil e política e previsão supervisionada da política por série. Avaliamos sete candidatas com separação temporal e seleção em outras lojas. Na Bahia, 145 séries em duas origens totalizam 4.350 ajustes; o PSE por perfil aumenta o atendimento em 3,89 pontos percentuais e o custo em 1,93% frente à seleção global. Em um piloto M5 com 30 séries, dez lojas e três origens, os 1.350 ajustes permitem avaliar as duas abordagens. O preditivo apresenta custo médio 13,9% maior e atendimento 4,11 pontos inferior à referência global; suas recomendações coincidem com e sem perfil explícito. Diagnósticos identificam poucos exemplos por classe, instabilidade dos rótulos e falhas de seleção distintas dos limites físicos do estoque. Uma regra exploratória de recuo ao perfil reduz o custo do preditivo em 12,2%, mas não demonstra superioridade sobre as referências. Oráculos retrospectivos quantificam a distância ao melhor controle disponível e ao planejamento com informação perfeita. O estudo oferece uma arquitetura e uma avaliação rastreável, sem comprovar vantagem geral da contextualização. Amostragem retrospectiva, calibrações específicas por base e uso do piloto para desenvolvimento exigem confirmação independente.

Keywords: Inventory control, Algorithm selection, Demand heterogeneity, Meta-learning, Service level

1. Introdução

Uma rede varejista decide quando e quanto repor para muitas combinações de loja e produto. Vendas frequentes, longos intervalos sem demanda e picos ocasionais impõem necessidades diferentes. Essas diferenças motivam contextualizar a decisão, mas não demonstram que uma regra por grupo ou um modelo supervisionado supere uma política única bem calibrada. O benefício precisa aparecer no custo e no atendimento em períodos posteriores à escolha [1].

Comparar controladores e selecionar entre eles são problemas distintos. Uma política pode ser competitiva em média e inadequada para algumas séries. Reciprocamente, a existência de vencedoras diferentes não garante que suas identidades sejam previsíveis. A seleção de algoritmos fornece a formulação pertinente: características de uma instância orientam a escolha de um método de um portfólio [2, 3]. Aqui, a instância é a série loja–produto e a decisão é a família de política, com parâmetros calibrados no histórico da própria série.

Propomos o *Adaptive Inventory Policy Engine* (AIPE) para organizar caracterização, calibração, seleção e avaliação. Seu componente de escolha, o *Policy Selection Engine* (PSE), tem duas abordagens. O PSE por perfil recebe o perfil observado e consulta uma associação construída na validação. O PSE preditivo estima a política a partir das características da série, podendo receber o perfil como entrada adicional. A primeira compartilha uma recomendação no grupo; a segunda permite decisões distintas dentro dele. A aplicação pretendida reutiliza evidências de outras séries para orientar a família a calibrar. No experimento, todas as candidatas são ajustadas na série reservada para medir suas consequências e construir os oráculos; não foi mensurada economia computacional de implantação.

Investigamos três perguntas: o PSE por perfil acrescenta valor frente à seleção global? O preditivo melhora essa decisão e utiliza o perfil explícito? Quanto separa a recomendação dos melhores resultados retrospectivos? A avaliação combina dados proprietários da Bahia e um piloto público M5. As bases respondem a partes complementares dessas perguntas, sem reunir custos absolutos nem tratar o piloto como confirmação externa.

A contribuição é a arquitetura de seleção e sua avaliação operacional rastreável. Não propomos novas famílias de controladores, nem reivindicamos novidade na associação entre classes e políticas. Mostramos onde a contextualização altera o compromisso custo–serviço, onde o aprendizado falha e

como separar erros de seleção de insuficiência do portfólio ou de limitações físicas. Os resultados negativos delimitam as condições em que a complexidade adicional ainda não se justifica.

2. Trabalhos relacionados

A classificação ADI–CV^2 organiza padrões de frequência e tamanho da demanda [4]. Entretanto, classes estatísticas não determinam sozinhas a melhor reposição: custos, prazo, estoque inicial e atendimento também importam. Mohammaditabar et al. [5] integram classificação e escolha de políticas; Sheikh-Zadeh et al. [6] propõem classificação orientada ao desempenho em sistemas de múltiplos itens e escalões. Esses antecedentes situam o AIPE como uma instanciação de seleção contextual, não como a primeira integração entre classificação e inventário. Seus métodos não foram reproduzidos como comparadores.

Na literatura da revista, Tadayonrad e Ndiaye [7] aproximam previsão e consequências operacionais. Theunissen et al. [8] discutem a informação decisória preservada pela classificação. Essa perspectiva orienta nossa avaliação: reconhecer um perfil ou acertar o nome de uma política só tem utilidade se melhorar a decisão. Não implementamos o método topológico desses autores.

Zabraoui et al. [9] comparam algoritmos de inventário e combinações de busca genética e aprendizado por reforço com dados M5. A arquitetura GA–DQN integra nosso portfólio, com GA e DQN como controles, sem ser apresentada como contribuição algorítmica. Granularidade, filtros, custos e implementação local impedem uma reprodução exata de seu ranking.

Políticas limitadas de estoque-base oferecem outra referência para vendas perdidas [10]. Suas propriedades teóricas não garantem desempenho para nossa calibração. Os resultados de reforço também dependem do estado, da recompensa e do orçamento [11]. O AIPE separa essas implementações da escolha entre candidatas. A avaliação do seletor precisa, ainda, separar desenvolvimento e teste para evitar otimismo após escolher configurações [12].

3. AIPE e formulação da seleção

3.1. Da demanda à recomendação

A Figura 1 apresenta o fluxo. Cada histórico é preparado na unidade temporal da base e descrito por volume, dispersão, intermitência e estrutura temporal. As candidatas são calibradas no treino. Custo e serviço na

validação sustentam a associação por perfil ou os rótulos do preditivo. A recomendação é avaliada no teste reservado.

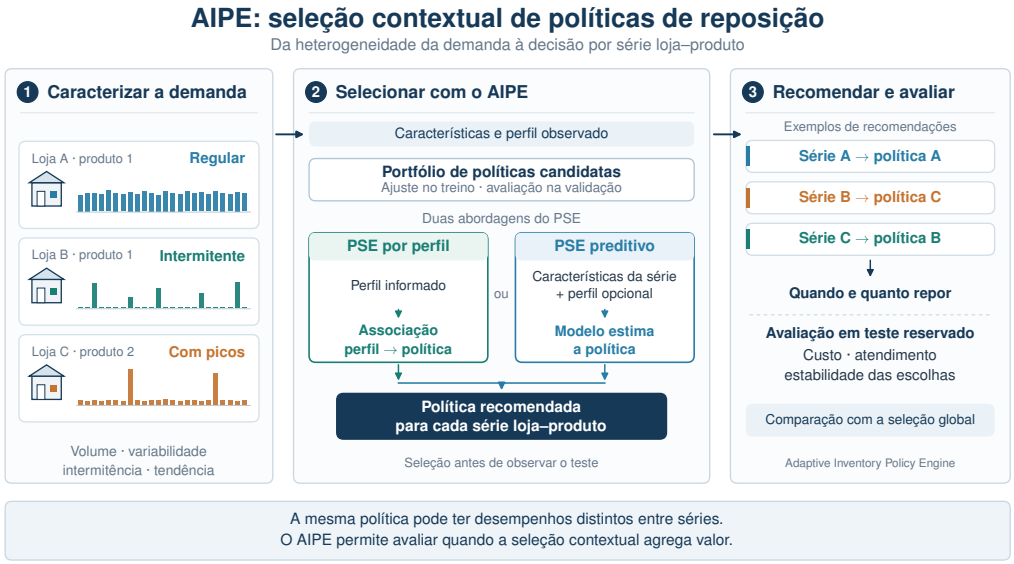


Figura 1: AIPE e duas abordagens do PSE. O perfil pode orientar uma associação compartilhada ou entrar em um modelo que estima a política por série. Séries e associações A/B/C são ilustrativas. Ganhos são objeto de avaliação, não propriedade presumida da arquitetura.

A adaptação significa recalcular descritores e revisar a recomendação entre janelas. Não há troca de controlador a cada transação nem implantação online validada. Cada série constitui um sistema separado de vendas perdidas, sem estoque compartilhado, transbordo ou capacidade conjunta.

Seja Π o portfólio, x_i a descrição do treino e g_i o perfil. O PSE por perfil recomenda $m(g_i)$; o preditivo recomenda $f(x_i, g_i)$ ou $f(x_i)$ na ablação. A seleção global usa uma mesma família para as séries da loja avaliada. Em todas as abordagens, os parâmetros são ajustados individualmente. A referência global, portanto, também utiliza o histórico de cada série.

3.2. Custo, serviço e escolha

Para demanda d_t, quantidade atendida v_t, saldo I_t e pedido q_t, avaliamos

$$C = \sum_t [hI_t + p(d_t - v_t) + K\mathbf{1}(q_t > 0) + cq_t], \qquad F = \frac{\sum_t v_t}{\sum_t d_t}. \tag{1}$$

O atendimento F é *fill rate*, não probabilidade de ciclo sem falta. Com demanda zero, permanece indefinido; o custo continua contabilizado. Usamos $h = 1$, $p = 5$, $K = 50$ e $c = 0{,}5$, em unidades do cenário, sem equivalência monetária calibrada.

Na validação A, a regra global minimiza $\bar{C}_{\pi,A}$ entre candidatas com $\bar{F}_{\pi,A} \geq \alpha$, com $\alpha = 0{,}70$. O PSE por perfil aplica essa regra a cada grupo A_g. Casos sem demanda não entram na média de serviço. Sem candidata viável, escolhe-se maior serviço e menor custo, registrando contingência. Perfis sem suporte usam a global. Na Bahia, empate no custo viável prefere maior serviço e depois identificador; no M5, prefere identificador. Contingências empatadas em serviço preferem menor custo. Essas convenções são preservadas por base e registradas no código.

O rótulo supervisionado aplica a restrição à própria série de validação: menor custo viável ou, sem viável, maior serviço e menor custo. Se todas as opções têm serviço indefinido, utiliza menor custo e mantém a marcação de demanda zero. Classificador e seletores agregados não impõem a mesma distribuição da restrição. Incluímos a moda dos rótulos como controle para não atribuir toda diferença à capacidade preditiva.

3.3. Características e perfis

O preditivo recebe 17 descritores: ADI, CV^2, intermitência, proporção de zeros, maior e média das sequências de zeros, *burstiness*, assimetria, curtose, entropia, tendência, autocorrelação, média, desvio-padrão, CV, extensão e número de ciclos positivos. O perfil categórico deriva desses descritores, sem constituir informação independente.

As regras são ordenadas (Tabela 1). ADI é $n/\max(n_+, 1)$ e CV^2 usa a dispersão de todos os ciclos, incluindo zeros, diferindo da taxonomia original baseada em tamanhos positivos. Os nomes são descritores heurísticos, sem comprovar sazonalidade ou impacto econômico.

Burstiness compara o desvio e a média dos intervalos positivos pela razão de sua diferença e soma, com regularização numérica. Tendência é a inclinação OLS dividida pela média; entropia usa dez classes de mesma largura. A autocorrelação na defasagem 17 recebe zero com até 18 ciclos ou variância desprezível. Essa convenção denota estimativa indisponível, não ausência de sazonalidade; com 23 ciclos, há somente seis pares.

Tabela 1: Primeira condição satisfeita determina o perfil; casos residuais recebem o perfil esparso. Cortes fixos, sem ajuste no teste.

Perfil	Condição
Esparso	ADI $\geq 1{,}32$, $\mathrm{CV}^2 \geq 0{,}49$ e sequência de zeros ≥ 5
Volatilidade / sazonalidade	Autocorrelação na defasagem 17 $\geq 0{,}25$ ou burstiness $\geq 0{,}30$
Tendência instável	Tendência normalizada absoluta $\geq 0{,}05$ ou entropia ≥ 2
Baixo volume estável	Média ≤ 2 e $\mathrm{CV}^2 < 0{,}49$
Venda frequente	ADI $< 1{,}32$

4. Desenho experimental

4.1. Bases e unidades de análise

A Tabela 2 distingue as avaliações. Na Bahia, transações complementares são somadas por loja, produto e ciclo; ciclos sem venda recebem zero. A coorte retrospectiva contém 145 séries, 115 lojas e nove produtos. Os 38 ciclos disponíveis, de 202301 a 202504, são unidades comerciais da fonte, não meses.

O M5 é uma fonte pública de vendas associada a uma competição de previsão [13]. O piloto sorteia 30 séries FOODS, três por loja nas dez lojas. Na primeira origem, o volume médio do treino define três estratos por loja, com uma escolha em cada estrato e semente 20261015. As séries são mantidas nas três origens. Usamos ciclos completos de 21 dias, sem aparar picos por IQR.

A elegibilidade exige três ciclos positivos no prefixo. O sorteio M5 usa 885 séries elegíveis na primeira origem de uma coorte histórica de 2.408 identificadores. Não representa todas as FOODS nem séries elegíveis somente depois. O recorte é inspirado no contexto de Zabraoui et al., sem afirmar identidade com sua amostra. A rodada maior interrompida não fornece conclusões deste artigo.

4.2. Simulador, portfólio e calibração

O prazo exato é de dois ciclos. A política observa o estado anterior ao recebimento; entregas chegam antes da demanda. Quantidades podem ser

Tabela 2: Matrizes completas analisadas. Casos série–origem e sementes não são séries independentes.

Dimensão	Bahia	Piloto M5
Séries / lojas	145 / 115	30 / 10
Origens de treino (ciclos)	17 e 23	50, 64 e 78
Validação / teste por origem	7 / 7	7 / 7
Casos série–origem	290	90
Ajustes de políticas	4.350	1.350
Testes sem demanda	7	4
Seletores	Global e por perfil	Global, por perfil e preditivo

fracionárias. Faltas são vendas perdidas, sem pedidos pendentes. Manutenção incide no saldo após demanda e o pedido é custeado na emissão, sem crédito terminal.

Validação e teste começam em estados comuns às candidatas, produzidos por uma referência EOQ: seis ciclos passados aquecem o sistema, e sua trajetória na validação determina estoque e pipeline do teste. Esses estados usam o passado, mas não representam a continuação particular de cada candidata. Escalas são calculadas no treino.

O portfólio contém EOQCycle, sSCycle, CappedBaseStock, GA, PPO, GA–DQN e DQN. EOQCycle usa lote $\max(1, \sqrt{2\mu K/h})$ e ponto de pedido $2\mu + 1{,}28\sigma\sqrt{2}$; sSCycle repõe até o ponto acrescido do lote. CappedBaseStock limita a quantidade da reposição até um alvo e calibra alvo e teto em grade 20×12. GA ajusta gatilho, lote e proteção com população 100 e 50 gerações. DQN usa Double DQN dueling; PPO usa otimização proximal. Ambos têm duas camadas de 64 unidades, 20 ações e no mínimo 20 mil transições, arredondadas ao episódio completo. GA–DQN acrescenta busca genética e mil demonstrações, mantendo gatilho e piso iguais nas demonstrações, treino e inferência.

Os quatro métodos estocásticos usam sementes 11, 29 e 47; as três referências determinísticas têm um ajuste. As sementes são promediadas antes da avaliação por caso. O híbrido tem esforço superior ao DQN, sem equivalência de orçamento. A calibração pode penalizar déficit de serviço. Na Bahia, CappedBaseStock também penaliza frequência de ruptura e amplificação dos pedidos com pesos unitários; no M5, ambos os pesos são zero. Essa diferença impede atribuir contrastes entre bases somente à demanda. Cada

matriz e código arquivado identificam a instanciação avaliada.

4.3. Avaliação e desenvolvimento do piloto

Em cada origem, uma loja inteira fica fora do conjunto que define a escolha. O PSE usa a validação das demais lojas e recomenda para o teste da loja reservada. Controladores continuam calibrados no histórico da própria série: avaliamos transferência do seletor com histórico disponível, não implantação sem dados prévios.

No M5, XGBoost tem 200 árvores, profundidade três, taxa 0,05, sem subamostragem e com semente fixa. Imputação, codificação categórica e classes são ajustadas dentro de cada fold. Classes raras não são removidas; treinos de classe única usam classificador constante. Cada treinamento reúne 27 exemplos. A ablação sem perfil mantém os demais componentes. Não se usam origens posteriores para recomendar em uma origem anterior.

Após o diagnóstico, examinamos uma única extensão: recuar ao PSE por perfil se o maior escore de classe for inferior a 0,60 ou a classe prevista tiver menos de três exemplos de treino. Não há busca de limiares no teste, mas a motivação veio dos resultados observados. Seu desempenho é exploratório, e o piloto passa a ser conjunto de desenvolvimento [12]. O escore não é probabilidade calibrada de viabilidade.

Na Bahia, os testes compartilham um ciclo; no M5, ocupam os ciclos 58–64, 72–78 e 86–92, sem sobreposição. Origens repetem séries. Intervalos exploratórios usam bootstrap pareado por loja, preservando séries e origens: 5.000 sorteios na Bahia e 2.000 no M5. Seletores e controladores permanecem fixos; a incerteza é condicional, sem novos treinamentos. Dez lojas do piloto limitam sua precisão.

4.4. Oráculos e informação perfeita

O melhor controlador único no teste é um diagnóstico retrospectivo. O oráculo do portfólio escolhe, por série–origem, a candidata de menor custo viável nas médias de teste entre sementes. Essas escolhas não fornecem rótulos ao treinamento. O acerto exige serviço mínimo e empate numérico no menor custo; concordância nominal é informada separadamente.

No M5, um programa linear inteiro misto conhece toda a demanda de teste e otimiza pedidos sob os mesmos custos, prazo e condições iniciais. Quantidades são contínuas; variáveis binárias representam emissão e complementaridade entre saldo e falta. É um ótimo determinístico condicional,

não um controlador estocástico implantável. Se 0,70 for fisicamente impossível antes das primeiras entregas, maximiza atendimento e depois minimiza custo. Soluções são reexecutadas no simulador e somente as comprovadamente ótimas recebem essa denominação.

A eficiência de custo é $100C^*/C_{\mathrm{PSE}}$, apenas quando referência e recomendação satisfazem o mesmo critério de serviço; ambos os custos zero equivalem a 100%. Serviço insuficiente não recebe crédito por custo baixo. A comparação com o MILP usa cada realização de treinamento viável: uma média entre sementes pode satisfazer o alvo sem que todas o satisfaçam. Repetir políticas determinísticas nessa análise não gera novas observações independentes.

5. Resultados na Bahia: PSE por perfil

As sete candidatas foram avaliadas em 290 casos série–origem. O custo médio usa todos os casos e o atendimento os 283 com demanda positiva; sete têm serviço indefinido. Somente EOQCycle e sSCycle superam 0,70 em média; nenhuma supera esse alvo no atendimento ponderado pelas unidades demandadas.

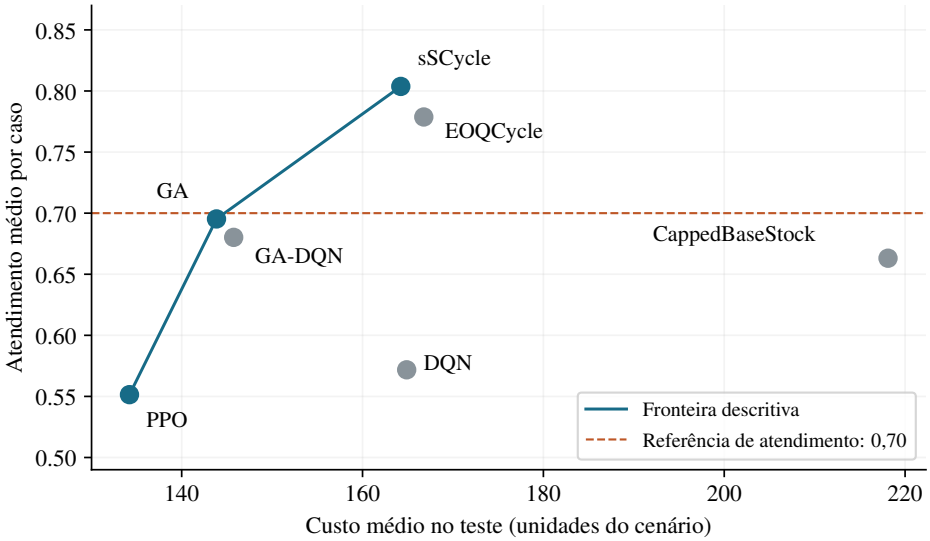


Figura 2: Portfólio na Bahia: custo médio em 290 casos e atendimento em 283 com demanda positiva. A fronteira é retrospectiva e descritiva; não é usada para escolher no teste.

PPO tem menor custo e menor atendimento. GA–DQN reduz custo em 11,60% frente ao DQN e eleva atendimento de 0,5718 para 0,6802; frente ao GA, custa 1,32% mais e atende menos. O híbrido não domina seu componente evolutivo no agregado, e seu esforço adicional impede atribuir o contraste apenas à combinação algorítmica.

Tabela 3: Escolha na validação das demais lojas; teste da loja reservada. Custo em 145 casos por linha; atendimento em 144 casos na origem 17 e 139 na origem 23.

Treino	Seleção	Custo	Atendimento	Abaixo de 0,70
17 ciclos	Global	180,58	0,5711	101
17 ciclos	PSE por perfil	186,79	0,6475	82
23 ciclos	Global	142,03	0,9073	18
23 ciclos	PSE por perfil	142,03	0,9073	18

Na primeira origem, a global escolhe GA em todos os casos. O PSE por perfil escolhe GA em 65, sSCycle em 75 e EOQCycle em cinco. Na segunda, ambos escolhem sSCycle nos 145 casos. A Figura 3 localiza essa diferenciação: perfis distintos não implicam recomendações distintas em todo período.

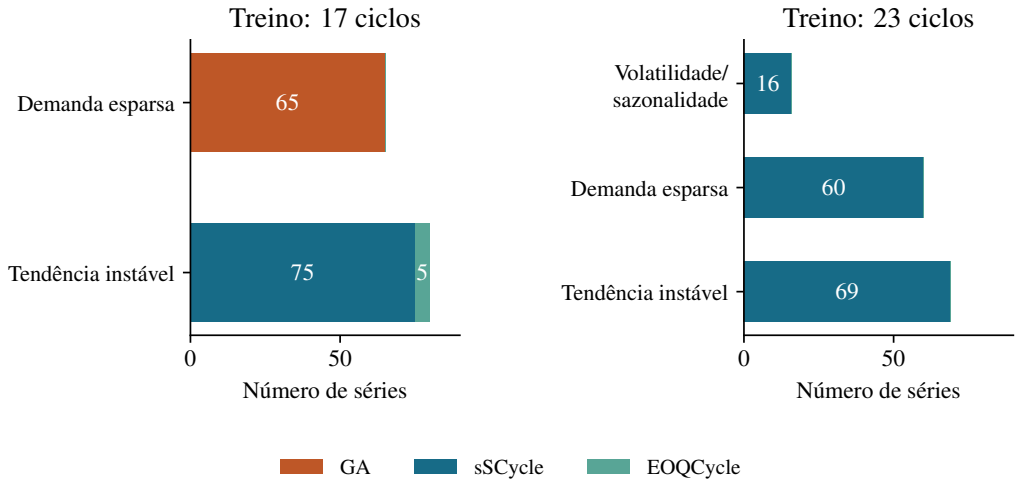


Figura 3: Escolhas do PSE por perfil na Bahia, com meta 0,70. Há 145 recomendações por origem. A segunda reproduz a seleção global.

Reunindo origens, o custo passa de 161,31 para 164,41, aumento de 1,93%; o atendimento cresce de 0,7362 para 0,7751, diferença de 3,89 pontos per-

centuais. O ponderado passa de 0,5750 para 0,6395. Casos abaixo de 0,70 diminuem de 119 para 100 entre 283 definidos. O resultado é serviço adicional com custo pontualmente maior, concentrado na primeira origem.

O bootstrap condicional de 115 lojas produz intervalos de 95% de $[-0{,}32; 4{,}16]\%$ para custo e $[2{,}78; 5{,}07]$ pontos para atendimento. Incluir zero no intervalo de custo não prova equivalência. Variar o limiar sem recalibrar o portfólio também não preserva o benefício: em 0,80, o PSE por perfil custa mais e atende ligeiramente menos; em 0,85, ambos escolhem sSCycle em todos os casos; em 0,90 e 0,95, todas as escolhas são contingências na validação.

6. Resultados no M5: duas abordagens do PSE

6.1. Custo e atendimento das recomendações

O piloto completa os 1.350 ajustes das 30 séries em três origens. As recomendações são avaliadas em 90 casos, com atendimento definido em 86. Não são 90 séries independentes. A Tabela 4 inclui dois controles: moda dos rótulos de treino e escolha individual da vencedora de validação. O último examina a transferência temporal do próprio rótulo, sem representar um limite superior para os seletores.

Tabela 4: M5: custo em 90 casos; atendimento e contagem de viáveis em 86 com demanda positiva. O recuo é exploratório, desenvolvido após o diagnóstico do piloto.

Seleção	Custo	Atendimento	Casos $\geq 0{,}70$
Global	1.086,97	0,7146	47
PSE por perfil	1.094,02	0,7091	46
PSE preditivo com perfil	1.238,30	0,6735	39
PSE preditivo sem perfil	1.238,30	0,6735	39
Moda dos rótulos	1.096,65	0,6885	42
Individual na validação	1.185,13	0,6838	44
Preditivo com recuo	1.087,26	0,6996	46

O preditivo custa 13,9% mais e atende 4,11 pontos percentuais menos que a global. O contraste desfavorável aparece nas três origens e nos dois perfis. WI_3 e TX_2 respondem por 65,4% da diferença líquida de custo. O PSE por perfil permanece próximo da global: maior custo e serviço ligeiramente menor, sem benefício agregado neste piloto.

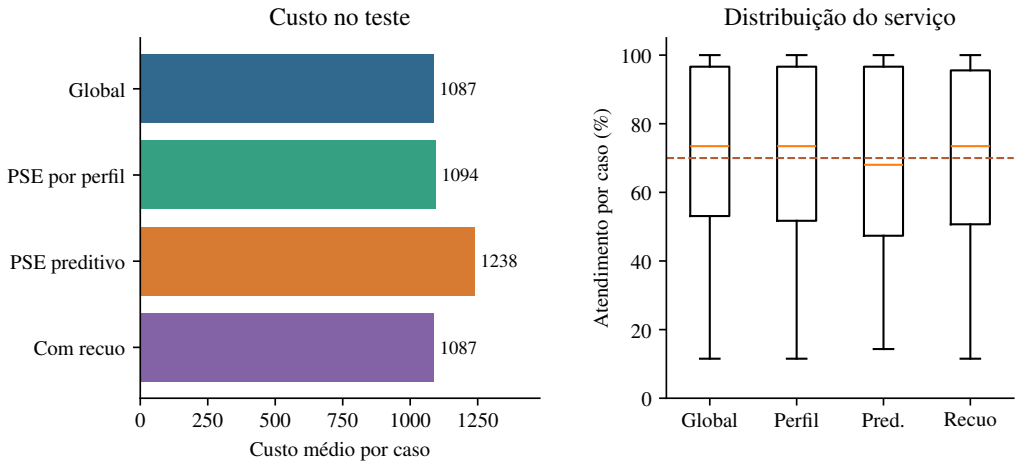


Figura 4: Piloto M5: custo e atendimento médios são apresentados separadamente. Caixas descrevem o serviço nos 86 casos definidos; linha em 0,70. O recuo foi desenvolvido no piloto, sem confirmação independente.

O recuo é acionado em 62 casos e muda a política em 48. Frente ao preditivo, reduz custo em 12,2% e aumenta serviço em 2,62 pontos. Frente à global, custa 0,026% mais e atende 1,49 ponto menos; o atendimento permanece abaixo de 0,70. O intervalo exploratório para a diferença de custo frente à global é $[-39{,}83; 39{,}30]$ unidades do cenário; para serviço, $[-2{,}87; -0{,}23]$ pontos. Proximidade de custo não comprova equivalência.

6.2. O que explica a dificuldade do preditivo?

Cada fold tem 27 exemplos para até sete classes. O modelo reproduz 100% dos rótulos do treino, mas somente 19 dos 90 rótulos de validação das lojas excluídas. Dois rótulos pertencem a classes ausentes no respectivo treinamento. Esses resultados são consistentes com sobreajuste, sem provar que mais dados, isoladamente, resolvam o problema.

A vencedora nominal da validação permanece vencedora no teste em 29/90 casos; admitindo empates no objetivo completo, em 33/90. Com demanda positiva nos dois blocos, a concordância nominal é 26/83. As vencedoras diferem entre sementes em 39/90 casos. O alvo categórico é sensível tanto ao período quanto ao treinamento. Escolher individualmente na validação aumenta os casos viáveis frente ao preditivo, mas não supera a global em custo ou atendimento médio.

Cada origem contém 26 séries esparsas e quatro de tendência, sem transição de perfil na amostra. As colunas de perfil têm importância por ganho zero em todos os folds; com e sem elas, as 90 recomendações coincidem. Redundância com as características numéricas e baixa diversidade ajudam a explicar a ausência de efeito, sem demonstrar inutilidade dos perfis em outras populações.

6.3. Distância aos melhores resultados e fontes das falhas

O preditivo iguala o menor custo viável do portfólio em 11 dos 39 casos nos quais sua recomendação é viável. Sua eficiência média condicional é 74,2%. A global acerta 15/47 e o PSE por perfil 12/46, com eficiências de 80,8% e 79,5%. Os denominadores diferem: não se avalia eficiência sobre um mesmo subconjunto.

Os 90 problemas com informação perfeita têm otimalidade comprovada. Nas 118 realizações de treinamento em que o preditivo satisfaz o alvo, iguala o ótimo determinístico em 14 e apresenta eficiência média de 54,6%. As realizações repetem séries e, para políticas determinísticas, a mesma trajetória; não ampliam a amostra independente. Mede-se distância ao planejamento com demanda conhecida, não a um controlador estocástico implantável.

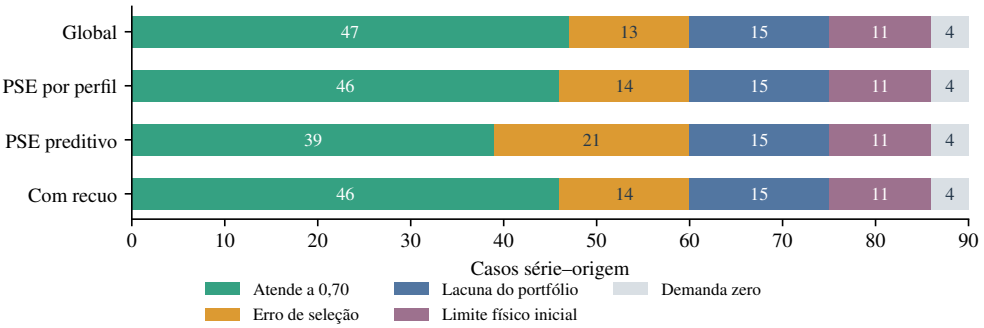


Figura 5: Decomposição dos 90 casos M5. Erro de seleção: outra candidata atende. Lacuna do portfólio: nenhuma candidata atende, mas o planejamento perfeito permite atender. Limite físico: condições iniciais impedem atingir 0,70. Demanda zero mantém serviço indefinido.

No preditivo, 39 casos atendem ao alvo; 21 falham apesar de existir política viável; 15 falham sem candidata viável, embora o planejamento perfeito permita atender; 11 têm restrição física inicial; e quatro têm demanda zero. O recuo reduz os erros de seleção de 21 para 14. Melhorar o seletor não

resolve sozinho todas as faltas: a Figura 5 separa intervenções sobre escolha, controle e abastecimento inicial.

7. Discussão

O AIPE explicita quando vale mudar a família de política entre séries. Na Bahia, o PSE por perfil troca custo por atendimento e diferencia escolhas em somente uma origem. No piloto M5, a global oferece compromisso melhor que o preditivo, enquanto o PSE por perfil permanece próximo da referência. Não há evidência de superioridade geral da contextualização.

A dificuldade do preditivo não se reduz ao algoritmo. Há sete classes e 27 exemplos por fold; rótulos variam com período e semente. Um classificador pode reproduzir o treino e falhar na loja reservada. O alvo categórico também descarta quão próximas as candidatas estão em custo e serviço. Isso motiva investigar alvos mais estáveis e critérios sensíveis à perda operacional, sem escolher soluções pelos mesmos testes usados para justificá-las.

O recuo limita recomendações individuais pouco sustentadas e aproxima seu custo ao da global, sem atendimento superior. Não resolve falta de opções viáveis nem faltas inevitáveis. A decomposição indica se a próxima intervenção deve mudar seletor, calibração ou condições de abastecimento.

A concentração de perfis limita sua avaliação. Na primeira origem M5, 826 das 885 séries elegíveis são esparsas, 57 têm tendência e apenas duas pertencem ao grupo volatilidade/sazonalidade. A baixa diversidade não decorre somente do sorteio. Aumentar a amostra sem registrar suporte por grupo não assegura avaliação representativa de todos os perfis.

Meta média, atendimento ponderado por unidades e garantia por série são exigências diferentes. Média de 0,70 pode coexistir com numerosas violações individuais. Essa definição precisa anteceder a seleção; modificá-la para favorecer o resultado mudaria o problema. Os custos e o limiar deste cenário não constituem recomendação comercial.

8. Limitações e próximos testes

Vendas podem omitir demanda censurada por falta. Coortes históricas, elegibilidade na primeira origem e horizontes de sete ciclos restringem população e período. Produtos compartilhados entre lojas podem gerar dependência não capturada inteiramente pelo bootstrap.

Não se trata de experimento causal de implantação. Custos não são financeiramente calibrados, não há suprimento conjunto e o estado inicial comum não reproduz trajetórias particulares. A calibração distinta da CappedBaseStock e os esforços desiguais limitam comparações entre algoritmos e bases.

A extensão com recuo foi desenvolvida no piloto; suas métricas não confirmam independentemente a melhoria. A próxima avaliação exige mais exemplos por classe, suporte para perfis raros, restrições de serviço comparáveis e validação interna por loja para ajustes do seletor. Séries reservadas devem ficar fora dessas decisões. Harmonização da calibração e sensibilidades de custo, prazo e horizonte precedem conclusões mais amplas.

9. Conclusão

Apresentamos o AIPE com PSE por perfil e preditivo, avaliando recomendações separadamente dos controladores. Na Bahia, o perfil acrescenta 3,89 pontos de atendimento com aumento pontual de custo de 1,93%. No piloto M5, o preditivo custa 13,9% mais e atende 4,11 pontos menos que a global. O recuo melhora esse preditivo, sem estabelecer vantagem sobre as referências.

Heterogeneidade e portfólio diverso não bastam para tornar a escolha aprendível. Oráculos e decomposição das falhas distinguem distância ao melhor candidato de restrições que o seletor não supera. A proposta permanece em desenvolvimento; avaliação independente deverá demonstrar em quais contextos sua complexidade oferece benefício operacional.

Disponibilidade de dados e código

Os dados brasileiros são proprietários e não são redistribuídos; o M5 é público. Código, configurações e fontes estão em `https://github.com/matheus013/msc`. Dados, bancos e modelos ficam fora da versão atual do repositório. Manifestos e snapshots locais identificam as matrizes; pacote arquivado e derivados autorizados deverão acompanhar a submissão. Não se promete acesso aos registros restritos mediante solicitação.

Autoria, financiamento e interesses

Autoria, contribuições CRediT, financiamento, agradecimentos e interesses devem ser confirmados pelos autores responsáveis. O manuscrito em por-

tuguês requer tradução, revisão humana e fechamento das declarações antes da submissão.

Uso de inteligência artificial na preparação do manuscrito

OpenAI Codex auxiliou organização bibliográfica, leitura de código, análise, visualização e redação. A figura conceitual usa desenhos vetoriais programáticos; os gráficos quantitativos derivam das matrizes identificadas. Conferência e responsabilidade pelo texto final cabem aos autores humanos. Sistemas de IA não são autores.

Referências

[1] S. Axsäter, Inventory Control, 2nd Edition, Vol. 90 of International Series in Operations Research & Management Science, Springer US, New York, NY, USA, 2006. doi:10.1007/0-387-33331-2.

[2] J. R. Rice, The algorithm selection problem, in: Advances in Computers, Vol. 15, Academic Press, 1976, pp. 65–118. doi:10.1016/S0065-2458(08)60520-3.

[3] L. Kotthoff, Algorithm selection for combinatorial search problems: A survey, AI Magazine 35 (3) (2014) 48–60. doi:10.1609/aimag.v35i3.2460.

[4] A. A. Syntetos, J. E. Boylan, J. D. Croston, On the categorization of demand patterns, J. Oper. Res. Soc. 56 (5) (2005) 495–503. doi:10.1057/palgrave.jors.2601841.

[5] D. Mohammaditabar, S. H. Ghodsypour, C. O'Brien, Inventory control system design by integrating inventory classification and policy selection, International Journal of Production Economics 140 (2) (2012) 655–659. doi:10.1016/j.ijpe.2011.03.012.

[6] A. Sheikh-Zadeh, M. D. Rossetti, M. A. Scott, Performance-based inventory classification methods for large-scale multi-echelon replenishment systems, Omega 101 (2021) 102276. doi:10.1016/j.omega.2020.102276.

[7] Y. Tadayonrad, A. B. Ndiaye, A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality, Supply Chain Analytics 3 (2023) 100026. doi:10.1016/j.sca.2023.100026.

[8] F. M. Theunissen, S. Alam, A. Sajjad, A topological analytics framework for preserving decision structure in supply chain inventory classification, Supply Chain Analytics 15 (2026) 100229. doi:10.1016/j.sca.2026.100229.

[9] O. Zabraoui, Y. Hmamou, A. Chafi, S. Kammouri Alami, A comparative study of multi-algorithm optimization for inventory analytics in supply chains, Supply Chain Analytics 12 (2025) 100154. doi:10.1016/j.sca.2025.100154.

[10] L. Xin, Technical note—understanding the performance of capped base-stock policies in lost-sales inventory models, Operations Research 69 (1) (2021) 61–70. doi:10.1287/opre.2020.2019.

[11] R. N. Boute, J. Gijsbrechts, W. van Jaarsveld, N. Vanvuchelen, Deep reinforcement learning for inventory control: A roadmap, European Journal of Operational Research 298 (2) (2022) 401–412. doi:10.1016/j.ejor.2021.07.016.

[12] G. C. Cawley, N. L. C. Talbot, On over-fitting in model selection and subsequent selection bias in performance evaluation, Journal of Machine Learning Research 11 (2010) 2079–2107.
URL https://www.jmlr.org/papers/v11/cawley10a.html

[13] S. Makridakis, E. Spiliotis, V. Assimakopoulos, M5 accuracy competition: Results, findings, and conclusions, International Journal of Forecasting 38 (4) (2022) 1346–1364. doi:10.1016/j.ijforecast.2021.11.013.