

Dissertação de Mestrado

Um Framework Adaptativo para Seleção de Políticas de Reposição em Regimes Operacionais Heterogêneos

Matheus Inácio Batista Santos
mibs@ic.ufal.br
Orientadores:

Dr. Rian Gabriel Santos Pinheiro
Dr. Bruno Costa e Silva Nogueira

Maceió

15 de outubro de 2026

Matheus Inácio Batista Santos

Um Framework Adaptativo para Seleção de Políticas de Reposição em Regimes Operacionais Heterogêneos

Dissertação em desenvolvimento no Programa de Pós-Graduação em Informática da Universidade Federal de Alagoas, Instituto de Computação.

Orientadores:
Dr. Rian Gabriel Santos Pinheiro

Dr. Bruno Costa e Silva Nogueira

Maceió

15 de outubro de 2026

Versão de trabalho da dissertação de mestrado em desenvolvimento no Instituto de Computação da Universidade Federal de Alagoas. Composição da banca a confirmar.

Dr. Rian Gabriel Santos Pinheiro - Orientador
Instituto de Computação
Universidade Federal de Alagoas

Dr. Bruno Costa e Silva Nogueira - Orientador
Instituto de Computação
Universidade Federal de Alagoas

- Examinador(a)

- Examinador(a)

- Examinador(a)

Maceió
15 de outubro de 2026

Resumo

Redes varejistas precisam escolher políticas de reposição para demandas heterogêneas. Esta dissertação propõe o *Adaptive Inventory Policy Engine* (AIPE), que integra preparação, caracterização, calibração e seleção contextual. O *Policy Selection Engine* (PSE) admite duas abordagens: associar o perfil informado a uma política ou estimar a política por série com aprendizado supervisionado. A avaliação usa sete candidatas, calibração no treino, escolha na validação de outras lojas e teste temporal reservado. Na Bahia, 145 séries em duas origens totalizam 4.350 ajustes; o PSE por perfil aumenta o custo médio em 1,93% e o atendimento em 3,89 pontos percentuais, reduzindo de 119 para 100 os casos abaixo de 0,70 entre 283 com demanda positiva. No piloto M5, 30 séries das dez lojas em três origens totalizam 1.350 ajustes. O preditivo custa 13,9% mais e atende 4,11 pontos menos que a global; incluir perfil não altera suas recomendações. Poucos exemplos por classe e instabilidade dos rótulos limitam o aprendizado. Um recuo exploratório ao perfil reduz a perda do preditivo, sem demonstrar superioridade sobre as referências. Oráculos retrospectivos e planejamento com informação perfeita separam erros de seleção, insuficiência do portfólio e restrições físicas iniciais. A contribuição é uma arquitetura e uma avaliação rastreável, com resultados favoráveis e limites explícitos. Coortes retrospectivas, calibrações específicas, janelas curtas e desenvolvimento no piloto exigem confirmação independente antes de atribuir vantagem geral ao AIPE.

Palavras-chave: Gestão de estoques; Seleção de políticas; Demanda intermitente; Aprendizado supervisionado; Nível de serviço.

Abstract

Retail networks must select replenishment policies for heterogeneous demand. This dissertation proposes the Adaptive Inventory Policy Engine (AIPE), integrating data preparation, characterization, calibration, and contextual selection. Its Policy Selection Engine (PSE) either maps a given profile to a policy or predicts the policy for each series using supervised learning. Seven candidates are fitted on training data, selected using validation data from other stores, and evaluated on held-out future periods. In Bahia, 145 series at two origins yield 4,350 fits. Profile-based selection increases mean cost by 1.93% and mean fill rate by 3.89 percentage points, reducing cases below 0.70 from 119 to 100 among 283 positive-demand cases. In the M5 pilot, 30 series from ten stores at three origins yield 1,350 fits. Predictive selection costs 13.9% more and serves 4.11 percentage points less than global selection; explicitly adding the profile does not change its recommendations. Limited class support and unstable labels constrain learning. An exploratory fallback to profile-based selection reduces the predictive selector's loss without demonstrating superiority over the references. Retrospective portfolio oracles and perfect-information planning separate selection errors, portfolio gaps, and initial physical limitations. The contribution is a framework and a traceable evaluation that reports both benefits and limitations. Retrospective cohorts, dataset-specific calibrations, short horizons, and development on the pilot require independent confirmation before claiming a general AIPE advantage.

Keywords: Inventory management; Policy selection; Intermittent demand; Supervised learning; Service level.

Sumário

Lista de Figuras v
Lista de Tabelas vi
Lista de Siglas vii

1 Introdução **1**
1.1 Motivação 1
1.1.1 Reposição em redes varejistas 1
1.1.2 Da calibração à seleção de políticas 2
1.2 Problema e questões de pesquisa 2
1.3 Objetivos 4
1.4 Contribuições e alcance da evidência 4
1.5 Escopo e delimitações 5

2 Referencial Teórico **6**
2.1 Formulação do Problema de Reposição 6
2.1.1 Política de Reposição: Estado, Ação e Parâmetros 6
2.1.2 Função Objetivo e Dinâmica de Estoque 7
2.2 Famílias de Políticas de Reposição 7
2.2.1 Políticas Clássicas 7
2.2.2 Parametrização de Políticas via Meta-Heurísticas 8
2.2.3 Políticas de Reposição via Aprendizado por Reforço 9
2.2.4 Políticas Híbridas GA-RL 9
2.3 Demanda Intermitente 10
2.3.1 Taxonomia ADI e CV quadrado 10
2.3.2 Efeitos na Reposição 11
2.4 Métricas de Previsão 11
2.4.1 Métricas Utilizadas 11
2.5 Testes Estatísticos 12
2.5.1 Teste de Wilcoxon 12
2.5.2 Teste de Friedman e Nemenyi 12
2.5.3 Tamanho de Efeito 13

3 Trabalhos Relacionados **14**
3.1 Famílias de métodos 14
3.2 Inventário e demanda intermitente 14
3.3 Previsão e utilidade operacional 15
3.4 Meta-heurísticas e aprendizado por reforço 16
3.5 Seleção de políticas e meta-aprendizado 16
3.6 Arquiteturas híbridas e posicionamento 17

4 Metodologia **18**
4.1 Visão geral e duas abordagens do PSE 18
4.2 Sistema de estoque e objetivo 19
4.2.1 Métricas e definição do serviço 19
4.3 Dados, preparo e cobertura 19
4.4 Características e perfis 20
4.5 Portfólio e calibração 21
4.5.1 Referências e busca de parâmetros 21
4.5.2 Reforço e híbrido 21
4.6 Separação temporal e comparação 22
4.7 Duas implementações do PSE 22
4.7.1 Associação e rótulos 22
4.7.2 Aprendizado e recuo conservador 23
4.7.3 Aplicação e reavaliação 23
4.8 Oráculos e decomposição das falhas 23
4.9 Incerteza e rastreabilidade 24

5 Resultados e Discussão **25**
5.1 Resultados: valor da seleção por perfil 25
5.1.1 Quais candidatas oferecem compromissos competitivos? 25
5.1.2 O perfil melhora a decisão frente à seleção global? 27
5.1.3 As escolhas e o atendimento são estáveis entre períodos? 28
5.2 Resultados no M5: duas abordagens do PSE 29
5.2.1 Custo e atendimento das recomendações 29
5.2.2 O que explica a dificuldade do preditivo? 30
5.2.3 Distância aos melhores resultados e fontes das falhas 31
5.3 Esforço computacional das políticas 31
5.4 Síntese das respostas e limites 32

6 Conclusões **34**
6.1 Respostas às questões de pesquisa 34
6.2 Contribuições e interpretação 35
6.3 Implicações 35

7 Continuidade e Validação Final **36**
7.1 Separar desenvolvimento e confirmação 36
7.2 Harmonizar o problema de decisão 36
7.3 Sensibilidades e eficiência 37
7.4 Critérios de fechamento 37

Referências **38**

Lista de Figuras

1.1 AIPE: caracterização da demanda, seleção e avaliação. O PSE associa o perfil informado a uma política ou estima a política a partir de características, com perfil opcional. Históricos e associações são ilustrativos. A utilidade da contextualização é avaliada em teste reservado. 3
5.1 Compromisso custo–serviço das sete candidatas na Bahia. Médias de teste em 290 casos série–origem para custo e 283 com demanda positiva para atendimento. A fronteira é descritiva: não utiliza o teste para escolher a recomendação nem representa dominância estatística ou por série. 26
5.2 Distribuição do atendimento das estratégias no teste, por origem. Cada caixa resume séries com demanda positiva; a linha tracejada indica 0,70. Há 144 casos por estratégia na primeira origem e 139 na segunda. As mesmas séries participam das duas estratégias; observações e origens não são independentes. . . . 28
5.3 Políticas escolhidas por perfil na validação das demais lojas, com meta 0,70. Cada painel contém 145 escolhas; os números indicam séries. A primeira origem diferencia grupos, enquanto a segunda recomenda sSCycle em todos eles. Nomes abreviados dos perfis correspondem às regras operacionais descritas no método. 29
5.4 Piloto M5: custo e atendimento médios são apresentados separadamente. Caixas descrevem o serviço nos 86 casos definidos; linha em 0,70. O recuo foi desenvolvido no piloto, sem confirmação independente. 30
5.5 Decomposição dos 90 casos M5. Erro de seleção: outra candidata atende. Lacuna do portfólio: nenhuma candidata atende, mas o planejamento perfeito permite atender. Limite físico: condições iniciais impedem atingir 0,70. Demanda zero mantém serviço indefinido. 31

Lista de Tabelas

2.1 Quadrantes de Syntetos-Boylan: limiares e interpretações. 10
3.1 Papel das famílias de métodos na pesquisa. 15
3.2 Relação entre linhas da literatura e o foco da dissertação. 17
4.1 Matrizes completas incluídas na avaliação. Sementes e origens são medidas repetidas. 20
4.2 Perfis: primeira regra satisfeita determina a classe. 20
5.1 Bahia, protocolo temporal: médias no teste de sete ciclos. Custo em unidades do cenário, calculado nos 290 casos. Atendimento médio e contagem abaixo da meta consideram os 283 casos com demanda positiva; sete casos têm atendimento indefinido. 26
5.2 Escolha na validação das demais lojas e avaliação no teste da loja reservada, com meta 0,70. Há 145 casos por linha; atendimento definido em 144 casos na origem 17 e 139 na origem 23. 27
5.3 M5: custo em 90 casos; atendimento e contagem de viáveis em 86 com demanda positiva. O recuo é exploratório, desenvolvido após o diagnóstico do piloto. . . . 29
5.4 Duração registrada dos ajustes executados na rodada Bahia. Tempos em segundos; médias e medianas por ajuste, sem os 54 reaproveitados. 32
7.1 Critérios de conclusão, sem datas ainda não acordadas. 37

Lista de Siglas

Sigla	Significado
AIPE	*Adaptive Inventory Policy Engine*; estrutura proposta para seleção contextual de políticas.
PSE	*Policy Selection Engine*; camada de seleção por perfil ou por modelo preditivo.
POD	Perfil Operacional de Demanda.
CTI	Custo Total de Inventário.
NS	Nível de Serviço: fração da demanda atendida.
TR	Taxa de Ruptura: fração de ciclos com falta.
BE	*Bullwhip Effect*: razão entre variâncias de pedidos e demanda.
FP	Frequência de Pedidos.
ADI	*Average Demand Interval*: intervalo médio entre demandas positivas.
CV	Coeficiente de Variação; CV^2 é seu quadrado.
SKU	*Stock Keeping Unit*: unidade de produto para controle de estoque.
EOQ	*Economic Order Quantity*: lote econômico de compra.
GA	*Genetic Algorithm*: algoritmo genético.
SA	*Simulated Annealing*: recozimento simulado.
DQN	*Deep Q-Network*: rede de valores de ação.
PPO	*Proximal Policy Optimization*: otimização de política com recorte.
RL / DRL	Aprendizado por reforço / aprendizado por reforço profundo.
GA-DQN	Política híbrida que combina GA e DQN.
LSTM	*Long Short-Term Memory*: rede recorrente com memória.
ANN	*Artificial Neural Network*: rede neural artificial.
ARIMA	*Autoregressive Integrated Moving Average*.
MASE	*Mean Absolute Scaled Error*.
sMAPE	*Symmetric Mean Absolute Percentage Error*.
RMSSE	*Root Mean Squared Scaled Error*.
ASP	*Algorithm Selection Problem*: problema de seleção de algoritmos.
M5	Competição de previsão baseada em vendas do Walmart.

1

Introdução

Uma rede varejista precisa decidir quando e quanto repor em cada loja. O problema se torna mais difícil quando um produto vende regularmente em uma unidade, mas passa vários ciclos sem venda em outra. Uma política que preserva disponibilidade no primeiro caso pode gerar excesso de estoque no segundo. Custos, faltas e variabilidade dos pedidos dependem da relação entre a regra de reposição e o comportamento da demanda (Axsäter, 2006; Syntetos and Boylan, 2005).

Esta dissertação investiga essa relação como um problema de seleção: dadas as características de uma série loja-produto e um portfólio de políticas, qual alternativa oferece menor custo sob uma exigência de serviço? A proposta recebe o nome de *Adaptive Inventory Policy Engine* (AIPE). Seu *Policy Selection Engine* (PSE) admite associação entre perfil e política e previsão supervisionada da política por série. As duas abordagens são avaliadas pelas consequências operacionais de suas recomendações.

1.1 Motivação

1.1.1 Reposição em redes varejistas

Diferenças de consumo, sazonalidade e condições logísticas dificultam o ajuste manual de estoques em redes com muitas lojas. Cada unidade decide sua reposição, mas seus pedidos também afetam o armazém. Lotes elevados podem reduzir a frequência de compra e aumentar o estoque; pedidos frequentes podem preservar disponibilidade e elevar custos fixos. A decisão envolve manutenção, falta, pedido e prazo de entrega (Axsäter, 2006; Zipkin, 2000).

A instabilidade dos pedidos acrescenta outra preocupação. Variações nas vendas podem produzir oscilações ainda maiores nas encomendas enviadas aos fornecedores, fenômeno conhecido como efeito chicote (Lee et al., 1997). Medir essa amplificação ajuda a avaliar consequências a montante, embora não substitua a análise conjunta de custo e serviço.

Considere dois históricos: um produto vende quantidades semelhantes a cada ciclo; outro apresenta a sequência “0, 0, 0, 50, 0, 0, 30”. No segundo caso, manter estoque para cobrir todos os picos pode ser caro, enquanto dimensioná-lo pela média pode aumentar as faltas. A demanda intermitente combina intervalos sem venda com ocorrências positivas; quando estas variam muito de tamanho, o padrão é chamado de *lumpy* (Croston, 1972; Syntetos and Boylan, 2005; Boylan and Syntetos, 2008).

Essas diferenças motivam comparar regras, mas não demonstram que um seletor por perfil será melhor que uma política única bem calibrada. A vantagem depende do portfólio, dos custos, do serviço exigido e da informação disponível antes da decisão. Uma escolha retrospectiva favorável pode desaparecer ao avaliar lojas ou períodos não usados no ajuste.

1.1.2 Da calibração à seleção de políticas

Políticas clássicas, meta-heurísticas e aprendizado por reforço oferecem formas distintas de decidir reposição. Uma meta-heurística pode ajustar o ponto de pedido e o lote de uma regra; um agente de reforço pode aprender ações a partir do estado do estoque. Antes desses ajustes, permanece a escolha de qual família utilizar (Syntetos et al., 2009; Boute et al., 2022).

O AIPE organiza essa escolha em quatro etapas: caracterizar a demanda, comparar políticas em um simulador comum, identificar alternativas viáveis segundo custo e serviço e investigar se essas diferenças orientam recomendações para novas séries. A formulação se aproxima da seleção de algoritmos, na qual características de uma instância ajudam a escolher um método (Rice, 1976; Kotthoff, 2014).

A previsão fornece informação auxiliar. Antecipar a demanda não determina automaticamente quando ou quanto pedir. Um modelo mais preciso tampouco garante menor custo de inventário. A avaliação principal deve ocorrer sobre as decisões de reposição e suas consequências operacionais.

A Figura 1.1 sintetiza a proposta: partir de séries heterogêneas, comparar um portfólio e avaliar a seleção contextual. O caminho entre essas etapas é uma hipótese a testar, não uma garantia de melhoria.

1.2 Problema e questões de pesquisa

A unidade de análise é a série de vendas de um produto em uma loja, agregada por ciclo comercial. As políticas decidem reposição sob condições comuns de demanda, custos e prazo. O critério de referência é o menor custo entre alternativas que atendam ao nível de serviço mínimo. Quando a restrição usa a média de um grupo, ela não garante atendimento mínimo para cada série.

A questão principal é: *características operacionais da demanda permitem selecionar políticas de reposição com melhor compromisso entre custo e serviço do que uma política única*



Figura 1.1: AIPE: caracterização da demanda, seleção e avaliação. O PSE associa o perfil informado a uma política ou estima a política a partir de características, com perfil opcional. Históricos e associações são ilustrativos. A utilidade da contextualização é avaliada em teste reservado.

aplicada à rede? A investigação se divide em três perguntas:

1. O desempenho relativo das políticas varia entre séries e perfis operacionais?
2. Características observadas antes da decisão permitem aprender uma relação útil entre perfil e política?
3. Essa relação mantém desempenho em novas lojas, produtos ou períodos?

A primeira pergunta trata de heterogeneidade; a segunda, de aprendizagem; a terceira, de generalização. Elas exigem evidências distintas. Encontrar vencedores diferentes na própria amostra não valida o PSE nem demonstra economia futura. Diferenças estatísticas entre políticas também não substituem a comparação entre estratégias de seleção.

As hipóteses correspondentes são que existe heterogeneidade operacional relevante, que parte dela é capturada pelas características das séries e que um seletor pode aproveitar essa informação fora da amostra. São hipóteses empíricas, não premissas da proposta. A avaliação da Bahia e o piloto M5 mostram benefícios condicionais da escolha por perfil e limites da implementação preditiva, sem estabelecer superioridade geral.

1.3 Objetivos

Objetivo geral

Propor e avaliar o AIPE como abordagem de seleção contextual de políticas de reposição para séries loja-produto, considerando custo de inventário, serviço e estabilidade dos pedidos em dados de uma rede varejista brasileira e em um recorte público do M5.

Objetivos específicos

1. Construir um ambiente comum para comparar políticas clássicas, meta-heurísticas, aprendizado por reforço e combinações desses métodos (Law, 2015; Talbi, 2009).
2. Preparar históricos e extrair características de intermitência, variabilidade, volume e comportamento temporal para análise por perfil.
3. Comparar política única e seleção por perfil, informando custo, serviço, casos inviáveis e sensibilidade às condições experimentais.
4. Desenvolver e validar o PSE com separação entre ajuste, escolha e avaliação, e comparar suas decisões com referências simples.
5. Examinar a validade externa em dados públicos de varejo e em recortes adicionais da base brasileira, preservando a rastreabilidade.

Os estudos da Paraíba e da qualificação motivaram o desenvolvimento. A evidência quantitativa consolidada compreende 145 séries da Bahia em duas origens e um piloto M5 com 30 séries nas dez lojas, em três origens. O capítulo de resultados separa as bases e suas condições. A rodada maior do M5 foi interrompida para construir o protocolo final; a expansão nacional foi cancelada e não integra as conclusões.

1.4 Contribuições e alcance da evidência

A contribuição metodológica é formular a escolha de políticas como seleção contextual apoiada por um portfólio avaliado em condições comuns. A contribuição empírica é estudar essa escolha em séries reais do varejo brasileiro e no piloto público M5, com os limites de cada avaliação identificados. A contribuição computacional é integrar preparação, caracterização, simulação e análise em um fluxo configurável.

GA, DQN, PPO e suas combinações são métodos conhecidos. Sua presença no portfólio não constitui novidade algorítmica; a arquitetura GA–DQN já aparece em Zabraoui et al. (2025). O interesse está em entender quando uma alternativa oferece vantagem e se essa informação sustenta uma recomendação verificável.

A infraestrutura permite avaliar separadamente controladores e seletores. Na Bahia, o PSE por perfil é confrontado com a global; no M5, a avaliação inclui o preditivo e uma extensão exploratória de recuo. O piloto não demonstra vantagem do modelo supervisionado e passa a integrar o desenvolvimento do protocolo final.

Cada política estocástica é ajustada com três sementes; referências determinísticas recebem um ajuste. Essas repetições descrevem variação do treinamento e não novas lojas ou demandas. A série e suas dependências por loja orientam a análise, como discutido nos capítulos de metodologia e resultados.

1.5 Escopo e delimitações

A pesquisa trata cada série loja-produto como uma decisão de reposição. Não modela substituição entre produtos, capacidade conjunta nem coordenação multiagente entre lojas e armazéns. O efeito chicote é um indicador complementar de variabilidade, não evidência de otimização de toda a rede.

O simulador avalia políticas sobre históricos preparados. Custos e abastecimento são parâmetros do cenário; roteamento, transporte e integração transacional com ERP ficam fora do escopo. A recomendação proposta é periódica e não troca de política a cada transação. Aprendizado por reforço multiagente, como o discutido por Liu et al. (2025), também não é implementado como coordenação da rede.

Os dados proprietários limitam a divulgação pública. A rastreabilidade depende de código, parâmetros e identificação dos artefatos e recortes. Vendas podem não representar toda a demanda quando há falta de estoque, e ciclos ausentes exigem tratamento cuidadoso. Essas limitações impedem interpretar automaticamente a simulação como ganho econômico realizável.

O Capítulo 2 apresenta os fundamentos; o Capítulo 3, a literatura; e o Capítulo 4, a implementação. O Capítulo 5 reúne as avaliações e seus diagnósticos. As conclusões estão no Capítulo 6, e a continuidade no Capítulo 7.

2

Referencial Teórico

A seleção de políticas de reposição exige distinguir três objetos: o processo de demanda, a regra que produz pedidos e o critério usado para comparar seus resultados. Este capítulo define esses objetos e apresenta os métodos de previsão e inferência utilizados no trabalho. A descrição operacional dos experimentos fica no Capítulo 4.

2.1 Formulação do Problema de Reposição

2.1.1 Política de Reposição: Estado, Ação e Parâmetros

Uma política π transforma o estado observado $\mathbf{s}_t$ em uma quantidade de pedido não negativa:

$$\pi : \mathcal{S} \to \mathcal{A}, \qquad Q_t = \pi(\mathbf{s}_t; \boldsymbol{\theta}).$$

O estado reúne estoque disponível, pedidos em trânsito e informações de demanda disponíveis até a decisão. Os parâmetros $\boldsymbol{\theta}$ podem ser limiares e lotes, no caso de regras analíticas, ou pesos de uma rede neural. Meta-heurísticas ajustam parâmetros de uma regra; aprendizado por reforço ajusta a própria representação da decisão. Todas essas alternativas precisam ser avaliadas sob a mesma dinâmica de estoque.

É necessário separar estoque físico de posição de estoque. O primeiro determina o atendimento imediato; a segunda acrescenta os pedidos em trânsito e evita solicitar novamente unidades já encomendadas. Uma previsão de demanda pode integrar o estado, mas não substitui essas informações. Um vetor reduzido também não garante que o processo seja Markoviano: essa propriedade depende de representar informação suficiente para suas transições.

2.1.2 Função Objetivo e Dinâmica de Estoque

Para um horizonte finito T, o problema conceitual consiste em minimizar o custo esperado:

$$\min_{\pi} \mathbb{E}\left[\sum_{t=1}^{T}\left(hI_t + c_s S_t + c_o^{\text{fix}}\mathbf{1}(Q_t > 0) + c_o^{\text{var}} Q_t\right)\right]. \tag{2.1}$$

I_t é o estoque após atendimento, S_t a demanda perdida, h o custo de manutenção por unidade e ciclo, c_s o custo por unidade não atendida e c_o^{fix}, c_o^{var} os custos fixo e variável de pedido. A esperança representa incerteza da demanda ou do treinamento; repetir uma trajetória determinística não estima essa distribuição.

Se B_t é o estoque antes da chegada e A_t a quantidade recebida no ciclo, a dinâmica de vendas perdidas é

$$S_t = \max(0, D_t - B_t - A_t), \quad I_t = \max(0, B_t + A_t - D_t), \quad B_{t+1} = I_t. \tag{2.2}$$

A demanda não atendida não se acumula como encomenda pendente. A convenção de chegada deve acompanhar a equação: um modelo com prazo efetivo ℓ usa $A_t = Q_{t-\ell}$, como na avaliação temporal principal, com entrega efetiva em dois ciclos. Nos estudos históricos, a fila de tamanho $L+1$ correspondia à chegada em $t+L+1$. As convenções são identificadas separadamente na metodologia.

Minimizar custo sem restrição pode favorecer uma política que quase nunca repõe. Por isso, o trabalho acrescenta um nível mínimo de serviço. A escolha do limiar expressa um compromisso operacional e deve anteceder a comparação. Custos e serviço precisam ser apresentados conjuntamente, pois uma economia obtida com menor atendimento não caracteriza dominância.

2.2 Famílias de Políticas de Reposição

2.2.1 Políticas Clássicas

As políticas clássicas oferecem referências interpretáveis. Sob demanda constante média μ por ciclo, custo fixo K por pedido e manutenção h por unidade e ciclo, o lote econômico é

$$Q^* = \sqrt{2K\mu/h}.$$

Demanda e manutenção devem usar a mesma unidade temporal. A EOQ define o tamanho do lote; um ponto de pedido separado estabelece quando solicitá-lo. Com estoque de segurança, esse ponto pode ser $s = \mu L + z\sigma\sqrt{L}$, sob aproximações sobre demanda e prazo. A implementação histórica será distinguida dessa fórmula porque emprega uma demanda acumulada no

horizonte.

A política (s,S) observa a posição de estoque P_t e pede $\max(0,S-P_t)$ quando $P_t \leq s$. O limiar inferior evita pedidos a cada pequena redução de estoque; o superior determina a recomposição. A concentração de pedidos em lotes pode amplificar a variabilidade a montante, fenômeno associado ao efeito chicote (Lee et al., 1997). A intensidade desse efeito depende dos parâmetros e da demanda, não apenas do nome da política.

O modelo do Jornaleiro determina uma quantidade de período único pelo quantil de demanda associado à razão crítica entre falta e excesso. Na aproximação normal, escreve-se $Q^* = \mu + z_\alpha \sigma$. Essa expressão é ótima somente sob as hipóteses do modelo e com α derivado dos custos pertinentes. Usar $z = 1{,}28$ como parâmetro fixo em uma regra multiperíodo constitui uma heurística inspirada no modelo, não uma garantia de otimalidade.

Regras analíticas podem receber parâmetros específicos por série e, portanto, não pressupõem necessariamente uma única parametrização para toda a rede. Sua simplicidade é uma vantagem comparativa relevante: um método mais complexo precisa demonstrar ganho além do obtido por calibração adequada de uma referência simples.

2.2.2 Parametrização de Políticas via Meta-Heurísticas

Meta-heurísticas procuram vetores $\boldsymbol{\theta}$ em um espaço de busca. Cada candidato induz uma política, cuja execução simulada fornece custo e serviço. Essa abordagem dispensa uma expressão diferenciável para o desempenho, mas continua sujeita a sobreajuste ao histórico usado na busca. O objetivo, os limites dos parâmetros e o orçamento de avaliações devem ser controlados na comparação.

O Algoritmo Genético (GA) mantém uma população de candidatos e alterna seleção, cruzamento e mutação (Holland, 1992; Talbi, 2009). Em reposição, cromossomos podem codificar ponto de pedido e lote; a avaliação associa cada vetor à trajetória resultante (Yuna et al., 2023). Não há garantia geral de ótimo global em orçamento finito.

O Recozimento Simulado (SA) parte de uma solução e explora vizinhos. Uma piora ΔC pode ser aceita com probabilidade $\exp(-\Delta C/T_k)$, em que T_k é a temperatura (Kirkpatrick et al., 1983). Seu resfriamento controla a passagem de exploração para busca local. O resultado depende da escala da função objetivo, da vizinhança e do número de iterações.

Na Otimização por Enxame de Partículas (PSO), cada posição representa um candidato; velocidade, melhor posição individual e melhor posição coletiva orientam a atualização (Kennedy and Eberhart, 1995). A Evolução Diferencial (DE) gera candidatos pela combinação de diferenças entre vetores e aplica cruzamento e seleção (Storn and Price, 1997). Ambos são alternativas para espaços contínuos, mas não constituem, por si, regras operacionais distintas de reposição.

Mesmo quando duas buscas ajustam a mesma regra, seus custos computacionais e soluções podem diferir. A comparação deve identificar qual parte do ganho decorre do algoritmo

de busca e qual decorre da regra parametrizada. Otimizar cada série também é diferente de selecionar, entre políticas já calibradas, qual deve ser aplicada a uma nova série.

2.2.3 Políticas de Reposição via Aprendizado por Reforço

O aprendizado por reforço representa o controle como um processo de decisão $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$. O agente escolhe pedidos, recebe uma recompensa e observa a transição do inventário. Com recompensa $r_t = -C_t$, busca maximizar o retorno descontado $\sum_t \gamma^t r_t$ (Sutton and Barto, 2018). Uma restrição de serviço não é automaticamente satisfeita por essa recompensa: precisa de tratamento explícito ou verificação posterior.

DQN aproxima a função de valor $Q_\theta(s,a)$ por uma rede neural, usando memória de experiências e rede-alvo (Mnih et al., 2015). Sua aplicação requer ações discretizadas. A resolução dessa discretização limita os lotes disponíveis; episódios adicionais sobre a mesma série aumentam interações simuladas, mas não acrescentam novas realizações independentes de demanda.

PPO atualiza uma política por gradiente com uma razão de probabilidades limitada por *clipping* (Schulman et al., 2017). Pode ser formulado com ações contínuas ou discretas; essa propriedade precisa ser informada para cada implementação. Comportamentos como pedidos excessivos ou ausência de reposição podem resultar da recompensa, da escala dos estados, da exploração ou do treinamento. A observação de uma trajetória degenerada não identifica isoladamente sua causa.

SARSA atualiza valores seguindo a própria política:

$$Q(s,a) \leftarrow Q(s,a) + \eta[r + \gamma Q(s',a') - Q(s,a)].$$

A versão tabular exige discretizar o estado; Expected SARSA substitui o próximo valor pela esperança sobre ações. A adequação de cada representação depende da informação preservada e do tamanho do problema, e não permite concluir antecipadamente que uma família será superior nas séries estudadas.

2.2.4 Políticas Híbridas GA-RL

Uma arquitetura híbrida usa a busca evolutiva para obter parâmetros ou experiências iniciais e depois ajusta uma política por reforço. No GA–DQN, transições geradas com a política do GA podem preencher a memória do agente antes do refinamento. Trata-se de uma hipótese de melhoria da inicialização; seu benefício exige comparação com os componentes isolados e controle dos respectivos orçamentos.

A inicialização não elimina o risco de sobreajuste. Se busca e aprendizado observarem a mesma trajetória usada na avaliação, o resultado descreve adaptação ao histórico, não generalização. Além disso, avaliações completas de candidatos do GA e transições armazenadas

no DQN são quantidades diferentes. O trabalho trata o híbrido como candidato do portfólio; o problema de pesquisa é a seleção contextual entre candidatos.

2.3 Demanda Intermitente

Uma série intermitente alterna ciclos sem demanda e ocorrências positivas, cujos tamanhos também podem variar (Croston, 1972; Boylan and Syntetos, 2008). Frequência e magnitude são dimensões distintas. Para $D_t \geq 0$, definem-se

$$n_+ = |\{t : D_t > 0\}|, \tag{2.3}$$

$$\mu = T^{-1}\sum_t D_t, \qquad \sigma^2 = (T-1)^{-1}\sum_t (D_t - \mu)^2. \tag{2.4}$$

A média sobre todos os ciclos descreve o volume por período, mas pode ocultar longos intervalos sem venda. Uma sequência com valores positivos estáveis e muitos zeros é operacionalmente diferente de outra igualmente esparsa, porém com grandes picos.

2.3.1 Taxonomia ADI e CV^2

A classificação de Syntetos and Boylan (2005) combina intervalo médio entre demandas e variação dos tamanhos positivos:

$$\mathrm{ADI} = T/n_+, \tag{2.5}$$

$$\mathrm{CV}_+^2 = (\sigma_+/\mu_+)^2. \tag{2.6}$$

Aqui, μ_+ e σ_+ são calculados apenas nas observações positivas, diferentemente da média e variância da Equação 2.4. Os limiares 1,32 e 0,49 delimitam quatro categorias, resumidas na Tabela 2.1 (Syntetos et al., 2009).

Tabela 2.1: Quadrantes de Syntetos-Boylan: limiares e interpretações.

Regime	ADI	CV^2	Interpretação operacional
Smooth (Regular)	$< 1{,}32$	$< 0{,}49$	Alta frequência, demanda estável.
Erratic (Errático)	$< 1{,}32$	$\geq 0{,}49$	Alta frequência, magnitude irregular.
Intermittent (Intermitente)	$\geq 1{,}32$	$< 0{,}49$	Muitos zeros, magnitude relativamente estável.
Lumpy (Grumoso)	$\geq 1{,}32$	$\geq 0{,}49$	Muitos zeros e magnitude altamente irregular.

A implementação disponível também calcula uma medida de CV^2 incluindo zeros. Essa medida é útil como característica, mas não reproduz exatamente a definição original dos tamanhos positivos. As categorias dos artefatos são mantidas como rótulos operacionais, com essa ressalva; uma comparação entre taxonomias exige recalcular explicitamente ambos os índices.

2.3.2 Efeitos na Reposição

Demanda esparsa dificulta estimar taxas de ocorrência; tamanhos irregulares ampliam o custo de errar lotes e estoques de segurança. Croston separa a estimação dos tamanhos positivos e dos intervalos entre ocorrências. Isso pode melhorar a previsão, mas não estabelece qual regra de reposição minimiza custo sob um prazo e uma restrição de serviço específicos.

Os quadrantes fornecem uma descrição inicial, não uma prescrição de política. Séries no mesmo quadrante podem diferir em volume, tendências, sequências de zeros e concentração de picos. A hipótese do AIPE é que essas diferenças adicionais possam auxiliar a escolha; sua utilidade precisa ser medida contra uma política global bem calibrada, não inferida da classificação.

2.4 Métricas de Previsão

Erros absolutos e quadráticos dependem da escala da série; o MAPE é indefinido quando a demanda observada é zero. O estudo emprega métricas escaladas e sMAPE, com convenções explícitas para denominadores nulos (Hyndman and Koehler, 2006; Makridakis et al., 2020). Nenhuma métrica de previsão substitui a avaliação do efeito da decisão sobre custo e serviço.

2.4.1 Métricas Utilizadas

Sejam $e_t = D_t - \hat{D}_t$ os erros em m pontos de avaliação e $d_1, \ldots, d_n$ o treinamento. O MASE compara o erro absoluto com a variação da referência ingênua:

$$\mathrm{MASE} = \frac{m^{-1} \sum_t |e_t|}{(n-1)^{-1} \sum_{j=2}^{n} |d_j - d_{j-1}|}. \tag{2.7}$$

Valores menores que um indicam erro inferior à escala ingênua (Hyndman and Koehler, 2006). A escala deve vir do treino; séries constantes requerem registro de indefinição ou regularização declarada. A presença de zeros, isoladamente, não impede o cálculo.

O sMAPE usa demanda e previsão simetricamente (Makridakis, 1993):

$$\mathrm{sMAPE} = \frac{200}{m} \sum_t \frac{|D_t - \hat{D}_t|}{|D_t| + |\hat{D}_t|} \,\%. \tag{2.8}$$

Adota-se contribuição zero quando ambos os termos do denominador são nulos. Seu intervalo é de zero a 200%, mas pequenas demandas podem produzir valores elevados; por isso é interpretado junto ao MASE.

A versão quadrática escalada é

$$\mathrm{RMSSE} = \sqrt{\frac{m^{-1}\sum_t e_t^2}{(n-1)^{-1}\sum_{j=2}^{n}(d_j - d_{j-1})^2}}. \tag{2.9}$$

Ela dá maior peso a erros grandes e também requer escala de treino não nula. O RMSSE complementa o diagnóstico; o MASE permanece a referência principal de comparação de previsão no estudo.

O viés médio, $\mathrm{MBE} = \overline{D} - \overline{\hat{D}}$, diferencia subestimação de superestimação. O U de Theil compara RMSE do modelo e da previsão ingênua (Theil, 1966). Esses indicadores auxiliam a interpretação, sem determinar a política vencedora. Uma relação entre menor erro e melhor reposição é hipótese empírica: depende da assimetria de custos, do prazo e da regra de decisão.

2.5 Testes Estatísticos

A comparação usa observações pareadas porque as políticas atendem às mesmas séries. Testes não paramétricos evitam exigir normalidade dos KPIs, mas não dispensam atenção à independência das unidades. Produtos da mesma loja e lojas expostas às mesmas condições podem ser dependentes. Repetições idênticas não aumentam o tamanho efetivo da amostra.

2.5.1 Teste de Wilcoxon

Para diferenças $\Delta_i = X_i^A - X_i^B$, a soma de postos com sinal é

$$W = \sum_{i:\Delta_i \neq 0} \mathrm{sgn}(\Delta_i) R_i, \tag{2.10}$$

em que R_i é o posto de $|\Delta_i|$. O teste de Wilcoxon (1945) avalia uma hipótese de localização sob condições sobre a distribuição das diferenças. Sua leitura como teste da mediana requer, em particular, simetria. Empates e diferenças nulas devem receber tratamento documentado.

2.5.2 Teste de Friedman e Nemenyi

Com K políticas avaliadas nas mesmas N instâncias, o teste de Friedman (1940) compara postos médios:

$$\chi_F^2 = \frac{12N}{K(K+1)} \sum_{j=1}^{K} \left(\bar{r}_j - \frac{K+1}{2} \right)^2. \tag{2.11}$$

A rejeição não identifica sozinha os pares diferentes. O procedimento de Nemenyi usa uma diferença crítica (Nemenyi, 1963):

$$\mathrm{DC} = q_\alpha \sqrt{\frac{K(K+1)}{6N}}. \tag{2.12}$$

Postos separados por mais que DC são distinguidos sob as condições do procedimento. Um posto favorável em custo não representa necessariamente serviço aceitável; as métricas e os limiares precisam permanecer visíveis.

2.5.3 Tamanho de Efeito

A diferença padronizada de médias é reportada como descrição complementar (Cohen, 1988):

$$d = \frac{\bar{X}_A - \bar{X}_B}{s_{\mathrm{pooled}}}, \qquad s_{\mathrm{pooled}} = \sqrt{\frac{(N_A-1)s_A^2 + (N_B-1)s_B^2}{N_A + N_B - 2}}. \tag{2.13}$$

Essa forma não utiliza a covariância do pareamento; medidas baseadas nas diferenças podem ser mais apropriadas para inferência pareada. Faixas convencionais de efeito pequeno, médio ou grande não substituem a diferença de custo em unidades operacionais e sua repercussão no serviço.

O conjunto de testes, efeitos e gráficos descreve a heterogeneidade observada. Não transforma uma escolha retrospectiva de vencedor em evidência de generalização. Essa distinção orienta o protocolo de validação do próximo capítulo: a avaliação de uma política e a avaliação do mecanismo que a seleciona são etapas diferentes.

3

Trabalhos Relacionados

A literatura fornece métodos para prever demanda, calibrar regras e aprender decisões de reposição. A questão desta dissertação é como escolher entre essas alternativas para uma série loja-produto. A revisão distingue o desempenho de uma política da capacidade de um seletor de reconhecer quando utilizá-la.

3.1 Famílias de métodos

Políticas clássicas têm formulações interpretáveis e constituem referências necessárias, mesmo quando se avaliam métodos de aprendizado (Axsäter, 2006; Zipkin, 2000). Meta-heurísticas exploram seus parâmetros; agentes de reforço aprendem ações sequenciais; e a seleção de algoritmos escolhe métodos a partir de características das instâncias. São níveis complementares, não substitutos automáticos.

A Tabela 3.1 resume seu papel no problema estudado. As limitações indicadas são questões de avaliação: não significam que toda implementação de uma família apresente o mesmo comportamento.

3.2 Inventário e demanda intermitente

Clark and Scarf (1960) estabelecem resultados de decomposição para sistemas multi-escalão sob hipóteses específicas. Os textos de Axsäter (2006) e Zipkin (2000) consolidam políticas, custos e medidas de serviço. Para estoques de segurança em redes, o modelo de serviço garantido e suas extensões oferecem outra linha de planejamento (Graves and Willems, 2000; Eruguz et al., 2016; Achkar et al., 2024). Esses resultados não dispensam verificar se demanda, abastecimento e coordenação correspondem ao caso aplicado.

Tabela 3.1: Papel das famílias de métodos na pesquisa.

Família	Decisão ou informação produzida	Questão de avaliação
Políticas clássicas	Quando e quanto pedir por uma regra explícita	Adequação e calibração ao cenário
Previsão	Estimativa de demanda ou de sua distribuição	Efeito da previsão sobre custo e serviço
Meta-heurísticas	Parâmetros de uma política escolhida	Custo de busca e validade fora do ajuste
Aprendizado por reforço	Ação condicionada ao estado	Recompensa, estabilidade e generalização
Seleção de políticas	Escolha de um membro do portfólio	Ganho incremental frente à referência global

A demanda intermitente requer atenção à frequência e ao tamanho das ocorrências. Croston (1972) separam esses componentes na previsão. A classificação ADI$\times$CV^2 diferencia padrões suaves, erráticos, intermitentes e *lumpy* (Syntetos and Boylan, 2005). Essa descrição organiza séries, mas não determina a política de menor custo: o resultado depende também de prazo, custos e serviço exigido.

A revisão de de Kok et al. (2018) mostra a diversidade de estruturas consideradas na otimização multi-escalão. Nesta dissertação, porém, as séries são simuladas como decisões locais. Não se reivindica a otimização conjunta de uma rede geral, nem se transfere uma garantia teórica de otimalidade para um cenário que não atende às hipóteses originais.

3.3 Previsão e utilidade operacional

Históricos com muitos zeros tornam problemático o uso de erros relativos divididos pela demanda observada. O MASE permite comparação entre escalas quando seu denominador é definido, mas séries constantes também exigem tratamento (Hyndman and Koehler, 2006). Métricas de previsão devem ser acompanhadas de convenções para casos degenerados, sem substituir a avaliação de inventário.

Estudos em varejo mostram que o desempenho preditivo depende da granularidade, dos dados e da forma de treinamento (Makridakis et al., 2020; Nasseri et al., 2023). Não há razão para supor que uma rede LSTM será sempre superior a modelos simples em históricos curtos. Um resultado de competição de previsão tampouco demonstra vantagem em custo de reposição.

Tadayonrad and Ndiaye (2023) aproximam a avaliação preditiva de custos e serviço. Essa conexão orienta o AIPE: previsões e seus erros fornecem sinais auxiliares, mas a seleção deve ser julgada pelas consequências da decisão. Para evitar informação futura, previsão, características e calibração precisam respeitar o mesmo corte temporal da avaliação.

3.4 Meta-heurísticas e aprendizado por reforço

Meta-heurísticas procuram soluções em espaços de parâmetros difíceis de tratar analiticamente (Talbi, 2009). Em inventário, permitem ajustar ponto de pedido e lote. Yuna et al. (2023) estudam otimização de parâmetros em demanda intermitente, enquanto Erkayman et al. (2025) combinam modelagem da demanda e busca de parâmetros. O ganho permanece condicionado à política e ao cenário de calibração.

Aprendizado por reforço formula reposição como decisão sequencial. Oroojlooyjadid et al. (2022) estudam DQN no *Beer Game*; Gijsbrechts et al. (2022) discutem aplicações de aprendizado profundo a inventário; e Vanvuchelen et al. (2020) aplicam PPO à reposição conjunta. Outros trabalhos investigam topologias e coordenação descentralizada (Geevers et al., 2024; Liu et al., 2025).

Esses estudos mostram possibilidades de controle adaptativo, mas a aplicação depende de estado, ação, recompensa e dinâmica do simulador. Um agente pode obter serviço elevado emitindo pedidos excessivos ou reduzir custo deixando de atender demanda. Custo, serviço e comportamento das ações precisam ser examinados em conjunto.

Históricos curtos restringem a avaliação, embora o número de ciclos observados não seja igual ao número possível de interações simuladas. Repetir episódios pode ampliar treinamento sem adicionar novos processos de demanda. Comportamento degenerado em uma implementação não demonstra incapacidade geral do algoritmo: pode refletir recompensa, orçamento, parametrização ou erro de código. Essa cautela importa ao interpretar resultados antigos após correções do ambiente.

3.5 Seleção de políticas e meta-aprendizado

Rice (1976) formalizam a escolha de um algoritmo a partir das características de uma instância. Revisões posteriores descrevem seletores supervisionados e sua avaliação (Kotthoff, 2014; Kerschke et al., 2019). No AIPE, a instância é a série loja-produto, o portfólio reúne políticas e a medida de desempenho combina custo e viabilidade de serviço.

A analogia separa três objetos: o melhor método global, o melhor método conhecido para cada instância e o método escolhido pelo seletor. O segundo é uma referência retrospectiva; não é implementável quando sua escolha exige conhecer resultados futuros. O terceiro deve ser avaliado em dados que não determinaram os rótulos ou o ajuste.

O teorema *No Free Lunch* trata de médias sobre classes de problemas sob condições próprias (Wolpert and Macready, 1997). Ele não prova que haverá troca de vencedores neste recorte varejista nem que as características escolhidas permitirão aprendê-la. Essas são questões empíricas. Características de instância podem ajudar na seleção (Kerschke and Trautmann, 2019), mas sua utilidade precisa ser verificada no problema aplicado.

Hiper-heurísticas selecionam ou geram heurísticas, inclusive durante a resolução (Drake

et al., 2020; Dokeroglu et al., 2024). O AIPE tem escopo mais restrito: propõe recomendar periodicamente uma política por série. Não troca controladores a cada estado do estoque nem coordena agentes em tempo real. Trabalhos com *bandits* e contexto investigam outras formas de adaptação em inventário (Preil and Krapp, 2022; Batsis and Samothrakis, 2024); abordagens integradas relacionam características e decisões em outros desenhos operacionais (Qi et al., 2023).

A consequência prática é comparar o seletor com uma referência global forte. A avaliação deve separar o ajuste das políticas da aprendizagem da escolha entre elas. Excluir uma loja do seletor, por exemplo, não elimina informação futura já usada para gerar seus resultados de simulação.

3.6 Arquiteturas híbridas e posicionamento

Zabraoui et al. (2025) combinam busca genética e aprendizado por reforço em um estudo de inventário com dados do Walmart M5. É uma referência próxima do portfólio adotado aqui. A arquitetura GA–DQN e combinações GA–RL não são apresentadas como invenções desta dissertação. Sua inclusão permite investigar se oferecem vantagem em determinados recortes e como se comparam a regras simples sob condições comuns.

A Tabela 3.2 situa o foco da pesquisa sem equiparar bases, contagens de políticas ou protocolos diferentes. Uma comparação quantitativa direta exigiria reproduzir custos, horizontes, demandas e critérios de serviço.

Tabela 3.2: Relação entre linhas da literatura e o foco da dissertação.

Referência	Foco	Relação com esta pesquisa
Oroojlooyjadid et al. 2022	Aprender controle sequencial	Política candidata, não seletor validado
Yuna et al. 2023	Calibrar em demanda intermitente	Busca de parâmetros dentro do portfólio
Zabraoui et al. 2025	Comparação e combinação de algoritmos	Referência das arquiteturas avaliadas
Rice 1976; Kotthoff 2014	Selecionar métodos por instância	Base conceitual do PSE
Esta dissertação	Seleção contextual em varejo brasileiro	Comparar seleção e referência global

O espaço de investigação está na avaliação dessa seleção em séries reais do recorte brasileiro e na integração de um protocolo rastreável. Não se afirma que selecionar políticas seja uma ideia inédita em inventário nem que a revisão esgote a literatura. O resultado deve ser uma evidência verificável sobre o ganho incremental da seleção, inclusive quando for pequeno ou ausente. O capítulo seguinte apresenta os dados, o ambiente e o protocolo para investigar essa questão.

4

Metodologia

O AIPE organiza quatro decisões: preparar a série, caracterizar sua demanda, calibrar candidatas e selecionar uma política. A Figura 1.1 apresenta essa arquitetura. A unidade de decisão é a série loja–produto, não a rede inteira. Identificadores de armazém, loja e produto garantem rastreabilidade; não tornam a simulação um modelo integrado de múltiplos escalões.

4.1 Visão geral e duas abordagens do PSE

O *Policy Selection Engine* (PSE) é a camada de escolha do AIPE. Há duas abordagens. O **PSE por perfil** recebe um perfil informado e consulta uma associação entre grupo e política, construída com resultados de validação. O **PSE preditivo** aprende a estimar a política por série a partir de características numéricas; o perfil pode ser uma entrada adicional. Portanto, PSE não é sinônimo de classificador. O modelo supervisionado é uma de suas implementações.

Se x_i descreve a série e g_i seu perfil, a primeira abordagem recomenda $m(g_i)$ e a segunda $f(x_i, g_i)$ ou $f(x_i)$ na ablação. A referência global mantém uma mesma família para todas as séries da loja avaliada. Em todas elas, os parâmetros do controlador são calibrados no histórico da própria série. O contraste mede diferenciação da família, não presença ou ausência de ajuste individual. A aplicação pretendida reutiliza evidências de outras séries para recomendar uma família antes de compará-las todas novamente. Na avaliação, o portfólio completo é ajustado na série reservada para medir consequências e oráculos. Não se demonstrou redução de custo computacional em implantação.

Há dois usos distintos de aprendizado: um agente de reforço aprende pedidos; o preditivo aprende qual controlador recomendar. Melhorar o agente não valida o seletor. Encontrar vencedoras distintas também não prova que suas identidades sejam previsíveis no futuro (Rice, 1976; Kotthoff, 2014).

4.2 Sistema de estoque e objetivo

O ambiente simula vendas perdidas com prazo exato de dois ciclos. A política decide antes do recebimento; entregas chegam antes da demanda. Faltas não são acumuladas como pedidos pendentes. Quantidades não negativas podem ser fracionárias. Não há restrição conjunta de transporte, transbordo ou disputa entre lojas por estoque.

O custo da Equação 2.1 soma manutenção do saldo após atendimento, falta, emissão e quantidade pedida. Os valores são $h = 1$, $c_s = 5$, $c_o^{\text{fix}} = 50$ e $c_o^{\text{var}} = 0{,}5$, sem crédito terminal. São unidades de cenário, sem calibração financeira. Pedidos em trânsito não atendem demanda antes da chegada.

4.2.1 Métricas e definição do serviço

Registram-se custo total de inventário (CTI), atendimento (NS), taxa de ruptura (TR), frequência de pedidos (FP) e amplificação de variância (BE):

$$\text{NS} = \frac{\sum_t (D_t - S_t)}{\sum_t D_t}, \qquad \text{TR} = \frac{\#\{t : S_t > 0\}}{T}, \qquad \text{FP} = \frac{\#\{t : Q_t > 0\}}{T}.$$

Aqui, S_t é falta e BE é $\text{Var}(Q)/\text{Var}(D)$, com convenção registrada para variância nula. NS é fração de unidades atendidas, não probabilidade de um ciclo sem falta. Demanda total zero mantém NS indefinido; o custo continua na análise.

O limiar é 0,70. A média por série, a razão entre unidades totais atendidas e demandadas e a garantia de 0,70 em cada série não são equivalentes. Por isso, reportamos custo, média de NS, atendimento ponderado quando disponível e contagem de violações. Custo baixo com pouco atendimento não caracteriza eficiência operacional.

4.3 Dados, preparo e cobertura

A avaliação proprietária utiliza 145 séries da Bahia, em 115 lojas e nove produtos, com 38 ciclos de 202301 a 202504. Registros complementares são somados por armazém, loja, produto e ciclo; ciclos sem venda recebem zero. A coorte mantém identificadores históricos. Em cada origem, exige-se pelo menos três ciclos positivos no treino. Esse requisito é passado-dependente, mas não torna prospectiva a seleção inicial dos identificadores.

O piloto M5 utiliza 30 séries FOODS das dez lojas, com três por loja. O sorteio usa três estratos de volume médio do prefixo de 50 ciclos, com uma escolha por estrato e semente 20261015. As 30 séries permanecem nas origens 50, 64 e 78. São ciclos completos de 21 dias, sem corte de picos por IQR. O sorteio parte das 885 elegíveis na primeira origem da coorte histórica local de 2.408 IDs, sem representar todas as FOODS ou séries elegíveis somente depois.

Tabela 4.1: Matrizes completas incluídas na avaliação. Sementes e origens são medidas repetidas.

Dimensão	Bahia	Piloto M5
Séries / lojas	145 / 115	30 / 10
Origens do treino	17 e 23	50, 64 e 78
Validação / teste	7 / 7 ciclos	7 / 7 ciclos
Casos série–origem	290	90
Ajustes de políticas	4.350	1.350
Testes com demanda positiva	283	86

Vendas podem omitir demanda censurada por ruptura. Reindexar ausência de venda como zero pressupõe cobertura da fonte, não prova ausência de procura. Os dados brasileiros são restritos; M5 é público. O recorte local é inspirado no contexto de Zabraoui et al. (2025), sem identidade comprovada de filtros, amostra ou implementação.

4.4 Características e perfis

O preditivo recebe 17 características: ADI, CV^2, intermitência, proporção de zeros, maior e média das sequências de zeros, burstiness, assimetria, curtose, entropia, tendência, autocorrelação, média, desvio-padrão, CV, extensão e número de ciclos positivos. Todas usam somente o treino; perfil e metadados não alteram essa restrição temporal.

A característica CV^2 inclui zeros, diferindo da taxonomia original baseada em tamanhos positivos (Seção 2.3.1). Burstiness é $(s_\tau - \bar{\tau})/(s_\tau + \bar{\tau} + 10^{-9})$ nos intervalos entre ocorrências positivas, recebendo zero com menos de dois intervalos (Goh and Barabási, 2008). Tendência é a inclinação OLS dividida pela média regularizada; entropia usa dez classes de mesma largura. Autocorrelação na defasagem 17 recebe zero com até 18 ciclos ou variância desprezível. Zero nessa condição significa estimativa indisponível.

Tabela 4.2: Perfis: primeira regra satisfeita determina a classe.

Perfil	Condição
Sparse High Impact	ADI $\geq 1{,}32$, $CV^2 \geq 0{,}49$, sequência de zeros ≥ 5
High Volatility Seasonal	Autocorrelação $\geq 0{,}25$ ou burstiness $\geq 0{,}30$
Unstable Trend	Tendência absoluta $\geq 0{,}05$ ou entropia ≥ 2
Low Volume Stable	Média ≤ 2, $CV^2 < 0{,}49$
Fast Moving	ADI $< 1{,}32$

Os nomes são heurísticos; casos não cobertos recebem Sparse High Impact. Não se assume sazonalidade ou impacto econômico empiricamente comprovados. A coluna de política previamente associada aos nomes no código não gera os rótulos do experimento: custos e serviço na validação definem a escolha.

4.5 Portfólio e calibração

EOQCycle, sSCycle, CappedBaseStock, GA, PPO, GA–DQN e DQN compõem o portfólio. DQN é controle necessário do híbrido. Outros métodos preservados no projeto não são resultados adicionais desta matriz. A composição privilegia diversidade de regras; sua retirada do escopo não estabelece inferioridade universal.

4.5.1 Referências e busca de parâmetros

Com média $\hat{\mu}$ e desvio populacional $\hat{\sigma}$ do treino, as escalas são

$$I_0 = \hat{\mu}L + 1{,}28\hat{\sigma}\sqrt{L}, \tag{4.1}$$

$$Q_{\text{ref}} = \max(1, \sqrt{2\hat{\mu}c_o^{\text{fix}}/h}), \tag{4.2}$$

$$s_{\text{ref}} = \hat{\mu}L + 1{,}28\hat{\sigma}\sqrt{L}. \tag{4.3}$$

EOQCycle pede lote fixo ao atingir o ponto; sSCycle repõe até $s_{\text{ref}} + Q_{\text{ref}}$. Não se alega otimização exata de (s, S). CappedBaseStock calibra alvo e teto em grade 20×12, motivada pela família de Xin (2021).

GA ajusta gatilho, lote e proteção adicional com 100 indivíduos e 50 gerações. Seu objetivo acrescenta penalidade pelo déficit de serviço à referência

$$\boldsymbol{\theta}_i^* = \arg\min_{\boldsymbol{\theta}\in\Theta_i} \text{CTI}(\pi_{\boldsymbol{\theta}}, i) \quad \text{sujeito a } \text{NS}(\pi_{\boldsymbol{\theta}}, i) \geq 0{,}70. \tag{4.4}$$

Penalização não garante viabilidade; o serviço observado deve ser conferido. Na Bahia, a calibração da CappedBaseStock também utiliza ruptura e amplificação dos pedidos com pesos unitários; no M5, esses pesos são zero. As matrizes representam instanciações específicas, sem equivalência plena entre objetivos de treino.

4.5.2 Reforço e híbrido

DQN utiliza Double DQN dueling e PPO utiliza otimização proximal, com duas camadas de 64 unidades e 20 ações discretas. O estado reúne estoque, referência ingênua de demanda, pedidos em trânsito, média e dispersão dos últimos seis ciclos e posição no horizonte. Escalas vêm do treino; observações são passadas. Previsores especializados disponíveis no projeto não alimentam os resultados reportados.

O orçamento mínimo é de 20 mil transições, arredondado ao episódio completo. GA–DQN acrescenta a busca genética e mil demonstrações. Acima do gatilho genético, pede zero; abaixo, executa o máximo entre a ação da rede e metade do lote genético. Essa transformação é igual em demonstração, treino e aplicação. O esforço excede o do DQN; não se isola

causalmente o benefício da combinação (Zabraoui et al., 2025).

GA, PPO, DQN e GA–DQN usam sementes 11, 29 e 47; as referências determinísticas têm um ajuste. Primeiro promediamos as sementes dentro de série, origem e política. Elas representam variação do treinamento, não novas realizações de demanda.

4.6 Separação temporal e comparação

Em cada origem o, o desenho é

$$\underbrace{1,\ldots,o}_{\text{treino}}\ ;\ \underbrace{o+1,\ldots,o+7}_{\text{validação}}\ ;\ \underbrace{o+8,\ldots,o+14}_{\text{teste}}. \tag{4.5}$$

Na Bahia, os testes compartilham um ciclo; no M5, ocupam 58–64, 72–78 e 86–92, sem sobreposição. Não se combinam origens posteriores para recomendar em uma anterior.

A validação começa após seis ciclos de aquecimento com referência EOQ. A trajetória dessa referência na validação fornece estoque e pipeline comuns no teste. O estado usa apenas o passado e não continua o estoque próprio de cada candidata. Essa convenção isola comparações no mesmo ponto inicial, sem simular implantação contínua de cada política.

Uma loja inteira é excluída do conjunto que define o seletor, separadamente em cada origem. As outras lojas fornecem resultados de validação; a loja reservada fornece o teste. O controlador conserva o treino no histórico da própria série. Avalia-se transferência do seletor com histórico disponível, não generalização para lojas sem observações.

4.7 Duas implementações do PSE

4.7.1 Associação e rótulos

Para um conjunto A de casos de validação, a regra global escolhe

$$\hat{\pi}_A = \arg\min_{\pi:\bar{F}_{\pi,A}\geq 0{,}70} \bar{C}_{\pi,A}. \tag{4.6}$$

O PSE por perfil aplica a regra a cada A_g. Sem viável, escolhe maior NS e menor custo; perfis sem suporte usam a global. O rótulo preditivo usa o mesmo critério na série individual. Serviço inteiramente indefinido leva a menor custo, com marcação de demanda zero. Empates restantes usam convenção determinística registrada na análise.

As restrições por série e por grupo diferem; a moda dos rótulos é um controle adicional com o mesmo alvo categórico. Todos os seletores são avaliados pelas consequências de suas escolhas. Acurácia é auxiliar: errar entre políticas quase empatadas difere de perder muito serviço.

4.7.2 Aprendizado e recuo conservador

O piloto utiliza XGBoost com 200 árvores, profundidade três, taxa 0,05, semente fixa e sem subamostragem. Imputação, codificação do perfil e classes são ajustadas dentro de cada fold. Classes raras não são removidas; uma classe única leva a classificador constante. Cada treinamento tem 27 exemplos.

A ablação retira somente a entrada de perfil. Após o diagnóstico, uma extensão recua ao PSE por perfil quando o maior escore é menor que 0,60 ou a classe prevista tem menos de três exemplos no treino. A regra não observa o teste ao decidir, mas foi motivada pelos resultados do piloto: é desenvolvimento, não confirmação independente (Cawley and Talbot, 2010). O escore não é probabilidade calibrada de serviço.

4.7.3 Aplicação e reavaliação

O resultado é uma recomendação acompanhada de evidências de custo, serviço e suporte da escolha. Recalcular descritores entre janelas não equivale a retreinar o modelo. Frequência de atualização, integração operacional e supervisão humana ainda exigem desenho próprio; não foram validadas como implantação contínua.

4.8 Oráculos e decomposição das falhas

O melhor controlador único no teste e a melhor candidata por caso são referências retrospectivas. Não fornecem rótulos para a escolha. O oráculo do portfólio usa as médias entre sementes e a regra de menor custo viável. Empates numéricos contam como acerto sem exigir identidade nominal.

No M5, o planejamento com informação perfeita conhece a demanda do horizonte. Seu MILP mantém custos, prazo e estado inicial, com quantidades contínuas e variáveis binárias de emissão e saldo. Para falta u_t, chegada inicial a_t e pedido q_{t-L}:

$$I_t - u_t = I_{t-1} + a_t + q_{t-L} - d_t, \quad I_t u_t = 0, \quad \sum_t u_t \leq (1-\alpha) \sum_t d_t.$$

A complementaridade é linearizada com variáveis binárias e limites suficientes para o horizonte. Pedidos sem chegada antes do fim recebem zero, sem crédito terminal. Quando o alvo é fisicamente impossível nas primeiras entregas, maximiza-se atendimento antes de minimizar custo. Cada solução é conferida no simulador e recebe status de otimalidade.

Esse ótimo é determinístico e condicional, não o melhor controlador estocástico implantável. A eficiência $100C^*/C_{\mathrm{AIPE}}$ só é calculada sob o mesmo critério de serviço, com ambos os custos zero equivalendo a 100%. Compara-se o MILP com cada realização de treinamento viável, pois cumprir o alvo na média das sementes não implica cumpri-lo em cada uma.

A decomposição distingue atendimento do alvo, erro de seleção com alternativa viável, ausência de candidata viável apesar de possibilidade física, limite inicial do sistema e demanda zero. Assim, uma falta não é atribuída automaticamente ao seletor.

4.9 Incerteza e rastreabilidade

Bootstrap pareado preserva produtos e origens de cada loja: 5.000 sorteios na Bahia, 2.000 no M5. Ajustes e escolhas permanecem fixos; os intervalos são condicionais. Dependência entre lojas que compartilham produtos e a pequena quantidade de lojas do piloto limitam a inferência.

Manifestos, snapshots, sementes e bancos transacionais identificam a implementação de cada matriz. Os resultados derivam de `bahia145_cpu16_2026-10-15` e `m5_pse_pilot30_v2_2026-10-15`, em `experiment/data/08_reporting/research_v2`. O diagnóstico registra predições reproduzidas e regras exploratórias. Dados não integram o Git e possuem backup separado; código e fontes documentais estão versionados.

Os estudos brasileiros anteriores, incluindo a qualificação, motivam a investigação. A evidência quantitativa deste capítulo usa somente as matrizes descritas, sem misturar configurações. A expansão nacional está cancelada e a rodada maior M5 foi interrompida; ambas ficam fora das conclusões.

5

Resultados e Discussão

A avaliação distingue qualidade dos controladores e utilidade da seleção. A Bahia examina o PSE por perfil em 145 séries; o piloto M5 examina as duas abordagens em 30 séries e três origens. As bases permanecem separadas, com seus próprios denominadores e calibrações. O piloto também serve ao desenvolvimento do seletor, sem representar confirmação independente da extensão com recuo.

5.1 Resultados: valor da seleção por perfil

5.1.1 Quais candidatas oferecem compromissos competitivos?

A Tabela 5.1 resume os 290 casos série–origem. Sete casos não têm demanda no teste: um na primeira origem e seis na segunda. Seus custos permanecem na média dos 290 casos; o atendimento médio utiliza os 283 casos com denominador positivo. O atendimento ponderado é a razão entre a soma das unidades atendidas e a soma da demanda nos blocos avaliados, após a média das sementes. As origens repetidas não ampliam a amostra para 290 séries independentes.

PPO tem o menor custo descritivo, acompanhado do menor atendimento médio. Apenas EOQCycle e sSCycle superam 0,70 no conjunto dos testes; nenhuma política alcança essa meta no atendimento ponderado. Entre essas duas referências, sSCycle apresenta menor custo e maior atendimento médio. Essa comparação é um diagnóstico do teste, não uma escolha retrospectiva a ser atribuída ao seletor.

GA–DQN custa 11,60% menos que DQN e aumenta o atendimento médio de 0,5718 para 0,6802. Frente ao GA isolado, porém, custa 1,32% mais e atende menos, com média de 0,6953 para o GA. O refinamento híbrido não oferece vantagem agregada nessas duas dimensões sobre seu componente evolutivo. A diferença varia entre origens: na segunda, seu custo é ligeiramente menor que o do GA, também com menor atendimento. A comparação não isola

Tabela 5.1: Bahia, protocolo temporal: médias no teste de sete ciclos. Custo em unidades do cenário, calculado nos 290 casos. Atendimento médio e contagem abaixo da meta consideram os 283 casos com demanda positiva; sete casos têm atendimento indefinido.

Política	Custo	Atendimento	Ponderado	Abaixo de 0,70
EOQCycle	166,77	0,7787	0,6265	101
sSCycle	164,23	0,8037	0,6802	90
CappedBaseStock	218,11	0,6631	0,4948	148
GA	143,85	0,6953	0,5457	140
PPO	134,23	0,5514	0,4189	171
GA–DQN	145,75	0,6802	0,5248	144
DQN (controle)	164,88	0,5718	0,4033	164

causalmente o benefício das demonstrações ou do gatilho e não justifica excluir o híbrido antes de consolidar a avaliação M5.

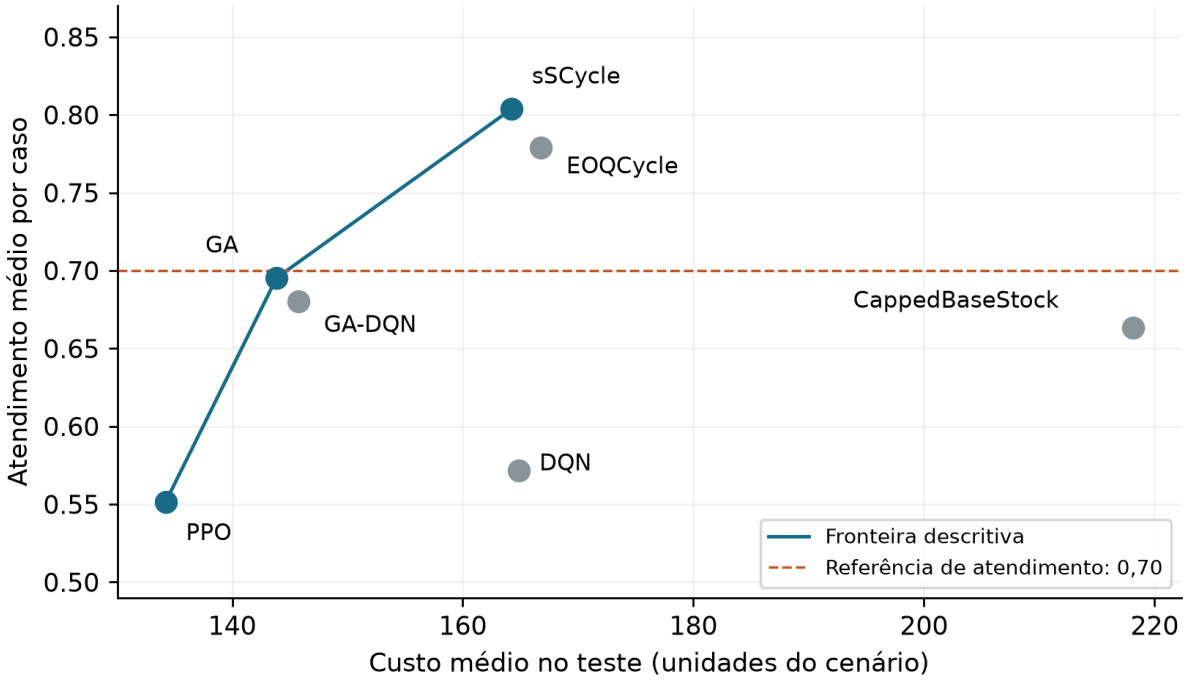


Figura 5.1: Compromisso custo–serviço das sete candidatas na Bahia. Médias de teste em 290 casos série–origem para custo e 283 com demanda positiva para atendimento. A fronteira é descritiva: não utiliza o teste para escolher a recomendação nem representa dominância estatística ou por série.

A Figura 5.1 distingue economia aparente por baixo atendimento de um compromisso competitivo. A restrição usada pelo seletor continua sendo avaliada na validação, sem recorrer a essa fronteira de teste.

Tabela 5.2: Escolha na validação das demais lojas e avaliação no teste da loja reservada, com meta 0,70. Há 145 casos por linha; atendimento definido em 144 casos na origem 17 e 139 na origem 23.

Treino	Estratégia	Custo	Atendimento	Abaixo de 0,70
17 ciclos	Global	180,58	0,5711	101
17 ciclos	Perfil	186,79	0,6475	82
23 ciclos	Global	142,03	0,9073	18
23 ciclos	Perfil	142,03	0,9073	18

5.1.2 O perfil melhora a decisão frente à seleção global?

Na primeira origem, a regra global escolhe GA para todas as séries. Por perfil, as escolhas são GA em 65 casos, sSCycle em 75 e EOQCycle em cinco. O maior atendimento custa mais, e ambas as estratégias ficam abaixo da meta no teste. Na segunda origem, os dois seletores escolhem sSCycle em todos os casos. A Tabela 5.2 evidencia, portanto, tanto mudança temporal da escolha global quanto ausência de diferenciação contextual na segunda janela.

No conjunto das origens, o custo médio passa de 161,31 na estratégia global para 164,41 por perfil: aumento de 1,93%. O atendimento médio cresce de 0,7362 para 0,7751, diferença de 3,89 pontos percentuais; o ponderado passa de 0,5750 para 0,6395. Os casos abaixo da meta diminuem de 119 para 100, entre os 283 com atendimento definido. Não há redução de custo, mas há melhora de serviço, concentrada na primeira origem. Essa melhora não assegura atendimento mínimo individual nem equivale a cumprir uma meta ponderada de 0,70.

Uma reamostragem exploratória pareada de 115 lojas, com 5.000 sorteios e todas as origens e produtos de cada loja preservados, produz intervalo condicional de 95% de $[-0{,}32; 4{,}16]\%$ para o aumento de custo por perfil. Os controladores e seletores permanecem fixos nos sorteios. O intervalo inclui zero e não representa incerteza de novos treinamentos ou de novas trajetórias de demanda; dependência entre lojas que compartilham produtos também permanece possível.

A sensibilidade reforça a distinção entre meta de escolha e serviço futuro. Em 0,80, todas as escolhas da segunda origem são contingências por ausência de candidata viável na validação, apesar do serviço posterior de 0,9073. Em 0,90 e 0,95, ambas as estratégias usam contingências nos 290 casos. Atendimento futuro alto não torna retroativamente viável uma escolha que descumpria o critério na validação.

A Figura 5.2 mostra por que a comparação não se esgota na média: a primeira janela concentra violações de serviço, enquanto a segunda tem distribuição e escolha coincidentes entre estratégias.

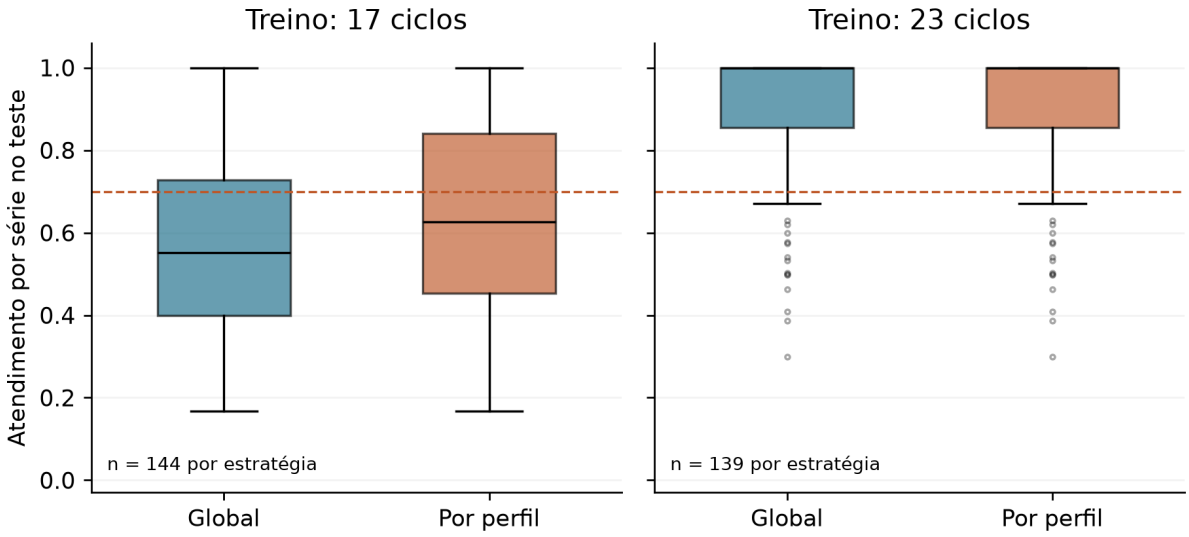


Figura 5.2: Distribuição do atendimento das estratégias no teste, por origem. Cada caixa resume séries com demanda positiva; a linha tracejada indica 0,70. Há 144 casos por estratégia na primeira origem e 139 na segunda. As mesmas séries participam das duas estratégias; observações e origens não são independentes.

5.1.3 As escolhas e o atendimento são estáveis entre períodos?

Os perfis são recalculados no prefixo disponível em cada origem. Com 17 ciclos, há 65 séries Sparse High Impact e 80 Unstable Trend; com 23, são 60, 69 e 16 High Volatility Seasonal. Essa mudança reflete a janela e as regras de caracterização, inclusive a indisponibilidade da autocorrelação na primeira origem. Não demonstra mudança de regime econômico em todas essas séries.

A Figura 5.3 localiza a diferenciação que produz o serviço adicional: na primeira origem, a regra por perfil substitui GA por sSCycle ou EOQCycle em parte das séries. Na segunda, identificar perfis não muda a política recomendada. Assim, a existência de grupos distintos não implica valor incremental da seleção em todo período.

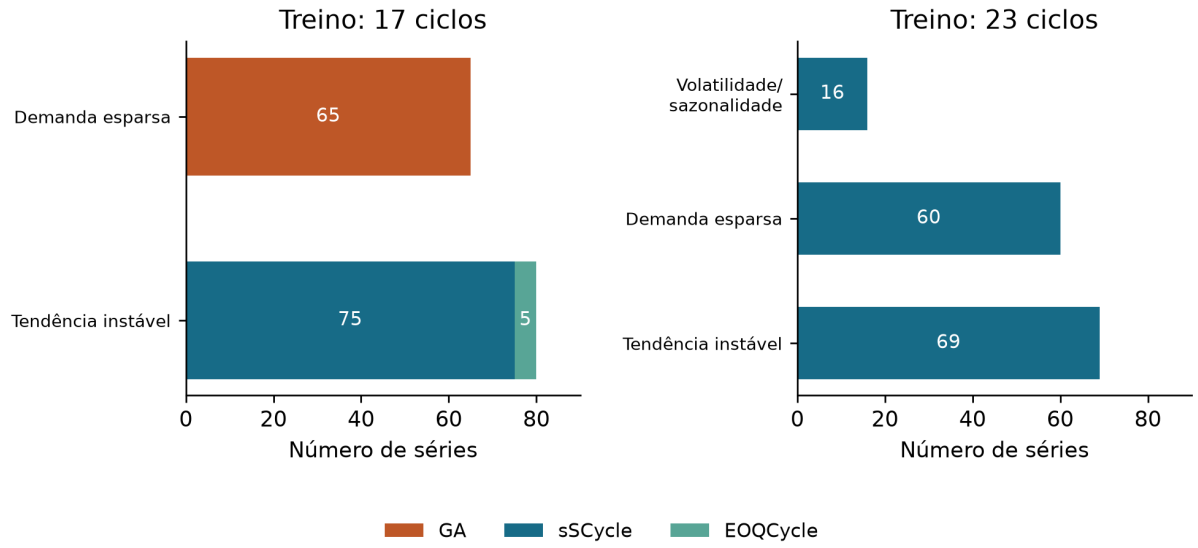


Figura 5.3: Políticas escolhidas por perfil na validação das demais lojas, com meta 0,70. Cada painel contém 145 escolhas; os números indicam séries. A primeira origem diferencia grupos, enquanto a segunda recomenda sSCycle em todos eles. Nomes abreviados dos perfis correspondem às regras operacionais descritas no método.

5.2 Resultados no M5: duas abordagens do PSE

5.2.1 Custo e atendimento das recomendações

O piloto completa os 1.350 ajustes das 30 séries em três origens. As recomendações são avaliadas em 90 casos, com atendimento definido em 86. Não são 90 séries independentes. A Tabela 5.3 inclui dois controles: moda dos rótulos de treino e escolha individual da vencedora de validação. O último examina a transferência temporal do próprio rótulo, sem representar um limite superior para os seletores.

Tabela 5.3: M5: custo em 90 casos; atendimento e contagem de viáveis em 86 com demanda positiva. O recuo é exploratório, desenvolvido após o diagnóstico do piloto.

Seleção	Custo	Atendimento	Casos $\geq 0{,}70$
Global	1.086,97	0,7146	47
PSE por perfil	1.094,02	0,7091	46
PSE preditivo com perfil	1.238,30	0,6735	39
PSE preditivo sem perfil	1.238,30	0,6735	39
Moda dos rótulos	1.096,65	0,6885	42
Individual na validação	1.185,13	0,6838	44
Preditivo com recuo	1.087,26	0,6996	46

O preditivo custa 13,9% mais e atende 4,11 pontos percentuais menos que a global. O contraste desfavorável aparece nas três origens e nos dois perfis. WI_3 e TX_2 respondem por 65,4% da diferença líquida de custo. O PSE por perfil permanece próximo da global: maior

custo e serviço ligeiramente menor, sem benefício agregado neste piloto.

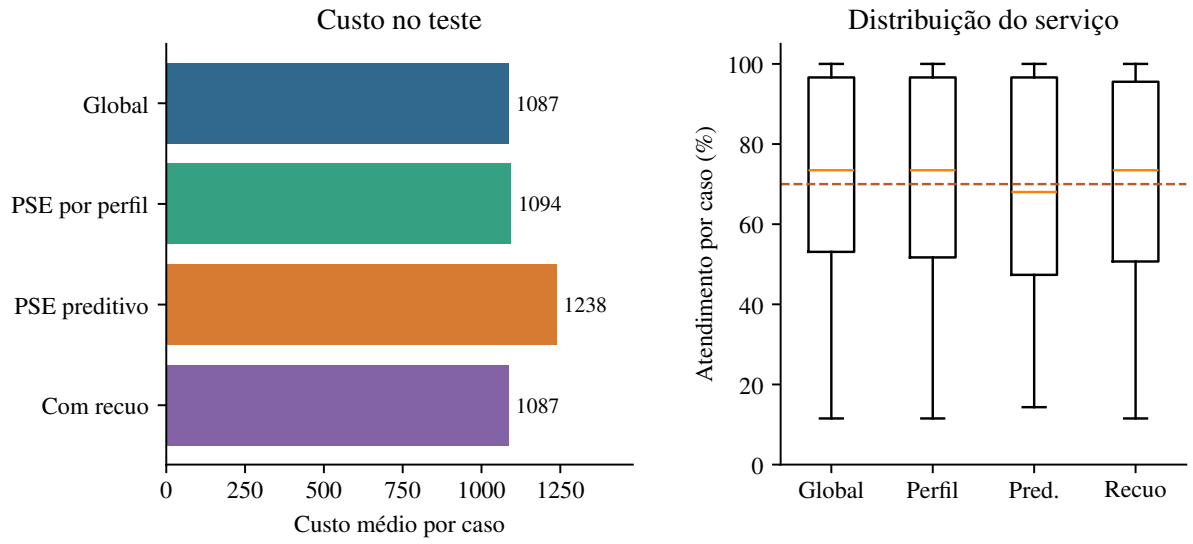


Figura 5.4: Piloto M5: custo e atendimento médios são apresentados separadamente. Caixas descrevem o serviço nos 86 casos definidos; linha em 0,70. O recuo foi desenvolvido no piloto, sem confirmação independente.

O recuo é acionado em 62 casos e muda a política em 48. Frente ao preditivo, reduz custo em 12,2% e aumenta serviço em 2,62 pontos. Frente à global, custa 0,026% mais e atende 1,49 ponto menos; o atendimento permanece abaixo de 0,70. O intervalo exploratório para a diferença de custo frente à global é $[-39{,}83; 39{,}30]$ unidades do cenário; para serviço, $[-2{,}87; -0{,}23]$ pontos. Proximidade de custo não comprova equivalência.

5.2.2 O que explica a dificuldade do preditivo?

Cada fold tem 27 exemplos para até sete classes. O modelo reproduz 100% dos rótulos do treino, mas somente 19 dos 90 rótulos de validação das lojas excluídas. Dois rótulos pertencem a classes ausentes no respectivo treinamento. Esses resultados são consistentes com sobreajuste, sem provar que mais dados, isoladamente, resolvam o problema.

A vencedora nominal da validação permanece vencedora no teste em 29/90 casos; admitindo empates no objetivo completo, em 33/90. Com demanda positiva nos dois blocos, a concordância nominal é 26/83. As vencedoras diferem entre sementes em 39/90 casos. O alvo categórico é sensível tanto ao período quanto ao treinamento. Escolher individualmente na validação aumenta os casos viáveis frente ao preditivo, mas não supera a global em custo ou atendimento médio.

Cada origem contém 26 séries esparsas e quatro de tendência, sem transição de perfil na amostra. As colunas de perfil têm importância por ganho zero em todos os folds; com e sem elas, as 90 recomendações coincidem. Redundância com as características numéricas e baixa

diversidade ajudam a explicar a ausência de efeito, sem demonstrar inutilidade dos perfis em outras populações.

5.2.3 Distância aos melhores resultados e fontes das falhas

O preditivo iguala o menor custo viável do portfólio em 11 dos 39 casos nos quais sua recomendação é viável. Sua eficiência média condicional é 74,2%. A global acerta 15/47 e o PSE por perfil 12/46, com eficiências de 80,8% e 79,5%. Os denominadores diferem: não se avalia eficiência sobre um mesmo subconjunto.

Os 90 problemas com informação perfeita têm otimalidade comprovada. Nas 118 realizações de treinamento em que o preditivo satisfaz o alvo, iguala o ótimo determinístico em 14 e apresenta eficiência média de 54,6%. As realizações repetem séries e, para políticas determinísticas, a mesma trajetória; não ampliam a amostra independente. Mede-se distância ao planejamento com demanda conhecida, não a um controlador estocástico implantável.

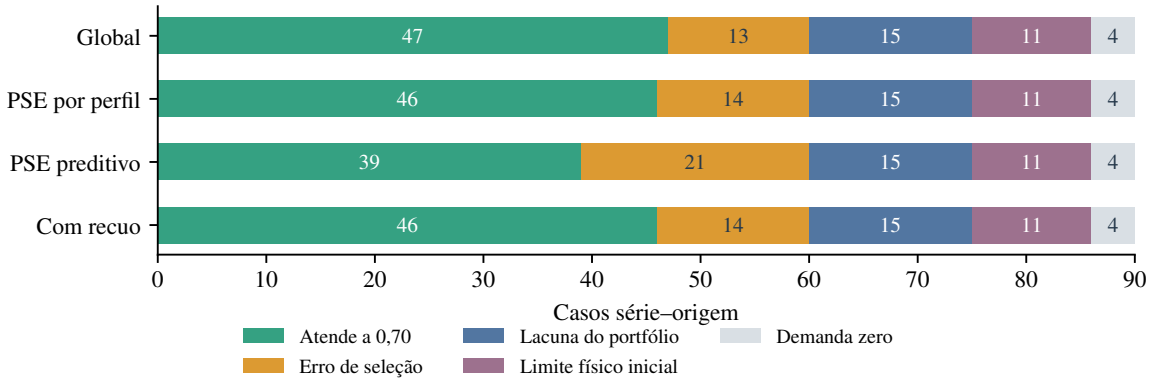


Figura 5.5: Decomposição dos 90 casos M5. Erro de seleção: outra candidata atende. Lacuna do portfólio: nenhuma candidata atende, mas o planejamento perfeito permite atender. Limite físico: condições iniciais impedem atingir 0,70. Demanda zero mantém serviço indefinido.

No preditivo, 39 casos atendem ao alvo; 21 falham apesar de existir política viável; 15 falham sem candidata viável, embora o planejamento perfeito permita atender; 11 têm restrição física inicial; e quatro têm demanda zero. O recuo reduz os erros de seleção de 21 para 14. Melhorar o seletor não resolve sozinho todas as faltas: a Figura 5.5 separa intervenções sobre escolha, controle e abastecimento inicial.

5.3 Esforço computacional das políticas

Tempo de ajuste é uma dimensão adicional da comparação, apresentada na Tabela 5.4. Cada ajuste é contado uma vez, sem duplicar seus registros de validação e teste. Ajustes reaproveitados são excluídos desta amostra de tempos. O registro mede a duração do ajuste no

ambiente de execução, sob concorrência e carga variável; não equivale a um teste controlado de velocidade entre processadores nem ao tempo total decorrido da rodada.

Tabela 5.4: Duração registrada dos ajustes executados na rodada Bahia. Tempos em segundos; médias e medianas por ajuste, sem os 54 reaproveitados.

Política	Ajustes	Mediana (s)	Média (s)
CappedBaseStock	284	0,01	0,01
DQN	870	52,10	52,10
EOQCycle	284	0,00	0,00
GA	852	0,53	0,49
GA–DQN	870	52,90	52,90
PPO	852	24,37	26,03
sSCycle	284	0,00	0,00

O tempo deve ser interpretado junto ao desempenho: maior esforço não comprova melhor recomendação. GA–DQN reúne busca, demonstrações e aprendizado, enquanto as referências analíticas têm ajuste simples. Uma comparação causal de eficiência exigiria controlar hardware, carga, orçamento e repetições. Os tempos registrados permitem descrever a execução, mas não substituem esse desenho.

5.4 Síntese das respostas e limites

A heterogeneidade produz escolhas diferentes, mas sua utilidade depende de período e comparador. Na Bahia, o perfil acrescenta serviço com custo pontualmente maior; na segunda origem, não diferencia a escolha global. No M5, o preditivo tem pior custo e serviço, e a informação explícita de perfil não altera as recomendações.

O classificador reproduz o treino, mas tem pouco suporte por classe e rótulos que mudam entre períodos e sementes. A regra de recuo reduz a perda do preditivo; não comprova superioridade sobre global ou perfil. Isso responde parcialmente à pergunta de aprendizagem: a implementação testada não converteu suas características em vantagem operacional.

O oráculo do portfólio e o planejamento com informação perfeita mostram limites diferentes. Há espaço para melhorar seleção e controle, mas 11 casos do M5 não permitem atingir o alvo nas condições iniciais. Maior capacidade preditiva não remove essa restrição. Tampouco custo baixo com falta deve ser interpretado como aproximação do ótimo viável.

A concentração dos perfis existe também fora da amostra: na primeira origem M5, 826/885 séries elegíveis são esparsas, 57 têm tendência e duas são do grupo de volatilidade/sazonalidade. Nas origens 64 e 78, são 1.977/2.033 e 2.360/2.408 séries esparsas. Os rótulos satisfazem a regra explícita, não resultam do perfil padrão. Ampliar o tamanho sem examinar essa cobertura não garante diversidade.

As evidências são condicionais a coortes retrospectivas, sete ciclos de teste, vendas possivelmente censuradas, custos de cenário e estados iniciais de referência. As origens repetem séries; a Bahia compartilha um ciclo. O bootstrap preserva lojas, mas não mede novos treinamentos ou toda a dependência entre produtos e lojas. A diferença de calibração da CappedBaseStock entre bases impede tratar seus contrastes como efeito puro da demanda.

A contribuição empírica é tornar essas diferenças verificáveis. O AIPE não recebe confirmação de vantagem geral; oferece um desenho para identificar quando a seleção agrega valor e qual componente precisa melhorar. A avaliação seguinte deve reservar séries não usadas no desenvolvimento e fixar escolhas antes de examinar seus testes.

6

Conclusões

Esta dissertação propõe o AIPE para selecionar políticas de reposição conforme o contexto da demanda. Seu PSE admite associação por perfil e previsão supervisionada da política por série. A investigação distingue calibração dos controladores, escolha entre candidatas e avaliação futura da recomendação. Essa separação é a contribuição metodológica central; a utilidade operacional depende dos resultados, não da complexidade da arquitetura.

6.1 Respostas às questões de pesquisa

O desempenho varia entre séries e períodos, mas a heterogeneidade não basta para justificar a seleção contextual. Na Bahia, 4.350 ajustes cobrem 145 séries em duas origens. O PSE por perfil acrescenta 3,89 pontos percentuais de atendimento com aumento pontual de custo de 1,93%. As violações individuais passam de 119 para 100 entre 283 casos com demanda. Na segunda origem, não há diferenciação frente à global.

O piloto M5 completa 1.350 ajustes em 30 séries, dez lojas e três origens. O preditivo apresenta custo 13,9% maior e atendimento 4,11 pontos menor que a global. Sua reprodução perfeita dos rótulos de treino não se transfere às lojas excluídas. O perfil explícito não é utilizado nas divisões das árvores, e as previsões coincidem com e sem essa entrada. A evidência identifica limites da implementação, sem provar impossibilidade da abordagem preditiva.

A relação entre características e política também é instável no tempo: apenas 29/90 vencedoras nominais da validação permanecem vencedoras no teste, ou 33/90 admitindo empates no objetivo. O recuo exploratório ao perfil reduz a perda do preditivo, mas não supera as referências e ainda requer confirmação em séries reservadas.

6.2 Contribuições e interpretação

O AIPE reúne duas implementações do seletor em uma infraestrutura rastreável. O estudo oferece evidência proprietária brasileira e pública M5, preservando diferenças de cobertura, escala e calibração. Portfólio e GA–DQN são fundamentados na literatura; não constituem novidades algorítmicas próprias.

A avaliação por oráculos acrescenta uma distinção prática. No M5, 21 falhas do preditivo poderiam ser evitadas por outra candidata; 15 exigem melhorar o portfólio ou sua calibração; 11 decorrem de restrições físicas iniciais; quatro casos não têm demanda. Seleção mais precisa não resolve todas essas causas. A distância ao planejamento com informação perfeita também não representa um ganho operacional disponível sem conhecimento futuro.

Os achados não demonstram economia geral nem implantação validada do AIPE. São condicionais a custos de cenário, vendas possivelmente censuradas, estados iniciais comuns e janelas curtas. Sementes e origens repetidas não ampliam a população independente. Os objetivos de serviço por série e por grupo também diferem entre abordagens.

6.3 Implicações

Antes de recomendar um controlador, é necessário definir o serviço pretendido: média por série, atendimento ponderado por unidades ou garantia individual. A comparação deve manter referências simples competitivas e informar falhas, não somente médias. No estado atual, a contextualização oferece benefício condicionado na Bahia e expõe dificuldades de aprendizagem no piloto público. A continuidade deve testar quando essa diferenciação se sustenta em novas séries, preservando a separação entre desenvolvimento e confirmação.

7

Continuidade e Validação Final

A Bahia e o piloto M5 têm matrizes completas. O próximo passo é construir a avaliação final do seletor, e não apresentar a rodada M5 interrompida como experimento concluído. O piloto já orientou diagnóstico e recuo; integra o conjunto de desenvolvimento. A expansão nacional permanece cancelada.

7.1 Separar desenvolvimento e confirmação

A próxima amostra deve oferecer mais exemplos por classe e registrar suporte de cada perfil. A concentração natural do M5 em séries esparsas impede presumir cobertura equilibrada. Elegibilidade e estratificação usam somente o treino; séries reservadas não podem orientar o ajuste do seletor.

Hiperparâmetros, critérios de recuo e eventual simplificação de rótulos devem ser definidos em validação interna por loja. O teste final fica isolado. Uma melhora encontrada no piloto não é uma segunda replicação independente (Cawley and Talbot, 2010). Ajustes de políticas compatíveis podem ser reaproveitados após auditoria de dados, configuração e código; mudanças científicas exigem novo ajuste da candidata afetada.

7.2 Harmonizar o problema de decisão

A calibração da CappedBaseStock precisa ser harmonizada entre bases antes de atribuir diferenças à demanda. Também é necessário comparar restrições de serviço com escopo claro: série, perfil ou rede. A meta de 0,70 e os custos atuais são parâmetros experimentais, não exigências empresariais já justificadas.

A instabilidade dos rótulos motiva examinar conjuntos de candidatas quase empatadas e alvos sensíveis ao custo de erro. Essa análise deve ocorrer no desenvolvimento, sem selecionar

a formulação pelo teste reservado. GA–DQN continua acompanhado por GA e DQN, com o esforço adicional informado.

7.3 Sensibilidades e eficiência

Prazo, custos relativos, estoque inicial, tratamento terminal e horizonte podem alterar o ranking e a viabilidade física. Seu efeito deverá ser separado do efeito do seletor. Calibração agrupada por perfil é outra hipótese: não equivale a seleção de família por perfil e exige comparação própria.

A escolha de CPU ou GPU deve considerar tempo total sob a carga de uso prevista. O piloto utilizou oito processos CPU; essa configuração operacional não é uma vantagem científica de uma política. Não há execução nacional ou expansão automática autorizada como requisito de conclusão desta análise.

7.4 Critérios de fechamento

Tabela 7.1: Critérios de conclusão, sem datas ainda não acordadas.

Etapa	Evidência necessária
Protocolo final	Objetivo, suporte e calibrações fixados antes do teste
PSE	Comparação independente com global, perfil e controles simples
Robustez	Falhas físicas, portfólio, seleção e sensibilidades separadas
Redação	Afirmações alinhadas à evidência e revisão dos autores

O artigo concentra a arquitetura e sua avaliação operacional; a dissertação mantém fundamentos, formulação e limites mais amplos. O material SBPO permanece arquivado. Autoria, declarações, disponibilidade de dados e elementos institucionais precisam ser fechados pelos responsáveis antes de submissão ou depósito.

Referências

Victoria G. Achkar, Braulio B. Brunaud, Héctor D. Pérez, Rami Musa, Carlos A. Méndez, and Ignacio E. Grossmann. Extensions to the guaranteed service model for industrial applications of multi-echelon inventory optimization. *European Journal of Operational Research*, 313(1):192–206, 2024. **DOI** 10.1016/j.ejor.2023.08.013.

Sven Axsäter. *Inventory Control*, volume 90 of *International Series in Operations Research & Management Science*. Springer US, New York, NY, USA, 2 edition, 2006. ISBN 9780387332505. **DOI** 10.1007/0-387-33331-2.

Alex Batsis and Spyridon Samothrakis. Contextual reinforcement learning for supply chain management. *Expert Systems with Applications*, 249:123541, 2024. **DOI** 10.1016/j.eswa.2024.123541.

Robert N. Boute, Joren Gijsbrechts, Willem van Jaarsveld, and Nathalie Vanvuchelen. Deep reinforcement learning for inventory control: A roadmap. *European Journal of Operational Research*, 298(2):401–412, 2022. **DOI** 10.1016/j.ejor.2021.07.016.

John E. Boylan and Aris A. Syntetos. Forecasting for inventory management of service parts. In Khairy A. H. Kobbacy and D. N. Prabhakar Murthy, editors, *Complex System Maintenance Handbook*, pages 479–506. Springer, London, UK, 2008. **DOI** 10.1007/978-1-84800-011-7_20.

Gavin C. Cawley and Nicola L. C. Talbot. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11: 2079–2107, 2010. URL https://www.jmlr.org/papers/v11/cawley10a.html.

Andrew J. Clark and Herbert Scarf. Optimal policies for a multi-echelon inventory problem. *Management Science*, 6(4):475–490, 1960. **DOI** 10.1287/mnsc.6.4.475.

Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, USA, 2 edition, 1988. ISBN 9780805802832.

J. D. Croston. Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303, 1972. **DOI** 10.1057/jors.1972.50.

Ton de Kok, Christopher Grob, Marco Laumanns, Stefan Minner, Jörg Rambau, and Konrad Schade. A typology and literature review on stochastic multi-echelon inventory models. *European Journal of Operational Research*, 269(3):955–983, 2018. **DOI** 10.1016/j.ejor.2018.02.047.

Tansel Dokeroglu, Tayfun Kucukyilmaz, and El-Ghazali Talbi. Hyper-heuristics: A survey and taxonomy. *Computers and Industrial Engineering*, 187:109815, 2024. **DOI** 10.1016/j.cie.2023.109815.

John H. Drake, Ahmed Kheiri, Ender Özcan, and Edmund K. Burke. Recent advances in selection hyper-heuristics. *European Journal of Operational Research*, 285(2):405–428, 2020. **DOI** 10.1016/j.ejor.2019.07.073.

Burak Erkayman, Ferhat Yuna, and Mustafa Yılmaz. Markov approach for inventory control with meta-heuristics in intermittent demand environment. *PLOS ONE*, 20:e0325658, 2025. **DOI** 10.1371/journal.pone.0325658.

Ayse Sena Eruguz, Evren Sahin, Zied Jemai, and Yves Dallery. A comprehensive survey of guaranteed-service models for multi-echelon inventory optimization. *International Journal of Production Economics*, 172:110–125, 2016. **DOI** 10.1016/j.ijpe.2015.11.017.

Milton Friedman. A comparison of alternative tests of significance for the problem of m rankings. *The Annals of Mathematical Statistics*, 11(1):86–92, 1940. **DOI** 10.1214/aoms/1177731944.

Kevin Geevers, Lotte van Hezewijk, and Martijn R. K. Mes. Multi-echelon inventory optimization using deep reinforcement learning. *Central European Journal of Operations Research*, 32 (3):653–683, 2024. **DOI** 10.1007/s10100-023-00872-2.

Joren Gijsbrechts, Robert N. Boute, Jan A. Van Mieghem, and Dennis J. Zhang. Can deep reinforcement learning improve inventory management? performance on lost sales, dual-sourcing, and multi-echelon problems. *Manufacturing & Service Operations Management*, 24(3):1349–1368, 2022. **DOI** 10.1287/msom.2021.1064.

Kwang-Il Goh and Albert-László Barabási. Burstiness and memory in complex systems. *EPL (Europhysics Letters)*, 81(4):48002, 2008. **DOI** 10.1209/0295-5075/81/48002.

Stephen C. Graves and Sean P. Willems. Optimizing strategic safety stock placement in supply chains. *Manufacturing & Service Operations Management*, 2(1):68–83, 2000. **DOI** 10.1287/msom.2.1.68.23267.

John H. Holland. *Adaptation in Natural and Artificial Systems*. MIT Press, Cambridge, MA, USA, 1992. ISBN 9780262581111.

Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006. **DOI** 10.1016/j.ijforecast.2006.03.001.

James Kennedy and Russell Eberhart. Particle swarm optimization. In *Proceedings of ICNN'95 — International Conference on Neural Networks*, volume 4, pages 1942–1948, 1995. **DOI** 10.1109/ICNN.1995.488968.

Pascal Kerschke and Heike Trautmann. Automated algorithm selection on continuous black-box problems by combining exploratory landscape analysis and machine learning. *Evolutionary Computation*, 27(1):99–127, 2019. **DOI** 10.1162/evco_a_00236.

Pascal Kerschke, Holger H. Hoos, Frank Neumann, and Heike Trautmann. Automated algorithm selection: Survey and perspectives. *Evolutionary Computation*, 27(1):3–45, 2019. **DOI** 10.1162/evco_a_00242.

S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983. **DOI** 10.1126/science.220.4598.671.

Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(3):48–60, 2014. **DOI** 10.1609/aimag.v35i3.2460.

Averill M. Law. *Simulation Modeling and Analysis*. McGraw-Hill Education, 5 edition, 2015. ISBN 9780073401324.

Hau L. Lee, V. Padmanabhan, and Seungjin Whang. Information distortion in a supply chain: The bullwhip effect. *Management Science*, 43(4):546–558, 1997. **DOI** 10.1287/mnsc.43.4.546.

Xiaotian Liu, Ming Hu, Yijie Peng, and Yaodong Yang. Multi-agent deep reinforcement learning for multi-echelon inventory management. *Production and Operations Management*, 34(7): 1836–1856, 2025. **DOI** 10.1177/10591478241305863.

Spyros Makridakis. Accuracy measures: Theoretical and practical concerns. *International Journal of Forecasting*, 9(4):527–529, 1993. **DOI** 10.1016/0169-2070(93)90079-3.

Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. The m4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1): 54–74, 2020. **DOI** 10.1016/j.ijforecast.2019.04.014.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharshan Kumaran,

Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015. **DOI** 10.1038/nature14236.

Mehran Nasseri, Taha Falatouri, Patrick Brandtner, and Farzaneh Darbanian. Applying machine learning in retail demand prediction—a comparison of tree-based ensembles and long short-term memory-based deep learning. *Applied Sciences*, 13(19):11112, 2023. **DOI** 10.3390/app131911112.

Peter Nemenyi. *Distribution-Free Multiple Comparisons*. PhD thesis, Princeton University, 1963.

Afshin Oroojlooyjadid, MohammadReza Nazari, Lawrence V. Snyder, and Martin Takáč. A deep q-network for the beer game: Deep reinforcement learning for inventory optimization. *Manufacturing & Service Operations Management*, 24(1):285–304, 2022. **DOI** 10.1287/msom.2020.0939.

Deniz Preil and Michael Krapp. Bandit-based inventory optimisation: Reinforcement learning in multi-echelon supply chains. *International Journal of Production Economics*, 252:108578, 2022. **DOI** 10.1016/j.ijpe.2022.108578.

Meng Qi, Yuanyuan Shi, Yongzhi Qi, Chenxin Ma, Rong Yuan, Di Wu, and Zuo-Jun Max Shen. A practical end-to-end inventory management model with deep learning. *Management Science*, 69(2):759–773, 2023. **DOI** 10.1287/mnsc.2022.4564.

John R. Rice. The algorithm selection problem. *Advances in Computers*, 15:65–118, 1976.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. **DOI** 10.48550/arXiv.1707.06347.

Rainer Storn and Kenneth Price. Differential evolution — a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4):341–359, 1997. **DOI** 10.1023/A:1008202821328.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, USA, 2 edition, 2018. ISBN 9780262039246.

Aris A. Syntetos and John E. Boylan. On the categorization of demand patterns. *Journal of the Operational Research Society*, 56(5):495–503, 2005. **DOI** 10.1057/palgrave.jors.2601841.

Aris A. Syntetos, John E. Boylan, and Stephen M. Disney. Forecasting for inventory planning: A 50-year review. *Journal of the Operational Research Society*, 60(S1):S149–S160, 2009. **DOI** 10.1057/jors.2008.173.

Yasin Tadayonrad and Alassane Balle Ndiaye. A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality. *Supply Chain Analytics*, 3:100026, 2023. **DOI** 10.1016/j.sca.2023.100026.

El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. John Wiley & Sons, Hoboken, NJ, USA, 2009. ISBN 9780470278581. **DOI** 10.1002/9780470496916.

Henri Theil. *Applied Economic Forecasting*. North-Holland, Amsterdam, 1966.

Nathalie Vanvuchelen, Joren Gijsbrechts, and Robert N. Boute. Use of proximal policy optimization for the joint replenishment problem. *Computers in Industry*, 119:103239, 2020. **DOI** 10.1016/j.compind.2020.103239.

Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. **DOI** 10.2307/3001968.

David H. Wolpert and William G. Macready. No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation*, 1(1):67–82, 1997. **DOI** 10.1109/4235.585893.

Linwei Xin. Technical note—understanding the performance of capped base-stock policies in lost-sales inventory models. *Operations Research*, 69(1):61–70, 2021. **DOI** 10.1287/opre.2020.2019.

Ferhat Yuna, Burak Erkayman, and Mustafa Yılmaz. Inventory control model for intermittent demand: A comparison of metaheuristics. *Soft Computing*, 27:6487–6505, 2023. **DOI** 10.1007/s00500-023-07871-0.

Oussama Zabraoui, Yahya Hmamou, Anas Chafi, and Salaheddine Kammouri Alami. A comparative study of multi-algorithm optimization for inventory analytics in supply chains. *Supply Chain Analytics*, 12:100154, 2025. **DOI** 10.1016/j.sca.2025.100154.

Paul H. Zipkin. *Foundations of Inventory Management*. McGraw-Hill/Irwin, Boston, MA, USA, 2000. ISBN 9780256113792.