

Dissertação de Mestrado

AIPE: Uma Metodologia para Seleção Contextual de Políticas de Reposição

Matheus Inácio Batista Santos
mibs@ic.ufal.br
Orientadores:

Dr. Rian Gabriel Santos Pinheiro
Dr. Bruno Costa e Silva Nogueira

Maceió

16 de outubro de 2026

Matheus Inácio Batista Santos

AIPE: Uma Metodologia para Seleção Contextual de Políticas de Reposição

Dissertação em desenvolvimento no Programa de Pós-Graduação em Informática da Universidade Federal de Alagoas, Instituto de Computação.

Orientadores:
Dr. Rian Gabriel Santos Pinheiro

Dr. Bruno Costa e Silva Nogueira

Maceió

16 de outubro de 2026

Versão de trabalho da dissertação de mestrado em desenvolvimento no Instituto de Computação da Universidade Federal de Alagoas. Composição da banca a confirmar.

Dr. Rian Gabriel Santos Pinheiro - Orientador
Instituto de Computação
Universidade Federal de Alagoas

Dr. Bruno Costa e Silva Nogueira - Orientador
Instituto de Computação
Universidade Federal de Alagoas

- Examinador(a)

- Examinador(a)

- Examinador(a)

Maceió
16 de outubro de 2026

Resumo

A heterogeneidade da demanda torna a escolha da política de reposição uma decisão própria, além da calibração de seus parâmetros. Esta dissertação propõe o *Adaptive Inventory Policy Engine* (AIPE), uma metodologia em cinco etapas: especificar a decisão, representar o contexto, construir evidência comparável, recomendar uma política e avaliar suas consequências. Seu *Policy Selection Engine* (PSE) associa perfis a famílias ou estima recomendações por série, com uma regra de intervenção que admite conservar a referência. A avaliação utiliza sete políticas em duas aplicações separadas. Na Bahia, 145 séries em duas origens totalizam 4.350 ajustes; a seleção por perfil aumenta o custo médio em 1,93% e o atendimento em 3,89 pontos percentuais frente à referência global. No piloto M5, 30 séries de dez lojas em três origens totalizam 1.350 ajustes. O preditivo por classe apresenta maior custo e menor atendimento. Uma extensão exploratória por custo e serviço previstos, com recuo, reduz o custo médio em 1,56% e aumenta o atendimento em 0,27 ponto, mas altera apenas três decisões; uma série concentra cerca de 92% da economia. Oráculos retrospectivos distinguem erros de escolha, insuficiência do portfólio e inviabilidade física. A contribuição é um procedimento que vincula cada recomendação à evidência e à decisão operacional correspondente. Os resultados demonstram sua execução nas interfaces avaliadas e delimitam a utilidade das implementações. Coortes retrospectivas, calibrações distintas, horizontes curtos e desenvolvimento no piloto restringem a generalização e exigem confirmação independente.

Palavras-chave: Metodologia de seleção; Gestão de estoques; Seleção contextual de políticas; Nível de serviço; AIPE.

Abstract

Demand heterogeneity makes replenishment-policy selection a decision in its own right, alongside parameter calibration. This dissertation proposes the Adaptive Inventory Policy Engine (AIPE), a methodology comprising five stages: specifying the decision, representing context, building comparable evidence, recommending a policy, and evaluating its consequences. Its Policy Selection Engine (PSE) maps profiles to policy families or estimates recommendations for each series, with an intervention rule that allows the reference policy to be retained. Seven policies are evaluated in two separate applications. In Bahia, 145 series at two origins yield 4,350 fits; profile-based selection increases mean cost by 1.93% and mean fill rate by 3.89 percentage points relative to global selection. In the M5 pilot, 30 series from ten stores at three origins yield 1,350 fits. The class-based predictive selector has higher cost and lower service. An exploratory extension based on predicted cost and service, with fallback, reduces mean cost by 1.56% and increases service by 0.27 percentage points, but changes only three decisions; one series accounts for approximately 92% of savings. Retrospective oracles distinguish selection errors, portfolio gaps, and physical infeasibility. The contribution is a procedure linking each recommendation to evidence and the corresponding operational decision. The results demonstrate execution through the evaluated interfaces and delimit the utility of the implementations. Retrospective cohorts, different calibrations, short horizons, and development on the pilot restrict generalization and require independent confirmation.

Keywords: Selection methodology; Inventory management; Contextual policy selection; Service level; AIPE.

Sumário

Lista de Figuras vi
Lista de Tabelas vii
Lista de Siglas viii

1 Introdução **1**
1.1 Motivação 1
1.1.1 Reposição em redes varejistas 1
1.1.2 Da calibração à seleção de políticas 2
1.2 Problema e questões de pesquisa 2
1.3 Objetivos 4
1.4 Contribuições e alcance da evidência 4
1.5 Escopo e delimitações 5

2 Referencial Teórico **6**
2.1 Formulação do Problema de Reposição 6
2.1.1 Política de Reposição: Estado, Ação e Parâmetros 6
2.1.2 Função Objetivo e Dinâmica de Estoque 7
2.2 Famílias de Políticas de Reposição 7
2.2.1 Políticas Clássicas 7
2.2.2 Parametrização de Políticas via Meta-Heurísticas 8
2.2.3 Políticas de Reposição via Aprendizado por Reforço 9
2.2.4 Políticas Híbridas GA-RL 9
2.3 Demanda Intermitente 10
2.3.1 Taxonomia ADI e CV quadrado 10
2.3.2 Efeitos na Reposição 11
2.4 Métricas de Previsão 11
2.4.1 Métricas Utilizadas 11
2.5 Testes Estatísticos 12
2.5.1 Teste de Wilcoxon 12
2.5.2 Teste de Friedman e Nemenyi 12
2.5.3 Tamanho de Efeito 13

3 Trabalhos Relacionados **14**
3.1 Famílias de métodos 14
3.2 Inventário e demanda intermitente 14
3.3 Previsão e utilidade operacional 15
3.4 Meta-heurísticas e aprendizado por reforço 16
3.5 Seleção de políticas e meta-aprendizado 16
3.6 Antecedentes e delimitação da contribuição 17

3.7 Arquiteturas híbridas e posicionamento 18

4 AIPE: Metodologia Proposta 19
4.1 Objeto, entradas e saídas 19
4.2 Princípios e contribuição investigada 20
4.3 Procedimento metodológico 20
4.3.1 Especificar a decisão 20
4.3.2 Representar o contexto 20
4.3.3 Construir evidência comparável 21
4.3.4 Recomendar pelo PSE 22
4.3.5 Avaliar e diagnosticar 22
4.4 Metodologia e instanciação 23
4.5 Critérios de avaliação da contribuição 23

5 Desenho da Avaliação Experimental 24
5.1 Sistema de estoque e objetivo 24
5.1.1 Métricas e definição do serviço 24
5.2 Dados, preparo e cobertura 25
5.3 Características e perfis 25
5.4 Portfólio e calibração 26
5.4.1 Referências e busca de parâmetros 26
5.4.2 Reforço e híbrido 27
5.5 Separação temporal e comparação 27
5.6 Instanciação dos seletores 28
5.6.1 Associação e rótulos 28
5.6.2 Aprendizado e recuo conservador 28
5.6.3 Comparação reduzida por consequências 28
5.6.4 Instanciação unificada em consolidação 29
5.6.5 Aplicação e reavaliação 30
5.7 Oráculos e decomposição das falhas 30
5.8 Incerteza e rastreabilidade 31

6 Resultados e Discussão 32
6.1 Resultados: valor da seleção por perfil 32
6.1.1 Quais candidatas oferecem compromissos competitivos? 32
6.1.2 O perfil melhora a decisão frente à seleção global? 33
6.1.3 As escolhas e o atendimento são estáveis entre períodos? 35
6.2 Resultados no M5: duas abordagens do PSE 36
6.2.1 Custo e atendimento das recomendações 36
6.2.2 O que explica a dificuldade do preditivo? 37
6.2.3 Distância aos melhores resultados e fontes das falhas 38
6.3 Comparação reduzida: consequências e decisão de intervenção 38
6.4 Esforço computacional das políticas 40
6.5 Síntese das respostas e limites 41

7 Conclusões 42
7.1 Respostas às questões de pesquisa 42
7.2 Contribuição e alcance 43
7.3 Continuidade 43

8 Continuidade e Validação Final **44**
8.1 Separar desenvolvimento e confirmação 44
8.2 Harmonizar o problema de decisão 44
8.3 Sensibilidades e eficiência 45
8.4 Critérios de fechamento 45

Referências **46**

Lista de Figuras

1.1 AIPE: caracterização da demanda, seleção e avaliação. O PSE associa o perfil informado a uma política ou estima a política a partir de características, com perfil opcional. Históricos e associações são ilustrativos. A utilidade da contextualização é avaliada em teste reservado. 3
4.1 Procedimento do AIPE. Revisões motivadas pelo diagnóstico exigem nova avaliação independente. 21
6.1 Compromisso custo–serviço das sete candidatas na Bahia. Médias de teste em 290 casos série–origem para custo e 283 com demanda positiva para atendimento. A fronteira é descritiva: não utiliza o teste para escolher a recomendação nem representa dominância estatística ou por série. 34
6.2 Distribuição do atendimento das estratégias no teste, por origem. Cada caixa resume séries com demanda positiva; a linha tracejada indica 0,70. Há 144 casos por estratégia na primeira origem e 139 na segunda. As mesmas séries participam das duas estratégias; observações e origens não são independentes. . . . 35
6.3 Políticas escolhidas por perfil na validação das demais lojas, com meta 0,70. Cada painel contém 145 escolhas; os números indicam séries. A primeira origem diferencia grupos, enquanto a segunda recomenda sSCycle em todos eles. Nomes abreviados dos perfis correspondem às regras operacionais descritas no método. 36
6.4 Piloto M5: custo e atendimento médios são apresentados separadamente. Caixas descrevem o serviço nos 86 casos definidos; linha em 0,70. O recuo foi desenvolvido no piloto, sem confirmação independente. 37
6.5 Decomposição dos 90 casos M5. Erro de seleção: outra candidata atende. Lacuna do portfólio: nenhuma candidata atende, mas o planejamento perfeito permite atender. Limite físico: condições iniciais impedem atingir 0,70. Demanda zero mantém serviço indefinido. 38
6.6 Diferenças frente à global na comparação reduzida. Menor custo e maior serviço são favoráveis. A variante com recuo intervém em apenas três casos. 39

Lista de Tabelas

2.1 Quadrantes de Syntetos-Boylan: limiares e interpretações. 10
3.1 Papel das famílias de métodos na pesquisa. 15
3.2 Relação entre linhas da literatura e o foco da dissertação. 18
4.1 Compromissos do AIPE e escolhas dependentes da aplicação. 23
5.1 Matrizes completas incluídas na avaliação. Sementes e origens são medidas repetidas. 25
5.2 Perfis: primeira regra satisfeita determina a classe. 26
6.1 Bahia, protocolo temporal: médias no teste de sete ciclos. Custo em unidades do cenário, calculado nos 290 casos. Atendimento médio e contagem abaixo da meta consideram os 283 casos com demanda positiva; sete casos têm atendimento indefinido. 33
6.2 Escolha na validação das demais lojas e avaliação no teste da loja reservada, com meta 0,70. Há 145 casos por linha; atendimento definido em 144 casos na origem 17 e 139 na origem 23. 33
6.3 M5: custo em 90 casos; atendimento e contagem de viáveis em 86 com demanda positiva. O recuo é exploratório, desenvolvido após o diagnóstico do piloto. . . . 36
6.4 Comparação no piloto M5. Custo inclui 90 casos; serviço usa 86 com demanda positiva. 39
6.5 Duração registrada dos ajustes executados na rodada Bahia. Tempos em segundos; médias e medianas por ajuste, sem os 54 reaproveitados. 40
8.1 Critérios de conclusão, sem datas ainda não acordadas. 45

Lista de Siglas

Sigla	Significado
AIPE	*Adaptive Inventory Policy Engine*; metodologia proposta para seleção contextual de políticas.
PSE	*Policy Selection Engine*; camada de seleção por perfil ou por modelo preditivo.
POD	Perfil Operacional de Demanda.
CTI	Custo Total de Inventário.
NS	Nível de Serviço: fração da demanda atendida.
TR	Taxa de Ruptura: fração de ciclos com falta.
BE	*Bullwhip Effect*: razão entre variâncias de pedidos e demanda.
FP	Frequência de Pedidos.
ADI	*Average Demand Interval*: intervalo médio entre demandas positivas.
CV	Coeficiente de Variação; CV^2 é seu quadrado.
SKU	*Stock Keeping Unit*: unidade de produto para controle de estoque.
EOQ	*Economic Order Quantity*: lote econômico de compra.
GA	*Genetic Algorithm*: algoritmo genético.
SA	*Simulated Annealing*: recozimento simulado.
DQN	*Deep Q-Network*: rede de valores de ação.
PPO	*Proximal Policy Optimization*: otimização de política com recorte.
RL / DRL	Aprendizado por reforço / aprendizado por reforço profundo.
GA-DQN	Política híbrida que combina GA e DQN.
LSTM	*Long Short-Term Memory*: rede recorrente com memória.
ANN	*Artificial Neural Network*: rede neural artificial.
ARIMA	*Autoregressive Integrated Moving Average*.
MASE	*Mean Absolute Scaled Error*.
sMAPE	*Symmetric Mean Absolute Percentage Error*.
RMSSE	*Root Mean Squared Scaled Error*.
ASP	*Algorithm Selection Problem*: problema de seleção de algoritmos.
M5	Competição de previsão baseada em vendas do Walmart.

1

Introdução

Uma rede varejista precisa decidir quando e quanto repor em cada loja. O problema se torna mais difícil quando um produto vende regularmente em uma unidade, mas passa vários ciclos sem venda em outra. Uma política que preserva disponibilidade no primeiro caso pode gerar excesso de estoque no segundo. Custos, faltas e variabilidade dos pedidos dependem da relação entre a regra de reposição e o comportamento da demanda (Axsäter, 2006; Syntetos and Boylan, 2005).

Esta dissertação propõe o *Adaptive Inventory Policy Engine* (AIPE), uma metodologia para selecionar políticas de reposição conforme o contexto de cada série loja–produto. O AIPE organiza a especificação da decisão, a representação do contexto, a construção de evidência comparável, a recomendação e a avaliação de suas consequências. Seu *Policy Selection Engine* (PSE) é o componente que realiza a escolha, por associação a um perfil informado ou por estimação supervisionada. Bahia e M5 constituem aplicações para avaliar o procedimento; não definem sua identidade metodológica.

1.1 Motivação

1.1.1 Reposição em redes varejistas

Diferenças de consumo, sazonalidade e condições logísticas dificultam o ajuste manual de estoques em redes com muitas lojas. Cada unidade decide sua reposição, mas seus pedidos também afetam o armazém. Lotes elevados podem reduzir a frequência de compra e aumentar o estoque; pedidos frequentes podem preservar disponibilidade e elevar custos fixos. A decisão envolve manutenção, falta, pedido e prazo de entrega (Axsäter, 2006; Zipkin, 2000).

A instabilidade dos pedidos acrescenta outra preocupação. Variações nas vendas podem produzir oscilações ainda maiores nas encomendas enviadas aos fornecedores, fenômeno co-

nhecido como efeito chicote (Lee et al., 1997). Medir essa amplificação ajuda a avaliar consequências a montante, embora não substitua a análise conjunta de custo e serviço.

Na demanda intermitente, intervalos sem venda alternam com ocorrências positivas; quando estas variam muito de tamanho, o padrão é chamado de *lumpy* (Croston, 1972; Syntetos and Boylan, 2005; Boylan and Syntetos, 2008).

Essas diferenças motivam comparar regras, mas não demonstram que um seletor por perfil será melhor que uma política única bem calibrada. A vantagem depende do portfólio, dos custos, do serviço exigido e da informação disponível antes da decisão. Uma escolha retrospectiva favorável pode desaparecer ao avaliar lojas ou períodos não usados no ajuste.

1.1.2 Da calibração à seleção de políticas

Políticas clássicas, meta-heurísticas e aprendizado por reforço oferecem formas distintas de decidir reposição. Uma meta-heurística pode ajustar o ponto de pedido e o lote de uma regra; um agente de reforço pode aprender ações a partir do estado do estoque. Além de calibrar cada candidata, é necessário decidir qual família utilizar (Syntetos et al., 2009; Boute et al., 2022).

O AIPE organiza essa escolha em cinco etapas: especificar a decisão, representar o contexto, construir evidência comparável, recomendar pelo PSE e avaliar as consequências. A separação permite identificar quais informações sustentam a escolha e qual evidência seria necessária para substituí-la. A formulação se aproxima da seleção de algoritmos, na qual características de uma instância ajudam a escolher um método (Rice, 1976; Kotthoff, 2014).

A previsão fornece informação auxiliar: sua precisão não determina automaticamente quando pedir nem garante menor custo de inventário.

A Figura 1.1 sintetiza a proposta: partir de séries heterogêneas, comparar um portfólio e avaliar a seleção contextual. O caminho entre essas etapas é uma hipótese a testar, não uma garantia de melhoria.

1.2 Problema e questões de pesquisa

A unidade de análise é a série de vendas de um produto em uma loja, agregada por ciclo comercial. As políticas decidem reposição sob condições comuns de demanda, custos e prazo. O critério de referência é o menor custo entre alternativas que atendam ao nível de serviço mínimo. Quando a restrição usa a média de um grupo, ela não garante atendimento mínimo para cada série.

A questão principal é: *como estruturar uma metodologia de seleção contextual de políticas de reposição que produza recomendações verificáveis e permita avaliar quando substituir uma referência?* A investigação se desdobra em três perguntas:



Figura 1.1: AIPE: caracterização da demanda, seleção e avaliação. O PSE associa o perfil informado a uma política ou estima a política a partir de características, com perfil opcional. Históricos e associações são ilustrativos. A utilidade da contextualização é avaliada em teste reservado.

1. Como articular contexto, calibração, seleção e avaliação em um procedimento com entradas, decisões e saídas explícitas?

2. Em que condições as implementações do PSE oferecem melhor compromisso entre custo e serviço do que uma referência global?

3. Quais limites da representação, da aprendizagem, do portfólio e do sistema restringem a transferência das recomendações?

A primeira pergunta trata da formulação metodológica; a segunda, de sua utilidade operacional; a terceira, de seus limites. A construção do procedimento responde à primeira, mas não demonstra as demais. Encontrar famílias vencedoras diferentes não prova que possam ser previstas nem que valha trocar a referência.

As hipóteses empíricas são que existe heterogeneidade operacional aproveitável, que o contexto disponível antes da decisão captura parte dela e que uma regra de intervenção pode reduzir escolhas desfavoráveis. São hipóteses de avaliação, não pressupostos necessários para obter uma recomendação. Os experimentos podem delimitá-las ou contrariá-las. O procedimento registra tanto melhorias quanto deteriorações, permitindo avaliar separadamente a execução da metodologia e seu benefício operacional.

1.3 Objetivos

Objetivo geral

Propor, implementar e avaliar o AIPE como metodologia de seleção contextual de políticas de reposição para séries loja–produto, explicitando o procedimento de recomendação, suas condições de aplicação e seu benefício incremental em custo e serviço frente a referências competitivas.

Objetivos específicos

1. Definir as entradas, etapas, critérios e saídas do AIPE, distinguindo o procedimento geral das escolhas específicas de aplicação.
2. Implementar o PSE por perfil e o PSE preditivo, separando escolha da família e calibração dos parâmetros.
3. Estabelecer um protocolo que preserve a informação disponível antes da decisão e compare recomendações sob condições operacionais compatíveis.
4. Avaliar custo, serviço, deteriorações e frequência de intervenção nas aplicações Bahia e M5.
5. Diagnosticar limites de representação, aprendizagem, cobertura do portfólio e viabilidade física, identificando o alcance da evidência e a validação ainda necessária.

Os estudos da Paraíba e da qualificação motivaram o desenvolvimento. A evidência quantitativa consolidada compreende 145 séries da Bahia em duas origens e um piloto M5 com 30 séries nas dez lojas, em três origens. O capítulo de resultados separa as bases e suas condições. A avaliação ampliada do M5 está em andamento sob o protocolo unificado e permanece fora das conclusões quantitativas desta versão. A avaliação nacional está fora do escopo experimental desta versão.

1.4 Contribuições e alcance da evidência

A contribuição principal é formular a seleção contextual como um procedimento com compromissos verificáveis. O AIPE encadeia cinco etapas, admite associação por perfil e estimação por série e exige uma referência competitiva para julgar a intervenção. O diagnóstico liga cada perda à decisão que pode corrigi-la: melhorar a escolha, ampliar o portfólio ou rever as condições operacionais. A metodologia torna essas decisões explícitas e passíveis de avaliação.

A contribuição empírica é delimitar a utilidade dessas escolhas em duas aplicações complementares. As vendas de uma rede varejista brasileira preservam heterogeneidade empresarial

observada; o piloto público M5 permite examinar implementações preditivas e suas falhas. Código, matrizes e oráculos sustentam a rastreabilidade da avaliação. Como as consequências são simuladas, o uso de dados reais oferece relevância aplicada, mas não comprova ganho financeiro de implantação.

GA, DQN, PPO e suas combinações são métodos conhecidos. Sua presença no portfólio não constitui novidade algorítmica; a arquitetura GA–DQN já aparece em Zabraoui et al. (2025). O interesse está em entender quando uma alternativa oferece vantagem e se essa informação sustenta uma recomendação verificável.

O procedimento permite avaliar separadamente controladores e seletores. Na Bahia, o PSE por perfil é confrontado com a global; no M5, a avaliação inclui o preditivo e uma extensão exploratória de recuo. O piloto não demonstra vantagem do modelo supervisionado e passa a integrar o desenvolvimento do protocolo final.

As três sementes das políticas estocásticas descrevem variação do treinamento, sem representar novas lojas ou demandas. A análise preserva as dependências por série e loja.

1.5 Escopo e delimitações

A pesquisa trata cada série loja-produto como uma decisão de reposição. Não modela substituição entre produtos, capacidade conjunta nem coordenação multiagente entre lojas e armazéns. O efeito chicote é um indicador complementar de variabilidade, não evidência de otimização de toda a rede.

O simulador avalia políticas sobre históricos preparados. Custos e abastecimento são parâmetros do cenário; roteamento, transporte e integração transacional com ERP ficam fora do escopo. A recomendação proposta é periódica e não troca de política a cada transação. Aprendizado por reforço multiagente, como o discutido por Liu et al. (2025), também não é implementado como coordenação da rede.

Os dados proprietários limitam a divulgação pública. A rastreabilidade depende de código, parâmetros e identificação dos artefatos e recortes. Vendas podem não representar toda a demanda quando há falta de estoque, e ciclos ausentes exigem tratamento cuidadoso. Essas limitações impedem interpretar automaticamente a simulação como ganho econômico realizável.

O Capítulo 2 apresenta os fundamentos; o Capítulo 3, a literatura; e o Capítulo 4, a metodologia AIPE. O Capítulo 5 descreve sua instanciação experimental. O Capítulo 6 reúne as avaliações e seus diagnósticos. As conclusões estão no Capítulo 7, e a continuidade no Capítulo 8.

2

Referencial Teórico

A seleção de políticas de reposição exige distinguir três objetos: o processo de demanda, a regra que produz pedidos e o critério usado para comparar seus resultados. Este capítulo define esses objetos e apresenta os métodos de previsão e inferência utilizados no trabalho. A descrição operacional dos experimentos fica no Capítulo 5.

2.1 Formulação do Problema de Reposição

2.1.1 Política de Reposição: Estado, Ação e Parâmetros

Uma política π transforma o estado observado $\mathbf{s}_t$ em uma quantidade de pedido não negativa:

$$\pi : \mathcal{S} \to \mathcal{A}, \qquad Q_t = \pi(\mathbf{s}_t; \boldsymbol{\theta}).$$

O estado reúne estoque disponível, pedidos em trânsito e informações de demanda disponíveis até a decisão. Os parâmetros $\boldsymbol{\theta}$ podem ser limiares e lotes, no caso de regras analíticas, ou pesos de uma rede neural. Meta-heurísticas ajustam parâmetros de uma regra; aprendizado por reforço ajusta a própria representação da decisão. Todas essas alternativas precisam ser avaliadas sob a mesma dinâmica de estoque.

É necessário separar estoque físico de posição de estoque. O primeiro determina o atendimento imediato; a segunda acrescenta os pedidos em trânsito e evita solicitar novamente unidades já encomendadas. Uma previsão de demanda pode integrar o estado, mas não substitui essas informações. Um vetor reduzido também não garante que o processo seja Markoviano: essa propriedade depende de representar informação suficiente para suas transições.

2.1.2 Função Objetivo e Dinâmica de Estoque

Para um horizonte finito T, o problema conceitual consiste em minimizar o custo esperado:

$$\min_{\pi} \mathbb{E}\left[\sum_{t=1}^{T}\left(hI_t + c_s S_t + c_o^{\text{fix}}\mathbf{1}(Q_t > 0) + c_o^{\text{var}} Q_t\right)\right]. \tag{2.1}$$

I_t é o estoque após atendimento, S_t a demanda perdida, h o custo de manutenção por unidade e ciclo, c_s o custo por unidade não atendida e c_o^{fix}, c_o^{var} os custos fixo e variável de pedido. A esperança representa incerteza da demanda ou do treinamento; repetir uma trajetória determinística não estima essa distribuição.

Se B_t é o estoque antes da chegada e A_t a quantidade recebida no ciclo, a dinâmica de vendas perdidas é

$$S_t = \max(0, D_t - B_t - A_t), \quad I_t = \max(0, B_t + A_t - D_t), \quad B_{t+1} = I_t. \tag{2.2}$$

A demanda não atendida não se acumula como encomenda pendente. A convenção de chegada deve acompanhar a equação: um modelo com prazo efetivo ℓ usa $A_t = Q_{t-\ell}$, como na avaliação temporal principal, com entrega efetiva em dois ciclos. Nos estudos históricos, a fila de tamanho $L+1$ correspondia à chegada em $t+L+1$. As convenções são identificadas separadamente na metodologia.

Minimizar custo sem restrição pode favorecer uma política que quase nunca repõe. Por isso, o trabalho acrescenta um nível mínimo de serviço. A escolha do limiar expressa um compromisso operacional e deve anteceder a comparação. Custos e serviço precisam ser apresentados conjuntamente, pois uma economia obtida com menor atendimento não caracteriza dominância.

2.2 Famílias de Políticas de Reposição

2.2.1 Políticas Clássicas

As políticas clássicas oferecem referências interpretáveis. Sob demanda constante média μ por ciclo, custo fixo K por pedido e manutenção h por unidade e ciclo, o lote econômico é

$$Q^* = \sqrt{2K\mu/h}.$$

Demanda e manutenção devem usar a mesma unidade temporal. A EOQ define o tamanho do lote; um ponto de pedido separado estabelece quando solicitá-lo. Com estoque de segurança, esse ponto pode ser $s = \mu L + z\sigma\sqrt{L}$, sob aproximações sobre demanda e prazo. A implementação histórica será distinguida dessa fórmula porque emprega uma demanda acumulada no

horizonte.

A política (s,S) observa a posição de estoque P_t e pede $\max(0,S-P_t)$ quando $P_t \leq s$. O limiar inferior evita pedidos a cada pequena redução de estoque; o superior determina a recomposição. A concentração de pedidos em lotes pode amplificar a variabilidade a montante, fenômeno associado ao efeito chicote (Lee et al., 1997). A intensidade desse efeito depende dos parâmetros e da demanda, não apenas do nome da política.

O modelo do Jornaleiro determina uma quantidade de período único pelo quantil de demanda associado à razão crítica entre falta e excesso. Na aproximação normal, escreve-se $Q^* = \mu + z_\alpha \sigma$. Essa expressão é ótima somente sob as hipóteses do modelo e com α derivado dos custos pertinentes. Usar $z = 1{,}28$ como parâmetro fixo em uma regra multiperíodo constitui uma heurística inspirada no modelo, não uma garantia de otimalidade.

Regras analíticas podem receber parâmetros específicos por série e, portanto, não pressupõem necessariamente uma única parametrização para toda a rede. Sua simplicidade é uma vantagem comparativa relevante: um método mais complexo precisa demonstrar ganho além do obtido por calibração adequada de uma referência simples.

2.2.2 Parametrização de Políticas via Meta-Heurísticas

Meta-heurísticas procuram vetores $\boldsymbol{\theta}$ em um espaço de busca. Cada candidato induz uma política, cuja execução simulada fornece custo e serviço. Essa abordagem dispensa uma expressão diferenciável para o desempenho, mas continua sujeita a sobreajuste ao histórico usado na busca. O objetivo, os limites dos parâmetros e o orçamento de avaliações devem ser controlados na comparação.

O Algoritmo Genético (GA) mantém uma população de candidatos e alterna seleção, cruzamento e mutação (Holland, 1992; Talbi, 2009). Em reposição, cromossomos podem codificar ponto de pedido e lote; a avaliação associa cada vetor à trajetória resultante (Yuna et al., 2023). Não há garantia geral de ótimo global em orçamento finito.

O Recozimento Simulado (SA) parte de uma solução e explora vizinhos. Uma piora ΔC pode ser aceita com probabilidade $\exp(-\Delta C/T_k)$, em que T_k é a temperatura (Kirkpatrick et al., 1983). Seu resfriamento controla a passagem de exploração para busca local. O resultado depende da escala da função objetivo, da vizinhança e do número de iterações.

Na Otimização por Enxame de Partículas (PSO), cada posição representa um candidato; velocidade, melhor posição individual e melhor posição coletiva orientam a atualização (Kennedy and Eberhart, 1995). A Evolução Diferencial (DE) gera candidatos pela combinação de diferenças entre vetores e aplica cruzamento e seleção (Storn and Price, 1997). Ambos são alternativas para espaços contínuos, mas não constituem, por si, regras operacionais distintas de reposição.

Mesmo quando duas buscas ajustam a mesma regra, seus custos computacionais e soluções podem diferir. A comparação deve identificar qual parte do ganho decorre do algoritmo

de busca e qual decorre da regra parametrizada. Otimizar cada série também é diferente de selecionar, entre políticas já calibradas, qual deve ser aplicada a uma nova série.

2.2.3 Políticas de Reposição via Aprendizado por Reforço

O aprendizado por reforço representa o controle como um processo de decisão $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$. O agente escolhe pedidos, recebe uma recompensa e observa a transição do inventário. Com recompensa $r_t = -C_t$, busca maximizar o retorno descontado $\sum_t \gamma^t r_t$ (Sutton and Barto, 2018). Uma restrição de serviço não é automaticamente satisfeita por essa recompensa: precisa de tratamento explícito ou verificação posterior.

DQN aproxima a função de valor $Q_\theta(s,a)$ por uma rede neural, usando memória de experiências e rede-alvo (Mnih et al., 2015). Sua aplicação requer ações discretizadas. A resolução dessa discretização limita os lotes disponíveis; episódios adicionais sobre a mesma série aumentam interações simuladas, mas não acrescentam novas realizações independentes de demanda.

PPO atualiza uma política por gradiente com uma razão de probabilidades limitada por *clipping* (Schulman et al., 2017). Pode ser formulado com ações contínuas ou discretas; essa propriedade precisa ser informada para cada implementação. Comportamentos como pedidos excessivos ou ausência de reposição podem resultar da recompensa, da escala dos estados, da exploração ou do treinamento. A observação de uma trajetória degenerada não identifica isoladamente sua causa.

SARSA atualiza valores seguindo a própria política:

$$Q(s,a) \leftarrow Q(s,a) + \eta[r + \gamma Q(s',a') - Q(s,a)].$$

A versão tabular exige discretizar o estado; Expected SARSA substitui o próximo valor pela esperança sobre ações. A adequação de cada representação depende da informação preservada e do tamanho do problema, e não permite concluir antecipadamente que uma família será superior nas séries estudadas.

2.2.4 Políticas Híbridas GA-RL

Uma arquitetura híbrida usa a busca evolutiva para obter parâmetros ou experiências iniciais e depois ajusta uma política por reforço. No GA–DQN, transições geradas com a política do GA podem preencher a memória do agente antes do refinamento. Trata-se de uma hipótese de melhoria da inicialização; seu benefício exige comparação com os componentes isolados e controle dos respectivos orçamentos.

A inicialização não elimina o risco de sobreajuste. Se busca e aprendizado observarem a mesma trajetória usada na avaliação, o resultado descreve adaptação ao histórico, não generalização. Além disso, avaliações completas de candidatos do GA e transições armazenadas

no DQN são quantidades diferentes. O trabalho trata o híbrido como candidato do portfólio; o problema de pesquisa é a seleção contextual entre candidatos.

2.3 Demanda Intermitente

Uma série intermitente alterna ciclos sem demanda e ocorrências positivas, cujos tamanhos também podem variar (Croston, 1972; Boylan and Syntetos, 2008). Frequência e magnitude são dimensões distintas. Para $D_t \geq 0$, definem-se

$$n_+ = |\{t : D_t > 0\}|, \tag{2.3}$$

$$\mu = T^{-1}\sum_t D_t, \qquad \sigma^2 = (T-1)^{-1}\sum_t (D_t - \mu)^2. \tag{2.4}$$

A média sobre todos os ciclos descreve o volume por período, mas pode ocultar longos intervalos sem venda. Uma sequência com valores positivos estáveis e muitos zeros é operacionalmente diferente de outra igualmente esparsa, porém com grandes picos.

2.3.1 Taxonomia ADI e CV^2

A classificação de Syntetos and Boylan (2005) combina intervalo médio entre demandas e variação dos tamanhos positivos:

$$\mathrm{ADI} = T/n_+, \tag{2.5}$$

$$\mathrm{CV}_+^2 = (\sigma_+/\mu_+)^2. \tag{2.6}$$

Aqui, μ_+ e σ_+ são calculados apenas nas observações positivas, diferentemente da média e variância da Equação 2.4. Os limiares 1,32 e 0,49 delimitam quatro categorias, resumidas na Tabela 2.1 (Syntetos et al., 2009).

Tabela 2.1: Quadrantes de Syntetos-Boylan: limiares e interpretações.

Regime	ADI	CV^2	Interpretação operacional
Smooth (Regular)	$< 1{,}32$	$< 0{,}49$	Alta frequência, demanda estável.
Erratic (Errático)	$< 1{,}32$	$\geq 0{,}49$	Alta frequência, magnitude irregular.
Intermittent (Intermitente)	$\geq 1{,}32$	$< 0{,}49$	Muitos zeros, magnitude relativamente estável.
Lumpy (Grumoso)	$\geq 1{,}32$	$\geq 0{,}49$	Muitos zeros e magnitude altamente irregular.

A implementação disponível também calcula uma medida de CV^2 incluindo zeros. Essa medida é útil como característica, mas não reproduz exatamente a definição original dos tamanhos positivos. As categorias dos artefatos são mantidas como rótulos operacionais, com essa ressalva; uma comparação entre taxonomias exige recalcular explicitamente ambos os índices.

2.3.2 Efeitos na Reposição

Demanda esparsa dificulta estimar taxas de ocorrência; tamanhos irregulares ampliam o custo de errar lotes e estoques de segurança. Croston separa a estimação dos tamanhos positivos e dos intervalos entre ocorrências. Isso pode melhorar a previsão, mas não estabelece qual regra de reposição minimiza custo sob um prazo e uma restrição de serviço específicos.

Os quadrantes fornecem uma descrição inicial, não uma prescrição de política. Séries no mesmo quadrante podem diferir em volume, tendências, sequências de zeros e concentração de picos. A hipótese do AIPE é que essas diferenças adicionais possam auxiliar a escolha; sua utilidade precisa ser medida contra uma política global bem calibrada, não inferida da classificação.

2.4 Métricas de Previsão

Erros absolutos e quadráticos dependem da escala da série; o MAPE é indefinido quando a demanda observada é zero. O estudo emprega métricas escaladas e sMAPE, com convenções explícitas para denominadores nulos (Hyndman and Koehler, 2006; Makridakis et al., 2020). Nenhuma métrica de previsão substitui a avaliação do efeito da decisão sobre custo e serviço.

2.4.1 Métricas Utilizadas

Sejam $e_t = D_t - \hat{D}_t$ os erros em m pontos de avaliação e $d_1, \ldots, d_n$ o treinamento. O MASE compara o erro absoluto com a variação da referência ingênua:

$$\mathrm{MASE} = \frac{m^{-1} \sum_t |e_t|}{(n-1)^{-1} \sum_{j=2}^{n} |d_j - d_{j-1}|}. \tag{2.7}$$

Valores menores que um indicam erro inferior à escala ingênua (Hyndman and Koehler, 2006). A escala deve vir do treino; séries constantes requerem registro de indefinição ou regularização declarada. A presença de zeros, isoladamente, não impede o cálculo.

O sMAPE usa demanda e previsão simetricamente (Makridakis, 1993):

$$\mathrm{sMAPE} = \frac{200}{m} \sum_t \frac{|D_t - \hat{D}_t|}{|D_t| + |\hat{D}_t|} \,\%. \tag{2.8}$$

Adota-se contribuição zero quando ambos os termos do denominador são nulos. Seu intervalo é de zero a 200%, mas pequenas demandas podem produzir valores elevados; por isso é interpretado junto ao MASE.

A versão quadrática escalada é

$$\mathrm{RMSSE} = \sqrt{\frac{m^{-1}\sum_t e_t^2}{(n-1)^{-1}\sum_{j=2}^{n}(d_j - d_{j-1})^2}}. \tag{2.9}$$

Ela dá maior peso a erros grandes e também requer escala de treino não nula. O RMSSE complementa o diagnóstico; o MASE permanece a referência principal de comparação de previsão no estudo.

O viés médio, $\mathrm{MBE} = \overline{D} - \overline{\hat{D}}$, diferencia subestimação de superestimação. O U de Theil compara RMSE do modelo e da previsão ingênua (Theil, 1966). Esses indicadores auxiliam a interpretação, sem determinar a política vencedora. Uma relação entre menor erro e melhor reposição é hipótese empírica: depende da assimetria de custos, do prazo e da regra de decisão.

2.5 Testes Estatísticos

A comparação usa observações pareadas porque as políticas atendem às mesmas séries. Testes não paramétricos evitam exigir normalidade dos KPIs, mas não dispensam atenção à independência das unidades. Produtos da mesma loja e lojas expostas às mesmas condições podem ser dependentes. Repetições idênticas não aumentam o tamanho efetivo da amostra.

2.5.1 Teste de Wilcoxon

Para diferenças $\Delta_i = X_i^A - X_i^B$, a soma de postos com sinal é

$$W = \sum_{i:\Delta_i \neq 0} \mathrm{sgn}(\Delta_i) R_i, \tag{2.10}$$

em que R_i é o posto de $|\Delta_i|$. O teste de Wilcoxon (1945) avalia uma hipótese de localização sob condições sobre a distribuição das diferenças. Sua leitura como teste da mediana requer, em particular, simetria. Empates e diferenças nulas devem receber tratamento documentado.

2.5.2 Teste de Friedman e Nemenyi

Com K políticas avaliadas nas mesmas N instâncias, o teste de Friedman (1940) compara postos médios:

$$\chi_F^2 = \frac{12N}{K(K+1)} \sum_{j=1}^{K} \left(\bar{r}_j - \frac{K+1}{2} \right)^2. \tag{2.11}$$

A rejeição não identifica sozinha os pares diferentes. O procedimento de Nemenyi usa uma diferença crítica (Nemenyi, 1963):

$$\mathrm{DC} = q_\alpha \sqrt{\frac{K(K+1)}{6N}}. \tag{2.12}$$

Postos separados por mais que DC são distinguidos sob as condições do procedimento. Um posto favorável em custo não representa necessariamente serviço aceitável; as métricas e os limiares precisam permanecer visíveis.

2.5.3 Tamanho de Efeito

A diferença padronizada de médias é reportada como descrição complementar (Cohen, 1988):

$$d = \frac{\bar{X}_A - \bar{X}_B}{s_{\mathrm{pooled}}}, \qquad s_{\mathrm{pooled}} = \sqrt{\frac{(N_A-1)s_A^2 + (N_B-1)s_B^2}{N_A + N_B - 2}}. \tag{2.13}$$

Essa forma não utiliza a covariância do pareamento; medidas baseadas nas diferenças podem ser mais apropriadas para inferência pareada. Faixas convencionais de efeito pequeno, médio ou grande não substituem a diferença de custo em unidades operacionais e sua repercussão no serviço.

O conjunto de testes, efeitos e gráficos descreve a heterogeneidade observada. Não transforma uma escolha retrospectiva de vencedor em evidência de generalização. Essa distinção orienta o protocolo de validação do próximo capítulo: a avaliação de uma política e a avaliação do mecanismo que a seleciona são etapas diferentes.

3

Trabalhos Relacionados

A literatura fornece métodos para prever demanda, calibrar regras e aprender decisões de reposição. A questão desta dissertação é como escolher entre essas alternativas para uma série loja-produto. A revisão distingue o desempenho de uma política da capacidade de um seletor de reconhecer quando utilizá-la.

3.1 Famílias de métodos

Políticas clássicas têm formulações interpretáveis e constituem referências necessárias, mesmo quando se avaliam métodos de aprendizado (Axsäter, 2006; Zipkin, 2000). Meta-heurísticas exploram seus parâmetros; agentes de reforço aprendem ações sequenciais; e a seleção de algoritmos escolhe métodos a partir de características das instâncias. São níveis complementares, não substitutos automáticos.

A Tabela 3.1 resume seu papel no problema estudado. As limitações indicadas são questões de avaliação: não significam que toda implementação de uma família apresente o mesmo comportamento.

3.2 Inventário e demanda intermitente

Clark and Scarf (1960) estabelecem resultados de decomposição para sistemas multi-escalão sob hipóteses específicas. Os textos de Axsäter (2006) e Zipkin (2000) consolidam políticas, custos e medidas de serviço. Para estoques de segurança em redes, o modelo de serviço garantido e suas extensões oferecem outra linha de planejamento (Graves and Willems, 2000; Eruguz et al., 2016; Achkar et al., 2024). Esses resultados não dispensam verificar se demanda, abastecimento e coordenação correspondem ao caso aplicado.

Tabela 3.1: Papel das famílias de métodos na pesquisa.

Família	Decisão ou informação produzida	Questão de avaliação
Políticas clássicas	Quando e quanto pedir por uma regra explícita	Adequação e calibração ao cenário
Previsão	Estimativa de demanda ou de sua distribuição	Efeito da previsão sobre custo e serviço
Meta-heurísticas	Parâmetros de uma política escolhida	Custo de busca e validade fora do ajuste
Aprendizado por reforço	Ação condicionada ao estado	Recompensa, estabilidade e generalização
Seleção de políticas	Escolha de um membro do portfólio	Ganho incremental frente à referência global

A demanda intermitente requer atenção à frequência e ao tamanho das ocorrências. Croston (1972) separam esses componentes na previsão. A classificação ADI$\times$CV^2 diferencia padrões suaves, erráticos, intermitentes e *lumpy* (Syntetos and Boylan, 2005). Essa descrição organiza séries, mas não determina a política de menor custo: o resultado depende também de prazo, custos e serviço exigido.

A revisão de de Kok et al. (2018) mostra a diversidade de estruturas consideradas na otimização multi-escalão. Nesta dissertação, porém, as séries são simuladas como decisões locais. Não se reivindica a otimização conjunta de uma rede geral, nem se transfere uma garantia teórica de otimalidade para um cenário que não atende às hipóteses originais.

3.3 Previsão e utilidade operacional

Históricos com muitos zeros tornam problemático o uso de erros relativos divididos pela demanda observada. O MASE permite comparação entre escalas quando seu denominador é definido, mas séries constantes também exigem tratamento (Hyndman and Koehler, 2006). Métricas de previsão devem ser acompanhadas de convenções para casos degenerados, sem substituir a avaliação de inventário.

Estudos em varejo mostram que o desempenho preditivo depende da granularidade, dos dados e da forma de treinamento (Makridakis et al., 2020; Nasseri et al., 2023). Não há razão para supor que uma rede LSTM será sempre superior a modelos simples em históricos curtos. Um resultado de competição de previsão tampouco demonstra vantagem em custo de reposição.

Tadayonrad and Ndiaye (2023) aproximam a avaliação preditiva de custos e serviço. Essa conexão orienta o AIPE: previsões e seus erros fornecem sinais auxiliares, mas a seleção deve ser julgada pelas consequências da decisão. Para evitar informação futura, previsão, características e calibração precisam respeitar o mesmo corte temporal da avaliação.

3.4 Meta-heurísticas e aprendizado por reforço

Meta-heurísticas procuram soluções em espaços de parâmetros difíceis de tratar analiticamente (Talbi, 2009). Em inventário, permitem ajustar ponto de pedido e lote. Yuna et al. (2023) estudam otimização de parâmetros em demanda intermitente, enquanto Erkayman et al. (2025) combinam modelagem da demanda e busca de parâmetros. O ganho permanece condicionado à política e ao cenário de calibração.

Aprendizado por reforço formula reposição como decisão sequencial. Oroojlooyjadid et al. (2022) estudam DQN no *Beer Game*; Gijsbrechts et al. (2022) discutem aplicações de aprendizado profundo a inventário; e Vanvuchelen et al. (2020) aplicam PPO à reposição conjunta. Outros trabalhos investigam topologias e coordenação descentralizada (Geevers et al., 2024; Liu et al., 2025).

Esses estudos mostram possibilidades de controle adaptativo, mas a aplicação depende de estado, ação, recompensa e dinâmica do simulador. Um agente pode obter serviço elevado emitindo pedidos excessivos ou reduzir custo deixando de atender demanda. Custo, serviço e comportamento das ações precisam ser examinados em conjunto.

Históricos curtos restringem a avaliação, embora o número de ciclos observados não seja igual ao número possível de interações simuladas. Repetir episódios pode ampliar treinamento sem adicionar novos processos de demanda. Comportamento degenerado em uma implementação não demonstra incapacidade geral do algoritmo: pode refletir recompensa, orçamento, parametrização ou erro de código. Essa cautela importa ao interpretar resultados antigos após correções do ambiente.

3.5 Seleção de políticas e meta-aprendizado

Rice (1976) formalizam a escolha de um algoritmo a partir das características de uma instância. Revisões posteriores descrevem seletores supervisionados e sua avaliação (Kotthoff, 2014; Kerschke et al., 2019). No AIPE, a instância é a série loja-produto, o portfólio reúne políticas e a medida de desempenho combina custo e viabilidade de serviço.

A analogia separa três objetos: o melhor método global, o melhor método conhecido para cada instância e o método escolhido pelo seletor. O segundo é uma referência retrospectiva; não é implementável quando sua escolha exige conhecer resultados futuros. O terceiro deve ser avaliado em dados que não determinaram os rótulos ou o ajuste.

O teorema *No Free Lunch* trata de médias sobre classes de problemas sob condições próprias (Wolpert and Macready, 1997). Ele não prova que haverá troca de vencedores neste recorte varejista nem que as características escolhidas permitirão aprendê-la. Essas são questões empíricas. Características de instância podem ajudar na seleção (Kerschke and Trautmann, 2019), mas sua utilidade precisa ser verificada no problema aplicado.

Hiper-heurísticas selecionam ou geram heurísticas, inclusive durante a resolução (Drake

et al., 2020; Dokeroglu et al., 2024). O AIPE tem escopo mais restrito: propõe recomendar periodicamente uma política por série. Não troca controladores a cada estado do estoque nem coordena agentes em tempo real. Trabalhos com *bandits* e contexto investigam outras formas de adaptação em inventário (Preil and Krapp, 2022; Batsis and Samothrakis, 2024); abordagens integradas relacionam características e decisões em outros desenhos operacionais (Qi et al., 2023).

A consequência prática é comparar o seletor com uma referência global forte. A avaliação deve separar o ajuste das políticas da aprendizagem da escolha entre elas. Excluir uma loja do seletor, por exemplo, não elimina informação futura já usada para gerar seus resultados de simulação.

3.6 Antecedentes e delimitação da contribuição

A integração entre classificação de inventário e seleção de política aparece explicitamente em Mohammaditabar et al. (2012); classificação baseada em desempenho é objeto de Sheikh-Zadeh et al. (2021). Esses antecedentes situam a associação entre perfil e política como uma linha estabelecida. A comparação aqui é conceitual: a revisão dirigida verificou os metadados, mas não reproduziu os métodos nem realizou uma comparação algorítmica sustentada pela leitura integral desses estudos.

Francuz and Bányai (2026) apresentam uma estrutura que combina escolha de família, parâmetros e otimização multiobjetivo. Seu modelo de aprendizado aproxima o simulador para reduzir avaliações; a aplicação usa demanda sintética sazonal e pedidos pendentes. Esse desenho difere de aprender uma recomendação para séries reservadas, mas já cobre integração, múltiplas políticas e eficiência por aproximação. O posicionamento do AIPE depende, portanto, de explicitar a decisão de recomendação e a evidência usada para avaliá-la, além de reunir métodos em uma arquitetura.

Elmachtoub and Grigas (2022) fundamentam aprender segundo a consequência da decisão, em vez de apenas erro preditivo. Geifman and El-Yaniv (2019) estudam predição com rejeição; Laroche et al. (2019), melhoria de políticas com recuo à referência sob hipóteses próprias. Esses trabalhos sustentam componentes da extensão conservadora, sem fornecer garantias automáticas para nossa seleção de famílias ou para o fill rate de cada série.

O posicionamento do AIPE é, portanto, metodológico e aplicado: articular contexto, evidência operacional, seleção e decisão de intervenção em um procedimento verificável para reposição. Sua utilidade depende da comparação entre implementações e referências. A revisão não estabelece prioridade sobre toda combinação possível desses mecanismos; uma afirmação de novidade universal exigiria cobertura bibliográfica e comparação mais amplas.

3.7 Arquiteturas híbridas e posicionamento

Zabraoui et al. (2025) combinam busca genética e aprendizado por reforço em um estudo de inventário com dados do Walmart M5. É uma referência próxima do portfólio adotado aqui. A arquitetura GA–DQN e combinações GA–RL não são apresentadas como invenções desta dissertação. Sua inclusão permite investigar se oferecem vantagem em determinados recortes e como se comparam a regras simples sob condições comuns.

A Tabela 3.2 situa o foco da pesquisa sem equiparar bases, contagens de políticas ou protocolos diferentes. Uma comparação quantitativa direta exigiria reproduzir custos, horizontes, demandas e critérios de serviço.

Tabela 3.2: Relação entre linhas da literatura e o foco da dissertação.

Referência	Foco	Relação com esta pesquisa
Oroojlooyjadid et al. 2022	Aprender controle sequencial	Política candidata, não seletor validado
Yuna et al. 2023	Calibrar em demanda intermitente	Busca de parâmetros dentro do portfólio
Zabraoui et al. 2025	Comparação e combinação de algoritmos	Referência das arquiteturas avaliadas
Rice 1976; Kotthoff 2014	Selecionar métodos por instância	Base conceitual do PSE
Esta dissertação	Seleção contextual em varejo brasileiro	Comparar seleção e referência global

O espaço de investigação está na formulação do procedimento AIPE e na avaliação de quando suas recomendações agregam valor. A evidência brasileira e pública permite examinar instâncias distintas, sem provar generalização irrestrita. A contribuição não se reduz ao portfólio nem exige inventar um novo controlador; requer justificar as decisões da metodologia e demonstrar seu alcance. O capítulo seguinte define esse procedimento antes de apresentar sua instanciação experimental.

4

AIPE: Metodologia Proposta

O *Adaptive Inventory Policy Engine* (AIPE) é a metodologia proposta nesta dissertação para organizar a seleção contextual de políticas de reposição. Seu objeto é a decisão sobre qual família aplicar a uma série loja–produto. O procedimento vincula a escolha à informação disponível, à exigência de atendimento e às consequências operacionais. Uma recomendação pode conservar a referência quando faltar evidência para substituí-la.

A metodologia define entradas, etapas, critérios e saídas. A implementação computacional executa o procedimento; Bahia e M5 são aplicações para avaliar sua utilidade. Assim, a proposta não se confunde com um simulador, um classificador ou a lista de algoritmos comparados. Tampouco pressupõe que contextualizar sempre produza economia.

4.1 Objeto, entradas e saídas

Uma instância do AIPE é especificada pelas unidades de decisão, históricos e contexto, portfólio de políticas, ambiente de estoque, regra operacional de comparação e desenho de avaliação. A regra declara custos, serviço e desempates. O desenho informa como separar construção e avaliação da recomendação. Esses elementos precisam estar definidos antes de interpretar os resultados.

Para a unidade i e o instante o, a informação $H_{i,o}$ reúne somente observações disponíveis até a escolha. Obtêm-se características $x_{i,o} = \phi(H_{i,o})$ e, quando disponível, um perfil $g_{i,o}$. Perfil derivado das mesmas características é uma representação resumida, não uma fonte independente de informação. Um perfil informado externamente exige origem e disponibilidade documentadas.

A saída compreende a família recomendada, os parâmetros de aplicação e um registro que identifica contexto, referência, suporte da escolha, restrição de serviço e versão do procedimento. Se nenhuma candidata for viável, essa condição deve ser registrada. Escolher a menos desfavorável não certifica atendimento do alvo.

4.2 Princípios e contribuição investigada

O AIPE distingue seleção da família e calibração de parâmetros; exige comparação operacional compatível; impede informação futura na recomendação; e avalia o benefício incremental frente a uma referência competitiva. Esses princípios se apoiam em seleção de algoritmos e avaliação de modelos (Rice, 1976; Kerschke et al., 2019; Cawley and Talbot, 2010).

A contribuição investigada é a articulação desses princípios em um procedimento de reposição que vincula duas abordagens do PSE à decisão de intervir e ao diagnóstico das perdas. A associação entre contexto e escolha possui antecedentes; a avaliação do AIPE examina como essa articulação define responsabilidades, permite comparar implementações e orienta a revisão dos componentes. Coerência do procedimento, utilidade operacional e transferência entre aplicações constituem critérios distintos de avaliação.

A aplicação requer históricos com cobertura identificável, candidatas executáveis sob convenções comuns e uma definição de serviço. Se vendas estiverem censuradas ou custos forem ilustrativos, a validade da recomendação permanece condicionada a essas limitações. A adaptação refere-se à escolha conforme o contexto e à reavaliação documentada; não significa troca contínua de controlador já validada em produção.

4.3 Procedimento metodológico

O procedimento tem cinco etapas, apresentadas na Figura 4.1. Uma avaliação observada pode motivar uma nova versão; não deve ser reutilizada como confirmação independente dessa revisão.

4.3.1 Especificar a decisão

A especificação fixa o significado de uma recomendação e do benefício esperado. Definem-se unidade, horizonte, dinâmica de estoque e instante da escolha. A exigência de serviço informa se vale para cada série, perfil ou conjunto. Média por série, atendimento ponderado por unidades e restrição individual são objetivos diferentes.

A referência recebe o mesmo acesso ao passado. Uma referência global mantém a família, mas pode ajustar parâmetros para cada unidade. O desenho deve representar o uso pretendido: novas lojas com histórico, períodos futuros e outra população exigem separações distintas. Uma avaliação que exclui lojas não demonstra, sozinha, transferência para produtos novos.

4.3.2 Representar o contexto

A representação disponibiliza ao seletor o contexto que poderá ser observado no uso pretendido. Preparam-se os históricos e calculam-se características ou perfis anteriores à escolha.

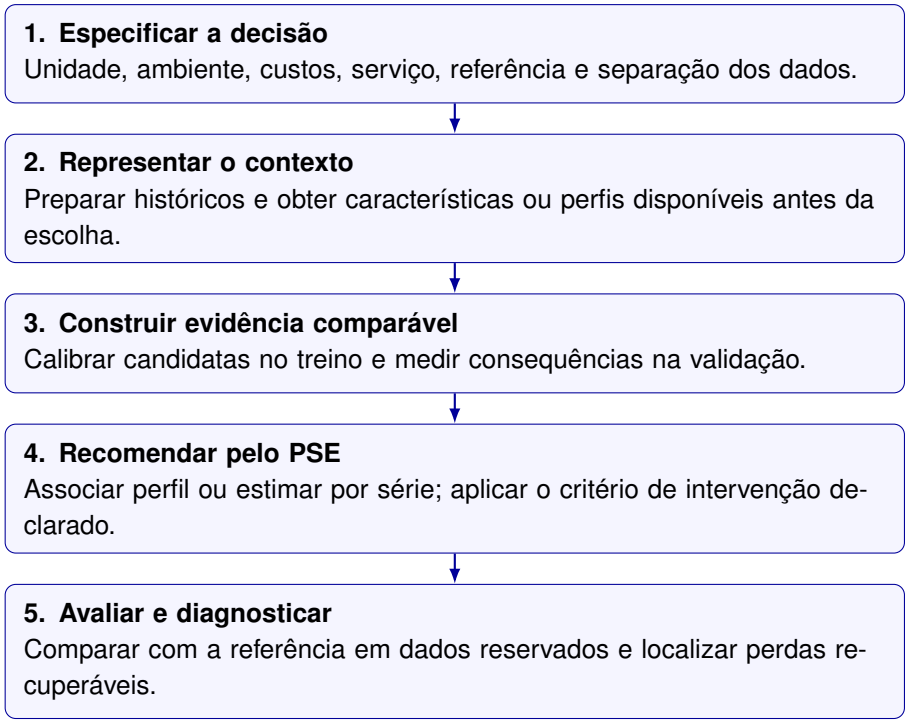


Figura 4.1: Procedimento do AIPE. Revisões motivadas pelo diagnóstico exigem nova avaliação independente.

Elegibilidade, preenchimentos, escalas e codificações respeitam o corte temporal. Ausência de venda, registro e procura não são equivalentes sem justificativa.

A representação é examinada por seu apoio à decisão. Seu objetivo não é maximizar descritores nem produzir grupos artificialmente equilibrados. Perfis raros, variáveis indisponíveis e regras que concentram quase todas as séries em uma categoria integram o diagnóstico de suporte.

4.3.3 Construir evidência comparável

A evidência precisa distinguir diferenças entre políticas de diferenças nas condições de avaliação. Cada família recebe parâmetros ajustados com os dados admitidos para calibração. A validação registra custo, atendimento e esforço sob condições comuns. Estoque inicial, pedidos em trânsito, tratamento terminal e serviço precisam ter a mesma interpretação para todas as candidatas.

Preserva-se a matriz de consequências, em vez de guardar somente a vencedora. Sua identidade pode mudar com janela, semente e empates sem relevância operacional. A matriz permite construir associações por perfil, rótulos ou alvos de custo e serviço. Vencer na validação não prova vantagem futura.

4.3.4 Recomendar pelo PSE

O *Policy Selection Engine* (PSE) converte contexto e evidência de validação em uma recomendação. Duas abordagens respondem à mesma decisão:

$$\text{por perfil: } \widehat{p}_i = m(g_i), \qquad \text{preditiva: } \widehat{p}_i = f(x_i, g_i) \text{ ou } f(x_i).$$

A primeira consulta uma associação entre perfil informado e família. A segunda estima uma recomendação por série, com perfil opcional. PSE não é sinônimo de classificador.

O preditivo pode aprender a identidade da vencedora ou estimar suas consequências. Nesta última implementação, prevê custo $\widehat{C}_{i,p}$ e serviço $\widehat{F}_{i,p}$ para cada candidata p e escolhe, por exemplo,

$$\widehat{p}_i = \arg \min_{p:\widehat{F}_{i,p} \geq \alpha} \widehat{C}_{i,p}.$$

Se nenhuma for prevista como viável, aplica-se a contingência declarada. Avaliar erro pela consequência operacional tem fundamento em aprendizado orientado à decisão (Elmachtoub and Grigas, 2022); não é apresentado como invenção geral do AIPE.

Uma regra de intervenção a_i determina se a candidata substitui a referência:

$$p_i^{\text{AIPE}} = \begin{cases} \widehat{p}_i, & a_i = 1, \\ p_i^{\text{ref}}, & a_i = 0. \end{cases}$$

A regra pode permitir a escolha direta ou exigir benefício previsto e suporte. Limiares são definidos no desenvolvimento, sem consultar o teste reservado. Recuo e predição seletiva têm antecedentes (Geifman and El-Yaniv, 2019; Laroche et al., 2019). A questão investigada é sua utilidade na escolha de famílias de reposição. Confiança de classe e serviço previsto não garantem atendimento realizado.

4.3.5 Avaliar e diagnosticar

A avaliação mede se a recomendação acrescenta valor à referência. Depois de fixar as escolhas, comparam-se custo, serviço, deteriorações e intervenções em dados que não determinaram o ajuste. Acurácia e frequência de vitória são auxiliares: trocar políticas quase empatadas difere de provocar uma ruptura importante.

O diagnóstico distingue erro de escolha com candidata viável, insuficiência do portfólio apesar de possibilidade física e inviabilidade nas condições do sistema. Demanda zero fica separada. Um planejamento com informação perfeita fornece limite retrospectivo, não desempenho operacional disponível sem conhecer o futuro. A constatação de uma limitação deve orientar a revisão do componente correspondente.

4.4 Metodologia e instanciação

Tabela 4.1: Compromissos do AIPE e escolhas dependentes da aplicação.

Compromisso metodológico	Escolha de instanciação
Contexto anterior à decisão	Descritores, perfil e histórico mínimo
Comparação operacional compatível	Portfólio, ambiente, custos e prazo
Separação entre ajuste, escolha e teste	Janelas e grupos de validação
Referência e contingência explícitas	Família e critério de intervenção
Avaliação incremental rastreável	Métricas, tolerâncias e incerteza

Trocar base, modelo ou limiar não cria uma nova metodologia: essas escolhas instanciam o procedimento. Usar informação futura ou custos incompatíveis viola seus compromissos. As cinco etapas podem ser aplicadas a outros cenários, mas essa possibilidade de especificação não demonstra generalização empírica para eles.

Na implementação atual, políticas e seletores seguem interfaces verificadas no fluxo de pesquisa. O pré-processamento é compartilhado, o avaliador confere a cobertura da matriz e a fila distingue ajuste de controladores e pontuação das recomendações. A substituição de métodos preserva o significado dos dados, ações e indicadores; mudar o ambiente ou a informação disponível exige outra verificação. A comparação experimental exercita alternativas de portfólio e seleção, sem validar indiscriminadamente todos os módulos possíveis.

4.5 Critérios de avaliação da contribuição

A **coerência** exige entradas, recomendações e consequências identificáveis, sem antecipação do teste. A **utilidade** exige comparação com referências fortes, considerando custo, serviço e deteriorações. A **transferibilidade** exige investigar a persistência das conclusões em outras séries, lojas, períodos e condições.

Essas dimensões não são intercambiáveis. Um procedimento reproduzível pode recomendar mal; um ganho localizado pode não se transferir. Um resultado desfavorável de determinada implementação limita sua utilidade demonstrada, sem resolver a avaliação de todas as implementações possíveis. A avaliação, portanto, precisa vincular cada conclusão ao critério que a sustenta.

No uso pretendido, o AIPE reaproveita evidências de outras unidades para recomendar uma família antes de comparar todas novamente. Na avaliação, o portfólio completo é ajustado nas unidades reservadas para medir consequências e oráculos. Essa despesa experimental não demonstra economia computacional de implantação. O próximo capítulo apresenta as escolhas usadas para avaliar o procedimento na Bahia e no piloto M5.

5

Desenho da Avaliação Experimental

Este capítulo instancia a metodologia AIPE nas aplicações Bahia e M5. Dados, custos, prazos, políticas, modelos e janelas descritos a seguir são escolhas experimentais; não definem requisitos universais da metodologia. O protocolo separa o ajuste dos controladores, a construção do seletor e a avaliação das recomendações.

5.1 Sistema de estoque e objetivo

O ambiente simula vendas perdidas com prazo exato de dois ciclos. A política decide antes do recebimento; entregas chegam antes da demanda. Faltas não são acumuladas como pedidos pendentes. Quantidades não negativas podem ser fracionárias. Não há restrição conjunta de transporte, transbordo ou disputa entre lojas por estoque.

O custo da Equação 2.1 soma manutenção do saldo após atendimento, falta, emissão e quantidade pedida. Os valores são $h = 1$, $c_s = 5$, $c_o^{\text{fix}} = 50$ e $c_o^{\text{var}} = 0{,}5$, sem crédito terminal. São unidades de cenário, sem calibração financeira. Pedidos em trânsito não atendem demanda antes da chegada.

5.1.1 Métricas e definição do serviço

Registram-se custo total de inventário (CTI), atendimento (NS), taxa de ruptura (TR), frequência de pedidos (FP) e amplificação de variância (BE):

$$\text{NS} = \frac{\sum_t (D_t - S_t)}{\sum_t D_t}, \qquad \text{TR} = \frac{\#\{t : S_t > 0\}}{T}, \qquad \text{FP} = \frac{\#\{t : Q_t > 0\}}{T}.$$

Aqui, S_t é falta e BE é $\text{Var}(Q)/\text{Var}(D)$, com convenção registrada para variância nula. NS é fração de unidades atendidas, não probabilidade de um ciclo sem falta. Demanda total zero mantém NS indefinido; o custo continua na análise.

O limiar é 0,70. A média por série, a razão entre unidades totais atendidas e demandadas e a garantia de 0,70 em cada série não são equivalentes. Por isso, reportamos custo, média de NS, atendimento ponderado quando disponível e contagem de violações. Custo baixo com pouco atendimento não caracteriza eficiência operacional.

5.2 Dados, preparo e cobertura

A avaliação proprietária utiliza 145 séries da Bahia, em 115 lojas e nove produtos, com 38 ciclos de 202301 a 202504. Registros complementares são somados por armazém, loja, produto e ciclo; ciclos sem venda recebem zero. A coorte mantém identificadores históricos. Em cada origem, exige-se pelo menos três ciclos positivos no treino. Esse requisito é passado-dependente, mas não torna prospectiva a seleção inicial dos identificadores.

O piloto M5 utiliza 30 séries FOODS das dez lojas, com três por loja. O sorteio usa três estratos de volume médio do prefixo de 50 ciclos, com uma escolha por estrato e semente 20261015. As 30 séries permanecem nas origens 50, 64 e 78. São ciclos completos de 21 dias, sem corte de picos por IQR. O sorteio parte das 885 elegíveis na primeira origem da coorte histórica local de 2.408 IDs, sem representar todas as FOODS ou séries elegíveis somente depois.

Tabela 5.1: Matrizes completas incluídas na avaliação. Sementes e origens são medidas repetidas.

Dimensão	Bahia	Piloto M5
Séries / lojas	145 / 115	30 / 10
Origens do treino	17 e 23	50, 64 e 78
Validação / teste	7 / 7 ciclos	7 / 7 ciclos
Casos série–origem	290	90
Ajustes de políticas	4.350	1.350
Testes com demanda positiva	283	86

Vendas podem omitir demanda censurada por ruptura. Reindexar ausência de venda como zero pressupõe cobertura da fonte, não prova ausência de procura. Os dados brasileiros são restritos; M5 é público. O recorte local é inspirado no contexto de Zabraoui et al. (2025), sem identidade comprovada de filtros, amostra ou implementação.

5.3 Características e perfis

O preditivo recebe 17 características: ADI, CV^2, intermitência, proporção de zeros, maior e média das sequências de zeros, burstiness, assimetria, curtose, entropia, tendência, autocorrelação, média, desvio-padrão, CV, extensão e número de ciclos positivos. Todas usam somente o treino; perfil e metadados não alteram essa restrição temporal.

A característica CV^2 inclui zeros, diferindo da taxonomia original baseada em tamanhos positivos (Seção 2.3.1). Burstiness é $(s_\tau - \bar{\tau})/(s_\tau + \bar{\tau} + 10^{-9})$ nos intervalos entre ocorrências positivas, recebendo zero com menos de dois intervalos (Goh and Barabási, 2008). Tendência é a inclinação OLS dividida pela média regularizada; entropia usa dez classes de mesma largura. Autocorrelação na defasagem 17 recebe zero com até 18 ciclos ou variância desprezível. Zero nessa condição significa estimativa indisponível.

Tabela 5.2: Perfis: primeira regra satisfeita determina a classe.

Perfil	Condição
Sparse High Impact	ADI $\geq 1{,}32$, $CV^2 \geq 0{,}49$, sequência de zeros ≥ 5
High Volatility Seasonal	Autocorrelação $\geq 0{,}25$ ou burstiness $\geq 0{,}30$
Unstable Trend	Tendência absoluta $\geq 0{,}05$ ou entropia ≥ 2
Low Volume Stable	Média ≤ 2, $CV^2 < 0{,}49$
Fast Moving	ADI $< 1{,}32$

Os nomes são heurísticos; casos não cobertos recebem Sparse High Impact. Não se assume sazonalidade ou impacto econômico empiricamente comprovados. A coluna de política previamente associada aos nomes no código não gera os rótulos do experimento: custos e serviço na validação definem a escolha.

5.4 Portfólio e calibração

EOQCycle, sSCycle, CappedBaseStock, GA, PPO, GA–DQN e DQN compõem o portfólio. DQN é controle necessário do híbrido. Outros métodos preservados no projeto não são resultados adicionais desta matriz. A composição privilegia diversidade de regras; sua retirada do escopo não estabelece inferioridade universal.

5.4.1 Referências e busca de parâmetros

Com média $\hat{\mu}$ e desvio populacional $\hat{\sigma}$ do treino, as escalas são

$$I_0 = \hat{\mu}L + 1{,}28\hat{\sigma}\sqrt{L}, \tag{5.1}$$

$$Q_{\text{ref}} = \max(1, \sqrt{2\hat{\mu}c_o^{\text{fix}}/h}), \tag{5.2}$$

$$s_{\text{ref}} = \hat{\mu}L + 1{,}28\hat{\sigma}\sqrt{L}. \tag{5.3}$$

EOQCycle pede lote fixo ao atingir o ponto; sSCycle repõe até $s_{\text{ref}} + Q_{\text{ref}}$. Não se alega otimização exata de (s, S). CappedBaseStock calibra alvo e teto em grade 20×12, motivada pela família de Xin (2021).

GA ajusta gatilho, lote e proteção adicional com 100 indivíduos e 50 gerações. Seu objetivo acrescenta penalidade pelo déficit de serviço à referência

$$\boldsymbol{\theta}_i^* = \arg\min_{\boldsymbol{\theta}\in\Theta_i} \mathrm{CTI}(\pi_{\boldsymbol{\theta}}, i) \quad \text{sujeito a } \mathrm{NS}(\pi_{\boldsymbol{\theta}}, i) \geq 0{,}70. \tag{5.4}$$

Penalização não garante viabilidade; o serviço observado deve ser conferido. Na Bahia, a calibração da CappedBaseStock também utiliza ruptura e amplificação dos pedidos com pesos unitários; no M5, esses pesos são zero. As matrizes representam instanciações específicas, sem equivalência plena entre objetivos de treino.

5.4.2 Reforço e híbrido

DQN utiliza Double DQN dueling e PPO utiliza otimização proximal, com duas camadas de 64 unidades e 20 ações discretas. O estado reúne estoque, referência ingênua de demanda, pedidos em trânsito, média e dispersão dos últimos seis ciclos e posição no horizonte. Escalas vêm do treino; observações são passadas. Previsores especializados disponíveis no projeto não alimentam os resultados reportados.

O orçamento mínimo é de 20 mil transições, arredondado ao episódio completo. GA–DQN acrescenta a busca genética e mil demonstrações. Acima do gatilho genético, pede zero; abaixo, executa o máximo entre a ação da rede e metade do lote genético. Essa transformação é igual em demonstração, treino e aplicação. O esforço excede o do DQN; não se isola causalmente o benefício da combinação (Zabraoui et al., 2025).

GA, PPO, DQN e GA–DQN usam sementes 11, 29 e 47; as referências determinísticas têm um ajuste. Primeiro promediamos as sementes dentro de série, origem e política. Elas representam variação do treinamento, não novas realizações de demanda.

5.5 Separação temporal e comparação

Em cada origem o, o desenho é

$$\underbrace{1,\ldots,o}_{\text{treino}} \; ; \; \underbrace{o+1,\ldots,o+7}_{\text{validação}} \; ; \; \underbrace{o+8,\ldots,o+14}_{\text{teste}}. \tag{5.5}$$

Na Bahia, os testes compartilham um ciclo; no M5, ocupam 58–64, 72–78 e 86–92, sem sobreposição. Não se combinam origens posteriores para recomendar em uma anterior.

A validação começa após seis ciclos de aquecimento com referência EOQ. A trajetória dessa referência na validação fornece estoque e pipeline comuns no teste. O estado usa apenas o passado e não continua o estoque próprio de cada candidata. Essa convenção isola comparações no mesmo ponto inicial, sem simular implantação contínua de cada política.

Uma loja inteira é excluída do conjunto que define o seletor, separadamente em cada origem. As outras lojas fornecem resultados de validação; a loja reservada fornece o teste. O controlador conserva o treino no histórico da própria série. Avalia-se transferência do seletor com histórico disponível, não generalização para lojas sem observações.

5.6 Instanciação dos seletores

5.6.1 Associação e rótulos

Para um conjunto A de casos de validação, a regra global escolhe

$$\hat{\pi}_A = \arg \min_{\pi : \bar{F}_{\pi,A} \geq 0{,}70} \bar{C}_{\pi,A}. \tag{5.6}$$

O PSE por perfil aplica a regra a cada A_g. Sem viável, escolhe maior NS e menor custo; perfis sem suporte usam a global. O rótulo preditivo usa o mesmo critério na série individual. Serviço inteiramente indefinido leva a menor custo, com marcação de demanda zero. Empates restantes usam convenção determinística registrada na análise.

As restrições por série e por grupo diferem; a moda dos rótulos é um controle adicional com o mesmo alvo categórico. Todos os seletores são avaliados pelas consequências de suas escolhas. Acurácia é auxiliar: errar entre políticas quase empatadas difere de perder muito serviço.

5.6.2 Aprendizado e recuo conservador

O piloto utiliza XGBoost com 200 árvores, profundidade três, taxa 0,05, semente fixa e sem subamostragem. Imputação, codificação do perfil e classes são ajustadas dentro de cada fold. Classes raras não são removidas; uma classe única leva a classificador constante. Cada treinamento tem 27 exemplos.

A ablação retira somente a entrada de perfil. Após o diagnóstico, uma extensão recua ao PSE por perfil quando o maior escore é menor que 0,60 ou a classe prevista tem menos de três exemplos no treino. A regra não observa o teste ao decidir, mas foi motivada pelos resultados do piloto: é desenvolvimento, não confirmação independente (Cawley and Talbot, 2010). O escore não é probabilidade calibrada de serviço.

5.6.3 Comparação reduzida por consequências

A extensão usa a mesma matriz M5, sem repetir ajustes de controladores. Duas florestas Extra-Trees estimam custo e serviço das sete candidatas: 64 árvores, profundidade máxima quatro e mínimo de três observações por folha. O custo é aprendido como $\log(1+C)$ e transformado de

volta. O serviço usa casos definidos, sem transformar demanda zero em atendimento completo. A recomendação direta escolhe menor custo previsto entre candidatas com serviço previsto de pelo menos 0,70; sem candidata viável, prioriza serviço e depois custo.

A variante com recuo usa a global como referência e exige serviço previsto de pelo menos 0,70, serviço previsto não inferior ao da referência e economia acima de uma margem. A margem pertence a $\{0;0{,}02;0{,}05;0{,}10;\infty\}$, sendo ∞ o recuo permanente. Ela minimiza custo na validação interna sujeita a serviço médio não inferior à referência. Cada origem mantém uma loja externa reservada; dentro das outras nove, exclui-se uma loja por vez para ajustar em oito. Depois da escolha da margem, o modelo externo é ajustado em nove lojas e recomenda para a décima.

Um classificador ExtraTrees com a mesma regularização oferece um controle por rótulo vencedor; outra ablação remove o perfil da previsão de consequências sem recuo. As recomendações são persistidas antes da pontuação do teste. Ainda assim, o piloto já motivou o desenho: a análise é exploratória. O critério empírico não garante atendimento futuro, e a diferença entre objetivos individuais previstos e objetivos médios dos comparadores permanece uma limitação.

5.6.4 Instanciação unificada em consolidação

A entrada atual separa planejamento, ajuste dos controladores e avaliação dos seletores. A preparação audita painéis, identidades, código e configurações antes de aproveitar checkpoints. A avaliação recusa matrizes incompletas e usa o mesmo pré-processamento para modelos por classe e por consequências, ajustado somente no conjunto admitido em cada fold.

O desenho unificado mantém uma loja externa reservada por origem e divide as lojas restantes em cinco grupos internos para escolher a margem de intervenção. Cada grupo interno é excluído do ajuste que produz suas previsões. Esse desenho substitui a exclusão interna de uma loja por vez apenas na avaliação ampliada; os resultados da comparação reduzida apresentados nesta dissertação permanecem associados ao protocolo que os gerou. A divisão em grupos reduz esforço, mas não garante recomendações idênticas.

Na Bahia, preservam-se 145 séries e duas origens, com avaliação também dos seletores preditivos. A CappedBaseStock passa a usar pesos zero de ruptura e amplificação, como no piloto M5; seus 290 ajustes precisam ser refeitos. Os outros 4.060 ajustes foram considerados compatíveis na auditoria. No M5, a continuidade mantém 2.408 identificadores históricos e elegibilidade por origem; a auditoria identificou 9.906 ajustes reaproveitáveis entre as fontes, sem zerar os resultados anteriores. Essas contagens descrevem execução e reaproveitamento, não novas observações independentes.

O avaliador compara global, perfil, classe vencedora com e sem perfil, moda dos rótulos, floresta de classe de controle e previsão de consequências com e sem perfil e com recuo. Características e ambiente permanecem fixos; essas variantes exercitam sobretudo portfólio e

seleção. A comparação por loja, as intervenções, os oráculos e as causas das falhas integram as saídas. A interpretação distingue execução das interfaces e benefício operacional.

As matrizes em consolidação ainda não atualizam as tabelas desta versão. A avaliação brasileira com vendas reais tem relevância aplicada própria; continua sendo uma simulação, com custos de cenário e possível censura das vendas. A apresentação conjunta com M5 fornece contextos complementares, sem misturar seus custos nem transformar a ampliação em confirmação independente do piloto.

5.6.5 Aplicação e reavaliação

O resultado é uma recomendação acompanhada de evidências de custo, serviço e suporte da escolha. Recalcular descritores entre janelas não equivale a retreinar o modelo. Frequência de atualização, integração operacional e supervisão humana ainda exigem desenho próprio; não foram validadas como implantação contínua.

5.7 Oráculos e decomposição das falhas

O melhor controlador único no teste e a melhor candidata por caso são referências retrospectivas. Não fornecem rótulos para a escolha. O oráculo do portfólio usa as médias entre sementes e a regra de menor custo viável. Empates numéricos contam como acerto sem exigir identidade nominal.

No M5, o planejamento com informação perfeita conhece a demanda do horizonte. Seu MILP mantém custos, prazo e estado inicial, com quantidades contínuas e variáveis binárias de emissão e saldo. Para falta u_t, chegada inicial a_t e pedido q_{t-L}:

$$I_t - u_t = I_{t-1} + a_t + q_{t-L} - d_t, \quad I_t u_t = 0, \quad \sum_t u_t \leq (1-\alpha) \sum_t d_t.$$

A complementaridade é linearizada com variáveis binárias e limites suficientes para o horizonte. Pedidos sem chegada antes do fim recebem zero, sem crédito terminal. Quando o alvo é fisicamente impossível nas primeiras entregas, maximiza-se atendimento antes de minimizar custo. Cada solução é conferida no simulador e recebe status de otimalidade.

Esse ótimo é determinístico e condicional, não o melhor controlador estocástico implantável. A eficiência $100C^*/C_{\mathrm{AIPE}}$ só é calculada sob o mesmo critério de serviço, com ambos os custos zero equivalendo a 100%. Compara-se o MILP com cada realização de treinamento viável, pois cumprir o alvo na média das sementes não implica cumpri-lo em cada uma.

A decomposição distingue atendimento do alvo, erro de seleção com alternativa viável, ausência de candidata viável apesar de possibilidade física, limite inicial do sistema e demanda zero. Assim, uma falta não é atribuída automaticamente ao seletor.

5.8 Incerteza e rastreabilidade

Bootstrap pareado preserva produtos e origens de cada loja: 5.000 sorteios na Bahia, 2.000 na avaliação original M5 e 5.000 na comparação reduzida por consequências. Ajustes e escolhas permanecem fixos; os intervalos são condicionais. Dependência entre lojas que compartilham produtos e a pequena quantidade de lojas do piloto limitam a inferência.

Manifestos, snapshots, sementes e bancos transacionais identificam a implementação de cada matriz. Os resultados derivam de `bahia145_cpu16_2026-10-15` e `m5_pse_pilot30_v2_2026-10-15`, em `experiment/data/08_reporting/research_v2`. O diagnóstico registra predições reproduzidas e regras exploratórias. A comparação por consequências está em `m5_pse_consequences30_v2_2026-10-15`. Dados não integram o Git e possuem backup separado; código e fontes documentais estão versionados.

Os estudos brasileiros anteriores, incluindo a qualificação, motivam a investigação. A evidência quantitativa deste capítulo usa somente as matrizes descritas, sem misturar configurações. A expansão nacional está cancelada. A continuidade M5 e a avaliação unificada ficam fora das conclusões quantitativas até sua consolidação e conferência.

6

Resultados e Discussão

Este capítulo avalia as instanciações da metodologia AIPE, distinguindo qualidade dos controladores, utilidade da seleção e limites da recomendação. A Bahia examina o PSE por perfil em 145 séries; o piloto M5 examina as duas abordagens em 30 séries e três origens. As bases permanecem separadas, com seus próprios denominadores e calibrações. O piloto também serve ao desenvolvimento do seletor, sem representar confirmação independente da extensão com recuo.

Os números a seguir pertencem às matrizes e protocolos identificados no Capítulo 5. A avaliação unificada amplia os seletores da Bahia e harmoniza uma calibração, mas suas saídas ainda precisam de consolidação e auditoria antes de atualizar tabelas, figuras ou conclusões. Assim, os resultados do piloto não são atribuídos à validação interna em cinco grupos adotada nessa ampliação.

6.1 Resultados: valor da seleção por perfil

6.1.1 Quais candidatas oferecem compromissos competitivos?

A Tabela 6.1 resume os 290 casos série–origem. Sete casos não têm demanda no teste: um na primeira origem e seis na segunda. Seus custos permanecem na média dos 290 casos; o atendimento médio utiliza os 283 casos com denominador positivo. O atendimento ponderado é a razão entre a soma das unidades atendidas e a soma da demanda nos blocos avaliados, após a média das sementes. As origens repetidas não ampliam a amostra para 290 séries independentes.

PPO tem o menor custo descritivo, acompanhado do menor atendimento médio. Apenas EOQCycle e sSCycle superam 0,70 no conjunto dos testes; nenhuma política alcança essa meta no atendimento ponderado. Entre essas duas referências, sSCycle apresenta menor custo

Tabela 6.1: Bahia, protocolo temporal: médias no teste de sete ciclos. Custo em unidades do cenário, calculado nos 290 casos. Atendimento médio e contagem abaixo da meta consideram os 283 casos com demanda positiva; sete casos têm atendimento indefinido.

Política	Custo	Atendimento	Ponderado	Abaixo de 0,70
EOQCycle	166,77	0,7787	0,6265	101
sSCycle	164,23	0,8037	0,6802	90
CappedBaseStock	218,11	0,6631	0,4948	148
GA	143,85	0,6953	0,5457	140
PPO	134,23	0,5514	0,4189	171
GA–DQN	145,75	0,6802	0,5248	144
DQN (controle)	164,88	0,5718	0,4033	164

e maior atendimento médio. Essa comparação é um diagnóstico do teste, não uma escolha retrospectiva a ser atribuída ao seletor.

GA–DQN custa 11,60% menos que DQN e aumenta o atendimento médio de 0,5718 para 0,6802. Frente ao GA isolado, porém, custa 1,32% mais e atende menos, com média de 0,6953 para o GA. O refinamento híbrido não oferece vantagem agregada nessas duas dimensões sobre seu componente evolutivo. A diferença varia entre origens: na segunda, seu custo é ligeiramente menor que o do GA, também com menor atendimento. A comparação não isola causalmente o benefício das demonstrações ou do gatilho e não justifica excluir o híbrido antes de consolidar a avaliação M5.

A Figura 6.1 distingue economia aparente por baixo atendimento de um compromisso competitivo. A restrição usada pelo seletor continua sendo avaliada na validação, sem recorrer a essa fronteira de teste.

6.1.2 O perfil melhora a decisão frente à seleção global?

Tabela 6.2: Escolha na validação das demais lojas e avaliação no teste da loja reservada, com meta 0,70. Há 145 casos por linha; atendimento definido em 144 casos na origem 17 e 139 na origem 23.

Treino	Estratégia	Custo	Atendimento	Abaixo de 0,70
17 ciclos	Global	180,58	0,5711	101
17 ciclos	Perfil	186,79	0,6475	82
23 ciclos	Global	142,03	0,9073	18
23 ciclos	Perfil	142,03	0,9073	18

Na primeira origem, a regra global escolhe GA para todas as séries. Por perfil, as escolhas são GA em 65 casos, sSCycle em 75 e EOQCycle em cinco. O maior atendimento custa mais, e ambas as estratégias ficam abaixo da meta no teste. Na segunda origem, os dois seletores escolhem sSCycle em todos os casos. A Tabela 6.2 evidencia, portanto, tanto mudança temporal da escolha global quanto ausência de diferenciação contextual na segunda janela.

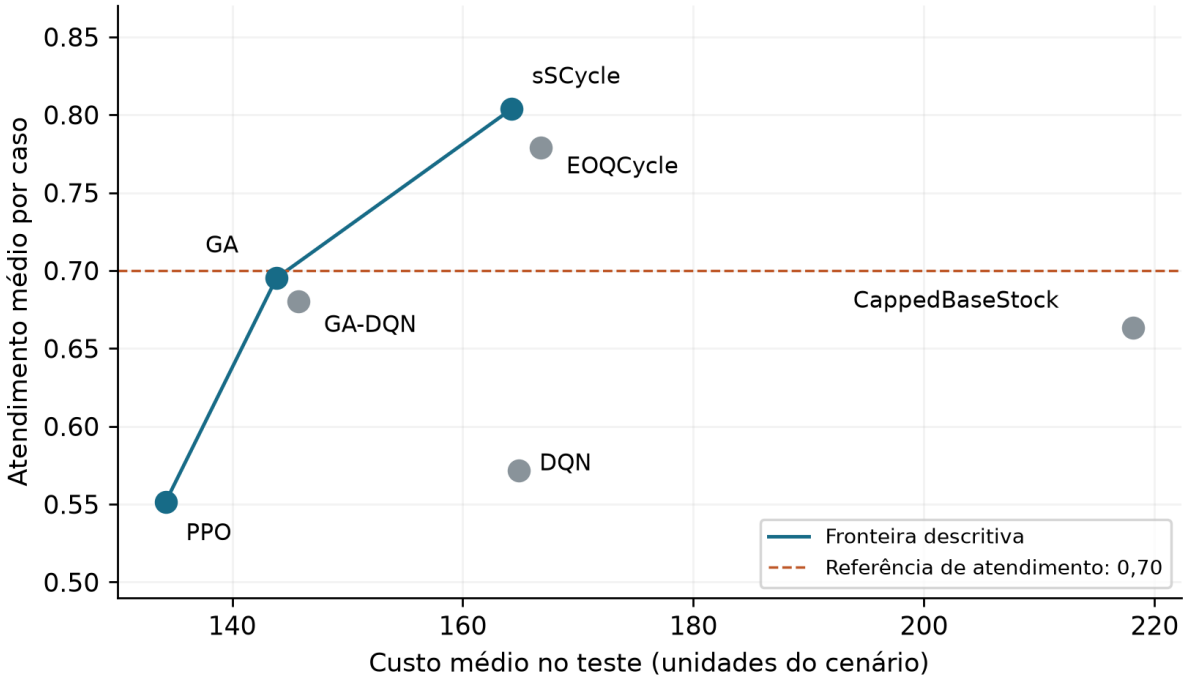


Figura 6.1: Compromisso custo–serviço das sete candidatas na Bahia. Médias de teste em 290 casos série–origem para custo e 283 com demanda positiva para atendimento. A fronteira é descritiva: não utiliza o teste para escolher a recomendação nem representa dominância estatística ou por série.

No conjunto das origens, o custo médio passa de 161,31 na estratégia global para 164,41 por perfil: aumento de 1,93%. O atendimento médio cresce de 0,7362 para 0,7751, diferença de 3,89 pontos percentuais; o ponderado passa de 0,5750 para 0,6395. Os casos abaixo da meta diminuem de 119 para 100, entre os 283 com atendimento definido. Não há redução de custo, mas há melhora de serviço, concentrada na primeira origem. Essa melhora não assegura atendimento mínimo individual nem equivale a cumprir uma meta ponderada de 0,70.

Uma reamostragem exploratória pareada de 115 lojas, com 5.000 sorteios e todas as origens e produtos de cada loja preservados, produz intervalo condicional de 95% de $[-0{,}32; 4{,}16]\%$ para o aumento de custo por perfil. Os controladores e seletores permanecem fixos nos sorteios. O intervalo inclui zero e não representa incerteza de novos treinamentos ou de novas trajetórias de demanda; dependência entre lojas que compartilham produtos também permanece possível.

A sensibilidade reforça a distinção entre meta de escolha e serviço futuro. Em 0,80, todas as escolhas da segunda origem são contingências por ausência de candidata viável na validação, apesar do serviço posterior de 0,9073. Em 0,90 e 0,95, ambas as estratégias usam contingências nos 290 casos. Atendimento futuro alto não torna retroativamente viável uma escolha que descumpria o critério na validação.

A Figura 6.2 mostra por que a comparação não se esgota na média: a primeira janela concentra violações de serviço, enquanto a segunda tem distribuição e escolha coincidentes

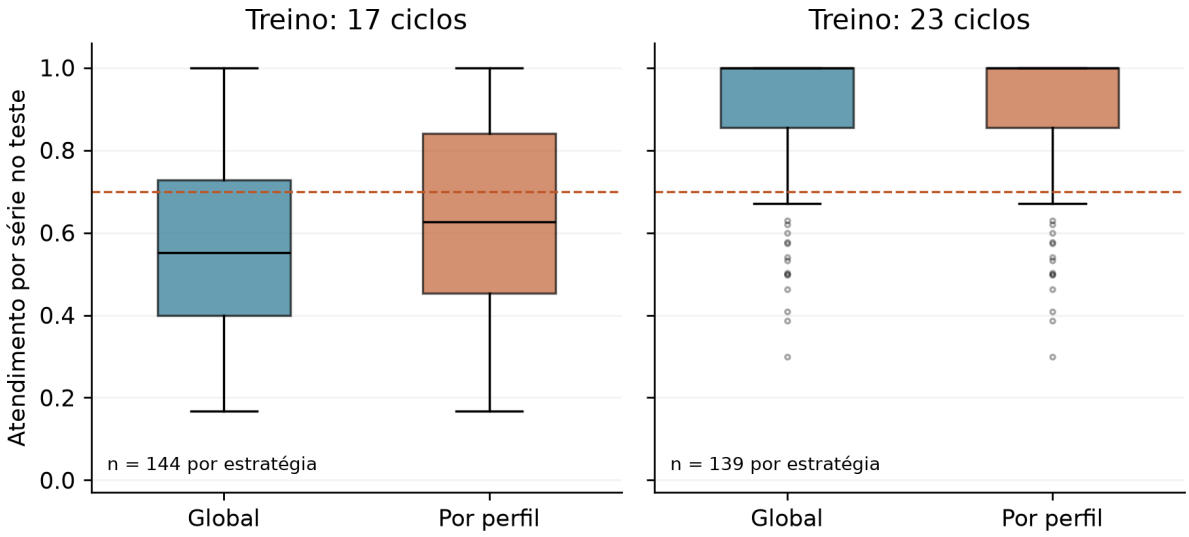


Figura 6.2: Distribuição do atendimento das estratégias no teste, por origem. Cada caixa resume séries com demanda positiva; a linha tracejada indica 0,70. Há 144 casos por estratégia na primeira origem e 139 na segunda. As mesmas séries participam das duas estratégias; observações e origens não são independentes.

entre estratégias.

6.1.3 As escolhas e o atendimento são estáveis entre períodos?

Os perfis são recalculados no prefixo disponível em cada origem. Com 17 ciclos, há 65 séries Sparse High Impact e 80 Unstable Trend; com 23, são 60, 69 e 16 High Volatility Seasonal. Essa mudança reflete a janela e as regras de caracterização, inclusive a indisponibilidade da autocorrelação na primeira origem. Não demonstra mudança de regime econômico em todas essas séries.

A Figura 6.3 localiza a diferenciação que produz o serviço adicional: na primeira origem, a regra por perfil substitui GA por sSCycle ou EOQCycle em parte das séries. Na segunda, identificar perfis não muda a política recomendada. Assim, a existência de grupos distintos não implica valor incremental da seleção em todo período.

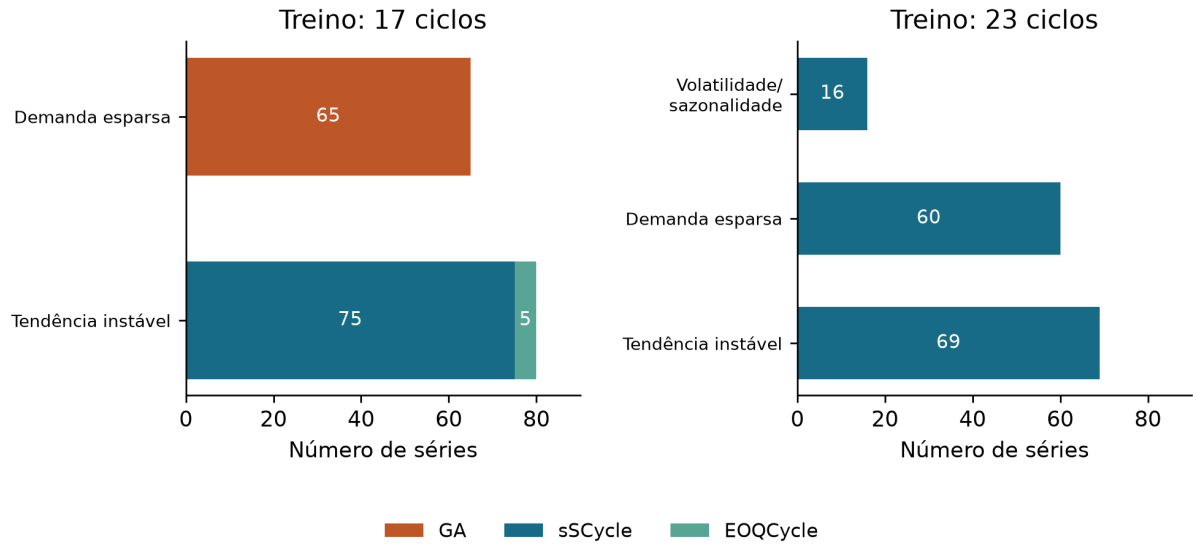


Figura 6.3: Políticas escolhidas por perfil na validação das demais lojas, com meta 0,70. Cada painel contém 145 escolhas; os números indicam séries. A primeira origem diferencia grupos, enquanto a segunda recomenda sSCycle em todos eles. Nomes abreviados dos perfis correspondem às regras operacionais descritas no método.

6.2 Resultados no M5: duas abordagens do PSE

6.2.1 Custo e atendimento das recomendações

O piloto completa os 1.350 ajustes das 30 séries em três origens. As recomendações são avaliadas em 90 casos, com atendimento definido em 86. Não são 90 séries independentes. A Tabela 6.3 inclui dois controles: moda dos rótulos de treino e escolha individual da vencedora de validação. O último examina a transferência temporal do próprio rótulo, sem representar um limite superior para os seletores.

Tabela 6.3: M5: custo em 90 casos; atendimento e contagem de viáveis em 86 com demanda positiva. O recuo é exploratório, desenvolvido após o diagnóstico do piloto.

Seleção	Custo	Atendimento	Casos $\geq 0{,}70$
Global	1.086,97	0,7146	47
PSE por perfil	1.094,02	0,7091	46
PSE preditivo com perfil	1.238,30	0,6735	39
PSE preditivo sem perfil	1.238,30	0,6735	39
Moda dos rótulos	1.096,65	0,6885	42
Individual na validação	1.185,13	0,6838	44
Preditivo com recuo	1.087,26	0,6996	46

O preditivo custa 13,9% mais e atende 4,11 pontos percentuais menos que a global. O contraste desfavorável aparece nas três origens e nos dois perfis. WI_3 e TX_2 respondem por 65,4% da diferença líquida de custo. O PSE por perfil permanece próximo da global: maior

custo e serviço ligeiramente menor, sem benefício agregado neste piloto.

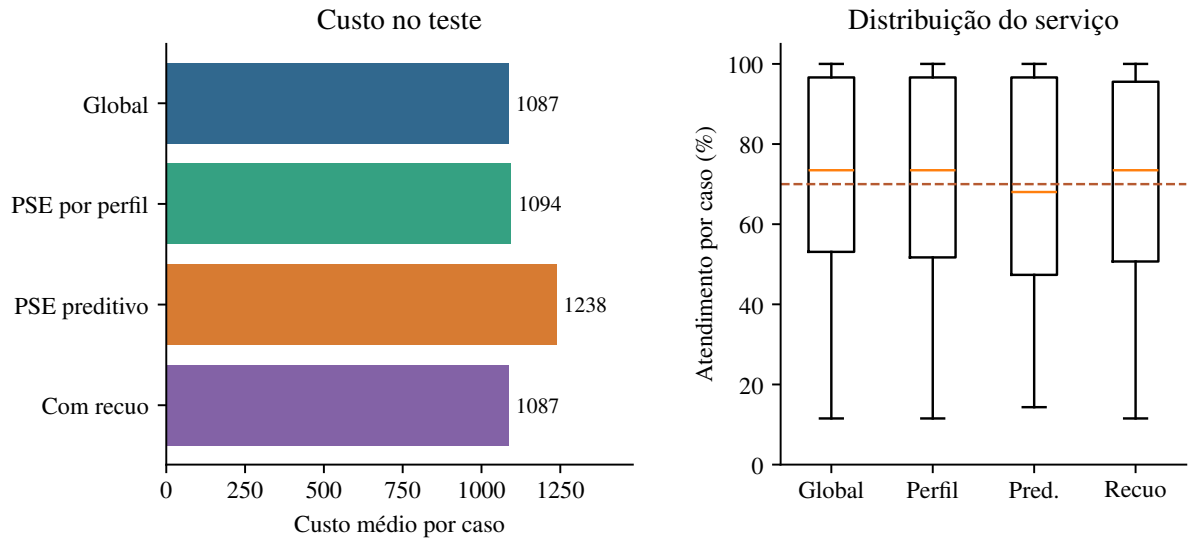


Figura 6.4: Piloto M5: custo e atendimento médios são apresentados separadamente. Caixas descrevem o serviço nos 86 casos definidos; linha em 0,70. O recuo foi desenvolvido no piloto, sem confirmação independente.

O recuo é acionado em 62 casos e muda a política em 48. Frente ao preditivo, reduz custo em 12,2% e aumenta serviço em 2,62 pontos. Frente à global, custa 0,026% mais e atende 1,49 ponto menos; o atendimento permanece abaixo de 0,70. O intervalo exploratório para a diferença de custo frente à global é $[-39{,}83; 39{,}30]$ unidades do cenário; para serviço, $[-2{,}87; -0{,}23]$ pontos. Proximidade de custo não comprova equivalência.

6.2.2 O que explica a dificuldade do preditivo?

Cada fold tem 27 exemplos para até sete classes. O modelo reproduz 100% dos rótulos do treino, mas somente 19 dos 90 rótulos de validação das lojas excluídas. Dois rótulos pertencem a classes ausentes no respectivo treinamento. Esses resultados são consistentes com sobreajuste, sem provar que mais dados, isoladamente, resolvam o problema.

A vencedora nominal da validação permanece vencedora no teste em 29/90 casos; admitindo empates no objetivo completo, em 33/90. Com demanda positiva nos dois blocos, a concordância nominal é 26/83. As vencedoras diferem entre sementes em 39/90 casos. O alvo categórico é sensível tanto ao período quanto ao treinamento. Escolher individualmente na validação aumenta os casos viáveis frente ao preditivo, mas não supera a global em custo ou atendimento médio.

Cada origem contém 26 séries esparsas e quatro de tendência, sem transição de perfil na amostra. As colunas de perfil têm importância por ganho zero em todos os folds; com e sem elas, as 90 recomendações coincidem. Redundância com as características numéricas e baixa

diversidade ajudam a explicar a ausência de efeito, sem demonstrar inutilidade dos perfis em outras populações.

6.2.3 Distância aos melhores resultados e fontes das falhas

O preditivo iguala o menor custo viável do portfólio em 11 dos 39 casos nos quais sua recomendação é viável. Sua eficiência média condicional é 74,2%. A global acerta 15/47 e o PSE por perfil 12/46, com eficiências de 80,8% e 79,5%. Os denominadores diferem: não se avalia eficiência sobre um mesmo subconjunto.

Os 90 problemas com informação perfeita têm otimalidade comprovada. Nas 118 realizações de treinamento em que o preditivo satisfaz o alvo, iguala o ótimo determinístico em 14 e apresenta eficiência média de 54,6%. As realizações repetem séries e, para políticas determinísticas, a mesma trajetória; não ampliam a amostra independente. Mede-se distância ao planejamento com demanda conhecida, não a um controlador estocástico implantável.

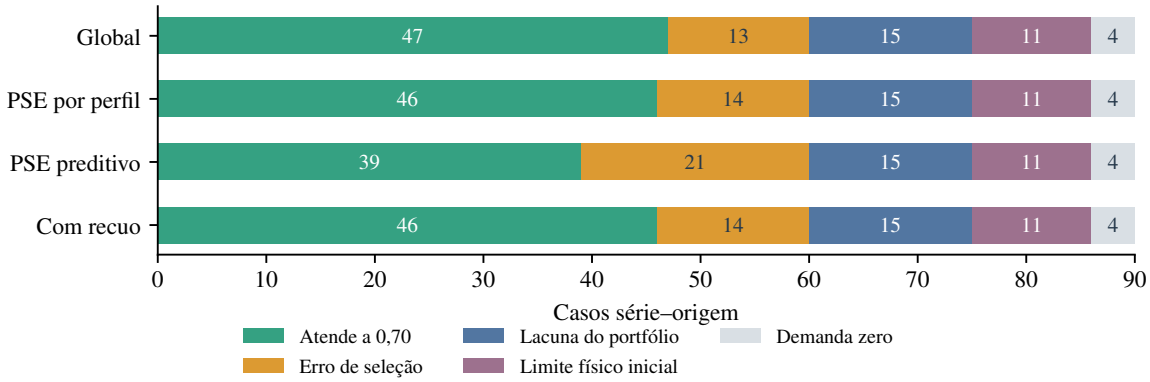


Figura 6.5: Decomposição dos 90 casos M5. Erro de seleção: outra candidata atende. Lacuna do portfólio: nenhuma candidata atende, mas o planejamento perfeito permite atender. Limite físico: condições iniciais impedem atingir 0,70. Demanda zero mantém serviço indefinido.

No preditivo, 39 casos atendem ao alvo; 21 falham apesar de existir política viável; 15 falham sem candidata viável, embora o planejamento perfeito permita atender; 11 têm restrição física inicial; e quatro têm demanda zero. O recuo reduz os erros de seleção de 21 para 14. Melhorar o seletor não resolve sozinho todas as faltas: a Figura 6.5 separa intervenções sobre escolha, controle e abastecimento inicial.

6.3 Comparação reduzida: consequências e decisão de intervenção

A comparação reduzida reutiliza a matriz do piloto M5 e testa uma implementação adicional da metodologia, sem novos ajustes de controladores. O objeto é a escolha: prever custo e

serviço por família ajuda mais que prever uma vencedora? O recuo evita intervenções desfavoráveis? Os resultados respondem a essas perguntas no desenvolvimento, não em uma amostra independente.

Tabela 6.4: Comparação no piloto M5. Custo inclui 90 casos; serviço usa 86 com demanda positiva.

Implementação ou referência	Custo médio	NS médio	Casos $\geq 0{,}70$
Global	1.086,97	71,46%	47
PSE por perfil	1.094,02	70,91%	46
Preditivo original	1.238,30	67,35%	39
Classe vencedora: floresta de controle	1.074,17	68,97%	40
Consequências sem recuo	1.083,36	69,37%	38
Consequências sem perfil e sem recuo	1.148,09	69,25%	38
Consequências com recuo	1.070,03	71,72%	47

A previsão de consequências sem recuo reduz o custo médio em 0,33%, mas perde 2,09 pontos de serviço frente à global. O controle de classificação por floresta também reduz custo e perde atendimento. Logo, a melhora frente ao XGBoost original não pode ser atribuída exclusivamente ao alvo de aprendizagem: modelo e regularização também importam.

Com recuo, o custo médio fica 1,56% abaixo da global e o atendimento 0,27 ponto acima. Contudo, somente três de 90 decisões mudam. Na origem 50, CA_2/FOODS_1_096 passa de CappedBaseStock para GA; na origem 78, duas séries de TX_2 passam de EOQCycle para sSCycle. Uma delas, FOODS_3_135, concentra aproximadamente 92% da economia líquida. A Figura 6.6 apresenta as diferenças médias; a concentração impede interpretá-las como ganho disseminado.

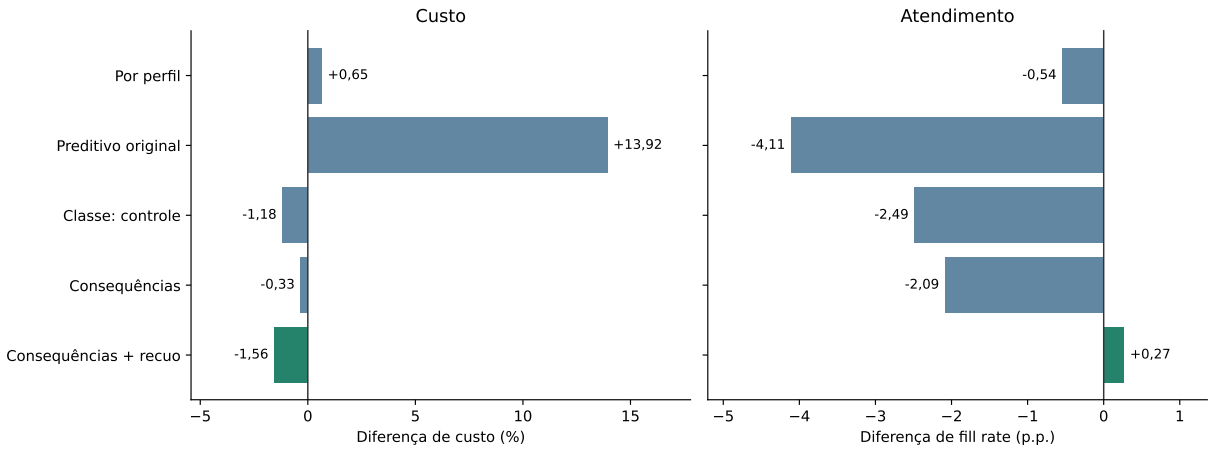


Figura 6.6: Diferenças frente à global na comparação reduzida. Menor custo e maior serviço são favoráveis. A variante com recuo intervém em apenas três casos.

As três intervenções reduzem custo e aumentam serviço nos casos em que ocorreram. En-

tretanto, duas permanecem abaixo de 70%, embora o seletor tenha previsto viabilidade. A variante conserva os mesmos 47 casos que atendem ao alvo, sem novas falhas nem recuperações em relação à referência. O ganho médio não equivale a resolver o atendimento individual.

O bootstrap pareado por dez lojas, com cinco mil sorteios, produz intervalo exploratório de 95% de $[-48{,}10; 0{,}00]$ para diferença de custo médio e $[0{,}000; 0{,}734]$ ponto percentual para diferença de serviço. Os intervalos alcançam zero. Mantêm-se fixos os ajustes e as escolhas; não se modela toda a incerteza de treinamento nem se corrige multiplicidade. Dependência temporal, concentração em duas lojas e desenvolvimento no piloto limitam a inferência.

O resultado sugere que restringir intervenções merece mais investigação do que simplesmente recomendar uma candidata para toda série. A metodologia permite tornar essa decisão explícita e avaliar suas consequências, mas o pequeno número de trocas não demonstra transferência. A próxima avaliação deve preservar controles, harmonizar objetivos e reservar séries que não tenham orientado a regra.

6.4 Esforço computacional das políticas

Tempo de ajuste é uma dimensão adicional da comparação, apresentada na Tabela 6.5. Cada ajuste é contado uma vez, sem duplicar seus registros de validação e teste. Ajustes reaproveitados são excluídos desta amostra de tempos. O registro mede a duração do ajuste no ambiente de execução, sob concorrência e carga variável; não equivale a um teste controlado de velocidade entre processadores nem ao tempo total decorrido da rodada.

Tabela 6.5: Duração registrada dos ajustes executados na rodada Bahia. Tempos em segundos; médias e medianas por ajuste, sem os 54 reaproveitados.

Política	Ajustes	Mediana (s)	Média (s)
CappedBaseStock	284	0,01	0,01
DQN	870	52,10	52,10
EOQCycle	284	0,00	0,00
GA	852	0,53	0,49
GA–DQN	870	52,90	52,90
PPO	852	24,37	26,03
sSCycle	284	0,00	0,00

O tempo deve ser interpretado junto ao desempenho: maior esforço não comprova melhor recomendação. GA–DQN reúne busca, demonstrações e aprendizado, enquanto as referências analíticas têm ajuste simples. Uma comparação causal de eficiência exigiria controlar hardware, carga, orçamento e repetições. Os tempos registrados permitem descrever a execução, mas não substituem esse desenho.

6.5 Síntese das respostas e limites

A segunda questão de pesquisa encontra respostas diferentes nas duas aplicações: contextualizar a escolha nem sempre melhora o compromisso entre custo e serviço. Na Bahia, o perfil acrescenta serviço com custo pontualmente maior; na segunda origem, não diferencia a escolha global. No M5, o preditivo tem pior custo e serviço, e a informação explícita de perfil não altera as recomendações.

O classificador reproduz o treino, mas tem pouco suporte por classe e rótulos que mudam entre períodos e sementes. A primeira regra de recuo ao perfil reduz a perda do preditivo, sem superar global ou perfil. A extensão por consequências com recuo à global apresenta melhora pontual concentrada em três intervenções, com intervalos que alcançam zero. O contraste localiza a dificuldade na conversão de contexto em decisão útil: o preditivo por classe falha nesse objetivo, enquanto a extensão conservadora oferece uma hipótese de melhoria ainda exploratória.

O oráculo do portfólio e o planejamento com informação perfeita mostram limites diferentes. Há espaço para melhorar seleção e controle, mas 11 casos do M5 não permitem atingir o alvo nas condições iniciais. Maior capacidade preditiva não remove essa restrição. Tampouco custo baixo com falta deve ser interpretado como aproximação do ótimo viável.

A concentração dos perfis existe também fora da amostra: na primeira origem M5, 826/885 séries elegíveis são esparsas, 57 têm tendência e duas são do grupo de volatilidade/sazonalidade. Nas origens 64 e 78, são 1.977/2.033 e 2.360/2.408 séries esparsas. Os rótulos satisfazem a regra explícita, não resultam do perfil padrão. Ampliar o tamanho sem examinar essa cobertura não garante diversidade.

As evidências são condicionais a coortes retrospectivas, sete ciclos de teste, vendas possivelmente censuradas, custos de cenário e estados iniciais de referência. As origens repetem séries; a Bahia compartilha um ciclo. O bootstrap preserva lojas, mas não mede novos treinamentos ou toda a dependência entre produtos e lojas. A diferença de calibração da CappedBaseStock entre bases impede tratar seus contrastes como efeito puro da demanda.

Quanto à primeira questão de pesquisa, as aplicações mostram a execução das etapas e dos diagnósticos definidos pelo AIPE. Quanto à terceira, distinguem dificuldades de aprendizagem, cobertura do portfólio e viabilidade física. Essa separação é o resultado metodológico da análise: identifica qual decisão deve ser revista quando a recomendação falha. A confirmação de benefício operacional requer séries excluídas do desenvolvimento e escolhas fixadas antes de examinar seus testes.

7

Conclusões

Esta dissertação propõe o AIPE como metodologia para selecionar políticas de reposição conforme o contexto da demanda. Sua formulação explicita entradas, cinco etapas, critérios e saídas, distinguindo o procedimento geral das escolhas de cada aplicação. O PSE é o componente de recomendação; associação por perfil e estimação preditiva são suas duas abordagens. Algoritmos de estoque, modelos supervisionados e mecanismos de recuo são instrumentos para instanciá-las.

7.1 Respostas às questões de pesquisa

A primeira questão trata de como estruturar o procedimento. O AIPE encadeia especificação da decisão, representação do contexto, construção de evidência comparável, recomendação e avaliação. Ao separar família e parâmetros, referência e intervenção, desenvolvimento e confirmação, a metodologia explicita quais dados sustentam uma escolha e o que precisa ser observado para julgá-la. O capítulo metodológico define esses compromissos; o desenho experimental mostra sua execução. A existência do procedimento não demonstra, por si, economia operacional.

A segunda questão trata de sua utilidade. Na Bahia, a instanciação por perfil acrescenta 3,89 pontos percentuais de atendimento com aumento pontual de custo de 1,93%, reduzindo violações de 119 para 100 entre 283 casos com demanda. Na segunda origem, não diferencia a escolha global. No piloto M5, o preditivo original custa 13,9% mais e atende 4,11 pontos menos que a referência. Sua capacidade de reproduzir rótulos no treinamento não se transfere às lojas excluídas.

A extensão por consequências com recuo apresenta custo médio 1,56% menor e atendimento 0,27 ponto maior que a global. Entretanto, conserva a referência em 87 de 90 decisões, concentra aproximadamente 92% da economia em uma série e mantém os mesmos 47 casos

com serviço de pelo menos 70%. Os intervalos exploratórios alcançam diferença zero. O resultado favorece investigar uma intervenção seletiva, sem demonstrar superioridade generalizável.

A terceira questão trata dos limites. Características, rótulos e famílias vencedoras são sensíveis à janela e ao suporte disponível. O piloto contém poucos exemplos por classe e perfis concentrados. Na implementação original, o perfil explícito não altera as recomendações; na floresta por consequências, sua retirada piora o resultado. São evidências condicionais a modelos distintos, não uma conclusão universal sobre perfis.

7.2 Contribuição e alcance

A contribuição principal é o procedimento AIPE e sua instanciação verificável. Ele não pressupõe que a escolha contextual seja sempre preferível: permite examinar quando intervir e quando conservar a referência. O mecanismo de recuo, isoladamente, possui antecedentes; o uso de M5 ou GA–DQN também não constitui novidade própria. Seu alcance decorre da formulação para o problema, da justificativa das decisões e da evidência disponível para cada implementação.

O diagnóstico distingue perdas com causas diferentes. No preditivo original do M5, 21 falhas têm alternativa viável no portfólio, 15 ocorrem sem candidata viável apesar de possibilidade física, 11 decorrem das condições iniciais e quatro casos não têm demanda. Assim, uma melhoria do seletor não resolve toda ruptura. O planejamento perfeito fornece limite condicional, sem representar economia disponível a uma política sem informação futura.

A implementação e os registros computacionais sustentam a rastreabilidade; os resultados brasileiros e públicos avaliam o procedimento em contextos delimitados. Não demonstram implantação contínua, economia financeira realizável ou redução do custo computacional de uso. Origens e sementes repetidas não ampliam a população independente. Custos de cenário, vendas possivelmente censuradas, calibrações diferentes e janelas curtas restringem as conclusões.

7.3 Continuidade

O próximo passo é harmonizar objetivos e calibração e fixar uma avaliação independente da regra de intervenção. O piloto já observado permanece desenvolvimento. Referências globais fortes devem acompanhar ambas as abordagens do PSE, com análise de deteriorações e concentração de benefícios. O fechamento da avaliação deve informar em quais condições recomendar a intervenção, quais deteriorações ela produz e quando conservar a referência.

8

Continuidade e Validação Final

A metodologia AIPE está formulada e possui duas aplicações experimentais. A Bahia e o piloto M5 têm matrizes completas. A avaliação unificada amplia os seletores na Bahia e organiza a continuidade do M5. Sua consolidação precede a avaliação final; a rodada parcial não é apresentada como experimento concluído. O piloto já orientou diagnóstico e recuo; integra o conjunto de desenvolvimento. A avaliação nacional está fora do escopo experimental desta versão.

8.1 Separar desenvolvimento e confirmação

A próxima amostra deve oferecer mais exemplos por classe e registrar suporte de cada perfil. A concentração natural do M5 em séries esparsas impede presumir cobertura equilibrada. Elegibilidade e estratificação usam somente o treino; séries reservadas não podem orientar o ajuste do seletor.

O pipeline unificado usa cinco grupos internos por loja para escolher a margem de recuo, mantendo a loja externa excluída em cada origem. Outros hiperparâmetros e eventual simplificação de rótulos devem ser definidos somente no desenvolvimento. O teste final fica isolado. Uma melhora encontrada no piloto não é uma segunda replicação independente (Cawley and Talbot, 2010). Ajustes de políticas compatíveis podem ser reaproveitados após auditoria de dados, configuração e código; mudanças científicas exigem novo ajuste da candidata afetada.

8.2 Harmonizar o problema de decisão

A avaliação unificada aplica pesos zero de ruptura e amplificação à calibração da CappedBaseStock nas duas bases. As tabelas desta versão ainda refletem as matrizes anteriores; a

atualização depende da conferência das novas saídas. Também é necessário comparar restrições de serviço com escopo claro: série, perfil ou rede. A meta de 0,70 e os custos atuais são parâmetros experimentais, não exigências empresariais já justificadas.

A comparação reduzida por consequências e recuo fornece um candidato para continuidade, com benefício concentrado em três intervenções. A instabilidade dos rótulos também motiva examinar conjuntos de candidatas quase empatadas e alvos sensíveis ao custo de erro. Essa análise deve ocorrer no desenvolvimento, sem selecionar a formulação pelo teste reservado. GA–DQN continua acompanhado por GA e DQN, com o esforço adicional informado.

8.3 Sensibilidades e eficiência

Prazo, custos relativos, estoque inicial, tratamento terminal e horizonte podem alterar o ranking e a viabilidade física. Seu efeito deverá ser separado do efeito do seletor. Calibração agrupada por perfil é outra hipótese: não equivale a seleção de família por perfil e exige comparação própria.

A escolha de CPU ou GPU deve considerar tempo total sob a carga de uso prevista. O piloto utilizou oito processos CPU; essa configuração operacional não é uma vantagem científica de uma política. A eficiência computacional deve ser relatada como propriedade da execução, separada da qualidade das recomendações.

8.4 Critérios de fechamento

Tabela 8.1: Critérios de conclusão, sem datas ainda não acordadas.

Etapa	Evidência necessária
Formulação do AIPE	Entradas, etapas, saídas e limites explicitados independentemente das bases
Protocolo final	Objetivo, suporte e calibrações fixados antes do teste
PSE	Comparação independente com global, perfil e controles simples
Robustez	Falhas físicas, portfólio, seleção e sensibilidades separadas
Redação	Afirmações alinhadas à evidência e revisão dos autores

O artigo concentra a arquitetura e sua avaliação operacional; a dissertação mantém fundamentos, formulação e limites mais amplos. Autoria, declarações, disponibilidade de dados e elementos institucionais precisam ser fechados pelos responsáveis antes de submissão ou depósito.

Referências

Victoria G. Achkar, Braulio B. Brunaud, Héctor D. Pérez, Rami Musa, Carlos A. Méndez, and Ignacio E. Grossmann. Extensions to the guaranteed service model for industrial applications of multi-echelon inventory optimization. *European Journal of Operational Research*, 313(1):192–206, 2024. **DOI** 10.1016/j.ejor.2023.08.013.

Sven Axsäter. *Inventory Control*, volume 90 of *International Series in Operations Research & Management Science*. Springer US, New York, NY, USA, 2 edition, 2006. ISBN 9780387332505. **DOI** 10.1007/0-387-33331-2.

Alex Batsis and Spyridon Samothrakis. Contextual reinforcement learning for supply chain management. *Expert Systems with Applications*, 249:123541, 2024. **DOI** 10.1016/j.eswa.2024.123541.

Robert N. Boute, Joren Gijsbrechts, Willem van Jaarsveld, and Nathalie Vanvuchelen. Deep reinforcement learning for inventory control: A roadmap. *European Journal of Operational Research*, 298(2):401–412, 2022. **DOI** 10.1016/j.ejor.2021.07.016.

John E. Boylan and Aris A. Syntetos. Forecasting for inventory management of service parts. In Khairy A. H. Kobbacy and D. N. Prabhakar Murthy, editors, *Complex System Maintenance Handbook*, pages 479–506. Springer, London, UK, 2008. **DOI** 10.1007/978-1-84800-011-7_20.

Gavin C. Cawley and Nicola L. C. Talbot. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11: 2079–2107, 2010. URL https://www.jmlr.org/papers/v11/cawley10a.html.

Andrew J. Clark and Herbert Scarf. Optimal policies for a multi-echelon inventory problem. *Management Science*, 6(4):475–490, 1960. **DOI** 10.1287/mnsc.6.4.475.

Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, USA, 2 edition, 1988. ISBN 9780805802832.

J. D. Croston. Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303, 1972. **DOI** 10.1057/jors.1972.50.

Ton de Kok, Christopher Grob, Marco Laumanns, Stefan Minner, Jörg Rambau, and Konrad Schade. A typology and literature review on stochastic multi-echelon inventory models. *European Journal of Operational Research*, 269(3):955–983, 2018. **DOI** 10.1016/j.ejor.2018.02.047.

Tansel Dokeroglu, Tayfun Kucukyilmaz, and El-Ghazali Talbi. Hyper-heuristics: A survey and taxonomy. *Computers and Industrial Engineering*, 187:109815, 2024. **DOI** 10.1016/j.cie.2023.109815.

John H. Drake, Ahmed Kheiri, Ender Özcan, and Edmund K. Burke. Recent advances in selection hyper-heuristics. *European Journal of Operational Research*, 285(2):405–428, 2020. **DOI** 10.1016/j.ejor.2019.07.073.

Adam N. Elmachtoub and Paul Grigas. Smart predict, then optimize. *Management Science*, 2022. **DOI** 10.1287/mnsc.2020.3922.

Burak Erkayman, Ferhat Yuna, and Mustafa Yılmaz. Markov approach for inventory control with meta-heuristics in intermittent demand environment. *PLOS ONE*, 20:e0325658, 2025. **DOI** 10.1371/journal.pone.0325658.

Ayse Sena Eruguz, Evren Sahin, Zied Jemai, and Yves Dallery. A comprehensive survey of guaranteed-service models for multi-echelon inventory optimization. *International Journal of Production Economics*, 172:110–125, 2016. **DOI** 10.1016/j.ijpe.2015.11.017.

Ádám Francuz and Tamás Bányai. Metaheuristic-based model selection framework for eoq and inventory policies using machine learning and multi-objective optimization. *Algorithms*, 19(5): 415, 2026. **DOI** 10.3390/a19050415.

Milton Friedman. A comparison of alternative tests of significance for the problem of m rankings. *The Annals of Mathematical Statistics*, 11(1):86–92, 1940. **DOI** 10.1214/aoms/1177731944.

Kevin Geevers, Lotte van Hezewijk, and Martijn R. K. Mes. Multi-echelon inventory optimization using deep reinforcement learning. *Central European Journal of Operations Research*, 32 (3):653–683, 2024. **DOI** 10.1007/s10100-023-00872-2.

Yonatan Geifman and Ran El-Yaniv. Selectivenet: A deep neural network with an integrated reject option. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97, pages 2151–2159, 2019. URL https://proceedings.mlr.press/v97/geifman19a.html.

Joren Gijsbrechts, Robert N. Boute, Jan A. Van Mieghem, and Dennis J. Zhang. Can deep reinforcement learning improve inventory management? performance on lost sales,

dual-sourcing, and multi-echelon problems. *Manufacturing & Service Operations Management*, 24(3):1349–1368, 2022. **DOI** 10.1287/msom.2021.1064.

Kwang-Il Goh and Albert-László Barabási. Burstiness and memory in complex systems. *EPL (Europhysics Letters)*, 81(4):48002, 2008. **DOI** 10.1209/0295-5075/81/48002.

Stephen C. Graves and Sean P. Willems. Optimizing strategic safety stock placement in supply chains. *Manufacturing & Service Operations Management*, 2(1):68–83, 2000. **DOI** 10.1287/msom.2.1.68.23267.

John H. Holland. *Adaptation in Natural and Artificial Systems*. MIT Press, Cambridge, MA, USA, 1992. ISBN 9780262581111.

Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006. **DOI** 10.1016/j.ijforecast.2006.03.001.

James Kennedy and Russell Eberhart. Particle swarm optimization. In *Proceedings of ICNN'95 — International Conference on Neural Networks*, volume 4, pages 1942–1948, 1995. **DOI** 10.1109/ICNN.1995.488968.

Pascal Kerschke and Heike Trautmann. Automated algorithm selection on continuous black-box problems by combining exploratory landscape analysis and machine learning. *Evolutionary Computation*, 27(1):99–127, 2019. **DOI** 10.1162/evco_a_00236.

Pascal Kerschke, Holger H. Hoos, Frank Neumann, and Heike Trautmann. Automated algorithm selection: Survey and perspectives. *Evolutionary Computation*, 27(1):3–45, 2019. **DOI** 10.1162/evco_a_00242.

S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983. **DOI** 10.1126/science.220.4598.671.

Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(3):48–60, 2014. **DOI** 10.1609/aimag.v35i3.2460.

Romain Laroche, Paul Trichelair, and Remi Tachet des Combes. Safe policy improvement with baseline bootstrapping. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97, pages 3652–3661, 2019. URL https://proceedings.mlr.press/v97/laroche19a.html.

Hau L. Lee, V. Padmanabhan, and Seungjin Whang. Information distortion in a supply chain: The bullwhip effect. *Management Science*, 43(4):546–558, 1997. **DOI** 10.1287/mnsc.43.4.546.

Xiaotian Liu, Ming Hu, Yijie Peng, and Yaodong Yang. Multi-agent deep reinforcement learning for multi-echelon inventory management. *Production and Operations Management*, 34(7): 1836–1856, 2025. **DOI** 10.1177/10591478241305863.

Spyros Makridakis. Accuracy measures: Theoretical and practical concerns. *International Journal of Forecasting*, 9(4):527–529, 1993. **DOI** 10.1016/0169-2070(93)90079-3.

Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. The m4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1): 54–74, 2020. **DOI** 10.1016/j.ijforecast.2019.04.014.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015. **DOI** 10.1038/nature14236.

Davood Mohammaditabar, Seyed Hassan Ghodsypour, and Chris O'Brien. Inventory control system design by integrating inventory classification and policy selection. *International Journal of Production Economics*, 140(2):655–659, 2012. **DOI** 10.1016/j.ijpe.2011.03.012.

Mehran Nasseri, Taha Falatouri, Patrick Brandtner, and Farzaneh Darbanian. Applying machine learning in retail demand prediction—a comparison of tree-based ensembles and long short-term memory-based deep learning. *Applied Sciences*, 13(19):11112, 2023. **DOI** 10.3390/app131911112.

Peter Nemenyi. *Distribution-Free Multiple Comparisons*. PhD thesis, Princeton University, 1963.

Afshin Oroojlooyjadid, MohammadReza Nazari, Lawrence V. Snyder, and Martin Takáč. A deep q-network for the beer game: Deep reinforcement learning for inventory optimization. *Manufacturing & Service Operations Management*, 24(1):285–304, 2022. **DOI** 10.1287/msom.2020.0939.

Deniz Preil and Michael Krapp. Bandit-based inventory optimisation: Reinforcement learning in multi-echelon supply chains. *International Journal of Production Economics*, 252:108578, 2022. **DOI** 10.1016/j.ijpe.2022.108578.

Meng Qi, Yuanyuan Shi, Yongzhi Qi, Chenxin Ma, Rong Yuan, Di Wu, and Zuo-Jun Max Shen. A practical end-to-end inventory management model with deep learning. *Management Science*, 69(2):759–773, 2023. **DOI** 10.1287/mnsc.2022.4564.

John R. Rice. The algorithm selection problem. *Advances in Computers*, 15:65–118, 1976.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. **DOI** 10.48550/arXiv.1707.06347.

Alireza Sheikh-Zadeh, Manuel D. Rossetti, and Marc A. Scott. Performance-based inventory classification methods for large-scale multi-echelon replenishment systems. *Omega*, 101: 102276, 2021. **DOI** 10.1016/j.omega.2020.102276.

Rainer Storn and Kenneth Price. Differential evolution — a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4):341–359, 1997. **DOI** 10.1023/A:1008202821328.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, USA, 2 edition, 2018. ISBN 9780262039246.

Aris A. Syntetos and John E. Boylan. On the categorization of demand patterns. *Journal of the Operational Research Society*, 56(5):495–503, 2005. **DOI** 10.1057/palgrave.jors.2601841.

Aris A. Syntetos, John E. Boylan, and Stephen M. Disney. Forecasting for inventory planning: A 50-year review. *Journal of the Operational Research Society*, 60(S1):S149–S160, 2009. **DOI** 10.1057/jors.2008.173.

Yasin Tadayonrad and Alassane Balle Ndiaye. A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality. *Supply Chain Analytics*, 3:100026, 2023. **DOI** 10.1016/j.sca.2023.100026.

El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. John Wiley & Sons, Hoboken, NJ, USA, 2009. ISBN 9780470278581. **DOI** 10.1002/9780470496916.

Henri Theil. *Applied Economic Forecasting*. North-Holland, Amsterdam, 1966.

Nathalie Vanvuchelen, Joren Gijsbrechts, and Robert N. Boute. Use of proximal policy optimization for the joint replenishment problem. *Computers in Industry*, 119:103239, 2020. **DOI** 10.1016/j.compind.2020.103239.

Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. **DOI** 10.2307/3001968.

David H. Wolpert and William G. Macready. No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation*, 1(1):67–82, 1997. **DOI** 10.1109/4235.585893.

Linwei Xin. Technical note—understanding the performance of capped base-stock policies in lost-sales inventory models. *Operations Research*, 69(1):61–70, 2021. **DOI** 10.1287/opre.2020.2019.

Ferhat Yuna, Burak Erkayman, and Mustafa Yılmaz. Inventory control model for intermittent demand: A comparison of metaheuristics. *Soft Computing*, 27:6487–6505, 2023. **DOI** 10.1007/s00500-023-07871-0.

Oussama Zabraoui, Yahya Hmamou, Anas Chafi, and Salaheddine Kammouri Alami. A comparative study of multi-algorithm optimization for inventory analytics in supply chains. *Supply Chain Analytics*, 12:100154, 2025. **DOI** 10.1016/j.sca.2025.100154.

Paul H. Zipkin. *Foundations of Inventory Management*. McGraw-Hill/Irwin, Boston, MA, USA, 2000. ISBN 9780256113792.