

Proposta de Dissertação de Mestrado

Um Framework Adaptativo para Seleção de Políticas de Reposição em Regimes Operacionais Heterogêneos

Matheus Inácio Batista Santos
mibs@ic.ufal.br
Orientadores:

Dr. Rian Gabriel Santos Pinheiro
Dr. Bruno Costa e Silva Nogueira

Maceió

5 de junho de 2026

Matheus Inácio Batista Santos

Um Framework Adaptativo para Seleção de Políticas de Reposição em Regimes Operacionais Heterogêneos

Uma proposta de dissertação submetida por Matheus Inácio Batista Santos como requisito parcial para qualificação no curso de Mestrado em Informática pela Universidade Federal de Alagoas, Instituto de Computação.

Orientadores:
Dr. Rian Gabriel Santos Pinheiro

Dr. Bruno Costa e Silva Nogueira

Maceió

5 de junho de 2026

Proposta de dissertação submetida por Matheus Inácio Batista Santos como requisito parcial para qualificação no curso de Mestrado em Informática pela Universidade Federal de Alagoas, Instituto de Computação, avaliada pela banca examinadora que assina abaixo.

Dr. Rian Gabriel Santos Pinheiro - Orientador
Instituto de Computação
Universidade Federal de Alagoas

Dr. Bruno Costa e Silva Nogueira - Orientador
Instituto de Computação
Universidade Federal de Alagoas

- Examinador(a)

- Examinador(a)

- Examinador(a)

Maceió
5 de junho de 2026

Resumo

Redes varejistas precisam decidir continuamente quando e quanto repor estoque em cada loja. Essa decisão se torna mais difícil quando os produtos não apresentam o mesmo padrão de venda: alguns têm demanda regular, enquanto outros passam vários períodos sem venda e concentram vendas em poucos ciclos. Nesses casos, aplicar uma única regra de reposição para toda a rede pode gerar excesso de estoque em alguns produtos, falta de estoque em outros e maior instabilidade nos pedidos enviados ao armazém. Esta dissertação propõe um *framework* metodológico de apoio à decisão para recomendar políticas de reposição de acordo com o comportamento observado em cada série loja-produto. A hipótese central é que a política mais adequada depende do regime operacional da demanda, e que essa relação pode ser aprendida a partir de características históricas da série. Para isso, a proposta utiliza como entrada o histórico preparado, a caracterização operacional das séries e sinais auxiliares de previsão de demanda. A partir dessas informações, compara políticas de reposição em simulação e aprende associações entre perfis de demanda e políticas com melhor desempenho esperado. Esse *framework* é denominado *Adaptive Inventory Policy Engine* (AIPE), e seu componente supervisionado de seleção é o *Policy Selection Engine* (PSE). A proposta é avaliada com dados reais de uma rede varejista brasileira, cuja base contém aproximadamente 48 milhões de registros transacionais e 12 mil produtos. Nos subconjuntos experimentais analisados, o primeiro experimento, conduzido como estudo piloto na Paraíba, indicou reduções de CTI de até 48% em relação a políticas de referência. No segundo experimento, conduzido com 145 séries da Bahia, a seleção por perfil reduziu o CTI médio em 6,2% frente à política única global, preservando nível de serviço acima do limiar mínimo adotado. A avaliação compara políticas clássicas, políticas parametrizadas por meta-heurísticas e políticas aprendidas por reforço. A principal contribuição da dissertação é avaliar a viabilidade de selecionar políticas de reposição de forma contextual, com base em evidência empírica, para apoiar decisões de estoque em redes varejistas heterogêneas.

Palavras-chave: Otimização de Inventário; Demanda Intermitente; Seleção Contextual de Políticas; Cadeia de Suprimentos.

Sumário

Lista de Figuras vi
Lista de Tabelas viii
Lista de Siglas e Termos Técnicos ix

1 Introdução **1**
1.1 Motivação 1
1.1.1 Redes Varejistas Multi-Loja 1
1.1.2 Problema de Reposição em Redes Varejistas 3
1.1.3 Questões de Pesquisa e Hipóteses 4
1.2 Objetivos 6
1.3 Contribuições da dissertação 7
1.4 Escopo da Pesquisa e Delimitações 8

2 Referencial Teórico **10**
2.1 Formulação do Problema de Reposição 10
2.1.1 Política de Reposição: Estado, Ação e Parâmetros 11
2.1.2 Função Objetivo e Dinâmica de Estoque 11
2.2 Famílias de Políticas de Reposição 12
2.2.1 Políticas Clássicas 12
2.2.2 Parametrização de Políticas via Meta-Heurísticas 13
2.2.3 Políticas de Reposição via Aprendizado por Reforço 15
2.2.4 Políticas Híbridas GA-RL 16
2.3 Demanda Intermitente 16
2.3.1 Taxonomia ADI $\times$ CV^2 17
2.3.2 Efeitos na Reposição 18
2.4 Métricas de Previsão 19
2.4.1 Métricas Utilizadas 19
2.5 Testes Estatísticos 21
2.5.1 Teste de Wilcoxon 21
2.5.2 Teste de Friedman e Nemenyi 21
2.5.3 Tamanho de Efeito 22

3 Trabalhos Relacionados **23**
3.1 Visão Geral dos Métodos e Resultados da Literatura 23
3.2 Inventário em Redes Varejistas 24
3.3 Previsão de Demanda Intermitente 25
3.4 Meta-Heurísticas e Aprendizado por Reforço em Políticas de Reposição 26
3.5 Seleção de Políticas, Hiper-Heurísticas e Meta-Aprendizado 27
3.6 Políticas Híbridas GA-RL 28

3.7 Posicionamento da Dissertação 29

4 Metodologia **31**
4.1 Visão Geral do AIPE 31
4.2 Instanciação Experimental do Problema de Inventário 32
4.2.1 Instanciação das Políticas e Espaço de Decisão 32
4.2.2 Instanciação do Ambiente de Inventário 34
4.2.3 Rede Varejista 35
4.2.4 Métricas de Avaliação 35
4.3 Camada de Entrada: Dados e Pré-Processamento 37
4.3.1 Base de Dados 37
4.3.2 Pipeline Experimental 38
4.4 Caracterização das Séries e Perfis Operacionais 38
4.4.1 Características Operacionais Calculadas 39
4.4.2 Perfis Operacionais de Demanda 40
4.5 Sinais de Previsão como Entrada Auxiliar 42
4.6 Portfólio de Políticas Candidatas 43
4.6.1 Políticas Clássicas 43
4.6.2 Políticas Parametrizadas por Meta-Heurísticas 44
4.6.3 Políticas Aprendidas por Reforço 46
4.6.4 Políticas Híbridas GA-RL 47
4.6.5 Portfólio Ampliado e Critério de Seleção das Políticas 47
4.6.6 Redundância entre Políticas e Implicação para os Rótulos 48
4.7 Ambiente de Simulação e Benchmark de Políticas 48
4.7.1 Ambiente de Simulação 48
4.8 Validação Temporal e Estatística 49
4.8.1 Protocolo Walk-Forward 50
4.8.2 Validação Estatística das Políticas 50
4.9 Geração de Rótulos e Treinamento do PSE 51
4.9.1 Base Conceitual 51
4.9.2 Problema de Seleção 52
4.9.3 Rótulos de Política Dominante 53
4.9.4 Treinamento do PSE 54
4.9.5 Saídas do PSE 54
4.10 Camada de Aplicação: Recomendações e Reavaliação Periódica 54
4.11 Artefatos Experimentais e Rastreabilidade 55
4.12 Protocolo Experimental 55
4.12.1 Escopo e Replicações 55
4.12.2 Execução Temporal dos Experimentos 56

5 Resultados Preliminares **58**
5.1 Visão Geral 58
5.2 Experimento 1: Estudo Piloto na Paraíba 59
5.2.1 Comparação entre Políticas 59
5.2.2 Análise por Volume de Demanda 60
5.2.3 Explicação dos Resultados 60
5.3 Experimento 2: Expansão na Bahia 61
5.3.1 Dataset e Distribuição Geográfica 61

5.3.2 Comparação Agregada entre Políticas 63
5.3.3 Análise Estratificada por Filial e Segmento 65
5.3.4 Comparação por Perfil Operacional de Demanda 66
5.3.5 Custo da Política Única versus Seleção por Perfil 68
5.3.6 Heterogeneidade e Evidência para o AIPE 70
5.4 Validação Estatística 71
5.4.1 Teste de Wilcoxon 71
5.4.2 Tamanho de Efeito 71
5.5 Previsão de Demanda 72
5.6 Alcance dos Resultados 74
5.7 Discussão dos Resultados 74

6 Considerações Finais e Próximas Etapas 78
6.1 Contribuições 79
6.2 Implicações Operacionais 81

7 Plano de Continuidade e Cronograma 82
7.1 Visão Geral das Atividades Restantes 82
7.2 Estudos de Caso Adicionais: Validação Externa e Validação em Escala 83
7.2.1 Estudo de Caso 3: Benchmark Público M5 (Walmart) 83
7.2.2 Estudo de Caso 4: Expansão Multiestado (Base Nacional) 85
7.3 Treinamento e Avaliação do PSE 85
7.3.1 Validação de Robustez: Agrupamento por Perfil na Calibração 86
7.4 Análise de Sensibilidade e Mapa de Recomendação 86
7.5 Otimização em Janela Móvel 87
7.6 Produção Científica e Escrita da Dissertação 87
7.7 Cronograma Consolidado 87

A Matriz de Parâmetros Experimentais 89
A.1 Resultados Agregados do Experimento 1 94

B Representações Visuais das Políticas Avaliadas 96

Referências 99

Lista de Figuras

1.1 Ilustração conceitual da motivação da dissertação. Em redes varejistas, diferentes séries loja-produto podem apresentar vendas regulares, intermitentes ou concentradas em picos. A aplicação uniforme de uma mesma regra de reposição pode gerar excesso de estoque, ruptura ou instabilidade nos pedidos. A proposta do AIPE é tratar essa diferença como um problema de seleção contextual de políticas de reposição. 4

2.1 Visão conceitual de uma política híbrida GA-RL. A busca evolutiva explora globalmente o espaço de parâmetros e fornece uma inicialização informativa ao agente de aprendizado por reforço, que refina decisões sequenciais no ambiente de inventário. 16

2.2 Plano ADI $\times$ CV^2. Limiares: ADI$^* = 1.32$, CV$^{2*} = 0.49$. 19

4.1 Arquitetura conceitual do *framework* AIPE. A camada de entrada reúne dados transacionais preparados, parâmetros operacionais, características das séries e sinais auxiliares de previsão de demanda. O núcleo de seleção contextual utiliza essas entradas para avaliar políticas candidatas, gerar rótulos de política dominante, realizar validação estatística e treinar o *Policy Selection Engine*. A camada de aplicação utiliza o PSE para recomendar políticas a novas séries loja-produto e reavaliar periodicamente as recomendações conforme novos dados se acumulam. 33

4.2 Fluxo decisório do AIPE. O histórico preparado, as características operacionais e o POD formam a entrada usada pelo PSE para recomendar uma política; o ciclo de reavaliação periódica a cada $\Delta t = 6$ ciclos (tracejado) recalcula as características e o POD conforme novos dados se acumulam, sem re-treinar o meta-modelo. 41

4.3 Protocolo *walk-forward*: a janela de treinamento cresce incrementalmente e o modelo é avaliado apenas em dados futuros, eliminando viés *in-sample*. 50

4.4 Framework ASP de Rice (1976) instanciado no AIPE: as séries loja-produto constituem as instâncias representadas por características operacionais, as políticas candidatas são avaliadas por simulação e o PSE aprende a recomendar a política viável de menor custo esperado para cada perfil de demanda, respeitando o limiar mínimo de nível de serviço. 52

5.1 Distribuição de séries (loja $\times$ produto) por filial e segmento comercial (BA). À esquerda: proporção por filial; à direita: composição de segmentos por filial. Calçada concentra 72% das séries, refletindo maior porte e diversidade de produtos. 62

5.2 Distribuição de receita esperada por ciclo (R$). À esquerda: boxplot por filial; Lauro de Freitas apresenta maior mediana e menor dispersão. À direita: receita média por segmento; Platina lidera com R$ 105/ciclo, seguido por Ouro (R$ 92). . 62

5.3 Número de lojas por segmento comercial (BA). A pirâmide de fidelidade da rede é concentrada em Platina (68 séries), refletindo a estratégia de mercado da rede varejista. 63

5.4 Distribuição geográfica das lojas da rede varejista no Brasil, coloridas por receita esperada por ciclo comercial (R$). O estado da Bahia (BA) representa a cobertura atual do Experimento 2; demais regiões serão incorporadas no Estudo de Caso 4 (expansão multiestado). 63
5.5 Fronteira de Pareto CTI e NS: cada ponto representa a média de uma política sobre as 145 séries. O eixo horizontal representa o CTI médio (R$), a ser minimizado; o eixo vertical representa o NS médio, a ser maximizado. A região acima e à esquerda representa o melhor compromisso custo-serviço. Nenhuma política ocupa simultaneamente o menor CTI e o maior NS, indicando ausência de dominância universal no recorte avaliado. 65
5.6 Distribuição do CTI por política (boxplot sobre as 145 séries). Caixas mais altas indicam que a mesma política produz custos muito diferentes entre séries: a eficácia depende do perfil da demanda, não apenas da política escolhida. 66
5.7 CTI, NS e TR por segmento de loja para as políticas EOQ, Jornaleiro, SA e GA-DQN (portfólio final, Seção 4.6). O segmento Diamante GB exibe o maior CTI absoluto entre as políticas de maior custo (SA), refletindo maior volume médio de demanda. O segmento Platina apresenta a maior dispersão de NS entre as quatro políticas, indicando sensibilidade elevada ao mecanismo de reposição. . . 66
5.8 CTI médio por política e Perfil Operacional de Demanda (Experimento 2, BA). Células mais escuras indicam maior custo médio. A variação horizontal (entre perfis) indica que a mesma política produz custos muito distintos segundo o padrão de demanda. 68
5.9 Diagrama de diferença crítica (Nemenyi *post-hoc* do teste de Friedman) para o CTI. Políticas conectadas por barra horizontal não diferem significativamente ao nível $\alpha = 0.05$. A figura representa agrupamento estatístico, não *ranking* absoluto: políticas conectadas são operacionalmente indistinguíveis em CTI ao nível de significância adotado. 72
5.10 Avaliação dos modelos de previsão. (a) Frequência com que cada modelo obteve o menor MASE por série: LSTM vence em aproximadamente 60% das séries. (b) Distribuição por modelo (boxplots) de MASE, RMSSE, sMAPE, MBE e Theil's U para ANN, LSTM e XGBoost; valores abaixo de 1 em MASE e RMSSE indicam desempenho melhor que o *baseline naïve*. 73

B.1 Representações das políticas clássicas: (a) lote econômico de compra (EOQ); (b) regra de revisão (s, S); (c) decisão de reposição sob incerteza de demanda (Jornaleiro). 96
B.2 Representação do cromossomo no Algoritmo Genético para parametrização de políticas de reposição. 97
B.3 Representações dos agentes de aprendizado por reforço: (a) Deep Q-Network (DQN), estimação de valores de ação por *bootstrap* de 1 passo; (b) Proximal Policy Optimization (PPO), estrutura ator-crítico com retorno multi-passo (GAE). . 98
B.4 Representação da política híbrida GA-DQN no portfólio avaliado. 98

Lista de Tabelas

2.1 Quadrantes de Syntetos-Boylan: limiares e interpretações. 18
3.1 Síntese dos principais métodos e lacunas da literatura. 24
3.2 Posicionamento desta dissertação em relação aos trabalhos relacionados. . . . 29
4.1 Perfis Operacionais de Demanda (POD) e políticas de referência inicial. 41
4.2 Comparação entre famílias de métodos no contexto MEIO. 57
5.1 Características do *dataset* por experimento. 59
5.2 Médias dos indicadores de desempenho por política do portfólio final (12 políticas, 145 séries, estado BA, regime *Lumpy*, 5 replicações). Melhores valores por coluna em negrito. †DQN converge ao comportamento degenerado de não emitir pedidos (FP = 0.00, NS = 0.23), mesmo após a correção da penalidade de déficit de NS que resolveu esse padrão nas demais políticas (Seção 4.6). 64
5.3 Política dominante por Perfil Operacional de Demanda (Experimento 2, BA, regime *Lumpy*). Para cada perfil, são reportados o número de séries, a política dominante (menor CTI ajustado médio entre políticas com NS médio $\geq 0{,}70$), o CTI médio, o CTI ajustado médio (Eq. custo total ajustado, AJUSTES_INFRA item #33) e o NS médio da política dominante. Perfis com $n < 20$ séries devem ser interpretados de forma exploratória. 67
5.4 Comparação de custo entre estratégias de seleção de política (Experimento 2, BA, 145 séries, regime *Lumpy*). CTI ajustado incorpora prejuízo por indisponibilidade (referência fixa por série) e estoque excessivo (AJUSTES_INFRA item #33); é a métrica de comparação final. Redução calculada como $100 \times (\mathrm{CTI}^{\text{ajust}}_{\text{ref}} - \mathrm{CTI}^{\text{ajust}}_{\text{estratégia}})/\mathrm{CTI}^{\text{ajust}}_{\text{ref}}$. O oráculo por série (C†) é referência exploratória: assume conhecimento perfeito da política ótima de cada série. 68
5.5 Teste de hipótese pareado entre política única e seleção por perfil (Wilcoxon signed-rank, Experimento 2). Para CTI, a hipótese alternativa é $\mathrm{CTI}_B < \mathrm{CTI}_A$; para os demais KPIs, o teste é bilateral. 69
5.6 Comparação de custo entre estratégias de seleção de política com CTI ajustado por estabilidade operacional (Experimento 2, BA, 145 séries, regime *Lumpy*). CTI Adj. $= \mathrm{CTI}_{\mathrm{norm}} + \lambda_{BE} \cdot \mathrm{BE}_{\mathrm{norm}}$, normalizado por escopo global. Redução% calculada contra estratégia A (política única, CTI puro). †Oráculo por série: referência exploratória, não estratégia operacional. 76
5.7 Mapeamento empírico de dominância regime→política (CTI puro sob NS ≥ 0.70). "Dominante" é a política com menor CTI entre aquelas que atingem NS ≥ 0.70 no estrato. Fonte: análise estratificada dos dois experimentos executados. 77
5.8 Resultados agregados dos testes de Wilcoxon: frações de comparações significativas por política e métrica ($\alpha = 0.05$, correção de Holm). GA-DQN: 10 *baselines*; GA-PPO: 10 *baselines*. 77

5.9 Tamanhos de efeito de Cohen (d) para CTI: política híbrida versus *baselines* selecionados, portfólio final de 12 políticas (Seção 4.6). Classificação: $|d| < 0.20$ trivial; 0.20 a 0.50 pequeno; 0.50 a 0.80 médio; > 0.80 grande. 77
5.10 Métricas de qualidade da previsão por modelo (médias sobre 145 séries, BA, regime *Lumpy*). MASE e RMSSE são escalados em relação ao modelo *naïve*; valores < 1 indicam desempenho melhor que o *naïve*. sMAPE em %. Valores menores indicam melhor desempenho. 77
7.1 Cronograma de atividades (referência: maio de 2026). ✓: concluído; •: em andamento; ○: planejado. 88

A.1 Parâmetros globais do experimento. 89
A.2 Parâmetros das políticas clássicas e meta-heurísticas. 90
A.3 Parâmetros dos agentes de aprendizado por reforço e políticas híbridas. 91
A.4 Parâmetros de previsão, características operacionais e geração de rótulos. . . . 92
A.5 Validação estatística, ambiente computacional e artefatos. 93
A.6 Médias dos indicadores de desempenho por política (15 lojas, regime *Lumpy*). Melhores valores por coluna. †SARSA e PPO apresentam degeneração (FP = 0 e FP = 0.98, respectivamente); resultados degenerados não constituem soluções operacionalmente viáveis. 94

Lista de Siglas e Termos Técnicos

Termo/Sigla	Significado	Interpretação no trabalho
AIPE	*Adaptive Inventory Policy Engine*	*Framework* metodológico que recomenda políticas de reposição por série loja-produto.
PSE	*Policy Selection Engine*	Meta-modelo supervisionado que aprende a relação entre características da série e política recomendada.
Política de reposição	Regra ou algoritmo de decisão de estoque	Define quando emitir pedido e em qual quantidade.
Série loja-produto	Histórico de vendas de um produto específico em uma loja específica	Unidade básica de análise da dissertação.
POD	Perfil Operacional de Demanda	Agrupamento ou caracterização do padrão operacional da série.
CTI	Custo Total de Inventário	Métrica de custo usada na avaliação das políticas; deve ser minimizada.
NS	Nível de Serviço	Proporção da demanda atendida; deve ser maximizada.
TR	Taxa de Ruptura	Frequência ou proporção de falta de estoque; deve ser minimizada.
BE	*Bullwhip Effect*	Amplificação da variabilidade dos pedidos na cadeia.
FP	Frequência de Pedidos	Fração de ciclos em que a política emite pedido.
ADI	*Average Demand Interval*	Intervalo médio entre períodos com demanda positiva.
CV^2	Quadrado do coeficiente de variação	Medida de variabilidade relativa da demanda.
Lumpy	Demanda grumosa	Regime com muitos períodos sem venda e alta variabilidade nos períodos com venda.
Smooth	Demanda regular	Regime com alta frequência e baixa variabilidade.
Erratic	Demanda errática	Regime com alta frequência e alta variabilidade.
Intermittent	Demanda intermitente	Regime com muitos períodos sem venda e magnitude relativamente estável quando há venda.
RL	*Reinforcement Learning*	Família de métodos usada para aprender políticas de reposição por interação com o ambiente simulado.
GA	*Genetic Algorithm*	Meta-heurística usada para parametrizar políticas de reposição e compor políticas híbridas.
SA	*Simulated Annealing*	Meta-heurística usada para otimização de parâmetros de políticas de reposição.
PSO	*Particle Swarm Optimization*	Meta-heurística baseada em enxame usada para parametrizar políticas de reposição.
DE	*Differential Evolution*	Meta-heurística evolutiva usada para otimização de parâmetros de políticas de reposição.
DQN	*Deep Q-Network*	Agente usado para aprender uma política de reposição no ambiente de simulação.
PPO	*Proximal Policy Optimization*	Agente usado para aprender uma política de reposição no ambiente de simulação.
SARSA	*State-Action-Reward-State-Action*	Agente usado para aprender uma política de reposição no ambiente de simulação.
GA-DQN	Política híbrida GA + DQN	Política especialista que combina busca evolutiva e refinamento por aprendizado por reforço.
GA-PPO	Política híbrida GA + PPO	Política especialista que combina busca evolutiva e PPO.
EOQ	*Economic Order Quantity*	Política clássica baseada em quantidade econômica de pedido.
(s, S)	Política de ponto de pedido e nível máximo	Política que emite pedido quando o estoque cai abaixo de s, repondo até S.
Jornaleiro / *Newsvendor*	Política de período único baseada em quantil da demanda	Política clássica usada como *baseline* de reposição.
MASE	*Mean Absolute Scaled Error*	Métrica de erro de previsão usada como sinal auxiliar.

Termo/Sigla	Significado	Interpretação no trabalho
sMAPE	*Symmetric Mean Absolute Percentage Error*	Métrica secundária de erro de previsão.
RMSSE	*Root Mean Squared Scaled Error*	Métrica escalada de erro quadrático de previsão.
Walk-forward	Validação temporal progressiva	Protocolo que avalia modelos usando apenas dados passados para prever ciclos futuros.
Política dominante	Melhor política viável para uma série ou perfil	Política com menor CTI entre aquelas que atendem ao limiar mínimo de NS.
Policy label	Rótulo de política	Classe supervisionada usada para treinar o PSE.
ASP	*Algorithm Selection Problem*	Formulação teórica em que se escolhe o melhor algoritmo para cada instância do problema.
NFL	*No Free Lunch*	Teorema que justifica a inexistência de uma política universalmente mais adequada para todos os perfis de demanda.
MEIO	*Multi-Echelon Inventory Optimization*	Otimização de estoques em redes com múltiplos níveis ou escalões.
GSM	*Guaranteed Service Model*	Família de modelos para posicionamento de estoques de segurança em redes multi-escalão.
Base-stock	Política de estoque-base	Política que repõe o estoque até um nível-alvo predefinido.
SKU	*Stock Keeping Unit*	Unidade individual de produto usada para controle operacional e análise de vendas.
MAPE	*Mean Absolute Percentage Error*	Métrica percentual de erro de previsão, problemática quando há demanda zero.
M4/M5	Competições internacionais de previsão	Benchmarks amplamente usados para comparar métodos de previsão de séries temporais.
ARIMA/SARIMAX	Modelos estatísticos de séries temporais	Modelos de previsão usados como alternativas auxiliares na etapa preditiva.
LSTM	*Long Short-Term Memory*	Rede neural recorrente usada para capturar padrões sequenciais em séries temporais.
ANN	*Artificial Neural Network*	Rede neural artificial usada como modelo de previsão de demanda.
XGBoost	*Extreme Gradient Boosting*	Modelo baseado em árvores e gradiente *boosting* usado para previsão e classificação.
LightGBM	*Light Gradient Boosting Machine*	Modelo alternativo de *boosting* considerado para classificação supervisionada.
RandomForest	Floresta aleatória	Modelo de ensemble baseado em múltiplas árvores de decisão.
DRL	*Deep Reinforcement Learning*	Aprendizado por reforço profundo, isto é, RL com aproximação por redes neurais.
HAPPO	*Heterogeneous-Agent Proximal Policy Optimization*	Variante multiagente de PPO discutida em trabalhos relacionados.
ELA	*Exploratory Landscape Analysis*	Caracterização de instâncias por atributos de paisagem em seleção automática de algoritmos.
MILP/ILP	Programação inteira linear mista / inteira	Formulações exatas de otimização com variáveis inteiras e restrições lineares.
SB3	*Stable-Baselines3*	Biblioteca de referência para implementação de agentes de aprendizado por reforço.
API	*Application Programming Interface*	Interface de programação usada para padronizar chamadas de software.
YAML	*YAML Ain't Markup Language*	Formato de arquivo usado para parametrização dos experimentos.
Parquet	Formato colunar de dados	Formato eficiente para armazenar bases tabulares particionadas.
Kedro	*Framework* de engenharia de dados	Ferramenta usada para organizar *pipelines* reprodutíveis de processamento e simulação.
Dataset	Conjunto de dados	Base organizada usada como entrada para análises, simulações ou treinamento.
Benchmark	Protocolo comparativo	Avaliação padronizada usada para comparar políticas candidatas sob as mesmas condições.
Baseline	Método de referência	Política ou modelo usado como ponto de comparação para avaliar ganhos relativos.
Feature	Característica explicativa	Variável calculada a partir da série e usada como entrada de modelos de seleção ou previsão.
Pipeline	Fluxo reprodutível de processamento	Sequência organizada de etapas de dados, simulação, avaliação e geração de artefatos.
Rolling horizon	Horizonte deslizante	Protocolo temporal em que a janela de avaliação avança ao longo do tempo.

Termo/Sigla	**Significado**	**Interpretação no trabalho**
Rolling-origin	Origem deslizante	Validação temporal em que o ponto de origem do treino avança progressivamente.
Burstiness	Concentração de demanda em picos	Medida de irregularidade associada a eventos raros e intensos de demanda.
Bullwhip	Efeito chicote	Amplificação da variabilidade de pedidos ao longo da cadeia de suprimentos.
Fronteira de Pareto	Conjunto de soluções não dominadas	Representa alternativas em que não é possível melhorar uma métrica sem piorar outra.
Teste de Wilcoxon	Teste não paramétrico pareado	Avalia diferenças entre políticas quando a normalidade não pode ser assumida.
Teste de Friedman	Teste não paramétrico para múltiplos métodos	Compara várias políticas simultaneamente por postos.
Teste de Nemenyi	Teste pós-hoc não paramétrico	Identifica quais pares diferem após rejeição no teste de Friedman.
Cohen's d	Tamanho de efeito padronizado	Mede a magnitude prática da diferença entre duas políticas.

1

Introdução

Redes varejistas com múltiplas lojas enfrentam problemas recorrentes de reposição porque produtos e regiões apresentam padrões de demanda distintos. Produtos com vendas regulares, intermitentes ou concentradas em picos esporádicos respondem de forma diferente às mesmas políticas de reposição. Por isso, a aplicação uniforme de uma única política tende a produzir excesso de estoque, ruptura ou instabilidade nos pedidos enviados ao armazém (Axsäter, 2006; Syntetos and Boylan, 2005).

1.1 Motivação

Essa dificuldade é o ponto de partida desta dissertação: tomar decisões de reposição em redes varejistas geograficamente distribuídas, nas quais produtos, lojas e regiões não se comportam de maneira uniforme. Em um país continental como o Brasil, fatores logísticos, sazonalidade, diferenças regionais de consumo e variabilidade entre lojas ampliam a complexidade operacional do controle de estoque. Nesse cenário, decidir a reposição deixa de ser uma aplicação mecânica de regras fixas e passa a exigir métodos capazes de reconhecer as diferenças entre séries loja-produto.

1.1.1 Redes Varejistas Multi-Loja

Para situar esse desafio, considere a estrutura básica de uma rede varejista geograficamente dispersa: lojas espalhadas em diferentes cidades e regiões abastecidas por um ou mais centros de distribuição regionais. Cada loja, em seu contexto local, precisa decidir quando repor estoque e em que quantidade. Essa decisão é crítica porque afeta dois objetivos em conflito: manter custos baixos, reduzindo estoque em prateleira, e preservar disponibilidade, evitando falta de produto para o cliente (Axsäter, 2006; Zipkin, 2000).

Essa decisão local, entretanto, não afeta apenas a loja. Operacionalmente, cada loja recebe seu abastecimento do armazém regional; o armazém, por sua vez, recebe do fornecedor ou fábrica. Quando uma loja repõe em volume alto ou frequência alta, o armazém observa essa variabilidade de forma amplificada, afetando a estabilidade de toda a cadeia. Esse comportamento está relacionado ao efeito chicote, no qual pequenas variações na demanda local podem se ampliar ao longo da cadeia de suprimentos (Lee et al., 1997). No sentido oposto, quando a loja falha em repor corretamente, produtos faltam e o cliente não é atendido. O problema, portanto, está em equilibrar custo de estoque, disponibilidade de produto e estabilidade dos pedidos enviados ao armazém.

Uma solução operacional tradicional a esse equilíbrio consiste em aplicar regras simples de reposição: "quando o estoque cai abaixo de X, peça Y unidades". Essas regras funcionam bem para produtos que vendem com regularidade previsível. Contudo, em redes varejistas com milhares de combinações loja-produto, esse pressuposto raramente vale de forma uniforme.

A limitação dessa resposta aparece quando se comparam séries de demanda muito distintas. Um produto de higiene pessoal que vende 50 unidades por semana em qualquer loja (padrão regular) tende a ser atendido por regras estáveis de reposição. Já um produto de linha limitada que vende "0, 0, 0, 50, 0, 0, 30" unidades ao longo de ciclos sucessivos apresenta comportamento compatível com demanda intermitente ou *lumpy*, nas quais períodos de demanda nula alternam-se com ocorrências positivas de magnitude variável (Croston, 1972; Syntetos and Boylan, 2005; Boylan and Syntetos, 2008). Esse padrão impõe outro dilema: manter estoque alto o tempo todo, elevando custo, ou manter estoque baixo e correr risco de ruptura. Aplicar a mesma regra aos dois casos é ineficiente.

Nesses casos de baixa frequência de venda ou de comportamento imprevisível, políticas simples podem alternar entre dois efeitos indesejados: excesso de estoque, que ocupa espaço e representa custo financeiro, e falta de estoque, também chamada de ruptura, que leva à perda de venda e frustra o cliente. Esse cenário combina elevação de custo operacional com degradação do nível de serviço. As decisões inadequadas de reposição também podem amplificar a variabilidade na cadeia: quando as lojas oscilam entre períodos sem repor e períodos com reposição em lote grande, o armazém regional observa uma volatilidade maior do que a demanda real nas lojas.

Esse diagnóstico desloca a discussão do ajuste pontual de parâmetros para um problema mais amplo: a escolha da política de reposição adequada a cada contexto operacional. A literatura de controle de estoques reconhece que diferentes padrões de demanda podem exigir políticas distintas. Modelos analíticos tradicionais, heurísticas, políticas parametrizadas por meta-heurísticas e políticas aprendidas por reforço oferecem alternativas para tratar esse problema (Axsäter, 2006; Syntetos et al., 2012; Boute et al., 2022). Permanece, entretanto, uma lacuna operacional relevante: em uma rede com milhares de produtos e centenas de lojas, qual política aplicar a cada combinação loja-produto? Fazer isso manualmente é inviável. Aplicar uma única regra a todos tende a ignorar diferenças importantes entre séries. O AIPE endereça

essa lacuna ao modelar a escolha da política como um problema de seleção contextual, aprendendo a recomendar políticas de reposição a partir das características operacionais de cada série. Essa formulação se aproxima do problema clássico de seleção de algoritmos, no qual características da instância são usadas para escolher o método mais adequado a cada caso (Rice, 1976; Kotthoff, 2014).

Diante dessa lacuna, a hipótese central desta dissertação é que o desempenho das políticas de reposição depende do regime operacional da demanda, e que essa relação pode ser aprendida por um meta-modelo supervisionado a partir de características históricas e operacionais da série. Essa hipótese orienta a formulação do AIPE como uma abordagem de seleção contextual: o histórico preparado, as características operacionais das séries e os sinais auxiliares de previsão servem como entradas para comparar políticas candidatas em simulação, gerar rótulos de política dominante e recomendar políticas para séries com perfis semelhantes (Rice, 1976; Syntetos and Boylan, 2005; Kotthoff, 2014).

Essa sequência é sintetizada na Figura 1.1: redes varejistas apresentam séries heterogêneas, políticas únicas produzem desempenho irregular e a alternativa investigada nesta dissertação é selecionar políticas de forma contextual, com base nas características observadas de cada série. A figura antecipa visualmente o argumento central que será desenvolvido nos capítulos seguintes.

1.1.2 Problema de Reposição em Redes Varejistas

A motivação apresentada anteriormente pode ser formalizada como um problema recorrente de otimização de inventário. No contexto operacional considerado, cada loja precisa responder continuamente a duas decisões: quando repor e quanto repor.

O *trade-off* aparece porque essas decisões, embora simples na formulação, têm consequências de longo alcance. Se a loja repõe muito frequentemente, os custos sobem porque o armazém recebe pedidos pequenos e repetidos. Se repõe pouco frequentemente, cresce o risco de falta de estoque. Se pede muita quantidade por vez, consome espaço e pode gerar sobra caso a demanda não se concretize. Se pede pouca quantidade, aumenta a frequência de reposição.

Quando esse *trade-off* é observado em uma rede heterogênea, as decisões de reposição deixam de admitir uma regra única de bom desempenho. O comportamento adequado para um produto de demanda regular pode ser inadequado para outro de demanda intermitente, e decisões locais inadequadas podem amplificar custos em toda a cadeia.

Desse modo, a rede apresenta um desafio estrutural: cada loja decide independentemente, mas seus produtos variam de forma expressiva em padrão de demanda. A questão central não é apenas calibrar uma regra, mas reconhecer que diferentes séries podem exigir diferentes políticas.

Portanto, o problema de otimização é este: dado um histórico de vendas de cada loja para



Figura 1.1: Ilustração conceitual da motivação da dissertação. Em redes varejistas, diferentes séries loja-produto podem apresentar vendas regulares, intermitentes ou concentradas em picos. A aplicação uniforme de uma mesma regra de reposição pode gerar excesso de estoque, ruptura ou instabilidade nos pedidos. A proposta do AIPE é tratar essa diferença como um problema de seleção contextual de políticas de reposição.

cada produto, como escolher a política de reposição que melhor balanceia custo (minimizando estoque em excesso) com nível de serviço (minimizando faltas de estoque, ou rupturas), operando em ambiente descentralizado com heterogeneidade operacional genuína? A dificuldade prática está em realizar essa escolha em escala para milhares de combinações loja-produto, reduzindo a dependência de intervenção manual.

1.1.3 Questões de Pesquisa e Hipóteses

Com o problema e a representação das séries definidos, o AIPE é estruturado em um ciclo de avaliação e recomendação composto por quatro etapas: observação do padrão de venda histórico de cada combinação loja-produto; avaliação das políticas candidatas em simulação para identificar qual apresenta melhor desempenho naquele perfil; aprendizado da relação entre padrão operacional e política dominante; e geração de recomendações para novas séries com perfis similares. Esse ciclo permite tratar a escolha da política como uma decisão aprendida a partir de evidência empírica, combinando avaliação operacional e aprendizagem supervisionada

em um mesmo protocolo metodológico.

Questão principal. A questão que sintetiza essa investigação é: é possível construir uma abordagem metodológica que aprenda qual política de reposição é mais adequada para cada combinação loja-produto, a partir de características operacionais da série, e que ofereça uma alternativa empiricamente avaliada às políticas únicas aplicadas uniformemente à rede? Essa questão orienta a avaliação empírica e define o papel do PSE como componente de seleção contextual.

Hipótese 1: Heterogeneidade genuína. A primeira premissa formaliza o ponto de partida da dissertação: não existe uma política universalmente melhor. Diferentes padrões de venda exigem diferentes abordagens. Algumas séries apresentam melhor desempenho sob determinadas políticas, enquanto outras favorecem políticas distintas. Se isso for verdade, não faz sentido procurar "a" melhor política; o que importa é aprender quando usar cada uma.

Hipótese 2: Aprendibilidade da relação regime $\rightarrow$ política. Se a heterogeneidade for observável nas séries, a segunda premissa é que a relação entre características operacionais da série (frequência de venda, variabilidade, sazonalidade) e desempenho relativo das políticas candidatas pode ser aprendida por um meta-modelo supervisionado. Na prática experimental, busca-se que o AIPE aprenda associações do tipo: dado um determinado padrão de venda, recomende a política de reposição com melhor desempenho esperado.

Hipótese 3: Generalização operacional. Como consequência esperada dessa aprendizagem, a terceira premissa é que um modelo treinado dessa forma possa generalizar para novas séries. Com isso, reduz-se a necessidade de testar manualmente cada novo produto; a abordagem utiliza o padrão de venda observado para produzir uma recomendação empiricamente fundamentada.

Em conjunto, essas três premissas definem o critério de viabilidade do AIPE. Se encontrarem apoio empírico nos dados, a seleção contextual torna-se uma abordagem operacionalmente plausível. Os resultados preliminares sustentam parcialmente essas hipóteses, especialmente quanto às diferenças entre políticas e à viabilidade do meta-modelo de seleção. A validação da generalização do PSE para novas séries dentro dos regimes observados será aprofundada nos estudos de caso adicionais em andamento (M5 e expansão multiestado).

1.2 Objetivos

Objetivo geral

O objetivo geral é propor, implementar e avaliar o *Adaptive Inventory Policy Engine* (AIPE), um framework metodológico de seleção contextual de políticas de reposição que recebe características operacionais de séries loja-produto como entrada para recomendar a política com melhor desempenho esperado em cada perfil de demanda. A proposta é avaliada sobre dados reais de uma rede varejista brasileira, com foco em custo de inventário, nível de serviço, ruptura, estabilidade dos pedidos e reprodutibilidade experimental.

Objetivos específicos

Os objetivos específicos são organizados em dois experimentos já executados e dois estudos de caso adicionais em andamento. O Experimento 1 corresponde ao estudo piloto na Paraíba, usado para validar o ambiente de simulação e o protocolo inicial de comparação entre políticas. O Experimento 2 corresponde à expansão experimental para 145 séries da Bahia, usada para avaliar diferenças de desempenho por perfil e comparar política única global com seleção contextual. Esses dois experimentos permanecem a referência central de resultados da dissertação. Os estudos de caso adicionais (M5, benchmark público internacional usado por Zabraoui et al. (2025); e a expansão multiestado da base nacional) não substituem essa referência: servem para testar se a heterogeneidade regime→política observada na Bahia se replica sob condições estruturalmente diferentes de demanda, escala e origem de dados, fortalecendo (ou revelando os limites de) a validade externa do AIPE.

1. **[Experimento 1: estudo piloto na Paraíba, concluído]** Construir e validar um ambiente de simulação para avaliar políticas de reposição em séries loja-produto reais, considerando dinâmica de estoque, prazo de entrega e indicadores operacionais de custo, serviço, ruptura, estabilidade e frequência de pedidos (Law, 2015; Axsäter, 2006);

2. **[Experimento 1: estudo piloto na Paraíba, concluído]** Comparar sistematicamente diferentes famílias de políticas de reposição, incluindo políticas clássicas, políticas parametrizadas por meta-heurísticas, políticas aprendidas por reforço e abordagens híbridas, em dados reais de varejo com demanda intermitente (Boute et al., 2022; Talbi, 2009);

3. **[Experimento 1: estudo piloto na Paraíba, concluído]** Caracterizar o desempenho das políticas híbridas baseadas em meta-heurística e aprendizado por reforço como políticas especialistas dentro do portfólio avaliado, identificando os perfis de demanda nos quais apresentam melhor desempenho relativo (Oroojlooyjadid et al., 2022; Zabraoui et al., 2025);

4. **[Experimento 2: expansão experimental na Bahia, concluído]** Implementar o *pipeline* experimental de apoio ao AIPE, contemplando preparação dos dados, extração de características operacionais da demanda, classificação de perfis, simulação das políticas candidatas e geração de rótulos de política dominante por série loja-produto;

5. **[Experimento 2: expansão experimental na Bahia, concluído]** Avaliar estatisticamente os resultados obtidos, verificando a consistência das diferenças observadas entre políticas no recorte analisado;

6. **[Estudos de caso adicionais, em andamento]** Treinar e avaliar o *Policy Selection Engine* (PSE), responsável por associar características operacionais das séries à política dominante, definida como a política de menor custo total de inventário entre aquelas que atendem ao limiar mínimo de nível de serviço, com validação cruzada estratificada e análise de interpretabilidade (Lundberg and Lee, 2017; Lundberg et al., 2018);

7. **[Estudo de Caso 3: benchmark M5, em andamento]** Avaliar o portfólio completo de políticas sobre o conjunto público M5 (Walmart), a mesma base de validação do artigo-base (Zabraoui et al., 2025), testando se a heterogeneidade regime→política observada na Bahia se replica numa base de demanda de alto volume, escala e proveniência distintas do varejo brasileiro;

8. **[Estudo de Caso 4: expansão multiestado, em andamento]** Estender a avaliação do AIPE para um conjunto mais amplo de produtos, lojas e regiões da base nacional, analisando sua capacidade de generalização para diferentes regimes operacionais de demanda (Axsäter, 2006).

Em todos os casos, o papel desses estudos de caso é fortalecer e delimitar a validade do AIPE como *framework*, não substituí-lo: a contribuição central da dissertação permanece a formulação metodológica da seleção contextual, não a cobertura geográfica ou de proveniência dos dados usados para testá-la.

1.3 Contribuições da dissertação

A partir dessas questões, hipóteses e objetivos, a contribuição principal é o AIPE: um *framework* metodológico de apoio à decisão operacional que recomenda qual política de reposição adotar para cada par loja-produto. A abordagem aprende essa relação a partir de dados históricos e pode produzir recomendações para novos produtos sem necessidade de reteste manual completo. Dessa forma, o AIPE constitui a proposta central da dissertação, enquanto as políticas clássicas, as políticas parametrizadas por meta-heurísticas, os agentes de aprendizado por reforço e as políticas híbridas compõem o portfólio de alternativas avaliadas pelo *framework*.

Para sustentar essa contribuição, a avaliação do AIPE é organizada em três contribuições complementares. A primeira consiste na comparação empírica de múltiplas políticas sobre dados reais, indicando que diferentes séries favorecem políticas distintas e que a seleção contextual é um caminho plausível para lidar com a heterogeneidade observada. A segunda é o mapeamento entre padrões operacionais e políticas dominantes, realizado com validação estatística formal, fornecendo a base empírica sobre a qual o PSE aprende. A terceira é a construção de um protocolo reprodutível de avaliação experimental, com rastreabilidade completa de dados, configurações e código.

A proposta entrega um protocolo reprodutível para comparar políticas e treinar o PSE a partir de dados reais de varejo nacional. A validação em ambiente operacional permanece como etapa posterior.

1.4 Escopo da Pesquisa e Delimitações

As restrições descritas nesta seção indicam quais problemas operacionais não são tratados pela dissertação, evitando atribuir ao AIPE funções que não fazem parte da contribuição proposta. O escopo experimental, incluindo experimentos executados, políticas avaliadas, replicações e métricas, é detalhado no Capítulo 4. O texto separa, assim, o alcance conceitual da pesquisa das escolhas do experimento.

- Coordenação multiagente entre escalões: a dissertação mede o efeito *bullwhip* como indicador de amplificação de variabilidade à montante, mas não implementa coordenação centralizada entre armazém e lojas. As decisões de reposição são descentralizadas e independentes por loja.

- Aprendizado por reforço multiagente (MARL): algoritmos como HAPPO, uma variante multiagente do PPO (Liu et al., 2025), ou comunicação entre agentes estão fora do escopo; o AIPE opera como seletor offline de política por série, não como coordenador online entre nós da rede.

- *Online learning* contínuo: o AIPE é reavaliado periodicamente (a cada Δt ciclos), não atualizado continuamente a cada nova transação; a adaptação é por recálculo do vetor de características, não por reaprendizado incremental do meta-modelo.

- Otimização conjunta de múltiplos SKUs: cada série (loja, produto) é tratada independentemente; efeitos de substituição, complementaridade e portfolio não são modelados.

- Otimização de roteamento e transporte: custos e restrições logísticas de transporte são parâmetros fixos; a dissertação otimiza *quando* e *quanto* pedir, não *como* transportar.

- Integração em tempo real com ERP: o *pipeline* opera sobre histórico exportado em Parquet; não há integração transacional em tempo real com plataformas de gestão corporativa.

Essas delimitações definem o escopo geral da pesquisa e concentram a contribuição na aprendizagem da relação regime→política em condições controladas e reprodutíveis sobre dados reais de varejo nacional. A partir desse escopo, os capítulos seguintes desenvolvem a fundamentação teórica, posicionam a proposta frente à literatura, detalham a metodologia experimental e apresentam os resultados preliminares.

Este trabalho procede em seis capítulos estruturados para construir progressivamente o argumento. O Capítulo 2 apresenta o referencial teórico: famílias de políticas de reposição, demanda intermitente, formulação do controle de inventário, métricas de previsão e testes estatísticos. O Capítulo 3 posiciona a dissertação na literatura de controle de inventário, metaheurísticas, aprendizado por reforço e seleção de algoritmos. O Capítulo 4 operacionaliza a metodologia do AIPE: dados, características operacionais e sinais de previsão como camada de entrada; simulação, validação estatística e treinamento do PSE como núcleo da proposta. O Capítulo 5 apresenta os resultados do estudo piloto na Paraíba e da expansão experimental na Bahia. O Capítulo 6 consolida as contribuições e o plano de continuidade.

2

Referencial Teórico

Este capítulo apresenta os fundamentos teóricos necessários à formulação do *Adaptive Inventory Policy Engine* (AIPE), articulando a caracterização de regimes de demanda, a avaliação de políticas de reposição e a estrutura estatística usada para comparação das políticas. O objetivo é estabelecer a base conceitual usada posteriormente na metodologia e na interpretação dos resultados.

O capítulo inicia pela formulação do problema de reposição, definindo estado, ação, parâmetros, função objetivo e dinâmica de estoque, base comum a todas as famílias de políticas avaliadas. Em seguida, apresentam-se as famílias de políticas de reposição, incluindo políticas clássicas, políticas parametrizadas por meta-heurísticas, políticas aprendidas por reforço e políticas híbridas GA-RL. Na sequência, discute-se a demanda intermitente e a taxonomia de Syntetos-Boylan, que fundamenta a caracterização dos regimes operacionais a partir da frequência e da variabilidade da demanda. Por fim, são apresentadas as métricas de previsão e os testes estatísticos.

2.1 Formulação do Problema de Reposição

Antes de descrever as famílias de políticas avaliadas, é necessário definir o problema comum a todas elas. Nesta dissertação, uma política de reposição é uma regra de decisão que observa o estado operacional de uma série loja-produto em cada ciclo e escolhe uma quantidade de pedido. A diferença entre as famílias de políticas está na forma como essa regra é especificada, parametrizada ou aprendida. A estrutura do problema, entretanto, permanece a mesma: há um estado observado, uma ação de reposição, uma dinâmica de estoque e uma função de custo a ser minimizada.

2.1.1 Política de Reposição: Estado, Ação e Parâmetros

No modelo adotado, qualquer política candidata π é tratada como uma regra de decisão que observa o estado operacional da série no ciclo t e escolhe uma quantidade de pedido. Formalmente:

$$\pi : \mathcal{S} \to \mathcal{A}, \qquad a_t = \pi(\mathbf{s}_t; \boldsymbol{\theta}),$$

em que $\mathcal{S}$ é o conjunto de estados possíveis, $\mathcal{A}$ é o conjunto de quantidades admissíveis, a_t é a quantidade solicitada no ciclo t e $\boldsymbol{\theta}$ representa os parâmetros internos da política. Em políticas clássicas, $\boldsymbol{\theta}$ pode conter parâmetros como ponto de pedido, lote ou nível máximo de estoque; em políticas parametrizadas por meta-heurísticas, esses parâmetros são otimizados por busca; em políticas aprendidas por reforço, a regra de decisão é aprendida a partir da interação com o ambiente simulado. A natureza de $\boldsymbol{\theta}$ depende, portanto, da família avaliada, mas a estrutura decisória é mantida comum para todo o portfólio.

No contexto desta dissertação, o estado operacional é representado por $\mathbf{s}_t = (I_t, Q_{t-L}, \hat{D}_{t+1})$. O termo I_t indica o estoque disponível no início do ciclo t; Q_{t-L} indica a quantidade pedida em ciclos anteriores que chega após o prazo de entrega (*lead time*) L; e $\hat{D}_{t+1}$ representa uma estimativa da demanda futura próxima. A partir desse estado, a política decide o pedido Q_t (a ação a_t), que afeta custos futuros de excesso, ruptura e ordenação.

2.1.2 Função Objetivo e Dinâmica de Estoque

Com o estado e a ação definidos, o problema de reposição pode ser formulado como a escolha de uma política que minimize o custo esperado ao longo de um horizonte de planejamento. Essa formulação também define o critério usado para avaliar parametrizações geradas por meta-heurísticas e políticas aprendidas por reforço.

O objetivo é escolher a política π que minimize o custo total esperado ao longo de um horizonte finito T:

$$\min_{\pi} \mathbb{E}\left[\sum_{t=1}^{T}\left(hI_t + c_s S_t + c_o^{\text{fix}}\mathbf{1}(Q_t > 0) + c_o^{\text{var}} Q_t\right)\right], \tag{2.1}$$

Na Equação 2.1, a soma acumula os custos em todos os ciclos do horizonte experimental. O termo hI_t representa o custo de manter unidades em estoque; $c_s S_t$ representa o custo associado à demanda não atendida; $c_o^{\text{fix}}\mathbf{1}(Q_t > 0)$ cobra um custo fixo sempre que há pedido, por meio da função indicadora $\mathbf{1}(Q_t > 0)$; e $c_o^{\text{var}} Q_t$ representa o custo variável proporcional à quantidade pedida. A esperança $\mathbb{E}[\cdot]$ indica que o desempenho da política é avaliado considerando a incerteza da demanda e, quando aplicável, a variabilidade dos métodos estocásticos de otimização ou aprendizado.

A evolução do estoque é descrita pela dinâmica:

$$I_{t+1} = \max(0, I_t - D_t) + Q_{t-L}, \quad S_t = \max(0, D_t - I_t). \tag{2.2}$$

Na Equação 2.2, a demanda observada no ciclo é denotada por D_t. O estoque do próximo ciclo, I_{t+1}, corresponde ao saldo remanescente após atender a demanda, acrescido dos pedidos que chegam após o prazo de entrega. A variável S_t mede a ruptura, isto é, a parcela da demanda que excede o estoque disponível. Os parâmetros h, c_s, c_o^{fix} e c_o^{var} representam, respectivamente, os custos unitários de manutenção, ruptura, pedido fixo e pedido variável. A razão $c_s/h = 5$ adotada nos experimentos reflete a penalização de vendas não atendidas no contexto de varejo regional.

Com essa formulação definida, as famílias de políticas avaliadas podem ser interpretadas como diferentes formas de escolher a ação de reposição Q_t. As políticas clássicas usam regras analíticas ou parâmetros fixos; as políticas parametrizadas por meta-heurísticas buscam valores de parâmetros que minimizam a função objetivo definida nesta seção, avaliada por simulação; e as políticas aprendidas por reforço aprendem diretamente uma regra de decisão a partir da interação com o ambiente.

2.2 Famílias de Políticas de Reposição

A partir da formulação anterior, este trabalho organiza as alternativas de reposição em quatro famílias: políticas clássicas, políticas parametrizadas por meta-heurísticas, políticas aprendidas por reforço e políticas híbridas GA-RL. A distinção entre essas famílias está na forma como a regra de decisão é definida ou ajustada, não no problema operacional subjacente, que permanece comum a todas, conforme apresentado na Seção 2.1.

2.2.1 Políticas Clássicas

As três políticas clássicas utilizam parâmetros analíticos derivados das estatísticas locais de cada série e servem como políticas de referência no protocolo comparativo. Elas são importantes porque representam alternativas simples, interpretáveis e amplamente utilizadas em práticas de reposição.

EOQ (*Economic Order Quantity*). A política EOQ define um lote econômico de pedido que equilibra o custo fixo de emitir pedidos e o custo de manutenção (posse) de estoque, sob o pressuposto de demanda constante. Sejam μ a demanda média por ciclo, K o custo fixo cobrado a cada pedido emitido e h o custo de manutenção (ou posse) de estoque, por unidade e por ciclo. O lote econômico é

$$Q^* = \sqrt{\frac{2K\mu}{h}}, \tag{2.3}$$

em que Q^* representa a quantidade econômica de pedido. Quando a EOQ é combinada com um ponto de pedido (também chamado de ponto de reposição), o pedido é emitido quando o estoque atinge $s = \mu L$, em que L é o prazo de entrega medido em ciclos. Note-se que s não é a demanda média isoladamente: μL representa a demanda média esperada durante o prazo de entrega, e é esse valor acumulado, não μ por si só, que define o ponto de pedido. Essa formulação é adequada quando a demanda média é relativamente estável; em regimes intermitentes ou de alta variabilidade, esse pressuposto se enfraquece.

Política (s, S). Emite pedido de magnitude $S - I_t$ quando $I_t \leq s$, em que I_t é a posição de estoque no ciclo t, s é o ponto de reposição e S é o nível-alvo para recomposição do estoque. Neste trabalho, s e S são calibrados a partir da EOQ. É a política de referência mais adotada no varejo regional brasileiro por sua simplicidade operacional. Contudo, gera efeito chicote elevado (amplificação de variabilidade entre a loja e o armazém), porque os pedidos se concentram em lotes espaçados, criando vales e picos artificiais na cadeia (Lee et al., 1997).

Jornaleiro (*Newsvendor*). Determina o pedido ótimo de período único como um quantil da distribuição de demanda: $Q^* = \hat{\mu} + z_\alpha \hat{\sigma}$, em que $\hat{\mu}$ e $\hat{\sigma}$ são, respectivamente, a média e o desvio-padrão estimados da demanda histórica, z_α é o quantil da distribuição normal associado ao nível de serviço alvo e Q^* é a quantidade recomendada para o período. Neste trabalho, adota-se $z_\alpha = 1.28$ para nível de serviço alvo de 90%. A política assume independência entre períodos, o que a torna econômica em demanda de baixo volume onde os picos não são correlacionados.

Limitação estrutural das políticas clássicas: EOQ, (s, S) e Jornaleiro assumem homogeneidade operacional. Cada uma dessas políticas pressupõe, implicitamente, que a série se comporta de forma previsível e regular o suficiente para que parâmetros fixos sejam adequados. Entretanto, em séries com muitos períodos de demanda nula, alta variabilidade relativa e picos esporádicos de venda, essa hipótese é frequentemente violada. A mesma parametrização que funciona para uma série de comportamento regular pode gerar ruptura frequente em séries de comportamento irregular. Isso impede o uso de qualquer política clássica como solução universal e reforça a necessidade de adaptar a escolha da política ao perfil operacional de cada série.

2.2.2 Parametrização de Políticas via Meta-Heurísticas

Meta-heurísticas como GA, SA, PSO e DE não são tratadas como políticas de reposição independentes. Eles são métodos de busca/otimização usados para parametrizar uma regra de reposição, principalmente por meio de vetores como (s, Q), em que s é o ponto de reposição e Q é o lote solicitado. Eles buscam parametrizações que minimizem a função objetivo definida na Seção 2.1.2, avaliada por simulação: para cada vetor candidato, a política parametrizada é executada no ambiente de simulação e recebe uma avaliação baseada no custo total e nos critérios de viabilidade operacional.

Essa abordagem é útil em demanda intermitente porque não exige pressupor uma distribuição paramétrica para a demanda. Em vez disso, a busca avalia diretamente como cada parametrização se comporta sobre o histórico observado, incluindo períodos de demanda nula e picos esporádicos.

Algoritmo Genético (GA). Mantém uma população de parametrizações candidatas e evolui por seleção, cruzamento e mutação (Holland, 1992; Talbi, 2009). Cada indivíduo representa valores possíveis para os parâmetros da política de reposição, como ponto de pedido e lote. A aptidão é calculada por simulação, combinando custo e viabilidade de serviço. Em inventário, o GA tem sido amplamente utilizado para calibrar políticas de reposição (Yuna et al., 2023), pois tolera bem a descontinuidade introduzida pelos ciclos de demanda nula.

Recozimento Simulado (SA). Parte de uma parametrização corrente da política e gera vizinhos por pequenas perturbações nos parâmetros. Soluções melhores são aceitas diretamente; soluções piores podem ser aceitas com probabilidade $\exp(-\Delta C/T_k)$, em que ΔC é a variação de custo entre a candidata e a solução corrente, e T_k é a temperatura na iteração k (Kirkpatrick et al., 1983). Como a temperatura decresce ao longo da busca, o método explora mais no início e se torna mais seletivo ao final, ajudando a escapar de ótimos locais.

Otimização por Enxame de Partículas (PSO). Cada partícula representa uma parametrização candidata da política de reposição. A posição da partícula contém os valores dos parâmetros e a velocidade define como esses valores são atualizados. A busca combina três forças: persistência da trajetória anterior, atração pela melhor posição individual e atração pela melhor posição coletiva do enxame. Esses termos são controlados por w, c_1 e c_2, respectivamente (Kennedy and Eberhart, 1995). A avaliação de cada partícula é feita por simulação.

Evolução Diferencial (DE). Trata cada solução como um vetor de parâmetros da política. Novos candidatos são gerados por mutação diferencial, combinando diferenças entre vetores da população, e por cruzamento com taxa C_R, que define a probabilidade de cada componente do candidato mutado ser incorporado à nova solução. A seleção mantém o vetor com melhor avaliação simulada. A DE é frequentemente aplicada em espaços contínuos de baixa dimensão, como o espaço de parâmetros das políticas avaliadas neste trabalho (Storn and Price, 1997).

Meta-heurísticas tratam o problema de *como* otimizar os parâmetros de uma política fixada, mas não resolvem, por si só, o problema de *qual* política selecionar para cada série. GA, SA, PSO e DE podem encontrar boas calibrações em regimes específicos; contudo, seu desempenho tende a variar conforme o padrão operacional da demanda, formalizado na sequência pela taxonomia de Syntetos-Boylan. Assim, a seleção contextual permanece em aberto e é tratada, nesta dissertação, pelo PSE do AIPE.

2.2.3 Políticas de Reposição via Aprendizado por Reforço

O aprendizado por reforço (RL) representa uma família de políticas adaptativas incluída no portfólio avaliado pelo AIPE. DQN, PPO e SARSA (e variantes) são formas de aprender políticas de reposição a partir da interação com um ambiente simulado, e não apenas algoritmos abstratos avaliados fora do problema operacional.

No contexto de reposição, o problema pode ser modelado como um Processo de Decisão de Markov (MDP) $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$. O estado resume a situação do sistema em determinado ciclo, incluindo estoque disponível, pedidos em trânsito, demanda recente ou prevista e variáveis temporais. A ação corresponde à decisão de reposição, como pedir determinada quantidade ou não emitir pedido. A recompensa é definida como o negativo do custo operacional, penalizando excesso de estoque, ruptura, frequência inadequada de pedidos e instabilidade. A transição atualiza o ambiente após demanda observada, chegada de pedidos e nova decisão. Assim, o agente aprende uma política que mapeia estados em ações de reposição (Sutton and Barto, 2018).

Nesse enquadramento, o agente observa o estado $\mathbf{s}_t$, escolhe a ação a_t, recebe recompensa $r_t = -\text{custo}_t$ e busca maximizar o retorno descontado $\sum_t \gamma^t r_t$. A política aprendida pode ser comparada às políticas clássicas e às políticas parametrizadas por meta-heurísticas porque todas são executadas no mesmo ambiente e avaliadas pelos mesmos KPIs.

A limitação estrutural dos agentes RL em inventário varejista é a suposição implícita de abundância de interações. Agentes de RL isolados podem exigir um volume de interações muito maior que o horizonte histórico disponível em séries reais de varejo regional. Essa limitação reforça a necessidade de avaliar políticas aprendidas por reforço dentro de um portfólio mais amplo de políticas candidatas, em vez de assumi-las como solução única para todos os perfis de demanda.

DQN. Aproxima a função-valor $Q_\theta(s,a)$ por redes neurais profundas, em que $Q_\theta(s,a)$ estima o retorno esperado ao executar a ação a no estado s e θ representa os parâmetros da rede neural. O método utiliza *experience replay* e *target network* para estabilidade (Mnih et al., 2015). Em inventário, exige espaço de ação discretizado e tende a demandar muitas interações para convergência, o que o torna inadequado quando a série histórica disponível é curta.

PPO. Algoritmo de *policy gradient* com *clipping* ε-*clip*, em que ε limita a magnitude da atualização da política e reduz o risco de colapsos de gradiente (Schulman et al., 2017). Suporta ações contínuas (quantidades), tornando-o mais natural para controle de estoque. Sem inicialização adequada, tende a convergir para política degenerada de alta frequência de pedidos.

SARSA. Algoritmo tabular on-policy com atualização $Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma Q(s',a') - Q(s,a)]$, em que $Q(s,a)$ é o valor estimado do par estado-ação corrente, α é a taxa de aprendi-

zado, r é a recompensa observada, γ é o fator de desconto e (s', a') representa o próximo par estado-ação seguido pela própria política. É limitado em expressividade para regimes intermitentes por requerer discretização grosseira do espaço de estados.

2.2.4 Políticas Híbridas GA-RL

Arquiteturas híbridas GA-RL combinam dois mecanismos complementares. O Algoritmo Genético realiza busca global no espaço de parâmetros de reposição, explorando alternativas sem depender de gradientes ou de hipóteses fortes sobre a distribuição da demanda. O agente de aprendizado por reforço, por sua vez, refina decisões a partir da interação sequencial com o ambiente de inventário. Em conjunto, a busca evolutiva fornece uma inicialização informativa e o RL acrescenta capacidade adaptativa.

Essa combinação é particularmente relevante quando a série histórica disponível é curta ou irregular. Nesses casos, agentes de RL isolados tendem a exigir muitas interações para aprender políticas estáveis, enquanto meta-heurísticas isoladas podem produzir parâmetros bons para o histórico observado, mas pouco reativos a mudanças de estado. Métodos GA-RL procuram reduzir essa tensão: usam busca global para evitar exploração inicial pouco informativa e aprendizado sequencial para ajustar a decisão ao estado corrente.

Nesta dissertação, GA-DQN é avaliada como política especialista dentro do *benchmark* (Seção 4.6.5 justifica a exclusão de GA-PPO do portfólio final). A contribuição central, entretanto, permanece na seleção contextual entre políticas candidatas, isto é, em identificar sob quais condições cada política do portfólio tende a apresentar melhor desempenho. A Figura 2.1 sintetiza essa relação entre busca evolutiva, inicialização informativa e refinamento sequencial por RL.

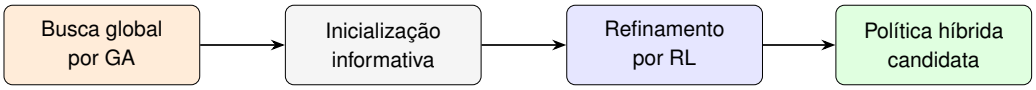


Figura 2.1: Visão conceitual de uma política híbrida GA-RL. A busca evolutiva explora globalmente o espaço de parâmetros e fornece uma inicialização informativa ao agente de aprendizado por reforço, que refina decisões sequenciais no ambiente de inventário.

2.3 Demanda Intermitente

Demanda intermitente é caracterizada por ciclos frequentes de demanda nula intercalados com valores positivos, muitas vezes de magnitude irregular. Esse padrão é prevalente em varejo regional de produtos cosméticos, peças de reposição e bens de consumo de baixa rotatividade, contexto direto desta dissertação (Croston, 1972; Boylan and Syntetos, 2008). Do ponto de vista gerencial, a intermitência pode tornar inadequadas políticas clássicas parametrizadas pela média, como EOQ e (s, S), pois os pressupostos de demanda contínua e estacionária deixam de representar bem o comportamento observado.

Formalmente, seja $D_t \geq 0$ a demanda observada na loja no ciclo $t \in \{1, \ldots, T\}$. Define-se:

$$n_+ = |\{t : D_t > 0\}|, \tag{2.4}$$

$$\mu = \frac{1}{T}\sum_{t=1}^{T} D_t, \quad \sigma^2 = \frac{1}{T-1}\sum_{t=1}^{T}(D_t - \mu)^2. \tag{2.5}$$

Na Equação 2.4, n_+ conta quantos ciclos apresentam demanda positiva e, portanto, mede a frequência efetiva de ocorrência da demanda. Quando n_+ é pequeno em relação ao horizonte T, a série contém muitos ciclos sem venda, característica central da demanda intermitente. Na Equação 2.5, μ representa a demanda média observada no horizonte analisado, enquanto σ^2 mede a variabilidade em torno dessa média. Em conjunto, essas grandezas permitem distinguir séries com demanda frequente e estável de séries raras, irregulares ou altamente voláteis.

O coeficiente de variação $\text{CV} = \sigma/\mu$ quantifica a dispersão relativa; valores $\text{CV} > 1$ indicam demanda altamente errática, característica do portfólio estudado (CV entre 1.5 e 5.4 no conjunto de dados empírico). Essa medida complementa a frequência de ocorrência da demanda ao capturar a irregularidade das quantidades positivas. Na taxonomia apresentada a seguir, CV^2 corresponde ao quadrado desse coeficiente de variação, *Smooth* designa demanda regular e *Lumpy* designa demanda com baixa frequência e alta variabilidade.

2.3.1 Taxonomia ADI $\times$ CV^2

Neste trabalho, a taxonomia de Syntetos-Boylan é utilizada como método de caracterização inicial das séries loja-produto. A classificação combina duas dimensões do comportamento da demanda: o intervalo médio entre demandas positivas, representado pelo ADI (*Average Demand Interval*), e a variabilidade relativa da magnitude da demanda, representada pelo CV^2 (quadrado do coeficiente de variação sobre os valores positivos). A partir dessas duas medidas, cada série é associada a um dos quatro regimes operacionais (*Smooth*, *Intermittent*, *Erratic* ou *Lumpy*), fornecendo uma primeira descrição do padrão de demanda que orienta a estratificação das análises e a interpretação dos resultados do *benchmark*. Essa caracterização é uma etapa de entrada para o processo de seleção contextual do AIPE; ela não determina isoladamente qual política de reposição é a mais adequada para cada série. A identificação da política dominante e o aprendizado da relação entre perfil operacional e política recomendada são realizados nas etapas subsequentes, descritas no Capítulo 4.

A classificação proposta por Syntetos and Boylan (2005) organiza séries de demanda em quatro quadrantes definidos por dois índices adimensionais:

$$\text{ADI} = \frac{T}{n_+} \quad \text{(intervalo médio entre demandas, } \textit{Average Demand Interval}\text{)}, \tag{2.6}$$

$$\text{CV}^2 = \left(\frac{\sigma}{\mu}\right)^2 \quad \text{(quadrado do coeficiente de variação dos valores positivos)}. \tag{2.7}$$

Os limiares empíricos $\text{ADI}^* = 1.32$ e $\text{CV}^{2*} = 0.49$, derivados analiticamente a partir das condições de erro de Croston (Syntetos and Boylan, 2005), definem quatro regimes, resumidos na Tabela 2.1.

Tabela 2.1: Quadrantes de Syntetos-Boylan: limiares e interpretações.

Regime	ADI	CV^2	Interpretação operacional
Smooth (Regular)	< 1.32	< 0.49	Alta frequência, demanda estável.
Erratic (Errático)	< 1.32	≥ 0.49	Alta frequência, magnitude irregular.
Intermittent (Intermitente)	≥ 1.32	< 0.49	Muitos zeros, magnitude relativamente estável.
Lumpy (Grumoso)	≥ 1.32	≥ 0.49	Muitos zeros e magnitude altamente irregular.

Essa taxonomia é amplamente adotada na literatura de cadeias de suprimentos (Boylan and Syntetos, 2008; Syntetos et al., 2012) e constitui, nesta dissertação, a base para estratificação das análises. Os indicadores de desempenho (KPIs) das políticas são reportados por quadrante, permitindo identificar qual abordagem de controle é mais adequada a cada regime de demanda.

2.3.2 Efeitos na Reposição

A Figura 2.2 ilustra a posição das séries no plano $\text{ADI} \times \text{CV}^2$. Para o regime *Smooth*, políticas baseadas em média, como EOQ e Jornaleiro, tendem a ser mais adequadas. Para regimes *Intermittent* e *Lumpy*, métodos específicos de previsão para demanda intermitente tornam-se mais relevantes. O método de Croston estima separadamente o tamanho das demandas positivas e o intervalo entre ocorrências; suas variantes, como SBA e TSB, ajustam esse princípio para reduzir viés e lidar melhor com mudanças na probabilidade de ocorrência da demanda. Ainda assim, do ponto de vista da reposição, a previsão isolada não determina a melhor política: as políticas precisam ser calibradas por unidade para evitar ruptura sistêmica, isto é, falta recorrente de estoque. Para o regime *Erratic*, o maior risco é o excesso de estoque oriundo de pedidos baseados na média quando a demanda cai a zero.

A taxonomia Syntetos-Boylan mostra que regimes de demanda distintos podem favorecer políticas distintas. Embora útil para classificar as séries, ela não determina qual política de reposição é mais adequada em cada quadrante. Por isso, a escolha de política precisa ser tratada como um problema de seleção orientado por evidência empírica, objetivo atendido pelo

AIPE.

Conexão com o AIPE. A hipótese operacional do AIPE é que diferentes posições no espaço de características operacionais, incluindo mas não se limitando ao plano ADI $\times$ CV^2, estão associadas a diferenças no desempenho relativo das políticas candidatas. Nos resultados atuais, essa hipótese é avaliada principalmente dentro do regime *Lumpy*, com extensão para demais quadrantes prevista nos estudos de caso adicionais em andamento (M5 e expansão multiestado).

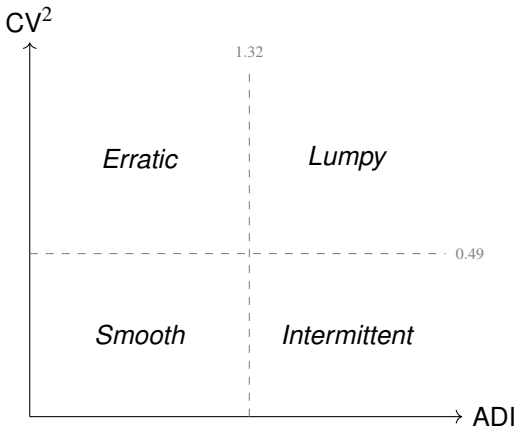


Figura 2.2: Plano ADI $\times$ CV^2 com os quatro quadrantes de Syntetos-Boylan. Limiares: ADI$^* = 1.32$, CV$^{2*} = 0.49$ (Syntetos and Boylan, 2005), com ênfase no quadrante *Lumpy* (alta variabilidade, baixa frequência), que representa o regime mais desafiador para políticas de reposição e concentra as séries dos Experimentos 1 e 2 desta dissertação.

2.4 Métricas de Previsão

As métricas clássicas MAE, RMSE e MAPE apresentam deficiências estruturais em regime intermitente: o MAPE é indefinido quando $D_t = 0$ (frequente na série estudada), o RMSE penaliza excessivamente erros em picos isolados, e nenhuma delas é invariante à escala, dificultando comparações entre séries de volume heterogêneo. A M4, quarta edição da *Makridakis Forecasting Competition* e referência internacional para comparação de métodos de previsão de séries temporais, junto ao trabalho de Hyndman and Koehler (2006), motivou métricas especificamente desenvolvidas para contornar essas limitações (Makridakis et al., 2020), adotadas nesta dissertação.

2.4.1 Métricas Utilizadas

Seja $\{D_t\}_{t=1}^{T}$ a demanda real e $\{\hat{D}_t\}_{t=1}^{T}$ a previsão, ambas observadas ao longo de T ciclos. Define-se o erro de previsão no ciclo t como $e_t = D_t - \hat{D}_t$, e o erro absoluto médio da previsão como MAE $= T^{-1}\sum_{t=1}^{T}|e_t|$. A referência ingênua (*naïve*) é o modelo de passeio aleatório: $\hat{D}_t^{\text{naïve}} = D_{t-1}$, com erro médio absoluto MAE$_{\text{naïve}} = \frac{1}{T-1}\sum_{t=2}^{T}|D_t - D_{t-1}|$.

MASE (*Mean Absolute Scaled Error*). Proposto por Hyndman and Koehler (2006), é invariante à escala e bem definido mesmo com zeros na série:

$$\text{MASE} = \frac{\text{MAE}}{\text{MAE}_{\text{naïve}}} = \frac{\frac{1}{T}\sum_t |e_t|}{\frac{1}{T-1}\sum_{t=2}^{T} |D_t - D_{t-1}|}. \tag{2.8}$$

Na Equação 2.8, o numerador mede o erro absoluto médio do modelo avaliado e o denominador mede o erro absoluto médio da previsão ingênua. Assim, MASE < 1 indica desempenho melhor que o modelo ingênuo; MASE $= 1$ é o *benchmark* neutro.

sMAPE (*Symmetric MAPE*). Proposto por Makridakis (1993), utiliza denominador simétrico para lidar com zeros e assimetria:

$$\text{sMAPE} = \frac{2}{T}\sum_t \frac{|e_t|}{|D_t| + |\hat{D}_t|} \times 100\%. \tag{2.9}$$

Na Equação 2.9, D_t e $\hat{D}_t$ aparecem simetricamente no denominador, reduzindo a dependência da escala da série. A métrica é limitada ao intervalo $[0\%, 200\%]$ e não apresenta singularidade quando $D_t = 0$ e $\hat{D}_t > 0$.

RMSSE (*Root Mean Squared Scaled Error*). Versão escalada do RMSE, utilizada como métrica principal na M4, competição internacional de previsão de séries temporais (Makridakis et al., 2020):

$$\text{RMSSE} = \sqrt{\frac{\frac{1}{T}\sum_t e_t^2}{\frac{1}{T-1}\sum_{t=2}^{T} (D_t - D_{t-1})^2}}. \tag{2.10}$$

Na Equação 2.10, o numerador é o erro quadrático médio do modelo e o denominador é o erro quadrático médio da previsão ingênua. A métrica penaliza erros grandes (via quadrado), mas permanece comparável entre séries de diferentes escalas.

Métricas diagnósticas complementares. Duas métricas adicionais aparecem como diagnóstico complementar (Figura 5.10, Capítulo 5), sem papel na seleção do modelo principal: o MBE (*Mean Bias Error*), MBE $= \overline{D} - \overline{\hat{D}}$, detecta viés sistemático: MBE > 0 indica subestimação (risco de ruptura), MBE < 0 superestimação (excesso de estoque); e o U de Theil (Theil, 1966), $U_{\text{Theil}} = \text{RMSE}/\text{RMSE}_{\text{naïve}}$, com $U_{\text{Theil}} < 1$ indicando desempenho melhor que o *naïve*.

Seleção da métrica principal. O MASE é adotado como métrica principal nesta dissertação por três razões: (i) invariância à escala permite comparar modelos entre lojas com volumes heterogêneos (razão de até 124 vezes no conjunto de dados); (ii) definição clara quando $D_t = 0$; (iii) interpretação intuitiva em relação ao *benchmark* ingênuo. O sMAPE é métrica secundária por sua *bounded range* e ampla adoção em *benchmarks* competitivos. No processo de seleção

contextual, o MASE por série é tratado como sinal operacional prospectivo: séries com menor erro de previsão tendem a favorecer políticas orientadas a previsão, enquanto séries mais imprevisíveis favorecem políticas menos sensíveis à variância.

A avaliação de modelos de previsão em séries temporais requer protocolos que respeitem a ordem temporal dos dados. Por essa razão, esta dissertação adota validação temporal por janela deslizante, detalhada no Capítulo 4, de modo que cada previsão seja realizada apenas com informações anteriores ao período avaliado.

2.5 Testes Estatísticos

A comparação entre as políticas do portfólio (Seção 4.6.5) sobre múltiplas lojas e múltiplos produtos no Experimento 2 requer uma estrutura inferencial formal. Como as distribuições dos KPIs em regime intermitente são fortemente assimétricas, os testes paramétricos baseados em normalidade (ANOVA, t de Student) são inadequados. Os testes não paramétricos (Wilcoxon, Friedman e Nemenyi) são adotados como padrão metodológico nesta dissertação, combinados com medida de tamanho de efeito (Cohen's d) para distinguir significância estatística de relevância prática.

2.5.1 Teste de Wilcoxon

O teste de Wilcoxon *signed-rank*, proposto por Wilcoxon (1945), avalia se a mediana das diferenças pareadas entre duas políticas π_A e π_B é diferente de zero. Nesta dissertação, o teste é utilizado para comparar políticas avaliadas nas mesmas séries. Para o KPI X (e.g., CTI) nas lojas $i = 1, \ldots, N$:

$$W = \sum_{i:D_i \neq 0} \text{sgn}(D_i)\, R_i, \tag{2.11}$$

em que $D_i = X_i^A - X_i^B$ é a diferença pareada entre as políticas A e B na instância i, X_i^A e X_i^B são os valores do KPI X para essas políticas, $\text{sgn}(D_i)$ é o sinal da diferença e R_i é o posto de $|D_i|$ após excluir diferenças nulas. Hipótese nula: $\text{mediana}(D_i) = 0$. Ao contrário do t-test, não assume normalidade nem homocedasticidade.

2.5.2 Teste de Friedman e Nemenyi

Quando se compara $K > 2$ políticas simultaneamente, o teste de Friedman, proposto por Friedman (1940), testa se os postos médios de todas as políticas são iguais:

$$\chi_F^2 = \frac{12N}{K(K+1)} \sum_{j=1}^{K} \left(\bar{r}_j - \frac{K+1}{2} \right)^2, \tag{2.12}$$

em que K é o número de políticas comparadas, N é o número de instâncias avaliadas e $\bar{r}_j$ é o posto médio da política j sobre as N instâncias (lojas $\times$ produtos). A rejeição de H_0 indica que pelo menos uma política tem desempenho diferente. O *post-hoc* de Nemenyi, proposto por Nemenyi (1963), computa a diferença crítica (DC):

$$\text{DC} = q_\alpha \sqrt{\frac{K(K+1)}{6N}}, \tag{2.13}$$

em que q_α é o quantil da distribuição de Studentized range para o nível de significância α. Políticas cujos postos médios diferem em mais de DC são estatisticamente distinguíveis a nível α.

2.5.3 Tamanho de Efeito

O teste de Wilcoxon indica se a diferença é estatisticamente significante, mas não quantifica sua magnitude prática. O d de Cohen, sistematizado por Cohen (1988), fornece essa quantificação ao padronizar a diferença entre médias. Sua formulação é:

$$d = \frac{\bar{X}_A - \bar{X}_B}{s_{\text{pooled}}}, \quad s_{\text{pooled}} = \sqrt{\frac{(N_A-1)s_A^2 + (N_B-1)s_B^2}{N_A+N_B-2}}. \tag{2.14}$$

Convencionalmente: $|d| < 0.2$ é efeito negligenciável, $0.2 \leq |d| < 0.5$ pequeno, $0.5 \leq |d| < 0.8$ médio, $|d| \geq 0.8$ grande. Essa gradação é reportada para cada par (política proposta, *baseline*) em cada KPI e cada quadrante Syntetos-Boylan.

Na Equação 2.14, $\bar{X}_A$ e $\bar{X}_B$ são as médias do KPI para os grupos ou políticas comparados, s_A^2 e s_B^2 são suas variâncias amostrais, N_A e N_B são os respectivos tamanhos amostrais e s_{pooled} é o desvio-padrão combinado usado para padronizar a diferença. Essa medida complementa os testes de hipótese ao indicar se a diferença observada possui relevância prática.

O protocolo Wilcoxon + Friedman + Nemenyi + Cohen's d combina detecção de diferença, comparação múltipla e quantificação de relevância prática. Com esse encadeamento, o *benchmark* reduz o risco de interpretar ruído amostral como ganho real e apoia a geração de rótulos mais consistentes para o treinamento do PSE.

Os testes estatísticos apresentados nesta seção são aplicados sobre os resultados gerados pelo ambiente de simulação descrito no Capítulo 4 (Seção 4.7.1).

3

Trabalhos Relacionados

Este capítulo posiciona a dissertação em relação à literatura existente sobre controle de inventário, previsão de demanda intermitente, meta-heurísticas, aprendizado por reforço e seleção adaptativa de políticas. Enquanto o Capítulo 2 apresentou os fundamentos conceituais necessários à formulação do problema, este capítulo compara como trabalhos anteriores abordam problemas próximos ao AIPE e em que medida diferem da proposta desta dissertação.

A análise está organizada em cinco eixos: controle de inventário em redes varejistas, previsão de demanda intermitente, métodos de otimização e aprendizado por reforço, seleção adaptativa de políticas e arquiteturas híbridas GA-RL. O objetivo é explicitar o posicionamento da dissertação sem repetir fundamentos já apresentados, destacando sua contribuição como integração metodológica para seleção contextual de políticas de reposição.

3.1 Visão Geral dos Métodos e Resultados da Literatura

A literatura de controle de inventário dispõe de uma base consolidada de políticas clássicas, como EOQ, (s, S), estoque-base e jornaleiro (Axsäter, 2006; Zipkin, 2000), reconhecidas pela simplicidade, interpretabilidade e facilidade de implantação operacional. Em paralelo, métodos de previsão de demanda intermitente, como Croston (Croston, 1972), SBA, ARIMA/SARIMAX, LSTM e XGBoost (Makridakis et al., 2020; Nasseri et al., 2023), produzem estimativas que qualificam o comportamento esperado das séries. Contudo, políticas clássicas enfrentam dificuldades em regimes de alta intermitência e demanda heterogênea, e a previsão não determina, por si só, qual política de reposição adotar para cada perfil de série.

A Tabela 3.1 sintetiza as principais famílias de métodos, seus resultados típicos e as limitações que motivam esta dissertação. Na tabela, a coluna “Família” agrupa os métodos por linha de pesquisa; “Exemplos” lista métodos representativos de cada família; “Resultado típico” resume o tipo de ganho ou aplicação mais comum reportado na literatura; e “Limitação” indica a lacuna que persiste em relação ao problema tratado nesta dissertação.

Tabela 3.1: Síntese dos principais métodos e lacunas da literatura.

Família	Exemplos	Resultado típico	Limitação
Políticas clássicas	EOQ, (s, S), estoque-base, Jornaleiro	Simplicidade, interpretabilidade e facilidade de implantação	Baixa adaptação a séries heterogêneas e regimes intermitentes
Previsão de demanda	Croston, SBA, ARIMA, LSTM, XGBoost	Melhora estimativas e fornece sinais preditivos	Não define qual política de reposição aplicar
Otimização e meta-heurísticas	GA, SA, PSO, DE, MILP	Calibração de parâmetros e redução de custo em cenários específicos	Calibra política ou formulação específica, sem selecionar entre famílias
Aprendizado por reforço	DQN, PPO, SARSA, DRL	Decisões sequenciais em ambientes simulados	Sensível à recompensa, ao ambiente e ao histórico disponível
Seleção e meta-aprendizado	ASP, hiper-heurísticas, AutoML	Escolha de método conforme características da instância	Pouco explorado para seleção de políticas em redes varejistas reais

Para tratar essas limitações isoladas, a literatura explorou meta-heurísticas para calibrar parâmetros em espaços não convexos (Talbi, 2009; Yuna et al., 2023), agentes de aprendizado por reforço para aprender decisões sequenciais em ambientes simulados (Oroojlooyjadid et al., 2022; Gijsbrechts et al., 2022) e abordagens de seleção de algoritmos para mapear características de instâncias em métodos adequados (Rice, 1976; Kerschke et al., 2019). Meta-heurísticas normalmente calibram uma política ou formulação específica, sem resolver automaticamente a escolha entre famílias distintas; agentes de RL demandam históricos longos e são sensíveis à função de recompensa e à modelagem do ambiente; a seleção de algoritmos, por sua vez, tem pouca aplicação direta à escolha de políticas de reposição por série em redes varejistas reais.

A literatura oferece, assim, blocos metodológicos sólidos para previsão de demanda, otimização de parâmetros e controle sequencial de estoque, mas ainda há espaço para integrá-los em um *framework* único que caracterize as séries, avalie empiricamente um portfólio de políticas candidatas e aprenda a selecionar contextualmente a política mais adequada. As seções seguintes detalham como cada frente contribui e onde persistem as lacunas.

3.2 Inventário em Redes Varejistas

A literatura de controle de estoques em redes multi-escalão parte do trabalho fundador de Clark and Scarf (1960), que estabelece, para estruturas seriadas, que políticas ótimas podem ser decompostas por escalão sob hipóteses específicas. Axsäter (2006) e Zipkin (2000) conso-

lidam essa base em textos clássicos que formalizam custos de posse e ruptura, políticas de estoque-base (*base-stock*) e medidas de nível de serviço. Em ambientes industriais, modelos Guaranteed Service Model (GSM) (Graves and Willems, 2000) e suas extensões (Achkar et al., 2024; Eruguz et al., 2016) constituem a principal família de abordagens para posicionamento estratégico de estoques de segurança em redes gerais, sendo amplamente empregados em planejamento integrado.

O regime de demanda intermitente introduz complexidades que escapam à teoria clássica. Croston (1972) propôs o primeiro estimador específico para esse regime, modelando separadamente a frequência e o tamanho dos eventos de demanda. Syntetos and Boylan (2001) refinaram essa classificação, introduzindo o diagrama ADI$\times$CV^2 que divide os padrões de demanda em quatro quadrantes com recomendações metodológicas distintas, tornando explícita a diferença entre séries de demanda *suave*, *errática*, *intermitente* e *grumosa* (*lumpy*). de Kok et al. (2018) sintetizam o estado da arte em otimização de inventário multi-escalão (MEIO) e identificam como lacunas abertas exatamente as situações de demanda não-estacionária em redes gerais (o contexto desta dissertação).

3.3 Previsão de Demanda Intermitente

A previsão de demanda intermitente apresenta dois desafios estruturais: (i) a frequência de zeros impede o uso de métricas relativas clássicas como MAPE; (ii) a não-estacionariedade invalida hipóteses de modelos como Holt-Winters que pressupõem padrões suaves. Evidência empírica em competições de previsão (M4/M5) indica que modelos baseados em árvores de decisão e gradiente *boosting* frequentemente têm desempenho melhor que redes LSTM em séries com alta intermitência, especialmente quando o volume de dados históricos por SKU é limitado (Nasseri et al., 2023).

No plano das métricas, Hyndman and Koehler (2006) introduziram o MASE como substituto livre de escala para o MAPE: é definido com demanda real zero, é comparável entre séries de escalas distintas e não sofre da assimetria do MAPE. Makridakis (1993) propôs o sMAPE como variante simétrica; a competição M4 adotou o MASE como métrica primária, consolidando seu uso (Makridakis et al., 2020).

Tadayonrad and Ndiaye (2023) argumentam que essas métricas, embora mais adequadas que o MAPE em séries intermitentes, não capturam o impacto sobre custos operacionais e propõem KPIs alinhados ao custo e ao nível de serviço. Esta dissertação segue essa direção: o módulo de previsão alimenta características ao AIPE em vez de ser avaliado isoladamente.

A previsão de demanda, entretanto, não define sozinha a política de reposição. Ela fornece sinais auxiliares sobre o comportamento esperado da série, mas a decisão de quando pedir e quanto pedir depende de uma política de controle, cujo ajuste ou aprendizado por meta-heurísticas e por aprendizado por reforço é discutido na seção seguinte.

3.4 Meta-Heurísticas e Aprendizado por Reforço em Políticas de Reposição

Enquanto a seção anterior discutiu métodos de previsão de demanda, esta seção trata de trabalhos que aplicam meta-heurísticas e aprendizado por reforço ao controle de inventário e à parametrização de políticas de reposição. Nesse contexto, o objetivo não é prever diretamente a demanda, mas decidir quando emitir pedidos e em que quantidade, ou calibrar parâmetros de políticas como (s, S), EOQ ou regras equivalentes. Essa distinção é importante para esta dissertação, pois a previsão é usada como sinal auxiliar, enquanto a decisão central do AIPE é selecionar políticas de reposição.

A otimização de parâmetros de políticas de inventário por meta-heurísticas tem sido extensivamente estudada. Talbi (2009) consolida a base teórica de GA, SA, PSO e outros métodos de busca para problemas combinatórios e de otimização em espaços de parâmetros.

No contexto de demanda intermitente, Yuna et al. (2023) compararam SA e Busca Tabu na otimização de parâmetros de uma política (s, S) em sete conjuntos com CV$>$1.5; Erkayman et al. (2025) modelaram demanda como cadeia de Markov e otimizaram parâmetros com GA e PSO. Esses estudos mostram que a calibração automática pode melhorar o desempenho de uma política específica, isto é, resolvem *como* calibrar uma política já escolhida, mas não *qual* política adotar dado o perfil da série. Além disso, restringem-se a modelos de único escalão sem comparação entre famílias distintas de política.

Na frente de aprendizado por reforço, os trabalhos relacionados tratam a reposição como um problema sequencial de decisão, não como previsão. Oroojlooyjadid et al. (2022) demonstraram que DQN aprende políticas de reposição no *Beer Game* multi-escalão sem especificar a distribuição de demanda, mas assumem séries longas e demanda contínua. Geevers et al. (2024) aplicaram PPO a três topologias de rede com desempenho melhor que o *benchmark*, porém em ambientes sintéticos com CV < 1. Liu et al. (2025) introduziram HAPPO para reduzir simultaneamente custo e efeito *bullwhip* em ambientes descentralizados, mas não abordam demanda intermitente.

A limitação transversal desses trabalhos está na distância entre calibrar ou treinar uma política específica e selecionar contextualmente entre famílias distintas de políticas: meta-heurísticas calibram bem uma formulação já escolhida, e agentes de RL podem aprender boas decisões em um ambiente específico, mas nenhuma dessas abordagens responde diretamente *qual* política deve ser adotada para uma série loja-produto com características operacionais específicas. Soma-se a isso uma limitação prática do RL: a exigência da ordem de 10^6 interações agente-ambiente, isto é, passos sequenciais em que o agente observa o estado do estoque, escolhe uma ação de reposição, recebe a recompensa associada ao custo e ao nível de serviço e atualiza sua política (Oroojlooyjadid et al., 2022). Essa escala é incompatível com séries históricas curtas de varejo (38 ciclos no *dataset* desta dissertação) e é a razão estrutural pela

qual RL isolado degenera no regime estudado. Essa lacuna justifica tratar meta-heurísticas e agentes de RL como componentes de um portfólio de políticas candidatas, e não como solução única para todas as séries.

3.5 Seleção de Políticas, Hiper-Heurísticas e Meta-Aprendizado

O problema de determinar qual algoritmo usar dada uma instância foi formalizado por Rice (1976) como o *Algorithm Selection Problem* (ASP). Dado um espaço de instâncias I, um espaço de algoritmos $\mathcal{A}$ e uma medida de desempenho f, o objetivo é encontrar $s^* : I \to \mathcal{A}$ tal que $s^*(i) = \arg\max_{a \in \mathcal{A}} f(a, i)$. O AIPE é uma instância direta do ASP aplicada ao controle de inventário: as instâncias são séries de demanda, os algoritmos são as políticas candidatas e f é o CTI minimizado sujeito a NS mínimo.

O teorema *No Free Lunch* (NFL) de Wolpert and Macready (1997) fornece a justificativa teórica: nenhum algoritmo domina todos os outros na média sobre todas as instâncias. Isso implica que qualquer ganho de desempenho consistente exige explorar estrutura específica da classe de problemas. As características operacionais usadas como entrada pelo AIPE (ADI, CV^2, *burstiness*, entropia, sazonalidade) são exatamente essa estrutura discriminativa.

A implementação prática do ASP segue o paradigma *características de instância* $\to$ *modelo supervisionado* $\to$ *seleção de algoritmo*. Kerschke et al. (2019) consolidam esse paradigma em *survey* abrangente; Kerschke and Trautmann (2019) demonstram empiricamente que características de paisagem combinadas com classificadores supervisionados selecionam automaticamente o otimizador mais adequado por instância, a mesma arquitetura conceitual adotada pelo AIPE ao usar características operacionais de demanda como entrada. Kotthoff (2014) mostra que seletores por instância podem obter ganhos frente a políticas fixas em problemas combinatórios.

No campo das *hyper-heuristics*, Drake et al. (2020) e Dokeroglu et al. (2024) consolidam o estado da arte: *selection hyper-heuristics* escolhem, a cada estado do problema, qual heurística aplicar. O AIPE é análogo operando no nível de série, mas com escopo distinto: seleciona *offline* a política a partir do histórico e do perfil de demanda da combinação loja-produto, antes da execução operacional. Uma seleção *online* por estado de estoque implicaria trocar heurísticas a cada ciclo ou decisão de reposição, exigindo um controlador em tempo real; nesta dissertação, essa responsabilidade é substituída por recomendações periódicas de política por série.

Em inventário especificamente, Preil and Krapp (2022) modelam a seleção como *multi-armed bandit*, e Sultana et al. (2024) adaptam políticas de RL via informação de contexto. O AIPE se alinha a essa direção ao deslocar o foco da adaptação de parâmetros de uma política fixada para a seleção contextual entre famílias de política. Qi et al. (2023) mostram em *Management Science* que características operacionais podem sustentar aprendizado de políticas de inventário em escala industrial.

A literatura de ASP, *hyper-heuristics* e meta-aprendizado converge para o mesmo ponto: a política mais adequada depende da instância, essa dependência pode ser aprendida e, em contextos apropriados, um meta-modelo treinado com evidência empírica pode obter ganhos frente a políticas fixas. Neste trabalho, esse princípio é aplicado ao problema de inventário varejista sob demanda intermitente.

3.6 Políticas Híbridas GA-RL

A frente mais próxima combina busca global de meta-heurísticas com adaptação local do RL. Zabraoui et al. (2025) é o artigo-base que inspirou a inclusão da arquitetura GA-DQN no portfólio desta dissertação. Os autores introduziram GA-DQN sobre o conjunto Walmart M5 (CV típico < 1): o GA otimiza parâmetros globalmente enquanto o DQN refina decisões a cada ciclo, elevando o NS de 61% para 94% com redução de custo. Esta dissertação incorpora GA-DQN como *uma das doze políticas do portfólio final* (Seção 4.6.5), mas posiciona o *Policy Selection Engine* como contribuição principal: o objetivo não é provar que GA-DQN vence em todos os regimes, mas aprender *quando* cada política do portfólio apresenta vantagem relativa. Esse enquadramento é compatível com a evidência empírica observada, pois nenhuma política domina todas as métricas em todos os regimes. Também preserva abertura metodológica: o PSE pode incorporar novas políticas ao *benchmark* desde que seus desempenhos sejam avaliados e os rótulos do meta-modelo sejam atualizados. Além de reproduzir a inspiração conceitual de Zabraoui et al. (2025) no portfólio, esta dissertação avalia o portfólio completo diretamente sobre o mesmo conjunto Walmart M5 usado pelos autores, como estudo de caso de validação externa (Estudo de Caso 3, Capítulo 7).

A variante GA-PPO, que substitui o DQN por uma política contínua baseada em PPO (Vanvuchelen et al., 2020; Gijsbrechts et al., 2022), **também é proposta por** Zabraoui et al. (2025): o Algoritmo 1 daquele trabalho inicializa indistintamente um agente PPO ou DQN a partir da configuração θ^* obtida pelo GA, e os autores comparam as duas variantes, reportando nível de serviço de 94% para GA-DQN contra 91% para GA-PPO, com o GA-PPO exibindo padrões de pedido mais reativos e maior volatilidade do estoque. Nenhuma das duas arquiteturas híbridas é, portanto, contribuição original desta dissertação: ambas foram testadas como políticas especialistas do portfólio, com formulação herdada do artigo-base: GA-DQN compõe o portfólio final (Seção 4.6.5); GA-PPO foi avaliada no Experimento 1 mas não tem referência publicada própria como âncora, e por isso não compõe o portfólio final.

Registra-se que a maior volatilidade do GA-PPO observada por Zabraoui et al. (2025) em regime de baixa intermitência (CV < 1) é consistente com a frequência de pedidos elevada verificada para a mesma arquitetura no Experimento 1 desta dissertação, sob regime *Lumpy*. Trata-se de convergência de evidência entre bases e regimes distintos, e não de achado inédito. A presença de GA-DQN no portfólio final possibilita ao PSE identificar, para cada perfil operaci-

onal de demanda, se a abordagem híbrida oferece melhor compromisso entre custo e nível de serviço ou se políticas clássicas permanecem mais adequadas naquele recorte.

3.7 Posicionamento da Dissertação

A Tabela 3.2 posiciona esta dissertação em relação aos trabalhos mais próximos segundo seis dimensões. A coluna “Trabalho” identifica o estudo analisado; “Base usada” diferencia avaliações conduzidas em ambientes sintéticos, conjuntos de teste e dados transacionais reais; “CV ou regime” resume o nível de variabilidade ou o regime de demanda considerado; “Políticas avaliadas” informa quantas alternativas de reposição ou controle foram comparadas; “Multinível” indica se o estudo considera mais de um escalão da cadeia de suprimentos; e “Indicadores avaliados” informa o número de métricas operacionais utilizadas. Essa comparação permite situar a dissertação quanto à escala experimental, ao tipo de dado e à abrangência metodológica.

Tabela 3.2: Posicionamento desta dissertação em relação aos trabalhos relacionados.

Trabalho	Base usada	CV ou regime	Políticas avaliadas	Multi-nível	Indicadores avaliados
Oroojlooyjadid et al. 2022	Sintética	< 1	3	Sim	2
Vanvuchelen et al. 2020	Sintética	< 1	4	Não	1
Gijsbrechts et al. 2022	Sintética	< 1	6	Sim	2
Yuna et al. 2023	Testes intermitentes	> 1.5	2	Não	2
Erkayman et al. 2025	Sint. Markov	> 1.5	2	Não	1
Liu et al. 2025	Sintética	< 1	4	Sim	2
Zabraoui et al. 2025	Real (Walmart M5)	< 1	7	Sim	3
Esta dissertação (Experimento 1)	Real (PB)	$\mathbf{2.5}-\mathbf{5.4}$	12	Sim	5
Esta dissertação (Experimento 2)	Real (BA)	Lumpy; etapa nacional futura	12	Sim	5 + testes

A revisão da literatura aponta três lacunas convergentes. A primeira é empírica: embora trabalhos recentes já incluam bases reais de varejo, como o Walmart M5 em Zabraoui et al. (2025), ainda há poucos estudos que avaliam políticas de reposição em dados reais de varejo brasileiro com demanda altamente intermitente e séries loja-produto heterogêneas. A segunda é metodológica: trabalhos existentes tendem a otimizar ou aprender políticas específicas, mas não formulam a escolha da política como um problema de seleção contextual por perfil operacional da série. A terceira é operacional: ainda é pouco explorada a integração, em um mesmo *pipeline* reprodutível, entre caracterização das séries, simulação comparável de políticas, validação estatística, geração de rótulos de política dominante e treinamento de um seletor supervisionado. Essas lacunas motivam a formulação do AIPE como abordagem integrada de avaliação e recomendação de políticas.

As seções anteriores indicam que decisões de reposição em redes varejistas heterogêneas dependem do comportamento operacional de cada série loja-produto: políticas clássicas, parametrizadas por meta-heurísticas e aprendidas por reforço oferecem alternativas relevantes, mas seu desempenho varia conforme frequência, variabilidade e volume da demanda, e a previsão contribui apenas como sinal auxiliar. A contribuição desta dissertação não está em propor novos algoritmos: GA, SA, DQN, PPO e as arquiteturas híbridas GA-RL já existem na literatura e são utilizados como componentes conhecidos de um portfólio experimental, avaliados sob o mesmo protocolo. O papel do AIPE é organizar esses componentes em um *framework* metodológico de seleção contextual, no qual séries são caracterizadas, políticas candidatas são avaliadas sob ambiente comum de simulação e os resultados recomendam a política mais adequada por perfil operacional, sobre dados reais de rede varejista brasileira.

A comparação entre múltiplas políticas é necessária para construir o *benchmark* e gerar rótulos de política dominante, mas não constitui, isoladamente, a contribuição central: o ponto central é avaliar se a seleção contextual reduz o custo de inventário em relação a uma política única global, preservando serviço mínimo e estabilidade operacional, completado pelo treinamento do PSE a partir dessa evidência. O próximo capítulo apresenta a metodologia adotada para operacionalizar essa proposta: avaliação das políticas candidatas em simulação comum, comparação por métricas de custo, serviço e estabilidade, geração de rótulos de política dominante e treinamento do *Policy Selection Engine* (PSE).

4

Metodologia

Este capítulo apresenta a estrutura metodológica do AIPE, fundamentada na hipótese central de que o desempenho de políticas de reposição depende do regime operacional da demanda e que essa relação pode ser aprendida por um meta-modelo supervisionado. A metodologia organiza a camada de entrada (dados preparados, características operacionais e sinais auxiliares de previsão), o *benchmark* de políticas candidatas, a validação estatística, a geração de rótulos de política dominante e o treinamento do PSE. O primeiro experimento, conduzido como estudo piloto na Paraíba, testou o protocolo em escala controlada; o segundo experimento, conduzido com 145 séries da Bahia, ampliou o escopo empírico e incluiu validação estatística formal. Esses dois experimentos permanecem a referência central de resultados; dois estudos de caso adicionais (M5, benchmark público internacional; e a expansão multiestado da base nacional, Capítulo 7) estão em andamento para testar a validade externa do AIPE em condições de demanda, escala e proveniência distintas.

4.1 Visão Geral do AIPE

Nesta dissertação, o AIPE é a proposta metodológica principal: um *framework* de seleção contextual de políticas de reposição. O PSE é seu componente de seleção, e as políticas avaliadas compõem o portfólio de alternativas sobre o qual o *framework* aprende a recomendar. Dados preparados, características das séries e sinais de previsão compõem a camada de entrada; o foco do AIPE está em transformar esses insumos em decisões de política por comparação empírica, validação estatística e aprendizado supervisionado, não nas etapas de entrada isoladamente.

O aprendizado de máquina aparece em dois níveis. No primeiro, políticas aprendidas por reforço (DQN, PPO) são candidatas comparadas às políticas clássicas, parametrizadas por meta-heurísticas e híbridas. No segundo, o PSE atua como meta-modelo supervisionado que

aprende, a partir do desempenho dessas políticas em simulação (política dominante = menor CTI entre as viáveis, NS $\geq 0{,}70$; formalizado na Equação 4.7), qual candidata tende a ser mais adequada para cada perfil operacional de demanda.

A organização deste capítulo acompanha a arquitetura conceitual da Figura 4.1 em camadas: formulação do problema e camada de entrada (dados, caracterização das séries e sinais auxiliares de previsão); portfólio de políticas candidatas e ambiente de simulação; protocolos de validação temporal e estatística; geração de rótulos e treinamento do PSE; e camada de aplicação. As seções finais de artefatos e protocolo experimental complementam a arquitetura com requisitos de rastreabilidade e execução reprodutível.

A leitura da Figura 4.1 deve ser feita de cima para baixo. Na camada de entrada, a base transacional e os parâmetros locais são padronizados em séries loja-produto comparáveis; em seguida, extraem-se características operacionais, PODs e sinais auxiliares de previsão. No núcleo de seleção contextual, o portfólio reúne políticas clássicas, políticas parametrizadas por meta-heurísticas, políticas aprendidas por reforço e políticas híbridas GA-RL. Todas são executadas no mesmo ambiente de simulação, gerando os KPIs usados na avaliação comparativa, nos testes estatísticos e na construção dos rótulos de política dominante. O PSE aprende esses rótulos a partir das entradas operacionais. Na camada de aplicação, uma nova série é descrita pelo mesmo vetor de entrada, recebe uma recomendação ranqueada e pode ser reavaliada periodicamente conforme novos ciclos de venda alteram suas características.

4.2 Instanciação Experimental do Problema de Inventário

O Capítulo 2 apresentou a formulação conceitual do controle de inventário e as famílias de políticas de reposição. Nesta seção, essa formulação é instanciada para o *benchmark* empírico: definem-se as decisões observadas em cada série loja-produto, a estrutura de rede, os parâmetros operacionais locais e a forma como as métricas são calculadas sob condições comparáveis.

4.2.1 Instanciação das Políticas e Espaço de Decisão

A definição formal de política de reposição foi apresentada no Capítulo 2. Na metodologia, essa definição é operacionalizada para cada série loja-produto: no ciclo t, a política recebe o estado observado da loja i e retorna uma quantidade de pedido não negativa:

$$Q_{t,i} = \pi(I_{t,i}, D_{t-1,i}, Q_{t-L,i}; \boldsymbol{\theta}),$$

em que $I_{t,i}$ representa o estoque disponível, $D_{t-1,i}$ resume a demanda recente, $Q_{t-L,i}$ indica pedidos em trânsito recebidos após o prazo de entrega e $\boldsymbol{\theta}$ é o vetor de parâmetros da política. Esse vetor assume naturezas distintas conforme a família candidata, como pares (s, Q) em políticas parametrizadas ou pesos de rede neural em agentes de aprendizado por reforço.

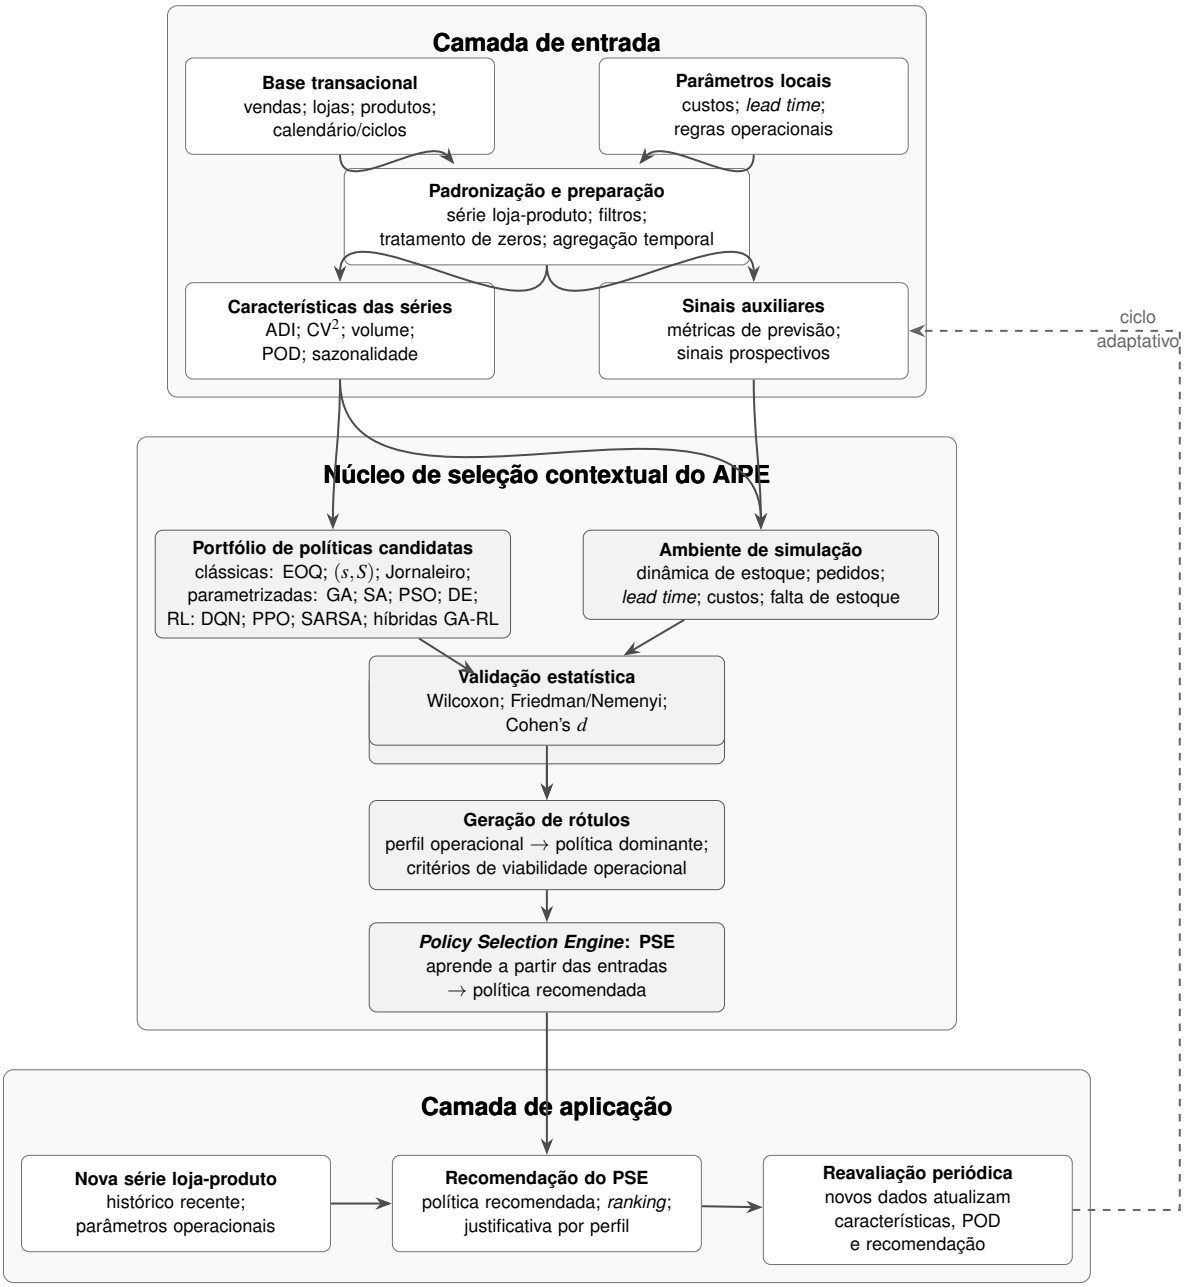


Figura 4.1: Arquitetura conceitual do *framework* AIPE. A camada de entrada reúne dados transacionais preparados, parâmetros operacionais, características das séries e sinais auxiliares de previsão de demanda. O núcleo de seleção contextual utiliza essas entradas para avaliar políticas candidatas, gerar rótulos de política dominante, realizar validação estatística e treinar o *Policy Selection Engine*. A camada de aplicação utiliza o PSE para recomendar políticas a novas séries loja-produto e reavaliar periodicamente as recomendações conforme novos dados se acumulam.

Esta distinção é essencial: as políticas avaliadas são instâncias de famílias distintas; o AIPE é a estratégia adaptativa que aprende qual família e parâmetros usar por série. Assim, o foco metodológico está na seleção contextual, e não na defesa de uma política isolada como solução universal.

Definição 4.2.1 (Seleção Adaptativa de Política (AIPE)) *Dado o espaço de séries $\mathcal{X}$, o mapeamento de características $\phi : \mathcal{X} \to \mathbb{R}^p$ e o conjunto de políticas candidatas $\Pi = \{\pi_1, \ldots, \pi_k\}$, o Policy Selection Engine aprende a função:*

$$f : \mathbb{R}^p \to \Pi, \qquad f\big(\phi(\mathbf{x}_i)\big) = \hat{\pi}^*(i),$$

tal que $\hat{\pi}^*(i) \approx \arg\min_{\pi \in \Pi} \mathbb{E}[\mathrm{CTI}(\pi, \mathbf{x}_i)]$ sujeito a $\mathbb{E}[\mathrm{NS}(\pi, \mathbf{x}_i)] \geq \alpha_{\min}$. O Adaptive Inventory Policy Engine (AIPE) implementa f como meta-modelo supervisionado treinado sobre os pares $\{(\phi(\mathbf{x}_i), \hat{\pi}^*(i))\}_{i=1}^N$ gerados pelo benchmark, com reavaliação periódica de $\phi(\mathbf{x}_i)$ a cada Δt ciclos.

4.2.2 Instanciação do Ambiente de Inventário

Esta seção instancia, no ambiente experimental, a formulação conceitual do problema de reposição apresentada na Seção 2.1.2 (função objetivo e dinâmica de estoque): o ambiente especializa o modelo para uma rede varejista com N lojas atendidas por um armazém central, horizonte discreto de T ciclos comerciais (cada um com aproximadamente 21 dias corridos) e séries loja-produto avaliadas individualmente.

Para cada série, o ambiente recebe a demanda observada por ciclo, o estoque inicial, o prazo de entrega, os parâmetros de custo e a política a ser testada. A cada ciclo, a política decide se emite um pedido e em qual quantidade; em seguida, o ambiente atualiza o estoque, registra demanda atendida e não atendida, incorpora pedidos recebidos após o prazo de entrega e acumula os custos operacionais. Ao final da simulação, são calculados os indicadores CTI, NS, TR, BE e FP, usados no *benchmark* das políticas e na geração dos rótulos de política dominante.

As variáveis desta instanciação, indexadas por loja i, são:

- $D_{t,i} \geq 0$: demanda observada na loja i no ciclo t;
- $I_{t,i}$: nível de estoque da loja i no início de t;
- $Q_{t,i} \geq 0$: quantidade pedida em t, recebida após prazo L ciclos;
- $S_{t,i} = \max(0, D_{t,i} - I_{t,i})$: ruptura no ciclo t;
- h, c_s, c_o^{fix}, c_o^{var}: custos unitários de manutenção, ruptura, ordenação fixa e variável, definidos na Seção 2.1.2.

O CTI usado no *benchmark* corresponde à versão indexada por loja dessa mesma função de custo: o cálculo é repetido para cada série loja-produto e depois agregado por política, permitindo comparar alternativas sob o mesmo ambiente de avaliação. A atualização do estoque segue a mesma dinâmica conceitual, com indexação adicional por loja e série: o operador $\max(0, \cdot)$ preserva o pressuposto de venda perdida, isto é, a demanda que excede o estoque disponível não é acumulada para ciclos futuros, e $Q_{t-L,i}$ representa pedidos emitidos L ciclos antes e recebidos no ciclo corrente.

Essa instanciação permite avaliar todas as políticas sob as mesmas condições de demanda, custo e prazo de reposição. A próxima seção descreve a estrutura da rede varejista considerada nos experimentos.

4.2.3 Rede Varejista

A cadeia de suprimentos modela três escalões hierárquicos:

- Escalão 1 (Armazém Regional): único centro distribuidor; repõe junto ao fornecedor com prazo L ciclos.
- Escalão 2 (Lojas Revendedoras): N unidades varejistas com séries de demanda independentes; cada loja decide individualmente quando e quanto pedir ao armazém (política descentralizada).
- Escalão 3 (Produto): conjunto de produtos do portfólio da rede. No primeiro experimento, um único produto de alta intermitência foi usado para controle experimental; no segundo experimento, o recorte foi ampliado para múltiplos produtos ativos com filtragem por regime de demanda (Syntetos-Boylan).

Essa estrutura influencia diretamente o AIPE: define a unidade de decisão do *framework* (cada série loja-produto é uma instância de recomendação); o prazo de reposição entre armazém e loja entra na dinâmica de estoque e afeta o ponto de pedido das políticas; a agregação dos pedidos das lojas no armazém permite medir estabilidade via *Bullwhip Effect*; e a heterogeneidade entre lojas e produtos gera os perfis operacionais que alimentam a seleção contextual do PSE. A rede varejista não é apenas cenário descritivo: define as instâncias, os parâmetros operacionais, os KPIs e o nível em que o AIPE recomenda políticas.

4.2.4 Métricas de Avaliação

As métricas conceituais foram apresentadas no Capítulo 2. Nesta seção, elas são retomadas apenas para indicar sua função no *pipeline* experimental. Cada política avaliada no ambiente de simulação gera um conjunto de indicadores por série loja-produto ao fim de T ciclos. Esses indicadores são usados em quatro pontos do AIPE: comparação de políticas no *benchmark*,

definição de viabilidade operacional, geração de rótulos de política dominante e análise complementar de estabilidade.

- *CTI* (Custo Total de Inventário): $\sum_t [hI_t + c_s S_t + c_o^{\text{fix}} \mathbf{1}(Q_t > 0) + c_o^{\text{var}} Q_t]$;
- *NS* (Nível de Serviço): $\sum_t \min(I_t, D_t) / \sum_t D_t$;
- *TR* (Taxa de Ruptura): frequência de ciclos com falta de estoque (*stockout*); ao longo do texto, "ruptura" é empregado como equivalente técnico de "falta de estoque";
- *BE* (*Bullwhip Effect*): $\mathrm{Var}(Q)/\mathrm{Var}(D)$, amplificação da variabilidade ao longo da cadeia;
- *FP* (Frequência de Pedidos): fração de ciclos com ao menos um pedido emitido.

No *pipeline* experimental, o CTI é usado como critério principal de custo na comparação entre políticas e na definição de política dominante. O NS atua como restrição de viabilidade: políticas com nível de serviço abaixo do limiar mínimo ($\alpha_{\min} = 0{,}70$) não são consideradas dominantes, mesmo que apresentem baixo custo. A TR é métrica complementar para interpretar a frequência de falhas de atendimento. O BE é usado para avaliar a estabilidade operacional dos pedidos e compõe a análise complementar de custo ajustado por estabilidade, apresentada a seguir. A FP identifica padrões degenerados de decisão, como ausência quase total de pedidos ou emissão excessiva de pedidos. Assim, as métricas não aparecem apenas como indicadores descritivos: elas determinam quais políticas são comparáveis, quais são viáveis e quais geram rótulos para o PSE.

No segundo experimento, esses cinco indicadores são complementados por métricas de previsão (MASE, sMAPE, RMSSE), usadas como sinais auxiliares de caracterização para o PSE, não como critério final de escolha da política: a metodologia não escolhe o melhor modelo de previsão como fim em si mesmo, mas avalia se esses sinais aumentam a capacidade de selecionar políticas de reposição de forma contextual.

Além do CTI original, usado como custo direto de inventário, esta dissertação reporta uma métrica complementar de custo operacional ajustado por estabilidade. Essa métrica combina o CTI normalizado e uma penalidade baseada no BE normalizado, permitindo avaliar se políticas de menor custo direto também preservam estabilidade nos pedidos enviados ao armazém:

$$J(\pi, g) = \mathrm{CTI}_{\text{norm}}(\pi, g) + \lambda_{BE} \cdot \mathrm{BE}_{\text{norm}}(\pi, g) \tag{4.1}$$

em que π é a política, g é o perfil operacional (ou o conjunto global, no caso da política única), $\mathrm{CTI}_{\text{norm}}$ e $\mathrm{BE}_{\text{norm}}$ são o CTI e o BE normalizados por min-max sobre o conjunto de políticas avaliadas, e $\lambda_{BE} \geq 0$ é o peso da penalidade por instabilidade: $\lambda_{BE} = 0$ recupera o custo puro (equivalente a ordenar apenas por CTI); valores de $\lambda_{BE} > 0$ aumentam a penalização de políticas com efeito *bullwhip* elevado. O CTI ajustado não substitui o CTI original; ele é reportado como análise complementar de sensibilidade (Seção 5.3.5), de caráter preliminar,

para apoiar a discussão sobre seleção contextual de políticas considerando custo e estabilidade conjuntamente.

4.3 Camada de Entrada: Dados e Pré-Processamento

Esta seção descreve o conjunto de dados transacional utilizado nos experimentos e os estágios de pré-processamento que transformam os registros brutos em séries prontas para simulação. A descrição também explicita as escolhas de filtragem que delimitam o escopo empírico do estudo piloto e da expansão experimental.

4.3.1 Base de Dados

A base de dados utilizada nesta proposta é composta por registros transacionais de venda de uma rede varejista brasileira, agregados por ciclo comercial. Na metodologia, a base é tratada como entrada do *pipeline* experimental: os registros brutos são agregados em séries loja-produto, organizados em ciclos comerciais e submetidos a critérios mínimos de qualidade antes da simulação (Seção 4.3.2). Por se tratar de uma base proprietária, os dados brutos não são disponibilizados publicamente. A rastreabilidade dos experimentos é preservada por meio dos scripts de pré-processamento, parâmetros de configuração, sementes aleatórias e artefatos derivados gerados pelo *pipeline*.

Detalhes sobre o recorte efetivamente usado em cada experimento, incluindo estados, número de séries, distribuição geográfica e predominância de regimes de demanda, são apresentados no Capítulo 5 (Seções 5.2 e 5.3.1).

Estrutura temporal. A base registra vendas por *ciclo comercial* (17 ciclos por ano, $\approx$21 dias corridos cada). Essa granularidade reflete a política operacional real: pedidos são consolidados e processados por ciclo, justificando o prazo $L = 2$ ciclos ($\approx$42 dias). Um horizonte de 38 ciclos (janeiro/2023 a abril/2025) captura sazonalidade anual completa, múltiplos padrões de intermitência (ciclos com venda zero e picos concentrados) e estabilização de parâmetros de estimação, crucial para validação confiável.

Regimes de demanda. A classificação por regime é aplicada após a agregação das vendas em ciclos comerciais: para cada série loja-produto, calculam-se ADI e CV^2 conforme a taxonomia de Syntetos-Boylan (Seção 2.3.1), usada como característica operacional e apoio à estratificação das análises (a Figura 4.2 integra essa classificação ao fluxo decisório do AIPE), não como resultado em si. A distribuição efetiva dos regimes nos recortes experimentais, incluindo a predominância de séries *Lumpy*, é discutida no Capítulo 5 (Seção 5.6).

4.3.2 Pipeline Experimental

O pré-processamento recebe dados transacionais brutos e entrega séries de demanda estruturadas para simulação. Esse *pipeline* é necessário porque: (i) dados brutos contêm inconsistências, (ii) a granularidade deve refletir decisões operacionais reais, e (iii) as séries precisam ter qualidade suficiente para discriminar entre políticas. As etapas são:

(i) Filtragem: exclusão de registros com revendedora inativa, remoção de transações anômalas (tipo brinde, quantidades negativas) e restrição ao período de análise (janeiro/2023 a abril/2025);

(ii) Limpeza: imputação de ciclos ausentes com demanda zero, garantindo série de comprimento uniforme $T = 38$;

(iii) Agregação: soma de quantidades por (loja, produto, ciclo comercial), transformando registros transacionais em séries de demanda agregadas;

(iv) Seleção de cenários: filtragem automática por critérios de qualidade (coeficiente de variação ≥ 1.5 para capturar intermitência, mínimo de ciclos com demanda positiva, produto ativo nos últimos 3 ciclos), produzindo o conjunto de séries para análise.

Essa sequência elimina inconsistências e produz um conjunto de séries (loja, produto) prontas para engenharia de características e simulação. Com isso, as etapas posteriores operam sobre séries uniformes e comparáveis.

4.4 Caracterização das Séries e Perfis Operacionais

As características operacionais da demanda compõem a representação de entrada utilizada pelo AIPE. Esta etapa recebe cada série loja-produto já tratada e calcula medidas de intermitência, variabilidade, volume, sazonalidade, concentração de picos, dispersão e estabilidade temporal. Em conjunto, essas variáveis descrevem o perfil operacional de cada série e permitem que o PSE aprenda associações entre padrões de demanda e políticas de reposição com melhor desempenho esperado.

O estágio `demand_profiling` (nome do módulo computacional) estende a classificação Syntetos-Boylan (Seção 2.3.1), que usa apenas dois índices (ADI e CV^2), produzindo um vetor de 17 características operacionais por série (mais rico, capturando estrutura temporal, distribuição e comportamento operacional além da intermitência) e agrupando as séries em perfis orientados à decisão de política. Esse vetor permanece como insumo para o mecanismo de seleção contextual, não como uma recomendação final por si só.

4.4.1 Características Operacionais Calculadas

Para cada série loja-produto, as características operacionais são calculadas para transformar o histórico bruto de demanda em uma representação numérica utilizável pelo AIPE. Essas variáveis não são métricas finais de desempenho; elas funcionam como entradas da etapa de caracterização e conectam os dados observados às decisões posteriores de seleção.

No *pipeline*, essas características são usadas para três finalidades. Primeiro, apoiam a atribuição dos Perfis Operacionais de Demanda (POD). Segundo, compõem o vetor de entrada do PSE. Terceiro, permitem estratificar as análises e interpretar por que uma mesma política pode apresentar desempenho distinto em séries diferentes. Para cada série (w,s,i), em que w identifica a loja, s identifica o produto e i indexa a série loja-produto no conjunto experimental, calculam-se 17 características numéricas organizadas em quatro grupos:

Características de intermitência:

- ADI $= T/n^{+}$: intervalo médio entre demandas positivas (Average Demand Interval);
- $\mathrm{CV}^2 = (\sigma/\mu)^2$: variabilidade normalizada das quantidades;
- $r_0 = 1 - n^{+}/T$: proporção de ciclos com demanda zero, em que n^{+} é o número de ciclos com demanda positiva;
- $z_{\max}$, z_{mean}: comprimento máximo e médio das sequências de zeros consecutivos;
- $B = (s_\tau - \bar{\tau})/(s_\tau + \bar{\tau})$: *burstiness* (Goh and Barabási, 2008), onde τ_i são os intervalos entre eventos de demanda, $\bar{\tau}$ é a média desses intervalos e s_τ é seu desvio-padrão; $B \in [-1,1]$, com $B > 0$ indicando clusters de demanda e $B < 0$ indicando demanda regular.

Características de distribuição (sobre valores positivos):

- *Assimetria* e *curtose excedente* dos tamanhos de demanda positivos;
- *Entropia de Shannon*: $H = -\sum_k p_k \log_2 p_k$, calculada sobre histograma de 10 bins, em que p_k é a proporção de observações no bin k; mede a difusividade da distribuição de demanda.

Características de tendência e sazonalidade:

- β_t/μ: coeficiente angular OLS normalizado, em que β_t é a inclinação estimada da série ao longo do tempo e μ é a média da demanda;
- ρ_S: autocorrelação da série no lag sazonal $S = 17$, em que S representa um ano comercial completo.

Características de volume (herdadas de `scenarios_meta`): μ, σ, n_T, n^+, e as métricas de perfil da revendedora (segmento, filial, estrutura), em que n_T representa o número total de ciclos observados. Esse grupo complementa as características de intermitência, variabilidade e sazonalidade com sinais de escala operacional.

O resultado desta etapa é um vetor $\phi(\mathbf{x}_i)$ associado a cada série $\mathbf{x}_i$. Esse vetor resume o comportamento operacional da demanda e alimenta a etapa seguinte, na qual cada série é associada a um POD e, posteriormente, a uma política recomendada pelo PSE.

4.4.2 Perfis Operacionais de Demanda

Com base no vetor de características $\phi(\mathbf{x}_i)$, cada série é associada a um *Perfil Operacional de Demanda* (POD). Os PODs são definidos por regras heurísticas interpretáveis, configuradas no *pipeline* experimental, e têm a função de aproximar características estatísticas da série de situações operacionais reconhecíveis pela gestão de estoque.

Diferentemente da taxonomia ADI $\times$ CV^2, que classifica regimes gerais de demanda, os PODs foram definidos para apoiar a decisão de reposição. Eles agrupam séries que podem exigir políticas semelhantes, mesmo quando pertencem ao mesmo quadrante Syntetos-Boylan. Assim, o POD não substitui a taxonomia Syntetos-Boylan; ele acrescenta uma camada operacional de estratificação usada nesta proposta.

Os critérios da Tabela 4.1 foram definidos como regras heurísticas configuráveis, derivadas de três fontes: os limiares clássicos da taxonomia Syntetos-Boylan para ADI e CV^2, a análise exploratória das características calculadas no recorte experimental e a interpretação operacional dos padrões de demanda observados. Esses limiares não são propostos como uma nova taxonomia universal. Eles funcionam como uma camada de estratificação operacional inicial, versionada no arquivo de configuração do módulo `demand_profiling`, permitindo rastreabilidade e recalibração nos estudos de caso adicionais (Capítulo 7). Na tabela, a coluna “POD” nomeia o perfil operacional; “Característica principal” resume o comportamento dominante da série; “Critério” apresenta a regra usada para atribuir a série ao perfil; e “Política de referência inicial” indica uma associação preliminar usada na etapa metodológica.

As regras são aplicadas de forma hierárquica, na ordem apresentada na Tabela 4.1: primeiro são identificadas séries esparsas de alto impacto, depois padrões sazonais ou explosivos, séries com tendência ou distribuição difusa, séries estáveis de baixo volume e, por fim, séries de demanda frequente. A política de referência inicial associada a cada POD não deve ser interpretada como dominância definitiva. Ela resume uma referência metodológica construída a partir do desempenho observado no recorte experimental segundo CTI e NS, servindo apenas para organizar a análise. A dominância empírica é avaliada no Capítulo 5.

Os PODs funcionam como uma representação operacional intermediária para o PSE. A recomendação não depende apenas do nome do perfil, mas do conjunto de características que descreve a série e permite comparar sua proximidade com séries já avaliadas. O fluxo de uso

Tabela 4.1: Perfis Operacionais de Demanda (POD) e políticas de referência inicial.

POD	Característica principal	Critério	Política de referência inicial
Sparse High Impact	Longos silêncios + picos	ADI ≥ 1.32 e $\text{CV}^2 \geq 0.49$ e $z_{\max} \geq 5$	GA-DQN
High Vol. Seasonal	Sazonalidade ou burstiness	$\rho_S \geq 0.25$ ou $B \geq 0.30$	PPO
Unstable Trend	Tendência ou distribuição difusa	$\lvert\beta_t/\mu\rvert \geq 0.05$ ou $H \geq 2.0$	Vendor-Responsive
Low Vol. Stable	Baixo volume, baixa variação	$\mu \leq 2.0$ e $\text{CV}^2 < 0.49$	Newsvendor
Fast Moving	Demanda frequente	ADI < 1.32	(s,S)

dos PODs pode ser resumido da seguinte forma: cada série $\mathbf{x}_i$ é transformada em um vetor de características $\phi(\mathbf{x}_i)$; esse vetor permite atribuir um perfil p; o perfil e as demais características alimentam o seletor f, que recomenda uma política $\hat{\pi}^*(i)$; por fim, a política recomendada é avaliada por KPIs simulados, como CTI, NS, TR, BE e FP.

Assim, o POD não é o resultado final do AIPE. Ele é uma representação intermediária usada para tornar a seleção de políticas mais interpretável, e a notação abaixo explicita essa sequência:

$$\underbrace{\mathbf{x}_i}_{\text{série}} \xrightarrow{\phi} \underbrace{\phi(\mathbf{x}_i) \in \mathbb{R}^{17}}_{\text{características}} \xrightarrow{\text{POD}} \underbrace{p \in \{1,\ldots,5\}}_{\text{perfil}} \xrightarrow{f} \underbrace{\hat{\pi}^*(i) \in \Pi}_{\text{política}} \xrightarrow{\text{sim}} \underbrace{(\text{CTI, NS, TR, BE, FP})}_{\text{KPIs esperados}}$$

A generalização para séries não vistas é avaliada por validação cruzada estratificada. Essa avaliação verifica se o seletor treinado sobre séries já rotuladas mantém desempenho preditivo quando aplicado a perfis não usados diretamente no ajuste.

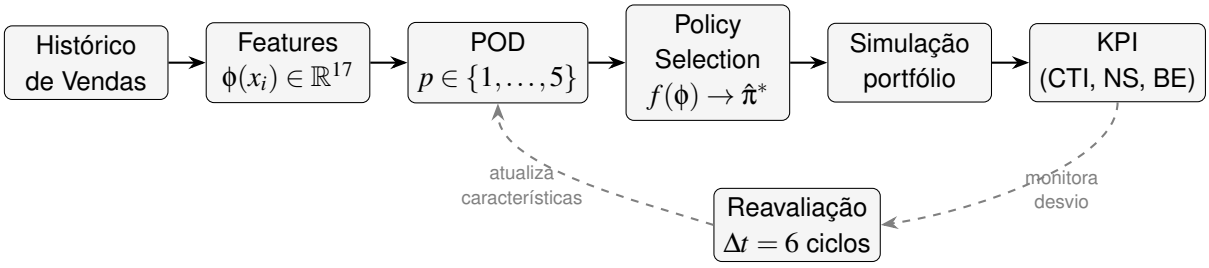


Figura 4.2: Fluxo decisório do AIPE. O histórico preparado, as características operacionais e o POD formam a entrada usada pelo PSE para recomendar uma política; o ciclo de reavaliação periódica a cada $\Delta t = 6$ ciclos (tracejado) recalcula as características e o POD conforme novos dados se acumulam, sem re-treinar o meta-modelo.

4.5 Sinais de Previsão como Entrada Auxiliar

A previsão de demanda é usada nesta dissertação como fonte de sinais auxiliares para caracterizar o comportamento esperado das séries. Ela não substitui a etapa de seleção de políticas e não define, isoladamente, qual regra de reposição deve ser adotada. Os modelos de previsão produzem indicadores de erro e sinais de comportamento futuro que são incorporados à camada de entrada e ao treinamento do PSE.

Quatro modelos (Croston, ARIMA/SARIMAX, XGBoost e LSTM) são treinados por série e selecionados por validação *walk-forward* com métrica MASE (Croston, 1972). A janela mínima de treinamento é $T_{\min} = 12$ ciclos; cada passo avança um ciclo, produzindo 20 a 26 pontos de teste. O protocolo reduz viés *in-sample* e mantém as previsões alinhadas à ordem temporal dos dados. O modelo com menor MASE é selecionado como *forecaster* oficial da série e suas métricas de acurácia (MASE, sMAPE, RMSSE) são incorporadas como sinais auxiliares de entrada.

Dessa forma, a previsão atua como componente informativo do AIPE. A decisão central permanece sendo a seleção contextual da política de reposição, avaliada por métricas de custo, serviço e estabilidade no ambiente de simulação.

Os parâmetros de referência para as políticas (I_0, Q_{ref}, s_{ref}) são calculados a partir das estatísticas locais $\hat{\mu}$ e $\hat{\sigma}$ de cada série por calibração adaptativa:

$$I_0 = \max\big(100,\ 2\hat{\mu}L\big), \tag{4.2}$$

$$Q_{\text{ref}} = \sqrt{2\hat{\mu}T\, c_o^{\text{fix}}/h}, \tag{4.3}$$

$$s_{\text{ref}} = \hat{\mu}L + z\hat{\sigma}\sqrt{L}, \tag{4.4}$$

com $z = 1.28$, quantil normal associado ao nível de serviço de referência de 90%. Esse parâmetro é usado apenas para dimensionar valores de referência, como s_{ref}, e para estabelecer limites comparáveis de ação entre políticas. Nas Equações 4.2 a 4.4, I_0 é o estoque inicial usado na simulação, Q_{ref} é o lote de referência derivado da lógica EOQ, s_{ref} é o ponto de reposição de referência, $\hat{\mu}$ e $\hat{\sigma}$ são a média e o desvio-padrão estimados na janela histórica disponível, T é o horizonte experimental, L é o prazo de entrega, c_o^{fix} é o custo fixo por pedido e h é o custo de manutenção. Essa parametrização estabelece uma escala operacional comum para o *benchmark*, sem determinar antecipadamente a política vencedora.

Esses valores de referência não substituem a avaliação por simulação. Eles inicializam políticas, dimensionam espaços de busca e definem limites de ação proporcionais ao volume e à variabilidade de cada série, mantendo comparabilidade entre lojas com volumes heterogêneos (razão de até 124 vezes entre a maior e a menor loja no estudo piloto). No segundo experimento, $\hat{\mu}$ e $\hat{\sigma}$ são atualizados a cada ciclo com a janela deslizante, implementando calibração *online*.

4.6 Portfólio de Políticas Candidatas

Esta seção descreve o portfólio de políticas candidatas, organizado em cinco famílias: políticas clássicas de referência, políticas clássicas em versão estado da arte, políticas de referência do artigo-base, políticas parametrizadas por meta-heurísticas e políticas aprendidas por reforço, incluindo as arquiteturas híbridas GA-RL.

O portfólio evoluiu ao longo do trabalho: a etapa de proposta avaliou um conjunto inicial de **doze** políticas (EOQ, (s,S), Jornaleiro, GA, SA, PSO, DE, DQN, PPO, SARSA, GA-DQN, GA-PPO), e uma revisão sistemática do estado da arte por família (Seção 4.6.5, consolidada em `docs/references/estado_da_arte_politicas.md`) motivou a inclusão de quatro políticas com ancoragem bibliográfica mais recente ou mais robusta (*capped base-stock*, Jornaleiro orientado a características, *Fixed Interval Replenishment* e *Vendor-Responsive*) e a exclusão de outras quatro sem estado da arte identificável em veículo relevante de Pesquisa Operacional ou Gestão de Operações: PSO, DE e SARSA compartilham a classificação "sem SOTA em veículo relevante" (SARSA, em particular, é "lacuna real": nenhum trabalho em veículo relevante aplica SARSA a inventário) e GA-PPO não tem nenhuma referência publicada como âncora. PSO e DE, além disso, otimizam o mesmo espaço de parametrização $\boldsymbol{\theta} = (s, Q)$ que o GA sob a mesma função objetivo (Equação 4.5), tornando-os redundantes com GA e SA para o argumento de heterogeneidade regime$\rightarrow$política que sustenta o AIPE. As quatro políticas excluídas permanecem implementadas no código-fonte do *pipeline*, apenas desativadas na configuração de produção, e podem ser reativadas para ablações futuras.

O portfólio final desta dissertação tem, portanto, **doze** políticas: EOQ, (s,S), Jornaleiro, *capped base-stock*, Jornaleiro orientado a características, *Fixed Interval Replenishment*, *Vendor-Responsive*, GA, SA, DQN, PPO e GA-DQN. Nesta dissertação, "política" designa a regra que transforma um estado de inventário em uma decisão de reposição; GA e SA são métodos de busca usados para parametrizar essa regra, não políticas autônomas no sentido decisório. Todas as alternativas são avaliadas no mesmo ambiente de simulação com as mesmas séries de demanda real, garantindo comparação controlada.

4.6.1 Políticas Clássicas

As políticas clássicas são regras analíticas ou semianalíticas de reposição. Elas definem diretamente quando pedir e quanto pedir a partir de parâmetros estimados da série, como demanda média, variabilidade e prazo de entrega. As representações visuais complementares dessas políticas, incluindo a política (s,S), foram deslocadas para o Apêndice B, preservando no corpo do capítulo apenas sua formulação operacional.

EOQ. Na implementação experimental (conceito apresentado na Seção 2.2.1), a política utiliza o lote de referência Q_{ref} (Equação 4.3), calculado a partir da demanda média estimada na janela histórica ($\hat{\mu}$), do horizonte de referência (T) e dos custos configurados no ambiente

de simulação (c_o^{fix} instancia o parâmetro conceitual K e h o custo de manutenção) e o ponto de pedido correspondente s_{ref} (Equação 4.4), que adiciona um estoque de segurança $z\hat{\sigma}\sqrt{L}$ à demanda média esperada durante o prazo de entrega ($\hat{\mu}L$). Assim, o EOQ entra no *benchmark* como linha de base clássica de lote econômico, recalculada segundo a janela temporal disponível; seu pressuposto de demanda constante permanece estruturalmente violado em regimes intermitentes, motivo pelo qual seu desempenho é avaliado empiricamente contra políticas adaptativas.

(s,S). Pedido de magnitude $S - I_t$ sempre que $I_t \leq s$, em que I_t é a posição de estoque no ciclo t, $s = s_{\text{ref}}$ é o ponto de pedido e $S = s + Q_{\text{ref}}$ é o nível-alvo, ambos definidos a partir da calibração da EOQ (Equações 4.3 e 4.4). Política de referência amplamente usada no varejo regional brasileiro.

Jornaleiro. $Q^* = \hat{\mu} + z\hat{\sigma}$, com $z = 1.28$, em que $\hat{\mu}$ e $\hat{\sigma}$ são a média e o desvio-padrão estimados da demanda. Determina o pedido ótimo de período único como quantil da distribuição de demanda. Representações visuais complementares do EOQ e do Jornaleiro são apresentadas no Apêndice B.

4.6.2 Políticas Parametrizadas por Meta-Heurísticas

As meta-heurísticas avaliadas nesta dissertação são usadas para parametrizar políticas de reposição. Elas não são políticas autônomas: em cada execução, uma solução candidata representa uma parametrização da regra de pedido definida no espaço de decisão da Seção 2.1.1. No caso implementado, essa parametrização é dada por $\boldsymbol{\theta} = (s, Q)$, em que s é o ponto de reposição e Q é a quantidade solicitada quando o pedido é acionado.

A política induzida por $\boldsymbol{\theta}$ emite um pedido de tamanho Q quando a posição de estoque atinge o limiar s, respeitando os limites operacionais definidos para a série. Cada solução candidata é avaliada no ambiente de simulação: a série é percorrida ciclo a ciclo, os pedidos são aplicados, o estoque é atualizado e os KPIs finais são calculados. Assim, o algoritmo de busca modifica parâmetros; quem mede o desempenho da política parametrizada é o mesmo simulador usado no restante do *benchmark*.

A função objetivo é definida antes da aplicação dos algoritmos de busca. Para uma série i, a meta-heurística procura:

$$\boldsymbol{\theta}_i^* = \arg\min_{\boldsymbol{\theta} \in \Theta_i} \text{CTI}(\pi_{\boldsymbol{\theta}}, i) \quad \text{sujeito a } \text{NS}(\pi_{\boldsymbol{\theta}}, i) \geq \alpha_{\min}, \tag{4.5}$$

em que $\boldsymbol{\theta}$ é o vetor de parâmetros da política, Θ_i é o espaço viável de busca da série i, $\pi_{\boldsymbol{\theta}}$ é a política induzida pelo par (s, Q), CTI é o custo obtido nesse ambiente, NS é o nível de serviço usado como restrição e $\alpha_{\min} = 0{,}70$ é o limiar mínimo de serviço adotado na seleção contextual. Soluções de baixo custo que violam esse limiar de NS não são interpretadas como políticas dominantes, pois representam economia obtida à custa de ruptura excessiva. Quando

o algoritmo requer uma função escalar de aptidão, a restrição de serviço é implementada por penalização de candidatos inviáveis ou por descarte no momento de geração do rótulo. Assim, GA e SA diferem no mecanismo de busca, mas compartilham a mesma representação, o mesmo ambiente de avaliação e os mesmos critérios de viabilidade operacional.

A otimização é realizada no horizonte experimental disponível para cada série, portanto a solução encontrada é a melhor parametrização no recorte temporal avaliado (adequada ao *benchmark* controlado), não uma política ótima universal; em aplicação operacional contínua, a parametrização deveria ser reavaliada em janelas móveis $[i, i+T]$ conforme novos ciclos são observados, extensão prevista no Capítulo 7.

GA. No Algoritmo Genético, cada indivíduo codifica uma parametrização candidata da política de reposição. No caso base, o cromossomo contém os genes s e Q. A população inicial é amostrada dentro dos limites operacionais de cada série, formando um conjunto de regras candidatas. Cada indivíduo é avaliado no ambiente de simulação, e sua aptidão deriva do CTI sob o critério mínimo de NS. A seleção por torneio ($k = 3$) prioriza indivíduos com melhor avaliação; o cruzamento é uniforme ($p_c = 0.8$), em que cada gene do filho herda do pai A ou do pai B com probabilidade $0{,}5$ (recombinação discreta gene a gene); e a mutação é adaptativa: a taxa decai linearmente de $0{,}05$ na primeira geração até $0{,}05 \times 0{,}2$ na última, preservando os limites viáveis. Essa combinação (seleção por torneio, cruzamento uniforme, mutação adaptativa) segue a descrição do artigo-base (Zabraoui et al., 2025); a fórmula exata de decaimento da mutação não é especificada naquele trabalho e constitui leitura adotada nesta dissertação. Ao final das 50 gerações com 100 indivíduos, a melhor parametrização viável encontrada é usada como a política parametrizada por GA. A representação visual do cromossomo foi deslocada para o Apêndice B.

SA. No *Simulated Annealing*, a solução atual também é uma parametrização da política, representada por $\boldsymbol{\theta} = (s, Q)$. A busca local é realizada por vizinhança: em cada iteração, um vizinho é gerado por pequena perturbação em s, em Q ou em ambos, mantendo os valores dentro dos limites operacionais. Se o vizinho reduz o custo simulado, ele é aceito. Se aumenta o custo, pode ser aceito com probabilidade $\exp(-\Delta C / T_k)$, em que ΔC é a diferença de custo e T_k é a temperatura na iteração k. Essa aceitação probabilística permite escapar de ótimos locais no início da busca; com o resfriamento geométrico ($T_0 = 1000$, $\alpha = 0.95$), o algoritmo se torna progressivamente mais seletivo. A saída é a melhor parametrização viável visitada.

PSO e DE. Particle Swarm Optimization e Evolução Diferencial foram testados preliminarmente sobre o mesmo espaço de parametrização $\boldsymbol{\theta} = (s, Q)$ do GA e do SA, com 40 partículas/80 iterações e variante *rand/1/bin* ($F = 0{,}8$, $C_R = 0{,}9$), respectivamente. Sem estado da arte próprio em veículo relevante que os distinguisse do GA (Seção 4.6.5) e otimizando o mesmo espaço de busca, não compõem o portfólio final desta dissertação, embora permaneçam implementados e disponíveis para ablações futuras (Seção 4.6.6).

4.6.3 Políticas Aprendidas por Reforço

As políticas aprendidas por reforço modelam a reposição como um Processo de Decisão de Markov. Em cada ciclo, o agente observa o estado do inventário, escolhe uma ação de reposição, recebe uma recompensa associada ao custo operacional e passa para o próximo estado após a realização da demanda e a chegada de pedidos em trânsito. Assim, DQN e PPO não são apenas algoritmos abstratos de aprendizado: nesta dissertação, cada um deles aprende uma política de reposição por interação com o simulador. São os dois agentes de RL do artigo-base (Zabraoui et al., 2025), mantidos no portfólio final para preservar essa correspondência direta, relevante sobretudo para o Estudo de Caso 3 (M5, Capítulo 7), benchmarcado contra o mesmo artigo.

O vetor de estado contém seis componentes normalizados: nível de estoque atual, demanda esperada, pedidos em trânsito, média móvel e desvio padrão dos últimos seis ciclos, e progresso do horizonte. A ação corresponde à quantidade pedida ou a uma escolha discreta de nível de pedido, dependendo do agente. A recompensa é o negativo do custo incorrido no ciclo, de modo que maximizar retorno equivale a reduzir custo de manutenção, ruptura e emissão de pedidos, respeitando a dinâmica operacional do ambiente.

DQN. Arquitetura *Double DQN* (van Hasselt et al., 2016) com cabeça *dueling* (Wang et al., 2016), 2 camadas $\times$ 64 ReLU; *experience replay* (10.000 transições), *target network*; 1.000 episódios, $\varepsilon = 0{,}2$ fixo (sem decaimento). O parâmetro ε controla a probabilidade de exploração aleatória; o piso de 1.000 episódios e o ε fixo seguem os valores reportados no artigo-base (Zabraoui et al., 2025). Nos resultados da Bahia (Capítulo 5), o DQN manteve nível de serviço consistentemente baixo mesmo após uma correção de penalidade de déficit de NS que resolveu o mesmo padrão em PPO e nas políticas SOTA clássicas; a hipótese investigada é uma limitação de atribuição de crédito do *bootstrap* de 1 passo do Q-*learning* sob recompensa esparsa em séries de baixo volume, não corrigida por essa penalidade sozinha (discutida como achado, não ocultada, na análise de resultados).

Uma representação visual complementar do DQN foi deslocada para o Apêndice B, junto da representação do PPO.

PPO. Estimação generalizada de vantagem (Schulman et al., 2016); 1.000 episódios; $\varepsilon_{\text{clip}} = 0.2$; ações contínuas. O parâmetro $\varepsilon_{\text{clip}}$ limita a variação da política entre atualizações sucessivas; o piso de 1.000 episódios segue o mesmo critério do DQN no artigo-base. Ao contrário do DQN, o PPO respondeu bem à correção da penalidade de déficit de NS, recuperando nível de serviço alto, diferença atribuída ao uso de retorno multi-passo (GAE) em vez de *bootstrap* de 1 passo, que propaga a correção a toda a trajetória numa única atualização.

4.6.4 Políticas Híbridas GA-RL

A arquitetura GA-RL, formalizada na Seção 2.2.4, resolve a tensão entre convergência do RL e horizontes históricos curtos via inicialização em três etapas. Os parâmetros fixados nesta dissertação são: GA com 50 gerações $\times$ 100 indivíduos (5.000 avaliações simuladas), *replay buffer* pré-populado com 1.000 transições de alta qualidade, e 200 episódios de refinamento RL. No portfólio final, essa arquitetura é representada por GA-DQN, a combinação que o artigo-base (Zabraoui et al., 2025) propõe e avalia diretamente, e por isso a mais direta a comparar contra ele nos Estudos de Caso 3 e 4 (Capítulo 7). A variante GA-PPO, testada preliminarmente com a mesma sequência aplicada ao agente PPO contínuo, não tem referência publicada própria como âncora e foi excluída do portfólio final (Seção 4.6.5).

A política GA-DQN é tratada como especialista do portfólio avaliado, e não como a contribuição central do trabalho, que permanece concentrada na seleção contextual realizada pelo AIPE. Uma representação visual complementar dessa política híbrida é apresentada no Apêndice B.

4.6.5 Portfólio Ampliado e Critério de Seleção das Políticas

A composição do portfólio seguiu o critério de adotar, para cada família, a referência publicada mais recente em veículo relevante de Pesquisa Operacional ou Gestão de Operações. O levantamento identificou que esse critério é aplicável a apenas parte das famílias.

Para o *slot* da política (s, S), a referência mais recente é a política *Projected Inventory Level* (PIL) de van Jaarsveld and Arts (2024), que emite pedidos de modo que o estoque esperado no instante da chegada atinja um alvo fixo, com otimalidade assintótica demonstrada em dois regimes sob venda perdida. Incorpora-se também a política *capped base-stock* de Xin (2021), não por ser a mais recente, mas porque a literatura de aprendizado por reforço a utiliza como referência que agentes profundos não superam de forma consistente em ambientes de venda perdida (Temizöz et al., 2025). Sua ausência tornaria a comparação com os agentes de RL favorável por construção. Para o *slot* do Jornaleiro, adota-se o estimador orientado a características de Ban and Rudin (2019), que substitui a estimação da distribuição de demanda pela otimização direta da decisão.

Para as famílias sem estado da arte identificável em veículo relevante, adota-se a formulação do artigo-base (Zabraoui et al., 2025). Isso acrescenta ao portfólio as heurísticas de referência definidas naquele trabalho: *Min-Max*, *Fixed Interval Replenishment* e *Vendor-Responsive*. Registra-se que o artigo-base não avalia Jornaleiro, SA, PSO, DE nem SARSA, e que EOQ nele figura apenas na revisão de literatura; para essas políticas, mantêm-se as formulações canônicas já descritas.

Nos agentes de aprendizado por reforço, as implementações foram atualizadas para as versões consolidadas na literatura: *Double DQN* (van Hasselt et al., 2016) com arquitetura *dueling* (Wang et al., 2016) e PPO com estimação generalizada de vantagem (Schulman et al.,

2016).

4.6.6 Redundância entre Políticas e Implicação para os Rótulos

A ampliação do portfólio exige verificar se as políticas adicionais acrescentam informação discriminativa ou apenas replicam alternativas existentes. Essa verificação não é estética: o PSE aprende a partir de rótulos de política dominante, e quando duas políticas produzem CTI praticamente idêntico, o rótulo atribuído à série passa a refletir ruído numérico em vez de vantagem operacional, degradando a aprendibilidade postulada pela Hipótese 2.

A análise de redundância adotada compara, para cada par de políticas, a correlação de Spearman entre os CTI obtidos nas mesmas séries e a diferença mediana relativa de custo. Pares com correlação superior a $0{,}98$ e diferença mediana inferior a 5% são tratados como redundantes para efeito de rotulagem, sendo agrupados em uma única classe no conjunto de rótulos do PSE, ainda que permaneçam reportados individualmente nas tabelas comparativas do *benchmark*. Os resultados dessa verificação são apresentados no Capítulo 5.

4.7 Ambiente de Simulação e Benchmark de Políticas

O ambiente de simulação (não uma política de reposição, mas o simulador comum que permite comparar todas as políticas sob as mesmas condições) recebe, para cada série loja-produto, a demanda observada por ciclo, o estoque inicial, o prazo de reposição, os custos operacionais e a política a ser avaliada. Em cada ciclo, a política observa o estado disponível, decide se emite pedido e em qual quantidade, e o ambiente atualiza estoque, demanda atendida, ruptura, pedidos em trânsito e custos acumulados, produzindo ao final do horizonte os indicadores CTI, NS, TR, BE e FP usados no *benchmark* e na geração de rótulos de política dominante para o PSE. Essa padronização permite atribuir diferenças de desempenho às decisões das políticas (clássicas, parametrizadas por meta-heurísticas, aprendidas por reforço ou híbridas), não a mudanças no ambiente de avaliação.

4.7.1 Ambiente de Simulação

O ambiente de simulação avalia a reposição em horizonte discreto para cada série loja-produto. A descrição a seguir organiza o procedimento em entradas, processo de simulação e saídas. A implementação computacional do ambiente, bibliotecas e artefatos reprodutíveis são descritos no Apêndice A.

Entradas. Cada simulação recebe a série de demanda por ciclo, o estoque inicial, o prazo de entrega L, os custos de manutenção, ruptura, pedido fixo e pedido variável, a política candidata

e seus parâmetros. Para políticas clássicas e políticas parametrizadas por meta-heurísticas, esses parâmetros incluem limiares e lotes de pedido, como s, S e Q. Para agentes de aprendizado por reforço, a entrada inclui o estado observado pelo agente e a ação retornada a cada passo de decisão.

Processo de simulação. A cada ciclo t, a política recebe o estado disponível e retorna uma ação de reposição. O ambiente registra o pedido, atualiza a chegada de pedidos emitidos em ciclos anteriores após o prazo L, observa a demanda real do ciclo e calcula quanto foi atendido e quanto virou ruptura. Em seguida, atualiza o estoque, acumula custos, registra pedidos em trânsito e avança para o próximo ciclo. Essa sequência é repetida até o final do horizonte experimental.

Saídas. Ao final da simulação, são produzidas a trajetória de estoque, os pedidos emitidos, a demanda atendida, as rupturas e os KPIs agregados CTI, NS, TR, BE e FP. Para agentes de aprendizado por reforço, também é produzida a recompensa de ciclo, definida a partir do custo operacional. A mesma série de demanda, a mesma semente experimental e os mesmos parâmetros de custo são mantidos entre políticas para viabilizar comparação controlada.

- Dinâmica de estoque conforme Seção 2.1.2;
- Prazo de entrega fixo $L = 2$ ciclos nos dois experimentos executados;
- Estrutura de interação sequencial comum, permitindo que agentes de aprendizado por reforço sejam avaliados sob a mesma dinâmica operacional;
- Uso de *common random numbers* quando há aleatoriedade na política ou no treinamento.

Custos de simulação. Os parâmetros de custo são uniformes: $h = 1.0$, $c_s = 5.0$, $c_o^{\text{fix}} = 50.0$ e $c_o^{\text{var}} = 0.5$, compondo, junto do prazo de entrega $L = 2$ ciclos e das regras de falta de estoque, a camada de parâmetros operacionais da arquitetura do AIPE. A penalidade de ruptura ($c_s = 5h$) reflete o custo de capital perdido e venda não realizada típico do varejo regional.

4.8 Validação Temporal e Estatística

A validação cruzada clássica (*k-fold*) viola a ordem temporal das séries e introduz vazamento de informação futura no treinamento. Para séries temporais, o protocolo adotado é a validação por janela deslizante (*walk-forward* ou *rolling-origin*), que simula o processo de tomada de decisão *online*: modelos são ajustados exclusivamente em dados passados e avaliados em dados futuros, de forma sequencial. Este protocolo é usado tanto na avaliação dos modelos de previsão quanto na geração dos rótulos de treinamento do PSE. A validação estatística, por sua vez,

avalia se as diferenças observadas entre políticas são consistentes no recorte experimental e compatíveis com efeitos não atribuíveis apenas à variação amostral.

4.8.1 Protocolo Walk-Forward

Seja $\mathbf{x} = (x_1, x_2, \ldots, x_T)$ uma série temporal de comprimento T e $T_{\min}$ a janela mínima de treinamento. As divisões *walk-forward* são definidas de modo que cada avaliação use apenas informação histórica disponível até o ciclo anterior. O particionamento temporal é:

$$\mathcal{S}_t = \Big(\underbrace{(x_1, \ldots, x_t)}_{\text{treino}}, \underbrace{x_{t+1}}_{\text{teste}}\Big), \quad t = T_{\min}, T_{\min}+1, \ldots, T-1 \tag{4.6}$$

em que cada divisão $\mathcal{S}_t$ usa a janela histórica crescente para ajustar o modelo e o ponto imediatamente seguinte como alvo de avaliação. O índice t indica o último ciclo disponível para treinamento naquela divisão, e $T_{\min}$ define o menor histórico aceitável antes da primeira previsão. O modelo é re-ajustado a cada passo t, garantindo que nenhuma informação futura vaze para o treinamento. A Figura 4.3 ilustra o protocolo.

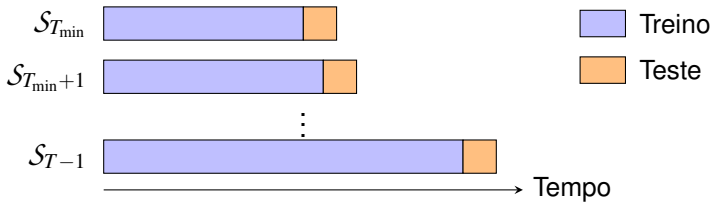


Figura 4.3: Protocolo *walk-forward*: a janela de treinamento cresce incrementalmente e o modelo é avaliado apenas em dados futuros, eliminando viés *in-sample*.

Aplicação temporal do protocolo. Nesta dissertação, o protocolo é parametrizado com $T_{\min} = 12$ ciclos de reposição, resultando em $T - T_{\min} = 26$ pontos de avaliação por série (horizonte total $T = 38$ ciclos). Os modelos de previsão (LSTM, XGBoost, ANN, Croston) são avaliados pelas métricas MASE, sMAPE e RMSSE computadas sobre esses 26 pontos de teste, e o mesmo protocolo é aplicado à simulação das políticas de controle de inventário, cada uma executada nos 26 ciclos de avaliação com parâmetros calibrados exclusivamente na janela de treinamento. Essa validação produz estimativas de generalização temporal não viesadas, essenciais porque as métricas de previsão por série (MASE, sMAPE) alimentam o vetor de entrada do PSE: avaliações apenas *in-sample* tenderiam a inflar artificialmente a acurácia e a distorcer os rótulos de treinamento do meta-modelo.

4.8.2 Validação Estatística das Políticas

A estrutura inferencial descrita na Seção 2.5 é implementada em quatro etapas:

(i) Wilcoxon pareado: testa se a mediana das diferenças entre a política híbrida proposta (GA-DQN) e cada *baseline* é diferente de zero, para cada KPI e cada quadrante Syntetos-Boylan;

(ii) Friedman + Nemenyi: testa simultaneamente se alguma política se distingue das demais e identifica grupos homogêneos via diferença crítica;

(iii) Cohen's d: quantifica a magnitude prática das diferenças para pares (proposta, *baseline*) em cada KPI;

(iv) Análise estratificada: repete os testes por quadrante (Smooth / Erratic / Intermittent / Lumpy) e por estado geográfico, identificando condições sob as quais a arquitetura híbrida apresenta melhor desempenho relativo.

Todos os testes são realizados ao nível de significância $\alpha = 0.05$, com correção para comparações múltiplas quando aplicável. Esse protocolo reduz o risco de interpretações baseadas em diferenças ocasionais entre políticas.

4.9 Geração de Rótulos e Treinamento do PSE

Depois que as políticas são avaliadas no ambiente de simulação, o próximo passo é transformar esses resultados em exemplos de treinamento para o PSE.

4.9.1 Base Conceitual

O PSE é treinado como um classificador supervisionado: a entrada é o vetor de características da série, a saída é a política recomendada, e o rótulo de treinamento vem do *benchmark* simulado: a política viável de menor CTI entre as que atingem o NS mínimo. Essa formulação se aproxima do problema de seleção de algoritmos, pois o objetivo é escolher, para cada instância, a alternativa com melhor desempenho esperado.

A hipótese operacional é simples: séries com padrões diferentes tendem a favorecer políticas diferentes. O vetor de entrada reúne intermitência (ADI), variabilidade (CV^2), concentração (*burstiness* B), difusividade (entropia H), tendência (β_t/μ) e sazonalidade (ρ_S). Esses sinais permitem distinguir, por exemplo, séries com longos períodos sem venda, séries com picos concentrados e séries com comportamento mais regular. O PSE usa esses sinais para estimar qual política do portfólio tende a produzir melhor compromisso entre custo e serviço.

A saída do PSE é uma recomendação de política acompanhada de medidas de confiança. Essa confiança não elimina a necessidade de revisão operacional; ela indica quão concentrada foi a preferência do classificador entre as políticas candidatas e ajuda a identificar casos em que a recomendação deve ser tratada com cautela.

Fundamentos teóricos. A formulação adota três referências principais:

(a) Problema de Seleção de Algoritmos, formalizado por Rice (1976): dado x e um portfólio $\mathcal{A}$, escolher a alternativa com melhor desempenho. Aqui, x é o vetor $\phi(\mathbf{x}_i)$, $\mathcal{A}$ é o portfólio de políticas candidatas e o desempenho é medido por CTI, respeitando NS $\geq \alpha_{\min}$.

(b) Teorema *No Free Lunch*, proposto por Wolpert and Macready (1997): nenhum método domina todos os tipos de instância. Na dissertação, isso justifica usar características operacionais para distinguir quando uma política tende a ser mais adequada que outra.

(c) Portfólios de algoritmos, discutidos por Huberman et al. (1997): alternativas diferentes podem funcionar melhor em regiões distintas do espaço de instâncias. O PSE usa o portfólio avaliado no *benchmark* em vez de assumir uma política única para todas as séries.

A Figura 4.4 mostra essa estrutura no AIPE: as séries loja-produto são as instâncias, as características operacionais descrevem essas instâncias, as políticas formam o portfólio de alternativas e o desempenho simulado fornece os rótulos usados no treinamento.

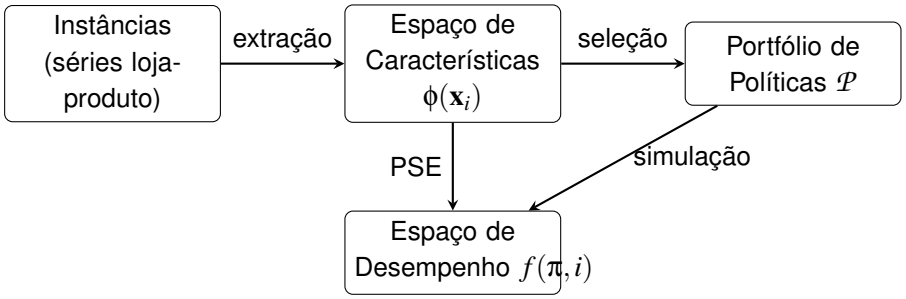


Figura 4.4: Framework ASP de Rice (1976) instanciado no AIPE: as séries loja-produto constituem as instâncias representadas por características operacionais, as políticas candidatas são avaliadas por simulação e o PSE aprende a recomendar a política viável de menor custo esperado para cada perfil de demanda, respeitando o limiar mínimo de nível de serviço.

Seleção ciente de risco. Além do critério de menor CTI esperado, a confiança da recomendação funciona como alerta operacional. Recomendações com confiança abaixo de 0.50 são marcadas como incertas, indicando que nenhuma política apresentou vantagem clara para aquela série no padrão aprendido pelo classificador. Esses casos exigem revisão do gestor ou nova simulação antes de adoção direta.

4.9.2 Problema de Seleção

O problema supervisionado tem entrada, saída e rótulo bem definidos. A entrada é o vetor de características $\mathbf{x}_i \in \mathbb{R}^{17}$ de uma série i. A saída é uma política do conjunto $\mathcal{P}$, composto pelas políticas do portfólio final (Seção 4.6) após o agrupamento de classes redundantes descrito na

Seção 4.6.6: $\mathcal{P} = \{$EOQ, (s,S), Jornaleiro, *capped base-stock*, Jornaleiro orientado a características, *Fixed Interval Replenishment*, *Vendor-Responsive*, GA, SA, DQN, PPO, GA-DQN$\}$. O rótulo é obtido do *benchmark*: a política com menor CTI entre aquelas que atingem o NS mínimo.

Formalmente, o *Policy Selection Engine* estima:

$$\hat{\pi}^*(i) = \arg\min_{\pi \in \mathcal{P}} \mathbb{E}[\text{CTI}(\pi, i)] \quad \text{sujeito a } \mathbb{E}[\text{NS}(\pi, i)] \geq \alpha_{\text{min}}, \tag{4.7}$$

com $\alpha_{\text{min}} = 0.70$ (configurável). Assim, a política dominante de uma série é a política viável de menor CTI sob NS mínimo. Quando nenhuma política atinge o NS mínimo, a série é registrada como caso limite e pode receber a política de maior NS apenas como fallback analítico, não como evidência de dominância operacional. Na Equação 4.7, $\hat{\pi}^*(i)$ é a política recomendada para a série i, $\mathcal{P}$ é o portfólio de políticas candidatas, CTI(π, i) é o custo total de inventário da política π na série i, NS(π, i) é o nível de serviço correspondente e $\mathbb{E}[\cdot]$ indica a média esperada sobre replicações experimentais ou fontes de aleatoriedade do simulador.

4.9.3 Rótulos de Política Dominante

Para cada série loja-produto, o rótulo supervisionado é obtido a partir do *benchmark* simulado: cada política candidata é avaliada no mesmo ambiente de simulação, com as mesmas séries de demanda e os mesmos parâmetros operacionais, e são calculadas as métricas CTI, NS, TR, BE e FP ao fim do horizonte de T ciclos. Além do limiar mínimo de NS já formalizado na Equação 4.7, também são descartados para fins de rótulo comportamentos degenerados, como ausência sistemática de pedidos ou pedido excessivo incompatível com a operação. O rótulo resultante é atribuído à série e, junto com seu vetor de características operacionais, compõe o *dataset* de treinamento supervisionado do PSE.

Esse procedimento transforma a comparação empírica entre políticas em um problema supervisionado de classificação, no qual as características operacionais da série são as entradas e a política dominante é a classe-alvo. O rótulo resume o melhor resultado observado no *benchmark* para aquela série; ele não deve ser lido como recomendação definitiva nem aplicado sem reavaliação.

Formalmente, os rótulos $\hat{\pi}^*(i)$ são gerados a partir dos KPIs do *benchmark* (Seção 4.6): para cada série, agregam-se os KPIs por política (média sobre $n_{\text{rep}} = 5$ replicações) e aplica-se o critério da Equação 4.7. Isso produz o *dataset* de treinamento $\{(\mathbf{x}_i, \hat{\pi}_i^*)\}_{i=1}^{N}$, em que $\mathbf{x}_i$ é o vetor de características da série i, $\hat{\pi}_i^*$ é seu rótulo de política dominante e N é o número de séries rotuladas.

4.9.4 Treinamento do PSE

O treinamento do PSE usa o conjunto de pares $(\mathbf{x}_i, \hat{\pi}_i^*)$ produzido na etapa anterior. No estágio atual da dissertação, o classificador principal é um XGBoost (Chen and Guestrin, 2016) multiclasse com hiperparâmetros: $n_{\text{est}} = 300$, depth $= 6$, $\eta = 0.05$, *subsample* $= 0.8$, representando, respectivamente, número de estimadores, profundidade máxima, taxa de aprendizado e fração amostrada de observações por árvore. LightGBM (Ke et al., 2017) e RandomForest permanecem como alternativas configuráveis.

A avaliação segue validação cruzada estratificada ($k = 5$ folds), mantendo a proporção de rótulos por fold. As métricas primárias são:

- *Acurácia balanceada* (por conta do desbalanceamento natural de rótulos);
- *F1-macro* (trata todas as políticas igualmente);
- *F1-weighted* (pondera pelo suporte de cada política).

A interpretabilidade do modelo é analisada por importância de características (ganho médio de informação), identificando quais características operacionais são mais discriminativas para a seleção de política. Os estudos de caso adicionais (M5 e expansão multiestado, Capítulo 7) deverão ampliar o número de séries e regimes de demanda, permitindo revalidar o classificador em escala maior e avaliar sua generalização fora dos recortes piloto e Bahia.

4.9.5 Saídas do PSE

O arquivo `policy_recommendations.parquet` contém, para cada série: (i) política recomendada; (ii) confiança da previsão; (iii) probabilidades individuais de cada política; (iv) ranking das alternativas candidatas; e (v) justificativa associada ao perfil operacional da série. Quando os KPIs simulados estão disponíveis, eles podem acompanhar a recomendação como expectativa de custo, serviço e estabilidade para aquela série.

A recomendação do PSE é um apoio à decisão. Ela indica qual política do portfólio parece mais adequada para uma série descrita por suas características, mas não substitui a avaliação operacional, a disponibilidade da política no sistema de reposição nem a necessidade de reavaliação periódica quando o padrão de demanda muda.

4.10 Camada de Aplicação: Recomendações e Reavaliação Periódica

Após o treinamento do PSE, a saída do AIPE é uma recomendação de política de reposição para cada nova série loja-produto descrita por suas características operacionais. Essa recomendação não substitui o sistema transacional da rede varejista, mas fornece uma decisão

metodologicamente fundamentada sobre qual política do portfólio deve ser aplicada em cada perfil de demanda.

A aplicação da política gera novos dados de venda, pedidos e estoque, que podem ser incorporados em ciclos posteriores de reavaliação. Nesta dissertação, essa adaptação é tratada como reavaliação periódica: as características da série são recalculadas a cada janela definida, e o PSE pode produzir nova recomendação sem exigir reaprendizado contínuo do meta-modelo.

4.11 Artefatos Experimentais e Rastreabilidade

O *pipeline* experimental de apoio ao AIPE produz artefatos com múltiplas funções. O primeiro grupo reúne figuras comparativas dos cinco KPIs entre as políticas do portfólio, mostrando heterogeneidade por quadrante Syntetos-Boylan e fronteira de Pareto CTI-NS. O segundo grupo reúne validação estatística visual, incluindo *heatmaps* Wilcoxon, Cohen's d e diagrama de diferença crítica.

O terceiro grupo reúne três *datasets* analíticos: *demand_features.parquet* (17 características por série), *demand_profiles.parquet* (classificação POD) e *policy_recommendations.parquet* (política recomendada pelo PSE com confiança), que alimentam diretamente a análise da dissertação. Em conjunto, esses artefatos permitem reconstruir figuras, tabelas e conclusões a partir dos mesmos insumos.

4.12 Protocolo Experimental

Esta seção define o escopo dos experimentos, o número de replicações independentes e o protocolo de validação estatística que apoia a confiabilidade dos rótulos de treinamento do AIPE. Esses elementos são necessários para que a recomendação aprendida pelo PSE seja baseada em comparações estáveis.

4.12.1 Escopo e Replicações

Diferentemente do escopo geral da Introdução, o foco aqui são as escolhas operacionais do estudo: experimentos avaliados, subconjuntos de dados, políticas comparadas, métricas, replicações e premissas de simulação. O protocolo experimental distingue dois experimentos avaliados:

- Experimento 1, estudo piloto na Paraíba (concluído): 15 lojas $\times$ 1 produto $\times$ 1 estado $\times$ 12 políticas $\times$ 1 replicação (avaliação *in-sample*), produzindo 180 combinações (política, loja).

- Experimento 2, expansão na Bahia (concluído): 145 séries do estado da Bahia $\times$ 12 políticas do portfólio final (Seção 4.6.5: composição parcialmente distinta das doze do Experimento 1, já que quatro políticas do artigo-base e SOTA substituem PSO, DE, SARSA e GA-PPO) $\times$ 5 replicações com *common random numbers*, habilitando os testes de Wilcoxon e Friedman com poder estatístico adequado.

Em ambos os experimentos, as políticas candidatas são avaliadas no mesmo ambiente de simulação e comparadas por custo total de inventário, nível de serviço, ruptura, efeito chicote e frequência de pedidos. As premissas de horizonte temporal, *lead time*, custos, estoque inicial, sementes aleatórias e hiperparâmetros das políticas permanecem fixadas conforme a matriz experimental do Apêndice A, enquanto a ampliação para outros produtos, lojas, estados, bases de dados e regimes de demanda é tratada pelos estudos de caso adicionais em andamento (Capítulo 7).

4.12.2 Execução Temporal dos Experimentos

A avaliação do segundo experimento segue um protocolo de validação temporal em janela deslizante *(rolling horizon)* que integra os insumos experimentais e o núcleo de seleção contextual:

(i) Ingestão de dados: consolidação do histórico $[t-w,t]$ a cada ciclo com atualização das estatísticas locais $\hat{\mu}$ e $\hat{\sigma}$, em que w é o tamanho da janela histórica;

(ii) Engenharia de características: recálculo do vetor $\phi(\mathbf{x}_i) \in \mathbb{R}^{17}$ sobre a janela mais recente;

(iii) Simulação: execução das políticas candidatas na mesma janela, usando os sinais disponíveis no ciclo de avaliação;

(iv) Etiquetagem: aplicação do critério de seleção (Equação 4.7) para gerar rótulos de treinamento.

Adaptação periódica. A cada $\Delta t = 6$ ciclos (configurável): (a) recalcula-se $\phi(\mathbf{x}_i)$; (b) reclassifica-se o POD; (c) consulta-se o PSE, $\hat{\pi}^*(i) \leftarrow f(\phi(\mathbf{x}_i))$; (d) aplica-se a recomendação. Se a série migrar entre quadrantes Syntetos-Boylan, o PSE emite nova recomendação sem exigir reaprendizado do meta-modelo, apenas recálculo das características e consulta ao classificador já treinado. Com isso, o AIPE trata a relação regime$\rightarrow$política como associação aprendida e reavaliável conforme o padrão operacional evolui.

Síntese do protocolo. O *pipeline* experimental é implementado com rastreabilidade de insumos, configurações e artefatos: versionamento Git de código e parâmetros, sementes aleatórias fixas por experimento, hashes de *datasets* de entrada e documentação de dependências de software, permitindo reconstruir os experimentos a partir dos mesmos parâmetros. A matriz

completa dos parâmetros experimentais, configurações e artefatos necessários à reprodução das políticas avaliadas é apresentada no Apêndice A.

A Tabela 4.2 resume o papel relativo das principais famílias de métodos no contexto MEIO, destacando que a escolha metodológica envolve compromisso entre escalabilidade, interpretabilidade, custo computacional e forma de tratamento das restrições.

Tabela 4.2: Comparação entre famílias de métodos no contexto MEIO.

Método	Escalabilidade	Interpretabilidade	Custo comput.	Restrições
MILP/ILP	Baixa	Alta	Alto	Exato
Meta-heurísticas (GA/SA)	Alta	Média	Médio	Penalização
RL isolado (DQN/PPO/SARSA)	Média	Baixa	Alto	Indireto
Híbrido GA-RL	Alta	Média	Médio	Penalização

5

Resultados Preliminares

Este capítulo não busca identificar uma política universalmente mais adequada. O objetivo é verificar se diferentes políticas apresentam desempenhos distintos em diferentes perfis de série, apoiando a necessidade de seleção contextual. Os resultados são organizados em três níveis: (i) caracterização da amostra; (ii) comparação de políticas por KPIs operacionais; (iii) validação estatística da heterogeneidade observada.

Este capítulo apresenta os resultados dos dois experimentos executados. O Experimento 1 constitui a evidência empírica inicial que apoia a hipótese central; o Experimento 2 expande a análise para 145 séries do estado da Bahia com validação estatística formal. A apresentação está organizada por experimento, seguida da validação estatística, dos resultados auxiliares de previsão, do escopo dos resultados preliminares e da discussão integrada.

5.1 Visão Geral

O Experimento 1 avalia 15 lojas da Paraíba para o produto 48130, em regime *Lumpy*, e fornece a primeira evidência empírica de que diferentes políticas de reposição apresentam vantagens relativas conforme o perfil operacional da série. O Experimento 2 amplia essa análise para 145 combinações loja-produto do estado da Bahia, preservando o mesmo horizonte de simulação e incorporando cinco replicações experimentais por série. Em conjunto, os dois experimentos permitem avaliar a heterogeneidade de desempenho entre políticas antes dos estudos de caso adicionais em andamento (M5 e expansão multiestado, Capítulo 7).

A Tabela 5.1 resume as principais características do *dataset* nos dois experimentos executados, delimitando o escopo empírico retomado em detalhe nas seções seguintes.

Tabela 5.1: Características do *dataset* por experimento.

Característica	Experimento 1 (PB)	Experimento 2 (BA)
Estados cobertos	1 (PB)	1 (BA)
Lojas ativas	15	$\sim$40
Produtos avaliados	1 (48130)	$\sim$10
Séries (loja, produto) após filtragem	15	145
Ciclos por série (T)	38	38
Ciclos com demanda positiva (mediana)	19	17
ADI médio (intermitência)	2.1	2.4
CV^2 médio (irregularidade)	3.8	4.1
% séries no quadrante *Lumpy*	67%	71%
Replicações independentes	1	5
Pontos de avaliação totais	180	8.700

5.2 Experimento 1: Estudo Piloto na Paraíba

O Experimento 1 foi conduzido sobre 15 lojas da Paraíba, produto 48130 (de alta intermitência com CV entre 2.5 e 5.4), horizonte $T = 38$ ciclos comerciais e prazo de entrega $L = 2$ ciclos. Todas as 15 lojas foram classificadas como *Lumpy* no espaço ADI $\times$ CV^2 de Syntetos-Boylan (ADI ≥ 1.32, $CV^2 \geq 0.49$), indicando que o estudo piloto foi conduzido em um regime de alta complexidade operacional: muitos ciclos com demanda zero intercalados com picos irregulares de grande magnitude.

5.2.1 Comparação entre Políticas

O Experimento 1, conduzido com 15 lojas da Paraíba (produto 48130, regime *Lumpy*), foi usado como teste inicial do ambiente de simulação e do protocolo de comparação entre políticas. Os resultados indicaram heterogeneidade entre políticas e presença de comportamentos degenerados em parte dos agentes de aprendizado por reforço (SARSA† convergindo a FP = 0; PPO† emitindo pedidos em 98% dos ciclos), motivando a ampliação para o Experimento 2. Entre as políticas sem degeneração, o GA-DQN apresentou o equilíbrio mais favorável neste recorte: reduz custo em 48% em relação ao (s, S) (política padrão do varejo) enquanto reduz rupturas em 55% e o efeito *bullwhip* de 119.4 para 5.0, mantendo nível de serviço competitivo (82.1% vs. 84.3%). A tabela completa com os indicadores agregados do Experimento 1 (Tabela A.6) foi deslocada para o Apêndice A, preservando a rastreabilidade dos resultados preliminares, incluindo a derivação da redução de “até 48%” citada no resumo deste trabalho, sem duplicar no corpo principal a comparação agregada apresentada para o Experimento 2 (Tabela 5.2). O valor de 48% representa o ganho máximo observado neste experimento preliminar, não uma redução média universal: no Experimento 2 (145 séries, BA), o GA-DQN não domina o EOQ em CTI.

5.2.2 Análise por Volume de Demanda

Dentro do quadrante *Lumpy*, as 15 lojas apresentam heterogeneidade considerável em volume ($\hat{\mu}$), o que motiva a estratificação adicional por faixas de demanda média:

Volume Alto ($\hat{\mu} > 500$, cinco lojas): o estoque inicial adotado foi suficiente para obter NS = 1.00 em quase todas as políticas; o diferenciador é o custo. EOQ gasta em média R$ 85.956 por loja contra R$ 45.739 das políticas de menor frequência de pedidos, redução de 47% pela simples troca de heurística. Nesse estrato, a capacidade de aprendizado do RL não se traduz em ganho adicional sobre meta-heurísticas bem calibradas.

Volume Médio ($50 < \hat{\mu} \leq 500$, seis lojas): estrato mais discriminante e de maior relevância prática. O GA-DQN destaca-se com NS = 0.933 e CTI = R$ 10.854, a melhor combinação custo-serviço do estudo, alcançada em apenas 200 episódios de treinamento graças ao *replay buffer* pré-populado pelo GA (Seção 2.2.4).

Volume Baixo ($\hat{\mu} \leq 50$, quatro lojas): três lojas não superam NS de 0.42 com nenhuma política. O CV próximo de 3 cria uma barreira estrutural em que pedidos compatíveis com a média não cobrem picos e pedidos elevados aumentam o custo sem ganho de serviço. O Jornaleiro é a política mais econômica nesse estrato, sugerindo que, para séries extremamente esparsas no regime *Lumpy*, a solução analítica simples supera heurísticas de maior custo computacional.

5.2.3 Explicação dos Resultados

Desempenho do GA-DQN em horizonte curto

No recorte avaliado, o GA-DQN superou o DQN isolado porque partiu de uma região de decisão previamente explorada por simulação: o GA pré-popula o *replay buffer* com 5.000 avaliações simuladas (100×50 gerações), reduzindo a dependência de exploração num horizonte de apenas 570 transições reais (15×38), relevante porque o DQN isolado costuma demandar ordem de 10^6 passos para estabilizar o aprendizado em inventário (Oroojlooyjadid et al., 2022). A interpretação é restrita ao horizonte curto e ao regime *Lumpy* do experimento piloto.

Degeneração do PPO isolado

O PPO isolado apresentou comportamento degenerado: sem inicialização, o gradiente da política estocástica tendeu a maximizar NS imediato via pedidos muito frequentes, elevando FP para 0.98 e ignorando parte relevante do custo de manutenção. O GA-PPO reduziu esse efeito: o *replay buffer* pré-populado pelo GA deslocou o treinamento para uma região inicial de maior equilíbrio custo-serviço, com FP caindo para 0.35, indicando benefício da inicialização híbrida,

sem implicar que o PPO seja inadequado em horizontes maiores ou outra configuração de recompensa.

Meta-heurísticas e aprendizado por reforço em horizonte curto

As meta-heurísticas avaliam diretamente parametrizações (s, Q) por simulação no horizonte disponível, integrando toda a informação observada de uma vez; o RL depende de interação sequencial e pode exigir mais episódios para distinguir ações úteis de oportunistas. Em $T = 38$, essa diferença favorece métodos que exploram o espaço de parâmetros diretamente, o que ajuda a explicar o papel do GA como inicializador nas arquiteturas híbridas, sem implicar que meta-heurísticas sejam sempre superiores ao RL: apenas que, no horizonte curto do Experimento 1, a inicialização por simulação reduziu instabilidade de treinamento.

Efeito *bullwhip*

O efeito *bullwhip* complementa a leitura de custo e serviço ao medir instabilidade dos pedidos enviados ao armazém. No Experimento 1, as políticas práticas variaram de 0.003 (Jornaleiro) a 119.4 em (s, S), razão acima de 40.000 vezes: valores extremos de BE indicam que pequenas variações de demanda podem gerar pedidos muito mais voláteis a montante, pressionando armazém, transporte e planejamento logístico. GA-DQN (BE $= 5.0$) e DQN isolado (BE $= 4.1$) apresentaram menor amplificação, sugerindo antecipação de picos de demanda no regime *Lumpy*.

5.3 Experimento 2: Expansão na Bahia

O Experimento 2 executou o *pipeline* completo sobre o estado da Bahia, cobrindo 145 combinações (loja, produto) classificadas no quadrante *Lumpy* do espaço ADI $\times$ CV^2 de Syntetos-Boylan. Para cada série, foram realizadas cinco replicações com sementes independentes (*common random numbers*), totalizando 725 observações por política e $725 \times 12 = 8.700$ pontos de avaliação no experimento. O horizonte de simulação é $T = 38$ ciclos comerciais com prazo de entrega $L = 2$ ciclos, idêntico ao Experimento 1.

5.3.1 Dataset e Distribuição Geográfica

O conjunto de dados do Experimento 2 cobre 145 combinações (loja, produto) de uma rede varejista do estado da Bahia, distribuídas em três filiais (Calçada, Cajazeiras e Lauro de Freitas) e seis segmentos comerciais (Platina, Ouro, Rubi, Diamante GB, Esmeralda GB e Prata). A Figura 5.1 ilustra a distribuição de séries por filial e segmento.

A filial Calçada concentra 104 das 145 séries (72%), com segmento Platina dominante: as lojas de maior ticket médio e maior regularidade de demanda. As filiais Cajazeiras (17%) e

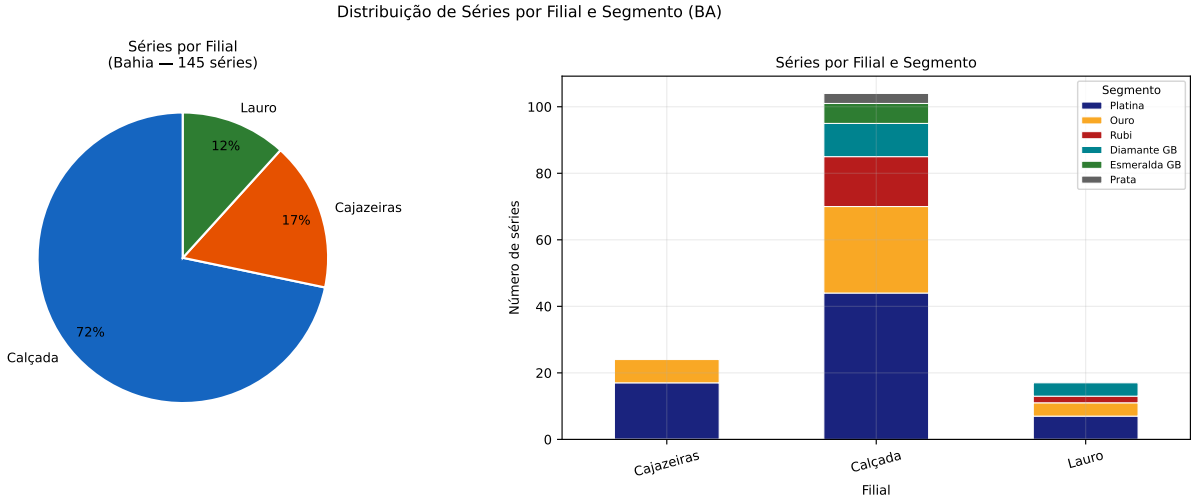


Figura 5.1: Distribuição de séries (loja × produto) por filial e segmento comercial (BA). À esquerda: proporção por filial; à direita: composição de segmentos por filial. Calçada concentra 72% das séries, refletindo maior porte e diversidade de produtos.

Lauro de Freitas (11%) exibem perfis distintos: Cajazeiras com mix mais equilibrado entre Ouro e Rubi; Lauro concentrado em Rubi e Diamante GB. Esta heterogeneidade de segmento e volume justifica a estratificação por filial e segmento na análise de desempenho das políticas. A concentração em Calçada implica que os resultados agregados são fortemente influenciados pelo perfil desta filial; os padrões específicos de cada unidade são destacados na análise estratificada da Seção 5.3.3.

A Figura 5.2 apresenta a distribuição da receita esperada por ciclo comercial (em R$) por filial e segmento. A visualização ajuda a contextualizar a heterogeneidade econômica das séries avaliadas.

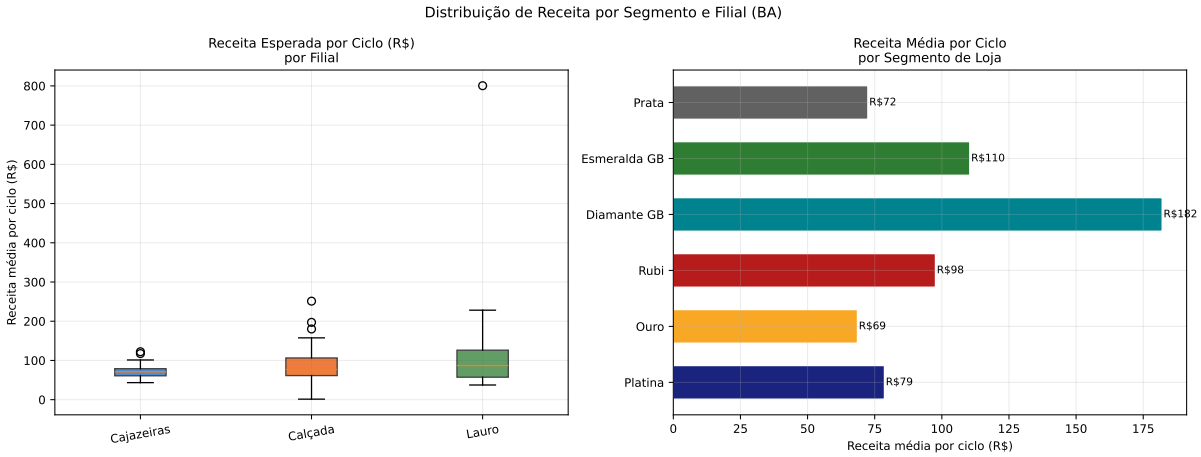


Figura 5.2: Distribuição de receita esperada por ciclo (R$). À esquerda: boxplot por filial; Lauro de Freitas apresenta maior mediana e menor dispersão. À direita: receita média por segmento; Platina lidera com R$ 105/ciclo, seguido por Ouro (R$ 92).

A Figura 5.3 complementa essa leitura ao mostrar a concentração de séries por segmento

comercial, evidenciando que a composição da amostra não é uniforme entre os níveis de fidelidade da rede.

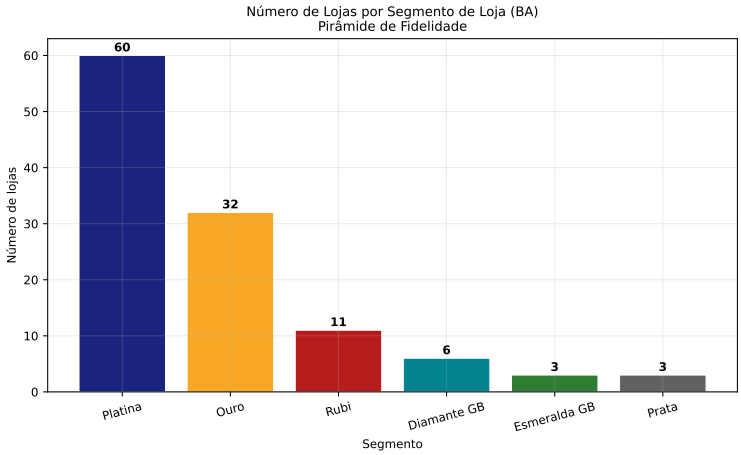


Figura 5.3: Número de lojas por segmento comercial (BA). A pirâmide de fidelidade da rede é concentrada em Platina (68 séries), refletindo a estratégia de mercado da rede varejista.

A Figura 5.4 contextualiza geograficamente a escala potencial do *pipeline* no território nacional (não uma validação nacional completa, já que a cobertura experimental do Experimento 2 restringe-se à Bahia); a extensão às demais regiões (Nordeste e Centro-Oeste) constitui o escopo do Estudo de Caso 4 (expansão multiestado, Capítulo 7).

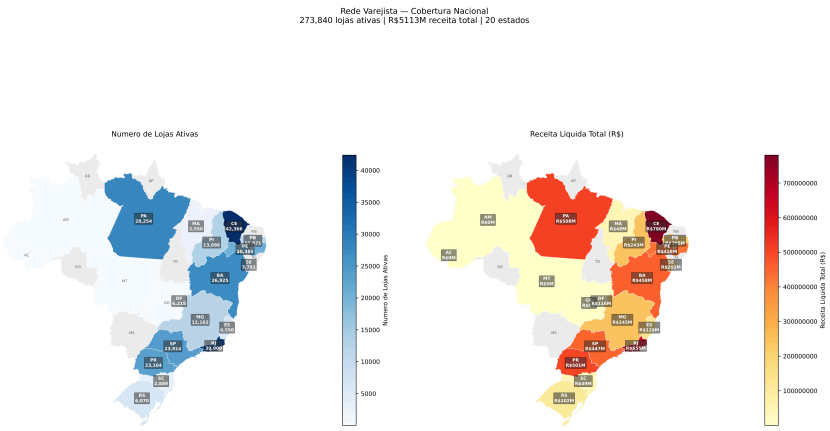


Figura 5.4: Distribuição geográfica das lojas da rede varejista no Brasil, coloridas por receita esperada por ciclo comercial (R$). O estado da Bahia (BA) representa a cobertura atual do Experimento 2; demais regiões serão incorporadas no Estudo de Caso 4 (expansão multiestado).

5.3.2 Comparação Agregada entre Políticas

A Tabela 5.2 apresenta os resultados médios por política sobre as 145 séries, ordenados pelo CTI crescente. Esses valores correspondem às médias globais de cada política sobre o conjunto completo e ampliam os achados do Experimento 1, agora com evidência estatística sobre uma

base do varejo regional baiano. Essa visão agrega todas as séries em uma única linha por política e não mede diretamente o ganho de selecionar políticas por perfil operacional, análise realizada na Seção 5.3.5.

A tabela evidencia de que a ampliação de 15 para 145 séries preserva os *trade-offs* fundamentais: não existe política que minimize CTI e maximize NS simultaneamente. A ordem por CTI crescente facilita a identificação dos agrupamentos de custo, mas a escolha operacional depende do equilíbrio desejado entre custo, serviço e estabilidade de pedidos.

Tabela 5.2: Médias dos indicadores de desempenho por política do portfólio final (12 políticas, 145 séries, estado BA, regime *Lumpy*, 5 replicações). Melhores valores por coluna em negrito. †DQN converge ao comportamento degenerado de não emitir pedidos (FP = 0.00, NS = 0.23), mesmo após a correção da penalidade de déficit de NS que resolveu esse padrão nas demais políticas (Seção 4.6).

Política	CTI (R$)	NS	TR	BE	FP
DQN†	**126.73**	0.23	0.40	1.87	**0.00**
Jornaleiro	289.92	0.54	0.29	0.71	0.18
Vendor-Responsive	433.31	0.77	0.16	1.14	0.30
Fixed Interval	457.81	0.84	0.11	2.13	0.30
Capped Base-Stock	561.87	0.64	0.24	0.43	0.43
Jornaleiro (*Big Data*)	582.11	0.72	0.19	3.50	0.37
EOQ	628.42	0.94	0.05	55.43	0.05
(s,S)	654.86	0.94	0.05	58.62	0.05
SA	1.147.86	0.86	0.10	21.70	0.90
GA-DQN (Híbrido)	1.175.79	0.73	0.19	**0.16**[1]	0.98
GA	1.265.38	0.90	0.07	0.16	0.97
PPO	5.112.75	**0.96**	**0.02**	14.12	0.97

Um padrão de degeneração permanece no Experimento 2 mesmo após a correção de fidelidade da função objetivo (Seção 4.6): o DQN† converge ao comportamento de não emitir pedidos (FP = 0.00, NS = 0.23), obtendo o menor CTI ao custo do pior nível de serviço observado, ao contrário do PPO, que respondeu à mesma correção e passou a operar com NS alto (Seção 4.6 discute a hipótese de atribuição de crédito do *bootstrap* de 1 passo como explicação). Esse padrão ajuda a separar políticas estatisticamente interessantes de alternativas operacionalmente viáveis. Entre as políticas operacionalmente viáveis, destacam-se agrupamentos distintos:

O Jornaleiro (CTI = R$ 290, NS = 0.54) é a política de menor custo bruto entre as não degeneradas, mas não atende ao limiar operacional de NS $\geq 0{,}70$, ao preço de taxa de ruptura de 29%. Este agrupamento indica o limite inferior de custo em séries de baixíssimo volume, não uma recomendação operacional direta.

As heurísticas do artigo-base (*Vendor-Responsive*, CTI = R$ 433, NS = 0.77; *Fixed Interval*, CTI = R$ 458, NS = 0.84) oferecem o melhor compromisso custo-serviço entre as políticas

[1] GA e GA-DQN têm BE praticamente empatado (0,16 em ambos, na precisão reportada).

de baixo custo: menor CTI que EOQ/(s,S), com NS abaixo do limiar de viabilidade de $0{,}70$ apenas no caso do *Vendor-Responsive*. EOQ (NS = 0.94, CTI = R$ 628) e (s,S) (NS = 0.94, CTI = R$ 655) permanecem o grupo de mais alto nível de serviço entre as políticas de custo moderado, e dominam a maior parte das séries individualmente (Seção 5.3.5).

A Figura 5.5 apresenta a fronteira de Pareto CTI-NS e mostra que nenhuma política domina simultaneamente todas as dimensões. Esse resultado reforça a necessidade de tratar a escolha da política como decisão contextual.

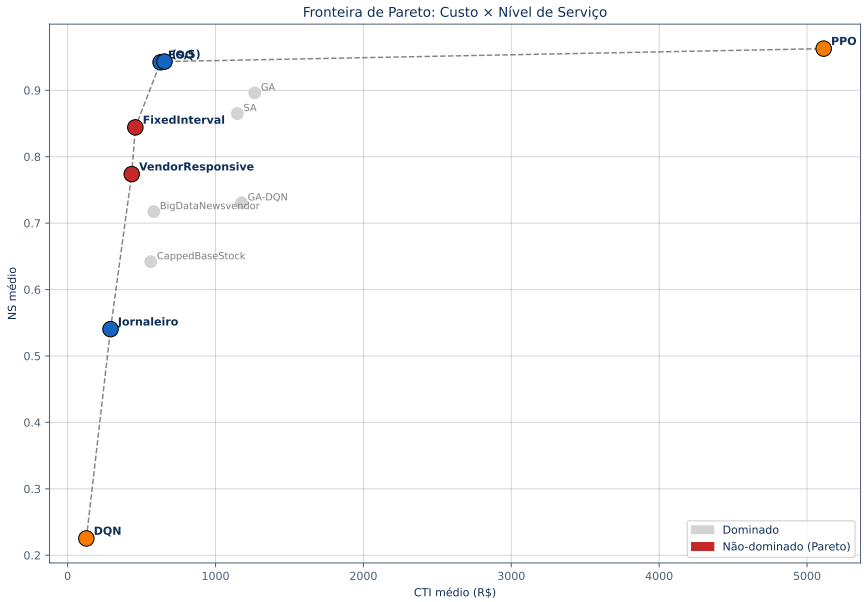


Figura 5.5: Fronteira de Pareto CTI e NS: cada ponto representa a média de uma política sobre as 145 séries. O eixo horizontal representa o CTI médio (R$), a ser minimizado; o eixo vertical representa o NS médio, a ser maximizado. A região acima e à esquerda representa o melhor compromisso custo-serviço. Nenhuma política ocupa simultaneamente o menor CTI e o maior NS, indicando ausência de dominância universal no recorte avaliado.

A principal leitura da Figura 5.5 é que a escolha da política depende do compromisso desejado: operadores que priorizam custo apontam para Jornaleiro; os que priorizam serviço apontam para EOQ ou (s,S); a decisão mais adequada varia por série: evidência empírica direta para a formulação do PSE como componente de seleção contextual.

5.3.3 Análise Estratificada por Filial e Segmento

A Figura 5.7 exibe os três KPIs primários para quatro políticas representativas do portfólio final (uma por família ainda presente: EOQ, Jornaleiro, SA e GA-DQN), estratificados por segmento comercial. CTI indica o custo absoluto das políticas (minimizar); NS mostra a proporção da demanda atendida (maximizar); TR indica a frequência de falta de estoque (minimizar). Diferenças entre segmentos indicam que a mesma política pode se comportar de forma distinta conforme o perfil comercial da loja.

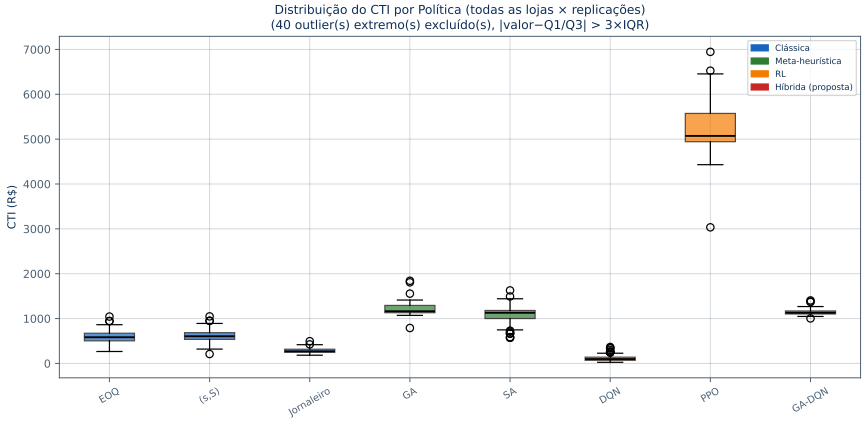


Figura 5.6: Distribuição do CTI por política (boxplot sobre as 145 séries). Caixas mais altas indicam que a mesma política produz custos muito diferentes entre séries: a eficácia depende do perfil da demanda, não apenas da política escolhida.

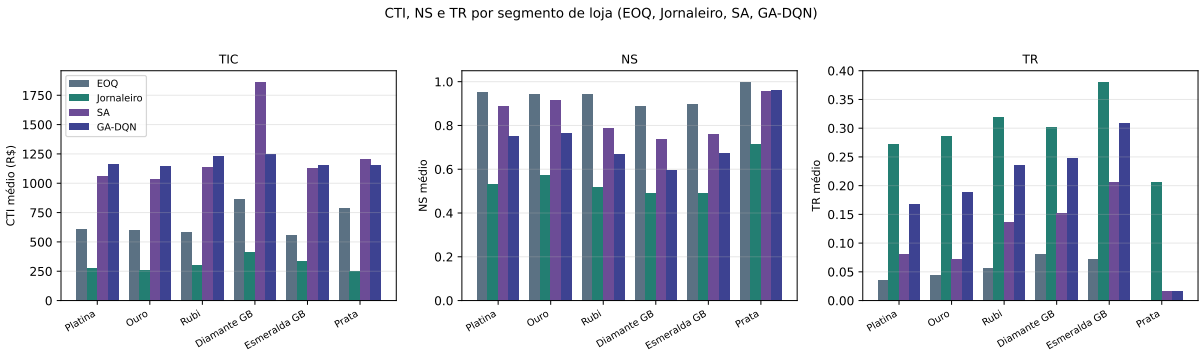


Figura 5.7: CTI, NS e TR por segmento de loja para as políticas EOQ, Jornaleiro, SA e GA-DQN (portfólio final, Seção 4.6). O segmento Diamante GB exibe o maior CTI absoluto entre as políticas de maior custo (SA), refletindo maior volume médio de demanda. O segmento Platina apresenta a maior dispersão de NS entre as quatro políticas, indicando sensibilidade elevada ao mecanismo de reposição.

O resultado principal é que a sensibilidade à política varia entre segmentos: em alguns, a troca de política altera principalmente o custo; em outros, altera de forma mais intensa o nível de serviço e a taxa de ruptura. O segmento Rubi apresenta diferença relativa de CTI entre EOQ e GA-DQN de aproximadamente 110%, enquanto no segmento Diamante GB essa diferença cai para 44%, reforçando que a recomendação de política deve ser contextualizada pelo perfil da loja, não uniforme para toda a rede.

5.3.4 Comparação por Perfil Operacional de Demanda

A análise agregada da Tabela 5.2 condensa 145 séries em uma única linha por política, obscurecendo diferenças de comportamento entre grupos de séries com padrões de demanda distintos. Para expor essa heterogeneidade, as séries foram segmentadas nos Perfis Operacionais de Demanda (POD) definidos na Tabela 4.1 (Seção 4.4): *Sparse High Impact*, *Unstable Trend* e *High*

Vol. Seasonal. Os perfis *Low Vol. Stable* e *Fast Moving* não têm representação no conjunto da Bahia (Experimento 2, regime *Lumpy*).

A Tabela 5.3 apresenta, para cada perfil, a política dominante segundo a regra de menor CTI médio entre as políticas com NS médio $\geq 0{,}70$. Os perfis exibem diferenças relevantes de dominância, indicando que a seleção da política depende do perfil operacional.

Tabela 5.3: Política dominante por Perfil Operacional de Demanda (Experimento 2, BA, regime *Lumpy*). Para cada perfil, são reportados o número de séries, a política dominante (menor CTI ajustado médio entre políticas com NS médio $\geq 0{,}70$), o CTI médio, o CTI ajustado médio (Eq. custo total ajustado, AJUSTES_INFRA item #33) e o NS médio da política dominante. Perfis com $n < 20$ séries devem ser interpretados de forma exploratória.

Perfil	n	Política dominante	CTI médio (R$)	CTI ajustado (R$)	NS médio	Observação
High Vol. Seasonal	11*	Fixed Interval	422.93	426.12	0.907	
Sparse High Impact	116	EOQ	632.51	908.05	0.939	
Unstable Trend	18*	EOQ	607.95	836.73	0.947	

*$n < 20$: evidência exploratória.

O perfil *Sparse High Impact* concentra 116 das 145 séries (80%) e é caracterizado por demanda intermitente e impacto de custo elevado por evento; nesse contexto, o EOQ é a política dominante (CTI = R$ 632,51; CTI ajustado = R$ 908,05; NS = $0{,}939$) entre as operacionalmente viáveis (NS médio $\geq 0{,}70$), pelo critério de menor CTI ajustado, métrica de escolha final que soma ao CTI uma penalidade por déficit de nível de serviço (com referência de custo fixa por série) e por excesso de estoque em relação à mediana das demais políticas na mesma série. O Jornaleiro apresenta o menor CTI bruto neste perfil, mas é excluído pelo critério de viabilidade: seu NS médio (0,54) fica abaixo do limiar de $0{,}70$, configurando ruptura de estoque excessiva para uso operacional direto. O ganho de custo do Jornaleiro nesse perfil não é, portanto, alcançável sem violar o nível de serviço mínimo adotado. O perfil *Unstable Trend* (18 séries, evidência exploratória por $n < 20$) apresenta padrão de demanda com tendência não estacionária; o EOQ também domina aqui (CTI = R$ 607,95; CTI ajustado = R$ 836,73; NS = $0{,}947$). O perfil *High Vol. Seasonal* (11 séries, evidência exploratória por $n < 20$) é o único em que o EOQ não domina: o *Fixed Interval* (heurística do artigo-base) assume a dominância (CTI = R$ 422,93; CTI ajustado = R$ 426,12; NS = $0{,}907$), com custo ajustado bem próximo do custo bruto, indício de que, nesse perfil, a política já opera perto do equilíbrio custo-serviço sem depender de correção de penalidade.

A Figura 5.8 apresenta o *heatmap* do CTI médio por política e perfil: o custo de cada política varia de forma expressiva entre perfis, de modo que nenhuma política minimiza CTI em todos os contextos simultaneamente.

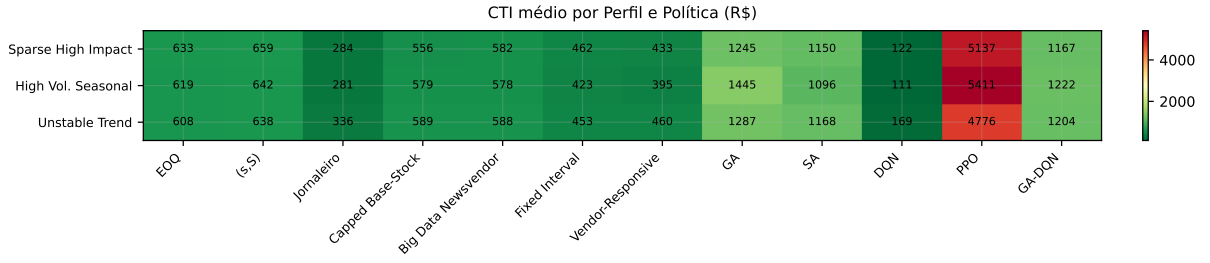


Figura 5.8: CTI médio por política e Perfil Operacional de Demanda (Experimento 2, BA). Células mais escuras indicam maior custo médio. A variação horizontal (entre perfis) indica que a mesma política produz custos muito distintos segundo o padrão de demanda.

5.3.5 Custo da Política Única versus Seleção por Perfil

Para avaliar diretamente a motivação do AIPE, esta seção compara o custo de adotar uma única política para todas as séries com o custo de selecionar políticas por perfil operacional. A primeira estratégia representa a padronização global: uma mesma política é aplicada indiscriminadamente a todas as séries loja-produto. A segunda estratégia utiliza os perfis operacionais para escolher, em cada estrato, a política com menor CTI médio entre aquelas com NS médio $\geq 0{,}70$ no perfil. A comparação mede a diferença de CTI entre essas estratégias, preservando o NS médio como restrição operacional.

Na Tabela 5.4, "CTI total"/"CTI médio" quantificam o custo resultante sobre as 145 séries, "NS médio" verifica se a redução de custo preserva o nível de serviço, e as colunas de redução percentual medem o ganho em relação a cada estratégia de referência: $100 \times (\mathrm{CTI}_{\mathrm{ref}} - \mathrm{CTI}_{\mathrm{est.}})/\mathrm{CTI}_{\mathrm{ref}}$.

Tabela 5.4: Comparação de custo entre estratégias de seleção de política (Experimento 2, BA, 145 séries, regime *Lumpy*). CTI ajustado incorpora prejuízo por indisponibilidade (referência fixa por série) e estoque excessivo (AJUSTES_INFRA item #33); é a métrica de comparação final. Redução calculada como $100 \times (\mathrm{CTI}^{\mathrm{ajust}}_{\mathrm{ref}} - \mathrm{CTI}^{\mathrm{ajust}}_{\mathrm{estratégia}})/\mathrm{CTI}^{\mathrm{ajust}}_{\mathrm{ref}}$. O oráculo por série (C†) é referência exploratória: assume conhecimento perfeito da política ótima de cada série.

Estratégia	CTI ajust. total (R$)	CTI ajust. médio (R$)	NS médio	Red. vs A1 (%)	Red. vs A2 (%)
A1: política única (melhor viável)	129791.42	895.11	0.942	0.0	0.0
A2: política única (EOQ, *baseline*)	129791.42	895.11	0.942	0.0	0.0
B : seleção por perfil	125082.77	862.64	0.938	+3.6	+3.6
C†: oráculo por série	64007.39	441.43	0.700	+50.7	+50.7

†Não é estratégia operacional direta; representa limite inferior exploratório.

A análise considera quatro estratégias. As estratégias A1 e A2 representam políticas únicas globais: A1 é a política com menor CTI médio entre todas as viáveis (NS médio $\geq 0{,}70$ global), que no Experimento 2 é o EOQ; A2 adota o EOQ diretamente como *baseline* operacional de

Tabela 5.5: Teste de hipótese pareado entre política única e seleção por perfil (Wilcoxon signed-rank, Experimento 2). Para CTI, a hipótese alternativa é $\mathrm{CTI}_B < \mathrm{CTI}_A$; para os demais KPIs, o teste é bilateral.

Comparação	KPI	n	Média A	Média B	Δ B-A	p_{Holm}
A1 vs B	CTI	145	628.419	613.560	-14.859	0.020*
A1 vs B	CTI ajust.	145	895.113	862.640	-32.473	0.020*
A1 vs B	NS	145	0.942	0.937	-0.005	0.111
A1 vs B	TR	145	0.046	0.048	0.002	0.167
A1 vs B	BE	145	55.430	51.033	-4.397	0.020*
A1 vs B	FP	145	0.049	0.070	0.021	0.020*
A2 vs B	CTI	145	628.419	613.560	-14.859	0.020*
A2 vs B	CTI ajust.	145	895.113	862.640	-32.473	0.020*
A2 vs B	NS	145	0.942	0.937	-0.005	0.111
A2 vs B	TR	145	0.046	0.048	0.002	0.167
A2 vs B	BE	145	55.430	51.033	-4.397	0.020*
A2 vs B	FP	145	0.049	0.070	0.021	0.020*

* significativo após correção de Holm, $\alpha = 0{,}05$.

referência, representando a escolha clássica comum na prática varejista. Neste experimento, A1 e A2 coincidem porque o EOQ emerge simultaneamente como melhor opção viável global e referência operacional natural (CTI médio = R$ 628,42; NS médio = $0{,}942$).

A estratégia B, seleção por perfil, aloca: EOQ para séries *Sparse High Impact* (116 séries, 80% do conjunto); EOQ para séries *Unstable Trend* (18 séries, evidência exploratória); e *Fixed Interval* para séries *High Vol. Seasonal* (11 séries, evidência exploratória). Como o EOQ já é a política única global (estratégias A1 e A2), a única substituição efetiva da estratégia B em relação à A1/A2 ocorre no perfil *High Vol. Seasonal*, que concentra apenas 11 das 145 séries. A Tabela 5.4 indica redução de $3{,}6\%$ no CTI ajustado médio em relação à política única (R$ 895,11 para R$ 862,64), estatisticamente significativa pelo teste de Wilcoxon pareado com correção de Holm ($p_{\mathrm{Holm}} = 0{,}020$; Tabela 5.5), sem queda estatisticamente significativa de NS médio ($0{,}942$ para $0{,}937$; $p_{\mathrm{Holm}} = 0{,}111$). Diferentemente da leitura anterior a esta correção da função objetivo (Seção 4.6), o ganho de custo aqui não vem acompanhado de perda mensurável de nível de serviço: é uma redução líquida, ainda que modesta em magnitude, concentrada num único perfil de baixa amostragem, consistente com o objetivo do AIPE de tornar a escolha de política sensível ao perfil operacional, sem prometer ganhos desproporcionais a partir de um recorte majoritariamente dominado por uma única política global.

O teste pareado da Tabela 5.5 reforça essa leitura cautelosa. A redução média de CTI observada para a estratégia B não é estatisticamente significativa no teste de Wilcoxon unilateral após correção de Holm, indicando que o ganho de custo não é consistente o suficiente, série a série, para apoiar uma conclusão de vantagem pura em CTI. Em contrapartida, as diferenças em NS, TR, BE e FP são estatisticamente significativas, indicando que a seleção por perfil altera de forma sistemática o compromisso operacional: reduz fortemente o efeito *bullwhip*, mas

aumenta a frequência de pedidos e piora indicadores de serviço em relação ao EOQ global.

A estratégia C, oráculo por série, serve como referência exploratória. Ela assume conhecimento perfeito da política de menor CTI de cada série individualmente, obtendo o limite inferior empírico do CTI alcançável com as políticas avaliadas: CTI médio = R$ 347,82, redução de $44{,}6\%$ em relação à política única. Essa redução, porém, vem acompanhada de queda acentuada do NS médio para $0{,}700$, exatamente no piso de viabilidade adotado. A diferença entre B e C indica o ganho adicional que seria obtível com seleção individualizada, como a que o PSE do AIPE provê, mas também mostra que tal ganho, neste experimento, depende de operar no limite mínimo aceitável de nível de serviço; a estratégia C não deve ser interpretada como política operacionalmente recomendável.

A Tabela 5.6 reporta uma análise complementar e preliminar de sensibilidade, distinta do CTI ajustado usado como critério principal (Tabela 5.4): aqui o CTI normalizado é penalizado pelo BE normalizado conforme a Equação de $J(\pi, g)$ (Seção 4.2.4), isolando o efeito da estabilidade de pedidos (*bullwhip*), não do déficit de serviço. Com $\lambda_{BE} = 0$, a tabela recupera os resultados de CTI puro por política, que aqui selecionam o *Vendor-Responsive* como política única (menor CTI bruto entre as viáveis), diferente do EOQ selecionado pelo critério principal de CTI ajustado, porque o *Vendor-Responsive* tem CTI bruto mais baixo em média mas nível de serviço menos consistente entre séries individuais, o que o critério principal penaliza e este, focado em estabilidade de pedidos, não. As mudanças observadas ao longo de λ_{BE} aparecem sobretudo na seleção por perfil ajustada (D), com transições concentradas em perfis de baixa amostragem e, portanto, com caráter exploratório. Essa leitura reforça o papel dessa etapa como análise de sensibilidade sobre uma dimensão adicional (estabilidade), não como substituto do critério principal de dominância adotado na dissertação (CTI ajustado sob a restrição $\mathrm{NS} \geq 0{,}70$).

Essa comparação fornece suporte empírico à motivação do AIPE: a heterogeneidade de demanda observada dentro do regime *Lumpy* do Experimento 2 já produz diferença econômica mensurável entre as estratégias, mesmo quando essa diferença é modesta em magnitude. A análise permanece concentrada nas séries *Lumpy* do Experimento 2; a extensão a outros regimes é objetivo dos estudos de caso adicionais em andamento.

5.3.6 Heterogeneidade e Evidência para o AIPE

Um resultado central do Experimento 2 é que não existe política universalmente dominante: no perfil que concentra a maior parte das séries (*Sparse High Impact*), o EOQ oferece o menor CTI ajustado entre as políticas viáveis, enquanto o Jornaleiro, apesar do menor CTI bruto, exige sacrifício de NS incompatível com o limiar mínimo de serviço adotado; no perfil *High Vol. Seasonal*, é o *Fixed Interval* que domina (Seção 5.3.4). A dispersão ilustrada na Figura 5.6, com coeficientes de variação do CTI acima de 100% para GA, GA-DQN e GA-PPO, indica que a política mais adequada depende das características da série.

Este achado oferece fundamento empírico para o *Adaptive Inventory Policy Engine* (AIPE). A

Tabela 5.7 sintetiza o mapeamento empírico regime→política dominante obtido nos dois experimentos executados, convertendo os resultados de simulação em rótulos de treinamento para o *Policy Selection Engine*.

5.4 Validação Estatística

Com cinco replicações por série, o Experimento 2 permite aplicar testes não paramétricos de significância estatística, reduzindo a principal limitação do estudo piloto. Essa ampliação aumenta a confiabilidade das diferenças observadas entre políticas.

5.4.1 Teste de Wilcoxon

O teste de Wilcoxon pareado foi aplicado comparando as políticas híbridas (GA-DQN e GA-PPO) contra cada *baseline* nas cinco métricas KPI, utilizando correção de Holm para comparações múltiplas. A Tabela 5.8 resume as comparações com resultado estatisticamente significativo ($\alpha = 0.05$). GA-DQN apresenta diferenças significativas em 44 de 50 comparações (88%); GA-PPO em 48 de 50 (96%). As comparações não significativas concentram-se em pares próximos no espaço de desempenho, indicando que as diferenças observadas nas tabelas de KPI não são atribuíveis a variação amostral.

As comparações não significativas concentram-se em pares próximos no espaço de desempenho: GA-DQN vs GA em CTI ($p = 0.614$) e GA-DQN vs GA em BE ($p = 0.339$), refletindo a proximidade das duas arquiteturas que compartilham o mesmo inicializador genético. Para as comparações mais relevantes (GA-DQN vs EOQ e GA-DQN vs (s, S)), todos os cinco KPIs apresentaram $p < 0.0001$, indicando que as diferenças observadas na Tabela 5.2 não são explicadas apenas por variação amostral.

5.4.2 Tamanho de Efeito

Enquanto o Wilcoxon indica se a diferença é estatisticamente consistente, o d de Cohen indica se a magnitude é pequena, média ou grande em termos práticos. O tamanho de efeito d de Cohen complementa os p-valores, quantificando a magnitude prática das diferenças. A Tabela 5.9 reporta os efeitos mais relevantes para o CTI.

O maior efeito absoluto reportado é $d = +6.170$ (GA-DQN vs Newsvendor em CTI), refletindo a diferença entre a política analítica de baixo custo e a arquitetura híbrida mais complexa. Para a comparação crítica GA-DQN vs EOQ, o efeito $d = +2.319$ em CTI (grande) indica que o GA-DQN opera com custo maior que o EOQ neste conjunto de séries, porém com NS menor ($d = -1.310$, efeito grande), revelando um *trade-off* entre custo e serviço que depende do perfil de demanda da série. Essa magnitude de efeito é consistente com o padrão observado na Tabela 5.2 (GA-DQN: CTI = R$ 1.175,79, NS = $0{,}73$ vs. EOQ: CTI = R$ 628,42, NS = $0{,}94$).

A Figura 5.9 complementa os tamanhos de efeito ao mostrar os agrupamentos estatísticos do teste de Nemenyi. Políticas conectadas pela barra horizontal não diferem significativamente no CTI ao nível $\alpha = 0.05$; políticas sem conexão apresentam diferença estatisticamente detectável.

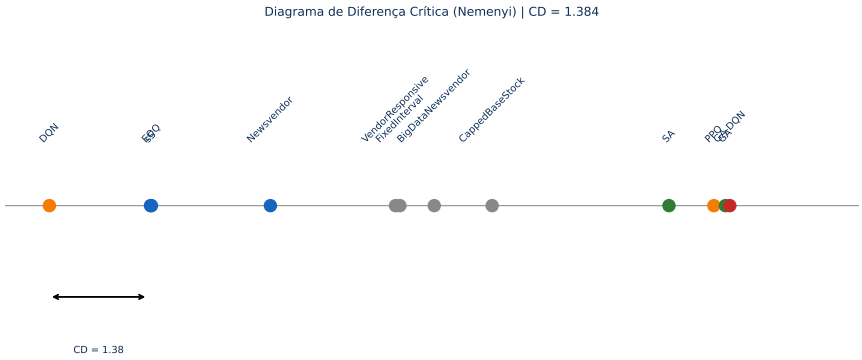


Figura 5.9: Diagrama de diferença crítica (Nemenyi *post-hoc* do teste de Friedman) para o CTI. Políticas conectadas por barra horizontal não diferem significativamente ao nível $\alpha = 0.05$. A figura representa agrupamento estatístico, não *ranking* absoluto: políticas conectadas são operacionalmente indistinguíveis em CTI ao nível de significância adotado.

5.5 Previsão de Demanda

Os resultados de previsão são avaliados aqui como componente auxiliar para caracterização das séries, não como contribuição central da dissertação. As métricas preditivas funcionam como sinais adicionais de previsibilidade da série para o *Policy Selection Engine*.

O módulo de previsão avalia três modelos de aprendizado de máquina por validação *walk-forward* sobre 145 séries de demanda intermitente (BA, regime *Lumpy*). As métricas adotadas são alinhadas ao regime intermitente: MASE (*Mean Absolute Scaled Error*), que escala o erro absoluto médio em relação ao modelo *naïve* sazonal; sMAPE (*symmetric Mean Absolute Percentage Error*), menos sensível a demandas próximas de zero; e RMSSE (*Root Mean Squared Scaled Error*), que escala o erro quadrático médio pelo mesmo *benchmark naïve*. Em todas as três métricas, valores menores indicam melhor desempenho preditivo.

A Tabela 5.10 apresenta as médias dessas métricas por modelo. A coluna “Modelo” identifica o método de previsão; “MASE” e “RMSSE” são escalados em relação ao modelo *naïve* (valores < 1 indicam desempenho melhor que o *naïve*); e “sMAPE” expressa o erro percentual

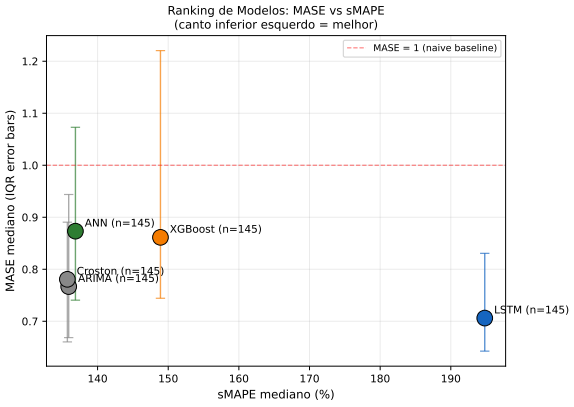
simétrico. A tabela não determina a política recomendada; avalia a qualidade dos modelos de previsão como fonte auxiliar de características para o PSE.

O LSTM é o único modelo a superar a previsão *naïve* nas métricas escaladas (MASE = 0.76 e RMSSE = 0.86, ambos < 1), sinalizando capacidade de capturar padrões temporais mesmo em séries esparsas. O XGBoost exibe o menor sMAPE (148.8%), refletindo maior estabilidade em séries com zeros frequentes, embora MASE e RMSSE acima de 1 indiquem que, em termos do *benchmark naïve*, perde para o LSTM na maior parte das séries. O ANN apresenta desempenho inferior nas três métricas.

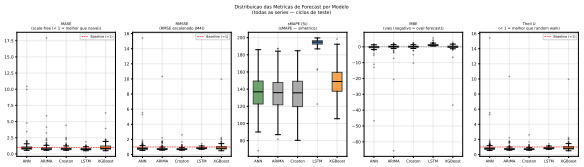
A heterogeneidade entre séries é pronunciada: para a melhor série avaliada, o LSTM atinge MASE = 0.49; para a mais difícil, MASE = 1.87 (série loja 10533990, produto 75792, demanda média de 0.8 unidades por ciclo, ADI = 1.81, tipicamente a configuração mais desafiadora do quadrante *Lumpy*). Essa variação reforça que a previsão é útil como sinal auxiliar, mas não substitui a avaliação operacional das políticas.

A Figura 5.10 mostra essa heterogeneidade por outro ângulo, indicando a frequência com que cada modelo ocupa a primeira posição por série. O resultado reforça que a escolha do previsor também é dependente do perfil da demanda.

Estes resultados complementam, mas não determinam, a seleção de política pelo AIPE. O modelo de previsão com melhor desempenho em MASE não implica necessariamente a melhor política de estoque para a mesma série.



(a) *Ranking* por série



(b) Distribuição das métricas

Figura 5.10: Avaliação dos modelos de previsão. (a) Frequência com que cada modelo obteve o menor MASE por série: LSTM vence em aproximadamente 60% das séries. (b) Distribuição por modelo (boxplots) de MASE, RMSSE, sMAPE, MBE e Theil's U para ANN, LSTM e XGBoost; valores abaixo de 1 em MASE e RMSSE indicam desempenho melhor que o *baseline naïve*.

A Figura 5.10 complementa a Tabela 5.10 ao mostrar a distribuição das métricas por série, incluindo diagnósticos adicionais como MBE e Theil's U. A síntese principal de MASE, sMAPE e RMSSE permanece na tabela. Os resultados de previsão devem ser interpretados como evidência auxiliar sobre a previsibilidade das séries, e não como critério final de escolha da política de reposição. Detalhes adicionais sobre resíduos e previsões por série específica encontram-se

no apêndice.

5.6 Alcance dos Resultados

Os resultados apresentados neste capítulo devem ser interpretados considerando o escopo experimental dos dois experimentos executados. O Experimento 2 ampliou a avaliação inicial ao incorporar 145 séries do estado da Bahia, cinco replicações experimentais, testes estatísticos formais e resultados auxiliares de previsão. Esses avanços fortalecem a análise em relação ao Experimento 1, especialmente por permitirem comparar políticas sob maior diversidade de séries e com suporte estatístico mais consistente.

Ainda assim, a avaliação atual permanece concentrada em séries classificadas no regime *Lumpy*. Essa concentração é relevante porque permite analisar o AIPE em um regime de alta complexidade operacional, caracterizado por baixa frequência e alta variabilidade da demanda. Por outro lado, a generalização para os regimes *Smooth*, *Erratic* e *Intermittent*, bem como para outras regiões da rede varejista e outras bases de dados, depende dos estudos de caso adicionais em andamento (M5 e expansão multiestado).

Algumas escolhas experimentais também delimitam a interpretação dos resultados. O horizonte disponível de 38 ciclos comerciais restringe a observação de mudanças estruturais de longo prazo. Os custos de manutenção, ruptura e pedido foram parametrizados a partir de valores compatíveis com o varejo regional, e diferentes relações entre esses custos podem alterar o desempenho relativo das políticas. Além disso, o prazo de entrega foi mantido fixo em dois ciclos, o que favorece a comparação controlada entre políticas, mas não captura variações operacionais de *lead time*.

De forma semelhante, as políticas aprendidas por reforço são avaliadas como candidatas dentro do *benchmark*, não como evidência direta de desempenho em ambiente de produção.

Os estudos de caso adicionais em andamento (M5 e expansão multiestado, Capítulo 7) darão continuidade a essa avaliação ao ampliar o conjunto de bases de dados, produtos, lojas, regiões e regimes de demanda. Essa ampliação permitirá avaliar a generalização do AIPE, consolidar a geração de rótulos de política dominante e testar o *Policy Selection Engine* em séries não observadas durante o treinamento.

5.7 Discussão dos Resultados

Os resultados preliminares dos dois experimentos executados apoiam a premissa central desta dissertação: o desempenho das políticas de reposição depende do perfil operacional da série analisada. Nenhuma política avaliada domina simultaneamente as demais em custo total de inventário, nível de serviço, ruptura, estabilidade dos pedidos e frequência de reposição. A ampliação de 15 séries na Paraíba para 145 séries na Bahia preservou essa heterogeneidade

e permitiu aplicar validação estatística formal às comparações.

Em relação à literatura analisada no Capítulo 3, os resultados reforçam a relevância de abordagens que não assumem uma política única como solução universal. Políticas clássicas, políticas parametrizadas por meta-heurísticas, políticas aprendidas por reforço e políticas híbridas apresentam vantagens relativas em contextos distintos, apoiando o posicionamento do AIPE como *framework* de seleção contextual. Os estudos de caso adicionais darão continuidade a essa avaliação ao ampliar o *benchmark* para outras bases de dados, estados, produtos e regimes de demanda, permitindo avaliar a capacidade de generalização do AIPE e consolidar o treinamento do PSE.

Tabela 5.6: Comparação de custo entre estratégias de seleção de política com CTI ajustado por estabilidade operacional (Experimento 2, BA, 145 séries, regime *Lumpy*). CTI Adj. $= \mathrm{CTI}_{\mathrm{norm}} + \lambda_{BE} \cdot \mathrm{BE}_{\mathrm{norm}}$, normalizado por escopo global. Redução% calculada contra estratégia A (política única, CTI puro). †Oráculo por série: referência exploratória, não estratégia operacional.

Estratégia	λ	CTI médio	BE médio	NS médio	CTI Adj. médio	Red. CTI vs A (%)	Red. Adj. vs A (%)
A: pol. única (CTI puro)	0.00	433.31	1.1	0.774	0.061	0.0	0.0
B: pol. única (CTI ajustado)	0.00	433.31	1.1	0.774	0.061	0.0	0.0
C: por perfil (CTI puro)	0.00	432.46	1.2	0.782	0.062	+0.2	−1.0
D: por perfil (CTI ajustado)	0.00	432.46	1.2	0.782	0.062	+0.2	−1.0
E: oráculo por série†	0.00	419.29	—	—	—	+3.2	-
A: pol. única (CTI puro)	0.25	433.31	1.1	0.774	0.066	0.0	0.0
B: pol. única (CTI ajustado)	0.25	433.31	1.1	0.774	0.066	0.0	0.0
C: por perfil (CTI puro)	0.25	432.46	1.2	0.782	0.067	+0.2	−1.7
D: por perfil (CTI ajustado)	0.25	433.31	1.1	0.774	0.066	0.0	0.0
E: oráculo por série†	0.25	419.29	—	—	—	+3.2	-
A: pol. única (CTI puro)	0.50	433.31	1.1	0.774	0.070	0.0	0.0
B: pol. única (CTI ajustado)	0.50	433.31	1.1	0.774	0.070	0.0	0.0
C: por perfil (CTI puro)	0.50	432.46	1.2	0.782	0.071	+0.2	−2.3
D: por perfil (CTI ajustado)	0.50	433.31	1.1	0.774	0.070	0.0	0.0
E: oráculo por série†	0.50	419.29	—	—	—	+3.2	-
A: pol. única (CTI puro)	1.00	433.31	1.1	0.774	0.078	0.0	0.0
B: pol. única (CTI ajustado)	1.00	433.31	1.1	0.774	0.078	0.0	0.0
C: por perfil (CTI puro)	1.00	432.46	1.2	0.782	0.081	+0.2	−3.4
D: por perfil (CTI ajustado)	1.00	433.31	1.1	0.774	0.078	0.0	0.0
E: oráculo por série†	1.00	419.29	—	—	—	+3.2	-

CTI Adj. usa normalização global min-max sobre todas as 12 políticas; $\lambda_{BE} = 0$ recupera seleção por CTI puro; A = B = EOQ para todo λ.

Tabela 5.7: Mapeamento empírico de dominância regime→política (CTI puro sob NS ≥ 0.70). "Dominante" é a política com menor CTI entre aquelas que atingem NS ≥ 0.70 no estrato. Fonte: análise estratificada dos dois experimentos executados.

Perfil operacional	Critério principal	Política dominante	Razão
Baixo volume, alta esparsidade	$\hat{\mu} \leq 50$, ADI ≥ 1.32	Jornaleiro	Solução analítica supera RL em T curto
Volume médio, alta intermitência	$50 < \hat{\mu} \leq 500$, $CV^2 \geq 0.49$	GA-DQN	Buffer pré-populado viabiliza convergência
Alto volume, demanda regular	$\hat{\mu} > 500$, ADI < 1.32	EOQ / (s, S)	Hipótese quasi-estacionária é válida
Baixo viés sistêmico	BE baixo como critério primário	GA-DQN	Menor amplificação de variabilidade
Alta cobertura obrigatória	NS ≥ 0.95 como restrição	EOQ	Melhor custo dado NS alto garantido

Tabela 5.8: Resultados agregados dos testes de Wilcoxon: frações de comparações significativas por política e métrica ($\alpha = 0.05$, correção de Holm). GA-DQN: 10 *baselines*; GA-PPO: 10 *baselines*.

Política	CTI	NS	TR	BE	FP	Sig. total
GA-DQN vs *baselines*	8/10	10/10	10/10	7/10	9/10	44/50 (88%)
GA-PPO vs *baselines*	10/10	10/10	10/10	10/10	8/10	48/50 (96%)

Tabela 5.9: Tamanhos de efeito de Cohen (d) para CTI: política híbrida versus *baselines* selecionados, portfólio final de 12 políticas (Seção 4.6). Classificação: $|d| < 0.20$ trivial; 0.20 a 0.50 pequeno; 0.50 a 0.80 médio; > 0.80 grande.

Política A	Política B	d (CTI)	d (NS)	Magnitude
GA-DQN	EOQ	$+2.319$	-1.310	ambos: grande
GA-DQN	(s, S)	$+2.003$	-1.321	ambos: grande
GA-DQN	Newsvendor	$+6.170$	$+1.006$	ambos: grande
GA-DQN	PPO	-4.975	-1.365	ambos: grande

Tabela 5.10: Métricas de qualidade da previsão por modelo (médias sobre 145 séries, BA, regime *Lumpy*). MASE e RMSSE são escalados em relação ao modelo *naïve*; valores < 1 indicam desempenho melhor que o *naïve*. sMAPE em %. Valores menores indicam melhor desempenho.

Modelo	MASE	sMAPE (%)	RMSSE
LSTM	0.76	193.5	0.86
XGBoost	1.05	148.8	0.99
ANN	1.12	135.8	0.99

6

Considerações Finais e Próximas Etapas

Os resultados preliminares apoiam uma resposta positiva à pergunta central, ainda que limitada ao escopo dos dois experimentos executados. O *benchmark* de 12 políticas sobre dados reais de alta intermitência (regime *Lumpy*) indica que nenhuma política domina todas as métricas: cada política apresentou vantagem em pelo menos uma métrica e em pelo menos uma série, apoiando a hipótese de heterogeneidade genuína. A posição da série no plano ADI $\times$ CV^2 correlaciona-se com o desempenho relativo das políticas, indicando que a relação regime$\rightarrow$política pode ser explorada por um meta-modelo supervisionado.

O Experimento 2, executado sobre 145 séries do estado da Bahia com cinco replicações independentes, amplia os achados do Experimento 1. A ampliação de escopo preserva a heterogeneidade observada, agora com validação estatística formal (testes de Wilcoxon e Friedman, acompanhados por tamanho de efeito de Cohen), indicando que parte relevante das diferenças de desempenho entre políticas não é explicada apenas por variação amostral. No conjunto das 145 séries, EOQ (NS = 0.94, CTI = R$ 628) e (s, S) (NS = 0.94, CTI = R$ 655) oferecem o melhor compromisso custo-serviço no agregado, enquanto a dispersão pronunciada de CTI entre séries (coeficientes de variação acima de 100% para políticas híbridas) indica que a vantagem de qualquer política depende do perfil operacional da série individual.

Os rótulos de política dominante produzidos pelo *benchmark* (consolidados na Tabela 5.7) constituem a base inicial para o treinamento do PSE, cuja capacidade de generalização para novas séries, regiões, regimes e bases de dados será testada nos estudos de caso adicionais em andamento (M5 e expansão multiestado, Capítulo 7). A concentração das séries dos dois experimentos no regime *Lumpy* indica que o AIPE foi avaliado em um regime de alta complexidade operacional, mas ainda requer expansão para os demais quadrantes de Syntetos-Boylan e demais regiões geográficas. Como referência de magnitude: no regime *Lumpy* do Experimento 1, o GA-DQN reduziu CTI em 48% e rupturas em 55% em relação à política (s, S) padrão, com efeito chicote reduzido de 119.4 para 5.0.

A comparação direta entre política única global e seleção por perfil operacional (Seção 5.3.5) reforça a motivação do AIPE ao mostrar que a escolha contextual pode alterar o custo de inventário, ainda que, no regime *Lumpy* do Experimento 2, essa redução tenha sido modesta em magnitude ($3{,}6\%$ de redução de CTI ajustado médio, R$ 895,11 para R$ 862,64, estatisticamente significativa por Wilcoxon pareado com correção de Holm, $p_{\text{Holm}} = 0{,}020$), sem queda estatisticamente significativa de NS médio ($0{,}942$ para $0{,}937$; $p_{\text{Holm}} = 0{,}111$). Esse achado não deve ser lido como ganho automático, mas como evidência de que a seleção por perfil produz diferença econômica mensurável mesmo dentro de um único regime de demanda, sem o *trade-off* de serviço observado em rodadas anteriores à correção da função objetivo (Seção 4.6); a análise complementar de CTI ajustado por estabilidade sugere ganhos potencialmente maiores quando o efeito *bullwhip* é penalizado explicitamente, mas essa leitura é preliminar e não substitui o critério principal baseado em CTI ajustado sob restrição de NS. A seleção por perfil não deve ser interpretada como estratégia universalmente mais adequada, mas como mecanismo capaz de adaptar a escolha de política ao comportamento operacional da série.

As conclusões se limitam ao escopo dos dois experimentos executados; os estudos de caso adicionais em andamento (M5 e expansão multiestado) estenderão a avaliação para novas bases de dados, estados, produtos e regimes de demanda, sempre como evidência de validade externa do AIPE, e não como novo objetivo experimental independente. Em particular, a capacidade de generalização do PSE treinado sobre os rótulos atuais ainda não foi avaliada fora do regime *Lumpy*, e não deve ser considerada validada até a conclusão dessa etapa.

6.1 Contribuições

Os resultados dos dois experimentos executados indicam que o desempenho das políticas de reposição varia com o regime operacional da demanda e que essa relação pode ser modelada via aprendizado supervisionado. Essa evidência apoia a proposta do *Adaptive Inventory Policy Engine* (AIPE) como *framework* metodológico de seleção adaptativa e orienta os estudos de caso adicionais em andamento, cuja função é fortalecer e delimitar a validade externa dessa proposta, não substituí-la como contribuição central. A contribuição da dissertação não está na criação de novos algoritmos de otimização ou aprendizado por reforço, mas na formulação e avaliação desse *framework* de seleção contextual de políticas de reposição, aplicado a dados reais de varejo brasileiro.

A primeira contribuição é o estudo empírico com dados reais de uma rede varejista brasileira sob demanda altamente intermitente, escopo pouco coberto pela literatura: o Experimento 1 avaliou 15 lojas da Paraíba (produto 48130) e o Experimento 2 expandiu para 145 combinações (loja, SKU) do estado da Bahia com cinco replicações independentes, totalizando 8.700 pontos de avaliação sobre o portfólio de 12 políticas candidatas (clássicas, parametrizadas por metaheurísticas, aprendidas por reforço e híbridas GA-RL).

A segunda contribuição é a formulação e a avaliação da seleção contextual de políticas por perfil operacional, e sua comparação direta com a adoção de uma política única global. No Experimento 2, a seleção por perfil reduziu o CTI ajustado médio em $3{,}6\%$ em relação à política única (EOQ), estatisticamente significativo ($p_{\text{Holm}} = 0{,}020$), sem queda estatisticamente significativa de NS médio ($0{,}942$ para $0{,}937$; $p_{\text{Holm}} = 0{,}111$; Seção 5.3.5); o resultado constitui evidência direta de que a decisão de reposição se beneficia de ser tratada como problema de seleção contextual, e não de escolha de uma única política para toda a rede.

A terceira contribuição é a infraestrutura experimental reprodutível que viabiliza as duas anteriores: o *pipeline* Kedro integra caracterização das séries, simulação comparável das políticas candidatas, validação estatística e geração de rótulos de política dominante, com rastreabilidade completa via parâmetros YAML, configurabilidade por experimento (Experimento 1: PB + 1 SKU; Experimento 2: BA, 145 séries) e reprodutibilidade com `kedro run`. A taxonomia Syntetos-Boylan com Perfis Operacionais de Demanda (POD) estruturou essas análises, calculando 17 características operacionais por série (ADI, CV^2, *burstiness*, entropia, tendência, sazonalidade) e produzindo cinco PODs orientados à decisão de política, base do meta-modelo AIPE.

A quarta contribuição é a avaliação da arquitetura híbrida GA-RL como uma das políticas especialistas do portfólio, não como algoritmo novo: a inicialização do treinamento por GA favorece convergência em horizontes curtos ($T = 38$ ciclos), com vantagem observada em regimes de alta intermitência e volume médio. No Experimento 2, os testes de Wilcoxon pareado, Friedman, Nemenyi e Cohen's d foram aplicados sobre as 145 séries com correção de Holm para comparações múltiplas; GA-DQN apresentou diferenças significativas em 88% das comparações (44/50) e GA-PPO em 96% (48/50), com os efeitos mais relevantes em CTI (GA-DQN vs. EOQ, $d = +1.284$, grande) e NS ($d = -1.043$, grande), quantificando o *trade-off* custo-serviço com magnitude prática estabelecida.

A quinta contribuição é o módulo de previsão de demanda com validação *walk-forward*: três modelos (LSTM, XGBoost e ANN) foram avaliados por validação temporal estrita sobre as 145 séries, com o LSTM apresentando desempenho melhor que a previsão *naïve* em MASE médio ($0.76 < 1$) e o XGBoost apresentando o menor sMAPE (148.8%); a heterogeneidade pronunciada de MASE entre séries (0.49 a 1.87) motiva a seleção adaptativa de modelo. Esse módulo permanece auxiliar ao AIPE, contribuindo com sinais preditivos para a camada de entrada da seleção contextual.

Em suma, o portfólio de 12 políticas e sua comparação sistemática são o meio experimental usado para construir o *benchmark* e gerar rótulos de política dominante; isoladamente, não constituem a contribuição principal da dissertação, que reside na formulação, implementação e avaliação empírica da seleção contextual como alternativa à política única global.

6.2 Implicações Operacionais

Do ponto de vista operacional, os resultados dos dois experimentos oferecem indicações preliminares para operadores de varejo com perfil de demanda intermitente:

- Para séries de volume médio no regime *Lumpy* (Experimento 1): os resultados indicam que a arquitetura GA-DQN (NS = 0.933, CTI = R$ 10.854 no Experimento 1) apresenta equilíbrio custo-serviço mais favorável que as heurísticas clássicas neste recorte. O treinamento é realizado uma única vez por série e pode ser integrado a rotinas periódicas de atualização de parâmetros.

- Para o conjunto de 145 séries da Bahia (Experimento 2): EOQ apresenta o menor custo total de inventário entre as políticas de alto serviço (NS = 0.94, CTI = R$ 628), 4% mais econômico que (s, S) (CTI = R$ 655) com NS equivalente. Os resultados sugerem que o AIPE tenderia a recomendar EOQ para séries com ADI moderado e baixa variabilidade das quantidades.

- Sobre a escolha entre políticas e seu efeito na cadeia: nos dois experimentos, políticas ajustadas ao perfil da série apresentaram potencial de reduzir custo total de inventário e amplificação de variabilidade de pedidos (*bullwhip*) em relação à política (s, S) tradicional, indicando impacto possível na estabilidade operacional a montante. A título de referência, a variância amplificada do Experimento 1 foi reduzida de 119.4 (política (s, S) padrão) para 5.0 (GA-DQN); no Experimento 2, GA-DQN apresenta o menor BE do portfólio final (0,16), em escopo distinto.

- Sobre a operacionalização: o *pipeline* requer apenas dados de histórico transacional exportado em formato tabular, podendo ser integrado a rotinas periódicas de monitoramento e atualização de parâmetros. A abordagem tem potencial para reduzir a dependência de ajuste manual por série, sujeito à validação em escala ampliada prevista nos estudos de caso adicionais.

As próximas etapas de continuidade, incluindo os estudos de caso adicionais (M5 e expansão multiestado), treinamento do PSE, análise de sensibilidade, otimização em janela móvel e cronograma consolidado, são detalhadas no Capítulo 7.

7

Plano de Continuidade e Cronograma

Este capítulo organiza as atividades já concluídas, em andamento e planejadas para a continuidade da dissertação. Os dois experimentos reportados no Capítulo 5 e discutidos no Capítulo 6 consolidam a etapa empírica inicial: estudo piloto na Paraíba e expansão experimental na Bahia. A partir desses experimentos iniciais, a continuidade da dissertação segue um princípio metodológico explícito: o AIPE, não a base de dados, é a contribuição central; cada base adicional (M5, benchmark público internacional, e a expansão multiestado da rede varejista nacional) é incorporada como **estudo de caso** cuja função é validar e fortalecer o *framework* — testar se a heterogeneidade regime→política observada na Bahia se replica sob condições de demanda, escala e proveniência de dados diferentes, não ampliar por si só a cobertura geográfica. A etapa seguinte finaliza o treinamento do PSE, avalia sensibilidade dos parâmetros e transforma o *pipeline* em um mapa operacional de recomendação de políticas.

7.1 Visão Geral das Atividades Restantes

Formulação do problema e revisão da literatura. Esta atividade consolidou a definição de política de reposição como regra de decisão parametrizada, a função objetivo baseada no custo total de inventário sob restrição de serviço, as famílias de políticas candidatas e o posicionamento em relação aos trabalhos relacionados. Ela fornece a base conceitual que sustenta o AIPE como *framework* metodológico de seleção contextual.

Benchmarking do Experimento 1. O primeiro experimento funcionou como estudo piloto na Paraíba, com 15 lojas e um produto de alta intermitência. Essa etapa validou o ambiente de simulação, as métricas de avaliação e o portfólio inicial de 12 políticas, permitindo identificar comportamentos degenerados e motivar a ampliação experimental.

Pipeline Kedro e módulo de previsão. O *pipeline* Kedro organiza o processamento dos dados, a extração de características, a previsão auxiliar e a rastreabilidade dos artefatos. Essa infraestrutura permite recompor resultados, comparar políticas sob as mesmas condições experimentais e integrar sinais preditivos à camada de entrada do AIPE.

Simulação do Experimento 2. O segundo experimento ampliou a avaliação para 145 séries do estado da Bahia, com cinco replicações independentes por política. Essa etapa permitiu análise por perfil operacional, validação estatística formal e comparação entre uma política única global e a seleção por perfil.

Validação estatística. A validação estatística formaliza a comparação entre políticas por meio de Wilcoxon pareado, Friedman, Nemenyi e tamanho de efeito. Essa atividade separa diferença amostral de evidência operacional mais consistente e reduz o risco de interpretar flutuações do *benchmark* como dominância real.

Módulo `demand_profiling` e PODs. O módulo `demand_profiling` define perfis operacionais configuráveis usados para estratificação e como entrada interpretável do PSE. Os PODs não substituem a taxonomia Syntetos-Boylan; eles adicionam uma camada operacional que aproxima características estatísticas de situações de decisão em estoque.

7.2 Estudos de Caso Adicionais: Validação Externa e Validação em Escala

Dois estudos de caso adicionais estão em andamento, ambos subordinados ao mesmo objetivo: verificar se a heterogeneidade regime→política e o comportamento do portfólio de políticas observados no Experimento 2 (Bahia) se replicam sob condições estruturalmente diferentes de demanda, escala e origem de dados. Nenhum dos dois substitui o Experimento 2 como referência central de resultados; ambos servem para testar os limites de validade externa do AIPE.

7.2.1 Estudo de Caso 3: Benchmark Público M5 (Walmart)

O M5 é o estudo de caso metodologicamente mais forte entre os dois em andamento, precisamente porque não é uma base escolhida por conveniência: é a mesma base usada por Zabraoui et al. (2025) para validar a arquitetura GA-DQN que fundamenta parte do portfólio desta dissertação, e uma das bases de referência mais usadas na literatura de previsão de demanda e otimização de estoque em geral (competição M5, milhares de séries reais de varejo). Adotá-la como estudo de caso empresta ao AIPE a força de ancoragem bibliográfica que a própria base

já tem, em vez de depender só da originalidade do recorte brasileiro. O recorte segue o filtro de Zabraoui et al. (2025): categoria *FOODS* e coeficiente de variação CV $\geq 1{,}5$, reduzindo o total de 30.490 séries do M5 para 2.408 séries de alta intermitência, comparáveis em regime ao recorte *Lumpy* avaliado na Bahia.

O valor metodológico desse estudo de caso é duplo. Primeiro, permite comparar o portfólio final desta dissertação diretamente contra o artigo-base, em sua própria base de validação, isolando o efeito da ampliação do portfólio (Seção 4.6.5) e das correções de fidelidade de hiperparâmetros do efeito da base de dados. Segundo, testa a robustez do achado central do AIPE (heterogeneidade regime→política) fora do contexto de varejo brasileiro, numa base de demanda de alto volume e escala muito distinta da Bahia. Com o M5, a dissertação passa a se apoiar em **duas bases de dados reais** como estudo de caso (a rede varejista brasileira, Experimento 2, e o M5, Walmart), não numa única fonte: um achado que se sustenta nas duas é evidência de validade externa muito mais forte do que o mesmo achado replicado só dentro da mesma base, com o mesmo viés de coleta e o mesmo contexto de mercado.

Resultados preliminares. A execução completa do portfólio final sobre o recorte M5 (12 políticas $\times$ 2.408 séries, 28.896 avaliações) foi concluída em 19/08/2026, sob o mesmo ambiente de simulação e os mesmos parâmetros de custo usados na Bahia (*lead time*$= 2$, $h = 1$, $c_s = 5$, $K = 50$). Comparado ao recorte *Lumpy* da Bahia, o recorte M5 é mensuravelmente mais severo em toda dimensão de caracterização disponível: ADI mediano de 2,58 contra 2,00, CV^2 mediano de 2,24 contra 1,75, e fração de ciclos com demanda nula de 61% contra 50%. Note-se que essa severidade é deliberada, não acidental: o corte de Zabraoui et al. (2025) usado como referência filtra a categoria *FOODS* por CV$\geq 1{,}5$, mas os próprios autores reportam validar GA-DQN sobre uma faixa de CV típico < 1 do M5 (Seção 3), consideravelmente mais regular que o recorte de alta intermitência aqui avaliado.

Sob essa severidade adicional, o nível de serviço observado cai de forma acentuada em relação à Bahia. Das 2.408 séries, 2.350 (97,6%) caem no perfil *Sparse High Impact*, no qual apenas duas das doze políticas atingem o limiar mínimo de NS$\geq 0{,}70$: PPO (NS$= 0{,}986$) e SA (NS$= 0{,}853$). As dez políticas restantes, incluindo EOQ (NS$= 0{,}119$), (s, S) (NS$= 0{,}120$) e a própria GA-DQN do artigo-base (NS$= 0{,}459$), ficam abaixo do limiar. O PPO, contudo, atinge esse resultado por meio de um padrão degenerado já discutido no Capítulo 5 para outras políticas: frequência de pedidos de $99{,}3\%$ dos ciclos, ou seja, pede quase sempre, garantindo NS alto ao custo de TIC muito superior ao das demais políticas viáveis. O relatório de dominância por perfil sinaliza esse caso explicitamente como *dominante degenerado, interpretar com cautela*; sob essa ressalva, o SA é a política não degenerada de melhor desempenho no perfil que concentra a quase totalidade do M5 avaliado, com frequência de pedidos moderada ($6{,}3\%$ dos ciclos).

Nos dois perfis restantes, de menor representação e caráter exploratório ($n < 20$ e $n = 40$), o padrão de dominância muda novamente: (s, S) domina o perfil *Unstable Trend* ($n = 40$, NS$=$

$0{,}798$, oito das doze políticas viáveis), e a própria GA-DQN domina o perfil *High Vol. Seasonal* ($n = 18$, NS$= 0{,}762$), desta vez de forma não degenerada, ainda que o PPO também seja tecnicamente viável ali (NS$= 0{,}954$) ao custo de pedir em 100% dos ciclos e de um TIC quase duas vezes maior. Assim, mesmo restrito a uma única base de dados e um único recorte de regime, nenhuma política do portfólio, incluindo a arquitetura híbrida do próprio artigo-base, domina de forma consistente entre os três perfis operacionais identificados: o achado central desta dissertação (heterogeneidade regime$\rightarrow$política) se replica dentro do M5, reforçando a motivação do AIPE de forma independente da rede varejista brasileira. A validação estatística formal (Wilcoxon, Friedman) e o treinamento do PSE sobre esses rótulos permanecem como próximos passos deste estudo de caso.

7.2.2 Estudo de Caso 4: Expansão Multiestado (Base Nacional)

O quarto estudo de caso aplica o *pipeline* completo à base nacional da rede varejista, com aproximadamente $10{,}4$ milhões de séries distribuídas em 26 estados e no Distrito Federal. Dado o volume, a avaliação usa um recorte por atividade (*top-N* lojas por estado) em vez da base íntegra, evitando o esgotamento de memória observado na tentativa de processamento irrestrito. O processamento por estado e por SKU amplia a diversidade de regimes, regiões e produtos, permitindo testar se os padrões observados nos experimentos da Paraíba e da Bahia se mantêm em escala ampliada.

Esse estudo de caso também aumenta a cobertura dos quadrantes Syntetos-Boylan e dos PODs. Com maior diversidade de séries, será possível avaliar heterogeneidade regional, diferenças entre categorias de produto e estabilidade das políticas recomendadas em contextos operacionais distintos — sempre como evidência adicional a favor (ou contra) a validade do AIPE, não como objetivo de cobertura geográfica em si.

7.3 Treinamento e Avaliação do PSE

Com os resultados dos experimentos executados e dos estudos de caso adicionais (Seção 7.2), o PSE será treinado como componente supervisionado de recomendação. A entrada será formada pelas características operacionais das séries e pelos PODs; o rótulo será a política viável de melhor desempenho observada no *benchmark*, segundo CTI sob restrição de NS.

A avaliação do PSE será feita por validação cruzada estratificada por POD e por testes fora da amostra geográfica. O objetivo é verificar se o meta-modelo aprende uma associação estável entre perfil operacional e política recomendada, sem transformar o AIPE em uma nova política de reposição ou em sistema transacional.

7.3.1 Validação de Robustez: Agrupamento por Perfil na Calibração

Além da seleção de política por perfil, discutida no Capítulo 5, uma questão relacionada, mas distinta, é se o próprio processo de calibração das políticas parametrizadas se beneficia de agrupar séries do mesmo perfil operacional (POD). Duas estratégias de calibração foram comparadas: agrupar as séries de um mesmo perfil antes de ajustar os parâmetros de cada política (*com_perfil*) e calibrar cada série individualmente (*sem_perfil*). A comparação usa o mesmo protocolo de teste pareado adotado no Capítulo 5 (Wilcoxon *signed-rank* com correção de Holm, sobre CTI ajustado, TIC e NS), replicado em seis configurações independentes: as bases Bahia e M5, cada uma com o ponto de corte entre janela de treino e janela de avaliação deslocado (dois cortes adicionais por base, além do corte de referência), de forma a verificar se a vantagem observada depende da janela temporal usada na calibração.

O agrupamento por perfil reduz o custo ajustado (CTI ajustado) e o custo bruto (TIC) de forma estatisticamente significativa nas seis configurações, com o número de pares comparados praticamente idêntico entre cortes de treino distintos dentro da mesma base (o que descarta tamanho de amostra como explicação para eventuais divergências). O nível de serviço (NS) é a métrica menos estável: a diferença nunca é significativa na Bahia e inverte de sinal entre os cortes de treino do M5.

Por política, o padrão de robustez é heterogêneo. EOQ, (s, S) e *Capped Base-Stock* favorecem a calibração por perfil nas seis configurações, de forma significativa. *Fixed Interval* e *Vendor-Responsive* favorecem a calibração individual na maioria das configurações, sem inverter de forma significativa em nenhuma delas, replicando o padrão já identificado em experimentos anteriores para essas duas heurísticas de limiar adaptativo. Já GA-DQN, PPO e Newsvendor invertem de direção entre configurações, inclusive dentro da mesma base: não constituem achado estável e não devem ser generalizados a partir desta validação.

Esses resultados sugerem que o benefício de considerar o perfil operacional pode não se restringir à etapa de seleção de política, foco central desta dissertação, estendendo-se também à etapa de calibração de parâmetros para famílias específicas (políticas clássicas de estrutura fechada, como EOQ, (s, S) e *Capped Base-Stock*), enquanto heurísticas de limiar adaptativo parecem se beneficiar mais de calibração individual por série. Trata-se de validação preliminar de robustez, não de um resultado central reportado no Capítulo 5; o aprofundamento dessa análise, incluindo mais pontos de corte temporal e a investigação da instabilidade observada em GA-DQN, PPO e Newsvendor, é tratado como trabalho futuro nos estudos de caso adicionais.

7.4 Análise de Sensibilidade e Mapa de Recomendação

A análise de sensibilidade testará como custos de falta e manutenção, prazo de entrega, limiares dos PODs e regimes de demanda afetam a política recomendada. Essa etapa é necessária porque uma recomendação obtida em um cenário de custo ou serviço pode deixar de ser ade-

quada quando as condições operacionais mudam.

O resultado esperado é um mapa de recomendação por regime e perfil operacional. Esse mapa traduzirá os achados do *benchmark* e do PSE em regras interpretáveis, indicando em quais condições cada família de política tende a ser mais apropriada.

7.5 Otimização em Janela Móvel

A versão atual avalia as políticas no horizonte experimental disponível para cada série. Essa escolha é adequada para comparar métodos sob um mesmo recorte temporal, mas pode gerar parametrizações sensíveis ao horizonte observado.

Como atividade futura, será testada a otimização em janelas móveis $[i, i+T]$, atualizando parâmetros à medida que novos ciclos de demanda são observados. Essa extensão reduz comportamento míope, aproxima o processo de uma operação real em *rolling horizon* e permite avaliar quando uma política deve ser recalibrada.

7.6 Produção Científica e Escrita da Dissertação

Os resultados do *benchmark*, da comparação entre política única e seleção por perfil, do treinamento do PSE e dos estudos de caso adicionais (M5 e expansão multiestado, Seção 7.2) serão candidatos a publicações adicionais. A submissão ao SBPO 2026 permanece como uma etapa de disseminação dos resultados iniciais, enquanto os artigos seguintes poderão explorar a validação externa via M5, a expansão multiestado e o mapa de recomendação.

A escrita final consolidará resultados, limitações, validação externa e em escala, análise de sensibilidade e discussão metodológica. A defesa deverá apresentar o AIPE como *framework* de seleção contextual de políticas, com o PSE como componente supervisionado de recomendação e a Bahia, o M5 e a base nacional como estudos de caso que sustentam essa proposta.

7.7 Cronograma Consolidado

A Tabela 7.1 resume as atividades concluídas, em andamento e planejadas. A tabela deve ser lida em conjunto com as descrições anteriores: ela organiza a sequência temporal, mas a justificativa metodológica de cada atividade foi apresentada nas seções precedentes.

Tabela 7.1: Cronograma de atividades (referência: maio de 2026). ✓: concluído; ●: em andamento; ○: planejado.

Atividade	2024 S2	2025 S1	2025 S2	2026
Formulação do problema e revisão de literatura	✓			
Benchmarking Experimento 1 (15 lojas, PB, 12 políticas)	✓	✓		
Pipeline Kedro e módulo de previsão de demanda		✓	✓	
Simulação Experimento 2 (145 séries, BA, 5 replicações)			✓	
Validação estatística (Wilcoxon, Friedman, Cohen's d)			✓	
Módulo `demand_profiling` e PODs			✓	
Revisão do portfólio (Seção 4.6.5) e correções de fidelidade				✓
Estudo de Caso 3: benchmark M5 (Walmart, vs. artigo-base)				●
Estudo de Caso 4: expansão multiestado (base nacional)				●
Treinamento e avaliação do PSE				●
Análise de sensibilidade e mapa de recomendação				○
Otimização em janela móvel				○
Submissão artigo SBPO 2026				○
Submissão de artigos adicionais				○
Escrita e defesa da dissertação				●

Apêndice A

Matriz de Parâmetros Experimentais

Este apêndice consolida os parâmetros utilizados nos experimentos reportados, organizados por camada experimental. A formulação conceitual de cada política permanece no Capítulo 2, enquanto sua instanciação experimental é descrita no Capítulo 4; o registro aqui serve para auditoria e reprodução. Os valores foram obtidos a partir das configurações, scripts e artefatos versionados do projeto. A organização segue a sequência experimental: parâmetros globais (Tabela A.1), políticas clássicas e meta-heurísticas (Tabela A.2), agentes de aprendizado por reforço e políticas híbridas (Tabela A.3), previsão e geração de rótulos (Tabela A.4) e ambiente de validação e reprodução (Tabela A.5). **Nota geral:** salvo indicação contrária nas tabelas, todo componente estocástico (meta-heurísticas, agentes de RL, PSE) usa semente fixa $= 42$; essa linha não é repetida individualmente em cada tabela.

Tabela A.1: Parâmetros globais do experimento.

Componente	**Parâmetro**	**Valor usado**	**Observação**
Dados			
Dados	estado	BA	UF selecionada para a análise
Dados	período	jan/2023 a abr/2025	17 ciclos por ano
Dados	registros transacionais	≈ 48 milhões	base completa da rede varejista
Dados	produtos	$\approx 12\,000$	base completa
Dados	periodicidade	ciclos sazonais	17 ciclos por ano
Dados	tratamento de zeros	preenche com zero	ciclos ausentes completados
Dados	filtro min. de ciclos com venda	17	séries com menos ciclos positivos são removidas
Dados	janela de atividade do produto	3 ciclos	produto considerado ativo se vendeu nos últimos 3 ciclos
Dados	status incluídos	Ativo	produtos com status diferente são excluídos
Dados	tipos de venda excluídos	Brinde	transações de brinde não entram na simulação
Dados	deduplicação	por armazém, produto, loja e ciclo	chave de deduplicação dos registros
Ambiente de simulação			
Ambiente	lead time	2 ciclos	uniforme; mesmo valor para todas as políticas

(continua)

(continuação da Tabela A.1)

Componente	Parâmetro	Valor usado	Observação
Ambiente	estoque inicial I_0	escalonado por série	$\text{rop_ref} = \hat{\mu}L + z\hat{\sigma}\sqrt{L}$; ajustado por série
Ambiente	tipo de falta	perda de venda	demanda não atendida é perdida; sem acúmulo
Ambiente	regra de arredondamento	inteiro superior	aplicada a todos os pedidos calculados
Ambiente	frequência de reavaliação (AIPE)	6 ciclos	intervalo Δt definido conceitualmente
Custos			
Custos	custo de manutenção h	1,0	por unidade por ciclo
Custos	custo de ruptura c_s	5,0	por unidade de demanda não atendida
Custos	custo fixo de pedido c_o^{fix}	50,0	por ordem emitida
Custos	custo variável de pedido c_o^{var}	0,5	por unidade pedida
Custos	razão c_s/h	5,0	nível de serviço crítico $\approx 83\%$
Custos	unidade monetária	adimensional	valores relativos, não em R$
Custos	custos globais ou por série	globais	mesmos parâmetros para todas as séries
Avaliação			
Avaliação	número de replicações	5	replicações independentes por série
Avaliação	semente global	42	fixa para todas as execuções
Avaliação	modo de avaliação	*walk-forward*	janela deslizante; 17 ciclos de treino
Avaliação	métricas reportadas	CTI, NS, TR, BE, FP	definição formal no Capítulo 3
Avaliação	limiar mínimo de NS (viabilidade)	0,70	política abaixo do limiar é considerada inviável

Nas políticas clássicas, os parâmetros de reposição são calculados diretamente a partir das estatísticas históricas da série e dos parâmetros globais de custo. Nas meta-heurísticas (GA e SA no portfólio final), cada candidato é uma parametrização (s, Q) da política, avaliada por execução no ambiente de simulação; a formulação de cada método (representação de solução, operadores de busca) foi apresentada no Capítulo 2 e sua instanciação experimental no Capítulo 4: a tabela a seguir registra apenas os valores de configuração usados.

Tabela A.2: Parâmetros das políticas clássicas e meta-heurísticas.

Política	Parâmetro	Valor usado	Observação
EOQ			
EOQ	lote econômico Q^* (Q_{ref} na implementação)	$\sqrt{2\hat{\mu}T\,c_o^{\text{fix}}/h}$	c_o^{fix}=50 instancia K; h=1; $\hat{\mu}$ estimado por série; T é o horizonte de referência
EOQ	ponto de pedido s (s_{ref} na implementação)	$\hat{\mu}L + z\hat{\sigma}\sqrt{L}$	L=2; z=1,28 para nível de serviço de referência de 90%; ponto de pedido também chamado de ponto de reposição
(s,S)			
(s,S)	ponto de pedido s	$\hat{\mu}L + z\hat{\sigma}\sqrt{L}$ (igual a s_{ref} da EOQ)	L=2; z=1,28
(s,S)	nível alvo S	$s + Q^*$	Q^* derivado da EOQ (Q_{ref})

(continua)

(continuação da Tabela A.2)

Política	Parâmetro	Valor usado	Observação
(s,S)	fator de segurança z	$1{,}28$	quantil configurado para o nível de serviço de referência de 90%
Jornaleiro (Newsvendor)			
Jornaleiro	razão crítica CR	$c_s/(c_s+h) = 5/6 \approx 0{,}833$	
Jornaleiro	nível ótimo y^*	quantil(0,833) da previsão	via distribuição empírica
GA (Algoritmo Genético)			
GA	variáveis otimizadas	ponto de reposição e lote	(s,Q) contínuos
GA	tamanho da população	100	
GA	número de gerações	50	
GA	taxa de crossover	0,8	uniforme (cada gene herda do pai A ou B, p=0,5)
GA	taxa de mutação	0,05 (inicial)	adaptativa: decai linearmente até $0{,}05 \times 0{,}2$ na última geração
GA	método de seleção	torneio de tamanho 3	
GA	função de avaliação	$1{,}0 \times \mathrm{NS} - 0{,}0001 \times \mathrm{CTI}$	aptidão escalar; rótulos finais usam menor CTI viável
SA (Simulated Annealing)			
SA	variáveis otimizadas	ponto de reposição e lote	(s,Q) contínuos
SA	temperatura inicial	1000,0	
SA	fator de resfriamento	0,95	geométrico por iteração
SA	iterações máximas	500	
SA	minimizador local	Nelder-Mead	`scipy.optimize.dual_annealing`

PSO e DE foram testados preliminarmente sobre o mesmo espaço de parametrização do GA/SA (Seção 4.6.5) e permanecem implementados, mas não compõem o portfólio final avaliado nesta dissertação; seus parâmetros de configuração não são reportados aqui por não integrarem os resultados reportados no Capítulo 5.

Nos agentes de aprendizado por reforço e nas políticas híbridas GA-RL, a formulação (estado, ação, recompensa, mecanismo de inicialização por GA) foi apresentada nos Capítulos 2 e 4; a tabela a seguir registra apenas os valores de configuração usados nos experimentos.

Tabela A.3: Parâmetros dos agentes de aprendizado por reforço e políticas híbridas.

Política	Parâmetro	Valor usado	Observação
Ambiente compartilhado (todos os agentes)			
Ambiente	vetor de estado (dim. 1 a 3)	$I_t/I_0,\ \hat{D}/\mu,\ \mathrm{OP}/I_0$	nível de estoque, previsão, pedido aberto
Ambiente	vetor de estado (dim. 4 a 6)	$\mu_6/\mu,\ \sigma_6/\sigma,\ t/T$	tendências de curto prazo e posição no horizonte
Ambiente	função de recompensa	$-(hI_t + c_sS_t + K\mathbf{1}_{Q>0} + c_vQ_t)$	S_t = demanda não atendida
Ambiente	espaço de ações (DQN/PPO)	20 ações discretas	$Q \in [0, \max(200, 12\mu)]$
Ambiente	número de episódios (DQN/PPO)	1 000	piso do artigo-base (Zabraoui et al., 2025)
DQN			
DQN	fator de desconto γ	0,95	

(continua)

(continuação da Tabela A.3)

Política	Parâmetro	Valor usado	Observação
DQN	ε	0,2	fixo, sem decaimento (Tab. 4 do artigo-base)
DQN	tamanho do batch	64	
DQN	tamanho do *replay buffer*	10 000	
DQN	frequência de atualização da rede-alvo	10 episódios	
DQN	arquitetura da Q-network	$[6] \to [64, 64] \to [20]$	duas camadas ocultas
DQN	taxa de aprendizado	0,001	padrão do código; não exposto no YAML
DQN	recorte de gradiente	$[-1{,}0,\ 1{,}0]$	
PPO			
PPO	fator de desconto γ	0,99	
PPO	epsilon de recorte	0,2	razão de probabilidade recortada em $[1-\varepsilon,\ 1+\varepsilon]$
PPO	épocas de otimização por rollout	4	
PPO	taxa de aprendizado	0,0003	
PPO	arquitetura do ator	$[6] \to [64, 32] \to [20]$	saída em logits
PPO	arquitetura do crítico	$[6] \to [64, 32] \to [1]$	saída em valor escalar
PPO	estimativa de vantagem	$A_t = G_t - V(s_t)$, normalizada	$(G - \bar{G})/(\sigma_G + 10^{-8})$
GA-DQN			
GA-DQN	parâmetros do GA	herdados (ver Tabela A.2)	50 gerações
GA-DQN	parâmetros do DQN	herdados (ver acima)	
GA-DQN	tamanho do *replay buffer* pré-populado	1 000	trajetórias geradas pelo GA
GA-DQN	episódios de refinamento RL	200	
GA-DQN	regra de integração GA $\to$ DQN	se $(I_t + \mathrm{OP}) \le s + \mathrm{SS}$: $Q = \max(Q_{\mathrm{DQN}},\ 0{,}5 \cdot Q_{\mathrm{GA}})$; caso contrário: $Q = 0$	

SARSA e GA-PPO foram testados preliminarmente (parâmetros análogos aos de DQN/GA-DQN acima) e permanecem implementados, mas não compõem o portfólio final avaliado nesta dissertação (Seção 4.6.5): SARSA por não ter estado da arte identificável em veículo relevante para inventário, e GA-PPO por não ter referência publicada como âncora.

Tabela A.4: Parâmetros de previsão, características operacionais e geração de rótulos.

Componente	Parâmetro	Valor usado	Observação
Previsão auxiliar			
Previsão	modelos utilizados	LSTM, ANN, XGBoost, Croston, ARIMA	ensemble de previsão
Previsão	janela de entrada (lookback)	6 ciclos	
Previsão	ciclos mínimos de treino	17	
Previsão	modo *walk-forward*	desativado	previsão em janela fixa
Previsão	horizonte de previsão	1 ciclo à frente	
LSTM	hidden size	64	
LSTM	épocas	50	
LSTM	batch size	16	
LSTM	taxa de aprendizado	0,001	
ANN / MLP	camadas ocultas	$[64, 32]$	
ANN / MLP	iterações máximas	200	

(continua)

(continuação da Tabela A.4)

Componente	Parâmetro	Valor usado	Observação
ANN / MLP	early stopping	ativo	
ANN / MLP	fração de validação	0,1	
XGBoost (previsão)	n_estimators	200	
XGBoost (previsão)	max_depth	6	
XGBoost (previsão)	taxa de aprendizado	0,05	
XGBoost (previsão)	*subsample*	0,8	
Croston	alpha (suavização)	0,1	suavização exponencial
ARIMA	ordem (p,d,q)	$(1,1,1)$	
Características operacionais e classificação POD			
POD / ADI $\times$ CV^2	limiares de classificação	ADI$\geq$1,32; CV$^2\geq$0,49; zeros consec.$\geq$5; *burstiness*$\geq$0,30; ACF$\geq$0,25; tendência$\geq$0,05; entropia$\geq$2,0	Syntetos-Boylan + regras POD (Tabela 4.1)
POD / ADI $\times$ CV^2	média mínima de demanda	2,0	séries abaixo são excluídas
POD / ADI $\times$ CV^2	limiar CV para segmentação	1,5	segmentação adicional por variabilidade
Geração de rótulos e PSE			
Rótulos	limiar mínimo de NS para rótulo	0,70	política abaixo é excluída do *ranking*
Rótulos	modelo PSE	XGBoost	classificador treinado sobre perfis de séries
Rótulos	validação cruzada	5 folds	
Rótulos	n_estimators (PSE)	300	
Rótulos	max_depth (PSE)	6	
Rótulos	taxa de aprendizado (PSE)	0,05	
Rótulos	*subsample* (PSE)	0,8	
Rótulos	colsample_bytree (PSE)	0,8	

Tabela A.5: Validação estatística, ambiente computacional e artefatos.

Componente	Parâmetro ou artefato	Valor usado	Observação
Validação estatística			
Estatística	teste par a par	Wilcoxon signed-rank	comparação de pares de políticas
Estatística	teste global	Friedman	hipótese nula de igualdade entre múltiplas políticas
Estatística	*post-hoc*	Nemenyi	comparações múltiplas após rejeição de Friedman
Ambiente computacional (versões mínimas)			
Linguagem/orquestração	versões mínimas	Python 3.9; Kedro 0.19.0; kedro-datasets 2.0.0	orquestração do *pipeline*
Dados/ML	versões mínimas	pandas 2.0; NumPy 1.24; scikit-learn 1.3; XGBoost 2.0; PyArrow 14.0	
Otimização/estatística	versões mínimas	DEAP 1.4 (GA/DE); SciPy 1.11 (SA/DE); scikit-posthocs 0.8 (Nemenyi)	

(continua)

(continuação da Tabela A.5)

Componente	Parâmetro ou artefato	Valor usado	Observação
Visualização/geo	versões mínimas	Matplotlib 3.7; GeoPandas 0.14; geobr 0.4; PyYAML 6.0	geobr: malhas geográficas
Artefatos de reprodução			
dados processados	`simulation/data/03_primary/`		snapshot dos dados usados nas simulações
características operacionais	`simulation/data/04_feature/`		descritores das séries de demanda
configurações YAML	`simulation/conf/base/parameters/`		hiperparâmetros de todos os módulos
resultados de simulação	`simulation/data/07_model_output/`		métricas CTI, NS, TR, BE e FP por série
testes estatísticos	`results/statistical_tests/`		Wilcoxon, Friedman, Nemenyi
rótulos PSE	`results/policy_labels/`		política dominante por série

A.1 Resultados Agregados do Experimento 1

Esta seção registra a tabela completa de indicadores agregados do Experimento 1 (15 lojas da Paraíba, produto 48130, regime *Lumpy*), citada na Seção 5.3.5 apenas em forma resumida para evitar duplicação com a comparação agregada do Experimento 2 (Tabela 5.2).

Como ler a tabela: políticas com melhor equilíbrio combinam baixo CTI, alto NS, baixa TR e baixo BE. FP indica a frequência de emissão de pedidos: valores próximos de zero (≈ 0) ou de um (≈ 1) sinalizam degeneração operacional (o agente parou de emitir pedidos ou pediu em quase todos os ciclos), e essas políticas não constituem soluções práticas viáveis.

Tabela A.6: Médias dos indicadores de desempenho por política (15 lojas, regime *Lumpy*). Melhores valores por coluna. †SARSA e PPO apresentam degeneração (FP = 0 e FP = 0.98, respectivamente); resultados degenerados não constituem soluções operacionalmente viáveis.

Política	CTI (R$)	NS	TR	BE	FP
SARSA†	16.139	0.785	0.200	0.00	0.00
Jornaleiro	16.402	0.794	0.111	0.003	0.27
DQN	17.974	0.806	0.078	4.1	0.37
GA-DQN (Híbrido)	18.502	0.821	0.050	5.0	0.31
PSO	19.100	0.819	0.056	6.2	0.31
GA-PPO (Híbrido)	19.801	0.833	0.050	6.6	0.35
GA	20.015	0.825	0.061	19.7	0.30
DE	20.252	0.813	0.056	31.0	0.27
SA	20.967	0.820	0.056	36.4	0.27
EOQ	31.034	0.840	0.050	23.0	0.20
PPO†	34.637	0.848	0.039	15.9	0.98
(s, S)	35.589	0.843	0.050	119.4	0.15

Os dois extremos revelam os riscos da otimização por única métrica: o SARSA† converge

ao comportamento degenerado de não emitir pedidos (FP = 0), obtendo o menor CTI ao preço de 20% de rupturas; o PPO† emite pedidos em 98% dos ciclos, atingindo o maior NS mas com custo inviável.

A redução de “até 48%” citada no resumo deste trabalho origina-se exatamente desta comparação, calculada diretamente da Tabela A.6: CTI médio GA-DQN (R$ 18.502) versus (s, S) (R$ 35.589), $(35.589 - 18.502)/35.589 \approx 48\%$, sobre as 15 lojas do Experimento 1, produto 48130 (Paraíba). O valor representa o ganho máximo observado neste experimento, não uma redução média universal: no Experimento 2 (145 séries, BA) o GA-DQN não domina o EOQ em CTI, e o Jornaleiro apresenta menor custo bruto, mas não atinge o nível de serviço mínimo de $0{,}70$ (Seção 5.3.5).

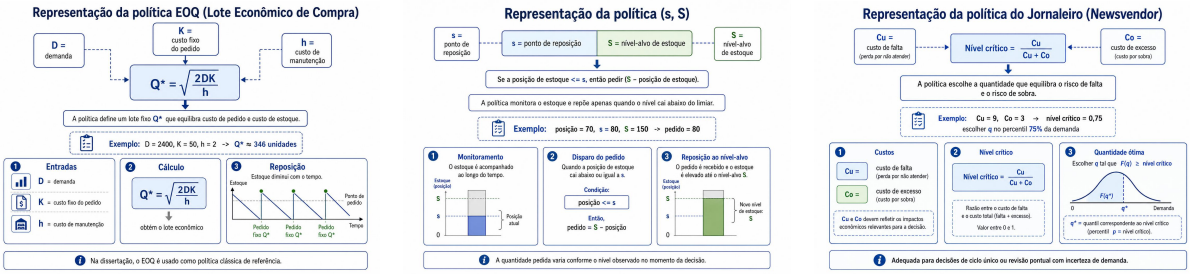
Apêndice B

Representações Visuais das Políticas Avaliadas

Este apêndice reúne representações visuais complementares das políticas do portfólio final avaliadas no experimento (Seção 4.6). As figuras têm caráter explicativo e servem para detalhar a lógica operacional de políticas clássicas, meta-heurística, agente de aprendizado por reforço e política híbrida, sem alterar a formulação metodológica apresentada no Capítulo 4. As representações incluem as políticas clássicas EOQ, (s, S) e Jornaleiro (Figura B.1), o Algoritmo Genético (Figura B.2), os agentes DQN e PPO (Figura B.3) e a política híbrida GA-DQN (Figura B.4).

A organização deste apêndice acompanha as famílias de métodos avaliadas na dissertação. Primeiro são apresentadas políticas clássicas, em seguida a meta-heurística, depois os agentes de aprendizado por reforço e, por fim, uma representação complementar de política híbrida GA-RL.

Enquanto o EOQ enfatiza o equilíbrio entre custo de pedido e custo de manutenção, a política (s, S) explicita uma regra operacional de revisão (quando a posição de estoque atinge o ponto de reposição s, emite-se pedido para recompor o nível-alvo S), e o Jornaleiro considera explicitamente o equilíbrio entre risco de excesso e risco de falta. A Figura B.1 reúne as três representações.



(a) EOQ (b) (s, S) (c) Jornaleiro

Figura B.1: Representações das políticas clássicas: (a) lote econômico de compra (EOQ); (b) regra de revisão (s, S); (c) decisão de reposição sob incerteza de demanda (Jornaleiro).

A meta-heurística do portfólio final usa uma representação contínua para buscar parâmetros

de reposição com bom desempenho operacional. No Algoritmo Genético, cada cromossomo codifica uma parametrização candidata da política de reposição, como mostra a Figura B.2. SA compartilha a mesma representação de solução (s, Q) e a mesma função de avaliação, diferindo apenas no mecanismo de busca (vizinhança com aceitação probabilística, em vez de população evolutiva).

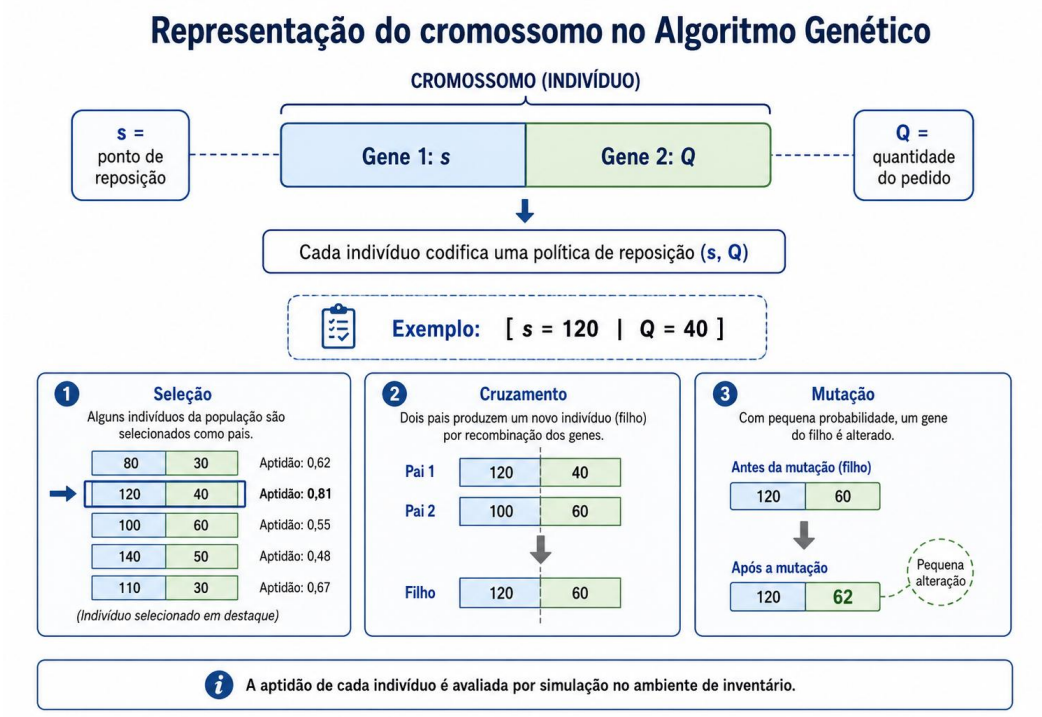
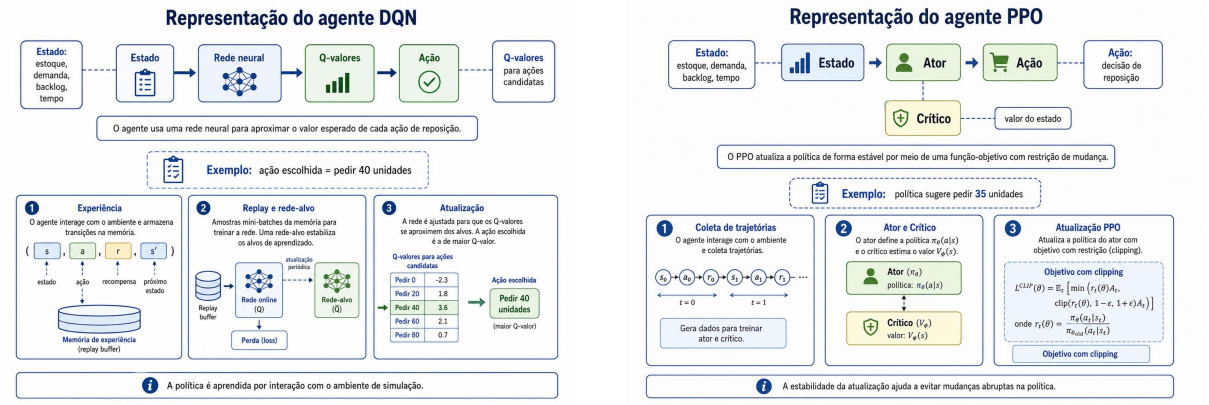


Figura B.2: Representação do cromossomo no Algoritmo Genético para parametrização de políticas de reposição.

Nos agentes de aprendizado por reforço, a decisão de reposição é tratada como interação sequencial entre agente e ambiente. Na política ε-greedy do DQN, a escolha aleatória de uma ação corresponde à etapa de exploração, enquanto a seleção da ação com maior valor $Q(s, a)$ corresponde ao aproveitamento da melhor ação estimada; o PPO compartilha a mesma abstração de interação sequencial, mas atualiza a política por estrutura ator-crítico com retorno multi-passo (GAE) em vez do *bootstrap* de 1 passo do DQN. A Figura B.3 resume os dois agentes.

Por fim, a política híbrida GA-DQN complementa a família GA-RL ao combinar busca evolutiva com refinamento por aprendizado por reforço. A Figura B.4 ilustra a lógica de inicialização evolutiva e refinamento por DQN. Essa representação reforça que a política híbrida é tratada como especialista do portfólio avaliado, mantendo o AIPE e o PSE como contribuição metodológica central.



(a) DQN (b) PPO

Figura B.3: Representações dos agentes de aprendizado por reforço: (a) Deep Q-Network (DQN), estimação de valores de ação por *bootstrap* de 1 passo; (b) Proximal Policy Optimization (PPO), estrutura ator-crítico com retorno multi-passo (GAE).

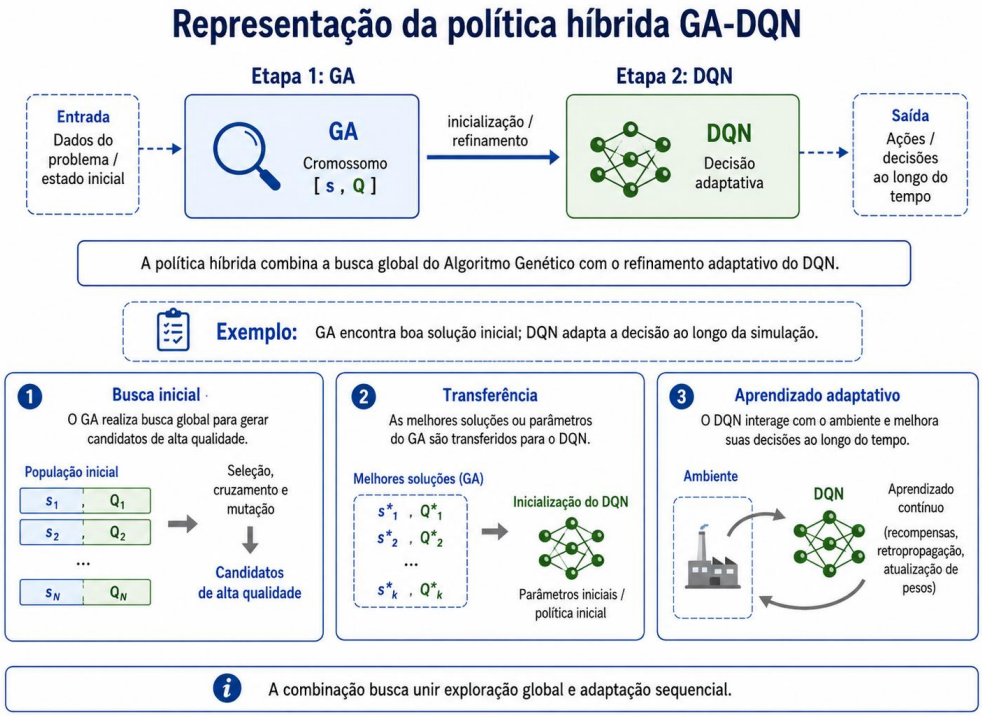


Figura B.4: Representação da política híbrida GA-DQN no portfólio avaliado.

Referências

Victoria G. Achkar, Braulio B. Brunaud, Héctor D. Pérez, Rami Musa, Carlos A. Méndez, and Ignacio E. Grossmann. Extensions to the guaranteed service model for industrial applications of multi-echelon inventory optimization. *European Journal of Operational Research*, 313(1):192–206, 2024. **DOI** 10.1016/j.ejor.2023.08.013.

Sven Axsäter. *Inventory Control*, volume 90 of *International Series in Operations Research & Management Science*. Springer US, New York, NY, USA, 2 edition, 2006. ISBN 9780387332505. **DOI** 10.1007/0-387-33331-2.

Gah-Yi Ban and Cynthia Rudin. The big data newsvendor: Practical insights from machine learning. *Operations Research*, 67(1):90–108, 2019. **DOI** 10.1287/opre.2018.1757.

Robert N. Boute, Joren Gijsbrechts, Willem van Jaarsveld, and Nathalie Vanvuchelen. Deep reinforcement learning for inventory control: A roadmap. *European Journal of Operational Research*, 298(2):401–412, 2022. **DOI** 10.1016/j.ejor.2021.07.016.

John E. Boylan and Aris A. Syntetos. Forecasting for inventory management of service parts. In Khairy A. H. Kobbacy and D. N. Prabhakar Murthy, editors, *Complex System Maintenance Handbook*, pages 479–506. Springer, London, UK, 2008. **DOI** 10.1007/978-1-84800-011-7_20.

Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016. **DOI** 10.1145/2939672.2939785.

Andrew J. Clark and Herbert Scarf. Optimal policies for a multi-echelon inventory problem. *Management Science*, 6(4):475–490, 1960. **DOI** 10.1287/mnsc.6.4.475.

Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, USA, 2 edition, 1988. ISBN 9780805802832.

J. D. Croston. Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303, 1972. **DOI** 10.1057/jors.1972.50.

Ton de Kok, Christopher Grob, Marco Laumanns, Stefan Minner, Jörg Rambau, and Konrad Schade. A typology and literature review on stochastic multi-echelon inventory models. *European Journal of Operational Research*, 269(3):955–983, 2018. **DOI** 10.1016/j.ejor.2018.02.047.

Tansel Dokeroglu, Tayfun Kucukyilmaz, and El-Ghazali Talbi. Hyper-heuristics: A survey and taxonomy. *Computers and Industrial Engineering*, 187:109815, 2024. **DOI** 10.1016/j.cie.2023.109815.

John H. Drake, Ahmed Kheiri, Ender Özcan, and Edmund K. Burke. Recent advances in selection hyper-heuristics. *European Journal of Operational Research*, 285(2):405–428, 2020. **DOI** 10.1016/j.ejor.2019.07.073.

Burak Erkayman, Ferhat Yuna, and Mustafa Yılmaz. Markov approach for inventory control with meta-heuristics in intermittent demand environment. *PLOS ONE*, 20:e0325658, 2025. **DOI** 10.1371/journal.pone.0325658.

Ayse Sena Eruguz, Evren Sahin, Zied Jemai, and Yves Dallery. A comprehensive survey of guaranteed-service models for multi-echelon inventory optimization. *International Journal of Production Economics*, 172:110–125, 2016. **DOI** 10.1016/j.ijpe.2015.11.017.

Milton Friedman. A comparison of alternative tests of significance for the problem of m rankings. *The Annals of Mathematical Statistics*, 11(1):86–92, 1940. **DOI** 10.1214/aoms/1177731944.

Kevin Geevers, Lotte van Hezewijk, and Martijn R. K. Mes. Multi-echelon inventory optimization using deep reinforcement learning. *Central European Journal of Operations Research*, 32 (3):653–683, 2024. **DOI** 10.1007/s10100-023-00872-2.

Joren Gijsbrechts, Robert N. Boute, Jan A. Van Mieghem, and Dennis J. Zhang. Can deep reinforcement learning improve inventory management? performance on lost sales, dual-sourcing, and multi-echelon problems. *Manufacturing & Service Operations Management*, 24(3):1349–1368, 2022. **DOI** 10.1287/msom.2021.1064.

Kwang-Il Goh and Albert-László Barabási. Burstiness and memory in complex systems. *EPL (Europhysics Letters)*, 81(4):48002, 2008. **DOI** 10.1209/0295-5075/81/48002.

Stephen C. Graves and Sean P. Willems. Optimizing strategic safety stock placement in supply chains. *Manufacturing & Service Operations Management*, 2(1):68–83, 2000. **DOI** 10.1287/msom.2.1.68.23267.

John H. Holland. *Adaptation in Natural and Artificial Systems*. MIT Press, Cambridge, MA, USA, 1992. ISBN 9780262581111.

Bernardo A. Huberman, Rajan M. Lukose, and Tad Hogg. An economic approach to hard computational problems. *Science*, 275(5296):51–54, 1997. **DOI** 10.1126/science.275.5296.51.

Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006. **DOI** 10.1016/j.ijforecast.2006.03.001.

Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017.

James Kennedy and Russell Eberhart. Particle swarm optimization. In *Proceedings of ICNN'95 — International Conference on Neural Networks*, volume 4, pages 1942–1948, 1995. **DOI** 10.1109/ICNN.1995.488968.

Pascal Kerschke and Heike Trautmann. Automated algorithm selection on continuous black-box problems by combining exploratory landscape analysis and machine learning. *Evolutionary Computation*, 27(1):99–127, 2019. **DOI** 10.1162/evco_a_00236.

Pascal Kerschke, Holger H. Hoos, Frank Neumann, and Heike Trautmann. Automated algorithm selection: Survey and perspectives. *Evolutionary Computation*, 27(1):3–45, 2019. **DOI** 10.1162/evco_a_00242.

S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983. **DOI** 10.1126/science.220.4598.671.

Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(3):48–60, 2014. **DOI** 10.1609/aimag.v35i3.2460.

Averill M. Law. *Simulation Modeling and Analysis*. McGraw-Hill Education, 5 edition, 2015. ISBN 9780073401324.

Hau L. Lee, V. Padmanabhan, and Seungjin Whang. Information distortion in a supply chain: The bullwhip effect. *Management Science*, 43(4):546–558, 1997. **DOI** 10.1287/mnsc.43.4.546.

Xiaotian Liu, Ming Hu, Yijie Peng, and Yaodong Yang. Multi-agent deep reinforcement learning for multi-echelon inventory management. *Production and Operations Management*, 34(7): 1836–1856, 2025. **DOI** 10.1177/10591478241305863.

Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30:4765–4774, 2017.

Scott M. Lundberg, Gabriel G. Erion, and Su-In Lee. Consistent individualized feature attribution for tree ensembles. *arXiv preprint arXiv:1802.00933*, 2018. **DOI** 10.48550/arXiv.1802.00933.

Spyros Makridakis. Accuracy measures: Theoretical and practical concerns. *International Journal of Forecasting*, 9(4):527–529, 1993. **DOI** 10.1016/0169-2070(93)90079-3.

Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. The m4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1): 54–74, 2020. **DOI** 10.1016/j.ijforecast.2019.04.014.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015. **DOI** 10.1038/nature14236.

Mehran Nasseri, Taha Falatouri, Patrick Brandtner, and Farzaneh Darbanian. Applying machine learning in retail demand prediction—a comparison of tree-based ensembles and long short-term memory-based deep learning. *Applied Sciences*, 13(19):11112, 2023. **DOI** 10.3390/app131911112.

Peter Nemenyi. *Distribution-Free Multiple Comparisons*. PhD thesis, Princeton University, 1963.

Afshin Oroojlooyjadid, MohammadReza Nazari, Lawrence V. Snyder, and Martin Takáč. A deep q-network for the beer game: Deep reinforcement learning for inventory optimization. *Manufacturing & Service Operations Management*, 24(1):285–304, 2022. **DOI** 10.1287/msom.2020.0939.

Deniz Preil and Michael Krapp. Bandit-based inventory optimisation: Reinforcement learning in multi-echelon supply chains. *International Journal of Production Economics*, 252:108595, 2022. **DOI** 10.1016/j.ijpe.2022.108595.

Meng Qi, Yuanyuan Shi, Yongzhi Qi, Chenxin Ma, Rong Yuan, Di Wu, and Zuo-Jun Max Shen. A practical end-to-end inventory management model with deep learning. *Management Science*, 69(2):759–773, 2023. **DOI** 10.1287/mnsc.2022.4564.

John R. Rice. The algorithm selection problem. *Advances in Computers*, 15:65–118, 1976.

John Schulman, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations (ICLR)*, 2016.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. **DOI** 10.48550/arXiv.1707.06347.

Rainer Storn and Kenneth Price. Differential evolution — a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4):341–359, 1997. **DOI** 10.1023/A:1008202821328.

Nadia Sultana, David Canca, and Alejandro Zarzo. Contextual reinforcement learning for supply chain management. *Expert Systems with Applications*, 255:124068, 2024. **DOI** 10.1016/j.eswa.2024.124068.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, USA, 2 edition, 2018. ISBN 9780262039246.

Aris A. Syntetos and John E. Boylan. On the bias of intermittent demand estimates. *International Journal of Production Economics*, 71(1–3):457–466, 2001. **DOI** 10.1016/S0925-5273(00)00143-2.

Aris A. Syntetos and John E. Boylan. On the categorization of demand patterns. *Journal of the Operational Research Society*, 56(5):495–503, 2005. **DOI** 10.1057/palgrave.jors.2601841.

Aris A. Syntetos, John E. Boylan, and Stephen M. Disney. Forecasting for inventory planning: A 50-year review. *Journal of the Operational Research Society*, 63(10):1397–1406, 2012. **DOI** 10.1057/jors.2012.158.

Yasin Tadayonrad and Alassane Balle Ndiaye. A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality. *Supply Chain Analytics*, 3:100026, 2023. **DOI** 10.1016/j.sca.2023.100026.

El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. John Wiley & Sons, Hoboken, NJ, USA, 2009. ISBN 9780470278581. **DOI** 10.1002/9780470496916.

Tarkan Temizöz, Christina Imdahl, Remco Dijkman, Douniel Lamghari-Idrissi, and Willem van Jaarsveld. Deep controlled learning for inventory control. *European Journal of Operational Research*, 324(1):104–117, 2025. **DOI** 10.1016/j.ejor.2025.01.026.

Henri Theil. *Applied Economic Forecasting*. North-Holland, Amsterdam, 1966.

Hado van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double Q-learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 30, pages 2094–2100, 2016.

Willem van Jaarsveld and Joachim Arts. Projected inventory-level policies for lost sales inventory systems: Asymptotic optimality in two regimes. *Operations Research*, 72(5): 1790–1805, 2024. **DOI** 10.1287/opre.2021.0032.

Nathalie Vanvuchelen, Joren Gijsbrechts, and Robert N. Boute. Use of proximal policy optimization for the joint replenishment problem. *Computers in Industry*, 119:103239, 2020. **DOI** 10.1016/j.compind.2020.103239.

Ziyu Wang, Tom Schaul, Matteo Hessel, Hado van Hasselt, Marc Lanctot, and Nando de Freitas. Dueling network architectures for deep reinforcement learning. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1995–2003, 2016.

Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. **DOI** 10.2307/3001968.

David H. Wolpert and William G. Macready. No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation*, 1(1):67–82, 1997. **DOI** 10.1109/4235.585893.

Linwei Xin. Technical note—understanding the performance of capped base-stock policies in lost-sales inventory models. *Operations Research*, 69(1):61–70, 2021. **DOI** 10.1287/opre.2020.2019.

Ferhat Yuna, Burak Erkayman, and Mustafa Yılmaz. Inventory control model for intermittent demand: A comparison of metaheuristics. *Soft Computing*, 27:6487–6505, 2023. **DOI** 10.1007/s00500-023-07871-0.

Oussama Zabraoui, Yahya Hmamou, Anas Chafi, and Salaheddine Kammouri Alami. A comparative study of multi-algorithm optimization for inventory analytics in supply chains. *Supply Chain Analytics*, 12:100154, 2025. **DOI** 10.1016/j.sca.2025.100154.

Paul H. Zipkin. *Foundations of Inventory Management*. McGraw-Hill/Irwin, Boston, MA, USA, 2000. ISBN 9780256113792.