


Representação do agente DQN



O agente usa uma rede neural para aproximar o valor esperado de cada ação de reposição.




Exemplo: ação escolhida = pedir 40 unidades

1

Experiência


O agente interage com o ambiente e armazena transições na memória.



2

Replay e rede-alvo

Amostras mini-batches da memória para treinar a rede. Uma rede-alvo estabiliza os alvos de aprendizado.



3

Atualização

A rede é ajustada para que os Q-valores se aproximem dos alvos. A ação escolhida é a de maior Q-valor.

Q-valores para ações candidatas

Pedir 0	-2.3
Pedir 20	1.8
Pedir 40	3.6
Pedir 60	2.1
Pedir 80	0.7

Ação escolhida

Pedir 40 unidades

(maior Q-valor)



A política é aprendida por interação com o ambiente de simulação.