


Representação do agente PPO




O PPO atualiza a política de forma estável por meio de uma função-objetivo com restrição de mudança.



Exemplo: política sugere pedir 35 unidades

1 Coleta de trajetórias


O agente interage com o ambiente e coleta trajetórias.



Gera dados para treinar ator e crítico.

2 Ator e Crítico

O ator define a política $\pi_\theta(a|s)$ e o crítico estima o valor $V_\phi(s)$.



3 Atualização PPO

Atualiza a política do ator com objetivo com restrição (clipping).

Objetivo com clipping

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) A_t \right) \right]$$

$$\text{onde } r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$$

Objetivo com clipping



A estabilidade da atualização ajuda a evitar mudanças abruptas na política.