

Dissertação de Mestrado

AIPE: Uma Metodologia para Seleção Contextual de Políticas de Reposição

Matheus Inácio Batista Santos
mibs@ic.ufal.br
Orientadores:

Dr. Rian Gabriel Santos Pinheiro
Dr. Bruno Costa e Silva Nogueira

Maceió

16 de outubro de 2026

Matheus Inácio Batista Santos

AIPE: Uma Metodologia para Seleção Contextual de Políticas de Reposição

Dissertação em desenvolvimento no Programa de Pós-Graduação em Informática da Universidade Federal de Alagoas, Instituto de Computação.

Orientadores:
Dr. Rian Gabriel Santos Pinheiro

Dr. Bruno Costa e Silva Nogueira

Maceió

16 de outubro de 2026

Versão de trabalho da dissertação de mestrado em desenvolvimento no Instituto de Computação da Universidade Federal de Alagoas. Composição da banca a confirmar.

Dr. Rian Gabriel Santos Pinheiro - Orientador
Instituto de Computação
Universidade Federal de Alagoas

Dr. Bruno Costa e Silva Nogueira - Orientador
Instituto de Computação
Universidade Federal de Alagoas

- Examinador(a)

- Examinador(a)

- Examinador(a)

Maceió
16 de outubro de 2026

Resumo

A gestão de estoques exige reconhecer quando adaptar a reposição ao contexto da demanda e quando conservar uma política de referência. Esta dissertação propõe o *Adaptive Inventory Policy Engine* (AIPE), uma metodologia modular e rastreável de apoio ao gerente de logística e estoques, buscando reduzir custos evitáveis sem deterioração relevante do atendimento. O procedimento tem cinco etapas: especificar a decisão, representar o contexto, construir evidência comparável, recomendar uma política e avaliar suas consequências. Seu *Policy Selection Engine* (PSE) associa perfis a famílias ou estima recomendações por série, com uma regra de intervenção que admite conservar a referência. A avaliação utiliza sete políticas em duas aplicações separadas: 145 séries empresariais da Bahia, em duas origens, e uma coorte histórica de 2.408 identificadores da quinta competição de previsão Makridakis (M5), com vendas do Walmart, em três origens. Custo, atendimento, deteriorações e distância a referências retrospectivas avaliam a utilidade de cada instanciação. Na Bahia, o perfil acrescenta atendimento com custo adicional; a previsão por classe aumenta custo e reduz serviço, enquanto o recuo por consequências mantém a referência. No M5, a previsão por consequências com recuo reduz o custo médio em 1,96% e acrescenta 0,32 ponto percentual de atendimento, embora produza deteriorações individuais e mantenha atendimento médio abaixo de 70%. Oráculos distinguem erros de escolha, insuficiência do portfólio e inviabilidade física. A contribuição central é o procedimento de apoio à decisão, sustentado pela integração das abordagens do PSE, pelo diagnóstico das limitações e pela avaliação em contextos complementares. Os resultados exercitam suas interfaces e delimitam a utilidade das implementações, sem demonstrar economia financeira realizada ou revisão cíclica do PSE. Coortes históricas, custos de cenário, horizontes curtos e desenvolvimento anterior restringem a generalização e exigem confirmação independente.

Palavras-chave: Metodologia de seleção; Gestão de estoques; Seleção contextual de políticas; Nível de serviço; AIPE.

Abstract

Inventory management requires recognizing when to adapt replenishment to demand context and when to retain a reference policy. This dissertation proposes the Adaptive Inventory Policy Engine (AIPE), a modular, traceable methodology supporting logistics and inventory managers in reducing avoidable costs without practically important deterioration in service. The procedure comprises five stages: specifying the decision, representing context, building comparable evidence, recommending a policy, and evaluating its consequences. Its Policy Selection Engine (PSE) maps profiles to policy families or estimates recommendations for each series, with an intervention rule that can retain the reference. We evaluate seven policies in two separate applications: 145 business series from Bahia at two origins and a historical cohort of 2,408 identifiers from the fifth Makridakis forecasting competition (M5), containing Walmart sales, at three origins. Cost, service, deterioration, and distance from retrospective references assess the utility of each implementation. In Bahia, profile-based selection adds service at an additional cost; class prediction increases cost and reduces service, while prediction of consequences with fallback retains the reference. In M5, prediction of consequences with fallback reduces mean cost by 1.96% and adds 0.32 percentage points of service, although individual deterioration occurs and mean service remains below 70%. Oracles distinguish selection errors, portfolio gaps, and physical infeasibility. The central contribution is the decision-support procedure, supported by integration of the PSE approaches, diagnosis of limitations, and evaluation in complementary contexts. The results exercise its interfaces and delimit the utility of the implementations, without establishing realized financial savings or cycle-by-cycle PSE revision. Historical cohorts, scenario-based costs, short horizons, and prior development restrict generalization and require independent confirmation.

Keywords: Selection methodology; Inventory management; Contextual policy selection; Service level; AIPE.

Sumário

Lista de Figuras vi
Lista de Tabelas vii
Lista de Siglas viii

1 Introdução **1**
1.1 Motivação 1
1.1.1 Reposição em redes varejistas 1
1.1.2 Da calibração à seleção de políticas 2
1.2 Problema e questões de pesquisa 2
1.3 Objetivos 4
1.4 Contribuições e alcance da evidência 5
1.5 Escopo e delimitações 6

2 Referencial Teórico **7**
2.1 Formulação do Problema de Reposição 7
2.1.1 Política de Reposição: Estado, Ação e Parâmetros 7
2.1.2 Função Objetivo e Dinâmica de Estoque 8
2.2 Famílias de Políticas de Reposição 8
2.2.1 Políticas Clássicas 8
2.2.2 Parametrização de Políticas via Meta-Heurísticas 9
2.2.3 Políticas de Reposição via Aprendizado por Reforço 10
2.2.4 Políticas Híbridas GA-RL 10
2.3 Demanda Intermitente 11
2.3.1 Taxonomia ADI e CV quadrado 11
2.3.2 Efeitos na Reposição 12
2.4 Métricas de Previsão 12
2.4.1 Métricas Utilizadas 12
2.5 Testes Estatísticos 13
2.5.1 Teste de Wilcoxon 13
2.5.2 Teste de Friedman e Nemenyi 13
2.5.3 Tamanho de Efeito 14

3 Trabalhos Relacionados **15**
3.1 Famílias de métodos 15
3.2 Inventário e demanda intermitente 15
3.3 Previsão e utilidade operacional 16
3.4 Meta-heurísticas e aprendizado por reforço 17
3.5 Seleção de políticas e meta-aprendizado 17
3.6 Antecedentes e delimitação da contribuição 18

3.7 Arquiteturas híbridas e posicionamento 19

4 AIPE: Metodologia Proposta 20
4.1 Objeto, entradas e saídas 20
4.1.1 Contrato de informação 21
4.1.2 Configuração temporal 21
4.2 Princípios e contribuição investigada 22
4.3 Procedimento metodológico 22
4.3.1 Especificar a decisão 22
4.3.2 Representar o contexto 23
4.3.3 Construir evidência comparável 24
4.3.4 Recomendar pelo PSE 24
4.3.5 Avaliar e diagnosticar 25
4.4 Metodologia e instanciação 25
4.5 Critérios de avaliação da contribuição 25

5 Desenho da Avaliação Experimental 27
5.1 Sistema de estoque e objetivo 27
5.1.1 Métricas e definição do serviço 27
5.2 Dados, preparo e cobertura 28
5.3 Características e perfis 29
5.4 Portfólio e calibração 29
5.4.1 Referências e busca de parâmetros 30
5.4.2 Reforço e híbrido 30
5.5 Separação temporal e comparação 31
5.6 Instanciação dos seletores 31
5.6.1 Associação e rótulos 31
5.6.2 Aprendizado e recuo conservador 31
5.6.3 Comparação por consequências 32
5.6.4 Execução e compatibilidade das matrizes 32
5.6.5 Aplicação e reavaliação 33
5.7 Oráculos e decomposição das falhas 33
5.8 Incerteza e rastreabilidade 34

6 Resultados e Discussão 35
6.1 Resultados da avaliação unificada 35
6.2 Diagnósticos complementares da avaliação unificada 39
6.3 Avaliação do contexto adicional 39
6.4 Esforço computacional das políticas 42
6.5 Síntese das respostas e limites 43

7 Conclusões 45
7.1 Respostas às questões de pesquisa 45
7.2 Contribuição e alcance 46
7.3 Continuidade 47

8 Continuidade e Validação Final **48**
8.1 Separar desenvolvimento e confirmação 48
8.2 Preservar o problema de decisão 49
8.3 Entrega gerencial e avaliação sequencial 49
8.4 Sensibilidades e eficiência 49
8.5 Critérios para a continuidade e a confirmação 50

Referências **51**

Lista de Figuras

1.1 Visão metodológica do AIPE e contexto adicional opcional 3
4.1 Procedimento do AIPE. Revisões motivadas pelo diagnóstico exigem nova avaliação independente. 23
6.1 Custo e atendimento nas duas aplicações. As médias não mostram a distribuição individual nem constituem fronteira de dominância por série. 36
6.2 Diferenças pareadas frente à referência global. Intervalos condicionais por loja, preservando produtos e origens; dez lojas limitam a precisão no M5. 37
6.3 Diagnóstico retrospectivo dos casos. A classificação distingue falha de seleção, cobertura do portfólio e restrição física inicial; demanda zero mantém atendimento indefinido. 38
6.4 Distribuição do atendimento nos casos com demanda positiva; linha horizontal indica 70%. Extremos são omitidos da exibição dos boxplots, mas permanecem nos cálculos. 38
6.5 Efeito incremental do contexto sobre custo (esquerda) e atendimento (direita), perante o PSE básico da mesma instância. Pontos: variações observadas; barras: intervalos condicionais de 95% de 5.000 reamostragens pareadas por loja/revendedor, mantendo produtos e origens agrupados. Custo negativo indica economia. Seleção e ativação protegida coincidiram nesta rodada. O bootstrap não refaz os ajustes; o M5 possui dez lojas. 42

Lista de Tabelas

2.1 Quadrantes de Syntetos-Boylan: limiares e interpretações. 11
3.1 Papel das famílias de métodos na pesquisa. 16
3.2 Relação entre linhas da literatura e o foco da dissertação. 19
4.1 Compromissos do AIPE e escolhas dependentes da aplicação. 25
5.1 Matrizes completas incluídas na avaliação. Sementes e origens são medidas repetidas. 28
5.2 Perfis: primeira regra satisfeita determina a classe. 29
6.1 Bahia: resultados por caso série–origem. Custo: 290 casos; atendimento: 283 casos definidos. Custo em unidades de cenário. 35
6.2 M5: resultados por caso série–origem. Custo: 5326 casos; atendimento: 5138 casos definidos. Custo em unidades de cenário. 36
6.3 Bahia: diferenças pareadas frente à referência global. Intervalos condicionais de 95%, com 5.000 reamostragens por loja. 39
6.4 Bahia: aproximação do oráculo do portfólio, calculado após agregar sementes. Eficiência somente entre casos comparáveis. 39
6.5 Bahia: planejamento com informação perfeita. Comparações por realização da política escolhida; sementes não são observações independentes. 40
6.6 M5: diferenças pareadas frente à referência global. Intervalos condicionais de 95%, com 5.000 reamostragens por loja. 40
6.7 M5: aproximação do oráculo do portfólio, calculado após agregar sementes. Eficiência somente entre casos comparáveis. 40
6.8 M5: planejamento com informação perfeita. Comparações por realização da política escolhida; sementes não são observações independentes. 41
6.9 Incremento do contexto adicional em relação ao PSE básico da mesma instância. Variação negativa de custo indica economia; atendimento em pontos percentuais. Nesta rodada, selecionada e protegida coincidem em todas as recomendações. . 41
6.10 Duração registrada dos ajustes não reaproveitados. Tempos em segundos; execução sob concorrência e carga variável. 43
8.1 Compromissos de continuidade e confirmação independente, sem datas ainda não acordadas. 50

Lista de Siglas

Sigla	Significado
AIPE	*Adaptive Inventory Policy Engine*; metodologia proposta para seleção contextual de políticas.
PSE	*Policy Selection Engine*; camada de seleção por perfil ou por modelo preditivo.
POD	Perfil Operacional de Demanda.
CTI	Custo Total de Inventário.
NS	Nível de Serviço: fração da demanda atendida.
TR	Taxa de Ruptura: fração de ciclos com falta.
BE	*Bullwhip Effect*: razão entre variâncias de pedidos e demanda.
FP	Frequência de Pedidos.
ADI	*Average Demand Interval*: intervalo médio entre demandas positivas.
CV	Coeficiente de Variação; CV^2 é seu quadrado.
SKU	*Stock Keeping Unit*: unidade de produto para controle de estoque.
EOQ	*Economic Order Quantity*: lote econômico de compra.
ERP	*Enterprise Resource Planning*: sistemas de gestão empresarial.
IQR	*Interquartile Range*: intervalo interquartil.
OLS	*Ordinary Least Squares*: mínimos quadrados ordinários.
MILP	*Mixed-Integer Linear Programming*: programação linear inteira mista.
CPU	*Central Processing Unit*: unidade central de processamento.
GPU	*Graphics Processing Unit*: unidade de processamento gráfico.
SARSA	*State–Action–Reward–State–Action*: método de aprendizado por reforço.
MAPE	*Mean Absolute Percentage Error*: erro percentual absoluto médio.
RMSE	*Root Mean Squared Error*: raiz do erro quadrático médio.
MBE	*Mean Bias Error*: viés médio.
GA	*Genetic Algorithm*: algoritmo genético.
SA	*Simulated Annealing*: recozimento simulado.
DQN	*Deep Q-Network*: rede de valores de ação.
PPO	*Proximal Policy Optimization*: otimização de política com recorte.
RL / DRL	Aprendizado por reforço / aprendizado por reforço profundo.
GA-DQN	Política híbrida que combina GA e DQN.
LSTM	*Long Short-Term Memory*: rede recorrente com memória.
ANN	*Artificial Neural Network*: rede neural artificial.
ARIMA	*Autoregressive Integrated Moving Average*.
MASE	*Mean Absolute Scaled Error*.
sMAPE	*Symmetric Mean Absolute Percentage Error*.
RMSSE	*Root Mean Squared Scaled Error*.
ASP	*Algorithm Selection Problem*: problema de seleção de algoritmos.
M5	Competição de previsão baseada em vendas do Walmart.

1

Introdução

Uma rede varejista precisa decidir quando e quanto repor em cada loja. O problema se torna mais difícil quando um produto vende regularmente em uma unidade, mas passa vários ciclos sem venda em outra. Uma política que preserva disponibilidade no primeiro caso pode gerar excesso de estoque no segundo. Custos, faltas e variabilidade dos pedidos dependem da relação entre a regra de reposição e o comportamento da demanda (Axsäter, 2006; Syntetos and Boylan, 2005).

Esta dissertação propõe o *Adaptive Inventory Policy Engine* (AIPE), uma metodologia modular e rastreável de apoio ao gerente de logística e estoques na escolha de políticas de reposição, buscando reduzir custos evitáveis sem deterioração relevante do atendimento. A seleção considera o contexto de cada série loja–produto e vincula a recomendação à evidência operacional. Seu *Policy Selection Engine* (PSE) é o componente que realiza a escolha, por associação a um perfil informado ou por estimação supervisionada. A Bahia e a base pública da quinta competição de previsão Makridakis (M5), com vendas do Walmart, constituem aplicações para avaliar o procedimento; não definem sua identidade metodológica.

1.1 Motivação

1.1.1 Reposição em redes varejistas

Diferenças de consumo, sazonalidade e condições logísticas dificultam o ajuste manual de estoques em redes com muitas lojas. Cada unidade decide sua reposição, mas seus pedidos também afetam o armazém. Lotes elevados podem reduzir a frequência de compra e aumentar o estoque; pedidos frequentes podem preservar disponibilidade e elevar custos fixos. A decisão envolve manutenção, falta, pedido e prazo de entrega (Axsäter, 2006; Zipkin, 2000).

A instabilidade dos pedidos acrescenta outra preocupação. Variações nas vendas podem produzir oscilações ainda maiores nas encomendas enviadas aos fornecedores, fenômeno co-

nhecido como efeito chicote (Lee et al., 1997). Medir essa amplificação ajuda a avaliar consequências a montante, embora não substitua a análise conjunta de custo e serviço.

Na demanda intermitente, intervalos sem venda alternam com ocorrências positivas; quando estas variam muito de tamanho, o padrão é chamado de *lumpy* (Croston, 1972; Syntetos and Boylan, 2005; Boylan and Syntetos, 2008).

Essas diferenças motivam comparar regras, mas não demonstram que um seletor por perfil será melhor que uma política única bem calibrada. A vantagem depende do portfólio, dos custos, do serviço exigido e da informação disponível antes da decisão. Uma escolha retrospectiva favorável pode desaparecer ao avaliar lojas ou períodos não usados no ajuste.

1.1.2 Da calibração à seleção de políticas

Políticas clássicas, meta-heurísticas e aprendizado por reforço oferecem formas distintas de decidir reposição. Uma meta-heurística pode ajustar o ponto de pedido e o lote de uma regra; um agente de reforço pode aprender ações a partir do estado do estoque. Além de calibrar cada candidata, é necessário decidir qual família utilizar (Syntetos et al., 2009; Boute et al., 2022).

O AIPE organiza essa escolha em cinco etapas: especificar a decisão, representar o contexto, construir evidência comparável, recomendar pelo PSE e avaliar as consequências. A separação permite identificar quais informações sustentam a escolha e qual evidência seria necessária para substituí-la. A formulação se aproxima da seleção de algoritmos, na qual características de uma instância ajudam a escolher um método (Rice, 1976; Kotthoff, 2014).

A previsão fornece informação auxiliar: sua precisão não determina automaticamente quando pedir nem garante menor custo de inventário.

A Figura 1.1 sintetiza a proposta: partir de séries heterogêneas, comparar um portfólio e avaliar a seleção contextual. A faixa tracejada apresenta a extensão opcional de atributos adicionais, sob escolhas do gestor e seleção interna por custo e atendimento. O gestor pode fixar atributos, indicar candidatos ou excluí-los; a comparação interna pode recomendar manter o PSE básico. Um estudo adicional de desenvolvimento examina essa extensão nas duas bases, com referência própria. Seu benefício depende da aplicação e da disponibilidade temporal documentada dos atributos.

1.2 Problema e questões de pesquisa

A unidade de análise é a série de vendas de um produto em uma loja, agregada por ciclo comercial. As políticas decidem reposição sob condições comuns de demanda, custos e prazo. O critério de referência é o menor custo entre alternativas que atendam ao nível de serviço mínimo. Quando a restrição usa a média de um grupo, ela não garante atendimento mínimo para cada série.



Figura 1.1: Visão metodológica do Adaptive Inventory Policy Engine (AIPE). O Policy Selection Engine (PSE) admite associação por perfil ou estimação por série. A faixa tracejada representa o módulo opcional de contexto: escolhas do gestor, seleção interna de candidatos e comparação com o PSE básico. A regra de intervenção decide entre candidata e referência. O benefício do módulo adicional deve ser verificado em cada aplicação. Os históricos são ilustrativos.

A questão principal é: *como uma metodologia modular de seleção contextual de políticas de reposição pode apoiar o gerente na redução de custos evitáveis, preservando o atendimento e a rastreabilidade das recomendações?* A investigação se desdobra em três perguntas:

1. Como articular contexto, calibração, seleção e avaliação em um procedimento com entradas, decisões e saídas explícitas?
2. Em que condições as implementações do PSE oferecem melhor compromisso entre custo e serviço do que uma referência global?
3. Quais limites da representação, da aprendizagem, do portfólio e do sistema restringem a transferência das recomendações?

As perguntas distinguem formulação, utilidade e limites. Construir o procedimento responde à primeira; famílias vencedoras diferentes não demonstram capacidade preditiva nem vantagem em substituir a referência.

As hipóteses empíricas são que existe heterogeneidade operacional aproveitável, que o contexto disponível antes da decisão captura parte dela e que uma regra de intervenção pode reduzir escolhas desfavoráveis. Os experimentos podem contrariar essas hipóteses. O registro de melhorias e deteriorações distingue execução e benefício operacional.

1.3 Objetivos

Objetivo geral

Propor, implementar e avaliar o AIPE como metodologia modular de apoio ao gerente de logística e estoques, com recomendações rastreáveis de famílias de reposição e parâmetros, buscando reduzir custos evitáveis sem deterioração relevante do atendimento frente a referências competitivas.

Objetivos específicos

1. Definir as entradas, etapas, critérios e saídas do AIPE, distinguindo o procedimento geral das escolhas específicas de aplicação.
2. Implementar o PSE por perfil e o PSE preditivo, separando escolha da família e calibração dos parâmetros.
3. Estabelecer um protocolo que preserve a informação disponível antes da decisão e compare recomendações sob condições operacionais compatíveis.

4. Avaliar custo, serviço, deteriorações e frequência de intervenção nas aplicações Bahia e M5.

5. Diagnosticar limites de representação, aprendizagem, cobertura do portfólio e viabilidade física, identificando o alcance da evidência e a validação ainda necessária.

Os estudos da Paraíba e da qualificação motivaram o desenvolvimento. A evidência quantitativa consolidada compreende 145 séries da Bahia em duas origens e uma coorte histórica de 2.408 identificadores do M5 nas dez lojas, com elegibilidade por origem. São 290 e 5.326 casos série–origem, respectivamente. O capítulo de resultados separa as bases e suas condições. O piloto anterior orientou o desenvolvimento, sem constituir confirmação independente. A avaliação nacional permanece fora do escopo experimental desta versão.

1.4 Contribuições e alcance da evidência

A contribuição metodológica do AIPE se apoia em três eixos:

1. **Seleção contextual:** integrar as abordagens do PSE por perfil e por estimação com contratos de informação, referência e escopo da restrição de serviço explícitos.

2. **Diagnóstico das limitações:** distinguir falha de seleção, insuficiência do portfólio e inviabilidade física do atendimento, orientando quais componentes ou condições revisar.

3. **Avaliação empírica:** examinar utilidade, condições de uso e limitações em vendas reais da Bahia e no referencial público M5, com análises separadas.

A implementação exercita substituições no portfólio e no PSE; a portabilidade dos demais módulos e a rastreabilidade completa da entrega gerencial permanecem pendentes. O diagnóstico é retrospectivo e condicional ao simulador, sem identificar causas de rupturas na empresa. As bases complementares sustentam a avaliação do procedimento, mas as consequências simuladas não comprovam ganho financeiro de implantação. A comparação empírica com integrações próximas da literatura também permanece necessária para delimitar o diferencial do AIPE.

O algoritmo genético (*genetic algorithm*, GA) e a rede Q profunda (*deep Q-network*, DQN) são métodos conhecidos. Também o é a otimização proximal de políticas (*proximal policy optimization*, PPO). Sua presença no portfólio não constitui novidade algorítmica; a arquitetura GA–DQN já aparece em Zabraoui et al. (2025). A avaliação investiga quando a seleção contextual oferece vantagem operacional.

O procedimento permite avaliar separadamente controladores e seletores. Em ambas as bases, referências globais e por perfil são confrontadas com implementações preditivas por classe e por consequências, incluindo uma regra de recuo à referência. A comparação verifica

a utilidade de cada instanciação, sem pressupor vantagem do modelo supervisionado. O piloto anterior integra o desenvolvimento do protocolo.

As três sementes das políticas estocásticas descrevem variação do treinamento, sem representar novas lojas ou demandas. A análise preserva as dependências por série e loja.

1.5 Escopo e delimitações

A pesquisa trata cada série loja-produto como um contexto de reposição. Seu objetivo é avaliar decisões apoiadas pela metodologia; diferenças de resultados entre séries não medem eficiência de lojas, equipes ou gerentes. Não modela substituição entre produtos, capacidade conjunta nem coordenação multiagente entre lojas e armazéns. O efeito chicote é um indicador complementar de variabilidade, não evidência de otimização de toda a rede.

O simulador avalia políticas sobre históricos preparados. Custos e abastecimento são parâmetros do cenário; roteamento, transporte e integração transacional com sistemas de gestão empresarial (*enterprise resource planning*, ERP) ficam fora do escopo. A recomendação admite cadência parametrizada, compatível com a informação disponível; revisão do PSE, ações de reposição e atualização dos modelos são decisões distintas. A avaliação atual mantém a família fixa em blocos de sete ciclos. Aprendizado por reforço multiagente, como o discutido por Liu et al. (2025), também não é implementado como coordenação da rede.

Dados proprietários limitam a divulgação; código, parâmetros e identificação de artefatos e recortes sustentam a rastreabilidade. Rupturas podem censurar vendas e ciclos ausentes exigem tratamento explícito. A simulação não comprova ganho econômico realizável.

2

Referencial Teórico

A seleção de políticas de reposição exige distinguir três objetos: o processo de demanda, a regra que produz pedidos e o critério usado para comparar seus resultados. Este capítulo define esses objetos e apresenta os métodos de previsão e inferência utilizados no trabalho. A descrição operacional dos experimentos fica no Capítulo 5.

2.1 Formulação do Problema de Reposição

2.1.1 Política de Reposição: Estado, Ação e Parâmetros

Uma política π transforma o estado observado $\mathbf{s}_t$ em uma quantidade de pedido não negativa:

$$\pi : \mathcal{S} \to \mathcal{A}, \qquad Q_t = \pi(\mathbf{s}_t; \boldsymbol{\theta}).$$

O estado reúne estoque disponível, pedidos em trânsito e informações de demanda disponíveis até a decisão. Os parâmetros $\boldsymbol{\theta}$ podem ser limiares e lotes, no caso de regras analíticas, ou pesos de uma rede neural. Meta-heurísticas ajustam parâmetros de uma regra; aprendizado por reforço ajusta a própria representação da decisão. Todas essas alternativas precisam ser avaliadas sob a mesma dinâmica de estoque.

É necessário separar estoque físico de posição de estoque. O primeiro determina o atendimento imediato; a segunda acrescenta os pedidos em trânsito e evita solicitar novamente unidades já encomendadas. Uma previsão de demanda pode integrar o estado, mas não substitui essas informações. Um vetor reduzido também não garante que o processo seja Markoviano: essa propriedade depende de representar informação suficiente para suas transições.

2.1.2 Função Objetivo e Dinâmica de Estoque

Para um horizonte finito T, o problema conceitual consiste em minimizar o custo esperado:

$$\min_{\pi} \mathbb{E}\left[\sum_{t=1}^{T}\left(hI_t + c_s S_t + c_o^{\text{fix}}\mathbf{1}(Q_t > 0) + c_o^{\text{var}} Q_t\right)\right]. \tag{2.1}$$

I_t é o estoque após atendimento, S_t a demanda perdida, h o custo de manutenção por unidade e ciclo, c_s o custo por unidade não atendida e c_o^{fix}, c_o^{var} os custos fixo e variável de pedido. A esperança representa incerteza da demanda ou do treinamento; repetir uma trajetória determinística não estima essa distribuição.

Se B_t é o estoque antes da chegada e A_t a quantidade recebida no ciclo, a dinâmica de vendas perdidas é

$$S_t = \max(0, D_t - B_t - A_t), \quad I_t = \max(0, B_t + A_t - D_t), \quad B_{t+1} = I_t. \tag{2.2}$$

A demanda não atendida não se acumula como encomenda pendente. A convenção de chegada deve acompanhar a equação: um modelo com prazo efetivo ℓ usa $A_t = Q_{t-\ell}$, como na avaliação temporal principal, com entrega efetiva em dois ciclos. Nos estudos históricos, a fila de tamanho $L+1$ correspondia à chegada em $t+L+1$. As convenções são identificadas separadamente na metodologia.

Minimizar custo sem restrição pode favorecer uma política que quase nunca repõe. Por isso, o trabalho acrescenta um nível mínimo de serviço. A escolha do limiar expressa um compromisso operacional e deve anteceder a comparação. Custos e serviço precisam ser apresentados conjuntamente, pois uma economia obtida com menor atendimento não caracteriza dominância.

2.2 Famílias de Políticas de Reposição

2.2.1 Políticas Clássicas

As políticas clássicas oferecem referências interpretáveis. Sob demanda constante média μ por ciclo, custo fixo K por pedido e manutenção h por unidade e ciclo, o lote econômico é

$$Q^* = \sqrt{2K\mu/h}.$$

Demanda e manutenção devem usar a mesma unidade temporal. A EOQ define o tamanho do lote; um ponto de pedido separado estabelece quando solicitá-lo. Com estoque de segurança, esse ponto pode ser $s = \mu L + z\sigma\sqrt{L}$, sob aproximações sobre demanda e prazo. A implementação histórica será distinguida dessa fórmula porque emprega uma demanda acumulada no

horizonte.

A política (s,S) observa a posição de estoque P_t e pede $\max(0,S-P_t)$ quando $P_t \leq s$. O limiar inferior evita pedidos a cada pequena redução de estoque; o superior determina a recomposição. A concentração de pedidos em lotes pode amplificar a variabilidade a montante, fenômeno associado ao efeito chicote (Lee et al., 1997). A intensidade desse efeito depende dos parâmetros e da demanda, não apenas do nome da política.

O modelo do Jornaleiro determina uma quantidade de período único pelo quantil de demanda associado à razão crítica entre falta e excesso. Na aproximação normal, escreve-se $Q^* = \mu + z_\alpha \sigma$. Essa expressão é ótima somente sob as hipóteses do modelo e com α derivado dos custos pertinentes. Usar $z = 1{,}28$ como parâmetro fixo em uma regra multiperíodo constitui uma heurística inspirada no modelo, não uma garantia de otimalidade.

Regras analíticas podem receber parâmetros específicos por série e, portanto, não pressupõem necessariamente uma única parametrização para toda a rede. Sua simplicidade é uma vantagem comparativa relevante: um método mais complexo precisa demonstrar ganho além do obtido por calibração adequada de uma referência simples.

2.2.2 Parametrização de Políticas via Meta-Heurísticas

Meta-heurísticas procuram vetores $\boldsymbol{\theta}$ em um espaço de busca. Cada candidato induz uma política, cuja execução simulada fornece custo e serviço. Essa abordagem dispensa uma expressão diferenciável para o desempenho, mas continua sujeita a sobreajuste ao histórico usado na busca. O objetivo, os limites dos parâmetros e o orçamento de avaliações devem ser controlados na comparação.

O Algoritmo Genético (GA) mantém uma população de candidatos e alterna seleção, cruzamento e mutação (Holland, 1992; Talbi, 2009). Em reposição, cromossomos podem codificar ponto de pedido e lote; a avaliação associa cada vetor à trajetória resultante (Yuna et al., 2023). Não há garantia geral de ótimo global em orçamento finito.

O Recozimento Simulado (SA) parte de uma solução e explora vizinhos. Uma piora ΔC pode ser aceita com probabilidade $\exp(-\Delta C/T_k)$, em que T_k é a temperatura (Kirkpatrick et al., 1983). Seu resfriamento controla a passagem de exploração para busca local. O resultado depende da escala da função objetivo, da vizinhança e do número de iterações.

Na Otimização por Enxame de Partículas (PSO), cada posição representa um candidato; velocidade, melhor posição individual e melhor posição coletiva orientam a atualização (Kennedy and Eberhart, 1995). A Evolução Diferencial (DE) gera candidatos pela combinação de diferenças entre vetores e aplica cruzamento e seleção (Storn and Price, 1997). Ambos são alternativas para espaços contínuos, mas não constituem, por si, regras operacionais distintas de reposição.

Mesmo quando duas buscas ajustam a mesma regra, seus custos computacionais e soluções podem diferir. A comparação deve identificar qual parte do ganho decorre do algoritmo

de busca e qual decorre da regra parametrizada. Otimizar cada série também é diferente de selecionar, entre políticas já calibradas, qual deve ser aplicada a uma nova série.

2.2.3 Políticas de Reposição via Aprendizado por Reforço

O aprendizado por reforço representa o controle como um processo de decisão $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$. O agente escolhe pedidos, recebe uma recompensa e observa a transição do inventário. Com recompensa $r_t = -C_t$, busca maximizar o retorno descontado $\sum_t \gamma^t r_t$ (Sutton and Barto, 2018). Uma restrição de serviço não é automaticamente satisfeita por essa recompensa: precisa de tratamento explícito ou verificação posterior.

DQN aproxima a função de valor $Q_\theta(s,a)$ por uma rede neural, usando memória de experiências e rede-alvo (Mnih et al., 2015). Sua aplicação requer ações discretizadas. A resolução dessa discretização limita os lotes disponíveis; episódios adicionais sobre a mesma série aumentam interações simuladas, mas não acrescentam novas realizações independentes de demanda.

PPO atualiza uma política por gradiente com uma razão de probabilidades limitada por *clipping* (Schulman et al., 2017). Pode ser formulado com ações contínuas ou discretas; essa propriedade precisa ser informada para cada implementação. Comportamentos como pedidos excessivos ou ausência de reposição podem resultar da recompensa, da escala dos estados, da exploração ou do treinamento. A observação de uma trajetória degenerada não identifica isoladamente sua causa.

SARSA (*state–action–reward–state–action*) atualiza valores seguindo a própria política:

$$Q(s,a) \leftarrow Q(s,a) + \eta[r + \gamma Q(s',a') - Q(s,a)].$$

A versão tabular exige discretizar o estado; Expected SARSA substitui o próximo valor pela esperança sobre ações. A adequação de cada representação depende da informação preservada e do tamanho do problema, e não permite concluir antecipadamente que uma família será superior nas séries estudadas.

2.2.4 Políticas Híbridas GA-RL

Uma arquitetura híbrida usa a busca evolutiva para obter parâmetros ou experiências iniciais e depois ajusta uma política por reforço. No GA–DQN, transições geradas com a política do GA podem preencher a memória do agente antes do refinamento. Trata-se de uma hipótese de melhoria da inicialização; seu benefício exige comparação com os componentes isolados e controle dos respectivos orçamentos.

A inicialização não elimina o risco de sobreajuste. Se busca e aprendizado observarem a mesma trajetória usada na avaliação, o resultado descreve adaptação ao histórico, não generalização. Além disso, avaliações completas de candidatos do GA e transições armazenadas

no DQN são quantidades diferentes. O trabalho trata o híbrido como candidato do portfólio; o problema de pesquisa é a seleção contextual entre candidatos.

2.3 Demanda Intermitente

Uma série intermitente alterna ciclos sem demanda e ocorrências positivas, cujos tamanhos também podem variar (Croston, 1972; Boylan and Syntetos, 2008). Frequência e magnitude são dimensões distintas. Para $D_t \geq 0$, definem-se

$$n_+ = |\{t : D_t > 0\}|, \tag{2.3}$$

$$\mu = T^{-1}\sum_t D_t, \qquad \sigma^2 = (T-1)^{-1}\sum_t (D_t - \mu)^2. \tag{2.4}$$

A média sobre todos os ciclos descreve o volume por período, mas pode ocultar longos intervalos sem venda. Uma sequência com valores positivos estáveis e muitos zeros é operacionalmente diferente de outra igualmente esparsa, porém com grandes picos.

2.3.1 Taxonomia ADI e CV^2

A classificação de Syntetos and Boylan (2005) combina intervalo médio entre demandas e variação dos tamanhos positivos:

$$\mathrm{ADI} = T/n_+, \tag{2.5}$$

$$\mathrm{CV}_+^2 = (\sigma_+/\mu_+)^2. \tag{2.6}$$

Aqui, μ_+ e σ_+ são calculados apenas nas observações positivas, diferentemente da média e variância da Equação 2.4. Os limiares 1,32 e 0,49 delimitam quatro categorias, resumidas na Tabela 2.1 (Syntetos et al., 2009).

Tabela 2.1: Quadrantes de Syntetos-Boylan: limiares e interpretações.

Regime	ADI	CV^2	Interpretação operacional
Smooth (Regular)	$< 1{,}32$	$< 0{,}49$	Alta frequência, demanda estável.
Erratic (Errático)	$< 1{,}32$	$\geq 0{,}49$	Alta frequência, magnitude irregular.
Intermittent (Intermitente)	$\geq 1{,}32$	$< 0{,}49$	Muitos zeros, magnitude relativamente estável.
Lumpy (Grumoso)	$\geq 1{,}32$	$\geq 0{,}49$	Muitos zeros e magnitude altamente irregular.

A implementação disponível também calcula uma medida de CV^2 incluindo zeros. Essa medida é útil como característica, mas não reproduz exatamente a definição original dos tamanhos positivos. As categorias dos artefatos são mantidas como rótulos operacionais, com essa ressalva; uma comparação entre taxonomias exige recalcular explicitamente ambos os índices.

2.3.2 Efeitos na Reposição

Demanda esparsa dificulta estimar taxas de ocorrência; tamanhos irregulares ampliam o custo de errar lotes e estoques de segurança. Croston separa a estimação dos tamanhos positivos e dos intervalos entre ocorrências. Isso pode melhorar a previsão, mas não estabelece qual regra de reposição minimiza custo sob um prazo e uma restrição de serviço específicos.

Os quadrantes fornecem uma descrição inicial, não uma prescrição de política. Séries no mesmo quadrante podem diferir em volume, tendências, sequências de zeros e concentração de picos. A hipótese do AIPE é que essas diferenças adicionais possam auxiliar a escolha; sua utilidade precisa ser medida contra uma política global bem calibrada, não inferida da classificação.

2.4 Métricas de Previsão

Erros absolutos e quadráticos dependem da escala da série; o erro percentual absoluto médio (*mean absolute percentage error*, MAPE) é indefinido quando a demanda observada é zero. O estudo emprega métricas escaladas e sMAPE, com convenções explícitas para denominadores nulos (Hyndman and Koehler, 2006; Makridakis et al., 2020). Nenhuma métrica de previsão substitui a avaliação do efeito da decisão sobre custo e serviço.

2.4.1 Métricas Utilizadas

Sejam $e_t = D_t - \hat{D}_t$ os erros em m pontos de avaliação e $d_1, \ldots, d_n$ o treinamento. O MASE compara o erro absoluto com a variação da referência ingênua:

$$\mathrm{MASE} = \frac{m^{-1} \sum_t |e_t|}{(n-1)^{-1} \sum_{j=2}^{n} |d_j - d_{j-1}|}. \tag{2.7}$$

Valores menores que um indicam erro inferior à escala ingênua (Hyndman and Koehler, 2006). A escala deve vir do treino; séries constantes requerem registro de indefinição ou regularização declarada. A presença de zeros, isoladamente, não impede o cálculo.

O sMAPE usa demanda e previsão simetricamente (Makridakis, 1993):

$$\mathrm{sMAPE} = \frac{200}{m} \sum_t \frac{|D_t - \hat{D}_t|}{|D_t| + |\hat{D}_t|} \,\%. \tag{2.8}$$

Adota-se contribuição zero quando ambos os termos do denominador são nulos. Seu intervalo é de zero a 200%, mas pequenas demandas podem produzir valores elevados; por isso é interpretado junto ao MASE.

A versão quadrática escalada é

$$\mathrm{RMSSE} = \sqrt{\frac{m^{-1}\sum_t e_t^2}{(n-1)^{-1}\sum_{j=2}^{n}(d_j - d_{j-1})^2}}. \tag{2.9}$$

Ela dá maior peso a erros grandes e também requer escala de treino não nula. O RMSSE complementa o diagnóstico; o MASE permanece a referência principal de comparação de previsão no estudo.

O viés médio (*mean bias error*, MBE), $\mathrm{MBE} = \overline{D} - \overline{\hat{D}}$, diferencia subestimação de superestimação. O U de Theil compara a raiz do erro quadrático médio (*root mean squared error*, RMSE) do modelo e da previsão ingênua (Theil, 1966). Esses indicadores auxiliam a interpretação, sem determinar a política vencedora. Uma relação entre menor erro e melhor reposição é hipótese empírica: depende da assimetria de custos, do prazo e da regra de decisão.

2.5 Testes Estatísticos

A comparação usa observações pareadas porque as políticas atendem às mesmas séries. Testes não paramétricos evitam exigir normalidade dos indicadores, mas não dispensam atenção à independência das unidades. Produtos da mesma loja e lojas expostas às mesmas condições podem ser dependentes. Repetições idênticas não aumentam o tamanho efetivo da amostra.

2.5.1 Teste de Wilcoxon

Para diferenças $\Delta_i = X_i^A - X_i^B$, a soma de postos com sinal é

$$W = \sum_{i:\Delta_i \neq 0} \mathrm{sgn}(\Delta_i) R_i, \tag{2.10}$$

em que R_i é o posto de $|\Delta_i|$. O teste de Wilcoxon (1945) avalia uma hipótese de localização sob condições sobre a distribuição das diferenças. Sua leitura como teste da mediana requer, em particular, simetria. Empates e diferenças nulas devem receber tratamento documentado.

2.5.2 Teste de Friedman e Nemenyi

Com K políticas avaliadas nas mesmas N instâncias, o teste de Friedman (1940) compara postos médios:

$$\chi_F^2 = \frac{12N}{K(K+1)} \sum_{j=1}^{K} \left(\bar{r}_j - \frac{K+1}{2} \right)^2. \tag{2.11}$$

A rejeição não identifica sozinha os pares diferentes. O procedimento de Nemenyi usa uma diferença crítica (Nemenyi, 1963):

$$\mathrm{DC} = q_\alpha \sqrt{\frac{K(K+1)}{6N}}. \tag{2.12}$$

Postos separados por mais que DC são distinguidos sob as condições do procedimento. Um posto favorável em custo não representa necessariamente serviço aceitável; as métricas e os limiares precisam permanecer visíveis.

2.5.3 Tamanho de Efeito

A diferença padronizada de médias é reportada como descrição complementar (Cohen, 1988):

$$d = \frac{\bar{X}_A - \bar{X}_B}{s_{\mathrm{pooled}}}, \qquad s_{\mathrm{pooled}} = \sqrt{\frac{(N_A-1)s_A^2 + (N_B-1)s_B^2}{N_A + N_B - 2}}. \tag{2.13}$$

Essa forma não utiliza a covariância do pareamento; medidas baseadas nas diferenças podem ser mais apropriadas para inferência pareada. Faixas convencionais de efeito pequeno, médio ou grande não substituem a diferença de custo em unidades operacionais e sua repercussão no serviço.

O conjunto de testes, efeitos e gráficos descreve a heterogeneidade observada. Não transforma uma escolha retrospectiva de vencedor em evidência de generalização. Essa distinção orienta o protocolo de validação do próximo capítulo: a avaliação de uma política e a avaliação do mecanismo que a seleciona são etapas diferentes.

3

Trabalhos Relacionados

A literatura fornece métodos para prever demanda, calibrar regras e aprender decisões de reposição. A questão desta dissertação é como escolher entre essas alternativas para uma série loja-produto. A revisão distingue o desempenho de uma política da capacidade de um seletor de reconhecer quando utilizá-la.

3.1 Famílias de métodos

Políticas clássicas têm formulações interpretáveis e constituem referências necessárias, mesmo quando se avaliam métodos de aprendizado (Axsäter, 2006; Zipkin, 2000). Meta-heurísticas exploram seus parâmetros; agentes de reforço aprendem ações sequenciais; e a seleção de algoritmos escolhe métodos a partir de características das instâncias. São níveis complementares, não substitutos automáticos.

A Tabela 3.1 resume seu papel no problema estudado. As limitações indicadas são questões de avaliação: não significam que toda implementação de uma família apresente o mesmo comportamento.

3.2 Inventário e demanda intermitente

Clark and Scarf (1960) estabelecem resultados de decomposição para sistemas multi-escalão sob hipóteses específicas. Os textos de Axsäter (2006) e Zipkin (2000) consolidam políticas, custos e medidas de serviço. Para estoques de segurança em redes, o modelo de serviço garantido e suas extensões oferecem outra linha de planejamento (Graves and Willems, 2000; Eruguz et al., 2016; Achkar et al., 2024). Esses resultados não dispensam verificar se demanda, abastecimento e coordenação correspondem ao caso aplicado.

Tabela 3.1: Papel das famílias de métodos na pesquisa.

Família	Decisão ou informação produzida	Questão de avaliação
Políticas clássicas	Quando e quanto pedir por uma regra explícita	Adequação e calibração ao cenário
Previsão	Estimativa de demanda ou de sua distribuição	Efeito da previsão sobre custo e serviço
Meta-heurísticas	Parâmetros de uma política escolhida	Custo de busca e validade fora do ajuste
Aprendizado por reforço	Ação condicionada ao estado	Recompensa, estabilidade e generalização
Seleção de políticas	Escolha de um membro do portfólio	Ganho incremental frente à referência global

A demanda intermitente requer atenção à frequência e ao tamanho das ocorrências. Croston (1972) separam esses componentes na previsão. A classificação ADI$\times$CV^2 diferencia padrões suaves, erráticos, intermitentes e *lumpy* (Syntetos and Boylan, 2005). Essa descrição organiza séries, mas não determina a política de menor custo: o resultado depende também de prazo, custos e serviço exigido.

A revisão de de Kok et al. (2018) mostra a diversidade de estruturas consideradas na otimização multi-escalão. Nesta dissertação, porém, as séries são simuladas como decisões locais. Não se reivindica a otimização conjunta de uma rede geral, nem se transfere uma garantia teórica de otimalidade para um cenário que não atende às hipóteses originais.

3.3 Previsão e utilidade operacional

Históricos com muitos zeros tornam problemático o uso de erros relativos divididos pela demanda observada. O MASE permite comparação entre escalas quando seu denominador é definido, mas séries constantes também exigem tratamento (Hyndman and Koehler, 2006). Métricas de previsão devem ser acompanhadas de convenções para casos degenerados, sem substituir a avaliação de inventário.

Estudos em varejo mostram que o desempenho preditivo depende da granularidade, dos dados e da forma de treinamento (Makridakis et al., 2020; Nasseri et al., 2023). Não há razão para supor que uma rede LSTM será sempre superior a modelos simples em históricos curtos. Um resultado de competição de previsão tampouco demonstra vantagem em custo de reposição.

Tadayonrad and Ndiaye (2023) aproximam a avaliação preditiva de custos e serviço. Essa conexão orienta o AIPE: previsões e seus erros fornecem sinais auxiliares, mas a seleção deve ser julgada pelas consequências da decisão. Para evitar informação futura, previsão, características e calibração precisam respeitar o mesmo corte temporal da avaliação.

3.4 Meta-heurísticas e aprendizado por reforço

Meta-heurísticas procuram soluções em espaços de parâmetros difíceis de tratar analiticamente (Talbi, 2009). Em inventário, permitem ajustar ponto de pedido e lote. Yuna et al. (2023) estudam otimização de parâmetros em demanda intermitente, enquanto Erkayman et al. (2025) combinam modelagem da demanda e busca de parâmetros. O ganho permanece condicionado à política e ao cenário de calibração.

Aprendizado por reforço formula reposição como decisão sequencial. Oroojlooyjadid et al. (2022) estudam DQN no *Beer Game*; Gijsbrechts et al. (2022) discutem aplicações de aprendizado profundo a inventário; e Vanvuchelen et al. (2020) aplicam PPO à reposição conjunta. Outros trabalhos investigam topologias e coordenação descentralizada (Geevers et al., 2024; Liu et al., 2025).

Esses estudos mostram possibilidades de controle adaptativo, mas a aplicação depende de estado, ação, recompensa e dinâmica do simulador. Um agente pode obter serviço elevado emitindo pedidos excessivos ou reduzir custo deixando de atender demanda. Custo, serviço e comportamento das ações precisam ser examinados em conjunto.

Históricos curtos restringem a avaliação, embora o número de ciclos observados não seja igual ao número possível de interações simuladas. Repetir episódios pode ampliar treinamento sem adicionar novos processos de demanda. Comportamento degenerado em uma implementação não demonstra incapacidade geral do algoritmo: pode refletir recompensa, orçamento, parametrização ou erro de código. Essa cautela importa ao interpretar resultados antigos após correções do ambiente.

3.5 Seleção de políticas e meta-aprendizado

Rice (1976) formalizam a escolha de um algoritmo a partir das características de uma instância. Revisões posteriores descrevem seletores supervisionados e sua avaliação (Kotthoff, 2014; Kerschke et al., 2019). No AIPE, a instância é a série loja-produto, o portfólio reúne políticas e a medida de desempenho combina custo e viabilidade de serviço.

A analogia separa três objetos: o melhor método global, o melhor método conhecido para cada instância e o método escolhido pelo seletor. O segundo é uma referência retrospectiva; não é implementável quando sua escolha exige conhecer resultados futuros. O terceiro deve ser avaliado em dados que não determinaram os rótulos ou o ajuste.

O teorema *No Free Lunch* trata de médias sobre classes de problemas sob condições próprias (Wolpert and Macready, 1997). Ele não prova que haverá troca de vencedores neste recorte varejista nem que as características escolhidas permitirão aprendê-la. Essas são questões empíricas. Características de instância podem ajudar na seleção (Kerschke and Trautmann, 2019), mas sua utilidade precisa ser verificada no problema aplicado.

Hiper-heurísticas selecionam ou geram heurísticas, inclusive durante a resolução (Drake

et al., 2020; Dokeroglu et al., 2024). O AIPE tem escopo mais restrito: propõe recomendar periodicamente uma política por série. Não troca controladores a cada estado do estoque nem coordena agentes em tempo real. Trabalhos com *bandits* e contexto investigam outras formas de adaptação em inventário (Preil and Krapp, 2022; Batsis and Samothrakis, 2024); abordagens integradas relacionam características e decisões em outros desenhos operacionais (Qi et al., 2023).

A consequência prática é comparar o seletor com uma referência global forte. A avaliação deve separar o ajuste das políticas da aprendizagem da escolha entre elas. Excluir uma loja do seletor, por exemplo, não elimina informação futura já usada para gerar seus resultados de simulação.

3.6 Antecedentes e delimitação da contribuição

A integração entre classificação de inventário e seleção de política aparece explicitamente em Mohammaditabar et al. (2012); classificação baseada em desempenho é objeto de Sheikh-Zadeh et al. (2021). Esses antecedentes situam a associação entre perfil e política como uma linha estabelecida. A comparação aqui é conceitual: a revisão dirigida verificou os metadados, mas não reproduziu os métodos nem realizou uma comparação algorítmica sustentada pela leitura integral desses estudos.

Francuz and Bányai (2026) apresentam uma estrutura que combina escolha de família, parâmetros e otimização multiobjetivo. Seu modelo de aprendizado aproxima o simulador para reduzir avaliações; a aplicação usa demanda sintética sazonal e pedidos pendentes. Esse desenho difere de aprender uma recomendação para séries reservadas, mas já cobre integração, múltiplas políticas e eficiência por aproximação. O posicionamento do AIPE depende, portanto, de explicitar a decisão de recomendação e a evidência usada para avaliá-la, além de reunir métodos em uma arquitetura.

Elmachtoub and Grigas (2022) fundamentam aprender segundo a consequência da decisão, em vez de apenas erro preditivo. Geifman and El-Yaniv (2019) estudam predição com rejeição; Laroche et al. (2019), melhoria de políticas com recuo à referência sob hipóteses próprias. Esses trabalhos sustentam componentes da extensão conservadora, sem fornecer garantias automáticas para nossa seleção de famílias ou para o fill rate de cada série.

O posicionamento do AIPE é, portanto, metodológico e aplicado: articular contexto, evidência operacional, seleção e decisão de intervenção em um procedimento verificável para reposição. Sua utilidade depende da comparação entre implementações e referências. A revisão não estabelece prioridade sobre toda combinação possível desses mecanismos; uma afirmação de novidade universal exigiria cobertura bibliográfica e comparação mais amplas.

3.7 Arquiteturas híbridas e posicionamento

Zabraoui et al. (2025) combinam busca genética e aprendizado por reforço em um estudo de inventário com dados do Walmart M5. É uma referência próxima do portfólio adotado aqui. A arquitetura GA–DQN e combinações GA–RL não são apresentadas como invenções desta dissertação. Sua inclusão permite investigar se oferecem vantagem em determinados recortes e como se comparam a regras simples sob condições comuns.

A Tabela 3.2 situa o foco da pesquisa sem equiparar bases, contagens de políticas ou protocolos diferentes. Uma comparação quantitativa direta exigiria reproduzir custos, horizontes, demandas e critérios de serviço.

Tabela 3.2: Relação entre linhas da literatura e o foco da dissertação.

Referência	Foco	Relação com esta pesquisa
Oroojlooyjadid et al. 2022	Aprender controle sequencial	Política candidata, não seletor validado
Yuna et al. 2023	Calibrar em demanda intermitente	Busca de parâmetros dentro do portfólio
Zabraoui et al. 2025	Comparação e combinação de algoritmos	Referência das arquiteturas avaliadas
Rice 1976; Kotthoff 2014	Selecionar métodos por instância	Base conceitual do PSE
Esta dissertação	Seleção contextual em varejo brasileiro	Comparar seleção e referência global

O espaço de investigação está na formulação do procedimento AIPE e na avaliação de quando suas recomendações agregam valor. A evidência brasileira e pública permite examinar instâncias distintas, sem provar generalização irrestrita. A contribuição não se reduz ao portfólio nem exige inventar um novo controlador; requer justificar as decisões da metodologia e demonstrar seu alcance. O capítulo seguinte define esse procedimento antes de apresentar sua instanciação experimental.

4

AIPE: Metodologia Proposta

O *Adaptive Inventory Policy Engine* (AIPE) é a metodologia proposta nesta dissertação para apoiar o gerente de logística e estoques na redução de custos evitáveis, preservando o atendimento. Seu objeto é recomendar uma família de reposição e sua parametrização conforme o contexto de estoque. O procedimento vincula a escolha à informação disponível, à exigência de atendimento e às consequências operacionais. Uma recomendação pode conservar a referência quando faltar evidência para substituí-la.

A metodologia define entradas, etapas, critérios e saídas. A implementação computacional executa o procedimento; Bahia e M5 são aplicações para avaliar sua utilidade. Assim, a proposta não se confunde com um simulador, um classificador ou a lista de algoritmos comparados. Tampouco pressupõe que contextualizar sempre produza economia.

4.1 Objeto, entradas e saídas

Uma instância do AIPE é especificada pelas unidades de decisão, históricos e contexto, portfólio de políticas, ambiente de estoque, regra operacional de comparação e desenho de avaliação. A regra declara custos, serviço e desempates. O desenho informa como separar construção e avaliação da recomendação. Esses elementos precisam estar definidos antes de interpretar os resultados.

Para a unidade i e o instante o, a informação $H_{i,o}$ reúne somente observações disponíveis até a escolha. Obtêm-se características $x_{i,o} = \phi(H_{i,o})$ e, quando disponível, um perfil $g_{i,o}$. Perfil derivado das mesmas características é uma representação resumida, não uma fonte independente de informação. Um perfil informado externamente exige origem e disponibilidade documentadas.

A saída pretendida compreende família recomendada, parâmetros com unidades e condições de aplicação, referência, alternativas e consequências esperadas. O registro identifica

contexto, suporte da escolha, restrição de serviço e versão do procedimento. Estimativas disponíveis antes da escolha ficam separadas dos resultados posteriores. O gerente decide aceitar, rejeitar ou ajustar a recomendação; essa participação humana ainda requer avaliação com usuários. Se nenhuma candidata for viável, essa condição deve ser registrada. Escolher a menos desfavorável não certifica atendimento do alvo.

4.1.1 Contrato de informação

O histórico deve identificar produto, local, datas, unidades e se registra demanda, vendas ou saídas. Prazo de reposição, custos e meta de atendimento definem a comparação; quando desconhecidos, exigem estimativa identificada ou cenário declarado. A política atualmente utilizada, quando conhecida e reproduzível, fornece uma referência operacional. Caso contrário, a referência adotada é metodológica. O gerente pode fornecer objetivos, restrições e perfil; descritores estatísticos são calculados a partir do histórico admissível.

Cada entrada registra fonte, escopo, data, unidade, qualidade e transformações, com origem observada, informada, estimada ou assumida em cenário. Zero válido, ausência, desconhecido e não aplicável têm significados distintos. A falta de informação pode restringir uma saída a cenários ou impedir sua emissão; não autoriza preenchimento silencioso.

Orientar quanto comprar agora requer saldo disponível, compromissos, pedidos em trânsito e restrições reais de fornecimento. A avaliação de famílias admite estados iniciais e regras declarados de cenário. Essa distinção permite examinar a metodologia com dados incompletos sem apresentar a simulação como uma compra imediatamente executável.

4.1.2 Configuração temporal

O desenho separa seis dimensões temporais: período básico de observação e ação; ciclo de agregação e análise da demanda; cadência de revisão do PSE; horizonte de planejamento; janela histórica; e frequência de atualização dos modelos. A recomendação tem validade até sua próxima revisão, enquanto o planejamento pode considerar um horizonte maior. Revisar pode significar manter a família, sem alterar parâmetros ou retreinar modelos.

A cadência informada para a empresa-fonte é uma reavaliação por ciclo comercial. O AIPE admite essa configuração e propõe explicitar outras cadências conforme a resolução e a latência dos dados. Alterar períodos exige compatibilizar agregação, incidência temporal dos custos, prazo e descritores; dados agregados por ciclo não validam decisões diárias. Custos por pedido conservam sua incidência por emissão. A parametrização proposta não demonstra desempenho sob frequências ainda não avaliadas.

Em uso sequencial, estoque e pedidos em trânsito evoluem entre revisões. Trocar de família deve preservar os compromissos e o estado decorrentes das decisões anteriores, respeitando chegadas e eventuais custos de mudança. Cada estratégia terá sua trajetória; condições iniciais

e eventos exógenos comuns não implicam reinicializar estoques a cada revisão. A instanciação atual fixa a família por sete ciclos e ainda não avalia essa revisão sequencial do PSE.

4.2 Princípios e contribuição investigada

O AIPE distingue seleção da família e calibração de parâmetros; exige comparação operacional compatível; impede informação futura na recomendação; e avalia o benefício incremental frente a uma referência competitiva. Esses princípios se apoiam em seleção de algoritmos e avaliação de modelos (Rice, 1976; Kerschke et al., 2019; Cawley and Talbot, 2010).

A contribuição central é a metodologia modular e rastreável de apoio à escolha de políticas. A integração das duas abordagens do PSE, o diagnóstico das limitações e a avaliação em contextos complementares sustentam essa proposta. A associação entre contexto e escolha possui antecedentes; a avaliação do AIPE examina como essa articulação define responsabilidades, permite comparar implementações e orienta a revisão dos componentes. Coerência do procedimento, utilidade operacional e transferência entre aplicações constituem critérios distintos de avaliação.

A aplicação requer históricos com cobertura identificável, candidatas executáveis sob convenções comuns e uma definição de serviço. Se vendas estiverem censuradas ou custos forem ilustrativos, a validade da recomendação permanece condicionada a essas limitações. A adaptação refere-se à escolha conforme o contexto e à reavaliação documentada; não significa troca contínua de controlador já validada em produção.

4.3 Procedimento metodológico

O procedimento tem cinco etapas, apresentadas na Figura 4.1. Uma avaliação observada pode motivar uma nova versão; não deve ser reutilizada como confirmação independente dessa revisão.

4.3.1 Especificar a decisão

A especificação fixa o significado de uma recomendação e do benefício esperado. Definem-se unidade, horizonte, dinâmica de estoque e instante da escolha. A exigência de serviço informa se vale para cada série, perfil ou conjunto. Média por série, atendimento ponderado por unidades e restrição individual são objetivos diferentes.

A referência recebe o mesmo acesso ao passado. Uma referência global mantém a família, mas pode ajustar parâmetros para cada unidade. O desenho deve representar o uso pretendido: novas lojas com histórico, períodos futuros e outra população exigem separações distintas. Uma avaliação que exclui lojas não demonstra, sozinha, transferência para produtos novos.

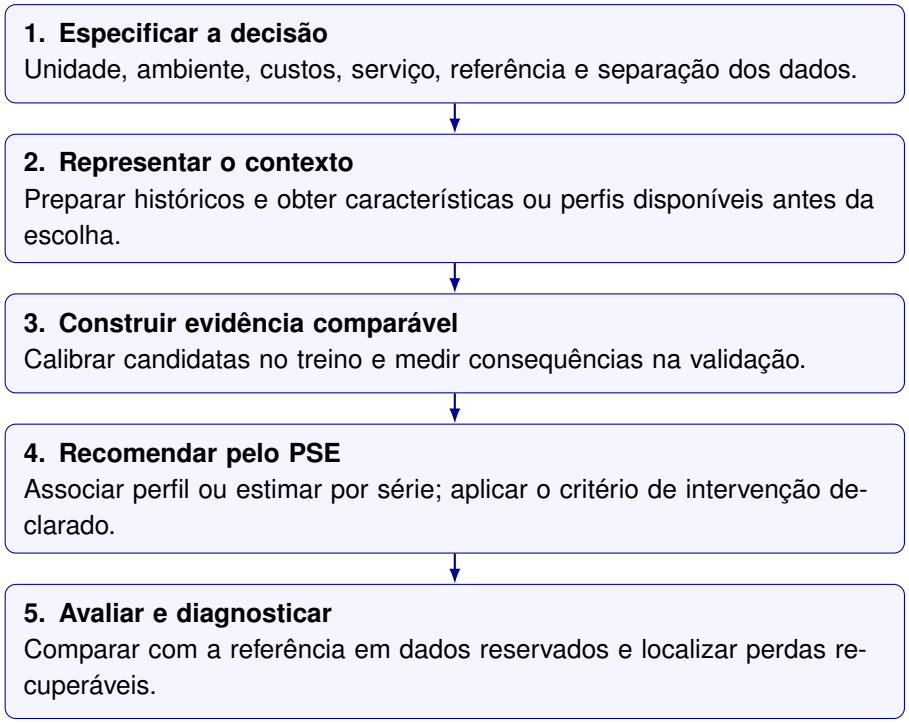


Figura 4.1: Procedimento do AIPE. Revisões motivadas pelo diagnóstico exigem nova avaliação independente.

4.3.2 Representar o contexto

A representação disponibiliza ao seletor o contexto que poderá ser observado no uso pretendido. Preparam-se os históricos e calculam-se características ou perfis anteriores à escolha. Elegibilidade, preenchimentos, escalas e codificações respeitam o corte temporal. Ausência de venda, registro e procura não são equivalentes sem justificativa.

O módulo opcional de atributos adicionais permite ao gestor definir entradas fixas, candidatas à seleção ou excluídas. A seleção interna admite candidatos quando melhoram a comparação operacional sob restrições de atendimento e volume de atributos. Os fixos permanecem na variante ampliada; a adoção dessa variante é comparada ao PSE básico antes da avaliação externa. A escolha da representação é distinta da regra que decide entre política candidata e referência. Seu benefício precisa ser verificado em cada aplicação, com disponibilidade temporal documentada.

A representação é examinada por seu apoio à decisão. Seu objetivo não é maximizar descritores nem produzir grupos artificialmente equilibrados. Perfis raros, variáveis indisponíveis e regras que concentram quase todas as séries em uma categoria integram o diagnóstico de suporte.

4.3.3 Construir evidência comparável

A evidência precisa distinguir diferenças entre políticas de diferenças nas condições de avaliação. Cada família recebe parâmetros ajustados com os dados admitidos para calibração. A validação registra custo, atendimento e esforço sob condições comuns. Estoque inicial, pedidos em trânsito, tratamento terminal e serviço precisam ter a mesma interpretação para todas as candidatas.

Preserva-se a matriz de consequências, em vez de guardar somente a vencedora. Sua identidade pode mudar com janela, semente e empates sem relevância operacional. A matriz permite construir associações por perfil, rótulos ou alvos de custo e serviço. Vencer na validação não prova vantagem futura.

4.3.4 Recomendar pelo PSE

O *Policy Selection Engine* (PSE) converte contexto e evidência de validação em uma recomendação. Duas abordagens respondem à mesma decisão:

$$\text{por perfil: } \widehat{p}_i = m(g_i), \qquad \text{preditiva: } \widehat{p}_i = f(x_i, g_i) \text{ ou } f(x_i).$$

A primeira consulta uma associação entre perfil informado e família. A segunda estima uma recomendação por série, com perfil opcional. PSE não é sinônimo de classificador.

O preditivo pode aprender a identidade da vencedora ou estimar suas consequências. Nesta última implementação, prevê custo $\widehat{C}_{i,p}$ e serviço $\widehat{F}_{i,p}$ para cada candidata p e escolhe, por exemplo,

$$\widehat{p}_i = \arg \min_{p:\widehat{F}_{i,p} \geq \alpha} \widehat{C}_{i,p}.$$

Se nenhuma for prevista como viável, aplica-se a contingência declarada. Avaliar erro pela consequência operacional tem fundamento em aprendizado orientado à decisão (Elmachtoub and Grigas, 2022); não é apresentado como invenção geral do AIPE.

Uma regra de intervenção a_i determina se a candidata substitui a referência:

$$p_i^{\text{AIPE}} = \begin{cases} \widehat{p}_i, & a_i = 1, \\ p_i^{\text{ref}}, & a_i = 0. \end{cases}$$

A regra pode permitir a escolha direta ou exigir benefício previsto e suporte. Limiares são definidos no desenvolvimento, sem consultar o teste reservado. Recuo e predição seletiva têm antecedentes (Geifman and El-Yaniv, 2019; Laroche et al., 2019). A questão investigada é sua utilidade na escolha de famílias de reposição. Confiança de classe e serviço previsto não garantem atendimento realizado.

4.3.5 Avaliar e diagnosticar

A avaliação mede se a recomendação acrescenta valor à referência. Depois de fixar as escolhas, comparam-se custo, serviço, deteriorações e intervenções em dados que não determinaram o ajuste. Acurácia e frequência de vitória são auxiliares: trocar políticas quase empatadas difere de provocar uma ruptura importante.

O diagnóstico distingue erro de escolha com candidata viável, insuficiência do portfólio apesar de possibilidade física e inviabilidade nas condições do sistema. Demanda zero fica separada. Um planejamento com informação perfeita fornece limite retrospectivo, não desempenho operacional disponível sem conhecer o futuro. A constatação de uma limitação deve orientar a revisão do componente correspondente.

4.4 Metodologia e instanciação

Tabela 4.1: Compromissos do AIPE e escolhas dependentes da aplicação.

Compromisso metodológico	Escolha de instanciação
Contexto anterior à decisão	Descritores, perfil e histórico mínimo
Comparação operacional compatível	Portfólio, ambiente, custos e prazo
Separação entre ajuste, escolha e teste	Janelas e grupos de validação
Referência e contingência explícitas	Família e critério de intervenção
Avaliação incremental rastreável	Métricas, tolerâncias e incerteza

Trocar base, modelo ou limiar não cria uma nova metodologia: essas escolhas instanciam o procedimento. Usar informação futura ou custos incompatíveis viola seus compromissos. As cinco etapas podem ser aplicadas a outros cenários, mas essa possibilidade de especificação não demonstra generalização empírica para eles.

Na implementação atual, políticas e seletores seguem interfaces verificadas no fluxo de pesquisa. O pré-processamento é compartilhado, o avaliador confere a cobertura da matriz e a fila distingue ajuste de controladores e pontuação das recomendações. A substituição de métodos preserva o significado dos dados, ações e indicadores; mudar o ambiente ou a informação disponível exige outra verificação. A comparação experimental exercita alternativas de portfólio e seleção, sem validar indiscriminadamente todos os módulos possíveis.

4.5 Critérios de avaliação da contribuição

A **coerência** exige entradas, recomendações e consequências identificáveis, sem antecipação do teste. A **utilidade** exige comparação com referências fortes, considerando custo, serviço, deteriorações e incerteza. A relevância prática cabe ao julgamento humano informado pelo

contexto, pela escala da economia e pelo esforço de uso, sem percentual mínimo universal. Rastreabilidade permite esse julgamento, mas não substitui evidência de benefício. Ausência de diferença detectável não prova preservação do atendimento; afirmar não inferioridade requer margem e desenho próprios. A **transferibilidade** exige investigar a persistência das conclusões em outras séries, lojas, períodos e condições.

Essas dimensões não são intercambiáveis. Um procedimento reproduzível pode recomendar mal; um ganho localizado pode não se transferir. Um resultado desfavorável de determinada implementação limita sua utilidade demonstrada, sem resolver a avaliação de todas as implementações possíveis. A avaliação, portanto, precisa vincular cada conclusão ao critério que a sustenta.

No uso pretendido, o AIPE reaproveita evidências de outras unidades para recomendar uma família antes de comparar todas novamente. Na avaliação, o portfólio completo é ajustado nas unidades reservadas para medir consequências e oráculos. Essa despesa experimental não demonstra economia computacional de implantação. O próximo capítulo apresenta as escolhas usadas para avaliar o procedimento na Bahia e no M5.

5

Desenho da Avaliação Experimental

Este capítulo instancia a metodologia AIPE nas aplicações Bahia e M5. Dados, custos, prazos, políticas, modelos e janelas descritos a seguir são escolhas experimentais; não definem requisitos universais da metodologia. O protocolo separa o ajuste dos controladores, a construção do seletor e a avaliação das recomendações. A comparação entre abordagens do PSE examina a seleção contextual; os oráculos delimitam falhas de seleção, insuficiência do portfólio e inviabilidade física. As duas aplicações fornecem evidência sobre condições de uso, sem validar toda configuração admitida pela metodologia.

5.1 Sistema de estoque e objetivo

O ambiente simula vendas perdidas com prazo exato de dois ciclos. A política decide antes do recebimento; entregas chegam antes da demanda. Faltas não são acumuladas como pedidos pendentes. Quantidades não negativas podem ser fracionárias. Não há restrição conjunta de transporte, transbordo ou disputa entre lojas por estoque.

O custo da Equação 2.1 soma manutenção do saldo após atendimento, falta, emissão e quantidade pedida. Os valores são $h = 1$, $c_s = 5$, $c_o^{\text{fix}} = 50$ e $c_o^{\text{var}} = 0{,}5$, sem crédito terminal. São unidades de cenário, sem calibração financeira. Pedidos em trânsito não atendem demanda antes da chegada.

5.1.1 Métricas e definição do serviço

Registram-se custo total de inventário (CTI), atendimento (NS), taxa de ruptura (TR), frequência de pedidos (FP) e amplificação de variância (BE):

$$\text{NS} = \frac{\sum_t (D_t - S_t)}{\sum_t D_t}, \qquad \text{TR} = \frac{\#\{t : S_t > 0\}}{T}, \qquad \text{FP} = \frac{\#\{t : Q_t > 0\}}{T}.$$

Aqui, S_t é falta e BE é $\mathrm{Var}(Q)/\mathrm{Var}(D)$, com convenção registrada para variância nula. NS é fração de unidades atendidas, não probabilidade de um ciclo sem falta. Demanda total zero mantém NS indefinido; o custo continua na análise.

O limiar é 0,70. A média por série, a razão entre unidades totais atendidas e demandadas e a garantia de 0,70 em cada série não são equivalentes. Por isso, reportamos custo, média de NS, atendimento ponderado quando disponível e contagem de violações. Custo baixo com pouco atendimento não caracteriza eficiência operacional.

5.2 Dados, preparo e cobertura

A avaliação proprietária utiliza 145 séries da Bahia, em 115 unidades comerciais e nove produtos, com 38 ciclos de 202301 a 202504. As unidades correspondem aos revendedores identificados na fonte e são denominadas lojas nesta avaliação. Registros complementares são somados por armazém, loja, produto e ciclo; células sem agregado registrado são preenchidas com zero, sob hipótese explícita de cobertura da fonte. A coorte mantém identificadores históricos. Em cada origem, exige-se pelo menos três ciclos positivos no treino. Esse requisito é passado-dependente, mas não torna prospectiva a seleção inicial dos identificadores.

O M5 utiliza a coorte histórica local de 2.408 identificadores loja–produto da categoria de alimentos (`FOODS`), nas dez lojas de três estados. Usam-se ciclos completos de 21 dias, sem corte de picos pelo intervalo interquartil (*interquartile range*, IQR). A exigência de três ciclos positivos no prefixo admite 885 séries na origem 50, 2.033 na origem 64 e 2.408 na origem 78. O recorte não representa todas as séries FOODS. Um piloto de 30 séries orientou o desenvolvimento; sua ampliação não estabelece confirmação independente.

Tabela 5.1: Matrizes completas incluídas na avaliação. Sementes e origens são medidas repetidas.

Dimensão	Bahia	M5
Séries / lojas	145 / 115	2.408 / 10
Origens do treino	17 e 23	50, 64 e 78
Validação / teste	7 / 7 ciclos	7 / 7 ciclos
Casos série–origem	290	5.326
Ajustes de políticas	4.350	79.890
Testes com demanda positiva	283	5.138

A auditoria da coorte canônica Bahia identificou 2.697 de 5.510 células preenchidas com zero por ausência de agregado (48,9%). Essa contagem descreve o painel auditado, sem estimar demanda perdida nem caracterizar a base M5. Vendas podem omitir demanda censurada por ruptura. Reindexar ausência de venda como zero pressupõe cobertura da fonte, não prova ausência de procura. Os dados brasileiros são restritos; M5 é público. O recorte local é inspirado no contexto de Zabraoui et al. (2025), sem identidade comprovada de filtros, amostra ou

implementação.

5.3 Características e perfis

O preditivo recebe 17 características: ADI, CV^2, intermitência, proporção de zeros, maior e média das sequências de zeros, burstiness, assimetria, curtose, entropia, tendência, autocorrelação, média, desvio-padrão, CV, extensão e número de ciclos positivos. Todas usam somente o treino; perfil e metadados não alteram essa restrição temporal.

A característica CV^2 inclui zeros, diferindo da taxonomia original baseada em tamanhos positivos (Seção 2.3.1). Burstiness é $(s_\tau - \bar{\tau})/(s_\tau + \bar{\tau} + 10^{-9})$ nos intervalos entre ocorrências positivas, recebendo zero com menos de dois intervalos (Goh and Barabási, 2008). Tendência é a inclinação por mínimos quadrados ordinários (*ordinary least squares*, OLS) dividida pela média regularizada; entropia usa dez classes de mesma largura. Autocorrelação na defasagem 17 recebe zero com até 18 ciclos ou variância desprezível. Zero nessa condição significa estimativa indisponível.

Tabela 5.2: Perfis: primeira regra satisfeita determina a classe.

Perfil	Condição
Sparse High Impact	ADI $\geq 1{,}32$, $CV^2 \geq 0{,}49$, sequência de zeros ≥ 5
High Volatility Seasonal	Autocorrelação $\geq 0{,}25$ ou burstiness $\geq 0{,}30$
Unstable Trend	Tendência absoluta $\geq 0{,}05$ ou entropia ≥ 2
Low Volume Stable	Média ≤ 2, $CV^2 < 0{,}49$
Fast Moving	ADI $< 1{,}32$

Os nomes são heurísticos; casos não cobertos recebem Sparse High Impact. Não se assume sazonalidade ou impacto econômico empiricamente comprovados. A coluna de política previamente associada aos nomes no código não gera os rótulos do experimento: custos e serviço na validação definem a escolha.

5.4 Portfólio e calibração

EOQCycle, sSCycle, CappedBaseStock, GA, PPO, GA–DQN e DQN compõem o portfólio. DQN é controle necessário do híbrido. Outros métodos preservados no projeto não são resultados adicionais desta matriz. A composição privilegia diversidade de regras; sua retirada do escopo não estabelece inferioridade universal.

5.4.1 Referências e busca de parâmetros

Com média $\hat{\mu}$ e desvio populacional $\hat{\sigma}$ do treino, as escalas são

$$I_0 = \hat{\mu}L + 1{,}28\hat{\sigma}\sqrt{L}, \tag{5.1}$$

$$Q_{\text{ref}} = \max(1, \sqrt{2\hat{\mu}c_o^{\text{fix}}/h}), \tag{5.2}$$

$$s_{\text{ref}} = \hat{\mu}L + 1{,}28\hat{\sigma}\sqrt{L}. \tag{5.3}$$

EOQCycle pede lote fixo ao atingir o ponto; sSCycle repõe até $s_{\text{ref}} + Q_{\text{ref}}$. Não se alega otimização exata de (s, S). CappedBaseStock calibra alvo e teto em grade 20×12, motivada pela família de Xin (2021).

GA ajusta gatilho, lote e proteção adicional com 100 indivíduos e 50 gerações. Seu objetivo acrescenta penalidade pelo déficit de serviço à referência

$$\boldsymbol{\theta}_i^* = \arg\min_{\boldsymbol{\theta}\in\Theta_i} \text{CTI}(\pi_{\boldsymbol{\theta}}, i) \quad \text{sujeito a } \text{NS}(\pi_{\boldsymbol{\theta}}, i) \geq 0{,}70. \tag{5.4}$$

Penalização não garante viabilidade; o serviço observado deve ser conferido. A CappedBaseStock utiliza pesos zero para ruptura e amplificação dos pedidos nas duas bases. A harmonização do objetivo permite comparar as instanciações sob a mesma definição de calibração, preservando diferenças de demanda e escala.

5.4.2 Reforço e híbrido

DQN utiliza Double DQN dueling e PPO utiliza otimização proximal, com duas camadas de 64 unidades e 20 ações discretas. O estado reúne estoque, referência ingênua de demanda, pedidos em trânsito, média e dispersão dos últimos seis ciclos e posição no horizonte. Escalas vêm do treino; observações são passadas. Previsores especializados disponíveis no projeto não alimentam os resultados reportados.

O orçamento mínimo é de 20 mil transições, arredondado ao episódio completo. GA–DQN acrescenta a busca genética e mil demonstrações. Acima do gatilho genético, pede zero; abaixo, executa o máximo entre a ação da rede e metade do lote genético. Essa transformação é igual em demonstração, treino e aplicação. O esforço excede o do DQN; não se isola causalmente o benefício da combinação (Zabraoui et al., 2025).

GA, PPO, DQN e GA–DQN usam sementes 11, 29 e 47; as referências determinísticas têm um ajuste. Primeiro promediamos as sementes dentro de série, origem e política. Elas representam variação do treinamento, não novas realizações de demanda.

5.5 Separação temporal e comparação

Em cada origem o, o desenho é

$$\underbrace{1,\ldots,o}_{\text{treino}} \; ; \; \underbrace{o+1,\ldots,o+7}_{\text{validação}} \; ; \; \underbrace{o+8,\ldots,o+14}_{\text{teste}}. \tag{5.5}$$

Na Bahia, os testes compartilham um ciclo; no M5, ocupam 58–64, 72–78 e 86–92, sem sobreposição. Não se combinam origens posteriores para recomendar em uma anterior.

A validação começa após seis ciclos de aquecimento com referência EOQ. A trajetória dessa referência na validação fornece estoque e pipeline comuns no teste. O estado usa apenas o passado e não continua o estoque próprio de cada candidata. Essa convenção isola comparações no mesmo ponto inicial, sem simular implantação contínua de cada política.

Uma loja inteira é excluída do conjunto que define o seletor, separadamente em cada origem. As outras lojas fornecem resultados de validação; a loja reservada fornece o teste. O controlador conserva o treino no histórico da própria série. Avalia-se transferência do seletor com histórico disponível, não generalização para lojas sem observações.

5.6 Instanciação dos seletores

5.6.1 Associação e rótulos

Para um conjunto A de casos de validação, a regra global escolhe

$$\hat{\pi}_A = \arg \min_{\pi:\bar{F}_{\pi,A}\geq 0{,}70} \bar{C}_{\pi,A}. \tag{5.6}$$

O PSE por perfil aplica a regra a cada A_g. Sem viável, escolhe maior NS e menor custo; perfis sem suporte usam a global. O rótulo preditivo usa o mesmo critério na série individual. Serviço inteiramente indefinido leva a menor custo, com marcação de demanda zero. Empates restantes usam convenção determinística registrada na análise.

As restrições por série e por grupo diferem; a moda dos rótulos é um controle adicional com o mesmo alvo categórico. Todos os seletores são avaliados pelas consequências de suas escolhas. Acurácia é auxiliar: errar entre políticas quase empatadas difere de perder muito serviço.

5.6.2 Aprendizado e recuo conservador

O preditivo por classe utiliza XGBoost com 200 árvores, profundidade três, taxa 0,05, semente fixa e sem subamostragem. Imputação, codificação do perfil e classes são ajustadas dentro de

cada fold. Classes raras não são removidas; uma classe única leva a classificador constante. A quantidade de exemplos de treinamento depende da origem e da loja excluída.

A ablação retira somente a entrada de perfil. O piloto anterior motivou alternativas de aprendizagem e intervenção; a avaliação consolidada aplica os seletores às matrizes completas e mantém a distinção entre desenvolvimento e confirmação independente (Cawley and Talbot, 2010).

5.6.3 Comparação por consequências

A comparação usa a mesma matriz de cada base, sem repetir ajustes de controladores. Duas florestas ExtraTrees estimam custo e serviço das sete candidatas: 64 árvores, profundidade máxima quatro e mínimo de três observações por folha. O custo é aprendido como $\log(1+C)$ e transformado de volta. O serviço usa casos definidos, sem transformar demanda zero em atendimento completo. A recomendação direta escolhe menor custo previsto entre candidatas com serviço previsto de pelo menos 0,70; sem candidata viável, prioriza serviço e depois custo.

A variante com recuo usa a global como referência e exige serviço previsto de pelo menos 0,70, serviço previsto não inferior ao da referência e economia acima de uma margem. A margem pertence a $\{0;0{,}02;0{,}05;0{,}10;\infty\}$, sendo ∞ o recuo permanente. Ela minimiza custo na validação interna sujeita a serviço médio não inferior à referência. Cada origem mantém uma loja externa reservada e divide as demais em cinco grupos de lojas. Cada grupo interno recebe previsões de um modelo que exclui suas observações. Depois da escolha da margem, o modelo externo é ajustado em todas as lojas admitidas e recomenda para a loja reservada.

Um classificador ExtraTrees com a mesma regularização oferece um controle por rótulo vencedor; outra ablação remove o perfil da previsão de consequências sem recuo. As recomendações são persistidas antes da pontuação do teste. O piloto orientou o desenho; a análise consolidada não é apresentada como confirmação independente. O critério empírico não garante atendimento futuro, e a diferença entre objetivos individuais previstos e objetivos médios dos comparadores permanece uma limitação.

5.6.4 Execução e compatibilidade das matrizes

A execução separa planejamento, ajuste dos controladores e avaliação dos seletores. A preparação audita painéis, identidades, código e configurações antes de aproveitar checkpoints. A avaliação recusa matrizes incompletas e usa o mesmo pré-processamento para modelos por classe e por consequências, ajustado somente no conjunto admitido em cada partição. As duas bases incluem global, perfil, classe vencedora com e sem perfil, moda dos rótulos, floresta de classe de controle e previsão de consequências com e sem perfil e com recuo. Oráculos, intervenções e deteriorações completam a avaliação.

A Bahia reúne 4.350 ajustes e o M5, 79.890. Ajustes previamente compatíveis foram rea-

proveitados após auditoria, sem serem contados como novas observações independentes. A avaliação brasileira preserva sua relevância aplicada, mas continua sendo simulação com custos de cenário e possível censura das vendas. As bases fornecem contextos complementares, sem combinar custos entre elas.

5.6.5 Aplicação e reavaliação

O uso pretendido entrega recomendação, parametrização e evidências para decisão do gerente. Na avaliação atual, a família escolhida permanece por sete ciclos de teste, com ações de reposição em cada período. Essa configuração não valida uma nova seleção a cada ciclo comercial. Uma avaliação sequencial deverá separar revisão do PSE, atualização do seletor e recalibração dos controladores, mantendo estado e pedidos em trânsito próprios de cada estratégia. Integração operacional e supervisão humana exigem validação adicional.

5.7 Oráculos e decomposição das falhas

O melhor controlador único no teste e a melhor candidata por caso são referências retrospectivas. Não fornecem rótulos para a escolha. O oráculo do portfólio usa as médias entre sementes e a regra de menor custo viável. Empates numéricos contam como acerto sem exigir identidade nominal.

Nas duas bases, o planejamento com informação perfeita conhece a demanda do horizonte. Sua programação linear inteira mista (*mixed-integer linear programming*, MILP) mantém custos, prazo e estado inicial, com quantidades contínuas e variáveis binárias de emissão e saldo. Para falta u_t, chegada inicial a_t e pedido q_{t-L}:

$$I_t - u_t = I_{t-1} + a_t + q_{t-L} - d_t, \quad I_t u_t = 0, \quad \sum_t u_t \leq (1-\alpha) \sum_t d_t.$$

A complementaridade é linearizada com variáveis binárias e limites suficientes para o horizonte. Pedidos sem chegada antes do fim recebem zero, sem crédito terminal. Quando o alvo é fisicamente impossível nas primeiras entregas, maximiza-se atendimento antes de minimizar custo. Cada solução é conferida no simulador e recebe status de otimalidade.

Esse ótimo é determinístico e condicional, não o melhor controlador estocástico implantável. A eficiência $100C^*/C_{\mathrm{AIPE}}$ só é calculada sob o mesmo critério de serviço, com ambos os custos zero equivalendo a 100%. Compara-se o MILP com cada realização de treinamento viável, pois cumprir o alvo na média das sementes não implica cumpri-lo em cada uma.

A decomposição distingue atendimento do alvo, erro de seleção com alternativa viável, ausência de candidata viável apesar de possibilidade física, limite inicial do sistema e demanda zero. Assim, uma falta não é atribuída automaticamente ao seletor.

5.8 Incerteza e rastreabilidade

Bootstrap pareado preserva produtos e origens de cada loja, com 5.000 sorteios em cada base. Ajustes e escolhas permanecem fixos; os intervalos são condicionais. Dependência entre lojas que compartilham produtos e a quantidade de somente dez lojas do M5 limitam a inferência, mesmo com milhares de casos série–origem.

A auditoria das entradas encontrou vendas observadas nas duas bases, mas custos, prazo e estados iniciais de cenário. Preços e receita disponíveis não calibram custos logísticos. A fotografia brasileira de estoque, de 21/05/2025, é posterior aos testes e usa vínculos múltiplos entre franquias e revendedores; cobertura de códigos não comprova alocação física ou saldo histórico. Ela permanece fora dos estados iniciais.

Manifestos, snapshots, sementes e bancos transacionais identificam cada matriz. As matrizes são:
`aipe_ba145_unified_2026-10-15` e `aipe_m5_2408_unified_2026-10-15`

A pasta comum é `experiment/data/08_reporting/research_v2`. As recomendações são gravadas antes da pontuação externa. Dados não integram o Git e possuem backup separado; código e fontes documentais estão versionados.

A rastreabilidade existente é parcial: configurações, sementes, indicadores e recomendações são preservados, mas faltam parâmetros finais de todas as políticas, redes reutilizáveis, trajetórias e custos desagregados por caso. Uma prévia gerencial da Bahia consolidada separa recomendação e alternativas de validação dos resultados posteriores, com ausências explícitas; não completa esses artefatos. Recuperar detalhes pode exigir replay ou novo ajuste, registrado separadamente.

Os estudos brasileiros anteriores, incluindo a qualificação, motivam a investigação. A evidência quantitativa deste capítulo utiliza somente as matrizes consolidadas descritas, sem misturar configurações. A expansão nacional está cancelada. O módulo opcional de atributos adicionais é examinado em estudo de desenvolvimento separado, reutilizando as matrizes de controladores. As variantes desse estudo compartilham floresta de 32 árvores e regra de intervenção fixa; não são contrastes isolados de atributos frente aos modelos de 64 árvores ou ao XGBoost da avaliação principal. A ativação depende da disponibilidade temporal documentada. Na Bahia, a correspondência do cadastro com o período é informada pelo autor, sem histórico de alterações por campo.

6

Resultados e Discussão

Este capítulo avalia as instanciações da metodologia AIPE, distinguindo qualidade dos controladores, utilidade da seleção e limites da recomendação. A Bahia reúne 145 séries em duas origens, com 290 casos; a coorte histórica do M5 reúne 2.408 identificadores, com 5.326 casos nas três origens. As bases são analisadas separadamente sob a mesma definição de calibração e avaliação. Um piloto anterior orientou o desenvolvimento, sem tornar a ampliação uma confirmação independente.

Os números a seguir pertencem às matrizes completas e aos protocolos identificados no Capítulo 5. A comparação usa validação externa por loja e cinco grupos internos na escolha da margem de recuo. Custo inclui todos os casos; atendimento usa os 283 casos brasileiros e os 5.138 casos M5 com demanda positiva no teste. Um estudo adicional do módulo opcional de atributos é apresentado separadamente, com referência interna própria.

6.1 Resultados da avaliação unificada

Tabela 6.1: Bahia: resultados por caso série–origem. Custo: 290 casos; atendimento: 283 casos definidos. Custo em unidades de cenário.

Implementação	Custo médio	Atendimento	Viáveis	Trocas
Referência global	161,31	73,62%	164	0
PSE por perfil	164,41	77,51%	183	80
PSE por classe (XGBoost)	166,57	70,04%	155	206
Classe: floresta de controle	155,79	68,16%	154	143
Consequências	159,05	72,77%	165	106
Consequências sem perfil	161,65	74,07%	170	90
Consequências com recuo	161,31	73,62%	164	0

Trocas indicam política diferente da referência global; viáveis têm atendimento $\geq 0{,}70$.

Tabela 6.2: M5: resultados por caso série–origem. Custo: 5326 casos; atendimento: 5138 casos definidos. Custo em unidades de cenário.

Implementação	Custo médio	Atendimento	Viáveis	Trocas
Referência global	779,46	68,27%	2448	0
PSE por perfil	780,80	68,49%	2471	411
PSE por classe (XGBoost)	811,31	65,37%	2255	4259
Classe: floresta de controle	812,42	63,99%	2177	4299
Consequências	760,45	68,08%	2456	3629
Consequências sem perfil	761,77	67,92%	2440	3655
Consequências com recuo	764,20	68,59%	2472	679

Trocas indicam política diferente da referência global; viáveis têm atendimento $\geq 0{,}70$.

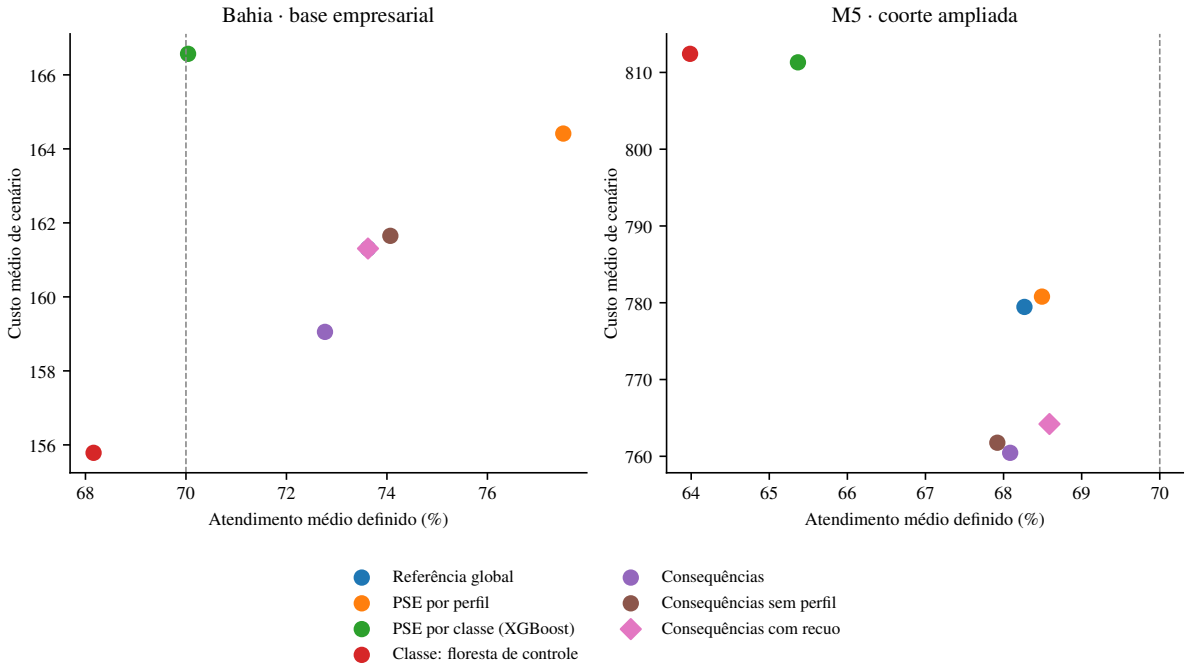


Figura 6.1: Custo e atendimento nas duas aplicações. As médias não mostram a distribuição individual nem constituem fronteira de dominância por série.

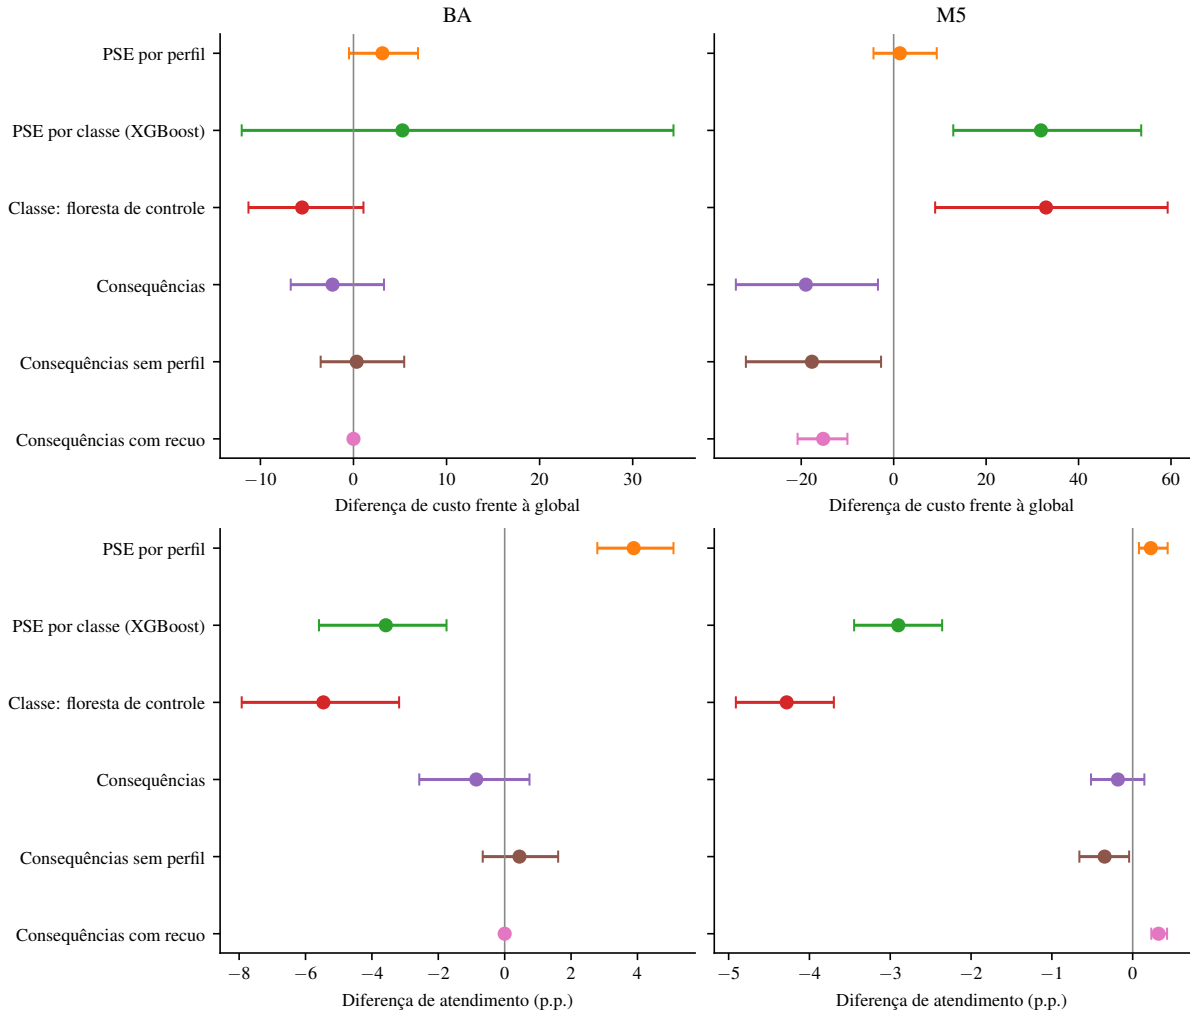


Figura 6.2: Diferenças pareadas frente à referência global. Intervalos condicionais por loja, preservando produtos e origens; dez lojas limitam a precisão no M5.

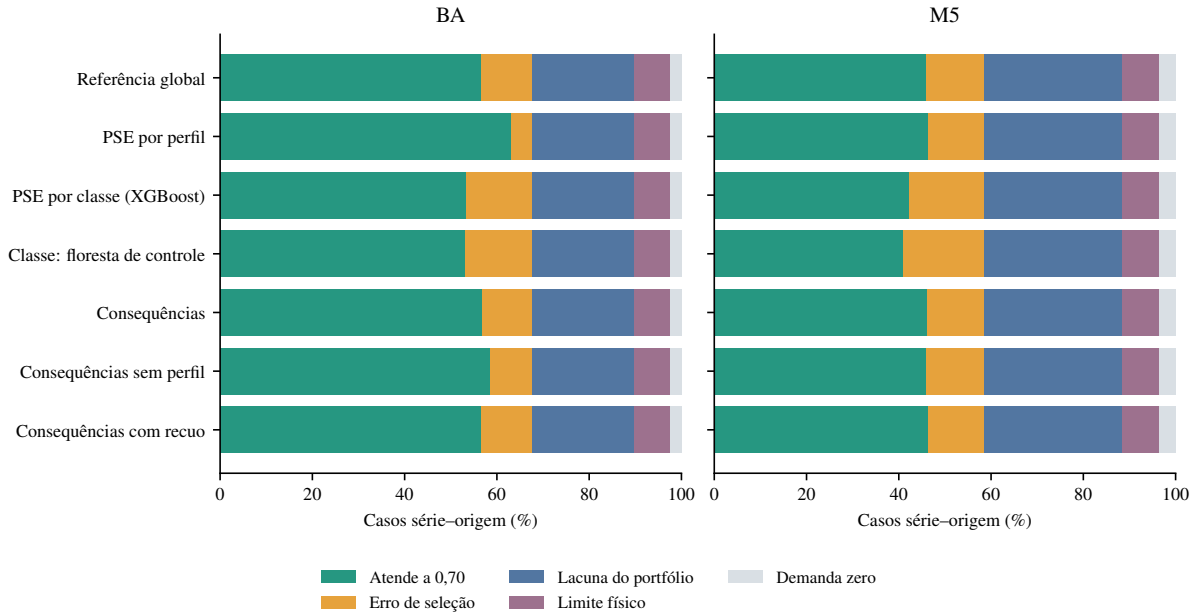


Figura 6.3: Diagnóstico retrospectivo dos casos. A classificação distingue falha de seleção, cobertura do portfólio e restrição física inicial; demanda zero mantém atendimento indefinido.

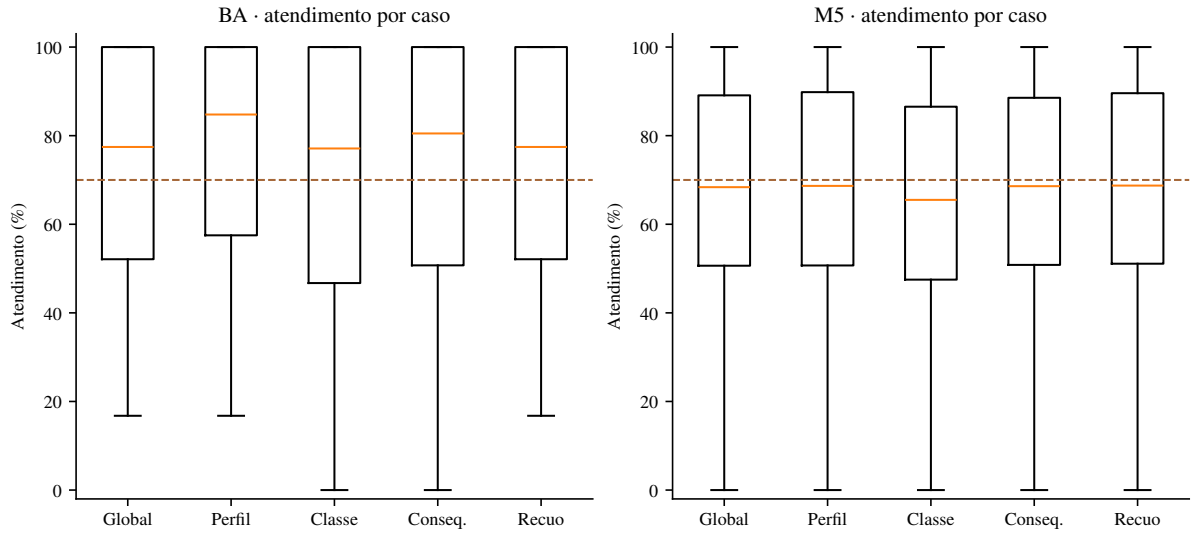


Figura 6.4: Distribuição do atendimento nos casos com demanda positiva; linha horizontal indica 70%. Extremos são omitidos da exibição dos boxplots, mas permanecem nos cálculos.

6.2 Diagnósticos complementares da avaliação unificada

Tabela 6.3: Bahia: diferenças pareadas frente à referência global. Intervalos condicionais de 95%, com 5.000 reamostragens por loja.

Implementação	Custo: diferença [IC]	Serviço: p.p. [IC]
PSE por perfil	3,11 [-0,48; 6,93]	3,89 [2,79; 5,09]
PSE por classe (XGBoost)	5,26 [-12,01; 34,38]	-3,58 [-5,59; -1,75]
Classe: floresta de controle	-5,52 [-11,28; 1,07]	-5,46 [-7,92; -3,18]
Consequências	-2,25 [-6,74; 3,28]	-0,86 [-2,57; 0,75]
Consequências sem perfil	0,34 [-3,53; 5,45]	0,45 [-0,66; 1,61]
Consequências com recuo	0,00 [0,00; 0,00]	0,00 [0,00; 0,00]

Tabela 6.4: Bahia: aproximação do oráculo do portfólio, calculado após agregar sementes. Eficiência somente entre casos comparáveis.

Implementação	Acertos / comparáveis	Eficiência média	Até 5%
Referência global	58/164	68,80%	66
PSE por perfil	61/183	69,02%	71
PSE por classe (XGBoost)	67/155	71,29%	74
Classe: floresta de controle	55/154	66,96%	59
Consequências	57/165	68,70%	65
Consequências sem perfil	55/170	68,31%	65
Consequências com recuo	58/164	68,80%	66

Comparabilidade exige atendimento de pelo menos 0,70 tanto da implementação quanto do oráculo. Denominadores diferentes não sustentam comparação direta das eficiências condicionais.

6.3 Avaliação do contexto adicional

O módulo adicional foi avaliado reutilizando as matrizes de políticas, sem novos ajustes dos controladores. Foram comparados o PSE básico, todos os atributos admissíveis, a seleção interna de atributos e sua ativação protegida, separadamente nas instâncias por classe e por consequências. Os contrastes usam florestas de 32 árvores com os mesmos parâmetros entre variantes; portanto, suas referências básicas não se confundem com o classificador XGBoost nem com as variantes canônicas de 64 árvores. Não houve atributos adicionais impostos pelo gestor: a variante de atributos fixos coincide com a básica.

Na Bahia, idade, segmento comercial e filial foram incorporados sob a premissa declarada pelo autor de que o cadastro foi extraído diretamente do banco no mesmo período. Essa confirmação não substitui um histórico de alterações por campo. No M5, foram usados departamento do produto, preço histórico, indicação estadual do Supplemental Nutrition Assistance Program (SNAP), programa norte-americano de assistência alimentar, e eventos do último bloco com-

Tabela 6.5: Bahia: planejamento com informação perfeita. Comparações por realização da política escolhida; sementes não são observações independentes.

Implementação	Acertos / realizações viáveis	Eficiência média	Casos: todos acertos
Referência global	60/252	64,51%	37
PSE por perfil	44/219	59,89%	34
PSE por classe (XGBoost)	114/251	68,17%	52
Classe: floresta de controle	72/199	63,31%	43
Consequências	63/202	64,05%	41
Consequências sem perfil	59/220	63,66%	38
Consequências com recuo	60/252	64,51%	37

290/290 planos com ótimo certificado; 260 casos com demanda positiva fisicamente permitem atingir a meta; 7 casos sem demanda mantêm atendimento indefinido. Eficiência restringe-se às realizações viáveis com ótimo certificado.

Tabela 6.6: M5: diferenças pareadas frente à referência global. Intervalos condicionais de 95%, com 5.000 reamostragens por loja.

Implementação	Custo: diferença [IC]	Serviço: p.p. [IC]
PSE por perfil	1,34 [-4,37; 9,32]	0,22 [0,08; 0,43]
PSE por classe (XGBoost)	31,86 [12,89; 53,56]	-2,90 [-3,45; -2,36]
Classe: floresta de controle	32,97 [8,97; 59,28]	-4,28 [-4,91; -3,70]
Consequências	-19,00 [-34,14; -3,40]	-0,18 [-0,52; 0,14]
Consequências sem perfil	-17,69 [-31,97; -2,73]	-0,35 [-0,66; -0,04]
Consequências com recuo	-15,25 [-20,79; -10,01]	0,32 [0,23; 0,43]

Tabela 6.7: M5: aproximação do oráculo do portfólio, calculado após agregar sementes. Eficiência somente entre casos comparáveis.

Implementação	Acertos / comparáveis	Eficiência média	Até 5%
Referência global	335/2448	66,39%	438
PSE por perfil	344/2471	66,18%	444
PSE por classe (XGBoost)	734/2255	74,18%	883
Classe: floresta de controle	714/2177	73,40%	858
Consequências	681/2456	76,39%	909
Consequências sem perfil	697/2440	76,62%	926
Consequências com recuo	417/2472	69,77%	573

Comparabilidade exige atendimento de pelo menos 0,70 tanto da implementação quanto do oráculo. Denominadores diferentes não sustentam comparação direta das eficiências condicionais.

Tabela 6.8: M5: planejamento com informação perfeita. Comparações por realização da política escolhida; sementes não são observações independentes.

Implementação	Acertos / realizações viáveis	Eficiência média	Casos: todos acertos
Referência global	117/3159	46,49%	69
PSE por perfil	98/2991	45,35%	68
PSE por classe (XGBoost)	661/5142	49,56%	207
Classe: floresta de controle	702/4815	49,41%	203
Consequências	324/4160	49,36%	151
Consequências sem perfil	358/4246	50,07%	159
Consequências com recuo	122/3005	47,56%	87

5326/5326 planos com ótimo certificado; 4707 casos com demanda positiva fisicamente permitem atingir a meta; 188 casos sem demanda mantêm atendimento indefinido. Eficiência restringe-se às realizações viáveis com ótimo certificado.

Tabela 6.9: Incremento do contexto adicional em relação ao PSE básico da mesma instância. Variação negativa de custo indica economia; atendimento em pontos percentuais. Nesta rodada, selecionada e protegida coincidem em todas as recomendações.

Base	Instância	Δ custo (%)	Δ atendimento (p.p.)
Bahia	Classe	-1,176	-1,265
Bahia	Consequências	+0,000	+0,000
M5	Classe	-0,204	+0,337
M5	Consequências	-0,035	-0,003

pleto de 21 dias do prefixo. Nenhuma informação futura foi usada; o preço funciona como contexto e não altera os custos unitários do ambiente.

A redução de custo por classe na Bahia (1,176%) veio acompanhada de queda de 1,265 ponto percentual no atendimento. Assim, o ganho de custo não satisfaz isoladamente a finalidade gerencial do AIPE. A instância por consequências manteve exatamente as decisões básicas. No M5, os efeitos selecionados foram pequenos: 0,204% de economia e 0,337 ponto percentual adicional por classe; por consequências, 0,035% de economia e variação de -0,003 ponto percentual.

O bootstrap pareado de 5.000 reamostragens por loja/revendedor, preservando produtos e origens no mesmo grupo, produziu para a variação de custo os intervalos condicionais de 95% [-2,895; 0,371] na Bahia por classe e [-0,684; 0,345] no M5 por classe. Para o atendimento, os respectivos intervalos foram [-2,423; -0,339] e [0,122; 0,609] pontos percentuais. Esses intervalos descrevem os modelos congelados, sem refazer a seleção ou o ajuste; no M5 há somente dez lojas.

Usar todos os atributos também não assegurou vantagem da seleção. No M5 por classe, todos os atributos reduziram o custo em 0,540%, ante 0,204% com seleção, mas com menor incremento de atendimento (0,132 ante 0,337 ponto percentual). Na Bahia por classe, todos os atributos elevaram o custo em 0,044% e reduziram o atendimento. Os contrastes sustentam a necessidade de avaliar informação adicional pelo efeito operacional, sem estabelecer superiori-

dade geral da seleção de atributos ou garantia de atendimento da regra de ativação.

A rodada constitui desenvolvimento: os resultados canônicos já eram conhecidos, as partições de treino dos seletores se sobrepõem e não se realizou confirmação independente. A ampliação permanece opcional; eventuais economias devem ser examinadas com as deteriorações por caso e a relevância definida pelo gestor.

A Figura 6.5 apresenta os contrastes de custo e atendimento e sua incerteza condicional.

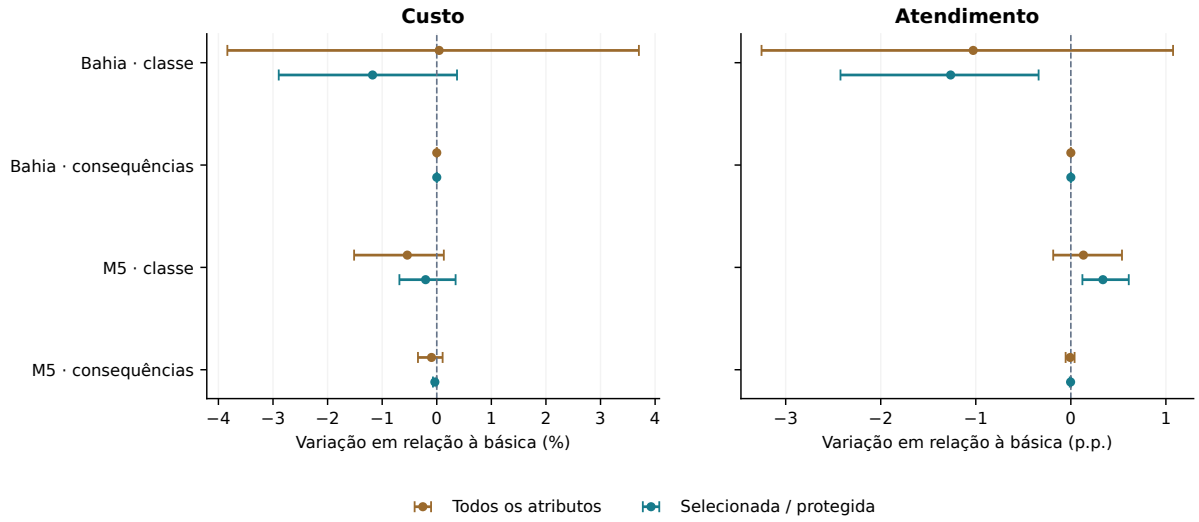


Figura 6.5: Efeito incremental do contexto sobre custo (esquerda) e atendimento (direita), perante o PSE básico da mesma instância. Pontos: variações observadas; barras: intervalos condicionais de 95% de 5.000 reamostragens pareadas por loja/revendedor, mantendo produtos e origens agrupados. Custo negativo indica economia. Seleção e ativação protegida coincidiram nesta rodada. O bootstrap não refaz os ajustes; o M5 possui dez lojas.

6.4 Esforço computacional das políticas

A Tabela 6.10 descreve os ajustes efetivamente executados nas filas consolidadas. Cada ajuste é contado uma vez, sem duplicar validação e teste. Os ajustes reaproveitados são excluídos. Na Bahia, apenas a CappedBaseStock foi reajustada nessa fila; os demais controladores foram incorporados após auditoria. No M5, a amostra contém ajustes novos das sete políticas. As contagens descrevem esforço, sem ampliar a população de séries.

As referências analíticas têm ajuste simples; GA–DQN inclui busca, demonstrações e treinamento da rede. Maior esforço não comprova recomendação melhor. Esses registros não constituem teste controlado de velocidade entre processadores e não equivalem ao tempo total decorrido. Comparar causalmente eficiência computacional exigiria controlar hardware, carga, orçamento e repetições.

Tabela 6.10: Duração registrada dos ajustes não reaproveitados. Tempos em segundos; execução sob concorrência e carga variável.

Base	Política	Ajustes	Mediana (s)	Média (s)
Bahia	CappedBaseStock	290	0,01	0,01
M5	CappedBaseStock	5.236	0,04	0,04
M5	DQN	13.878	49,91	50,03
M5	EOQCycle	4.624	0,00007	0,00007
M5	GA	13.872	1,42	1,50
M5	GA–DQN	13.877	51,59	51,86
M5	PPO	13.873	16,00	17,01
M5	sSCycle	4.624	0,00007	0,00007

6.5 Síntese das respostas e limites

A avaliação da utilidade exige distinguir o resultado da seleção e o resultado de cada controlador. Na Bahia, a seleção por perfil acrescenta atendimento com custo pontualmente maior; o preditivo por classe aumenta custo e perde serviço. A previsão direta de consequências reduz custo, mas também reduz atendimento médio. A variante conservadora mantém a referência nos 290 casos. Portanto, as diferentes implementações não oferecem uma resposta única sobre a conveniência de contextualizar.

No M5, a seleção por perfil permanece próxima da referência, enquanto o preditivo por classe aumenta custo em 4,09% e reduz atendimento em 2,90 pontos percentuais. A previsão direta de consequências reduz custo e perde atendimento; sua variante com recuo reduz custo em 1,96% e acrescenta 0,32 ponto. A comparação distingue aprender uma vencedora, estimar consequências e decidir quando intervir. Os ganhos médios coexistem com 19 novas violações e 43 recuperações do alvo: o número de casos viáveis aumenta, sem garantia individual.

A contribuição metodológica está em explicitar essas escolhas, submetê-las à mesma comparação operacional e localizar limitações. Conservar a referência é uma saída admitida; não demonstra que o preditivo acrescentou valor. Economia com atendimento menor também não satisfaz automaticamente o objetivo do gerente. Magnitude, incerteza, deteriorações e suporte das recomendações precisam acompanhar as médias.

O oráculo do portfólio e o planejamento com informação perfeita delimitam problemas diferentes. No M5, o recuo iguala o custo viável do portfólio em 417 dos 2.472 casos comparáveis, com eficiência média condicional de 69,77%. Frente ao ótimo determinístico, são 122 acertos em 3.005 realizações de treinamento comparáveis, com eficiência média de 47,56%. Casos, realizações e subconjuntos condicionais não são intercambiáveis. As Tabelas 6.7 e 6.8 preservam os denominadores de cada implementação.

A concentração dos perfis persiste na coorte M5: 826 das 885 séries elegíveis na primeira origem são esparsas, 57 têm tendência e duas pertencem ao grupo de volatilidade/sazonalidade. Nas origens 64 e 78, são 1.977 de 2.033 e 2.360 de 2.408 séries esparsas.

Os rótulos satisfazem regras explícitas; a maior cobertura não garante diversidade de contexto.

As evidências são condicionais a coortes históricas, sete ciclos de teste, vendas possivelmente censuradas, custos de cenário e estados iniciais de referência. As origens repetem séries; a Bahia compartilha um ciclo. O bootstrap preserva lojas, mas não mede novos treinamentos ou toda a dependência entre produtos e lojas. O M5 mantém dez lojas, apesar do grande número de casos.

Quanto à primeira questão de pesquisa, as aplicações exercitam as etapas e os contratos definidos pelo AIPE. Quanto à terceira, os diagnósticos distinguem dificuldades de seleção, cobertura do portfólio e viabilidade física. A confirmação de benefício operacional requer escolhas fixadas antes de examinar os testes e unidades excluídas do desenvolvimento. O módulo opcional de atributos adicionais é avaliado separadamente desta matriz de controladores e seletores.

7

Conclusões

Esta dissertação propõe o AIPE como metodologia modular de apoio ao gerente de logística e estoques na redução de custos evitáveis, preservando o atendimento. Recomendações contextualizadas devem reunir família, parâmetros, alternativas e evidências rastreáveis para decisão humana. Sua formulação explicita entradas, cinco etapas, critérios e saídas, distinguindo o procedimento geral das escolhas de cada aplicação. O PSE é o componente de recomendação; associação por perfil e estimação preditiva são suas duas abordagens. Algoritmos de estoque, modelos supervisionados e mecanismos de recuo são instrumentos para instanciá-las.

7.1 Respostas às questões de pesquisa

A primeira questão trata de como estruturar o procedimento. O AIPE encadeia especificação da decisão, representação do contexto, construção de evidência comparável, recomendação e avaliação. Ao separar família e parâmetros, referência e intervenção, desenvolvimento e confirmação, a metodologia explicita quais dados sustentam uma escolha e o que precisa ser observado para julgá-la. O capítulo metodológico define esses compromissos; o desenho experimental mostra sua execução. A existência do procedimento não demonstra, por si, economia operacional.

A segunda questão trata de sua utilidade. Na Bahia, a seleção por perfil acrescenta 3,89 pontos percentuais de atendimento com aumento pontual de custo de 1,93%, reduzindo violações de 119 para 100 entre 283 casos com demanda. A estimação por classe apresenta maior custo e menor atendimento que a referência. A previsão direta de consequências reduz custo e atendimento, enquanto sua variante com recuo reproduz a global nos 290 casos. A utilidade depende da implementação e do compromisso operacional que o gerente aceita.

No M5, a previsão de consequências com recuo reduz o custo médio em 1,96% e acrescenta 0,32 ponto percentual de atendimento frente à global. A regra modifica 679 dos 5.326

casos, com 19 novas violações e 43 recuperações do alvo. Os intervalos condicionais favorecem essas diferenças médias na coorte avaliada, mas a existência de perdas individuais impede alegar preservação geral do serviço. O atendimento médio é 68,59%, abaixo do alvo de 70%. Já a classificação da família vencedora aumenta custo e reduz atendimento. Assim, a avaliação sustenta utilidade de uma instanciação específica, sem demonstrar superioridade de toda abordagem contextual.

A terceira questão trata dos limites. Contexto disponível, cobertura dos perfis, estabilidade das escolhas e viabilidade do atendimento condicionam a recomendação. A concentração dos perfis persiste no M5 ampliado. O número maior de séries não elimina a dependência entre origens e lojas, nem substitui uma avaliação de transferência para outras condições de operação.

7.2 Contribuição e alcance

A contribuição principal é o AIPE como metodologia modular e rastreável de apoio ao gerente na escolha de políticas de reposição. As duas abordagens do PSE concretizam a seleção contextual sob contratos comuns; o diagnóstico identifica limitações da escolha, do portfólio e das condições físicas; Bahia e M5 delimitam sua utilidade em contextos complementares. O procedimento permite examinar quando intervir e quando conservar a referência. Seus métodos constituintes possuem antecedentes, e o diferencial frente às integrações próximas ainda requer confronto empírico.

O diagnóstico retrospectivo distingue limitações sob as hipóteses do simulador, sem estabelecer causas das rupturas observadas na empresa. No M5, o recuo mantém 649 falhas com alternativa viável, 1.586 casos sem candidata viável apesar de possibilidade física e 431 com restrição física inicial; outros 188 não têm demanda. Melhorar o seletor não resolve toda falta. A eficiência média é 69,77% frente ao portfólio nos 2.472 casos comparáveis e 47,56% frente ao planejamento perfeito nas 3.005 realizações de treinamento comparáveis. Os denominadores distintos delimitam cada medida, sem converter essa distância em economia disponível a uma política sem informação futura.

A implementação e os registros computacionais sustentam rastreabilidade parcial; parâmetros finais de todas as políticas, trajetórias completas e validação com gerentes continuam pendentes; os resultados brasileiros e públicos avaliam o procedimento em contextos delimitados. Não demonstram implantação contínua, economia financeira realizável ou redução do custo computacional de uso. Origens e sementes repetidas não ampliam a população independente. Custos de cenário, vendas possivelmente censuradas, coortes históricas e janelas curtas restringem as conclusões.

7.3 Continuidade

A relevância prática deve ser julgada pelo gerente com magnitudes, incerteza e deteriorações disponíveis, sem corte universal de economia. A parametrização temporal é requisito do desenho: a configuração testada mantém a família por sete ciclos e não demonstra revisão a cada ciclo. Avaliar essa rotina requer preservar estoque e compromissos entre decisões e definir atualizações dos modelos antes do teste.

O próximo passo é fixar uma avaliação independente da regra de intervenção e examinar sensibilidades das condições de uso. O piloto já observado permanece desenvolvimento. Referências globais fortes devem acompanhar ambas as abordagens do PSE, com análise de deteriorações e concentração de benefícios. A avaliação independente deve examinar em quais condições recomendar a intervenção, quais deteriorações ela produz e quando conservar a referência.

8

Continuidade e Validação Final

A metodologia AIPE está formulada e possui duas aplicações experimentais consolidadas. Bahia e M5 têm matrizes completas de controladores, seletores e oráculos, com 4.350 e 79.890 ajustes, respectivamente. Os resultados sustentam a execução do procedimento e delimitam a utilidade das implementações avaliadas. O piloto anterior orientou diagnóstico e recuo e integra o desenvolvimento; concluir a avaliação ampliada não estabelece confirmação independente. O estudo adicional de atributos também é de desenvolvimento. A continuidade deve examinar transferência, sensibilidades e uso gerencial, sem apresentar essas etapas como resultados já obtidos. A avaliação nacional permanece fora do escopo experimental desta versão.

8.1 Separar desenvolvimento e confirmação

Uma avaliação independente deverá reservar novas unidades ou períodos antes de examinar seus resultados e registrar suporte de cada perfil e classe. A concentração natural do M5 em séries esparsas impede presumir cobertura equilibrada. Elegibilidade e estratificação usam somente o treino; séries reservadas não podem orientar o ajuste do seletor.

O pipeline unificado usa cinco grupos internos por loja para escolher a margem de recuo, mantendo a loja externa excluída em cada origem. Outros hiperparâmetros e eventual simplificação de rótulos devem ser definidos somente no desenvolvimento. O teste de confirmação deverá ficar isolado dessas escolhas. Uma melhora encontrada no piloto ou na avaliação consolidada de desenvolvimento não é uma replicação independente (Cawley and Talbot, 2010). Ajustes de políticas compatíveis podem ser reaproveitados após auditoria de dados, configuração e código; mudanças científicas exigem novo ajuste da candidata afetada.

8.2 Preservar o problema de decisão

A avaliação unificada aplica pesos zero de ruptura e amplificação à calibração da CappedBaseStock nas duas bases. As tabelas e figuras desta versão apresentam as matrizes consolidadas. Novas comparações devem conservar o escopo da restrição de serviço: série, perfil ou rede. A meta de 0,70 e os custos atuais são parâmetros experimentais, não exigências empresariais já justificadas.

A previsão por consequências com recuo modifica 679 das 5.326 escolhas M5 e apresenta benefício médio, acompanhado de 19 novas violações e 43 recuperações do alvo. Na Bahia, conserva a referência nos 290 casos. Esses resultados justificam avaliar as condições de uso e as deteriorações, sem extrapolar uma vantagem universal. A instabilidade dos rótulos também motiva examinar conjuntos de candidatas quase empatadas e alvos sensíveis ao custo de erro. Essa análise deve ocorrer no desenvolvimento, sem selecionar a formulação pelo teste reservado. GA–DQN continua acompanhado por GA e DQN, com o esforço adicional informado.

8.3 Entrega gerencial e avaliação sequencial

A próxima etapa de desenvolvimento deve completar o contrato de recomendação: origem e qualidade das entradas, família e parâmetros finais, alternativas, consequências esperadas, hipóteses e ligação com a avaliação posterior. A prévia da Bahia reaproveita indicadores persistidos; parâmetros e trajetórias ausentes não podem ser inferidos dos totais. Sua recuperação requer execução adicional quando não houver artefato exato, preservando a matriz de origem. O julgamento humano e a efetividade do apoio exigem estudo com usuários ou em campo.

A cadência informada para a empresa-fonte é uma revisão por ciclo comercial. Uma avaliação dessa rotina deve fixar período de ação, agregação, revisão do PSE, horizonte, janela e atualização dos modelos. Cada estratégia conserva seu próprio estoque e pedidos em trânsito; mudanças de família não reinicializam o sistema. O calendário físico e as convenções de custo precisam permanecer comparáveis ao testar outras cadências. A execução por blocos continua válida em seu escopo e não deve ser modificada silenciosamente para representar esse novo desenho.

8.4 Sensibilidades e eficiência

Prazo, custos relativos, estoque inicial, tratamento terminal e horizonte podem alterar o ranking e a viabilidade física. Seu efeito deverá ser separado do efeito do seletor. Calibração agrupada por perfil é outra hipótese: não equivale a seleção de família por perfil e exige comparação própria.

A escolha da unidade central de processamento (*central processing unit*, CPU) ou da uni-

dade de processamento gráfico (*graphics processing unit*, GPU) deve considerar tempo total sob a carga de uso prevista. A execução consolidada utilizou paralelismo CPU com quantidade de processos ajustável; essa configuração operacional não é uma vantagem científica de uma política. A eficiência computacional deve ser relatada como propriedade da execução, separada da qualidade das recomendações. A relevância prática será discutida por magnitude, incerteza, deteriorações e contexto, sem impor economia percentual universal. Inferência de não inferioridade do atendimento, se pretendida, exigirá margem justificada e desenho específico.

8.5 Critérios para a continuidade e a confirmação

Tabela 8.1: Compromissos de continuidade e confirmação independente, sem datas ainda não acordadas.

Etapa	Evidência necessária
Formulação do AIPE	Entradas, etapas, saídas e limites explicitados independentemente das bases
Protocolo final	Objetivo, suporte e calibrações fixados antes do teste
PSE	Comparação independente com global, perfil e controles simples
Robustez	Falhas físicas, portfólio, seleção e sensibilidades separadas
Redação	Afirmações alinhadas à evidência e revisão dos autores

A comparação com as integrações mais próximas da literatura deverá explicitar o que o AIPE acrescenta em formulação, responsabilidades dos módulos e evidência, sem atribuir originalidade aos métodos constituintes. O artigo concentra a metodologia e sua avaliação operacional; a dissertação mantém fundamentos, formulação e limites mais amplos. Os responsáveis precisam confirmar autoria, declarações, disponibilidade de dados e elementos institucionais antes de submissão ou depósito.

Referências

Victoria G. Achkar, Braulio B. Brunaud, Héctor D. Pérez, Rami Musa, Carlos A. Méndez, and Ignacio E. Grossmann. Extensions to the guaranteed service model for industrial applications of multi-echelon inventory optimization. *European Journal of Operational Research*, 313(1):192–206, 2024. **DOI** 10.1016/j.ejor.2023.08.013.

Sven Axsäter. *Inventory Control*, volume 90 of *International Series in Operations Research & Management Science*. Springer US, New York, NY, USA, 2 edition, 2006. ISBN 9780387332505. **DOI** 10.1007/0-387-33331-2.

Alex Batsis and Spyridon Samothrakis. Contextual reinforcement learning for supply chain management. *Expert Systems with Applications*, 249:123541, 2024. **DOI** 10.1016/j.eswa.2024.123541.

Robert N. Boute, Joren Gijsbrechts, Willem van Jaarsveld, and Nathalie Vanvuchelen. Deep reinforcement learning for inventory control: A roadmap. *European Journal of Operational Research*, 298(2):401–412, 2022. **DOI** 10.1016/j.ejor.2021.07.016.

John E. Boylan and Aris A. Syntetos. Forecasting for inventory management of service parts. In Khairy A. H. Kobbacy and D. N. Prabhakar Murthy, editors, *Complex System Maintenance Handbook*, pages 479–506. Springer, London, UK, 2008. **DOI** 10.1007/978-1-84800-011-7_20.

Gavin C. Cawley and Nicola L. C. Talbot. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11: 2079–2107, 2010. URL https://www.jmlr.org/papers/v11/cawley10a.html.

Andrew J. Clark and Herbert Scarf. Optimal policies for a multi-echelon inventory problem. *Management Science*, 6(4):475–490, 1960. **DOI** 10.1287/mnsc.6.4.475.

Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, USA, 2 edition, 1988. ISBN 9780805802832.

J. D. Croston. Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303, 1972. **DOI** 10.1057/jors.1972.50.

Ton de Kok, Christopher Grob, Marco Laumanns, Stefan Minner, Jörg Rambau, and Konrad Schade. A typology and literature review on stochastic multi-echelon inventory models. *European Journal of Operational Research*, 269(3):955–983, 2018. **DOI** 10.1016/j.ejor.2018.02.047.

Tansel Dokeroglu, Tayfun Kucukyilmaz, and El-Ghazali Talbi. Hyper-heuristics: A survey and taxonomy. *Computers and Industrial Engineering*, 187:109815, 2024. **DOI** 10.1016/j.cie.2023.109815.

John H. Drake, Ahmed Kheiri, Ender Özcan, and Edmund K. Burke. Recent advances in selection hyper-heuristics. *European Journal of Operational Research*, 285(2):405–428, 2020. **DOI** 10.1016/j.ejor.2019.07.073.

Adam N. Elmachtoub and Paul Grigas. Smart predict, then optimize. *Management Science*, 2022. **DOI** 10.1287/mnsc.2020.3922.

Burak Erkayman, Ferhat Yuna, and Mustafa Yılmaz. Markov approach for inventory control with meta-heuristics in intermittent demand environment. *PLOS ONE*, 20:e0325658, 2025. **DOI** 10.1371/journal.pone.0325658.

Ayse Sena Eruguz, Evren Sahin, Zied Jemai, and Yves Dallery. A comprehensive survey of guaranteed-service models for multi-echelon inventory optimization. *International Journal of Production Economics*, 172:110–125, 2016. **DOI** 10.1016/j.ijpe.2015.11.017.

Ádám Francuz and Tamás Bányai. Metaheuristic-based model selection framework for eoq and inventory policies using machine learning and multi-objective optimization. *Algorithms*, 19(5): 415, 2026. **DOI** 10.3390/a19050415.

Milton Friedman. A comparison of alternative tests of significance for the problem of m rankings. *The Annals of Mathematical Statistics*, 11(1):86–92, 1940. **DOI** 10.1214/aoms/1177731944.

Kevin Geevers, Lotte van Hezewijk, and Martijn R. K. Mes. Multi-echelon inventory optimization using deep reinforcement learning. *Central European Journal of Operations Research*, 32 (3):653–683, 2024. **DOI** 10.1007/s10100-023-00872-2.

Yonatan Geifman and Ran El-Yaniv. Selectivenet: A deep neural network with an integrated reject option. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97, pages 2151–2159, 2019. URL https://proceedings.mlr.press/v97/geifman19a.html.

Joren Gijsbrechts, Robert N. Boute, Jan A. Van Mieghem, and Dennis J. Zhang. Can deep reinforcement learning improve inventory management? performance on lost sales,

dual-sourcing, and multi-echelon problems. *Manufacturing & Service Operations Management*, 24(3):1349–1368, 2022. **DOI** 10.1287/msom.2021.1064.

Kwang-Il Goh and Albert-László Barabási. Burstiness and memory in complex systems. *EPL (Europhysics Letters)*, 81(4):48002, 2008. **DOI** 10.1209/0295-5075/81/48002.

Stephen C. Graves and Sean P. Willems. Optimizing strategic safety stock placement in supply chains. *Manufacturing & Service Operations Management*, 2(1):68–83, 2000. **DOI** 10.1287/msom.2.1.68.23267.

John H. Holland. *Adaptation in Natural and Artificial Systems*. MIT Press, Cambridge, MA, USA, 1992. ISBN 9780262581111.

Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006. **DOI** 10.1016/j.ijforecast.2006.03.001.

James Kennedy and Russell Eberhart. Particle swarm optimization. In *Proceedings of ICNN'95 — International Conference on Neural Networks*, volume 4, pages 1942–1948, 1995. **DOI** 10.1109/ICNN.1995.488968.

Pascal Kerschke and Heike Trautmann. Automated algorithm selection on continuous black-box problems by combining exploratory landscape analysis and machine learning. *Evolutionary Computation*, 27(1):99–127, 2019. **DOI** 10.1162/evco_a_00236.

Pascal Kerschke, Holger H. Hoos, Frank Neumann, and Heike Trautmann. Automated algorithm selection: Survey and perspectives. *Evolutionary Computation*, 27(1):3–45, 2019. **DOI** 10.1162/evco_a_00242.

S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983. **DOI** 10.1126/science.220.4598.671.

Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(3):48–60, 2014. **DOI** 10.1609/aimag.v35i3.2460.

Romain Laroche, Paul Trichelair, and Remi Tachet des Combes. Safe policy improvement with baseline bootstrapping. In *Proceedings of the 36th International Conference on Machine Learning*, volume 97, pages 3652–3661, 2019. URL https://proceedings.mlr.press/v97/laroche19a.html.

Hau L. Lee, V. Padmanabhan, and Seungjin Whang. Information distortion in a supply chain: The bullwhip effect. *Management Science*, 43(4):546–558, 1997. **DOI** 10.1287/mnsc.43.4.546.

Xiaotian Liu, Ming Hu, Yijie Peng, and Yaodong Yang. Multi-agent deep reinforcement learning for multi-echelon inventory management. *Production and Operations Management*, 34(7): 1836–1856, 2025. **DOI** 10.1177/10591478241305863.

Spyros Makridakis. Accuracy measures: Theoretical and practical concerns. *International Journal of Forecasting*, 9(4):527–529, 1993. **DOI** 10.1016/0169-2070(93)90079-3.

Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. The m4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1): 54–74, 2020. **DOI** 10.1016/j.ijforecast.2019.04.014.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015. **DOI** 10.1038/nature14236.

Davood Mohammaditabar, Seyed Hassan Ghodsypour, and Chris O'Brien. Inventory control system design by integrating inventory classification and policy selection. *International Journal of Production Economics*, 140(2):655–659, 2012. **DOI** 10.1016/j.ijpe.2011.03.012.

Mehran Nasseri, Taha Falatouri, Patrick Brandtner, and Farzaneh Darbanian. Applying machine learning in retail demand prediction—a comparison of tree-based ensembles and long short-term memory-based deep learning. *Applied Sciences*, 13(19):11112, 2023. **DOI** 10.3390/app131911112.

Peter Nemenyi. *Distribution-Free Multiple Comparisons*. PhD thesis, Princeton University, 1963.

Afshin Oroojlooyjadid, MohammadReza Nazari, Lawrence V. Snyder, and Martin Takáč. A deep q-network for the beer game: Deep reinforcement learning for inventory optimization. *Manufacturing & Service Operations Management*, 24(1):285–304, 2022. **DOI** 10.1287/msom.2020.0939.

Deniz Preil and Michael Krapp. Bandit-based inventory optimisation: Reinforcement learning in multi-echelon supply chains. *International Journal of Production Economics*, 252:108578, 2022. **DOI** 10.1016/j.ijpe.2022.108578.

Meng Qi, Yuanyuan Shi, Yongzhi Qi, Chenxin Ma, Rong Yuan, Di Wu, and Zuo-Jun Max Shen. A practical end-to-end inventory management model with deep learning. *Management Science*, 69(2):759–773, 2023. **DOI** 10.1287/mnsc.2022.4564.

John R. Rice. The algorithm selection problem. *Advances in Computers*, 15:65–118, 1976.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. **DOI** 10.48550/arXiv.1707.06347.

Alireza Sheikh-Zadeh, Manuel D. Rossetti, and Marc A. Scott. Performance-based inventory classification methods for large-scale multi-echelon replenishment systems. *Omega*, 101: 102276, 2021. **DOI** 10.1016/j.omega.2020.102276.

Rainer Storn and Kenneth Price. Differential evolution — a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4):341–359, 1997. **DOI** 10.1023/A:1008202821328.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, USA, 2 edition, 2018. ISBN 9780262039246.

Aris A. Syntetos and John E. Boylan. On the categorization of demand patterns. *Journal of the Operational Research Society*, 56(5):495–503, 2005. **DOI** 10.1057/palgrave.jors.2601841.

Aris A. Syntetos, John E. Boylan, and Stephen M. Disney. Forecasting for inventory planning: A 50-year review. *Journal of the Operational Research Society*, 60(S1):S149–S160, 2009. **DOI** 10.1057/jors.2008.173.

Yasin Tadayonrad and Alassane Balle Ndiaye. A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality. *Supply Chain Analytics*, 3:100026, 2023. **DOI** 10.1016/j.sca.2023.100026.

El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. John Wiley & Sons, Hoboken, NJ, USA, 2009. ISBN 9780470278581. **DOI** 10.1002/9780470496916.

Henri Theil. *Applied Economic Forecasting*. North-Holland, Amsterdam, 1966.

Nathalie Vanvuchelen, Joren Gijsbrechts, and Robert N. Boute. Use of proximal policy optimization for the joint replenishment problem. *Computers in Industry*, 119:103239, 2020. **DOI** 10.1016/j.compind.2020.103239.

Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. **DOI** 10.2307/3001968.

David H. Wolpert and William G. Macready. No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation*, 1(1):67–82, 1997. **DOI** 10.1109/4235.585893.

Linwei Xin. Technical note—understanding the performance of capped base-stock policies in lost-sales inventory models. *Operations Research*, 69(1):61–70, 2021. **DOI** 10.1287/opre.2020.2019.

Ferhat Yuna, Burak Erkayman, and Mustafa Yılmaz. Inventory control model for intermittent demand: A comparison of metaheuristics. *Soft Computing*, 27:6487–6505, 2023. **DOI** 10.1007/s00500-023-07871-0.

Oussama Zabraoui, Yahya Hmamou, Anas Chafi, and Salaheddine Kammouri Alami. A comparative study of multi-algorithm optimization for inventory analytics in supply chains. *Supply Chain Analytics*, 12:100154, 2025. **DOI** 10.1016/j.sca.2025.100154.

Paul H. Zipkin. *Foundations of Inventory Management*. McGraw-Hill/Irwin, Boston, MA, USA, 2000. ISBN 9780256113792.