

Proposta de Dissertação de Mestrado

Um Framework Adaptativo para Seleção de Políticas de Reposição em Regimes Operacionais Heterogêneos

Matheus Inácio Batista Santos
mibs@ic.ufal.br
Orientadores:

Dr. Rian Gabriel Santos Pinheiro
Dr. Bruno Costa e Silva Nogueira

Maceió

5 de junho de 2026

Matheus Inácio Batista Santos

Um Framework Adaptativo para Seleção de Políticas de Reposição em Regimes Operacionais Heterogêneos

Uma proposta de dissertação submetida por Matheus Inácio Batista Santos como requisito parcial para qualificação no curso de Mestrado em Informática pela Universidade Federal de Alagoas, Instituto de Computação.

Orientadores:
Dr. Rian Gabriel Santos Pinheiro

Dr. Bruno Costa e Silva Nogueira

Maceió

5 de junho de 2026

Proposta de dissertação submetida por Matheus Inácio Batista Santos como requisito parcial para qualificação no curso de Mestrado em Informática pela Universidade Federal de Alagoas, Instituto de Computação, avaliada pela banca examinadora que assina abaixo.

Dr. Rian Gabriel Santos Pinheiro - Orientador
Instituto de Computação
Universidade Federal de Alagoas

Dr. Bruno Costa e Silva Nogueira - Orientador
Instituto de Computação
Universidade Federal de Alagoas

- Examinador(a)

- Examinador(a)

- Examinador(a)

Maceió
5 de junho de 2026

Resumo

Redes varejistas precisam escolher políticas de reposição para séries de demanda heterogêneas. Esta dissertação investiga se características dessas séries permitem melhorar o compromisso entre custo e atendimento em relação a uma política global. A proposta, denominada *Adaptive Inventory Policy Engine* (AIPE), integra preparação de dados, caracterização da demanda e comparação de políticas em simulação. A avaliação brasileira avalia a coorte de 145 séries em duas origens temporais, com sete políticas incluindo um controle adicional, três sementes nos métodos estocásticos e blocos separados de validação e teste. Os 4.350 ajustes estão completos. A seleção por perfil aumenta o custo médio em 1,93% e o atendimento em 3,89 pontos percentuais, reduzindo de 119 para 100 os casos abaixo da meta de 0,70 entre 283 casos série–origem com demanda positiva. Os sete casos sem demanda no teste têm atendimento indefinido e são contabilizados separadamente. A escolha global varia entre origens; na segunda, ambos os seletores recomendam a mesma política. A evidência não demonstra economia geral da seleção por perfil, mas explicita o custo do serviço adicional e a sensibilidade temporal das recomendações. A contribuição é a formulação e a avaliação rastreável da seleção contextual no varejo brasileiro. A coorte retrospectiva e as janelas curtas parcialmente sobrepostas limitam a generalização. O componente supervisionado de seleção, *Policy Selection Engine* (PSE), permanece a validar; a avaliação complementar no M5 permanece em andamento.

Palavras-chave: Gestão de estoques; Demanda intermitente; Seleção de políticas; Nível de serviço; Simulação.

Abstract

Retail networks must choose replenishment policies for heterogeneous demand series. This dissertation investigates whether demand characteristics can improve the cost–service trade-off relative to a global policy. The proposed Adaptive Inventory Policy Engine (AIPE) integrates data preparation, demand characterization, and simulation-based policy comparison. The Brazilian evaluation evaluates the same 145-series cohort at two temporal origins, using seven policies including an additional control, three training seeds for stochastic methods, and separate validation and test blocks. All 4,350 fits are complete. Profile-based selection increases mean cost by 1.93% and mean fill rate by 3.89 percentage points. Cases below the 0.70 target decrease from 119 to 100 among 283 series–origin cases with positive test demand. Fill rate is undefined in seven zero-demand cases, which are counted separately. The global choice changes between origins; at the second origin, both selectors recommend the same policy. The evidence does not establish general cost savings from profile-based selection. It identifies the cost of additional service and the temporal sensitivity of recommendations. The contribution is a formulation and traceable evaluation of contextual policy selection in Brazilian retail. Retrospective cohort membership and short, partially overlapping test windows limit generalization. The supervised Policy Selection Engine (PSE) remains to be validated, while the complementary M5 evaluation is ongoing.

Keywords: Inventory management; Intermittent demand; Policy selection; Service level; Simulation.

Sumário

Lista de Figuras vi
Lista de Tabelas vii
Lista de Siglas viii

1 Introdução **1**
1.1 Motivação 1
1.1.1 Reposição em redes varejistas 1
1.1.2 Da calibração à seleção de políticas 2
1.2 Problema e questões de pesquisa 2
1.3 Objetivos 4
1.4 Contribuições e alcance da evidência 4
1.5 Escopo e delimitações 5

2 Referencial Teórico **6**
2.1 Formulação do Problema de Reposição 6
2.1.1 Política de Reposição: Estado, Ação e Parâmetros 6
2.1.2 Função Objetivo e Dinâmica de Estoque 7
2.2 Famílias de Políticas de Reposição 7
2.2.1 Políticas Clássicas 7
2.2.2 Parametrização de Políticas via Meta-Heurísticas 8
2.2.3 Políticas de Reposição via Aprendizado por Reforço 9
2.2.4 Políticas Híbridas GA-RL 9
2.3 Demanda Intermitente 10
2.3.1 Taxonomia ADI e CV quadrado 10
2.3.2 Efeitos na Reposição 11
2.4 Métricas de Previsão 11
2.4.1 Métricas Utilizadas 11
2.5 Testes Estatísticos 12
2.5.1 Teste de Wilcoxon 12
2.5.2 Teste de Friedman e Nemenyi 12
2.5.3 Tamanho de Efeito 13

3 Trabalhos Relacionados **14**
3.1 Famílias de métodos 14
3.2 Inventário e demanda intermitente 14
3.3 Previsão e utilidade operacional 15
3.4 Meta-heurísticas e aprendizado por reforço 16
3.5 Seleção de políticas e meta-aprendizado 16
3.6 Arquiteturas híbridas e posicionamento 17

4 Metodologia **18**
4.1 Dados e protocolo temporal da Bahia 18
4.1.1 Protocolo e cobertura 18
4.2 Visão Geral do AIPE 20
4.3 Formulação do problema e componentes do framework 20
4.3.1 Decisão e Ambiente 20
4.3.2 Métricas de Avaliação 22
4.4 Camada de Entrada: Dados e Pré-Processamento 23
4.4.1 Base de Dados 23
4.4.2 Preparação das Séries 23
4.5 Características e Perfis Operacionais 24
4.5.1 Regras de Perfil 25
4.6 Sinais Auxiliares de Previsão e Calibração 25
4.7 Portfólio de Políticas Candidatas 26
4.7.1 Composição e Referências 26
4.7.2 Regras Analíticas e Heurísticas 27
4.7.3 Busca de Parâmetros 27
4.7.4 Agentes de Reforço e Arquitetura Híbrida 28
4.7.5 Redundância e Classes de Rotulagem 29
4.8 Simulação, Validação Temporal e Estatística 29
4.8.1 Ambiente de Simulação 29
4.8.2 Separação Temporal 29
4.8.3 Inferência e Unidade Experimental 30
4.9 Geração de Rótulos e PSE 31
4.9.1 Problema de Seleção 31
4.9.2 Treinamento e Avaliação Propostos 31
4.9.3 Aplicação e Reavaliação 32
4.10 Escopo Experimental e Rastreabilidade 32

5 Resultados e Discussão **34**
5.1 Resultados: valor da seleção por perfil 34
5.1.1 Quais candidatas oferecem compromissos competitivos? 34
5.1.2 O perfil melhora a decisão frente à seleção global? 36
5.1.3 As escolhas e o atendimento são estáveis entre períodos? 37
5.2 Esforço computacional das políticas 38
5.3 Generalização e componentes ainda não avaliados 39
5.4 Alcance e limitações 39

6 Conclusões **40**
6.1 Respostas às questões de pesquisa 40
6.2 Contribuições e limites 40
6.3 Implicações e continuidade 41

7 Plano de Continuidade **42**
7.1 Consolidação dos experimentos 42
7.1.1 M5: avaliação pública com protocolo temporal 42
7.2 Validação da seleção 42
7.2.1 Calibração agrupada por perfil 43
7.3 Sensibilidade e eficiência 43

7.4 Consolidação do texto e critérios de conclusão 43

A Parâmetros e Resultados Complementares **45**
A.1 Resultados Agregados do Piloto na Paraíba 48

Referências **49**

Lista de Figuras

1.1 Ilustração conceitual da motivação da dissertação. Em redes varejistas, diferentes séries loja-produto podem apresentar vendas regulares, intermitentes ou concentradas em picos. A aplicação uniforme de uma mesma regra de reposição pode gerar excesso de estoque, ruptura ou instabilidade nos pedidos. A proposta do AIPE é tratar essa diferença como um problema de seleção contextual de políticas de reposição. 3
4.1 Fluxo da avaliação e separação da informação. Cada candidata é ajustada no treino da própria série. A estratégia de seleção usa a validação das demais lojas e é avaliada no teste da loja reservada. Os dois testes compartilham um ciclo; as origens são medidas repetidas. 19
4.2 Arquitetura conceitual do *framework* AIPE. A camada de entrada reúne dados transacionais preparados, parâmetros operacionais, características das séries e sinais auxiliares de previsão de demanda. O núcleo de seleção contextual utiliza essas entradas para avaliar políticas candidatas, gerar rótulos de política dominante, realizar validação estatística e treinar o *Policy Selection Engine*. A camada de aplicação utiliza o PSE para recomendar políticas a novas séries loja-produto e reavaliar periodicamente as recomendações conforme novos dados se acumulam. 21
4.3 Protocolo *walk-forward*: a janela de treinamento cresce incrementalmente e o modelo é avaliado apenas em dados futuros, respeitando a ordem das observações na divisão entre treino e avaliação. 30
5.1 Compromisso custo–serviço das sete candidatas na Bahia. Médias de teste em 290 casos série–origem para custo e 283 com demanda positiva para atendimento. A fronteira é descritiva: não utiliza o teste para escolher a recomendação nem representa dominância estatística ou por série. 35
5.2 Distribuição do atendimento das estratégias no teste, por origem. Cada caixa resume séries com demanda positiva; a linha tracejada indica 0,70. Há 144 casos por estratégia na primeira origem e 139 na segunda. As mesmas séries participam das duas estratégias; observações e origens não são independentes. . . . 37
5.3 Políticas escolhidas por perfil na validação das demais lojas, com meta 0,70. Cada painel contém 145 escolhas; os números indicam séries. A primeira origem diferencia grupos, enquanto a segunda recomenda sSCycle em todos eles. Nomes abreviados dos perfis correspondem às regras operacionais descritas no método. 38

Lista de Tabelas

2.1 Quadrantes de Syntetos-Boylan: limiares e interpretações. 10
3.1 Papel das famílias de métodos na pesquisa. 15
3.2 Relação entre linhas da literatura e o foco da dissertação. 17
4.1 Regras hierárquicas dos Perfis Operacionais de Demanda. 25
5.1 Bahia, protocolo temporal: médias no teste de sete ciclos. Custo em unidades do cenário, calculado nos 290 casos. Atendimento médio e contagem abaixo da meta consideram os 283 casos com demanda positiva; sete casos têm atendimento indefinido. 35
5.2 Escolha na validação das demais lojas e avaliação no teste da loja reservada, com meta 0,70. Há 145 casos por linha; atendimento definido em 144 casos na origem 17 e 139 na origem 23. 36
5.3 Duração registrada dos ajustes executados na rodada Bahia. Tempos em segundos; médias e medianas por ajuste, sem os 54 reaproveitados. 38
7.1 Etapas de continuidade e critérios de conclusão, sem datas ainda não acordadas. 44

A.1 Dados e ambiente de referência. 45
A.2 Regras e parâmetros das políticas clássicas e meta-heurísticas. 46
A.3 Agentes de reforço e híbrido: configurações documentadas. 46
A.4 Previsão auxiliar e seleção de políticas. 47
A.5 Rastreabilidade da reprodução. 47
A.6 Indicadores históricos do piloto PB: 15 lojas do produto 48130. 48

Lista de Siglas

Sigla	Significado
AIPE	*Adaptive Inventory Policy Engine*; estrutura proposta para seleção contextual de políticas.
PSE	*Policy Selection Engine*; componente supervisionado de seleção.
POD	Perfil Operacional de Demanda.
CTI	Custo Total de Inventário.
NS	Nível de Serviço: fração da demanda atendida.
TR	Taxa de Ruptura: fração de ciclos com falta.
BE	*Bullwhip Effect*: razão entre variâncias de pedidos e demanda.
FP	Frequência de Pedidos.
ADI	*Average Demand Interval*: intervalo médio entre demandas positivas.
CV	Coeficiente de Variação; CV^2 é seu quadrado.
SKU	*Stock Keeping Unit*: unidade de produto para controle de estoque.
EOQ	*Economic Order Quantity*: lote econômico de compra.
GA	*Genetic Algorithm*: algoritmo genético.
SA	*Simulated Annealing*: recozimento simulado.
DQN	*Deep Q-Network*: rede de valores de ação.
PPO	*Proximal Policy Optimization*: otimização de política com recorte.
RL / DRL	Aprendizado por reforço / aprendizado por reforço profundo.
GA-DQN	Política híbrida que combina GA e DQN.
LSTM	*Long Short-Term Memory*: rede recorrente com memória.
ANN	*Artificial Neural Network*: rede neural artificial.
ARIMA	*Autoregressive Integrated Moving Average*.
MASE	*Mean Absolute Scaled Error*.
sMAPE	*Symmetric Mean Absolute Percentage Error*.
RMSSE	*Root Mean Squared Scaled Error*.
ASP	*Algorithm Selection Problem*: problema de seleção de algoritmos.
M5	Competição de previsão baseada em vendas do Walmart.

1

Introdução

Uma rede varejista precisa decidir quando e quanto repor em cada loja. O problema se torna mais difícil quando um produto vende regularmente em uma unidade, mas passa vários ciclos sem venda em outra. Uma política que preserva disponibilidade no primeiro caso pode gerar excesso de estoque no segundo. Custos, faltas e variabilidade dos pedidos dependem da relação entre a regra de reposição e o comportamento da demanda (Axsäter, 2006; Syntetos and Boylan, 2005).

Esta dissertação investiga essa relação como um problema de seleção: dadas as características de uma série loja-produto e um portfólio de políticas, qual alternativa oferece menor custo sob uma exigência de serviço? A proposta recebe o nome de *Adaptive Inventory Policy Engine* (AIPE). Seu componente supervisionado, o *Policy Selection Engine* (PSE), permanece em desenvolvimento e validação.

1.1 Motivação

1.1.1 Reposição em redes varejistas

Diferenças de consumo, sazonalidade e condições logísticas dificultam o ajuste manual de estoques em redes com muitas lojas. Cada unidade decide sua reposição, mas seus pedidos também afetam o armazém. Lotes elevados podem reduzir a frequência de compra e aumentar o estoque; pedidos frequentes podem preservar disponibilidade e elevar custos fixos. A decisão envolve manutenção, falta, pedido e prazo de entrega (Axsäter, 2006; Zipkin, 2000).

A instabilidade dos pedidos acrescenta outra preocupação. Variações nas vendas podem produzir oscilações ainda maiores nas encomendas enviadas aos fornecedores, fenômeno conhecido como efeito chicote (Lee et al., 1997). Medir essa amplificação ajuda a avaliar consequências a montante, embora não substitua a análise conjunta de custo e serviço.

Considere dois históricos: um produto vende quantidades semelhantes a cada ciclo; outro apresenta a sequência “0, 0, 0, 50, 0, 0, 30”. No segundo caso, manter estoque para cobrir todos os picos pode ser caro, enquanto dimensioná-lo pela média pode aumentar as faltas. A demanda intermitente combina intervalos sem venda com ocorrências positivas; quando estas variam muito de tamanho, o padrão é chamado de *lumpy* (Croston, 1972; Syntetos and Boylan, 2005; Boylan and Syntetos, 2008).

Essas diferenças motivam comparar regras, mas não demonstram que um seletor por perfil será melhor que uma política única bem calibrada. A vantagem depende do portfólio, dos custos, do serviço exigido e da informação disponível antes da decisão. Uma escolha retrospectiva favorável pode desaparecer ao avaliar lojas ou períodos não usados no ajuste.

1.1.2 Da calibração à seleção de políticas

Políticas clássicas, meta-heurísticas e aprendizado por reforço oferecem formas distintas de decidir reposição. Uma meta-heurística pode ajustar o ponto de pedido e o lote de uma regra; um agente de reforço pode aprender ações a partir do estado do estoque. Antes desses ajustes, permanece a escolha de qual família utilizar (Syntetos et al., 2009; Boute et al., 2022).

O AIPE organiza essa escolha em quatro etapas: caracterizar a demanda, comparar políticas em um simulador comum, identificar alternativas viáveis segundo custo e serviço e investigar se essas diferenças orientam recomendações para novas séries. A formulação se aproxima da seleção de algoritmos, na qual características de uma instância ajudam a escolher um método (Rice, 1976; Kotthoff, 2014).

A previsão fornece informação auxiliar. Antecipar a demanda não determina automaticamente quando ou quanto pedir. Um modelo mais preciso tampouco garante menor custo de inventário. A avaliação principal deve ocorrer sobre as decisões de reposição e suas consequências operacionais.

A Figura 1.1 sintetiza a proposta: partir de séries heterogêneas, comparar um portfólio e avaliar a seleção contextual. O caminho entre essas etapas é uma hipótese a testar, não uma garantia de melhoria.

1.2 Problema e questões de pesquisa

A unidade de análise é a série de vendas de um produto em uma loja, agregada por ciclo comercial. As políticas decidem reposição sob condições comuns de demanda, custos e prazo. O critério de referência é o menor custo entre alternativas que atendam ao nível de serviço mínimo. Quando a restrição usa a média de um grupo, ela não garante atendimento mínimo para cada série.

A questão principal é: *características operacionais da demanda permitem selecionar políticas de reposição com melhor compromisso entre custo e serviço do que uma política única*



Figura 1.1: Ilustração conceitual da motivação da dissertação. Em redes varejistas, diferentes séries loja-produto podem apresentar vendas regulares, intermitentes ou concentradas em picos. A aplicação uniforme de uma mesma regra de reposição pode gerar excesso de estoque, ruptura ou instabilidade nos pedidos. A proposta do AIPE é tratar essa diferença como um problema de seleção contextual de políticas de reposição.

aplicada à rede? A investigação se divide em três perguntas:

1. O desempenho relativo das políticas varia entre séries e perfis operacionais?
2. Características observadas antes da decisão permitem aprender uma relação útil entre perfil e política?
3. Essa relação mantém desempenho em novas lojas, produtos ou períodos?

A primeira pergunta trata de heterogeneidade; a segunda, de aprendizagem; a terceira, de generalização. Elas exigem evidências distintas. Encontrar vencedores diferentes na própria amostra não valida o PSE nem demonstra economia futura. Diferenças estatísticas entre políticas também não substituem a comparação entre estratégias de seleção.

As hipóteses correspondentes são que existe heterogeneidade operacional relevante, que parte dela é capturada pelas características das séries e que um seletor pode aproveitar essa informação fora da amostra. As duas últimas permanecem em avaliação. Os resultados da

qualificação são exploratórios e motivam testes adicionais; não autorizam concluir que a seleção contextual supera sempre a melhor política global.

1.3 Objetivos

Objetivo geral

Propor e avaliar o AIPE como abordagem de seleção contextual de políticas de reposição para séries loja-produto, considerando custo de inventário, serviço e estabilidade dos pedidos em dados de uma rede varejista brasileira e em um recorte público do M5.

Objetivos específicos

1. Construir um ambiente comum para comparar políticas clássicas, meta-heurísticas, aprendizado por reforço e combinações desses métodos (Law, 2015; Talbi, 2009).

2. Preparar históricos e extrair características de intermitência, variabilidade, volume e comportamento temporal para análise por perfil.

3. Comparar política única e seleção por perfil, informando custo, serviço, casos inviáveis e sensibilidade às condições experimentais.

4. Desenvolver e validar o PSE com separação entre ajuste, escolha e avaliação, e comparar suas decisões com referências simples.

5. Examinar a validade externa em dados públicos de varejo e em recortes adicionais da base brasileira, preservando a rastreabilidade.

O piloto da Paraíba avaliou 15 lojas e um produto; a etapa histórica da Bahia ampliou a análise para 145 séries. Uma nova execução dessa coorte acrescenta ajuste no passado e blocos separados de validação e teste. O M5 oferece uma comparação histórica com 2.408 séries, cuja renova execução permanece em andamento. Esses estudos têm protocolos próprios, identificados no capítulo de resultados. A expansão nacional não integra a execução ativa.

1.4 Contribuições e alcance da evidência

A contribuição metodológica é formular a escolha de políticas como seleção contextual apoiada por um portfólio avaliado em condições comuns. A contribuição empírica é estudar essa escolha em séries reais do varejo brasileiro, com forte intermitência. A contribuição computacional é integrar preparação, caracterização, simulação e análise em um fluxo configurável.

GA, SA, DQN, PPO e suas combinações são métodos conhecidos. Sua presença no portfólio não constitui novidade algorítmica; a arquitetura GA–DQN já aparece em Zabraoui et al. (2025). O interesse está em entender quando uma alternativa oferece vantagem e se essa informação sustenta uma recomendação verificável.

A infraestrutura implementada permite comparar candidatos e regras explícitas de seleção. A nova execução da Bahia avalia essas escolhas em períodos posteriores; o PSE supervisionado ainda requer avaliação própria fora da amostra. Versões distintas do portfólio e do protocolo permanecem separadas para preservar o significado de cada resultado.

O protocolo histórico prevê cinco execuções por série e política, mas isso não basta para afirmar independência. Saídas determinísticas ou praticamente idênticas não aumentam a evidência empírica. A série e suas dependências por loja devem orientar a análise, como discutido nos capítulos de metodologia e resultados.

1.5 Escopo e delimitações

A pesquisa trata cada série loja-produto como uma decisão de reposição. Não modela substituição entre produtos, capacidade conjunta nem coordenação multiagente entre lojas e armazéns. O efeito chicote é um indicador complementar de variabilidade, não evidência de otimização de toda a rede.

O simulador avalia políticas sobre históricos preparados. Custos e abastecimento são parâmetros do cenário; roteamento, transporte e integração transacional com ERP ficam fora do escopo. A recomendação proposta é periódica e não troca de política a cada transação. Aprendizado por reforço multiagente, como o discutido por Liu et al. (2025), também não é implementado como coordenação da rede.

Os dados proprietários limitam a divulgação pública. A rastreabilidade depende de código, parâmetros e identificação dos artefatos e recortes. Vendas podem não representar toda a demanda quando há falta de estoque, e ciclos ausentes exigem tratamento cuidadoso. Essas limitações impedem interpretar automaticamente a simulação como ganho econômico realizável.

O Capítulo 2 apresenta os fundamentos; o Capítulo 3, a literatura; e o Capítulo 4, a implementação. O Capítulo 5 reúne os resultados exploratórios. As conclusões estão no Capítulo 6, e a continuidade no Capítulo 7.

2

Referencial Teórico

A seleção de políticas de reposição exige distinguir três objetos: o processo de demanda, a regra que produz pedidos e o critério usado para comparar seus resultados. Este capítulo define esses objetos e apresenta os métodos de previsão e inferência utilizados no trabalho. A descrição operacional dos experimentos fica no Capítulo 4.

2.1 Formulação do Problema de Reposição

2.1.1 Política de Reposição: Estado, Ação e Parâmetros

Uma política π transforma o estado observado $\mathbf{s}_t$ em uma quantidade de pedido não negativa:

$$\pi : \mathcal{S} \to \mathcal{A}, \qquad Q_t = \pi(\mathbf{s}_t; \boldsymbol{\theta}).$$

O estado reúne estoque disponível, pedidos em trânsito e informações de demanda disponíveis até a decisão. Os parâmetros $\boldsymbol{\theta}$ podem ser limiares e lotes, no caso de regras analíticas, ou pesos de uma rede neural. Meta-heurísticas ajustam parâmetros de uma regra; aprendizado por reforço ajusta a própria representação da decisão. Todas essas alternativas precisam ser avaliadas sob a mesma dinâmica de estoque.

É necessário separar estoque físico de posição de estoque. O primeiro determina o atendimento imediato; a segunda acrescenta os pedidos em trânsito e evita solicitar novamente unidades já encomendadas. Uma previsão de demanda pode integrar o estado, mas não substitui essas informações. Um vetor reduzido também não garante que o processo seja Markoviano: essa propriedade depende de representar informação suficiente para suas transições.

2.1.2 Função Objetivo e Dinâmica de Estoque

Para um horizonte finito T, o problema conceitual consiste em minimizar o custo esperado:

$$\min_{\pi} \mathbb{E}\left[\sum_{t=1}^{T}\left(hI_t + c_s S_t + c_o^{\text{fix}}\mathbf{1}(Q_t > 0) + c_o^{\text{var}} Q_t\right)\right]. \tag{2.1}$$

I_t é o estoque após atendimento, S_t a demanda perdida, h o custo de manutenção por unidade e ciclo, c_s o custo por unidade não atendida e c_o^{fix}, c_o^{var} os custos fixo e variável de pedido. A esperança representa incerteza da demanda ou do treinamento; repetir uma trajetória determinística não estima essa distribuição.

Se B_t é o estoque antes da chegada e A_t a quantidade recebida no ciclo, a dinâmica de vendas perdidas é

$$S_t = \max(0, D_t - B_t - A_t), \quad I_t = \max(0, B_t + A_t - D_t), \quad B_{t+1} = I_t. \tag{2.2}$$

A demanda não atendida não se acumula como encomenda pendente. A convenção de chegada deve acompanhar a equação: um modelo com prazo efetivo ℓ usa $A_t = Q_{t-\ell}$, como na avaliação temporal principal, com entrega efetiva em dois ciclos. Nos estudos históricos, a fila de tamanho $L+1$ correspondia à chegada em $t+L+1$. As convenções são identificadas separadamente na metodologia.

Minimizar custo sem restrição pode favorecer uma política que quase nunca repõe. Por isso, o trabalho acrescenta um nível mínimo de serviço. A escolha do limiar expressa um compromisso operacional e deve anteceder a comparação. Custos e serviço precisam ser apresentados conjuntamente, pois uma economia obtida com menor atendimento não caracteriza dominância.

2.2 Famílias de Políticas de Reposição

2.2.1 Políticas Clássicas

As políticas clássicas oferecem referências interpretáveis. Sob demanda constante média μ por ciclo, custo fixo K por pedido e manutenção h por unidade e ciclo, o lote econômico é

$$Q^* = \sqrt{2K\mu/h}.$$

Demanda e manutenção devem usar a mesma unidade temporal. A EOQ define o tamanho do lote; um ponto de pedido separado estabelece quando solicitá-lo. Com estoque de segurança, esse ponto pode ser $s = \mu L + z\sigma\sqrt{L}$, sob aproximações sobre demanda e prazo. A implementação histórica será distinguida dessa fórmula porque emprega uma demanda acumulada no

horizonte.

A política (s,S) observa a posição de estoque P_t e pede $\max(0,S-P_t)$ quando $P_t \leq s$. O limiar inferior evita pedidos a cada pequena redução de estoque; o superior determina a recomposição. A concentração de pedidos em lotes pode amplificar a variabilidade a montante, fenômeno associado ao efeito chicote (Lee et al., 1997). A intensidade desse efeito depende dos parâmetros e da demanda, não apenas do nome da política.

O modelo do Jornaleiro determina uma quantidade de período único pelo quantil de demanda associado à razão crítica entre falta e excesso. Na aproximação normal, escreve-se $Q^* = \mu + z_\alpha \sigma$. Essa expressão é ótima somente sob as hipóteses do modelo e com α derivado dos custos pertinentes. Usar $z = 1{,}28$ como parâmetro fixo em uma regra multiperíodo constitui uma heurística inspirada no modelo, não uma garantia de otimalidade.

Regras analíticas podem receber parâmetros específicos por série e, portanto, não pressupõem necessariamente uma única parametrização para toda a rede. Sua simplicidade é uma vantagem comparativa relevante: um método mais complexo precisa demonstrar ganho além do obtido por calibração adequada de uma referência simples.

2.2.2 Parametrização de Políticas via Meta-Heurísticas

Meta-heurísticas procuram vetores $\boldsymbol{\theta}$ em um espaço de busca. Cada candidato induz uma política, cuja execução simulada fornece custo e serviço. Essa abordagem dispensa uma expressão diferenciável para o desempenho, mas continua sujeita a sobreajuste ao histórico usado na busca. O objetivo, os limites dos parâmetros e o orçamento de avaliações devem ser controlados na comparação.

O Algoritmo Genético (GA) mantém uma população de candidatos e alterna seleção, cruzamento e mutação (Holland, 1992; Talbi, 2009). Em reposição, cromossomos podem codificar ponto de pedido e lote; a avaliação associa cada vetor à trajetória resultante (Yuna et al., 2023). Não há garantia geral de ótimo global em orçamento finito.

O Recozimento Simulado (SA) parte de uma solução e explora vizinhos. Uma piora ΔC pode ser aceita com probabilidade $\exp(-\Delta C/T_k)$, em que T_k é a temperatura (Kirkpatrick et al., 1983). Seu resfriamento controla a passagem de exploração para busca local. O resultado depende da escala da função objetivo, da vizinhança e do número de iterações.

Na Otimização por Enxame de Partículas (PSO), cada posição representa um candidato; velocidade, melhor posição individual e melhor posição coletiva orientam a atualização (Kennedy and Eberhart, 1995). A Evolução Diferencial (DE) gera candidatos pela combinação de diferenças entre vetores e aplica cruzamento e seleção (Storn and Price, 1997). Ambos são alternativas para espaços contínuos, mas não constituem, por si, regras operacionais distintas de reposição.

Mesmo quando duas buscas ajustam a mesma regra, seus custos computacionais e soluções podem diferir. A comparação deve identificar qual parte do ganho decorre do algoritmo

de busca e qual decorre da regra parametrizada. Otimizar cada série também é diferente de selecionar, entre políticas já calibradas, qual deve ser aplicada a uma nova série.

2.2.3 Políticas de Reposição via Aprendizado por Reforço

O aprendizado por reforço representa o controle como um processo de decisão $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$. O agente escolhe pedidos, recebe uma recompensa e observa a transição do inventário. Com recompensa $r_t = -C_t$, busca maximizar o retorno descontado $\sum_t \gamma^t r_t$ (Sutton and Barto, 2018). Uma restrição de serviço não é automaticamente satisfeita por essa recompensa: precisa de tratamento explícito ou verificação posterior.

DQN aproxima a função de valor $Q_\theta(s,a)$ por uma rede neural, usando memória de experiências e rede-alvo (Mnih et al., 2015). Sua aplicação requer ações discretizadas. A resolução dessa discretização limita os lotes disponíveis; episódios adicionais sobre a mesma série aumentam interações simuladas, mas não acrescentam novas realizações independentes de demanda.

PPO atualiza uma política por gradiente com uma razão de probabilidades limitada por *clipping* (Schulman et al., 2017). Pode ser formulado com ações contínuas ou discretas; essa propriedade precisa ser informada para cada implementação. Comportamentos como pedidos excessivos ou ausência de reposição podem resultar da recompensa, da escala dos estados, da exploração ou do treinamento. A observação de uma trajetória degenerada não identifica isoladamente sua causa.

SARSA atualiza valores seguindo a própria política:

$$Q(s,a) \leftarrow Q(s,a) + \eta[r + \gamma Q(s',a') - Q(s,a)].$$

A versão tabular exige discretizar o estado; Expected SARSA substitui o próximo valor pela esperança sobre ações. A adequação de cada representação depende da informação preservada e do tamanho do problema, e não permite concluir antecipadamente que uma família será superior nas séries estudadas.

2.2.4 Políticas Híbridas GA-RL

Uma arquitetura híbrida usa a busca evolutiva para obter parâmetros ou experiências iniciais e depois ajusta uma política por reforço. No GA–DQN, transições geradas com a política do GA podem preencher a memória do agente antes do refinamento. Trata-se de uma hipótese de melhoria da inicialização; seu benefício exige comparação com os componentes isolados e controle dos respectivos orçamentos.

A inicialização não elimina o risco de sobreajuste. Se busca e aprendizado observarem a mesma trajetória usada na avaliação, o resultado descreve adaptação ao histórico, não generalização. Além disso, avaliações completas de candidatos do GA e transições armazenadas

no DQN são quantidades diferentes. O trabalho trata o híbrido como candidato do portfólio; o problema de pesquisa é a seleção contextual entre candidatos.

2.3 Demanda Intermitente

Uma série intermitente alterna ciclos sem demanda e ocorrências positivas, cujos tamanhos também podem variar (Croston, 1972; Boylan and Syntetos, 2008). Frequência e magnitude são dimensões distintas. Para $D_t \geq 0$, definem-se

$$n_+ = |\{t : D_t > 0\}|, \tag{2.3}$$

$$\mu = T^{-1}\sum_t D_t, \qquad \sigma^2 = (T-1)^{-1}\sum_t (D_t - \mu)^2. \tag{2.4}$$

A média sobre todos os ciclos descreve o volume por período, mas pode ocultar longos intervalos sem venda. Uma sequência com valores positivos estáveis e muitos zeros é operacionalmente diferente de outra igualmente esparsa, porém com grandes picos.

2.3.1 Taxonomia ADI e CV^2

A classificação de Syntetos and Boylan (2005) combina intervalo médio entre demandas e variação dos tamanhos positivos:

$$\mathrm{ADI} = T/n_+, \tag{2.5}$$

$$\mathrm{CV}_+^2 = (\sigma_+/\mu_+)^2. \tag{2.6}$$

Aqui, μ_+ e σ_+ são calculados apenas nas observações positivas, diferentemente da média e variância da Equação 2.4. Os limiares 1,32 e 0,49 delimitam quatro categorias, resumidas na Tabela 2.1 (Syntetos et al., 2009).

Tabela 2.1: Quadrantes de Syntetos-Boylan: limiares e interpretações.

Regime	ADI	CV^2	Interpretação operacional
Smooth (Regular)	$< 1{,}32$	$< 0{,}49$	Alta frequência, demanda estável.
Erratic (Errático)	$< 1{,}32$	$\geq 0{,}49$	Alta frequência, magnitude irregular.
Intermittent (Intermitente)	$\geq 1{,}32$	$< 0{,}49$	Muitos zeros, magnitude relativamente estável.
Lumpy (Grumoso)	$\geq 1{,}32$	$\geq 0{,}49$	Muitos zeros e magnitude altamente irregular.

A implementação disponível também calcula uma medida de CV^2 incluindo zeros. Essa medida é útil como característica, mas não reproduz exatamente a definição original dos tamanhos positivos. As categorias dos artefatos são mantidas como rótulos operacionais, com essa ressalva; uma comparação entre taxonomias exige recalcular explicitamente ambos os índices.

2.3.2 Efeitos na Reposição

Demanda esparsa dificulta estimar taxas de ocorrência; tamanhos irregulares ampliam o custo de errar lotes e estoques de segurança. Croston separa a estimação dos tamanhos positivos e dos intervalos entre ocorrências. Isso pode melhorar a previsão, mas não estabelece qual regra de reposição minimiza custo sob um prazo e uma restrição de serviço específicos.

Os quadrantes fornecem uma descrição inicial, não uma prescrição de política. Séries no mesmo quadrante podem diferir em volume, tendências, sequências de zeros e concentração de picos. A hipótese do AIPE é que essas diferenças adicionais possam auxiliar a escolha; sua utilidade precisa ser medida contra uma política global bem calibrada, não inferida da classificação.

2.4 Métricas de Previsão

Erros absolutos e quadráticos dependem da escala da série; o MAPE é indefinido quando a demanda observada é zero. O estudo emprega métricas escaladas e sMAPE, com convenções explícitas para denominadores nulos (Hyndman and Koehler, 2006; Makridakis et al., 2020). Nenhuma métrica de previsão substitui a avaliação do efeito da decisão sobre custo e serviço.

2.4.1 Métricas Utilizadas

Sejam $e_t = D_t - \hat{D}_t$ os erros em m pontos de avaliação e $d_1, \ldots, d_n$ o treinamento. O MASE compara o erro absoluto com a variação da referência ingênua:

$$\mathrm{MASE} = \frac{m^{-1} \sum_t |e_t|}{(n-1)^{-1} \sum_{j=2}^{n} |d_j - d_{j-1}|}. \tag{2.7}$$

Valores menores que um indicam erro inferior à escala ingênua (Hyndman and Koehler, 2006). A escala deve vir do treino; séries constantes requerem registro de indefinição ou regularização declarada. A presença de zeros, isoladamente, não impede o cálculo.

O sMAPE usa demanda e previsão simetricamente (Makridakis, 1993):

$$\mathrm{sMAPE} = \frac{200}{m} \sum_t \frac{|D_t - \hat{D}_t|}{|D_t| + |\hat{D}_t|} \,\%. \tag{2.8}$$

Adota-se contribuição zero quando ambos os termos do denominador são nulos. Seu intervalo é de zero a 200%, mas pequenas demandas podem produzir valores elevados; por isso é interpretado junto ao MASE.

A versão quadrática escalada é

$$\mathrm{RMSSE} = \sqrt{\frac{m^{-1}\sum_t e_t^2}{(n-1)^{-1}\sum_{j=2}^{n}(d_j - d_{j-1})^2}}. \tag{2.9}$$

Ela dá maior peso a erros grandes e também requer escala de treino não nula. O RMSSE complementa o diagnóstico; o MASE permanece a referência principal de comparação de previsão no estudo.

O viés médio, $\mathrm{MBE} = \overline{D} - \overline{\hat{D}}$, diferencia subestimação de superestimação. O U de Theil compara RMSE do modelo e da previsão ingênua (Theil, 1966). Esses indicadores auxiliam a interpretação, sem determinar a política vencedora. Uma relação entre menor erro e melhor reposição é hipótese empírica: depende da assimetria de custos, do prazo e da regra de decisão.

2.5 Testes Estatísticos

A comparação usa observações pareadas porque as políticas atendem às mesmas séries. Testes não paramétricos evitam exigir normalidade dos KPIs, mas não dispensam atenção à independência das unidades. Produtos da mesma loja e lojas expostas às mesmas condições podem ser dependentes. Repetições idênticas não aumentam o tamanho efetivo da amostra.

2.5.1 Teste de Wilcoxon

Para diferenças $\Delta_i = X_i^A - X_i^B$, a soma de postos com sinal é

$$W = \sum_{i:\Delta_i \neq 0} \mathrm{sgn}(\Delta_i) R_i, \tag{2.10}$$

em que R_i é o posto de $|\Delta_i|$. O teste de Wilcoxon (1945) avalia uma hipótese de localização sob condições sobre a distribuição das diferenças. Sua leitura como teste da mediana requer, em particular, simetria. Empates e diferenças nulas devem receber tratamento documentado.

2.5.2 Teste de Friedman e Nemenyi

Com K políticas avaliadas nas mesmas N instâncias, o teste de Friedman (1940) compara postos médios:

$$\chi_F^2 = \frac{12N}{K(K+1)} \sum_{j=1}^{K} \left(\bar{r}_j - \frac{K+1}{2} \right)^2. \tag{2.11}$$

A rejeição não identifica sozinha os pares diferentes. O procedimento de Nemenyi usa uma diferença crítica (Nemenyi, 1963):

$$\mathrm{DC} = q_\alpha \sqrt{\frac{K(K+1)}{6N}}. \tag{2.12}$$

Postos separados por mais que DC são distinguidos sob as condições do procedimento. Um posto favorável em custo não representa necessariamente serviço aceitável; as métricas e os limiares precisam permanecer visíveis.

2.5.3 Tamanho de Efeito

A diferença padronizada de médias é reportada como descrição complementar (Cohen, 1988):

$$d = \frac{\bar{X}_A - \bar{X}_B}{s_{\mathrm{pooled}}}, \qquad s_{\mathrm{pooled}} = \sqrt{\frac{(N_A-1)s_A^2 + (N_B-1)s_B^2}{N_A + N_B - 2}}. \tag{2.13}$$

Essa forma não utiliza a covariância do pareamento; medidas baseadas nas diferenças podem ser mais apropriadas para inferência pareada. Faixas convencionais de efeito pequeno, médio ou grande não substituem a diferença de custo em unidades operacionais e sua repercussão no serviço.

O conjunto de testes, efeitos e gráficos descreve a heterogeneidade observada. Não transforma uma escolha retrospectiva de vencedor em evidência de generalização. Essa distinção orienta o protocolo de validação do próximo capítulo: a avaliação de uma política e a avaliação do mecanismo que a seleciona são etapas diferentes.

3

Trabalhos Relacionados

A literatura fornece métodos para prever demanda, calibrar regras e aprender decisões de reposição. A questão desta dissertação é como escolher entre essas alternativas para uma série loja-produto. A revisão distingue o desempenho de uma política da capacidade de um seletor de reconhecer quando utilizá-la.

3.1 Famílias de métodos

Políticas clássicas têm formulações interpretáveis e constituem referências necessárias, mesmo quando se avaliam métodos de aprendizado (Axsäter, 2006; Zipkin, 2000). Meta-heurísticas exploram seus parâmetros; agentes de reforço aprendem ações sequenciais; e a seleção de algoritmos escolhe métodos a partir de características das instâncias. São níveis complementares, não substitutos automáticos.

A Tabela 3.1 resume seu papel no problema estudado. As limitações indicadas são questões de avaliação: não significam que toda implementação de uma família apresente o mesmo comportamento.

3.2 Inventário e demanda intermitente

Clark and Scarf (1960) estabelecem resultados de decomposição para sistemas multi-escalão sob hipóteses específicas. Os textos de Axsäter (2006) e Zipkin (2000) consolidam políticas, custos e medidas de serviço. Para estoques de segurança em redes, o modelo de serviço garantido e suas extensões oferecem outra linha de planejamento (Graves and Willems, 2000; Eruguz et al., 2016; Achkar et al., 2024). Esses resultados não dispensam verificar se demanda, abastecimento e coordenação correspondem ao caso aplicado.

Tabela 3.1: Papel das famílias de métodos na pesquisa.

Família	Decisão ou informação produzida	Questão de avaliação
Políticas clássicas	Quando e quanto pedir por uma regra explícita	Adequação e calibração ao cenário
Previsão	Estimativa de demanda ou de sua distribuição	Efeito da previsão sobre custo e serviço
Meta-heurísticas	Parâmetros de uma política escolhida	Custo de busca e validade fora do ajuste
Aprendizado por reforço	Ação condicionada ao estado	Recompensa, estabilidade e generalização
Seleção de políticas	Escolha de um membro do portfólio	Ganho incremental frente à referência global

A demanda intermitente requer atenção à frequência e ao tamanho das ocorrências. Croston (1972) separam esses componentes na previsão. A classificação ADI$\times$CV^2 diferencia padrões suaves, erráticos, intermitentes e *lumpy* (Syntetos and Boylan, 2005). Essa descrição organiza séries, mas não determina a política de menor custo: o resultado depende também de prazo, custos e serviço exigido.

A revisão de de Kok et al. (2018) mostra a diversidade de estruturas consideradas na otimização multi-escalão. Nesta dissertação, porém, as séries são simuladas como decisões locais. Não se reivindica a otimização conjunta de uma rede geral, nem se transfere uma garantia teórica de otimalidade para um cenário que não atende às hipóteses originais.

3.3 Previsão e utilidade operacional

Históricos com muitos zeros tornam problemático o uso de erros relativos divididos pela demanda observada. O MASE permite comparação entre escalas quando seu denominador é definido, mas séries constantes também exigem tratamento (Hyndman and Koehler, 2006). Métricas de previsão devem ser acompanhadas de convenções para casos degenerados, sem substituir a avaliação de inventário.

Estudos em varejo mostram que o desempenho preditivo depende da granularidade, dos dados e da forma de treinamento (Makridakis et al., 2020; Nasseri et al., 2023). Não há razão para supor que uma rede LSTM será sempre superior a modelos simples em históricos curtos. Um resultado de competição de previsão tampouco demonstra vantagem em custo de reposição.

Tadayonrad and Ndiaye (2023) aproximam a avaliação preditiva de custos e serviço. Essa conexão orienta o AIPE: previsões e seus erros fornecem sinais auxiliares, mas a seleção deve ser julgada pelas consequências da decisão. Para evitar informação futura, previsão, características e calibração precisam respeitar o mesmo corte temporal da avaliação.

3.4 Meta-heurísticas e aprendizado por reforço

Meta-heurísticas procuram soluções em espaços de parâmetros difíceis de tratar analiticamente (Talbi, 2009). Em inventário, permitem ajustar ponto de pedido e lote. Yuna et al. (2023) estudam otimização de parâmetros em demanda intermitente, enquanto Erkayman et al. (2025) combinam modelagem da demanda e busca de parâmetros. O ganho permanece condicionado à política e ao cenário de calibração.

Aprendizado por reforço formula reposição como decisão sequencial. Oroojlooyjadid et al. (2022) estudam DQN no *Beer Game*; Gijsbrechts et al. (2022) discutem aplicações de aprendizado profundo a inventário; e Vanvuchelen et al. (2020) aplicam PPO à reposição conjunta. Outros trabalhos investigam topologias e coordenação descentralizada (Geevers et al., 2024; Liu et al., 2025).

Esses estudos mostram possibilidades de controle adaptativo, mas a aplicação depende de estado, ação, recompensa e dinâmica do simulador. Um agente pode obter serviço elevado emitindo pedidos excessivos ou reduzir custo deixando de atender demanda. Custo, serviço e comportamento das ações precisam ser examinados em conjunto.

Históricos curtos restringem a avaliação, embora o número de ciclos observados não seja igual ao número possível de interações simuladas. Repetir episódios pode ampliar treinamento sem adicionar novos processos de demanda. Comportamento degenerado em uma implementação não demonstra incapacidade geral do algoritmo: pode refletir recompensa, orçamento, parametrização ou erro de código. Essa cautela importa ao interpretar resultados antigos após correções do ambiente.

3.5 Seleção de políticas e meta-aprendizado

Rice (1976) formalizam a escolha de um algoritmo a partir das características de uma instância. Revisões posteriores descrevem seletores supervisionados e sua avaliação (Kotthoff, 2014; Kerschke et al., 2019). No AIPE, a instância é a série loja-produto, o portfólio reúne políticas e a medida de desempenho combina custo e viabilidade de serviço.

A analogia separa três objetos: o melhor método global, o melhor método conhecido para cada instância e o método escolhido pelo seletor. O segundo é uma referência retrospectiva; não é implementável quando sua escolha exige conhecer resultados futuros. O terceiro deve ser avaliado em dados que não determinaram os rótulos ou o ajuste.

O teorema *No Free Lunch* trata de médias sobre classes de problemas sob condições próprias (Wolpert and Macready, 1997). Ele não prova que haverá troca de vencedores neste recorte varejista nem que as características escolhidas permitirão aprendê-la. Essas são questões empíricas. Características de instância podem ajudar na seleção (Kerschke and Trautmann, 2019), mas sua utilidade precisa ser verificada no problema aplicado.

Hiper-heurísticas selecionam ou geram heurísticas, inclusive durante a resolução (Drake

et al., 2020; Dokeroglu et al., 2024). O AIPE tem escopo mais restrito: propõe recomendar periodicamente uma política por série. Não troca controladores a cada estado do estoque nem coordena agentes em tempo real. Trabalhos com *bandits* e contexto investigam outras formas de adaptação em inventário (Preil and Krapp, 2022; Batsis and Samothrakis, 2024); abordagens integradas relacionam características e decisões em outros desenhos operacionais (Qi et al., 2023).

A consequência prática é comparar o seletor com uma referência global forte. A avaliação deve separar o ajuste das políticas da aprendizagem da escolha entre elas. Excluir uma loja do seletor, por exemplo, não elimina informação futura já usada para gerar seus resultados de simulação.

3.6 Arquiteturas híbridas e posicionamento

Zabraoui et al. (2025) combinam busca genética e aprendizado por reforço em um estudo de inventário com dados do Walmart M5. É uma referência próxima do portfólio adotado aqui. A arquitetura GA–DQN e combinações GA–RL não são apresentadas como invenções desta dissertação. Sua inclusão permite investigar se oferecem vantagem em determinados recortes e como se comparam a regras simples sob condições comuns.

A Tabela 3.2 situa o foco da pesquisa sem equiparar bases, contagens de políticas ou protocolos diferentes. Uma comparação quantitativa direta exigiria reproduzir custos, horizontes, demandas e critérios de serviço.

Tabela 3.2: Relação entre linhas da literatura e o foco da dissertação.

Referência	Foco	Relação com esta pesquisa
Oroojlooyjadid et al. 2022	Aprender controle sequencial	Política candidata, não seletor validado
Yuna et al. 2023	Calibrar em demanda intermitente	Busca de parâmetros dentro do portfólio
Zabraoui et al. 2025	Comparação e combinação de algoritmos	Referência das arquiteturas avaliadas
Rice 1976; Kotthoff 2014	Selecionar métodos por instância	Base conceitual do PSE
Esta dissertação	Seleção contextual em varejo brasileiro	Comparar seleção e referência global

O espaço de investigação está na avaliação dessa seleção em séries reais do recorte brasileiro e na integração de um protocolo rastreável. Não se afirma que selecionar políticas seja uma ideia inédita em inventário nem que a revisão esgote a literatura. O resultado deve ser uma evidência verificável sobre o ganho incremental da seleção, inclusive quando for pequeno ou ausente. O capítulo seguinte apresenta os dados, o ambiente e o protocolo para investigar essa questão.

4

Metodologia

O AIPE organiza a caracterização da demanda, a comparação de políticas e a avaliação de sua escolha. O protocolo a seguir define a evidência experimental. A formulação geral e o PSE proposto ampliam o escopo da dissertação, com seus componentes ainda não avaliados identificados explicitamente.

4.1 Dados e protocolo temporal da Bahia

A avaliação utiliza 145 séries loja-produto da Bahia, em 115 lojas e nove produtos, com 38 ciclos comerciais disponíveis. O objetivo é comparar uma política global com a escolha por perfil em períodos posteriores aos usados no ajuste e na seleção. A coorte foi definida retrospectivamente; os ajustes e a seleção, porém, utilizam apenas a informação disponível antes do teste. Essa distinção limita a generalização para séries ainda não observadas.

4.1.1 Protocolo e cobertura

Os registros complementares de vendas são somados por chave, sem descartar transações apenas por compartilharem loja, produto e ciclo. A coorte tem identificadores fixos; em cada origem, exige ao menos três ciclos positivos no treino. As 145 séries são elegíveis nos dois prefixos, de 17 e 23 ciclos. Cada prefixo é seguido por sete ciclos de validação e sete de teste. Na numeração iniciada em um, os testes abrangem os ciclos 25–31 e 31–37: compartilham um ciclo e representam medidas repetidas das mesmas séries.

Perfis, escalas dos estados e parâmetros são calculados no treino. O prazo efetivo de entrega é de dois ciclos, e EOQCycle utiliza demanda e manutenção na mesma unidade temporal. Custos de manutenção, falta, emissão e quantidade permanecem, respectivamente, em 1 por unidade e ciclo, 5 por unidade não atendida, 50 por pedido e 0,5 por unidade pedida. São unidades do cenário, sem equivalência monetária calibrada. O custo soma manutenção, falta

e pedidos no bloco de teste, sem crédito pelo estoque final. Estados iniciais comuns são obtidos por uma política EOQ de referência: um aquecimento no passado precede a validação, e sua trajetória na validação determina o estado inicial do teste. O teste não continua o estoque particular de cada candidata.

O portfólio principal contém EOQCycle, sSCycle, CappedBaseStock, GA, PPO e GA–DQN; DQN é o controle adicional do híbrido. As três primeiras políticas têm um ajuste por série e origem. GA, PPO, GA–DQN e DQN usam sementes 11, 29 e 47, totalizando 4.350 ajustes e 8.700 registros de validação ou teste. A matriz está completa, sem casos excluídos por falta de política ou semente. O GA usa população de 100 indivíduos e 50 gerações. DQN e PPO têm orçamento mínimo de 20 mil transições, arredondado para episódios completos: 20.009 e 20.010 nas duas origens. GA–DQN acrescenta busca genética e mil transições de demonstração; seu esforço total é maior que o do DQN isolado. A variante avaliada mantém o mesmo gatilho e piso de pedido nas demonstrações, no treinamento e na inferência.

As sementes são primeiro promediadas dentro de cada série, origem e política. Para cada loja excluída, as políticas global e por perfil são escolhidas na validação das demais lojas e avaliadas no teste da loja reservada. O limiar principal continua em 0,70. Escolher uma alternativa viável na validação não garante repetir seu atendimento no futuro. Se nenhuma candidata cumpre a meta, a escolha de maior serviço é registrada como alternativa de contingência, sem classificá-la como viável.

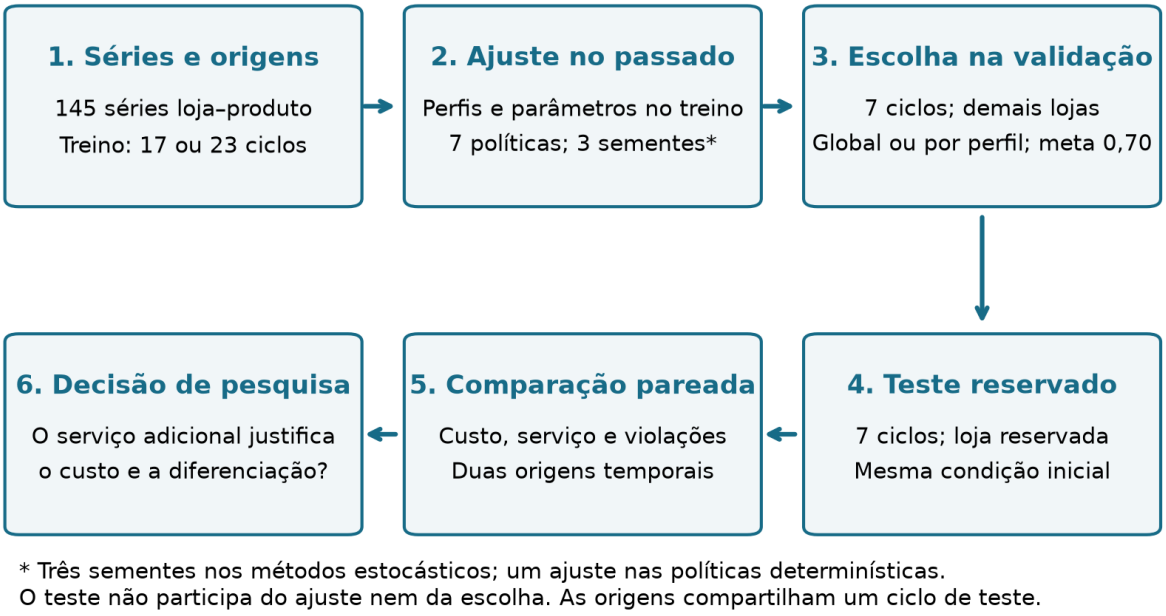


Figura 4.1: Fluxo da avaliação e separação da informação. Cada candidata é ajustada no treino da própria série. A estratégia de seleção usa a validação das demais lojas e é avaliada no teste da loja reservada. Os dois testes compartilham um ciclo; as origens são medidas repetidas.

O fluxo da Figura 4.1 mantém separadas duas decisões: ajustar o controlador e escolher qual controlador recomendar. Para cada caso, o atendimento é $F = \sum_t v_t / \sum_t d_t$, em que v_t é a demanda atendida e d_t a demanda observada. Quando o denominador é zero, F permanece indefinido. A média por caso atribui peso igual às séries com demanda; o atendimento ponderado usa a razão entre todas as unidades atendidas e demandadas. Ambos acompanham o custo total, para evitar que baixo atendimento seja interpretado como eficiência econômica.

4.2 Visão Geral do AIPE

A unidade de decisão é a série loja–produto, identificada por armazém, loja e produto. O histórico preparado é transformado em um vetor de características, que descreve frequência, magnitude e estrutura temporal da demanda. Políticas candidatas são ajustadas e executadas no mesmo simulador. Seus custos e níveis de serviço fornecem rótulos para um meta-modelo de seleção. A Figura 4.2 reúne essas etapas.

Há dois usos distintos de aprendizado: agentes de reforço aprendem uma regra de pedido dentro do portfólio; o PSE procura aprender qual regra escolher para uma série. Melhorar um controlador não demonstra automaticamente utilidade do seletor. Da mesma forma, encontrar vencedores diferentes por série não prova que suas identidades sejam previsíveis em dados futuros. A comparação do AIPE precisa incluir a melhor política global viável e referências simples bem calibradas.

A previsão é um sinal auxiliar, não o critério de escolha final. O custo total de inventário (CTI) é minimizado sob uma restrição de nível de serviço (NS). Ruptura, variabilidade dos pedidos e frequência de reposição complementam a leitura. Essa organização permite investigar heterogeneidade, mas não antecipa uma vantagem para políticas complexas nem para seleção por perfil.

4.3 Formulação do problema e componentes do framework

4.3.1 Decisão e Ambiente

Para cada série i e ciclo t, a política retorna $Q_{t,i} \geq 0$ a partir do estoque, da fila de pedidos e da informação passada de demanda. Regras de limiar usam a posição de estoque; agentes aprendidos recebem uma representação numérica do estado. A ação produz custos de ordenação no ciclo em que é emitida e altera o estoque disponível somente quando chega. A dinâmica de vendas perdidas segue a Equação 2.2.

O cenário empresarial inclui um armazém regional e lojas revendedoras com vários produtos. Entretanto, o simulador avalia cada série separadamente: não otimiza estoque compartilhado do armazém, capacidade de transporte ou competição entre lojas por suprimento. Os

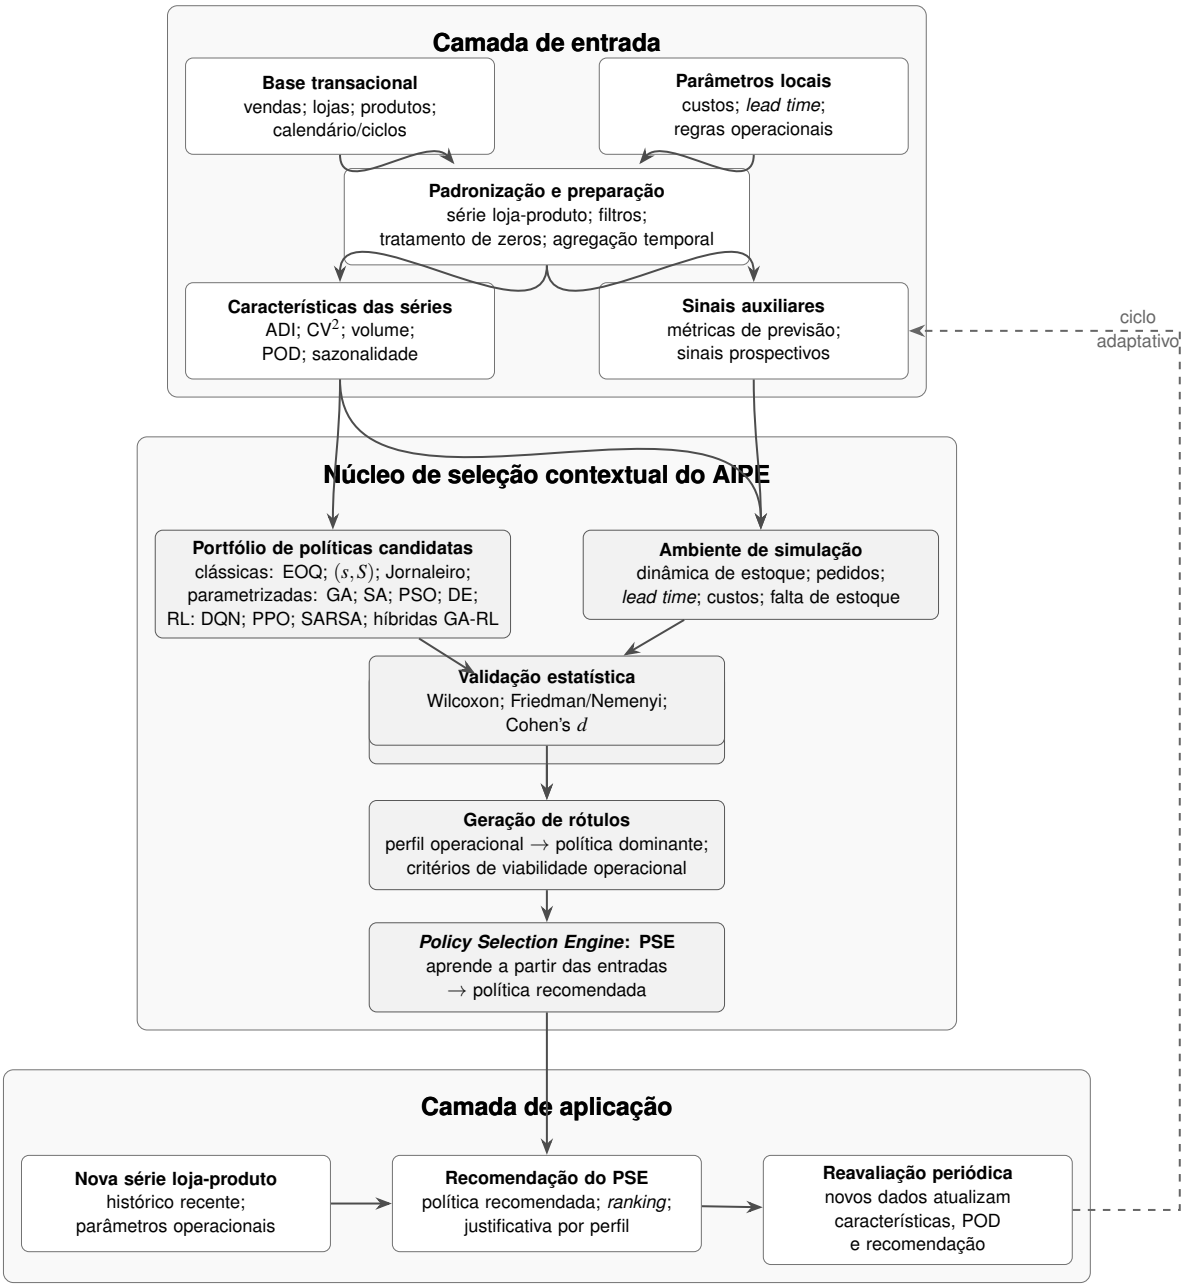


Figura 4.2: Arquitetura conceitual do *framework* AIPE. A camada de entrada reúne dados transacionais preparados, parâmetros operacionais, características das séries e sinais auxiliares de previsão de demanda. O núcleo de seleção contextual utiliza essas entradas para avaliar políticas candidatas, gerar rótulos de política dominante, realizar validação estatística e treinar o *Policy Selection Engine*. A camada de aplicação utiliza o PSE para recomendar políticas a novas séries loja-produto e reavaliar periodicamente as recomendações conforme novos dados se acumulam.

identificadores hierárquicos servem à rastreabilidade e à agregação. Medir variabilidade dos pedidos das lojas não equivale a validar um modelo integrado de múltiplos escalões.

Definição 4.3.1 (Seleção Contextual de Política) *Dado um portfólio Π, a representação ϕ e séries $\mathbf{d}_i$, o PSE proposto estima $f : \mathbb{R}^p \to \Pi$, com $f(\phi(\mathbf{d}_i)) = \hat{\pi}_i$. A referência de treinamento é a política de menor custo observado entre as que cumprem o serviço mínimo. Sua aplicação a novas séries depende de validação separada da construção desses rótulos.*

Os custos configurados são $h = 1$, $c_s = 5$, $c_o^{\text{fix}} = 50$ e $c_o^{\text{var}} = 0{,}5$. Esses valores definem um cenário experimental uniforme. A razão entre falta e manutenção expressa a penalização adotada, mas não comprova custos monetários reais da empresa. Sem calibração econômica, diferenças de CTI devem ser interpretadas como diferenças no objetivo simulado, mesmo quando os relatórios históricos usam a identificação de reais.

4.3.2 Métricas de Avaliação

Além do CTI definido na Equação 2.1, registram-se

$$\text{NS} = \frac{\sum_t (D_t - S_t)}{\sum_t D_t}, \qquad \text{TR} = \frac{\#\{t : S_t > 0\}}{T}, \qquad \text{FP} = \frac{\#\{t : Q_t > 0\}}{T},$$

e $\text{BE} = \text{Var}(Q)/\text{Var}(D)$. NS é a fração das unidades demandadas que foi atendida, não a probabilidade de um ciclo sem falta. TR mede a frequência de faltas; FP, a frequência de pedidos; BE, a amplificação da variância dos pedidos em relação à demanda. Variância de demanda nula exige uma convenção registrada, pois o quociente deixa de ter interpretação direta.

O limiar principal é $\alpha_{\min} = 0{,}70$. Na rotulagem por série, a restrição incide sobre o serviço daquela série; na escolha de uma política global ou por perfil, incide sobre a média do grupo. Essas regras não são equivalentes. Um grupo com NS médio acima do limiar pode conter muitas séries abaixo dele. As tabelas devem informar média, distribuição e número de violações individuais, além do custo agregado.

Também se examina, de forma complementar,

$$J(\pi, g) = \text{CTI}_{\text{norm}}(\pi, g) + \lambda_{BE} \text{BE}_{\text{norm}}(\pi, g).$$

A normalização min–max precisa fixar o conjunto de políticas e o escopo usado para calcular extremos. Com $\lambda_{BE} = 0$, a ordenação equivale ao custo; pesos positivos favorecem estabilidade. Esse índice não tem unidade monetária e não substitui o CTI. A sensibilidade ajuda a mostrar como a preferência muda, sem demonstrar que um peso escolhido após observar resultados seja adequado à operação.

Uma interpretação conjunta é essencial: baixo custo com baixo NS pode refletir pouca reposição, e BE pequeno pode ocorrer porque quase não há pedidos. Esses padrões não são

automaticamente descartados; são identificados nos indicadores e confrontados com restrições previamente definidas. Excluir um comportamento depois de observar seu desempenho mudaria o portfólio e precisaria de justificativa explícita.

4.4 Camada de Entrada: Dados e Pré-Processamento

4.4.1 Base de Dados

A fonte é uma base proprietária de vendas de uma rede varejista brasileira, organizada em ciclos comerciais. Os recortes avaliados compreendem 15 lojas da Paraíba para um produto e 145 combinações loja–produto da Bahia. O horizonte documentado contém 38 ciclos, de 202301 a 202504, com 17 ciclos comerciais por ano. Essa codificação deve ser convertida em uma ordem temporal consistente; não representa um calendário mensal comum.

Vendas observadas são usadas como aproximação da demanda. Se a loja ficou sem produto, a venda registrada pode ser menor que a intenção de compra. A simulação não reconstrói essa demanda censurada. Também é necessário diferenciar ausência de transação, ausência de registro e indisponibilidade da loja. Tratar todos esses casos como zero produz séries uniformes, mas introduz uma hipótese que afeta frequência, variância e perfis.

Os dados brutos não são disponibilizados publicamente. A reprodução depende de autorização para acesso ou de artefatos derivados permitidos, além de código, parâmetros e versão do ambiente. Resultados agregados preservam a descrição científica, mas não tornam uma análise integralmente reproduzível quando suas entradas continuam restritas. O estudo explicita esse limite, em vez de substituir disponibilidade de dados por uma lista de bibliotecas.

4.4.2 Preparação das Séries

O preparo consolida transações por armazém, loja, produto e ciclo. Valores negativos e registros incompatíveis seguem os filtros da versão executada. Transações complementares da mesma chave são somadas; repetições técnicas do mesmo evento exigem identificação antes da remoção. A nova execução da Bahia utiliza a agregação adotada descrita na Seção 4.1. O resultado é uma tabela de demanda por ciclo, acompanhada de metadados da série e do registro das exclusões aplicadas.

As séries são ordenadas e reindexadas nos ciclos do horizonte. Ciclos sem venda recebem zero na preparação histórica. Antes de usar essa convenção, verificam-se a cobertura da fonte e a distinção entre loja inativa e demanda nula. Séries inteiramente sem vendas não permitem comparar serviço pela razão de unidades atendidas. Sua exclusão, quando aplicada, é registrada como critério de amostragem, sem ocultar que altera a população analisada.

Critérios de atividade, volume, número de demandas positivas e variabilidade delimitam os cenários. Os filtros evoluíram entre execuções, portanto não se presume que uma descrição

única, como CV mínimo, identifique todos os recortes. O manifesto deve registrar a condição efetivamente aplicada e a contagem antes e depois de cada filtro. A representação dos regimes e a distribuição geográfica dos cenários avaliados aparecem no Capítulo 5.

Para avaliação futura, critérios de inclusão precisam depender apenas do passado. Exigir produto ativo nos últimos ciclos do horizonte completo, por exemplo, usa informação que não estaria disponível no início da decisão. Mesmo que o modelo seja treinado em um prefixo, uma coorte selecionada com o futuro continua retrospectiva. Essa distinção é relevante para interpretar qualquer extensão temporal do experimento.

4.5 Características e Perfis Operacionais

O vetor de entrada resume a série sem substituir sua trajetória na simulação. Intermitência é representada por ADI, proporção de zeros e comprimentos de sequências sem demanda. Volume e dispersão incluem média, desvio-padrão, CV, quantidade de ciclos e de ocorrências positivas. Assimetria e curtose dos valores positivos descrevem tamanhos extremos; tendência, autocorrelação e entropia acrescentam informação sobre organização temporal e distribuição.

A implementação reúne cerca de 17 características principais, além de metadados e codificação do perfil; a dimensão final depende da seleção de colunas. Não se deve afirmar dimensão fixa depois de acrescentar atributos ou indicadores de previsão. As estatísticas são calculadas na mesma unidade de ciclo da série e suas convenções, incluindo amostra ou população no desvio-padrão, precisam acompanhar o vetor salvo.

Para intervalos τ entre demandas positivas, a concentração de ocorrências é resumida por

$$B = \frac{s_\tau - \bar{\tau}}{s_\tau + \bar{\tau}},$$

com regularização numérica quando necessária (Goh and Barabási, 2008). Valores positivos indicam intervalos mais variáveis que a média; negativos, maior regularidade. Poucos eventos não sustentam uma estimativa estável. A entropia $H = -\sum_k p_k \log_2 p_k$ usa um histograma de dez classes sobre todos os ciclos; não é calculada somente sobre demandas positivas.

A tendência é a inclinação de uma regressão temporal simples dividida pela média. A dependência anual é resumida pela autocorrelação na defasagem 17, correspondente a um ano comercial. Uma janela de 17 ciclos não permite estimar essa autocorrelação com segurança; no código, janelas insuficientes recebem zero. O resultado significa ausência de estimativa, não demonstra ausência de sazonalidade.

Como explicado na Seção 2.3.1, a característica CV^2 do código inclui ciclos zero, enquanto a classificação original usa a dispersão dos tamanhos positivos. Mantêm-se os rótulos já arquivados para rastrear os resultados, mas sem apresentar equivalência exata entre as definições. Essa diferença também impede interpretar os limiares originais como uma validação automática da classificação operacional implementada.

4.5.1 Regras de Perfil

A Tabela 4.1 define cinco Perfis Operacionais de Demanda (POD). As regras são aplicadas na ordem apresentada: a primeira satisfeita determina o perfil. Uma série não enquadrada nas condições recebe a classe residual Sparse High Impact. Por esse motivo, nomes como "alta sazonalidade" e "tendência instável" são descritores heurísticos; não garantem que todas as séries do grupo possuam exatamente aquela propriedade.

Tabela 4.1: Regras hierárquicas dos Perfis Operacionais de Demanda.

Perfil	Primeira condição satisfeita
Sparse High Impact	ADI ≥ 1.32, $CV^2 \geq 0.49$ e maior sequência de zeros ≥ 5
High Volatility Seasonal	Autocorrelação na defasagem 17 ≥ 0.25 ou $B \geq 0.30$
Unstable Trend	Tendência normalizada absoluta ≥ 0.05 ou $H \geq 2$
Low Volume Stable	Média ≤ 2 e $CV^2 < 0{,}49$
Fast Moving	ADI $< 1{,}32$

O perfil organiza a análise e pode ser codificado como entrada do PSE. Não é uma recomendação fixa de controlador. A associação inicial entre nomes de perfis e políticas no código não substitui a seleção pela matriz de custo e serviço. Essa separação evita interpretar uma regra previamente atribuída, como "perfil sazonal recebe PPO", como uma descoberta empírica do experimento.

Na Bahia, os artefatos de perfil apresentam 116 séries Sparse High Impact, 18 Unstable Trend e 11 High Volatility Seasonal. Essa concentração limita a informação disponível sobre grupos pequenos. Os limiares não foram aprendidos de uma grande população independente e devem ser submetidos a sensibilidade. Se forem ajustados usando os mesmos resultados que avaliam o seletor, a comparação deixa de representar validação independente da representação.

4.6 Sinais Auxiliares de Previsão e Calibração

O projeto contempla Croston, ARIMA, redes neurais e XGBoost como fontes de previsão. Croston estima ocorrência e tamanho separadamente (Croston, 1972); modelos autorregressivos descrevem dependência temporal; modelos supervisionados utilizam janelas recentes. A configuração determina quais candidatos são executados em cada versão. Não se presume que todos tenham sido avaliados em cada recorte apenas porque estão disponíveis no código.

A comparação emprega MASE como métrica principal e sMAPE e RMSSE como complementares, conforme as definições do Capítulo 2. Nos artefatos históricos, a função de métricas usa diferenças da própria sequência avaliada como escala e exclui pares demanda/previsão

ambos zero do sMAPE; essa convenção difere das definições de referência. A escolha do modelo deve ocorrer antes do bloco usado para avaliar a política, ou em validação interna. Se o erro de previsão integrar o PSE, ele precisa ser produzido sem observar a demanda que será usada para medir o resultado final da recomendação.

Também é necessário verificar o consumo desse sinal. A presença de um arquivo de previsões não prova que ele foi fornecido ao simulador. Quando nenhuma previsão externa é recebida, o ambiente usa uma referência ingênua baseada na demanda anterior, com inicialização por média. A metodologia distingue a previsão efetivamente usada, as métricas calculadas como diagnóstico e as entradas previstas para versões futuras do seletor.

Os valores de referência de reposição são derivados da média $\hat{\mu}$, do desvio $\hat{\sigma}$, do parâmetro L e de $z = 1{,}28$:

$$I_0 = \hat{\mu}L + z\hat{\sigma}\sqrt{L}, \tag{4.1}$$

$$Q_{\text{ref}} = \sqrt{2\hat{\mu}T_{\text{cal}}c_o^{\text{fix}}/h}, \tag{4.2}$$

$$s_{\text{ref}} = \hat{\mu}L + z\hat{\sigma}\sqrt{L}. \tag{4.3}$$

T_{cal} é a quantidade de ciclos usados na calibração do lote legado. A primeira expressão corresponde à escala do pipeline disponível; outros estoques iniciais aparecem em versões históricas e devem ser identificados pela execução. A expressão de Q_{ref} acumula demanda no horizonte, embora h seja por ciclo: não é a EOQ dimensionalmente uniforme $\sqrt{2\hat{\mu}c_o^{\text{fix}}/h}$. A diferença permanece registrada, sem reatribuir resultados antigos a uma formulação distinta.

Estoque inicial, limites de ação e região de busca afetam fortemente o desempenho em séries curtas. Um estoque inicial amplo pode elevar serviço sem exigir aprendizado, e um limite baixo de pedido pode impedir atendimento de picos. Em validação temporal, essas escalas devem ser calculadas somente no treino. Usar média e desvio da série completa, mesmo mantendo o ajuste da política em um prefixo, introduz informação futura na avaliação.

4.7 Portfólio de Políticas Candidatas

4.7.1 Composição e Referências

O portfólio inicial contém EOQ, (s,S), Jornaleiro, GA, SA, PSO, DE, DQN, PPO, SARSA, GA–DQN e GA–PPO. A configuração posterior mantém doze alternativas, porém substitui PSO, DE, SARSA e GA–PPO por CappedBaseStock, BigDataNewsvendor, FixedInterval e VendorResponsive. A contagem de políticas, isoladamente, não identifica um experimento: tabelas, configurações e arquivos precisam concordar sobre a lista de candidatos.

A revisão da composição busca referências competitivas e diversidade de decisões, em vez de aumentar o número de algoritmos semelhantes. CappedBaseStock é motivada por Xin

(2021) e pelas comparações com aprendizado profundo discutidas por Temizöz et al. (2025). O Jornaleiro orientado a características se relaciona à otimização de decisão de Ban and Rudin (2019). A formulação PIL de van Jaarsveld and Arts (2024) é uma referência da literatura disponível para extensão, não um candidato do portfólio final de doze.

FixedInterval e VendorResponsive são interpretações das descrições de Zabraoui et al. (2025). A primeira usa revisão periódica e reposição até um alvo; a segunda ajusta a proteção de estoque pelo serviço passado. Como o artigo-base não fornece todos os detalhes numéricos dessas regras, a implementação local precisa declarar suas equações e parâmetros. Preservar o nome de uma política não comprova reprodução exata de outro estudo.

A redução do portfólio é uma escolha de escopo. Não permite afirmar inexistência de literatura sobre SARSA, PSO ou DE em inventário, nem que seus resultados seriam sempre redundantes. As versões excluídas permanecem disponíveis para análises futuras. O Apêndice A registra parâmetros e identificadores, enquanto o Capítulo 5 apresenta a composição associada a cada conjunto de resultados.

4.7.2 Regras Analíticas e Heurísticas

EOQ legado pede Q_{ref} quando a posição de estoque cai até s_{ref}. A política (s,S) utiliza esse mesmo limiar e alvo $S = s_{\text{ref}} + Q_{\text{ref}}$, pedindo até o alvo. Ambas herdam a escala de lote discutida na Equação 4.2. Uma comparação com a EOQ canônica precisa corrigir a unidade temporal antes de interpretar diferenças como vantagem de aprendizado.

O Jornaleiro implementado utiliza $\max(0, \hat{\mu} + 1{,}28\hat{\sigma})$ como lote e um ponto de pedido baseado em $\hat{\mu}L$. Trata-se de uma regra recorrente inspirada no quantil normal, não do ótimo de um problema de período único com razão crítica estimada. As versões CappedBaseStock e BigDataNewsvendor acrescentam alternativas de calibração, mas sua fidelidade à referência depende de comparar hipóteses e procedimentos, não apenas o rótulo.

No FixedInterval, a revisão ocorre a cada três ciclos e o alvo cobre revisão mais reposição, com proteção proporcional à variabilidade. No VendorResponsive, o fator de segurança aumenta quando o serviço acumulado fica abaixo da meta interna e diminui quando fica acima. Essas regras oferecem referências simples adaptáveis. Nenhuma delas deve ser removida porque supera um método proposto; sua função é tornar a comparação exigente.

4.7.3 Busca de Parâmetros

GA e SA ajustam uma regra de ponto de pedido e lote, representada por $\boldsymbol{\theta} = (s, Q)$. O problema de referência é

$$\boldsymbol{\theta}_i^* = \arg\min_{\boldsymbol{\theta} \in \Theta_i} \mathrm{CTI}(\pi_{\boldsymbol{\theta}}, i) \quad \text{sujeito a } \mathrm{NS}(\pi_{\boldsymbol{\theta}}, i) \geq \alpha_{\min}. \tag{4.4}$$

A execução pode representar a restrição por penalidade ou usar uma soma ponderada de custo e serviço. Esses objetivos não são idênticos: uma solução favorecida pela aptidão ainda precisa

ter a viabilidade verificada no critério de rotulagem. Os pesos e termos adicionais de risco fazem parte da versão experimental e não podem ser omitidos ao atribuir desempenho ao algoritmo.

A configuração de referência histórica BA do GA emprega 100 indivíduos e 50 gerações, seleção por torneio, cruzamento uniforme e mutação adaptativa. O artigo-base motiva esses operadores (Zabraoui et al., 2025), mas a regra local de redução da mutação é uma escolha de implementação. O SA usa temperatura inicial 1000, resfriamento 0,95 e 500 iterações. Os detalhes de espaço de busca, sementes e operadores estão no apêndice; não são repetidos como uma descrição de módulos computacionais.

O orçamento dessas buscas difere do orçamento de agentes de reforço. Avaliar milhares de candidatos completos não é equivalente a milhares de passos do simulador. A comparação deve registrar avaliações e tempo, além dos KPIs finais, especialmente quando a inicialização híbrida incorpora trabalho prévio do GA. Sem esse controle, um resultado favorável pode refletir maior esforço computacional.

4.7.4 Agentes de Reforço e Arquitetura Híbrida

O estado disponível reúne estoque, previsão ou demanda recente, pedidos em trânsito, média e dispersão recentes e posição no horizonte. Na implementação atual, DQN usa uma arquitetura Double DQN (van Hasselt et al., 2016) com componentes dueling (Wang et al., 2016); PPO usa estimação generalizada de vantagem (Schulman et al., 2016). A recompensa parte do custo negativo, podendo incorporar penalidades na versão específica.

Os parâmetros de referência histórica incluem duas camadas de 64 unidades, memória de 10.000 transições e mil episódios para DQN, com exploração 0.2. PPO também usa mil episódios e clipping 0.2. O projeto atual discretiza quantidades admissíveis; não se atribui a esses resultados a propriedade de ações contínuas apenas porque PPO permite essa formulação. Sementes, resolução de ações, taxas de aprendizado e atualização de alvos acompanham a configuração de reprodução.

GA–DQN utiliza a parametrização evolutiva para gerar experiências iniciais e depois refina o agente, com referência de mil transições e 200 episódios na configuração híbrida. As 5.000 avaliações candidatas do GA não equivalem ao tamanho da memória. A arquitetura é uma especialista do portfólio, motivada pelo artigo-base (Zabraoui et al., 2025); não constitui a novidade principal da seleção contextual.

Correções de operadores, penalidades e treinamento ocorreram durante o projeto. A descrição do código recente não prova que esse mesmo código gerou uma tabela anterior. Resultados associados a agentes degenerados são mantidos com sua versão; explicar sua causa exige ablações controladas. Episódios repetidos na demanda observada são interações sintéticas, não novas amostras de vendas nem validação de generalização.

4.7.5 Redundância e Classes de Rotulagem

Políticas muito semelhantes podem gerar rótulos instáveis quando pequenas diferenças numéricas decidem o vencedor. A análise prevista compara correlação de Spearman dos custos e diferença mediana relativa; correlação acima de 0,98 e diferença abaixo de 5% sinalizam possível redundância. Esse diagnóstico não basta para unir classes: é necessário conferir também serviço, regra de decisão e estabilidade em outros períodos.

Agrupar candidatos é uma decisão do conjunto de treinamento, não uma alteração retrospectiva dos resultados reportados. Se aplicado, o mapa de classes precisa ficar explícito e ser definido sem olhar o desempenho do teste. Uma política redundante em custo pode ser distinta em serviço; ocultar essa diferença enfraqueceria a interpretação do seletor.

4.8 Simulação, Validação Temporal e Estatística

4.8.1 Ambiente de Simulação

O simulador recebe demanda fixa, estoque inicial, fila vazia, custos e uma política. Em cada ciclo, a política decide usando o estado anterior à chegada. A primeira quantidade da fila é recebida e o novo pedido acrescentado; a demanda do ciclo é atendida com o estoque disponível; faltas são perdidas; manutenção incide sobre o saldo após demanda. Pedido fixo e variável são cobrados na emissão. Não há crédito pelo estoque ou pelos pedidos em trânsito ao final.

Na instanciação histórica, a fila contém $L+1$ posições. Assim, o parâmetro $L=2$ implica chegada do pedido de t em $t+3$ nessa indexação. Não corresponde a uma entrega efetiva em dois ciclos, apesar da nomenclatura histórica. Manter a convenção entre candidatos favorece comparabilidade interna, mas não elimina a necessidade de verificar sua aderência ao prazo real. Horizonte curto, estoque inicial e efeito terminal podem determinar parcela relevante do resultado.

Cada trajetória produz custos de manutenção, falta e pedido, além dos KPIs e históricos de estoque e ações. A decomposição permite conferir se os componentes somam o CTI. As políticas compartilham demanda e condições operacionais, mas seus procedimentos de calibração podem diferir. A execução também precisa registrar falhas de candidatos; excluir silenciosamente séries com erro rompe a matriz pareada.

4.8.2 Separação Temporal

Para previsão, uma avaliação de origem crescente usa apenas o prefixo anterior ao alvo:

$$\mathcal{S}_t = ((d_1,\ldots,d_t),d_{t+1}), \qquad t = T_{\min},\ldots,T-1. \tag{4.5}$$

Essa divisão é necessária, mas não suficiente para prevenir vazamento. Normalização, imputação, perfis, estoque inicial, limites de ação e escolha de hiperparâmetros também precisam usar somente a informação disponível antes da avaliação. Uma figura de janelas não comprova que todas essas etapas respeitaram o protocolo.

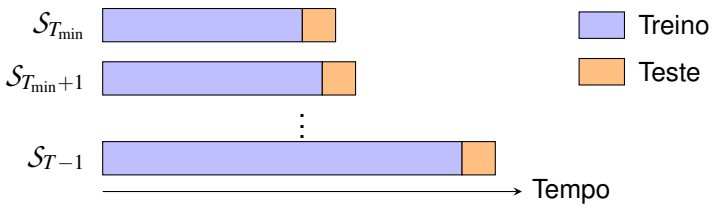


Figura 4.3: Protocolo *walk-forward*: a janela de treinamento cresce incrementalmente e o modelo é avaliado apenas em dados futuros, respeitando a ordem das observações na divisão entre treino e avaliação.

A documentação inicial menciona treino mínimo de 12 ciclos e até 26 alvos de previsão. A configuração posterior adota 17 ciclos e oferece tanto divisão única quanto ajuste por origem crescente. Esses modos não devem ser confundidos com uma única avaliação de controle. Os KPIs da matriz histórica são compatíveis com um bloco de 21 ciclos após 17 de treino; a identificação final depende da configuração arquivada, não do número nominal de ciclos da série.

Há limitações residuais na execução histórica: escalas podem vir de metadados da série completa, perfis podem usar os 38 ciclos e o estado do ambiente pode normalizar pelo próprio bloco avaliado. Por isso, não se afirma avaliação integralmente livre de informação futura para as tabelas existentes. Uma nova execução rigorosa deve restringir todas as etapas ao passado e preservar um bloco final que não participe da escolha do seletor.

O treinamento de controladores, a seleção de uma política e a avaliação da recomendação exigem papéis temporais separados. O primeiro ajusta parâmetros; o segundo usa validação para comparar candidatos; o último mede o resultado em demanda futura intocada. Avaliar o seletor com a mesma matriz que define seus rótulos mede ajuste retrospectivo. Mesmo a exclusão de uma loja da rotulagem não corrige informação futura já incorporada à calibração de suas políticas.

4.8.3 Inferência e Unidade Experimental

Wilcoxon compara pares de políticas nas mesmas séries; Friedman e Nemenyi comparam postos entre candidatos; tamanhos de efeito e diferenças absolutas descrevem relevância prática, conforme a Seção 2.5. Os testes usam nível nominal de 5%, com procedimento de comparações múltiplas identificado na execução. Estratificações exploratórias não devem produzir muitas declarações isoladas de significância sem considerar sua multiplicidade.

A unidade de observação é a série loja–produto. Séries da mesma loja e lojas que compartilham produtos ou condições comerciais podem ser dependentes. A análise deve reconhecer essa estrutura, por exemplo, mediante reamostragem por loja e verificações de sensibilidade. Não se obtém independência multiplicando o número de séries por repetições determinísticas.

O segundo experimento registra cinco avaliações nominais por política e série. O código treina ou otimiza o candidato antes de repetir a trajetória, e os desvios registrados de CTI são essencialmente nulos. Portanto, essas avaliações não são cinco treinamentos independentes nem justificam uma alegação de *common random numbers* como fonte de poder adicional. Para medir variabilidade de aprendizado, seriam necessárias sementes distintas de treinamento e resultados separados por semente.

4.9 Geração de Rótulos e PSE

4.9.1 Problema de Seleção

A formulação segue o problema de seleção de algoritmos de Rice (1976): descrever uma instância e escolher uma alternativa do portfólio. A discussão de portfólios (Huberman et al., 1997) motiva diversidade de candidatos. Os resultados de Wolpert and Macready (1997) não demonstram que qualquer perfil específico melhorará decisões; a utilidade da representação precisa ser testada na população estudada.

O alvo conceitual é

$$\hat{\pi}_i^* = \arg\min_{\pi \in \Pi} \mathbb{E}[\mathrm{CTI}(\pi, i)] \quad \text{sujeito a } \mathbb{E}[\mathrm{NS}(\pi, i)] \geq \alpha_{\min}. \tag{4.6}$$

Na matriz disponível, a esperança é aproximada pelo resultado registrado, não por uma distribuição comprovadamente estimada. O rótulo identifica a melhor candidata observada sob o limiar, não um ótimo universal. Se nenhuma atende ao serviço, registra-se inviabilidade; uma escolha pelo maior NS é apenas fallback, com o déficit informado.

Custos empatados devem receber regra estável, preferindo serviço e, depois, um identificador fixo. Quando diferenças são muito pequenas, um conjunto de candidatas equivalentes pode ser mais adequado que uma classe rígida. A estabilidade dos rótulos diante de sementes, custos e períodos é parte da validação: acurácia alta ao reproduzir rótulos arbitrários não garante melhora operacional.

4.9.2 Treinamento e Avaliação Propostos

O conjunto supervisionado reúne $(\phi(\mathbf{d}_i), \hat{\pi}_i^*)$. XGBoost é o classificador principal previsto (Chen and Guestrin, 2016), com referência de 300 árvores, profundidade seis, taxa 0,05 e amostragem 0.8. LightGBM (Ke et al., 2017) e RandomForest são alternativas. A presença dessas imple-

mentações e de artefatos de ajuste não equivale à validação do PSE em escala nacional ou em produção.

A avaliação deve separar lojas e períodos, evitando que produtos da mesma loja apareçam simultaneamente no treino e no teste sem justificativa. Validação estratificada pode ser usada quando todas as classes têm suporte suficiente, mas não resolve dependência entre instâncias. Classes raras exigem estratégia explícita; excluí-las da validação e depois reportar desempenho global de treino ocultaria seu efeito.

Acurácia balanceada, F1-macro e F1 ponderado ajudam a interpretar desbalanceamento, mas o resultado principal do seletor deve ser custo e serviço das políticas recomendadas. Uma classe incorreta pode ter desempenho praticamente igual ao rótulo, enquanto uma escolha correta pode não cumprir o serviço no futuro. A comparação deve incluir o melhor candidato global escolhido na mesma validação, EOQ com unidades consistentes e seleção sem a variável de perfil.

O estudo também precisa separar métricas após ajuste em toda a amostra das métricas fora do ajuste. Probabilidades do classificador não são probabilidades calibradas de viabilidade de serviço. A importância das características pode indicar associações, mas não prova causalidade nem estabilidade entre períodos. Essas verificações integram a continuidade do trabalho, descrita no Capítulo 7.

4.9.3 Aplicação e Reavaliação

O produto previsto é uma política recomendada, um ranking de alternativas e um indicador de incerteza. Quando disponíveis, custos e serviços simulados acompanham a decisão como evidência condicionada ao cenário. Recomendações incertas ou inviáveis exigem nova análise; um limiar de confiança, como 0,50, é uma regra de triagem a calibrar, não comprovação de que o risco esteja controlado.

A adaptação proposta consiste em recalcular características e consultar o seletor em intervalos definidos, por exemplo a cada seis ciclos. Essa consulta não equivale a retreinar o modelo, e não há evidência de implantação contínua dessa rotina nos experimentos apresentados. Uma aplicação real também depende de disponibilidade da política no sistema, restrições empresariais e monitoramento do serviço realizado.

4.10 Escopo Experimental e Rastreabilidade

O piloto da Paraíba fornece 180 combinações de 15 lojas e 12 políticas, sob a versão inicial. A expansão da Bahia reúne 145 séries e um portfólio posterior também de 12 candidatas, com composição distinta. Os resultados pertencem a essas versões e recortes. Não são uma validação nacional, um experimento independente para cada repetição ou uma aplicação conjunta de todos os controladores implementados.

Cada execução deve associar dados, lista de políticas, parâmetros, semente, divisão temporal e versão do código. Arquivos de características, perfis, KPIs e recomendações têm funções diferentes; o relatório precisa indicar qual foi usado em cada tabela. Hashes de entrada e manifesto de execução ajudam a detectar troca de arquivos, mas não certificam, isoladamente, ausência de informação futura ou fidelidade do algoritmo.

O Apêndice A concentra a matriz de parâmetros e os artefatos necessários à reprodução. As fontes de vendas e PDFs de referência são preservadas. Correções recentes de código não sobrescrevem resultados históricos nem autorizam reinterpretá-los como novos experimentos. Uma comparação entre versões requer reexecução explícita sob protocolo congelado.

Os resultados históricos do M5 e a avaliação temporal da Bahia têm funções distintas no Capítulo 5. O M5 sob o protocolo temporal permanece em execução; a expansão nacional foi retirada da execução ativa.

5

Resultados e Discussão

Este capítulo organiza as evidências pelas perguntas de pesquisa. A mesma matriz permite examinar a qualidade das candidatas, o valor da escolha contextual, sua estabilidade e o esforço computacional. Bahia e M5 são bases separadas da avaliação, não versões concorrentes do experimento. A Bahia está completa; o M5 permanece em execução e não recebe conclusões quantitativas parciais.

5.1 Resultados: valor da seleção por perfil

5.1.1 Quais candidatas oferecem compromissos competitivos?

A Tabela 5.1 resume os 290 casos série–origem. Sete casos não têm demanda no teste: um na primeira origem e seis na segunda. Seus custos permanecem na média dos 290 casos; o atendimento médio utiliza os 283 casos com denominador positivo. O atendimento ponderado é a razão entre a soma das unidades atendidas e a soma da demanda nos blocos avaliados, após a média das sementes. As origens repetidas não ampliam a amostra para 290 séries independentes.

PPO tem o menor custo descritivo, acompanhado do menor atendimento médio. Apenas EOQCycle e sSCycle superam 0,70 no conjunto dos testes; nenhuma política alcança essa meta no atendimento ponderado. Entre essas duas referências, sSCycle apresenta menor custo e maior atendimento médio. Essa comparação é um diagnóstico do teste, não uma escolha retrospectiva a ser atribuída ao seletor.

GA–DQN custa 11,60% menos que DQN e aumenta o atendimento médio de 0,5718 para 0,6802. Frente ao GA isolado, porém, custa 1,32% mais e atende menos, com média de 0,6953 para o GA. O refinamento híbrido não oferece vantagem agregada nessas duas dimensões sobre seu componente evolutivo. A diferença varia entre origens: na segunda, seu custo é ligeiramente menor que o do GA, também com menor atendimento. A comparação não isola

Tabela 5.1: Bahia, protocolo temporal: médias no teste de sete ciclos. Custo em unidades do cenário, calculado nos 290 casos. Atendimento médio e contagem abaixo da meta consideram os 283 casos com demanda positiva; sete casos têm atendimento indefinido.

Política	Custo	Atendimento	Ponderado	Abaixo de 0,70
EOQCycle	166,77	0,7787	0,6265	101
sSCycle	164,23	0,8037	0,6802	90
CappedBaseStock	218,11	0,6631	0,4948	148
GA	143,85	0,6953	0,5457	140
PPO	134,23	0,5514	0,4189	171
GA–DQN	145,75	0,6802	0,5248	144
DQN (controle)	164,88	0,5718	0,4033	164

causalmente o benefício das demonstrações ou do gatilho e não justifica excluir o híbrido antes de consolidar a avaliação M5.

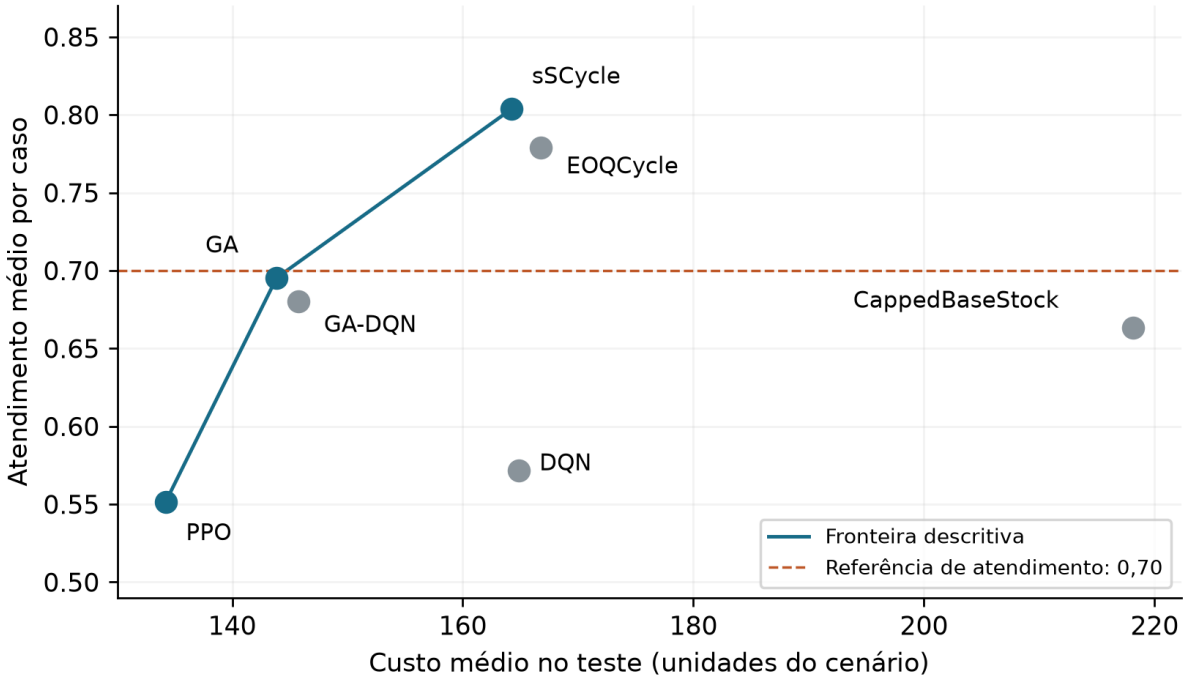


Figura 5.1: Compromisso custo–serviço das sete candidatas na Bahia. Médias de teste em 290 casos série–origem para custo e 283 com demanda positiva para atendimento. A fronteira é descritiva: não utiliza o teste para escolher a recomendação nem representa dominância estatística ou por série.

A Figura 5.1 distingue economia aparente por baixo atendimento de um compromisso competitivo. A restrição usada pelo seletor continua sendo avaliada na validação, sem recorrer a essa fronteira de teste.

Tabela 5.2: Escolha na validação das demais lojas e avaliação no teste da loja reservada, com meta 0,70. Há 145 casos por linha; atendimento definido em 144 casos na origem 17 e 139 na origem 23.

Treino	Estratégia	Custo	Atendimento	Abaixo de 0,70
17 ciclos	Global	180,58	0,5711	101
17 ciclos	Perfil	186,79	0,6475	82
23 ciclos	Global	142,03	0,9073	18
23 ciclos	Perfil	142,03	0,9073	18

5.1.2 O perfil melhora a decisão frente à seleção global?

Na primeira origem, a regra global escolhe GA para todas as séries. Por perfil, as escolhas são GA em 65 casos, sSCycle em 75 e EOQCycle em cinco. O maior atendimento custa mais, e ambas as estratégias ficam abaixo da meta no teste. Na segunda origem, os dois seletores escolhem sSCycle em todos os casos. A Tabela 5.2 evidencia, portanto, tanto mudança temporal da escolha global quanto ausência de diferenciação contextual na segunda janela.

No conjunto das origens, o custo médio passa de 161,31 na estratégia global para 164,41 por perfil: aumento de 1,93%. O atendimento médio cresce de 0,7362 para 0,7751, diferença de 3,89 pontos percentuais; o ponderado passa de 0,5750 para 0,6395. Os casos abaixo da meta diminuem de 119 para 100, entre os 283 com atendimento definido. Não há redução de custo, mas há melhora de serviço, concentrada na primeira origem. Essa melhora não assegura atendimento mínimo individual nem equivale a cumprir uma meta ponderada de 0,70.

Uma reamostragem exploratória pareada de 115 lojas, com 5.000 sorteios e todas as origens e produtos de cada loja preservados, produz intervalo condicional de 95% de $[-0{,}32; 4{,}16]\%$ para o aumento de custo por perfil. Os controladores e seletores permanecem fixos nos sorteios. O intervalo inclui zero e não representa incerteza de novos treinamentos ou de novas trajetórias de demanda; dependência entre lojas que compartilham produtos também permanece possível.

A sensibilidade reforça a distinção entre meta de escolha e serviço futuro. Em 0,80, todas as escolhas da segunda origem são contingências por ausência de candidata viável na validação, apesar do serviço posterior de 0,9073. Em 0,90 e 0,95, ambas as estratégias usam contingências nos 290 casos. Atendimento futuro alto não torna retroativamente viável uma escolha que descumpria o critério na validação.

A Figura 5.2 mostra por que a comparação não se esgota na média: a primeira janela concentra violações de serviço, enquanto a segunda tem distribuição e escolha coincidentes entre estratégias.

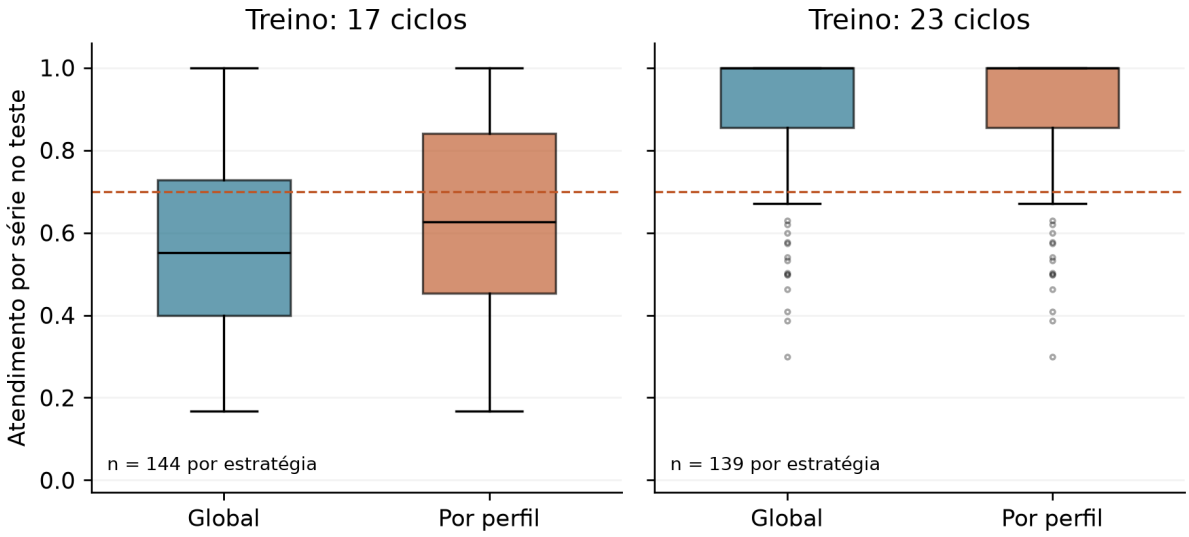


Figura 5.2: Distribuição do atendimento das estratégias no teste, por origem. Cada caixa resume séries com demanda positiva; a linha tracejada indica 0,70. Há 144 casos por estratégia na primeira origem e 139 na segunda. As mesmas séries participam das duas estratégias; observações e origens não são independentes.

5.1.3 As escolhas e o atendimento são estáveis entre períodos?

Os perfis são recalculados no prefixo disponível em cada origem. Com 17 ciclos, há 65 séries Sparse High Impact e 80 Unstable Trend; com 23, são 60, 69 e 16 High Volatility Seasonal. Essa mudança reflete a janela e as regras de caracterização, inclusive a indisponibilidade da autocorrelação na primeira origem. Não demonstra mudança de regime econômico em todas essas séries.

A Figura 5.3 localiza a diferenciação que produz o serviço adicional: na primeira origem, a regra por perfil substitui GA por sSCycle ou EOQCycle em parte das séries. Na segunda, identificar perfis não muda a política recomendada. Assim, a existência de grupos distintos não implica valor incremental da seleção em todo período.

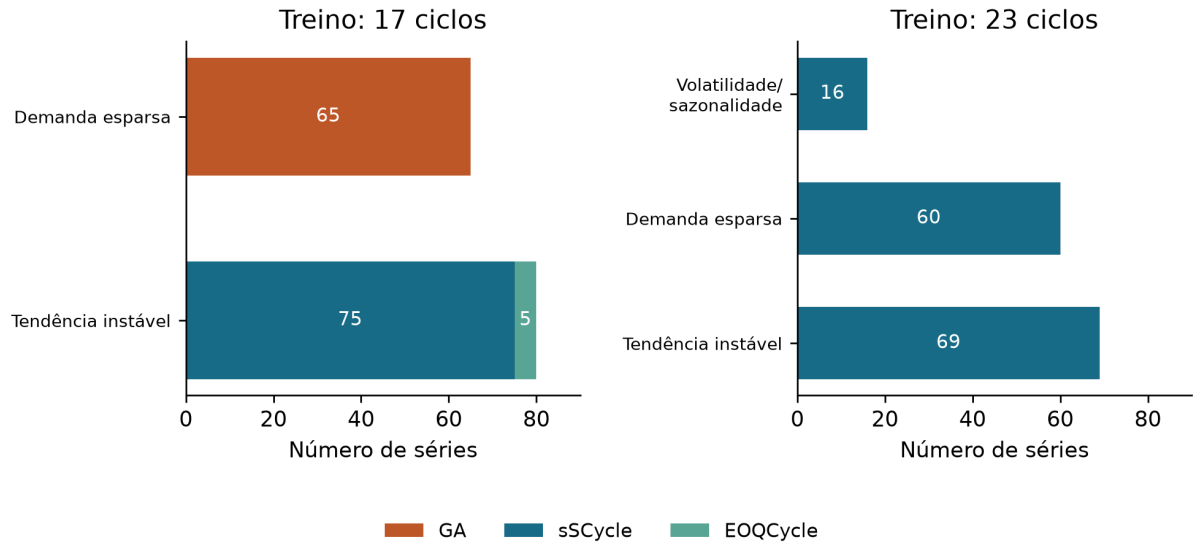


Figura 5.3: Políticas escolhidas por perfil na validação das demais lojas, com meta 0,70. Cada painel contém 145 escolhas; os números indicam séries. A primeira origem diferencia grupos, enquanto a segunda recomenda sSCycle em todos eles. Nomes abreviados dos perfis correspondem às regras operacionais descritas no método.

5.2 Esforço computacional das políticas

Tempo de ajuste é uma dimensão adicional da comparação, apresentada na Tabela 5.3. Cada ajuste é contado uma vez, sem duplicar seus registros de validação e teste. Ajustes reaproveitados são excluídos desta amostra de tempos. O registro mede a duração do ajuste no ambiente de execução, sob concorrência e carga variável; não equivale a um teste controlado de velocidade entre processadores nem ao tempo total decorrido da rodada.

Tabela 5.3: Duração registrada dos ajustes executados na rodada Bahia. Tempos em segundos; médias e medianas por ajuste, sem os 54 reaproveitados.

Política	Ajustes	Mediana (s)	Média (s)
CappedBaseStock	284	0,01	0,01
DQN	870	52,10	52,10
EOQCycle	284	0,00	0,00
GA	852	0,53	0,49
GA–DQN	870	52,90	52,90
PPO	852	24,37	26,03
sSCycle	284	0,00	0,00

O tempo deve ser interpretado junto ao desempenho: maior esforço não comprova melhor recomendação. GA–DQN reúne busca, demonstrações e aprendizado, enquanto as referências analíticas têm ajuste simples. Uma comparação causal de eficiência exigiria controlar hardware, carga, orçamento e repetições. Os tempos registrados permitem descrever a execução, mas não substituem esse desenho.

5.3 Generalização e componentes ainda não avaliados

O M5 amplia a investigação para uma fonte pública de vendas. A execução utiliza 2.408 identificadores de alimentos, com elegibilidade determinada no prefixo de cada origem. A conclusão deverá apresentar custo, atendimento, escolhas e incerteza por base, sem comparar custos absolutos entre conjuntos. Enquanto a matriz não estiver completa, não é possível afirmar que o benefício observado na Bahia se mantém no M5.

A previsão e o PSE supervisionado integram a proposta ampla do AIPE, mas não são intervenções validadas pela comparação entre seleção global e por perfil. Sua eficácia exige desenho próprio, com características e rótulos produzidos antes do teste, referências competitivas e métricas operacionais. Resultados de desenvolvimento ficam preservados nos arquivos de pesquisa e não funcionam como evidência adicional desta matriz.

5.4 Alcance e limitações

A escolha por perfil melhora o atendimento agregado na Bahia com custo maior; o efeito concentra-se em uma origem. Isso responde à pergunta sobre valor incremental sob as condições avaliadas, sem demonstrar uma vantagem universal. A restrição média não assegura atendimento individual ou ponderado pelo volume. As duas janelas compartilham um ciclo e repetem séries, e a coorte foi definida retrospectivamente.

As vendas podem omitir demanda censurada por falta de estoque. Custos são unidades de cenário, e o estado inicial comum depende de uma política de referência. Prazo, custos relativos, crédito terminal e extensão do horizonte podem alterar os resultados. Não foram avaliadas todas essas sensibilidades. O intervalo por loja é condicional aos controladores e escolhas fixos; não mede incerteza de novos treinamentos ou novas realizações da demanda.

O fechamento da investigação depende da consolidação M5 e das análises previstas no Capítulo 7. Questões que exigem outros desenhos permanecem explicitamente abertas, sem preencher lacunas com valores de configurações diferentes.

6

Conclusões

Esta dissertação investiga se características da demanda ajudam a escolher políticas de reposição com melhor compromisso entre custo e atendimento. O AIPE organiza essa avaliação em preparação, caracterização e comparação de candidatos. Os resultados disponíveis sustentam examinar a utilidade incremental da escolha por perfil; ainda não demonstram economia geral nem validam o PSE supervisionado.

6.1 Respostas às questões de pesquisa

O desempenho das candidatas e o benefício de selecionar entre elas são questões distintas. Os 4.350 ajustes cobrem as 145 séries em duas origens, com escolha na validação das demais lojas e avaliação no teste da loja reservada. Em conjunto, selecionar por perfil aumenta o custo em 1,93% e o atendimento médio em 3,89 pontos percentuais. Os casos abaixo da meta passam de 119 para 100 entre os 283 com demanda positiva no teste. O resultado representa serviço adicional com custo maior. Na segunda origem, as estratégias fazem escolhas idênticas.

Essas observações ainda não respondem integralmente às perguntas sobre aprendizagem e generalização. A escolha explícita por perfil foi avaliada temporalmente, mas o PSE supervisionado requer treinamento e teste próprios. A coorte continua selecionada retrospectivamente; as duas janelas são curtas, compartilham um ciclo e repetem as mesmas séries. A transferência para outros produtos, períodos e fontes de dados permanece aberta.

6.2 Contribuições e limites

A contribuição metodológica é distinguir três problemas: calibrar uma política, escolher uma candidata do portfólio e avaliar a recomendação em dados posteriores. A contribuição empírica é examinar essa distinção em dados reais do varejo brasileiro e preparar sua avaliação

complementar no conjunto público M5. A infraestrutura integrada permite rastrear dados, configurações, sementes e saídas da avaliação.

Os métodos do portfólio e a arquitetura GA–DQN já existem na literatura. Seu uso não constitui novidade algorítmica. Na Bahia, o híbrido melhora custo e atendimento frente ao DQN, mas não frente ao GA na média dos testes. Como também consome busca genética e demonstrações, a comparação não isola um ganho causal da combinação. A avaliação temporal M5 deverá complementar essa leitura antes de uma decisão definitiva sobre o portfólio.

O ajuste utiliza informação passada e sementes independentes de treinamento, que não equivalem a novas lojas ou novas realizações de demanda. Custos simulados, vendas possivelmente censuradas e estados iniciais de referência delimitam a interpretação operacional.

6.3 Implicações e continuidade

A definição do serviço antecede a escolha do controlador. Média por série, atendimento ponderado pela demanda e garantia individual produzem exigências distintas. Na Bahia, as médias das estratégias superam 0,70 quando as origens são reunidas, mas o atendimento ponderado permanece abaixo desse alvo e há numerosas violações individuais. A média global, portanto, é insuficiente para julgar a adequação empresarial.

O avanço seguinte é consolidar o M5 sob o protocolo temporal, examinar estabilidade temporal e definir o valor econômico do atendimento adicional antes de treinar o PSE. O plano do Capítulo 7 organiza essas dependências. A conclusão atual é delimitada: perfis podem alterar o compromisso entre custo e serviço, mas seu benefício precisa ser demonstrado frente a uma política global competitiva em períodos reservados.

7

Plano de Continuidade

A continuidade parte de uma avaliação temporal da Bahia já concluída e de uma avaliação M5 em andamento. O objetivo é consolidar evidência comparável para a seleção de políticas e, então, avaliar o PSE supervisionado. A expansão nacional foi cancelada na execução atual e não constitui requisito para concluir as etapas seguintes.

7.1 Consolidação dos experimentos

A Bahia dispõe de manifesto, 4.350 ajustes completos e métricas de validação e teste. A análise deverá examinar a variação entre origens, os casos sem demanda e o compromisso entre custo e atendimento. As análises complementam a mesma matriz experimental, com cobertura e proveniência verificadas.

7.1.1 M5: avaliação pública com protocolo temporal

A execução M5 utiliza a coorte histórica de 2.408 identificadores, sujeita à elegibilidade no prefixo de cada origem. Isso preserva uma comparação condicional à coorte, sem tornar prospectiva sua seleção inicial. O recorte local é inspirado em Zabraoui et al. (2025); não reproduz uma amostra publicada com identificadores e filtros numéricos integralmente especificados.

A comparação com a Bahia deverá usar métricas e regras de escolha comuns, mantendo separadas as escalas de custo e as propriedades da demanda. A avaliação M5 ainda não sustenta conclusões neste documento.

7.2 Validação da seleção

O próximo desenho deverá ampliar os períodos e reduzir a sobreposição dos testes. Características, normalização, parâmetros e critérios de inclusão devem depender do passado disponível.

A seleção usará validação, e o teste ficará reservado à avaliação. O comparador principal será a melhor política global viável escolhida sob a mesma informação.

O PSE receberá características anteriores à decisão e rótulos produzidos apenas nos dados de ajuste. Sua avaliação incluirá custo, atendimento, déficit de serviço e arrependimento relativo à referência. Acurácia e F1 serão diagnósticos auxiliares: rótulos próximos em desempenho não têm o mesmo significado econômico que erros com grande perda de serviço. Modelos supervisionados serão comparados com política global, regras por perfil e modelos simples, respeitando tempo e agrupamento por loja.

7.2.1 Calibração agrupada por perfil

Calibrar parâmetros em grupos é uma hipótese distinta de escolher políticas por perfil. Uma eventual comparação entre ajuste individual e agrupado deverá manter cortes, custos e orçamento comuns. Benefícios e inversões entre períodos serão apresentados conjuntamente, sem interpretar um recorte favorável como robustez geral.

7.3 Sensibilidade e eficiência

As análises deverão variar custos, prazo, estoque inicial, tratamento terminal e exigência de serviço. Média por série, atendimento ponderado e restrições individuais serão comparados como problemas de decisão distintos. A escolha de um peso para custo e serviço deverá anteceder o teste, evitando ajustar o objetivo para favorecer um resultado observado.

A revisão do portfólio combinará diversidade das regras, custo computacional e evidência nas duas bases. Métodos semelhantes não serão considerados equivalentes apenas por correlação de custo. A eventual retirada de candidatos será definida nos dados de desenvolvimento e documentada antes da avaliação final. GA–DQN continuará sendo comparado com GA e DQN, com o esforço total da combinação informado.

CPU e GPU serão escolhidas por medições do tempo total e do uso de recursos. A execução M5 atual usa oito processos CPU para coexistir com o uso normal da máquina. Essa configuração operacional não altera sementes, cortes ou candidatos, nem é um resultado de qualidade das políticas.

7.4 Consolidação do texto e critérios de conclusão

O artigo para *Supply Chain Analytics* e a dissertação compartilham resultados conferidos, mas têm funções diferentes: o artigo concentra a avaliação incremental da seleção; a dissertação explica fundamentos, percurso e limites. O material SBPO permanece arquivado. Autoria, declarações, disponibilidade de dados e adequação editorial serão consolidadas antes de submissão

ou depósito.

Tabela 7.1: Etapas de continuidade e critérios de conclusão, sem datas ainda não acordadas.

Etapa	Critério de conclusão
Consolidação Bahia	Resultados temporais, falhas de serviço e limites documentados
Conclusão M5	Cobertura planejada, matriz completa e comparação por origem
Seleção e sensibilidade	Critérios de decisão definidos e teste preservado
Avaliação do PSE	Comparação fora da amostra com referências competitivas
Redação e defesa	Afirmações, contribuições e pendências coerentes com a evidência

Apêndice A

Parâmetros e Resultados Complementares

Este apêndice reúne configurações históricas de referência e a tabela do piloto. Elas não identificam a versão de cada controlador na ausência de um manifesto completo. As diferenças entre PB, BA e M5 permanecem registradas; o protocolo temporal da Bahia está na Seção 5.1.

Tabela A.1: Dados e ambiente de referência.

Componente	**Configuração**
Base real	PB: 15 séries do produto 48130; BA: 145 séries, 115 lojas e 9 produtos. Horizonte de 38 ciclos.
Base M5	2.408 séries FOODS, 10 lojas, 287 produtos e 93 ciclos, após os filtros da configuração M5.
Ciclo	Agregação em blocos de aproximadamente 21 dias. O último bloco M5 pode ser incompleto.
Filtros BA	Produto ativo, exclusão de brindes, preenchimento de ciclos ausentes com zero; filtro de atividade e variabilidade conforme configuração.
Filtros M5	FOODS, CV$\geq 1,5$ e suavização superior por $Q_3 + 1,5\,IQR$ na série agregada. Filtro e suavização usam o histórico completo.
Entrega histórica	Configuração $L = 2$ com fila de $L+1$ posições: entrega em $t+3$. A nova Bahia usa a convenção efetiva de dois ciclos.
Estoque inicial	$I_0 = \hat{\mu}L + 1{,}28\hat{\sigma}\sqrt{L}$, escalado por série. A estimação pelo histórico completo limita a interpretação temporal.
Custos	Manutenção 1/unidade/ciclo, falta 5/unidade, pedido fixo 50 e variável 0,5/unidade; cenário simulado, sem calibração econômica independente.
Avaliação	Divisão configurada BA: 17 ciclos iniciais e M5: 19; cinco avaliações nominais por política. Repetições determinísticas não são treinamentos independentes.
Semente	Referência 42; a independência exige novos treinamentos e controle dos geradores aleatórios.

Tabela A.2: Regras e parâmetros das políticas clássicas e meta-heurísticas.

Política	**Configuração de referência**
EOQ legado	$Q = \sqrt{2\hat{\mu}TK/h}$; $s = \hat{\mu}L + z\hat{\sigma}\sqrt{L}$, $z = 1{,}28$. Demanda e manutenção devem usar a mesma unidade temporal; o fator T requer revisão.
(s, S)	Mesmo ponto de pedido, nível-alvo $S = s + Q$. Herda a escala do lote EOQ.
Jornaleiro	Implementação heurística $Q = \max(0, \hat{\mu} + 1{,}28\hat{\sigma})$, quando a posição de estoque não excede $\hat{\mu}L$; não equivale automaticamente ao quantil ótimo de período único.
GA	População 100, 50 gerações no recorte BA e 500 na configuração M5; cruzamento 0,8, torneio 3, mutação inicial 0,05 com redução linear até 20% dessa taxa.
SA	Temperatura inicial 1.000, resfriamento 0,95 e 500 iterações; o código atual usa busca vetorizada com aceitação de Metropolis.
Aptidão	Configuração ponderada $\mathrm{NS} - 0{,}0001\,\mathrm{CTI}$ e variantes penalizadas; a seleção final usa menor custo entre candidatos com serviço viável. Não confundir aptidão de treino com critério de escolha.

Tabela A.3: Agentes de reforço e híbrido: configurações documentadas.

Componente	**Configuração**
Estado	Seis componentes: estoque, previsão, pedidos em trânsito, média e dispersão recentes e posição no horizonte, normalizados conforme o simulador.
Recompensa	Negativo do custo de manutenção, falta e pedido. Variantes incorporam penalidades de serviço e estabilidade; a versão precisa ser registrada.
Ações	20 quantidades discretas; limite escalado pela demanda média.
DQN	$\gamma = 0{,}95$, $\varepsilon = 0{,}2$, lote 64, memória 10.000, rede-alvo atualizada a cada 10 episódios, taxa 0,001. Configuração de referência: 1.000 episódios.
PPO	$\gamma = 0{,}99$, recorte 0,2, quatro épocas por atualização, taxa 0,0003. A implementação atual usa ator-crítico e GAE; os resultados antigos não são regenerados por essa alteração.
GA–DQN	Inicialização pelo GA, memória pré-populada com 1.000 transições e 200 episódios de refinamento na configuração híbrida; horizonte e orçamento variam entre experimentos.
Arquiteturas	Estado de dimensão 6; duas camadas ocultas na configuração dos agentes. A versão exata é definida nos arquivos de parâmetros, não inferida dos KPIs.

Tabela A.4: Previsão auxiliar e seleção de políticas.

Componente	**Configuração**
Previsão	LSTM, ANN, XGBoost, Croston e ARIMA; janela de entrada 6 ciclos, treinamento mínimo 17 e previsão de um ciclo.
LSTM / ANN	LSTM: 64 unidades, 50 épocas, lote 16 e taxa 0,001; ANN: camadas 64/32, máximo 200 iterações, parada antecipada e validação 0,1.
XGBoost	Previsão: 200 árvores, profundidade 6, taxa 0,05 e subamostragem 0,8.
Croston / ARIMA	Suavização 0,1 / ordem $(1, 1, 1)$.
POD	ADI 1,32, CV^2 0,49, maior silêncio 5, burstiness 0,30, autocorrelação 0,25, tendência 0,05 e entropia 2; regras de prioridade descritas na metodologia.
Rótulos	Menor CTI entre políticas com NS$\geq 0{,}70$; esse filtro não assegura serviço individual quando aplicado a médias de perfil.
PSE proposto	XGBoost: 300 árvores, profundidade 6, taxa 0,05, subamostragem e seleção de colunas 0,8; validação de cinco partições prevista. A existência da configuração não demonstra validação do seletor.

Tabela A.5: Rastreabilidade da reprodução.

Evidência	**Local e interpretação**
Dados preparados	`experiment/data/03_primary/`, com diretório próprio para M5.
Características	`experiment/data/04_feature/`; registrar se foram estimadas antes ou depois da separação temporal.
Configurações	`experiment/conf/base/parameters/` e `experiment/conf/m5/`; versões diferentes podem gerar portfólios com o mesmo número de políticas.
KPIs	`experiment/data/07_model_output/`; chave loja-produto-política e contagem de séries verificadas antes de agregar.
Análises	`experiment/data/08_reporting/`; distinguir tabelas históricas, critérios penalizados e reanálises posteriores.
Software	Ambiente Python definido em `experiment/pyproject.toml`. Código atual e histórico devem ser identificados separadamente por versão e hash.
Inferência	Comparações pareadas por série, controle de multiplicidade e dependência entre séries; cinco repetições de um episódio determinístico não ampliam a amostra.

A.1 Resultados Agregados do Piloto na Paraíba

A Tabela A.6 preserva o piloto de 15 lojas. O ganho de 48% do GA–DQN frente a (s, S) é $(35.589 - 18.502)/35.589$, acompanhado de NS 0,821 contra 0,843. Não é ganho universal nem validação do PSE. Resultados de outros portfólios não são combinados com os da Bahia ou M5.

Tabela A.6: Indicadores históricos do piloto PB: 15 lojas do produto 48130.

Política	CTI	NS	TR	BE	FP
SARSA	16.139	0,785	0,200	0,00	0,00
Jornaleiro	16.402	0,794	0,111	0,003	0,27
DQN	17.974	0,806	0,078	4,1	0,37
GA–DQN	18.502	0,821	0,050	5,0	0,31
PSO	19.100	0,819	0,056	6,2	0,31
GA–PPO	19.801	0,833	0,050	6,6	0,35
GA	20.015	0,825	0,061	19,7	0,30
DE	20.252	0,813	0,056	31,0	0,27
SA	20.967	0,820	0,056	36,4	0,27
EOQ	31.034	0,840	0,050	23,0	0,20
PPO	34.637	0,848	0,039	15,9	0,98
(s, S)	35.589	0,843	0,050	119,4	0,15

Referências

Victoria G. Achkar, Braulio B. Brunaud, Héctor D. Pérez, Rami Musa, Carlos A. Méndez, and Ignacio E. Grossmann. Extensions to the guaranteed service model for industrial applications of multi-echelon inventory optimization. *European Journal of Operational Research*, 313(1):192–206, 2024. **DOI** 10.1016/j.ejor.2023.08.013.

Sven Axsäter. *Inventory Control*, volume 90 of *International Series in Operations Research & Management Science*. Springer US, New York, NY, USA, 2 edition, 2006. ISBN 9780387332505. **DOI** 10.1007/0-387-33331-2.

Gah-Yi Ban and Cynthia Rudin. The big data newsvendor: Practical insights from machine learning. *Operations Research*, 67(1):90–108, 2019. **DOI** 10.1287/opre.2018.1757.

Alex Batsis and Spyridon Samothrakis. Contextual reinforcement learning for supply chain management. *Expert Systems with Applications*, 249:123541, 2024. **DOI** 10.1016/j.eswa.2024.123541.

Robert N. Boute, Joren Gijsbrechts, Willem van Jaarsveld, and Nathalie Vanvuchelen. Deep reinforcement learning for inventory control: A roadmap. *European Journal of Operational Research*, 298(2):401–412, 2022. **DOI** 10.1016/j.ejor.2021.07.016.

John E. Boylan and Aris A. Syntetos. Forecasting for inventory management of service parts. In Khairy A. H. Kobbacy and D. N. Prabhakar Murthy, editors, *Complex System Maintenance Handbook*, pages 479–506. Springer, London, UK, 2008. **DOI** 10.1007/978-1-84800-011-7_20.

Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016. **DOI** 10.1145/2939672.2939785.

Andrew J. Clark and Herbert Scarf. Optimal policies for a multi-echelon inventory problem. *Management Science*, 6(4):475–490, 1960. **DOI** 10.1287/mnsc.6.4.475.

Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, USA, 2 edition, 1988. ISBN 9780805802832.

J. D. Croston. Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303, 1972. **DOI** 10.1057/jors.1972.50.

Ton de Kok, Christopher Grob, Marco Laumanns, Stefan Minner, Jörg Rambau, and Konrad Schade. A typology and literature review on stochastic multi-echelon inventory models. *European Journal of Operational Research*, 269(3):955–983, 2018. **DOI** 10.1016/j.ejor.2018.02.047.

Tansel Dokeroglu, Tayfun Kucukyilmaz, and El-Ghazali Talbi. Hyper-heuristics: A survey and taxonomy. *Computers and Industrial Engineering*, 187:109815, 2024. **DOI** 10.1016/j.cie.2023.109815.

John H. Drake, Ahmed Kheiri, Ender Özcan, and Edmund K. Burke. Recent advances in selection hyper-heuristics. *European Journal of Operational Research*, 285(2):405–428, 2020. **DOI** 10.1016/j.ejor.2019.07.073.

Burak Erkayman, Ferhat Yuna, and Mustafa Yılmaz. Markov approach for inventory control with meta-heuristics in intermittent demand environment. *PLOS ONE*, 20:e0325658, 2025. **DOI** 10.1371/journal.pone.0325658.

Ayse Sena Eruguz, Evren Sahin, Zied Jemai, and Yves Dallery. A comprehensive survey of guaranteed-service models for multi-echelon inventory optimization. *International Journal of Production Economics*, 172:110–125, 2016. **DOI** 10.1016/j.ijpe.2015.11.017.

Milton Friedman. A comparison of alternative tests of significance for the problem of m rankings. *The Annals of Mathematical Statistics*, 11(1):86–92, 1940. **DOI** 10.1214/aoms/1177731944.

Kevin Geevers, Lotte van Hezewijk, and Martijn R. K. Mes. Multi-echelon inventory optimization using deep reinforcement learning. *Central European Journal of Operations Research*, 32 (3):653–683, 2024. **DOI** 10.1007/s10100-023-00872-2.

Joren Gijsbrechts, Robert N. Boute, Jan A. Van Mieghem, and Dennis J. Zhang. Can deep reinforcement learning improve inventory management? performance on lost sales, dual-sourcing, and multi-echelon problems. *Manufacturing & Service Operations Management*, 24(3):1349–1368, 2022. **DOI** 10.1287/msom.2021.1064.

Kwang-Il Goh and Albert-László Barabási. Burstiness and memory in complex systems. *EPL (Europhysics Letters)*, 81(4):48002, 2008. **DOI** 10.1209/0295-5075/81/48002.

Stephen C. Graves and Sean P. Willems. Optimizing strategic safety stock placement in supply chains. *Manufacturing & Service Operations Management*, 2(1):68–83, 2000. **DOI** 10.1287/msom.2.1.68.23267.

John H. Holland. *Adaptation in Natural and Artificial Systems*. MIT Press, Cambridge, MA, USA, 1992. ISBN 9780262581111.

Bernardo A. Huberman, Rajan M. Lukose, and Tad Hogg. An economic approach to hard computational problems. *Science*, 275(5296):51–54, 1997. **DOI** 10.1126/science.275.5296.51.

Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006. **DOI** 10.1016/j.ijforecast.2006.03.001.

Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017.

James Kennedy and Russell Eberhart. Particle swarm optimization. In *Proceedings of ICNN'95 — International Conference on Neural Networks*, volume 4, pages 1942–1948, 1995. **DOI** 10.1109/ICNN.1995.488968.

Pascal Kerschke and Heike Trautmann. Automated algorithm selection on continuous black-box problems by combining exploratory landscape analysis and machine learning. *Evolutionary Computation*, 27(1):99–127, 2019. **DOI** 10.1162/evco_a_00236.

Pascal Kerschke, Holger H. Hoos, Frank Neumann, and Heike Trautmann. Automated algorithm selection: Survey and perspectives. *Evolutionary Computation*, 27(1):3–45, 2019. **DOI** 10.1162/evco_a_00242.

S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983. **DOI** 10.1126/science.220.4598.671.

Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(3):48–60, 2014. **DOI** 10.1609/aimag.v35i3.2460.

Averill M. Law. *Simulation Modeling and Analysis*. McGraw-Hill Education, 5 edition, 2015. ISBN 9780073401324.

Hau L. Lee, V. Padmanabhan, and Seungjin Whang. Information distortion in a supply chain: The bullwhip effect. *Management Science*, 43(4):546–558, 1997. **DOI** 10.1287/mnsc.43.4.546.

Xiaotian Liu, Ming Hu, Yijie Peng, and Yaodong Yang. Multi-agent deep reinforcement learning for multi-echelon inventory management. *Production and Operations Management*, 34(7): 1836–1856, 2025. **DOI** 10.1177/10591478241305863.

Spyros Makridakis. Accuracy measures: Theoretical and practical concerns. *International Journal of Forecasting*, 9(4):527–529, 1993. **DOI** 10.1016/0169-2070(93)90079-3.

Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. The m4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1): 54–74, 2020. **DOI** 10.1016/j.ijforecast.2019.04.014.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015. **DOI** 10.1038/nature14236.

Mehran Nasseri, Taha Falatouri, Patrick Brandtner, and Farzaneh Darbanian. Applying machine learning in retail demand prediction—a comparison of tree-based ensembles and long short-term memory-based deep learning. *Applied Sciences*, 13(19):11112, 2023. **DOI** 10.3390/app131911112.

Peter Nemenyi. *Distribution-Free Multiple Comparisons*. PhD thesis, Princeton University, 1963.

Afshin Oroojlooyjadid, MohammadReza Nazari, Lawrence V. Snyder, and Martin Takáč. A deep q-network for the beer game: Deep reinforcement learning for inventory optimization. *Manufacturing & Service Operations Management*, 24(1):285–304, 2022. **DOI** 10.1287/msom.2020.0939.

Deniz Preil and Michael Krapp. Bandit-based inventory optimisation: Reinforcement learning in multi-echelon supply chains. *International Journal of Production Economics*, 252:108578, 2022. **DOI** 10.1016/j.ijpe.2022.108578.

Meng Qi, Yuanyuan Shi, Yongzhi Qi, Chenxin Ma, Rong Yuan, Di Wu, and Zuo-Jun Max Shen. A practical end-to-end inventory management model with deep learning. *Management Science*, 69(2):759–773, 2023. **DOI** 10.1287/mnsc.2022.4564.

John R. Rice. The algorithm selection problem. *Advances in Computers*, 15:65–118, 1976.

John Schulman, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations (ICLR)*, 2016.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. **DOI** 10.48550/arXiv.1707.06347.

Rainer Storn and Kenneth Price. Differential evolution — a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4):341–359, 1997. **DOI** 10.1023/A:1008202821328.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, USA, 2 edition, 2018. ISBN 9780262039246.

Aris A. Syntetos and John E. Boylan. On the categorization of demand patterns. *Journal of the Operational Research Society*, 56(5):495–503, 2005. **DOI** 10.1057/palgrave.jors.2601841.

Aris A. Syntetos, John E. Boylan, and Stephen M. Disney. Forecasting for inventory planning: A 50-year review. *Journal of the Operational Research Society*, 60(S1):S149–S160, 2009. **DOI** 10.1057/jors.2008.173.

Yasin Tadayonrad and Alassane Balle Ndiaye. A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality. *Supply Chain Analytics*, 3:100026, 2023. **DOI** 10.1016/j.sca.2023.100026.

El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. John Wiley & Sons, Hoboken, NJ, USA, 2009. ISBN 9780470278581. **DOI** 10.1002/9780470496916.

Tarkan Temizöz, Christina Imdahl, Remco Dijkman, Douniel Lamghari-Idrissi, and Willem van Jaarsveld. Deep controlled learning for inventory control. *European Journal of Operational Research*, 324(1):104–117, 2025. **DOI** 10.1016/j.ejor.2025.01.026.

Henri Theil. *Applied Economic Forecasting*. North-Holland, Amsterdam, 1966.

Hado van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double Q-learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 30, pages 2094–2100, 2016.

Willem van Jaarsveld and Joachim Arts. Projected inventory-level policies for lost sales inventory systems: Asymptotic optimality in two regimes. *Operations Research*, 72(5): 1790–1805, 2024. **DOI** 10.1287/opre.2021.0032.

Nathalie Vanvuchelen, Joren Gijsbrechts, and Robert N. Boute. Use of proximal policy optimization for the joint replenishment problem. *Computers in Industry*, 119:103239, 2020. **DOI** 10.1016/j.compind.2020.103239.

Ziyu Wang, Tom Schaul, Matteo Hessel, Hado van Hasselt, Marc Lanctot, and Nando de Freitas. Dueling network architectures for deep reinforcement learning. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1995–2003, 2016.

Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. **DOI** 10.2307/3001968.

David H. Wolpert and William G. Macready. No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation*, 1(1):67–82, 1997. **DOI** 10.1109/4235.585893.

Linwei Xin. Technical note—understanding the performance of capped base-stock policies in lost-sales inventory models. *Operations Research*, 69(1):61–70, 2021. **DOI** 10.1287/opre.2020.2019.

Ferhat Yuna, Burak Erkayman, and Mustafa Yılmaz. Inventory control model for intermittent demand: A comparison of metaheuristics. *Soft Computing*, 27:6487–6505, 2023. **DOI** 10.1007/s00500-023-07871-0.

Oussama Zabraoui, Yahya Hmamou, Anas Chafi, and Salaheddine Kammouri Alami. A comparative study of multi-algorithm optimization for inventory analytics in supply chains. *Supply Chain Analytics*, 12:100154, 2025. **DOI** 10.1016/j.sca.2025.100154.

Paul H. Zipkin. *Foundations of Inventory Management*. McGraw-Hill/Irwin, Boston, MA, USA, 2000. ISBN 9780256113792.