

Seleção Contextual de Políticas de Reposição em Redes Varejistas

O AIPE como *framework* metodológico de apoio à decisão

Matheus Inácio Batista Santos

Exame de Qualificação de Mestrado

Instituto de Computação — UFAL

Orientadores: Dr. Rian G. S. Pinheiro e Dr. Bruno C. S. Nogueira

1. Problema
2. Hipótese e contribuição
3. Lacuna na literatura
4. AIPE
5. Metodologia experimental
6. Resultados preliminares
7. Limitações e continuidade


Problema

**Redes varejistas heterogêneas precisam decidir
quando e quanto repor estoque
em cada combinação loja-produto.**

Heterogeneidade da demanda

Motivação da proposta

Heterogeneidade da demanda exige seleção contextual de políticas de reposição



Consequências de uma política única

Custo	Ruptura	Efeito chicote
Excesso de estoque parado, ocupando espaço e capital.	Falta de produto na prateleira, venda perdida, cliente frustrado.	Pedidos das lojas amplificam a variabilidade observada pelo armazém regional.

Custo, disponibilidade e estabilidade dos pedidos são objetivos **em conflito** — e o equilíbrio adequado depende do **perfil da série**.

Introdução

*É possível construir uma abordagem metodológica que **aprenda qual política de reposição é mais adequada** para cada combinação loja-produto, a partir de características operacionais da série, oferecendo uma alternativa empiricamente avaliada às políticas únicas aplicadas uniformemente à rede?*

Hipótese central

O desempenho das políticas de reposição depende do **regime / perfil operacional da demanda**, e essa relação pode ser **aprendida** por um meta-modelo supervisionado.

1. **Heterogeneidade genuína:** não existe política universalmente melhor.
2. **Aprendibilidade:** a relação perfil $\rightarrow$ política pode ser aprendida a partir de características operacionais.
3. **Generalização:** um modelo treinado dessa forma pode recomendar políticas para novas séries.

Contribuição da dissertação

Contribuição central: formulação e avaliação do AIPE como framework de seleção contextual.

1. **Formulação do AIPE** como *framework* de seleção contextual de políticas de reposição.
2. **Estudo empírico** com dados reais de varejo brasileiro intermitente.
3. **Pipeline reprodutível** para caracterização, simulação, geração de rótulos e recomendação.
4. **Benchmark com 12 políticas** como meio experimental para gerar evidência e rótulos.

O que esta dissertação *não* é

Não cria novos algoritmos de otimização ou de aprendizado por reforço. A contribuição está na **formulação e avaliação** do AIPE como *framework* de seleção contextual.

Principais Trabalhos Relacionados

Panorama da literatura

Família	Exemplos	Limitação
Políticas clássicas	EOQ, (s, S) , Jornaleiro	Baixa adaptação a séries heterogêneas
Previsão de demanda	Croston, ARIMA, LSTM, XGBoost	Não define a política a aplicar
Parametrização por meta-heurísticas	GA, SA, PSO, DE, MILP	Calibra política já escolhida, não seleciona entre famílias
Aprend. por reforço	DQN, PPO, SARSA	Exige históricos longos ($\sim 10^6$ passos)
Seleção/meta-aprend.	ASP, hiper-heurísticas, AutoML	Pouco explorado em varejo real

Fonte: capítulo de Trabalhos Relacionados, Tabela 3.1

Três lacunas convergentes

Empírica

Poucos estudos avaliam políticas de reposição em **dados reais de varejo brasileiro** com demanda altamente intermitente.

Metodológica

Trabalhos existentes otimizam ou aprendem políticas *específicas*, mas não formulam a escolha como **seleção contextual por perfil operacional**.

Operacional

Pouco explorada a integração, em um **pipeline reprodutível**, entre caracterização, simulação, validação estatística e treinamento de um seletor supervisionado.


Posicionamento da dissertação

Trabalho	Dados reais	CV/regime	Políticas	Multinível	Indicadores
Oroojlooyjadid et al. (2022)	Não	< 1	3	Sim	2
Yuna et al. (2023)	Não	> 1,5	2	Não	2
Liu et al. (2024) – HAPPO	Não	< 1	4	Sim	2
Zabraoui et al. (2025) – GA-DQN	Não	< 1	7	Sim	3
Esta dissertação (Exp. 1, PB)	Sim	2,5–5,4	12	Sim	5
Esta dissertação (Exp. 2, BA)	Sim	Lumpy	12	Sim	5 + testes

Fonte: Capítulo 3, Tabela 3.2 (subconjunto)

Proposta

Visão geral do AIPE



O PSE decide; o portfólio de 12 políticas fornece as alternativas avaliadas.

As 12 políticas formam o portfólio sobre o qual ele aprende a recomendar. A cada Δt ciclos, a aplicação realimenta a entrada (reavaliação periódica).

Entradas do AIPE

Dados preparados

Séries loja-produto, ciclos comerciais (17/ano, ≈ 21 dias), filtragem e limpeza.

Características operacionais

17 variáveis: intermitência, distribuição, tendência, sazonalidade, volume.

Sinais de previsão

MASE, sMAPE, RMSSE de 4 modelos (Croston, ARIMA, XGBoost, LSTM).

Atenção

Caracterização e previsão são **entradas**, não a responsabilidade final do AIPE. A previsão é **signal auxiliar**, não critério final de escolha de política.

Metodologia

Perfis Operacionais de Demanda (POD)

POD	Critério ou grupo de características
Sparse High Impact	Intermitência alta, variabilidade alta e picos relevantes
High Vol. Seasonal	Sinal sazonal e/ou concentração de demanda em janelas
Unstable Trend	Tendência relevante e/ou mudanças de regime
Low Vol. Stable	Baixa média com baixa variabilidade
Fast Moving	Baixa intermitência e giro recorrente

Fonte: capítulo de Metodologia, Tabela 4.2; demand_profiling

POD classifica. Simulação avalia. Rótulo escolhe. PSE aprende.

Parâmetros fixos

- Horizonte $T = 38$ ciclos comerciais
- Prazo de entrega $L = 2$ ciclos
- $h = 1,0$; $c_s = 5,0$; $c_o^{\text{fix}} = 50,0$; $c_o^{\text{var}} = 0,5$
- Restrição de viabilidade: $NS \geq \alpha_{\min} = 0,70$

Indicadores (KPIs)

- **CTI**: custo total de inventário
- **NS**: nível de serviço
- **TR**: taxa de ruptura
- **BE**: efeito *bullwhip* ($\text{Var}(Q)/\text{Var}(D)$)
- **FP**: frequência de pedidos

Todas as políticas são avaliadas no **mesmo simulador**, com a mesma demanda real, custos e sementes – garantindo comparação controlada.

Portfólio de 12 políticas candidatas

Clássicas	Param. por meta-heurística	Aprendidas por reforço	Híbridas GA-RL
EOQ	Política parametrizada por GA	DQN	GA-DQN
(s, S)	Política parametrizada por SA	PPO	GA-PPO
Jornaleiro	Política parametrizada por PSO; Política parametrizada por DE	SARSA	

Cuidado conceitual

GA, SA, PSO e DE **não são políticas autônomas**: são métodos de busca usados para parametrizar a regra (s, Q). Quem decide é sempre a regra de reposição; a meta-heurística apenas a calibra.

O rótulo não nasce do PSE: nasce dos resultados simulados.

1. **Benchmark das políticas:** para cada série loja-produto, todas as políticas candidatas são avaliadas no mesmo ambiente de simulação.
2. **Geração do rótulo:** escolhe-se a política viável de menor CTI, respeitando o nível mínimo de serviço.

$$\hat{\pi}^*(i) = \arg \min_{\pi \in \mathcal{P}} \text{CTI}(\pi, i) \quad \text{sujeito a} \quad \text{NS}(\pi, i) \geq 0,70$$

Do rótulo ao PSE

O PSE aprende os rótulos gerados no benchmark e recomenda para novas séries.

Treinamento do PSE

- Entrada: características operacionais da série
- Alvo supervisionado: rótulo de política dominante
- Saída: política recomendada, confiança e *ranking*

Meta-modelo supervisionado de seleção (algoritmo agnóstico nesta etapa).

Estágio atual

A regra de rotulagem e o pipeline estão definidos e testados preliminarmente. A validação em escala nacional do PSE é etapa de continuidade.

Resultados

Experimento 1: estudo piloto (Paraíba)

Escopo

- 15 lojas $\times$ 1 produto (48130)
- 12 políticas $\times$ 1 replicação
- 180 combinações (política, loja)
- Regime *Lumpy* (100% das lojas)

O que validou

- Ambiente de simulação e métricas
- Protocolo de comparação entre políticas
- Comportamentos degenerados (SARSA: $FP = 0$; PPO: $FP = 0,98$)

Resultado de referência (não generalizável)

Em volume médio, GA-DQN reduziu CTI em **48%** e rupturas em 55% vs. (s, S) , com BE caindo de 119,4 para 5,0 – o **ganho máximo observado** neste recorte piloto, não uma média universal.


Experimento 2: expansão na Bahia

- 145 séries (loja, produto), 3 filiais, 6 segmentos comerciais
- 12 políticas $\times$ 5 replicações independentes
- 8.700 pontos de avaliação no total
- Regime *Lumpy* em 71% das séries


Cinco replicações por série habilitam testes estatísticos formais, o que o piloto da Paraíba (1 replicação) não permitia.

Distribuição das séries (BA)

Distribuição de Lojas por Filial e Segmento (BA)




Séries por Filial e Segmento




Distribuição de séries (loja $\times$ produto) por filial e segmento comercial.

Fronteira de Pareto CTI-NS



Cada ponto é a média de uma política sobre as 145 séries da Bahia.

Dispersão de CTI por política



Distribuição do CTI por política (boxplot sobre as 145 séries).

Nenhuma política domina simultaneamente

Custo, serviço e estabilidade são objetivos **em conflito** – nenhuma política minimiza CTI e maximiza NS ao mesmo tempo.

- **EOQ** e (s, S) : melhor equilíbrio custo-serviço agregado ($NS = 0,94$)
- **Jornaleiro**: menor custo bruto, mas $NS = 0,54$ (abaixo do limiar de viabilidade)
- **SA**: alternativa compacta, bom equilíbrio ($NS = 0,86$)

Política única vs. seleção por perfil


Estratégia	CTI médio (R\$)	NS médio	Red. vs. A1 (%)
A1/A2: política única (EOQ)	628,42	0,942	0,0
B: seleção por perfil	589,62	0,883	+6,2
C [†] : oráculo por série	347,82	0,700	+44,6

[†]Oráculo: conhecimento perfeito por série – referência exploratória, **não** é estratégia operacional.

Leitura cautelosa

A seleção por perfil reduz CTI médio em **6,2%**, mas com queda real de NS médio (0,942 → 0,883). É um **trade-off custo-serviço mensurável**, não um ganho puro.

CTI médio por política e perfil



CTI médio por política e Perfil Operacional de Demanda (Experimento 2, BA).

Dominância depende do perfil

Perfil	n	Dominante	CTI médio (R\$)
Sparse High Impact	116	SA	584,01
Unstable Trend	18*	EOQ	607,95
High Vol. Seasonal	11*	EOQ	618,79

* $n < 20$: evidência exploratória.

Cuidado com o custo bruto

O Jornaleiro tem o **menor CTI bruto** em Sparse High Impact (R\$ 284), mas $NS = 0,55$ – abaixo do limiar de viabilidade de 0,70. Não é dominante.

CTI ajustado: leitura (análise complementar)

$$J(\pi, g) = \text{CTI}_{\text{norm}}(\pi, g) + \lambda_{BE} \cdot \text{BE}_{\text{norm}}(\pi, g)$$

- $\lambda_{BE} = 0$: recupera o critério principal (CTI puro)
- Na visão global do experimento, $A = B = \text{EOQ}$ para todo λ_{BE}
- Mudanças de dominância aparecem por perfil e devem ser lidas como **evidência exploratória** quando $n < 20$

Status: preliminar e complementar

Não substitui o critério principal (CTI puro sob $\text{NS} \geq 0,70$). Mostra sensibilidade do resultado quando a estabilidade dos pedidos recebe maior peso.

Limitações atuais

- Avaliação concentrada no regime **Lumpy** (PB e BA); demais quadrantes de Syntetos-Boylan ainda não cobertos.
- Perfis *Unstable Trend* ($n = 18$) e *High Vol. Seasonal* ($n = 11$) têm $n < 20$ – evidência exploratória, não conclusiva.
- O oráculo por série é **limite teórico exploratório**, não política implementável.
- O PSE ainda não foi treinado e validado em escala nacional.
- Horizonte fixo de 38 ciclos; parâmetros de custo e *lead time* fixos no recorte avaliado.
- Previsão de demanda é sinal auxiliar – não validada como critério de seleção isolado.

Plano de continuidade

Atividade	24 S2	25 S1	25 S2	26
Formulação e revisão da literatura	✓			
Benchmarking Experimento 1 (PB)	✓	✓		
Pipeline Kedro e previsão de demanda		✓	✓	
Simulação Exp. 2 (BA) e validação estatística			✓	
Módulo demand_profiling e PODs			✓	
Expansão nacional multiestado/multi-SKU				●
Treinamento e avaliação do PSE				●
Análise de sensibilidade e janela móvel				○
Escrita e defesa da dissertação				●

✓ concluído ● em andamento ○ planejado

Expansão nacional: $\approx 10,4$ milhões de séries, 26 estados + DF.

Seleção contextual supera política única

A decisão de reposição melhora quando considera o contexto operacional de cada série.

Seleção contextual

evidência empírica + PSE como
meta-modelo

Pipeline reprodutível

Kedro, rastreabilidade completa

Dados reais brasileiros

PB e BA, regime *Lumpy*

Obrigado.

Perguntas e discussão