

Seleção Contextual de Políticas de Reposição em Redes Varejistas

O AIPE como *framework* metodológico de apoio à decisão

Matheus Inácio Batista Santos

Exame de Qualificação de Mestrado

Instituto de Computação — UFAL

Orientadores: Dr. Rian G. S. Pinheiro e Dr. Bruno C. S. Nogueira

Redes varejistas heterogêneas precisam decidir
quando e **quanto** repor estoque
em cada combinação loja-produto.

Heterogeneidade da demanda

Produto regular


Vende com previsibilidade (ex.: 50 un./semana em qualquer loja).

Produto intermitente / lumpy

Períodos de demanda nula intercalados com picos esporádicos (ex.: “0, 0, 0, 50, 0, 0, 30”).

Motivação da proposta

Heterogeneidade da demanda exige seleção contextual de políticas de reposição



Mesma rede, padrões distintos

Aplicar a **mesma política** a séries com comportamentos tão diferentes tende a ser ineficiente.

Consequências de uma política única

Custo	Ruptura	Efeito chicote
Excesso de estoque parado, ocupando espaço e capital.	Falta de produto na prateleira, venda perdida, cliente frustrado.	Pedidos das lojas amplificam a variabilidade observada pelo armazém regional.

Custo, disponibilidade e estabilidade dos pedidos são objetivos **em conflito** — e o equilíbrio adequado depende do **perfil da série**.

É possível construir uma abordagem metodológica que aprenda qual política de reposição é mais adequada para cada combinação loja-produto, a partir de características operacionais da série, oferecendo uma alternativa empiricamente avaliada às políticas únicas aplicadas uniformemente à rede?

O desempenho das políticas de reposição depende do **regime / perfil operacional da demanda**, e essa relação pode ser **aprendida** por um meta-modelo supervisionado.

1. **Heterogeneidade genuína:** não existe política universalmente melhor.
2. **Aprendibilidade:** a relação perfil $\rightarrow$ política pode ser aprendida a partir de características operacionais.
3. **Generalização:** um modelo treinado dessa forma pode recomendar políticas para novas séries.

A lacuna não é falta de algoritmos

O que já existe

- Modelos analíticos clássicos (EOQ, (s, S) , Jornaleiro)
- Políticas parametrizadas por meta-heurísticas
- Políticas aprendidas por reforço
- Comparações isoladas entre famílias

O que falta

- **Seleção contextual** validada em dados reais
- Evidência em **varejo brasileiro** intermitente
- Ligação explícita entre perfil e política dominante

Posicionamento

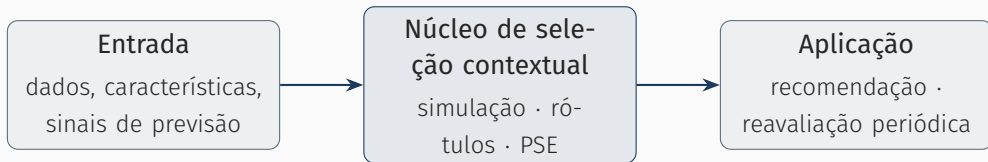
O problema se aproxima da **seleção de algoritmos** (Rice, 1976) – escolher, para cada instância, a alternativa com melhor desempenho esperado.

1. **Comparação empírica** de 12 políticas sobre dados reais de varejo brasileiro intermitente.
2. **Mapeamento perfil** → **política dominante**, com validação estatística formal.
3. **Pipeline reproduzível** (dados reais, rastreabilidade completa de código e configuração).

O que esta dissertação não é

Não cria novos algoritmos de otimização ou de aprendizado por reforço. A contribuição está na **formulação e avaliação** do AIPE como *framework* de seleção contextual.

Visão geral do AIPE



O **PSE** é o componente de seleção do AIPE; as 12 políticas formam o portfólio sobre o qual ele aprende a recomendar. A cada Δt ciclos, a aplicação realimenta a entrada (reavaliação periódica).

Dados preparados

Séries loja-produto, ciclos comerciais (17/ano, ≈ 21 dias), filtragem e limpeza.

Características operacionais

17 variáveis: intermitência, distribuição, tendência, sazonalidade, volume.

Sinais de previsão

MASE, sMAPE, RMSSE de 4 modelos (Croston, ARIMA, XGBoost, LSTM).

Atenção

Caracterização e previsão são **entradas**, não a responsabilidade final do AIPE. A previsão é **signal auxiliar**, não critério final de escolha de política.

Perfis Operacionais de Demanda (POD)

POD	Critério	Referência inicial
Sparse High Impact	$ADI \geq 1,32, CV^2 \geq 0,49, z_{\max} \geq 5$	GA-DQN
High Vol. Seasonal	$\rho_S \geq 0,25$ ou $B \geq 0,30$	PPO
Unstable Trend	$ \beta_t/\mu \geq 0,05$ ou $H \geq 2,0$	GA-PPO
Low Vol. Stable	$\mu \leq 2,0, CV^2 < 0,49$	Jornaleiro
Fast Moving	$ADI < 1,32$	(s, S)

Fonte: capítulo de Metodologia, Tabela 4.1; demand_profiling

As regras são **heurísticas configuráveis** – a política de referência é um ponto de partida, não a dominância empírica final.

Parâmetros fixos

- Horizonte $T = 38$ ciclos comerciais
- Prazo de entrega $L = 2$ ciclos
- $h = 1,0$; $c_s = 5,0$; $c_o^{\text{fix}} = 50,0$; $c_o^{\text{var}} = 0,5$
- Restrição de viabilidade: NS
 $\geq \alpha_{\text{min}} = 0,70$

Indicadores (KPIs)

- **CTI**: custo total de inventário
- **NS**: nível de serviço
- **TR**: taxa de ruptura
- **BE**: efeito *bullwhip* ($\text{Var}(Q)/\text{Var}(D)$)
- **FP**: frequência de pedidos

Todas as políticas são avaliadas no **mesmo simulador**, com a mesma demanda real, custos e sementes – garantindo comparação controlada.

Clássicas	Param. por meta-heurística	Aprendidas por reforço	Híbridas GA-RL
EOQ	GA	DQN	GA-DQN
(s, S)	SA	PPO	GA-PPO
Jornaleiro	PSO, DE	SARSA	

Cuidado conceitual

GA, SA, PSO e DE **não são políticas autônomas**: são métodos de busca usados para parametrizar a regra (s, Q) . Quem decide é sempre a regra de reposição; a meta-heurística apenas a calibra.

$$\hat{\pi}^*(i) = \arg \min_{\pi \in \mathcal{P}} \mathbb{E}[\text{CTI}(\pi, i)] \quad \text{sujeito a } \mathbb{E}[\text{NS}(\pi, i)] \geq 0,70$$

Para cada série, o rótulo é a política viável de **menor CTI** entre as que atingem o NS mínimo.

PSE (estágio atual)

- Classificador XGBoost multiclasse
- Entrada: vetor de 17 características
- Saída: política recomendada + confiança + *ranking*

Ainda não finalizado

O PSE foi formulado e testado nos rótulos disponíveis; o treinamento em escala e a validação de generalização são etapa da expansão nacional.

Experimento 1: estudo piloto (Paraíba)

Escopo

- 15 lojas $\times$ 1 produto (48130)
- 12 políticas $\times$ 1 replicação
- 180 combinações (política, loja)
- Regime *Lumpy* (100% das lojas)

O que validou

- Ambiente de simulação e métricas
- Protocolo de comparação entre políticas
- Comportamentos degenerados (SARSA: FP = 0; PPO: FP = 0,98)


Resultado de referência (não generalizável)

Em volume médio, GA-DQN reduziu CTI em **48%** e rupturas em 55% vs. (s, S), com BE caindo de 119,4 para 5,0 – o **ganho máximo observado** neste recorte piloto, não uma média universal.

Experimento 2: expansão na Bahia


Escopo

- 145 séries (loja, produto)
- 3 filiais, 6 segmentos comerciais
- 12 políticas $\times$ 5 replicações
- 8.700 pontos de avaliação
- Regime *Lumpy* (71% das séries)




Fonte: simulation/data/08_reporting/maps/distribuicao_lojas_segmento

Nenhuma política domina simultaneamente



Fronteira de Pareto CTI-NS



Dispersão de CTI por política

Sobre as 145 séries da Bahia: **EOQ** e **(s, S)** oferecem o melhor equilíbrio custo-serviço agregado ($NS = 0,94$); o **Jornaleiro** tem o menor custo bruto, mas $NS = 0,54$.

Política única vs. seleção por perfil


Estratégia	CTI médio (R\$)	NS médio	Red. vs. A1 (%)
A1/A2: política única (EOQ)	628,42	0,942	0,0
B: seleção por perfil	589,62	0,883	+6,2
C [†] : oráculo por série	347,82	0,700	+44,6

[†]Oráculo: conhecimento perfeito por série – referência exploratória, **não** é estratégia operacional.

Leitura cautelosa

A seleção por perfil reduz CTI médio em **6,2%**, mas com queda real de NS médio (0,942 → 0,883). É um **trade-off custo-serviço mensurável**, não um ganho puro.

Dominância depende do perfil operacional



CTI médio por política e POD


Perfil	<i>n</i>	Dominante	CTI (R\$)
Sparse High Impact	116	SA	584,01
Unstable Trend	18*	EOQ	607,95
High Vol. Seasonal	11*	EOQ	618,79

* $n < 20$: evidência exploratória.

Cuidado com o custo bruto

O Jornaleiro tem o **menor CTI bruto** em Sparse High Impact (R\$ 284), mas $NS = 0,55$ – abaixo do limiar de viabilidade de 0,70. Não é dominante: o ganho de custo não é alcançável sem violar o nível de serviço mínimo.

CTI ajustado por estabilidade (análise complementar)



Sensibilidade a λ_{BE}

$$J(\pi, g) = \text{CTI}_{\text{norm}} + \lambda_{BE} \cdot \text{BE}_{\text{norm}}$$

- $\lambda_{BE} = 0$: recupera o CTI puro (EOQ domina)
- $\lambda_{BE} \geq 0,25$: política única migra para SA (BE = 5,5 vs. 55,4 do EOQ)
- Em $\lambda_{BE} = 1,0$: até +56,6% de redução ajustada, com NS caindo de 0,942 para 0,862

Status: preliminar e complementar

Não substitui o critério principal (CTI puro sob $\text{NS} \geq 0,70$). A partir de $\lambda_{BE} \geq 0,5$, a seleção por perfil converge para a política única ajustada.

Limitações atuais

- Avaliação concentrada no regime *Lumpy* (PB e BA); demais quadrantes de Syntetos-Boylan ainda não cobertos.
- Perfis *Unstable Trend* ($n = 18$) e *High Vol. Seasonal* ($n = 11$) têm $n < 20$ – evidência exploratória, não conclusiva.
- O oráculo por série é **limite teórico exploratório**, não política implementável.
- O PSE ainda não foi treinado e validado em escala nacional.
- Horizonte fixo de 38 ciclos; parâmetros de custo e *lead time* fixos no recorte avaliado.
- Previsão de demanda é sinal auxiliar – não validada como critério de seleção isolado.

Plano de continuidade

Atividade	24 S2	25 S1	25 S2	26
Formulação e revisão da literatura	✓			
Benchmarking Experimento 1 (PB)	✓	✓		
Pipeline Kedro e previsão de demanda		✓	✓	
Simulação Exp. 2 (BA) e validação estatística			✓	
Módulo demand_profiling e PODs			✓	
Expansão nacional multiestado/multi-SKU				●
Treinamento e avaliação do PSE				●
Análise de sensibilidade e janela móvel				○
Escrita e defesa da dissertação				●

✓ concluído ● em andamento ○ planejado

Expansão nacional: $\approx 10,4$ milhões de séries, 26 estados + DF.

A decisão de reposição se beneficia de ser tratada como **problema de seleção contextual** – não de escolha de uma única política para toda a rede.

Seleção contextual

evidência empírica + PSE como
meta-modelo

Pipeline reprodutível

Kedro, rastreabilidade completa

Dados reais brasileiros

PB e BA, regime *Lumpy*

Obrigado.

Perguntas e discussão.