

Seleção Contextual de Políticas de Reposição em Redes Varejistas

O AIPE como *framework* metodológico de apoio à decisão

Matheus Inácio Batista Santos

Exame de Qualificação de Mestrado

Instituto de Computação — UFAL

Orientadores: Dr. Rian G. S. Pinheiro e Dr. Bruno C. S. Nogueira

1. Por que o problema importa?
2. Onde está a lacuna?
3. Qual é a proposta?
4. Como o AIPE funciona?
5. O que foi avaliado?
6. O que os resultados mostram?
7. O que falta?


Problema

Redes varejistas heterogêneas precisam decidir
quando e **quanto** repor estoque
em cada série loja-produto.

Heterogeneidade da demanda

Motivação da proposta

Heterogeneidade da demanda exige seleção contextual de políticas de reposição



Consequências de uma política única

Custo	Ruptura	Efeito chicote
Excesso de estoque parado, ocupando espaço e capital.	Falta de produto na prateleira, venda perdida, cliente frustrado.	Pedidos das lojas amplificam a variabilidade observada pelo armazém regional.

Custo, disponibilidade e estabilidade dos pedidos são objetivos **em conflito** — e o equilíbrio adequado depende do **perfil da série**.

Introdução

*É possível construir uma abordagem metodológica que **aprenda qual política de reposição é mais adequada** para cada série loja-produto, a partir de suas características operacionais, oferecendo uma alternativa empiricamente avaliada às políticas únicas aplicadas uniformemente à rede?*

Objetivo da pesquisa

Objetivo geral

Formular e avaliar o AIPE como um *framework* metodológico para **seleção contextual de políticas de reposição** em séries loja-produto de redes varejistas heterogêneas.

Objetivos específicos

1. Caracterizar séries loja-produto a partir de variáveis operacionais de demanda.
2. Avaliar um portfólio de políticas de reposição em ambiente de simulação controlado.
3. Gerar rótulos de política viável de menor CTI sob restrição de nível de serviço.
4. Estruturar a base metodológica para treinamento e validação futura do PSE.

Hipótese central

O desempenho das políticas de reposição depende do **regime / perfil operacional da demanda**, e essa relação pode ser **aprendida** por um meta-modelo supervisionado.

1. **Heterogeneidade genuína:** não existe política universalmente melhor.
2. **Aprendibilidade:** a relação perfil $\rightarrow$ política pode ser aprendida a partir de características operacionais.
3. **Generalização:** um modelo treinado dessa forma pode recomendar políticas para novas séries.

Contribuição da dissertação

Contribuição central: formulação e avaliação do AIPE como framework de seleção contextual.

1. **Formulação do AIPE** como *framework* de seleção contextual de políticas de reposição.
2. **Estudo empírico** com dados reais de varejo brasileiro intermitente.
3. **Pipeline reprodutível** para caracterização, simulação, geração de rótulos e recomendação.
4. **Benchmark com 12 políticas** como meio experimental para gerar evidência e rótulos.

O que esta dissertação *não* é

Não cria novos algoritmos de otimização ou de aprendizado por reforço. A contribuição está na **formulação e avaliação** do AIPE como *framework* de seleção contextual.

Principais Trabalhos Relacionados

Da literatura à lacuna

Políticas clássicas

Resolve:

- regras conhecidas de reposição
- interpretação simples
- baixo custo computacional

Falta:

- adaptação a séries heterogêneas
- escolha contextual entre políticas

Previsão e otimização

Resolve:

- melhora estimativas de demanda
- calibra parâmetros de uma política já escolhida

Falta:

- escolher qual família de política aplicar
- integrar custo, serviço e estabilidade em um processo de seleção

RL e métodos aprendidos

Resolve:

- aprende decisões sequenciais em ambientes simulados
- pode capturar dinâmicas complexas

Falta:

- exige histórico/interações longas
- pouco validado em varejo real intermitente
- não resolve sozinho a seleção entre famílias

A lacuna não é a ausência de políticas; é a ausência de um mecanismo contextual para escolher qual política aplicar em cada série loja-produto.

Três lacunas convergentes

Empírica

Poucos estudos avaliam políticas de reposição em **dados reais de varejo brasileiro** com demanda altamente intermitente.

Metodológica

Trabalhos existentes otimizam ou aprendem políticas *específicas*, mas não formulam a escolha como **seleção contextual por perfil operacional**.

Operacional

Pouco explorada a integração, em um **pipeline reprodutível**, entre caracterização, simulação, validação estatística e treinamento de um seletor supervisionado.


Posicionamento da dissertação

Trabalho	Dados reais	CV/regime	Políticas	Multinível	Indicadores
Oroojlooyjadid et al. (2022)	Não	< 1	3	Sim	2
Yuna et al. (2023)	Não	> 1,5	2	Não	2
Liu et al. (2024) – HAPPO	Não	< 1	4	Sim	2
Zabraoui et al. (2025) – GA-DQN	Não	< 1	7	Sim	3
Esta dissertação (Exp. 1, PB)	Sim	2,5–5,4	12	Sim	5
Esta dissertação (Exp. 2, BA)	Sim	Lumpy	12	Sim	5 + testes

Fonte: Capítulo 3, Tabela 3.2 (subconjunto)

Proposta

Visão geral do AIPE



O **PSE** recomenda; o portfólio de 12 políticas fornece as alternativas avaliadas.

As 12 políticas formam o portfólio sobre o qual ele aprende a recomendar. A cada Δt ciclos, a aplicação realimenta a entrada (reavaliação periódica).

Formulação matemática do AIPE

A decisão do AIPE é selecionar uma política para cada série loja-produto.

Elementos

- i : série loja-produto
- π : política candidata
- $\mathbf{x}_i$: características
- $z_{i,\pi} \in \{0, 1\}$: variável de decisão
- CTI: custo total de inventário
- NS: nível de serviço
- $\alpha_{\min} = 0,70$


Formulação por série i :

$$\begin{aligned} \min_{z_{i,\pi}} \quad & \sum_{\pi \in \mathcal{P}} z_{i,\pi} \overline{\text{CTI}}_{i,\pi} \\ & \sum_{\pi} z_{i,\pi} = 1 \\ & \sum_{\pi} z_{i,\pi} \overline{\text{NS}}_{i,\pi} \geq \alpha_{\min} \quad z_{i,\pi} \in \{0, 1\} \end{aligned}$$

Rodapé: AIPE escolhe a política; a política gera os pedidos.

Metodologia

Síntese do pipeline metodológico



Mapa da metodologia: dados preparados → características da série → simulação → POD → rótulo e PSE → recomendação.

Módulo 1 – Dados preparados



A unidade de análise do AIPE é a série loja-produto: uma sequência de demanda observada para um par específico.


Como a série é construída

- Unidade: série loja-produto
- Exemplo: loja A + produto X = uma série
- Horizonte em ciclos comerciais comparáveis
- Filtragem e limpeza antes da caracterização

Por que isso importa

A política é recomendada para uma série específica, não para uma loja inteira nem para uma categoria agregada.

Módulo 2 – Características e sinais auxiliares



As características descrevem a série; a previsão entra como sinal auxiliar, não como critério final de escolha.

Características da demanda


- ADI e CV^2
- *Burstiness* e variabilidade
- Tendência e sazonalidade
- Volume e concentração temporal

Sinais auxiliares

- Erros de previsão ajudam a medir previsibilidade
- O PSE usa sinais para recomendar melhor
- A previsão não escolhe a política

Esses atributos formam x_i , o vetor contextual da série loja-produto.

Módulo 3 – Ambiente de simulação



Parâmetros fixos


- Horizonte $T = 38$ ciclos comerciais
- Prazo de entrega $L = 2$ ciclos
- $h = 1,0$; $c_s = 5,0$; $c_o^{\text{fix}} = 50,0$; $c_o^{\text{var}} = 0,5$
- Restrição de viabilidade: NS
 $\geq \alpha_{\min} = 0,70$

Indicadores (KPIs)

- **CTI**: custo total de inventário
- **NS**: nível de serviço
- **TR**: taxa de ruptura
- **BE**: efeito *bullwhip* ($\text{Var}(Q)/\text{Var}(D)$)
- **FP**: frequência de pedidos

Todas as políticas são avaliadas no **mesmo ambiente**: mesma demanda real, mesmos custos, mesmas sementes e os mesmos KPIs (CTI, NS, TR, BE e FP).

Módulo 4 – Regimes de demanda



Syntetos-Boylan define o regime macro da demanda; no recorte BA, todas as séries avaliadas são Lumpy.

PODs: refinamento operacional dentro dos regimes



A taxonomia Syntetos-Boylan classifica o regime macro da demanda. Os PODs refinam esse regime usando características adicionais da série loja-produto.

POD	Critério ou grupo de características
Sparse High Impact	Longos silêncios + picos
High Vol. Seasonal	Concentração/sazonalidade
Unstable Trend	Tendência ou mudança de regime
Low Vol. Stable	Baixo volume e baixa variabilidade
Fast Moving	Demanda frequente

Fonte: capítulo de Metodologia, Tabela 4.1; demand_profiling

Regime $\neq$ POD. No recorte BA, todas as séries são Lumpy, mas são separadas em PODs distintos para apoiar a seleção contextual.

Do benchmark à recomendação



O rótulo nasce da simulação; o PSE aprende o padrão.

1. Simulação avalia cada política candidata.
2. O rótulo é a política viável de menor CTI.
3. O PSE aprende a mapear características da série para esse rótulo.
4. Para uma nova série, o PSE recomenda uma política e um ranking.

$$y_i = \arg \min_{\pi \in \mathcal{P}: \overline{\text{NS}}_{i,\pi} \geq 0,70} \overline{\text{CTI}}_{i,\pi}$$

$$f_{\theta}(\mathbf{x}_i) \rightarrow \hat{\pi}_i$$

Estágio atual

Regra de rotulagem e pipeline definidos; validação nacional do PSE é continuidade.

Módulo 6 – Recomendação



A saída do AIPE é uma política recomendada para a série loja-produto, acompanhada de um ranking de alternativas.

Como funciona

- Nova série entra com seu vetor contextual $\mathbf{x}_i$.
- O PSE estima a política indicada: $f_{\theta}(\mathbf{x}_i)$.
- A saída combina política principal, ranking e reavaliação periódica.

Exemplo de leitura

Série com muitos zeros e picos altos pode receber recomendação diferente de uma série estável, mesmo dentro do mesmo produto.

Portfólio de políticas candidatas

Clássicas	Param. por meta-heurística	Aprendidas por reforço	Híbridas GA-RL
EOQ	Política parametrizada por GA	DQN	GA-DQN
(s, S)	Política parametrizada por SA	PPO	GA-PPO
Jornaleiro	Política parametrizada por PSO; Política parametrizada por DE	SARSA	

Cuidado conceitual

GA, SA, PSO e DE **não são políticas autônomas**: são métodos de busca usados para parametrizar a regra (s, Q). Quem decide é sempre a regra de reposição; a meta-heurística apenas a calibra.

Resultados

Experimento 1: estudo piloto (Paraíba)

Escopo

- 15 lojas $\times$ 1 produto (48130)
- 12 políticas $\times$ 1 replicação
- 180 combinações (política, loja)
- Regime *Lumpy* (100% das lojas)

O que validou

- Ambiente de simulação e métricas
- Protocolo de comparação entre políticas
- Comportamentos degenerados (SARSA: $FP = 0$; PPO: $FP = 0,98$)

Resultado de referência (não generalizável)


Em volume médio, GA-DQN reduziu CTI em **48%** e rupturas em 55% vs. (s, S) , com BE caindo de 119,4 para 5,0 – o **ganho máximo observado** neste recorte piloto, não uma média universal.

Experimento 2: expansão na Bahia

- 145 séries (loja, produto), 3 filiais, 6 segmentos comerciais
- 12 políticas $\times$ 5 replicações independentes
- 8.700 pontos de avaliação no total
- 145/145 séries classificadas como *Lumpy* no recorte avaliado

Cinco replicações por série habilitam testes estatísticos formais, o que o piloto da Paraíba (1 replicação) não permitia.


Distribuição das séries no plano $ADI \times CV^2$



145/145 séries (100.0%) classificadas como Lumpy no recorte avaliado

Fonte: demand_profiles.parquet (145 séries, loja×produto, BA, Experimento 2). Cortes: ADI=1.32, CV²=0.49 (Syntetos-Boylan, 2005).

Fronteira de Pareto CTI–NS




Cada ponto é a média de uma política sobre as 145 séries da Bahia.

Custo, serviço e estabilidade são objetivos em conflito: nenhuma política minimiza CTI e maximiza NS ao mesmo tempo no recorte avaliado.

Política única vs. seleção por perfil

Política única vs. seleção por perfil — trade-off custo-serviço


Redução de CTI na seleção por perfil (B): 6.2% (R\$ 628.42 → R\$ 589.62) • NS 0.942 → 0.883



A seleção por perfil reduz custo médio, mas há queda de nível de serviço. Trata-se de trade-off custo-serviço.

† C (oráculo por série) é referência exploratória, não estratégia operacional.

A política viável de menor CTI muda por perfil



Cuidado com o custo bruto

O Jornaleiro tem o **menor CTI bruto** em Sparse High Impact (R\$ 284), mas $NS = 0,55$ – abaixo do limiar de viabilidade de 0,70. Não é política viável neste perfil.

Limitações atuais

- Avaliação concentrada no regime **Lumpy** (PB e BA); demais quadrantes de Syntetos-Boylan ainda não cobertos.
- Perfis *Unstable Trend* ($n = 18$) e *High Vol. Seasonal* ($n = 11$) têm $n < 20$ – evidência exploratória, não conclusiva.
- O oráculo por série é **limite teórico exploratório**, não política implementável.
- O PSE ainda não foi treinado e validado em escala nacional.
- Horizonte fixo de 38 ciclos; parâmetros de custo e *lead time* fixos no recorte avaliado.
- Previsão de demanda é sinal auxiliar – não validada como critério de seleção isolado.

Plano de continuidade

Atividade	24 S2	25 S1	25 S2	26
Formulação e revisão da literatura	✓			
Benchmarking Experimento 1 (PB)	✓	✓		
Pipeline Kedro e previsão de demanda		✓	✓	
Simulação Exp. 2 (BA) e validação estatística			✓	
Módulo <code>demand_profiling</code> e PODs			✓	
Expansão nacional multiestado/multi-SKU				●
Treinamento e avaliação do PSE				●
Análise de sensibilidade e janela móvel				○
Escrita e defesa da dissertação				●

✓ concluído ● em andamento ○ planejado

Expansão nacional: $\approx 10,4$ milhões de séries, 26 estados + DF.

Seleção contextual mostra ganho frente à política única no recorte avaliado

A decisão de reposição melhora quando considera o contexto operacional de cada série.

Seleção contextual

evidência empírica + PSE como
meta-modelo

Pipeline reprodutível

Kedro, rastreabilidade completa

Dados reais brasileiros

PB e BA, regime *Lumpy*

Obrigado.

Perguntas e discussão