

Otimização de Inventário Multi-Echelon sob Demanda Intermitente: Comparação de Doze Políticas em Dados Reais de Varejo Brasileiro

RESUMO

Modelos clássicos de inventário, como o *Economic Order Quantity* (EOQ) e a política de dois limiares (s, S), pressupõem estacionariedade, hipótese que apresenta limitações sistemáticas em cenários com demanda intermitente, gerando excesso de estoque e rupturas frequentes no varejo regional brasileiro. Estudos comparativos recentes baseados em conjuntos como o Walmart M5 não cobrem o regime de alta variabilidade caracterizado por coeficiente de variação (CV) entre 2.5 e 5.4, típico de produtos de baixo giro. Este trabalho apresenta uma comparação de doze políticas de controle de inventário em dados operacionais proprietários de varejo regional brasileiro, avaliadas em cinco indicadores: custo total, nível de serviço, taxa de ruptura, efeito de amplificação da demanda (*bullwhip*) e frequência de pedidos. A arquitetura híbrida GA-DQN (*Genetic Algorithm with Deep Q-Network*) apresentou o equilíbrio mais favorável entre as políticas avaliadas: custo inferior às heurísticas clássicas, efeito *bullwhip* menor que a política (s, S) e taxa de ruptura equivalente à melhor política prática isolada, resultado consistente com o desempenho esperado da arquitetura em regime de alta intermitência.


PALAVRAS CHAVE. Gestão de inventário; Demanda intermitente; Cadeia de suprimentos multi-nível; Meta-heurísticas; Aprendizado por reforço.

Tópicos (em ordem de PRIORIDADE): Logística e *Supply Chain*; Otimização de Processos; Inteligência Artificial e Aprendizado de Máquina.

ABSTRACT

Classical inventory models, such as the Economic Order Quantity (EOQ) and the two-threshold policy (s, S), rely on stationarity assumptions, a hypothesis that presents systematic limitations for intermittent-demand items, producing excess stock and frequent stockouts in Brazilian regional retail. Recent comparative studies based on datasets such as Walmart M5 do not cover this high-variability regime, characterized by a coefficient of variation (CV) between 2.5 and 5.4, typical of slow-moving products. This work presents a comparison of twelve inventory control policies on proprietary operational data from Brazilian regional retail, evaluated on five indicators: total cost, service level, stockout rate, demand amplification along the supply chain (*bullwhip* effect), and order frequency. The hybrid GA-DQN (Genetic Algorithm with Deep Q-Network) architecture presented the most favorable trade-off among the evaluated policies: lower cost than classical heuristics, a *bullwhip* effect lower than (s, S), and a stockout rate on par with the best practical standalone policy, suggesting consistent performance of the hybrid approach under high intermittent demand.

KEYWORDS. Inventory management; Intermittent demand; Multi-level supply chain; Metaheuristics; Reinforcement learning.



Paper topics (in order of PRIORITY): Logistics and Supply Chain; Process Optimisation; Artificial Intelligence and Machine Learning.

1. Introdução


A gestão ineficiente de inventário representa, segundo estimativas, entre 3.5% e 8% do faturamento anual do varejo brasileiro em capital imobilizado e perdas por ruptura [Silver et al., 2017]. No varejo regional, itens de baixo giro são tipicamente controlados com heurísticas clássicas como o Lote Econômico de Compra (EOQ) [Harris, 1913] e a política (s, S) [Hadley e Whitin, 1963], que pressupõem estacionariedade raramente verificada em dados reais [Silver et al., 2017]. Em cadeias *multi-echelon* com demanda *intermitente*, longos períodos sem consumo alternados com picos esporádicos [Croston, 1972] amplificam esse problema: violam hipóteses de normalidade e intensificam o efeito *bullwhip* ao longo da cadeia. Estudos comparativos recentes baseados no Walmart M5 não cobrem o regime de coeficiente de variação (CV) superior a 2.5, típico de produtos de baixo giro no varejo regional brasileiro [Syntetos e Boylan, 2001].

Apesar dos avanços recentes em RL e meta-heurísticas, há pouca evidência empírica comparando essas abordagens em cadeias *multi-echelon* sob demanda altamente intermitente baseada em dados operacionais proprietários de varejo regional brasileiro, especialmente em regime de CV entre 2.5 e 5.4. A hipótese central é que arquiteturas híbridas GA-RL (*Genetic Algorithm – Reinforcement Learning*) apresentam equilíbrio mais favorável entre custo, estabilidade logística e nível de serviço do que políticas clássicas e agentes de RL isolados nesse contexto. As contribuições deste trabalho são:

1. Comparação sistemática de doze políticas de controle de inventário em dados operacionais proprietários de varejo regional brasileiro com CV entre 2.5 e 5.4, regime pouco explorado na literatura disponível;
2. Avaliação em regime de demanda extremamente intermitente, não coberto por estudos baseados no Walmart M5;
3. Análise com cinco indicadores primários para todas as políticas, incluindo efeito *bullwhip* e frequência de pedidos;
4. Estratificação por perfil de demanda, revelando que a política ótima depende do regime de consumo;
5. Validação da arquitetura GA-DQN (*Genetic Algorithm – Deep Q-Network*) em dados operacionais proprietários de varejo regional brasileiro.

Os resultados sugerem que o GA-DQN apresentou o equilíbrio mais favorável entre as políticas avaliadas: custo 48% inferior à política (s, S) , efeito *bullwhip* aproximadamente 24 vezes menor e taxa de ruptura equivalente à melhor política isolada. A política (s, S) , frequentemente utilizada no varejo regional, apresentou desempenho consistentemente inferior em todos os estratos avaliados.

O restante do artigo está organizado como se segue: a Seção 2 revisa a literatura; a Seção 3 apresenta a formulação do problema; a Seção 4 descreve os dados; a Seção 5 detalha as doze políticas; a Seção 6 descreve o ambiente experimental; a Seção 7 apresenta e discute os resultados; e a Seção 8 conclui com recomendações práticas e trabalhos futuros.



2. Trabalhos Relacionados

Esta seção revisa os trabalhos mais relacionados em três frentes: o problema de inventário *multi-echelon* sob demanda intermitente, as abordagens de meta-heurísticas e aprendizado por reforço aplicadas ao controle de estoque, e as lacunas da literatura que este trabalho endereça.

2.1. Inventário Multi-Echelon sob Demanda Intermitente

A teoria clássica de controle de estoques, fundamentada no EOQ [Harris, 1913] e na política (s, S) [Hadley e Whitin, 1963], pressupõe demanda estacionária e quase-normal. Em contextos de demanda *intermitente*, essa hipótese apresenta limitações sistemáticas: a distribuição empírica é bimodal (zero com alta probabilidade; pico raro de grande magnitude) e os estimadores clássicos perdem confiabilidade [Croston, 1972]. Syntetos e Boylan [2001] formalizaram o regime intermitente em termos do coeficiente de variação, estabelecendo que padrões com $CV > 1.5$ exigem tratamento metodológico específico, limiar superado por todos os cenários deste estudo.

No ambiente *multi-echelon*, a complexidade adicional decorre do acoplamento entre níveis: a variabilidade dos pedidos das lojas amplifica-se ao longo da cadeia (efeito *bullwhip* [Lee et al., 1997]), tornando o problema de reposição ainda mais difícil de resolver com parâmetros estáticos [Axsäter, 2006; Clark e Scarf, 1960]. Problemas de grande escala, como o conjunto completo que origina este estudo (48 milhões de transações e 12 mil SKUs), evidenciam que o espaço de decisões cresce combinatorialmente com o número de produtos, lojas e ciclos [Shapiro, 2001; Boute et al., 2022].

2.2. Meta-Heurísticas e Aprendizado por Reforço

Uma primeira frente de pesquisa emprega meta-heurísticas para otimização de parâmetros de inventário. Yuna et al. [2023] compararam *Simulated Annealing* (SA) e Busca Tabu na otimização de parâmetros (s, S) em sete conjuntos de dados intermitentes, verificando superioridade do SA em cinco dos sete cenários. Erkeyman et al. [2025] modelaram a chegada de demanda como cadeia de Markov e otimizaram parâmetros de reposição com GA e PSO (*Particle Swarm Optimization*), mostrando que o PSO converge mais rapidamente em espaços de baixa dimensão. Ambos os estudos, porém, restringem-se a um único escalão e não incorporam agentes de RL.

Uma segunda frente aplica aprendizado por reforço ao controle de inventário. Oroojlooyjadid et al. [2022] demonstraram, no *Beer Game multi-echelon*, que DQN (*Deep Q-Network*) aprende políticas de reposição sem modelar a distribuição de demanda. Gijsbrechts et al. [2022] e Vanvuchelen et al. [2020] confirmaram que o RL profundo pode igualar, mas não domina universalmente, as melhores heurísticas. Liu et al. [2024] estenderam o paradigma ao ambiente descentralizado com HAPPO (*Heterogeneous-Agent Proximal Policy Optimization*), reduzindo custo e efeito *bullwhip* simultaneamente. Uma limitação transversal é a exigência de da ordem de 10^6 interações para convergência, tornando esses agentes inadequados para séries históricas curtas.

Zabraoui et al. [2025] constituem a referência mais próxima deste estudo. Sobre o conjunto Walmart M5, os autores propuseram a arquitetura híbrida GA-DQN: o GA otimiza globalmente os parâmetros estáticos de inventário enquanto a DQN refina localmente as decisões a cada ciclo. Essa combinação elevou o nível de serviço de 61% (DQN isolado) para 94%, com redução simultânea do custo total. O presente trabalho parte desse resultado e o estende a um regime de CV entre 2.5 e 5.4, incorporando sete políticas adicionais e cinco indicadores primários.

2.3. Lacunas da Literatura

A revisão acima revela quatro lacunas que este trabalho endereça: (i) ausência de estudos com CV extremo (> 2.5) em dados reais de varejo regional brasileiro; (ii) falta de comparação integrada entre políticas clássicas, meta-heurísticas e RL em ambiente *multi-echelon*; (iii) avaliação restrita de indicadores: efeito *bullwhip* e taxa de ruptura raramente aparecem como critérios primários para todas as políticas; e (iv) ausência de validação de arquiteturas híbridas fora do regime Walmart M5.

A Tabela 1 sintetiza as dimensões em que este estudo avança o estado da arte.

Tabela 1: Comparação de trabalhos relacionados em gestão de inventário. **Negrito:** dimensões em que este trabalho avança o estado da arte. “Dados Reais”: dados proprietários coletados no domínio-alvo (varejo com alta intermitência); Walmart M5, embora real, não representa esse regime (CV típico < 1).

Trabalho	Dados Reais	CV (regime)	Políticas (#)	Multi-nível	Indicadores (#)
Oroojlooyjadid et al. 2022	Não	< 1	3	Sim	2
Vanvuchelen et al. 2020	Não	< 1	4	Não	1
Gijsbrechts et al. 2022	Não	< 1	6	Sim	2
Yuna et al. 2023	Não	> 1.5	2	Não	2
Erkayman et al. 2025	Não	> 1.5	2	Não	1
Liu et al. 2024	Não	< 1	4	Sim	2
Zabraoui et al. 2025	Não	< 1	7	Sim	3
Este trabalho	Sim	2.5–5.4	12	Sim	5

3. Formulação do Problema

3.1. Definição Formal do Problema MEIO

O problema *Multi Echelon Inventory Optimization* (MEIO) considera uma cadeia de suprimentos real com $N = 15$ lojas varejistas abastecidas por um único armazém regional. O horizonte é discretizado em ciclos bimestrais $t \in \{1, \dots, T\}$, com $T = 38$. As variáveis e parâmetros centrais são:

- $D_{t,i} \geq 0$: demanda observada na loja i no ciclo t ;
- $I_{t,i}$: nível de estoque da loja i no início de t ;
- $Q_{t,i} \geq 0$: quantidade pedida em t , recebida após prazo $L = 2$ ciclos;
- $S_{t,i} = \max(0, D_{t,i} - I_{t,i})$: ruptura no ciclo t ;
- s_i : ponto de reposição, acionado quando $I_{t,i} \leq s_i$;
- $h, c_s, c_o^{fix}, c_o^{var}$: custos unitários de manutenção, ruptura, ordenação fixa e variável.

Uma política π mapeia o estado observado $(I_{t,i}, D_{t-1,i}, Q_{t-L,i})$ em uma decisão de pedido $Q_{t,i} = \pi(\cdot)$. O objetivo é determinar π^* que minimize o custo total acumulado:

$$\min_{\pi} \sum_{t=1}^T [h I_{t,i} + c_s S_{t,i} + c_o^{fix} \mathbf{1}(Q_{t,i} > 0) + c_o^{var} Q_{t,i}], \quad (1)$$

sujeito a:

$$I_{t+1,i} = \max(0, I_{t,i} - D_{t,i}) + Q_{t-L,i}, \quad \forall t, \forall i, \quad (2)$$

$$\sum_{i=1}^N Q_{t,i} \leq W_t, \quad \forall t, \quad (3)$$

$$I_{1,i} = I_0, \quad \forall i, \quad (4)$$

$$Q_{t,i} \geq 0, \quad \forall t, \forall i. \quad (5)$$

A restrição (2) governa a dinâmica de estoque: pedidos emitidos no ciclo t chegam após prazo fixo $L = 2$ ciclos. A restrição (3) limita o total pedido pelas N lojas à disponibilidade W_t do armazém no ciclo t ; neste estudo, assume-se disponibilidade irrestrita ($W_t \rightarrow \infty$), simplificação representativa de redes em que o armazém não é o gargalo operacional. A condição (4) fixa o estoque inicial, escalonado por loja conforme a Seção 6.2. A restrição (5) impede pedidos negativos; o estoque $I_{t,i}$ é naturalmente não-negativo pela dinâmica $\max(0, \cdot)$ em (2).

O regime de demanda é quantificado pelo coeficiente de variação $CV = \hat{\sigma}_D / \hat{\mu}_D$, onde $\hat{\sigma}_D$ é o desvio padrão e $\hat{\mu}_D$ é a média da demanda. Valores acima de 0.5 indicam demanda errática e acima de 1.5, demanda extremamente intermitente [Syntetos e Boylan, 2001]. Todos os 15 cenários deste estudo possuem CV entre 2.5 e 5.4, regime em que as hipóteses clássicas apresentam limitações severas.

3.2. Arquitetura Multi-Echelon

A cadeia de suprimentos modela um sistema de inventário multi-nível com três escalões hierárquicos, estrutura referenciada na literatura como MEIO [Axsäter, 2006; Clark e Scarf, 1960]:

- Escalão 1 (Armazém Regional): único centro distribuidor da Paraíba; repõe junto ao fornecedor com prazo $L = 2$ ciclos.
- Escalão 2 (Lojas Revendedoras): 15 unidades varejistas com séries de demanda independentes; cada loja decide individualmente quando e quanto pedir ao armazém.
- Escalão 3 (Produto/SKU): produto 48130, único SKU estudado; foco em um item isola o comportamento intermitente de efeitos de portfólio e torna os 38 ciclos suficientes para calibração e avaliação.

As decisões de reposição são tomadas de forma descentralizada: cada política π_i observa o estado local ($I_{t,i}, D_{t-1,i}, Q_{t-L,i}$) e emite o pedido $Q_{t,i}$ sem coordenação explícita com as demais lojas. Essa arquitetura é representativa da realidade operacional da maioria das redes de varejo regional brasileiras, onde sistemas integrados de planejamento multi-loja raramente estão disponíveis.

3.3. Métricas de Avaliação

Cinco indicadores são computados ao fim dos 38 ciclos para cada combinação (política, loja):

- CTI (Custo Total de Inventário): $\sum_t [hI_t + c_s S_t + c_o^{fix} \mathbf{1}(Q_t > 0) + c_o^{var} Q_t]$;
- NS (Nível de Serviço): $\sum_t \min(I_t, D_t) / \sum_t D_t$;



- *TR* (Taxa de Ruptura): fração de ciclos com *stockout*;
- *BE* (*Bullwhip Effect*): $\text{Var}(Q_1, \dots, Q_T) / \text{Var}(D_1, \dots, D_T)$, razão entre a variância dos pedidos e a variância da demanda, mede a amplificação da variabilidade ao longo da cadeia;
- *FP* (Frequência de Pedidos): fração de ciclos com ao menos um pedido emitido.

4. Base de Dados e Pré-Processamento

Esta seção descreve o contexto e a escala do conjunto de dados original, os critérios de seleção de lojas e produto, o *pipeline* de pré-processamento e a caracterização estatística da demanda das quinze unidades experimentais.

4.1. Contexto dos Dados

Os dados provêm de um sistema transacional de gestão de vendas de uma rede de varejo do Nordeste brasileiro. O conjunto completo contém aproximadamente 48 milhões de registros de transações de venda, distribuídos entre cerca de 12 mil produtos únicos (SKUs) e mais de 3 milhões de entidades de demanda em múltiplos estados. Para viabilizar o estudo experimental com rigor metodológico, adotou-se um recorte com três critérios: (i) restrição geográfica ao estado da Paraíba (PB); (ii) restrição de produto a um único SKU de comportamento intermitente representativo; e (iii) restrição temporal ao período disponível com séries suficientemente longas.

4.2. Estrutura Temporal e Ciclos de Venda

O sistema registra vendas por *ciclo bimestral* (17 ciclos por ano, ≈ 21 dias corridos cada), granularidade que reflete a política de consolidação de pedidos ao armazém e justifica o prazo $L = 2$ ciclos (≈ 42 dias). O horizonte experimental compreende janeiro de 2023 a abril de 2025 ($T = 38$ ciclos), período suficiente para capturar sazonalidade anual e padrões de intermitência.

4.3. Seleção do SKU e das Lojas

O produto 48130 foi selecionado a partir do conjunto completo de 12 mil SKUs com base em dois critérios: (i) maior cobertura de lojas com demanda ativa (ao menos 17 ciclos de demanda positiva no horizonte estudado); e (ii) regime de demanda extremamente intermitente ($CV > 1.5$ em todas as lojas ativas). O produto 48130 atende simultaneamente aos dois critérios, com 33 lojas ativas na Paraíba, sendo representativo de artigos sazonais de baixo giro com padrão errático de consumo.

4.4. Pipeline de Pré-Processamento

O pré-processamento seguiu cinco etapas sequenciais: (i) extração e filtragem geográfica (estado = PB, produto = 48130); (ii) limpeza de anomalias (remoção de transações com quantidade negativa ou superior a 50.000 unidades); (iii) agregação por ciclo (soma de quantidades vendidas por loja e ciclo); (iv) reconstituição de séries completas (vetor de comprimento $T = 38$ com imputação de zero nos ciclos sem registro); (v) seleção das quinze lojas com ao menos 17 ciclos com demanda positiva (45% do horizonte), limiar necessário para calibração estatística das políticas.

4.5. Caracterização Estatística da Demanda por Loja

A Tabela 2 apresenta o perfil das quinze lojas. A heterogeneidade é expressiva: a demanda média varia de 11.7 (Loja 15) a 1455.2 unidades por ciclo (Loja 1), razão de 124 vezes. Nenhuma loja apresenta CV inferior a 2.5, situando todos os cenários bem acima do limiar de demanda extremamente intermitente ($CV > 1.5$) de Syntetos e Boylan [2001] e invalidando as hipóteses de normalidade subjacentes a EOQ e (s, S) .

Esse gradiente motivou a estratificação em três grupos e a calibração adaptativa descrita na Seção 6:

- Grupo I (5 lojas, $\hat{\mu} > 500$ unid./ciclo): alto volume com picos esparsos (CV entre 2.83 e 5.39); estoque inicial adequado garante $NS = 1.00$ para quase todas as políticas, tornando o custo o principal diferenciador.
- Grupo II (6 lojas, $50 < \hat{\mu} \leq 500$): estrato de maior relevância prática, com variabilidade entre 2.83 e 4.51 e volume suficiente para que as políticas se diferenciem em todas as cinco métricas.
- Grupo III (4 lojas, $\hat{\mu} \leq 50$): baixíssimo volume; o CV próximo de 3 cria uma barreira estrutural em que qualquer pedido compatível com a média pode exceder a demanda real de vários ciclos futuros.

Tabela 2: Perfil de demanda das quinze lojas selecionadas, produto 48130, Paraíba, 2023–2025. Lojas ordenadas por $\hat{\mu}^+$ decrescente. $\hat{\mu}^+$: média apenas nos ciclos com demanda positiva; critérios de grupo baseados na média incondicional $\hat{\mu}$ (sobre todos os 38 ciclos): I ($\hat{\mu} > 500$), II (50–500), III (≤ 50).

Loja	$\hat{\mu}^+$ (unid./ciclo)	Desv. Pad.	CV	Ciclos Positivos	Grupo
1	1.455,2	5.037,5	5,14	18	I
2	1.375,7	4.464,6	4,35	22	I
3	703,6	2.561,1	5,39	18	I
4	553,4	1.380,2	3,67	19	I
5	518,2	1.150,1	2,83	25	I
6	300,9	590,3	2,95	19	II
7	246,0	546,4	3,04	22	II
8	181,6	393,0	2,90	23	II
9	169,7	489,5	3,79	23	II
10	88,3	274,8	4,51	19	II
11	85,4	253,3	4,31	19	II
12	44,8	85,9	2,53	24	III
13	43,1	88,4	2,83	22	III
14	34,7	97,1	3,97	20	III
15	11,7	25,5	3,24	19	III

5. Políticas de Controle de Inventário

Esta seção apresenta as doze políticas organizadas em quatro categorias de crescente sofisticação computacional.

5.1. Políticas Clássicas

As três políticas clássicas fundamentam-se em hipóteses de estacionariedade da demanda [Silver et al., 2017]: o EOQ minimiza os custos de ordenação e manutenção sob demanda constante [Harris, 1913]; a (s, S) emite pedido $S - I_t$ ao cruzar o ponto de reposição s [Hadley e Whitin, 1963]; e o Jornaleiro determina o pedido ótimo de período único como um quantil da distribuição de demanda [Cachon e Terwiesch, 2009]. Todas apresentam limitações em regime intermitente [Silver et al., 2017].

EOQ. $Q^* = \sqrt{2Dc_o^{fix}/h}$, com ponto de reposição $s = \hat{\mu}L$ [Harris, 1913].

(s, S) . Pedido de magnitude $S - I_t$ sempre que $I_t \leq s$, com $s = s_{EOQ}$ e $S = s + Q_{EOQ}$ [Hadley e Whitin, 1963].

Jornaleiro. $Q^* = \hat{\mu} + z\hat{\sigma}$, $z = 1.28$ (nível de serviço alvo de 90%) [Cachon e Terwiesch, 2009].

5.2. Meta-Heurísticas de Otimização

As quatro meta-heurísticas buscam (s^*, Q^*) minimizando a Equação (1) por busca global no espaço de parâmetros: GA [Holland, 1975] por seleção, cruzamento e mutação; SA [Kirkpatrick et al., 1983] por aceitação probabilística de soluções piores com temperatura decrescente ($\exp(-\Delta C/T_k)$); PSO [Kennedy e Eberhart, 1995] por combinação de experiências individual e coletiva de um enxame; e ED [Storn e Price, 1997] por perturbação diferencial na estratégia $rand/1/bin$.

5.3. Agentes de Aprendizado por Reforço

Os agentes de RL aprendem a política diretamente da interação com o ambiente, sem especificação explícita de (s, Q) . O vetor de estado compartilhado contém seis componentes normalizados: nível de estoque atual, demanda esperada, pedidos em trânsito, média móvel e desvio padrão dos últimos seis ciclos, e progresso do horizonte. A ação é $Q_{t,i}$ e a recompensa é o negativo do custo incorrido.

A DQN [Mnih et al., 2015] utiliza *experience replay* e *target network* para estabilizar o *Q-learning*; sua limitação central é a exigência de da ordem de 10^6 interações para convergência [Orojlooyjadid et al., 2022], inadequada para os 38 ciclos deste estudo. O PPO [Schulman et al., 2017] treina política estocástica com *clipping* da razão de probabilidades em $[1 - \epsilon_{clip}, 1 + \epsilon_{clip}]$, garantindo atualizações estáveis em ações contínuas, mas sensível ao ponto de partida. O SARSA [Sutton e Barto, 2018] é *on-policy* tabular, conservador em ambientes ruidosos, porém limitado em expressividade e sujeito a convergência degenerada em horizontes curtos.

5.4. Arquiteturas Híbridas

Arquiteturas híbridas combinam a busca global das meta-heurísticas com a adaptação local dos agentes de RL. Zabraoui et al. [2025] formalizaram esse princípio na arquitetura GA-DQN, que este trabalho replica e estende com a variante GA-PPO em regime de CV entre 2.5 e 5.4, não coberto por Zabraoui et al. [2025].

O *pipeline* opera em três fases: (i) o GA executa 50 gerações e identifica parâmetros de alta qualidade; (ii) as melhores soluções pré-populam um *replay buffer* com 1.000 transições representativas; (iii) o agente de RL (DQN ou PPO) treina por 200 episódios a partir desse ponto qualificado, evitando exploração do zero em horizontes curtos.

Tabela 3: Hiperparâmetros das doze políticas de controle de inventário.

Política	Categoria	Hiperparâmetros Principais
EOQ	Clássica	$Q^* = \sqrt{2Dc_o^{fix}/h}$; $s = \hat{\mu}L$
(s, S)	Clássica	$s = s_{EOQ}$; $S = s + Q_{EOQ}$
Jornaleiro	Clássica	$Q^* = \hat{\mu} + 1.28\hat{\sigma}$; SL alvo = 90%
GA	Metaheurística	Pop. = 100; Ger. = 50; $p_c = 0.7$; torneio $k = 3$; mut. gaussiana
SA	Metaheurística	$T_0 = 1000$; $\alpha = 0.95$; aceitação: $\exp(-\Delta C/T_k)$
PSO	Metaheurística	$N = 40$ part.; 80 iter.; $w = 0.7$; $c_1 = c_2 = 1.5$
ED	Metaheurística	$rand/1/bin$; $F = 0.8$; $C_R = 0.9$
DQN	Reforço	2 camadas $\times$ 64 ReLU; 500 ep.; ϵ -greedy decrescente; <i>replay</i> 10.000
PPO	Reforço	500 ep.; $\epsilon_{clip} = 0.2$; ações contínuas
SARSA	Reforço	Tabela-Q 5×10 ; $\alpha = 0.1$; $\gamma = 0.99$; $\epsilon = 0.1$
GA-DQN	Híbrida	GA (50 ger.) $\rightarrow$ <i>buffer</i> 1.000 trans. $\rightarrow$ DQN 200 ep.
GA-PPO	Híbrida	GA (50 ger.) $\rightarrow$ <i>buffer</i> 1.000 trans. $\rightarrow$ PPO 200 ep.

5.5. Hiperparâmetros

A Tabela 3 consolida os hiperparâmetros de todas as abordagens, facilitando reprodutibilidade.

6. Ambiente Experimental

Esta seção descreve o ambiente de simulação, a estratégia de calibração adaptativa que garante comparação justa entre lojas de volumes muito distintos e o protocolo de comparação adotado.

6.1. Ambiente de Simulação

O ambiente *InventoryEnv*, implementado em Python 3.11, simula um sistema de inventário (s, Q) com prazo de entrega fixo $L = 2$ ciclos. As bibliotecas utilizadas são NumPy, Pandas e Stable-Baselines3 com *backend* PyTorch para os agentes de RL. Todas as simulações utilizam semente aleatória fixa ($seed = 42$) para garantir reprodutibilidade. A série de demanda real de cada loja é mantida idêntica para todas as políticas, de modo que as diferenças de desempenho reflitam exclusivamente as características de cada política.

6.2. Calibração Adaptativa de Parâmetros por Loja

A heterogeneidade entre as lojas (11.7 a 1455 unid./ciclo) inviabiliza o uso de parâmetros absolutos uniformes. Os parâmetros de referência são escalonados pelas estatísticas $\hat{\mu}$ e $\hat{\sigma}$ de cada

loja:

$$I_0 = \max(100, 2\hat{\mu}L), \quad (6)$$

$$Q_{\text{ref}} = \sqrt{2\hat{\mu}T c_o^{fix}/h}, \quad (7)$$

$$s_{\text{ref}} = \hat{\mu}L + z\hat{\sigma}\sqrt{L}, \quad (8)$$

com $z = 1.28$ (nível de serviço alvo de 90%). Os espaços de busca das meta-heurísticas e os limites de ação dos agentes de RL são dimensionados proporcionalmente a Q_{ref} e s_{ref} .

6.3. Configuração de Custos e Protocolo de Comparação

Os parâmetros de custo são uniformes para todas as lojas e políticas: $h = 1.0$, $c_s = 5.0$, $c_o^{fix} = 50.0$ e $c_o^{var} = 0.5$. Todas as políticas são avaliadas sobre a mesma série de demanda real, no mesmo horizonte fixo de $T = 38$ ciclos, com calibração individualizada por loja conforme descrito acima. Os cinco indicadores definidos na Seção 3.3 são computados ao fim de cada simulação para cada combinação (política, loja).

7. Resultados e Discussão

Esta seção apresenta a comparação global das doze políticas, a análise estratificada por grupo de demanda, o comportamento do efeito *bullwhip*, uma discussão dos mecanismos subjacentes e a comparação direta com Zabraoui et al. [2025].

7.1. Comparação Global entre Políticas

A Tabela 4 apresenta as médias dos cinco indicadores sobre as quinze lojas, ordenadas por CTI crescente. Os melhores valores em cada coluna estão destacados em negrito.

Tabela 4: Médias dos indicadores de desempenho por política (15 lojas). Melhores valores por coluna em **negrito**. [†]SARSA e PPO apresentam degeneração ($FP = 0$ e $FP = 0.98$, respectivamente); resultados degenerados não constituem soluções operacionalmente viáveis.

Política	CTI (R\$)	NS	TR	BE	FP
SARSA [†]	16.139	0,785	0,200	0,00	0,00
Jornaleiro (<i>Newsvendor</i>)	16.402	0,794	0,111	0,003	0,27
Rede Q Profunda (DQN)	17.974	0,806	0,078	4,1	0,37
GA-DQN (Híbrido)	18.502	0,821	0,050	5,0	0,31
Enxame de Partículas (PSO)	19.100	0,819	0,056	6,2	0,31
GA-PPO (Híbrido)	19.801	0,833	0,050	6,6	0,35
Algoritmo Genético (GA)	20.015	0,825	0,061	19,7	0,30
Evolução Diferencial (ED)	20.252	0,813	0,056	31,0	0,27
<i>Sim. Annealing</i> (SA)	20.967	0,820	0,056	36,4	0,27
Lote Econômico (EOQ)	31.034	0,840	0,050	23,0	0,20
Política PPO [†]	34.637	0,848	0,039	15,9	0,98
Política (s, S)	35.589	0,843	0,050	119,4	0,15

Os dois extremos revelam os riscos da otimização por única métrica: o SARSA[†] converge à estratégia de não emitir pedidos ($FP = 0$), obtendo o menor CTI ao preço da maior taxa de ruptura



(0.200); o PPO[†] emite pedidos em 98% dos ciclos, atingindo o maior NS mas incorrendo em CTI inviável de R\$ 34.637. Entre as políticas práticas (sem degeneração), o GA-DQN apresentou o equilíbrio mais favorável entre as políticas práticas, com CTI apenas 13% acima do Jornaleiro e TR 55% menor. A política (s, S) , frequentemente utilizada no varejo regional, tem CTI 92% superior ao GA-DQN e efeito *bullwhip* de 119 vezes, indicando limitações consistentes nesse regime de demanda.

Ressalva-se que os resultados acima comparam médias sobre as quinze lojas sem testes de significância estatística formal. A ausência de réplicas independentes impede a aplicação de testes como o Wilcoxon *signed-rank* ou Friedman com *post-hoc* de Nemenyi; diferenças pequenas entre políticas próximas (como GA-DQN, GA-PPO e PSO) devem ser interpretadas com cautela. Essa limitação é discutida na Seção 8.3.

7.2. Análise Estratificada por Grupo de Demanda

A estratificação por grupo evidencia que não existe política universalmente dominante, resultado de maior relevância prática para gestores de *supply chain*.

Grupo I ($\hat{\mu} > 500$, cinco lojas): estoque inicial adequado garante NS = 1.00 para quase todas as políticas; o diferenciador é o custo. O EOQ gasta em média R\$ 85.956 por loja contra R\$ 45.739 das políticas de menor frequência de pedidos, redução de 47% apenas pela troca de heurística.

Grupo II ($50 < \hat{\mu} \leq 500$, seis lojas): estrato mais discriminante e de maior relevância prática. O GA-DQN destaca-se com NS = 0.933 e CTI = R\$ 10.854, a melhor combinação custo-serviço do estudo, atribuível ao *replay buffer* de alta qualidade gerado pelo GA [Oroojlooyjadid et al., 2022].

Grupo III ($\hat{\mu} \leq 50$, quatro lojas): três lojas não superam NS de 0.42 com nenhuma política. O CV próximo de 3 cria uma barreira estrutural em que pedidos compatíveis com a média não cobrem picos e pedidos elevados aumentam o custo sem ganho de serviço. Nesse estrato, o Jornaleiro é a política mais econômica.

7.3. Estabilidade Logística e Efeito Bullwhip

O efeito *bullwhip* [Lee et al., 1997] mede quanto a variabilidade dos pedidos supera a da demanda; valores elevados implicam oscilações desnecessárias e custos logísticos crescentes a montante. Os resultados revelam amplitude expressiva: excluindo o SARSA (degenerado, BE = 0), as políticas práticas variam de 0.003 (Jornaleiro) a 119.4 em (s, S) , razão superior a 40.000 vezes. Entre as políticas práticas, DQN (4.1) e GA-DQN (5.0) apresentam menor amplificação por aprenderem a antecipar picos de demanda; PSO (6.2) é a melhor meta-heurística nessa dimensão, enquanto SA (36.4) e ED (31.0) ficam elevados por otimizarem (s, Q) pela média histórica. Este indicador, avaliado aqui como critério primário para todas as doze políticas, permite analisar o impacto de cada abordagem sobre a estabilidade de toda a cadeia, dimensão crítica para distribuidores e operadores logísticos.

A Figura 1 sintetiza as três métricas primárias.

7.4. Discussão: Mecanismos e Comportamentos Observados

Os resultados permitem identificar quatro padrões explicativos.

Por que o GA-DQN supera o DQN isolado. O GA pré-popula o *replay buffer* com 5.000 avaliações simuladas (100×50 gerações), reduzindo a dependência de exploração em horizonte de




Figura 1: Desempenho comparativo das doze políticas segundo CTI médio, NS médio e BE médio (barras ordenadas do melhor para o pior em cada indicador).

apenas 570 transições reais (15×38) e contornando o requisito de da ordem de 10^6 passos do DQN [Mnih et al., 2015].

Por que o PPO converge para política de alta frequência de pedidos. Sem inicialização, o gradiente da política estocástica converge para maximizar NS imediato, ignorando o custo de manutenção (FP = 0.98, CTI = R\$ 34.637). O *buffer* pré-populado pelo GA força o agente a partir de uma região de equilíbrio custo-serviço, evitando essa degeneração no GA-PPO.

Por que o SARSA apresenta convergência inadequada. O SARSA tabular com espaço de estados 5×10 tem expressividade insuficiente para o regime intermitente: com demanda nula na maior parte dos ciclos, a política *on-policy* tende a aprender que não emitir pedido é a ação de menor custo imediato, convergindo para FP = 0 e TR = 0.200.

Meta-heurísticas versus RL em horizonte curto. Meta-heurísticas otimizam diretamente (s, Q) pela simulação do horizonte completo, integrando toda a informação disponível de uma vez; agentes de RL aprendem passo a passo, exigindo muito mais episódios para o mesmo padrão. Em $T = 38$, a otimização global é estruturalmente mais adequada, justificando o papel do GA como inicializador nas arquiteturas híbridas.

Custo computacional relativo. Políticas clássicas são analíticas (tempo constante); meta-heurísticas requerem segundos a minutos por loja, mas produzem parâmetros calculados uma única vez; agentes de RL exigem centenas de episódios de treinamento. Arquiteturas híbridas somam ambos os custos, porém o treinamento é realizado uma única vez por loja, tornando-as viáveis como rotina periódica em sistemas ERP.

7.5. Comparação com a Literatura

Considerando os cinco indicadores conjuntamente, o GA-DQN apresentou o equilíbrio mais favorável entre as políticas avaliadas: CTI de R\$ 18.502 (apenas 13% acima do Jornaleiro, que tem TR mais que o dobro), NS de 0.821 equiparável ao das meta-heurísticas isoladas (0.813–0.825) com CTI menor, BE de 5.0 e TR de 0.050 equivalente à (s, S) porém com custo 92% menor.

Esses resultados confirmam, em contexto de CV entre 2.5 e 5.4, a vantagem do GA-DQN reportada por Zabraoui et al. [2025] para o Walmart M5 (CV típico < 1), sugerindo que a arquitetura apresenta desempenho consistente entre regimes de demanda e ampliando seu escopo de aplicação.

8. Conclusão

8.1. Principais Resultados

A comparação sistemática de doze políticas em dados operacionais proprietários de varejo regional brasileiro com CV entre 2.5 e 5.4 sugere que a arquitetura híbrida GA-DQN apresentou o

equilíbrio mais favorável entre custo total, nível de serviço e estabilidade logística entre as políticas avaliadas. A hipótese central, de que arquiteturas híbridas GA-RL apresentam equilíbrio mais favorável do que políticas clássicas e agentes de RL isolados, é apoiada pelos resultados observados. A política (s, S) , frequentemente utilizada no varejo regional brasileiro, apresentou desempenho consistentemente inferior: superada em custo e estabilidade por todas as alternativas práticas avaliadas, com efeito *bullwhip* aproximadamente 24 vezes maior que o GA-DQN e CTI 92% superior.

8.2. Implicações Práticas

Com base na análise estratificada, três recomendações emergem diretamente dos resultados:

- Adotar GA-DQN como política padrão para o Grupo II (lojas de volume médio): $NS = 0.933$ e $CTI = R\$ 10.854$ justificam o custo computacional adicional frente às heurísticas clássicas. O treinamento é realizado uma única vez por loja e produto.
- Considerar a substituição da política (s, S) : consistentemente superada em custo e estabilidade logística pelas demais alternativas práticas em todos os estratos avaliados nesse regime de demanda. A migração direta para o Jornaleiro, sem custo computacional adicional, já contribui para reduzir o problema de amplificação da cadeia.
- Utilizar o Jornaleiro no Grupo III (baixo volume): sua simplicidade e baixo CTI superam abordagens sofisticadas nesse estrato, onde a barreira estrutural de NS limita qualquer política independentemente de sua complexidade.

Para *redes de varejo regional*, a adoção do GA-DQN pode representar redução da ordem de 48% no CTI frente à (s, S) (diferença de R\$ 17.087 por loja por período, sujeita às premissas do estudo), sem perda de nível de serviço. Para *distribuidores e operadores logísticos*, a redução do efeito *bullwhip* de 119 para 5 estabiliza a cadeia a montante, diminuindo custos de transporte e armazenagem. Para *pequenas e médias empresas* sem equipe de *data science*, a arquitetura requer apenas histórico de vendas disponível em qualquer sistema ERP e pode ser operacionalizada como rotina periódica automatizada. Do ponto de vista científico, o estudo oferece uma base de comparação reproduzível em regime de alta intermitência, replicável para qualquer produto com $CV > 1.5$.

8.3. Limitações

O estudo apresenta quatro limitações que devem ser consideradas na interpretação dos resultados. Primeiro, adota simulação determinística com série de demanda estática e sem réplicas independentes, o que pode subestimar a variância dos estimadores de desempenho. Segundo, restringe-se a um único SKU (produto 48130) em uma única região (Paraíba), limitando a generalização direta para outros produtos ou mercados. Terceiro, não considera restrições de capacidade de armazenagem nem prazo de entrega estocástico, presentes em ambientes reais de maior complexidade. Quarto, a comparação entre políticas baseia-se em médias sem testes de significância estatística formal; a ausência de réplicas independentes impede a aplicação de procedimentos como o Wilcoxon *signed-rank* ou o Friedman com *post-hoc* de Nemenyi, de modo que diferenças pequenas entre políticas próximas (particularmente GA-DQN, GA-PPO e PSO) podem não ser estatisticamente significativas. Quinto, os resultados representam desempenho *in-sample*: a mesma série



histórica é utilizada para calibração e avaliação das políticas, o que pode favorecer abordagens com maior capacidade de ajuste aos dados observados; validação *out-of-sample* com janela deslizante é necessária para confirmar a generalização.

8.4. Trabalhos Futuros

Como direções futuras, propõe-se: avaliação *out-of-sample* com janela deslizante para validar a generalização; extensão a múltiplos produtos com restrições de capacidade de armazenagem; incorporação de prazo de entrega estocástico; integração com modelos de previsão de demanda (Croston, *Long Short-Term Memory* (LSTM)) para alimentar as decisões com estimativas prospectivas; e exploração de arquiteturas de RL multiagente para coordenação explícita entre lojas.

Referências

- Axsäter, S. (2006). *Inventory Control*. Springer, New York, 2 edition.
- Boute, R. N., Gijsbrechts, J., van Jaarsveld, W., e Vanvuchelen, N. (2022). Deep reinforcement learning for inventory control: A roadmap. *European Journal of Operational Research*, 298(2): 401–412.
- Cachon, G. P. e Terwiesch, C. (2009). *Matching Supply with Demand: An Introduction to Operations Management*. McGraw-Hill, New York.
- Clark, A. J. e Scarf, H. (1960). Optimal policies for a multi-echelon inventory problem. *Management Science*, 6(4):475–490.
- Croston, J. D. (1972). Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303.
- Erkayman, B., Yuna, F., e Yilmaz, M. (2025). Markov approach for inventory control with meta-heuristics in intermittent demand environment. *PLOS ONE*.
- Gijsbrechts, J., Boute, R. N., Van Mieghem, J. A., e Zhang, D. J. (2022). Can deep reinforcement learning improve inventory management? Performance on lost sales, dual-sourcing, and multi-echelon problems. *Manufacturing & Service Operations Management*, 24(3):1349–1368.
- Hadley, G. e Whitin, T. M. (1963). *Analysis of Inventory Systems*. Prentice-Hall, Englewood Cliffs, NJ.
- Harris, F. W. (1913). How many parts to make at once. *Factory: The Magazine of Management*, 10 (2):135–136.
- Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press, Ann Arbor, MI.
- Kennedy, J. e Eberhart, R. (1995). Particle swarm optimization. In *Proceedings of the IEEE International Conference on Neural Networks*, p. 1942–1948.
- Kirkpatrick, S., Gelatt, C. D., e Vecchi, M. P. (1983). Optimization by simulated annealing. *Science*, 220(4598):671–680.



- Lee, H. L., Padmanabhan, V., e Whang, S. (1997). Information distortion in a supply chain: The bullwhip effect. *Management Science*, 43(4):546–558.
- Liu, X., Hu, M., Peng, Y., e Yang, Y. (2024). Multi-agent deep reinforcement learning for multi-echelon inventory management. *Production and Operations Management*, 34(7):1836–1856.
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., e Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540):529–533.
- Oroojlooyjadid, A., Nazari, M., Snyder, L. V., e Takáč, M. (2022). A deep Q-network for the beer game: Deep reinforcement learning for inventory optimization. *Manufacturing & Service Operations Management*, 24(2):285–304.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., e Klimov, O. (2017). Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- Shapiro, J. F. (2001). *Modeling the Supply Chain*. Duxbury, Pacific Grove, CA.
- Silver, E. A., Pyke, D. F., e Thomas, D. J. (2017). *Inventory and Production Management in Supply Chains*. CRC Press, Boca Raton, FL, 4 edition.
- Storn, R. e Price, K. (1997). Differential evolution — A simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4):341–359.
- Sutton, R. S. e Barto, A. G. (2018). *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, 2 edition.
- Syntetos, A. A. e Boylan, J. E. (2001). On the bias of intermittent demand estimates. *International Journal of Production Economics*, 71(1–3):457–466.
- Vanvuchelen, N., Gijsbrechts, J., e Boute, R. N. (2020). Use of proximal policy optimization for the joint replenishment problem. *Computers in Industry*, 119:103239.
- Yuna, F., Erkayman, B., e Yılmaz, M. (2023). Inventory control model for intermittent demand: A comparison of metaheuristics. *Soft Computing*, 27:6487–6505.
- Zabraoui, O., Hmamou, Y., Chafi, A., e Alami, S. K. (2025). A comparative study of multi-algorithm optimization for inventory analytics in supply chains. *Supply Chain Analytics*, 12: 100154.