Seleção de políticas de reposição sob restrições de serviço: evidências de uma rede varejista e do benchmark M5

Matheus Inácio Batista Santos[a]

[a]*Instituto de Computação, Universidade Federal de Alagoas, Brasil*

Abstract

Características da demanda podem orientar a escolha de políticas de reposição, mas diferenças entre séries não garantem vantagem de um seletor por perfil. Este estudo reanalisa matrizes históricas de simulação para comparar seleção contextual e seleção global sob uma restrição de atendimento em duas bases: 145 séries loja-produto de uma rede varejista brasileira e 2.408 séries da categoria alimentos do M5. Cada matriz registra doze rótulos de política. A escolha minimiza o custo médio entre alternativas com fill rate médio por série igual ou superior ao limiar, e sua transferência é examinada excluindo todas as séries da loja avaliada. No limiar principal de 0,70, a seleção por perfil aumenta o custo em 0,58% na base brasileira e reduz em 0,68% no M5; os intervalos condicionais por agrupamento de loja incluem zero em ambos os casos. VendorResponsive é a escolha global na base brasileira; recozimento simulado, no M5. O M5 contém 91,90% de séries sem demanda no prefixo de ajuste, limitando a comparabilidade operacional. Aumentar o serviço exigido altera os vencedores e, no M5, faz os seletores convergirem para PPO. A viabilidade média também esconde séries abaixo do limiar. Os resultados não estabelecem vantagem geral dos perfis examinados sobre a melhor referência global viável do portfólio. Sustentam avaliar custo, serviço e utilidade dos perfis conjuntamente, com limites: seleção retrospectiva, características do histórico completo e seletor supervisionado não validado. A base brasileira constitui o caso central; o M5 amplia a comparação, sem representar reprodução exata de outro estudo ou validação temporal independente.

Keywords: Gestão de estoques, Demanda intermitente, Seleção de políticas, Nível de serviço, Varejo, M5

1. Introdução

Uma rede varejista precisa decidir quando e quanto repor para muitas combinações de loja e produto. Uma regra que funciona para vendas frequentes pode produzir excesso de estoque em séries esparsas; outra, econômica em média, pode não cobrir picos relevantes. O problema não se resume a prever demanda: envolve escolher uma regra de decisão e ajustar seus parâmetros sob custos e exigências de atendimento [1].

Comparações de algoritmos ampliam o conjunto de alternativas disponíveis. Políticas analíticas, heurísticas, busca por parâmetros e aprendizado por reforço oferecem diferentes compromissos entre custo, serviço e esforço computacional. Entretanto, a existência de um portfólio não resolve a escolha operacional. O gestor precisa saber se vale aplicar uma política uniforme ou distinguir grupos de séries, e se a distinção oferece ganho suficiente para justificar maior complexidade.

Essa pergunta pode ser formulada como seleção de algoritmos: características de uma instância ajudam a escolher um método de um conjunto candidato [2, 3]. Em inventário, a instância é uma série loja-produto e o resultado depende da política, do ambiente e do serviço exigido. A proposta Adaptive Inventory Policy Engine (AIPE) organiza essa avaliação em caracterização, comparação e seleção. Seu componente supervisionado, Policy Selection Engine (PSE), é uma extensão ainda não validada neste artigo; a análise presente utiliza regras explícitas de escolha por perfil.

Trabalhos publicados em *Supply Chain Analytics* relacionam previsão e desempenho operacional [4], comparam múltiplos algoritmos de controle [5] e discutem se critérios de classificação preservam informação relevante para a decisão [6]. Essa literatura favorece uma pergunta mais específica que a busca de um controlador universal: os perfis utilizados realmente ajudam a escolher uma política, quando a referência global também é escolhida de forma competitiva?

A pesquisa parte dos experimentos da qualificação de mestrado com dados de uma rede brasileira. O piloto da Paraíba teve 15 lojas e um produto; seu papel foi estabelecer um protocolo inicial. O caso central deste artigo é o conjunto de 145 séries da Bahia. Incorporamos os artefatos históricos do M5 como comparação adicional, preservando diferenças de recorte, horizonte, informação inicial e orçamento de busca. Bahia e M5 constituem experimentos separados: cada série tem seu próprio ambiente de reposição, e a seleção ocorre dentro de cada base. Os custos são analisados dentro de cada base, e

o conjunto público complementa a evidência do caso brasileiro.

São investigadas três questões: (i) selecionar por perfil reduz custo em relação à melhor política global viável? (ii) a diferença persiste quando a loja avaliada não participa da escolha? (iii) como a exigência de serviço altera o resultado e a frequência de violações locais? O artigo contribui com uma comparação rastreável entre estratégias, inclusive quando a seleção contextual não apresenta ganho. A heterogeneidade dos vencedores é tratada como motivação, não como demonstração automática de utilidade do seletor.

2. Trabalhos relacionados e posicionamento

A classificação da demanda organiza diferenças de frequência e tamanho das ocorrências. A taxonomia ADI–CV^2 é uma referência para distinguir demanda suave, errática, intermitente e *lumpy* [7]. Uma classe estatística, porém, não identifica sozinha a melhor política: custo de falta, prazo, estado inicial e requisito de atendimento também influenciam a decisão.

Tadayonrad e Ndiaye [4] aproximam a avaliação de previsão dos custos de inventário e do serviço. Pietukhov et al. [8] estudam previsão de indicadores de desempenho em um contexto empírico. A conexão com este trabalho é avaliar consequências operacionais, sem transformar precisão preditiva em substituto de custo e atendimento. O benchmark M5 utilizado aqui não inclui, em seu grafo de execução, a etapa de previsão por redes de memória de longo e curto prazo (LSTM); não atribuímos seus resultados à aprendizagem de previsão.

Zabraoui et al. [5] comparam famílias de algoritmos de inventário e apresentam combinações de algoritmos genéticos (GA) e aprendizado por reforço com dados M5. A arquitetura GA–DQN, que combina GA e uma rede Q profunda (DQN, do inglês deep Q-network), e a ideia de portfólio já estão, portanto, na literatura da revista. Nosso foco não é propor a mesma combinação como novidade, mas avaliar a camada de escolha entre alternativas. As heurísticas inspiradas naquele estudo envolvem decisões de implementação próprias, e custos, filtros e granularidade não constituem uma reprodução exata de seus experimentos.

A análise de critérios de Theunissen et al. [6] destaca a diferença entre importância estatística e utilidade decisória. Não implementamos seu método topológico. Testamos uma consequência próxima: mesmo um perfil interpretável pode ser pouco útil se recomendar praticamente a mesma política global ou se suas mudanças elevarem custo sem benefício de serviço relevante.

Revisões de aprendizado por reforço em inventário discutem a importância do ambiente, da recompensa e da avaliação [9]. Uma baixa taxa de atendimento ou frequência de pedidos extrema não caracteriza, isoladamente, uma família algorítmica. Os resultados abaixo descrevem implementações e matrizes específicas. Corrigir um controlador atual não valida retrospectivamente uma saída armazenada de outra versão.

O M5 documenta uma competição de previsão sobre vendas reais de varejo [10]. Neste artigo, seus dados são agregados e usados em simulação de reposição. Os resultados não são classificações da competição nem uma comparação com seus vencedores. A comparação adicional examina retrospectivamente se o mesmo procedimento de seleção apresenta comportamento semelhante em outro conjunto, mantendo claras as restrições da transformação e do recorte.

3. Dados e ambiente de reposição

Os resultados apresentados nas seções seguintes provêm das matrizes históricas arquivadas, com 145 séries da Bahia e 2.408 do M5. As novas execuções de validação ainda não concluídas não integram essas tabelas ou conclusões.

3.1. Caso central: rede varejista brasileira

A base brasileira é proprietária. Os registros de vendas são agregados por ciclo comercial e preparados em séries loja-produto. A matriz analisada contém 145 séries da Bahia, 115 lojas e nove produtos, com 38 ciclos por série. O primeiro prefixo de referência do código tem 17 ciclos. Todos os rótulos macro de regime no artefato são *lumpy*. O horizonte curto e o recorte de alta irregularidade delimitam a evidência; não há avaliação nacional representativa.

Os perfis armazenados dividem a amostra em 116 séries Sparse High Impact, 18 Unstable Trend e 11 High Volatility Seasonal. Usamos os identificadores do projeto e sua interpretação operacional: longos intervalos sem venda e picos; tendência ou distribuição difusa; e sazonalidade ou concentração temporal. Os dois menores grupos são exploratórios. Seus nomes não constituem categorias comerciais universais nem identificam produtos intercambiáveis.

Vendas realizadas são um indicador imperfeito da demanda quando falta estoque. Além disso, completar ciclos ausentes com zero exige distinguir

ausência de venda e ausência de registro. O estudo não estima demanda censurada a partir de informação indisponível. Os resultados devem ser interpretados como replay das séries preparadas, sob o ambiente configurado.

3.2. Contraste público: M5

A matriz M5 contém 2.408 séries de alimentos, dez lojas e 287 produtos distintos, com 93 ciclos por série. O código agrega vendas diárias em blocos consecutivos de 21 dias, filtra a categoria FOODS e utiliza um limiar de CV de 1,5 calculado por produto sobre lojas e ciclos, e não individualmente por série. A configuração também prevê limitação de valores extremos por cercas de 1,5 vezes o intervalo interquartil. Trata-se de um recorte local inspirado no estudo de Zabraoui et al. [5]. A seção 3.7 daquele estudo descreve alimentos com demanda volátil, mas não publica uma lista de séries nem um limiar numérico de CV que permita certificar uma amostra idêntica. O corte de 1,5 e as 2.408 séries identificam, portanto, a adaptação local, não uma reprodução exata da amostra publicada.

O prefixo de referência da configuração M5 tem 19 ciclos. Nesse prefixo, 2.213 das 2.408 séries (91,90%) não registram demanda, e 2.237 têm menos de três ciclos positivos. Todas registram demanda positiva nos 74 ciclos posteriores. A matriz M5 representa, portanto, predominantemente um cenário sem vendas registradas no prefixo, distinto da base brasileira, onde nenhuma série tem prefixo nulo e todas têm ao menos três ciclos positivos. Os artefatos registram 2.350 séries *lumpy*, 33 erráticas, 24 suaves e uma intermitente. Os perfis são 2.350 Sparse High Impact, 40 Unstable Trend e 18 High Volatility Seasonal. Assim, o M5 é majoritariamente irregular, mas não exclusivamente *lumpy*. A predominância de um perfil, presente também na base brasileira, limita o contraste entre grupos.

A janela final de 93 ciclos inclui um bloco diário parcial. Estatísticas de recorte e suavização obtidas no histórico completo impedem tratar o conjunto como um teste temporal inteiramente independente. O M5 amplia a diversidade de origem, produtos e horizonte, mas permanece um recorte transformado de uma mesma fonte pública. Ter 2.408 séries não equivale a ter 2.408 lojas independentes.

3.3. Portfólio, custos e dinâmica

As duas matrizes possuem os mesmos doze rótulos: EOQ (lote econômico de pedido), (s, S), Newsvendor, CappedBaseStock, BigDataNewsvendor, FixedInterval, VendorResponsive, GA, recozimento simulado (SA, simu-

Tabela 1: Coortes verificadas nas matrizes analisadas. Prefixo indica o corte de ajuste configurado no código, não uma garantia de independência temporal de toda a preparação.

Característica	Rede brasileira (BA)	M5 FOODS
Séries	145	2.408
Lojas	115	10
Produtos	9	287
Ciclos disponíveis	38	93
Prefixo configurado	17	19
Prefixo sem demanda	0	2.213
Menos de 3 ciclos positivos no prefixo	0	2.237
Sparse High Impact	116	2.350
Unstable Trend	18	40
High Volatility Seasonal	11	18
Políticas na matriz	12	12

lated annealing), DQN, Proximal Policy Optimization (PPO) e GA–DQN. As matrizes registram avaliações separadas de cada série. Não há otimização conjunta de capacidade ou coordenação de pedidos entre lojas, embora a variabilidade dos pedidos seja observada como indicador complementar.

Os orçamentos configurados também diferem entre bases: GA utiliza 50 gerações na Bahia e 500 no M5; SA, 500 e 100 iterações; a fase de reforço do híbrido, 200 e 30 episódios, respectivamente. São valores encontrados nas configurações examinadas, sem um manifesto histórico completo que certifique cada execução. Não descrevemos as bases como comparação sob orçamento idêntico.

Os nomes identificam implementações do projeto. EOQ é uma heurística legada com fator de anualização na demanda e custo de manutenção por ciclo; sua quantidade não deve ser confundida automaticamente com um EOQ dimensionalmente normalizado. Newsvendor utiliza uma aproximação baseada em média e dispersão, não uma garantia de quantil ótimo. VendorResponsive é uma regra operacional própria, motivada por prazo e atendimento passado, cuja formulação não é idêntica a uma descrição subespecificada na literatura.

Nos KPIs, a quantidade de ciclos disponível é metadado da série, não a duração certificada do episódio. Os cortes configurados deixam 21 ciclos para avaliação na Bahia e 74 no M5; sem um manifesto histórico completo, essa correspondência deve ser confirmada na reprodução.

No ciclo t, a política decide antes da chegada prevista; o ambiente recebe

pedidos antigos, atende demanda sem acumular faltas para o futuro e cobra o estoque remanescente. A convenção de pipeline com configuração $L = 2$ entrega uma ordem emitida em t em $t + 3$. Essa regra é comum aos candidatos, mas não deve ser descrita como prazo efetivo contínuo de dois ciclos. Estoque inicial e limites de ação podem depender das estatísticas de cenário armazenadas, inclusive do histórico completo.

O custo total da série i sob política π é representado por

$$C_{i\pi} = \sum_{t} \left[h_i I_{it} + p_i U_{it} + k_i \mathbf{1}(Q_{it} > 0) + v_i Q_{it} \right], \tag{1}$$

com estoque remanescente I, falta U, pedido Q e coeficientes de manutenção, falta, emissão e quantidade. Os parâmetros são custos de cenário e não foram estimados neste artigo como preços econômicos comparáveis entre Brasil e Estados Unidos. Horizontes, volumes e escalas diferem. Por isso, custos absolutos só são comparados dentro de cada base.

O fill rate é $F_{i\pi} = \sum_t (D_{it} - U_{it}) / \sum_t D_{it}$, definido quando a demanda acumulada no período avaliado é positiva. Todas as séries das matrizes históricas têm demanda positiva no horizonte posterior ao prefixo configurado. Em janelas sem demanda, esse indicador é indefinido e deve ser reportado separadamente, sem atribuição artificial de atendimento completo. É uma fração de unidades atendidas, distinta da probabilidade de um ciclo sem falta. Outros indicadores são frequência de ciclos com ruptura, frequência de pedidos e razão entre variâncias de pedido e demanda. Essas medidas apoiam interpretação; a seleção principal utiliza custo e fill rate.

4. Seleção e protocolo de comparação

4.1. Referência global e escolha por perfil

Para um conjunto A de séries usadas na escolha, definimos custo e atendimento médios por política:

$$\bar{C}_{\pi,A} = |A|^{-1} \sum_{i \in A} C_{i\pi}, \qquad \bar{F}_{\pi,A} = |A|^{-1} \sum_{i \in A} F_{i\pi}. \tag{2}$$

Cada série recebe o mesmo peso. A média de fill rates não é o atendimento ponderado pelo volume total da rede. Seja Π o portfólio de políticas. A política global é

$$\widehat{\pi}_A = \arg \min_{\pi \in \Pi : \bar{F}_{\pi,A} \geq \alpha} \bar{C}_{\pi,A}. \tag{3}$$

A seleção por perfil aplica a mesma regra separadamente a A_g, o subconjunto associado ao perfil g. Se nenhuma política atende à restrição, escolhe-se maior atendimento médio, com custo como desempate, e registra-se fallback. Esse caso é explicitado: não é uma escolha viável que cumpriu o limiar. Entre candidatas viáveis com mesmo custo, preferimos maior serviço; no fallback empatado em serviço, menor custo. Empates restantes usam ordem alfabética do identificador. Um perfil ausente nas lojas de escolha utiliza a regra global.

A restrição é média e específica do conjunto usado para escolher. Não exige $F_{i\pi} \geq \alpha$ em toda série. Também não garante a média da loja excluída. Além disso, exigir viabilidade em cada perfil é diferente de exigi-la apenas no agregado. Uma política global viável pode ser inviável em um grupo; a escolha por perfil não precisa apresentar menor custo mesmo na avaliação retrospectiva.

O limiar principal é $\alpha = 0{,}70$, herdado da investigação original. Ele não representa recomendação de meta comercial. Avaliamos também 0,80, 0,85, 0,90 e 0,95, sem escolher a conclusão pelo limiar mais favorável. A diferença relativa de custo é

$$R = 100 \frac{\bar{C}_{\text{global}} - \bar{C}_{\text{perfil}}}{\bar{C}_{\text{global}}}. \tag{4}$$

$R > 0$ indica redução; $R < 0$, aumento. Diferenças de atendimento são dadas em pontos percentuais. Custo menor acompanhado por atendimento menor não é chamado de dominância.

4.2. Perfis operacionais e informação disponível

Os perfis são regras heurísticas ordenadas, não clusters aprendidos nem políticas previamente validadas. A prioridade é Sparse High Impact, High Volatility Seasonal, Unstable Trend, Low Volume Stable e Fast Moving. A primeira regra utiliza ADI elevado, CV^2 elevado e sequência longa de zeros; a segunda, autocorrelação sazonal ou concentração de ocorrências; a terceira, tendência ou entropia. Os perfis de baixo volume estável e venda frequente não aparecem nas matrizes de perfil analisadas. Para tornar a regra reproduzível, usamos $a = n/\max(n_+, 1)$, $c^2 = [s/(\mu + 10^{-9})]^2$ e Z, maior sequência de zeros. Aqui, n é o número de ciclos do cenário, n_+ é a quantidade de ciclos com demanda positiva, μ é a média sobre todos os ciclos e s é o desvio-padrão amostral, incluindo zeros. Essa variância difere da calculada apenas sobre os tamanhos positivos da demanda na taxonomia original. A Tabela 2 apresenta os cortes, aplicados na ordem indicada; uma série sem correspondência recebe Sparse High Impact.

Tabela 2: Regras operacionais de perfil: primeiro corte satisfeito determina o grupo.

Perfil	Condição
Sparse High Impact	$a \geq 1{,}32$, $c^2 \geq 0{,}49$ e $Z \geq 5$
High Volatility Seasonal	Autocorrelação na defasagem 17 $\geq 0{,}25$ ou burstiness $\geq 0{,}30$
Unstable Trend	Módulo da tendência normalizada $\geq 0{,}05$ ou entropia ≥ 2
Low Volume Stable	$\mu \leq 2$ e $c^2 < 0{,}49$
Fast Moving	$a < 1{,}32$

Burstiness é $(s_\Delta - \mu_\Delta)/(s_\Delta + \mu_\Delta + 10^{-9})$, em que μ_Δ e s_Δ são a média e o desvio-padrão dos intervalos Δ entre ocorrências positivas; recebe zero com menos de dois intervalos. Tendência é a inclinação estimada por mínimos quadrados ordinários (OLS) sobre o índice de ciclo, dividida por $\mu + 10^{-9}$. Entropia é $-\sum_j p_j \log_2(p_j + 10^{-12})$, em que p_j é a frequência relativa na classe j de um histograma com dez intervalos de mesma largura. Autocorrelação é a covariância na defasagem 17 dividida pela variância global; recebe zero se a série tem até 18 ciclos ou variância desprezível. Os rótulos descrevem regras locais, não sazonalidade ou impacto econômico empiricamente validados.

O código calcula essas características sobre as séries de cenário completas. A seleção neste artigo utiliza os perfis armazenados, sem alegar que estavam disponíveis antes de todos os ciclos avaliados. A coluna de política associada heuristicamente ao nome de um perfil não é usada como resultado: a política selecionada é determinada pelos custos e pelo serviço da matriz. Isso evita confundir uma associação escrita no código com evidência empírica de superioridade.

4.3. Transferência entre lojas e incerteza condicional

Calculamos inicialmente seletores retrospectivos na própria matriz. Em seguida, excluímos todas as séries da loja avaliada antes de escolher a política global e as políticas de perfil. As escolhas são pontuadas nas saídas dessa loja já existentes na matriz. Esse procedimento é leave-one-store-out: examina transferência da regra de escolha entre lojas, condicional aos resultados de cada política.

Não é validação temporal independente dos controladores. Excluir a loja do seletor não apaga informação futura usada para construir perfis, calibrar condições iniciais ou gerar saídas. Os termos de avaliação devem refletir

essa distinção: há transferência da escolha sobre uma matriz histórica, não demonstração de aprendizagem prospectiva de um PSE supervisionado.

O protocolo original registra cinco execuções por série e política. Contudo, os desvios-padrão de custo armazenados são efetivamente zero. São repetições de avaliação determinística, não cinco sementes independentes de treinamento. Cada série–política contribui uma observação agregada. A unidade de dependência utilizada para incerteza é a loja.

Os intervalos percentis de 95% usam 5.000 amostras bootstrap pareadas de lojas; cada loja sorteada leva todas as suas séries. Os seletores não são reajustados em cada sorteio. Os intervalos são, portanto, condicionais às matrizes, perfis e escolhas já obtidas. Não incluem incerteza de treinamento ou de nova demanda. No M5 existem apenas dez agrupamentos de loja, o que torna essa aproximação especialmente frágil; produtos compartilhados entre lojas introduzem dependência adicional não eliminada pelo agrupamento.

5. Resultados históricos

5.1. A melhor escolha global depende da base

No limiar de 0,70, VendorResponsive é a política global de menor custo viável na rede brasileira. O custo médio é 433,31 e o fill rate médio 0,7738. No M5, o vencedor é SA, com custo 19.500,54 e atendimento 0,8521. A diferença de vencedor mostra dependência do contexto, mas a diferença de custo absoluto não mede vantagem entre bases.

A restrição altera fortemente o conjunto admissível. No M5, apenas SA e PPO apresentam atendimento médio global acima de 0,70. GA–DQN registra 0,4666 e a heurística EOQ legada, 0,1332. Custos baixos dessas alternativas não constituem resultados competitivos sob o requisito escolhido. Sua insuficiência de atendimento descreve as implementações e o cenário analisados, sem estabelecer que os algoritmos sejam inadequados a todo varejo. O prefixo sem venda em 91,90% das séries é uma condição relevante para interpretar calibração e aprendizagem no M5. Pode estar associado a parâmetros pouco informativos, mas esta análise não isola seu efeito causal nem atribui todo o resultado a ele.

A Tabela 3 apresenta todo o portfólio, evitando restringir a comparação aos vencedores. O denominador do custo relativo é a política global viável de cada base, sem juntar moedas ou horizontes.

PPO apresenta atendimento médio de 0,9853, mas emite pedidos em cerca de 99,31% dos ciclos; SA atende 0,8521 e apresenta frequência média de

Tabela 3: Portfólio histórico completo: custo relativo à melhor global viável em $\alpha = 0{,}70$ e serviço médio. BA: denominador VendorResponsive; M5: denominador SA.

	BA		M5	
Política	Custo relativo	Serviço	Custo relativo	Serviço
BigDataNewsvendor	1,343	0,717	0,322	0,096
CappedBaseStock	1,297	0,642	0,297	0,098
DQN	0,292	0,225	0,318	0,076
EOQ	1,450	0,942	0,320	0,133
FixedInterval	1,057	0,844	0,301	0,100
GA	2,920	0,896	0,381	0,231
GA–DQN	2,714	0,731	0,406	0,467
Newsvendor	0,669	0,540	0,285	0,084
PPO	11,799	0,963	1,139	0,985
SA	2,649	0,865	1,000	0,852
VendorResponsive	1,000	0,774	0,287	0,100
(s, S)	1,511	0,943	0,321	0,134

pedidos de 8,02%. Seus custos e variabilidades também diferem. Assim, um ranking por custo bruto ou apenas por atendimento omitiria parte relevante da decisão operacional.

5.2. O ganho incremental de selecionar por perfil é pequeno

A Tabela 4 compara seletores com a loja avaliada excluída. Na rede brasileira, a seleção por perfil aumenta o custo médio de 433,31 para 435,80: redução relativa de $-0{,}576\%$, com intervalo $[-1{,}442; 0{,}153]\%$. O atendimento cresce de 0,7738 para 0,7816, ou 0,779 ponto percentual. São diferenças pequenas, e o intervalo de custo inclui zero.

Tabela 4: Seleção com exclusão da loja avaliada, em $\alpha = 0{,}70$. A coluna abaixo do limiar conta séries individualmente, não médias de perfil. Custos não são comparáveis entre bases.

Base	Estratégia	Custo médio	Fill rate	Abaixo do limiar
Brasileira	Global	433,31	0,7738	40
Brasileira	Perfil	435,80	0,7816	39
M5	Global	19.500,54	0,8521	270
M5	Perfil	19.367,73	0,8509	274

No caso brasileiro, a regra por perfil escolhe VendorResponsive para 130 séries e FixedInterval para 15. Na própria amostra, havia redução de apenas 0,195% de custo; essa vantagem não persiste ao retirar a loja. Encontrar um ajuste retrospectivo favorável, portanto, não basta para justificar maior complexidade de recomendação.

No M5, o custo por perfil cai de 19.500,54 para 19.367,73, redução de 0,681%, com intervalo $[-1{,}190; 2{,}402]$%. O atendimento diminui 0,122 ponto percentual. O seletor mantém SA nas 2.350 séries Sparse High Impact e distribui as outras 58 entre VendorResponsive, GA–DQN, EOQ, FixedInterval e CappedBaseStock. A política global já cobre o perfil de 97,59% das séries; a camada contextual muda uma parcela pequena das decisões.

Os intervalos condicionais das duas comparações principais incluem zero e não sustentam uma redução de custo positiva nesse critério. Isso não prova equivalência entre estratégias, nem elimina a possibilidade de ganhos em outros contextos. Mostra que estes perfis e estas matrizes não sustentam uma vantagem geral de custo sobre a melhor referência global viável do portfólio.

5.3. Serviço médio esconde falhas individuais

Em 0,70, a estratégia por perfil deixa 39 das 145 séries brasileiras e 274 das 2.408 séries M5 abaixo do limiar. São aproximadamente 26,9% e 11,4% das respectivas amostras. Os seletores cumprem sua regra de viabilidade média no conjunto de escolha, mas não oferecem garantia individual.

Isso muda a interpretação operacional. Um gestor pode aceitar uma média adequada para um grupo e ainda enfrentar faltas concentradas em produtos relevantes. Uma restrição por série, por volume de demanda ou por criticidade definiria outro problema. O artigo não transfere automaticamente os resultados de uma restrição média para essas exigências mais fortes.

A heurística EOQ legada na base brasileira tem fill rate médio 0,9422, maior que o dos seletores em 0,70. Compará-la isoladamente com uma escolha mais barata pode produzir uma economia expressiva, mas com atendimento diferente. O comparador principal utilizado aqui evita atribuir essa economia à camada de perfis quando uma política global de serviço semelhante já alcança custo próximo.

5.4. A sensibilidade ao limiar modifica vencedores e trade-offs

Na base brasileira, em 0,80, a escolha por perfil custa 4,178% mais que a global, com intervalo de redução $[-7{,}088; -1{,}860]$%. O fill rate melhora apenas 0,615 ponto percentual. Em 0,85 e 0,90 aparecem reduções de custo

de 2,233% e 1,413%, respectivamente, acompanhadas de queda média de atendimento de 0,515 e 0,471 ponto percentual. Essas diferenças devem ser vistas como compromissos condicionais, não como um limiar ótimo escolhido após observar os resultados.

No M5, em 0,80 e 0,85, perfis aumentam o custo em 2,333% e 3,013%. Em 0,90 e 0,95, ambas as estratégias escolhem PPO para todas as séries, com os mesmos indicadores. Um intervalo de contraste igual a zero nesse caso resulta de decisões idênticas na matriz, não de certeza sobre generalização.

Na base brasileira, em 0,95, a redução de custo por perfil é 17,246%, com intervalo condicional [12,091; 22,948]%, acompanhada de queda de 0,640 ponto percentual de atendimento. Nesse limiar, há grupos sem alternativa que satisfaça a exigência durante a escolha: 11 séries brasileiras e 40 M5 recebem escolhas de fallback por perfil. O resultado não pode ser descrito como viabilidade cumprida em todos os grupos. A sensibilidade revela, assim, tanto troca de vencedor quanto impossibilidade de atendimento da regra, e precisa ser lida junto com o serviço.

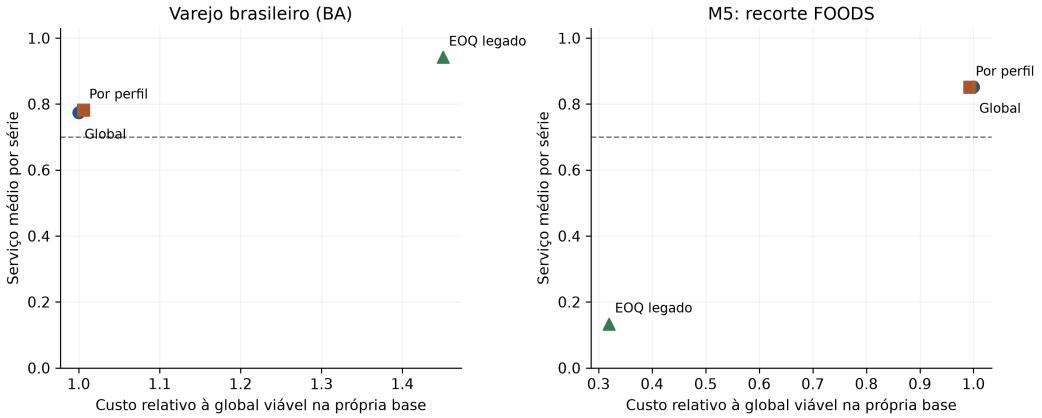


Figura 1: Custo e atendimento das políticas e estratégias nas duas bases. Os painéis possuem escalas próprias: diferenças absolutas de custo entre Brasil e M5 não têm interpretação econômica comum.

6. Discussão e implicações operacionais

Os resultados separam duas proposições frequentemente aproximadas: políticas vencedoras podem depender do contexto, e um perfil pode ajudar a identificar a vencedora. A primeira encontra um exemplo na troca entre

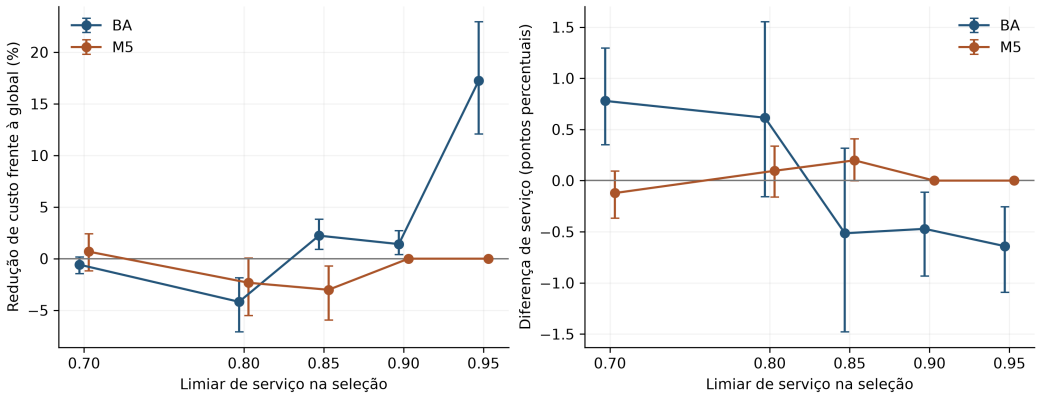


Figura 2: Contraste de seleção por perfil e global com exclusão de loja em diferentes limiares. Reduções de custo são interpretadas com diferenças de atendimento; intervalos são condicionais ao procedimento e às matrizes.

VendorResponsive e SA nas duas bases. A segunda exige ganho incremental frente à referência global. No limiar principal, esse ganho é pequeno ou ausente, com intervalos condicionais abrangendo zero.

A concentração em um perfil ajuda a interpretar essa limitação. Quando 80% das séries brasileiras e 97,59% das séries M5 pertencem a Sparse High Impact, a recomendação por perfil tende a reproduzir a escolha global na maior parte da amostra. Os grupos restantes podem conter diferenças operacionais importantes, mas sua representação não autoriza conclusões amplas sobre classes sazonais ou tendências. O aumento de séries no M5 não elimina o pequeno número de lojas ou a baixa diversidade de perfis.

O contraste M5 deve ainda ser entendido à luz da ausência de vendas registradas na maioria dos prefixos. Não se demonstrou que essa condição corresponda ao lançamento real dos produtos ou à indisponibilidade de histórico operacional. As políticas enfrentam demanda futura positiva após prefixos quase sempre nulos, e seus orçamentos configurados diferem. Essa assimetria limita qualquer conclusão de superioridade generalizável de SA ou inadequação de heurísticas. Uma análise específica deve separar séries com histórico disponível, alinhar orçamentos e avaliar estratégias de inicialização ou pooling; isso não foi realizado na comparação principal.

A referência utilizada também importa. Um estudo que compara perfis apenas com EOQ pode atribuir à representação um benefício proveniente da escolha de uma política de menor atendimento. A comparação com a melhor alternativa global viável pergunta o que a camada contextual acrescenta ao

portfólio já disponível. É um teste mais direto da utilidade da seleção, mesmo quando reduz o tamanho aparente do resultado.

Para a operação, a primeira decisão deve ser o significado da meta de serviço. Média por série, proporção total atendida e atendimento mínimo de itens críticos não são equivalentes. O segundo passo é verificar custos e ações no ponto de operação escolhido. No M5, a transição para PPO em limiares altos implica pedidos quase contínuos; no cenário de SA, a variabilidade média dos pedidos é elevada. São consequências que um ranking agregado não resolve. Restrições de capacidade, lotes mínimos e frequência máxima podem alterar a política preferida.

Os resultados não recomendam uma política única para todo varejo. Recomendam validar a complexidade adicional de um seletor antes de adotá-lo. Perfis podem continuar úteis para comunicação, investigação de falhas e agrupamento de parâmetros, mesmo que não reduzam custo nesta escolha. Essas utilidades são perguntas separadas e não devem ser apresentadas como benefício de seleção já demonstrado.

7. Limitações e continuidade

A análise trabalha com saídas existentes de um simulador. Os arquivos e seus hashes permitem reproduzir a reanálise, mas não recuperam automaticamente o estado de software que gerou cada controlador histórico. Implementações atuais de treinamento, previsão e aceleração podem diferir daquelas que produziram as matrizes. Não atribuímos resultados armazenados a uma nova execução CUDA nem alegamos que a avaliação dos doze controladores foi repetida neste artigo.

A configuração prevê prefixos de ajuste, porém informações de cenário, filtragem e perfis podem usar o histórico completo. A exclusão de loja controla participação na escolha da política, não todas as fontes de informação temporal. O grafo benchmark M5 não inclui treinamento do PSE ou previsão LSTM. O artigo não valida esses componentes apenas porque seus módulos existem no projeto. A suavização e os filtros calculados sobre o histórico completo também devem ser refeitos dentro das janelas em uma avaliação prospectiva. Manter IDs selecionados pela trajetória completa permite uma avaliação temporal condicional à coorte histórica, mas não torna prospectivo todo o processo de seleção da amostra. Na ingestão real, o tratamento de duplicatas de mesma chave exige verificar se os registros são repetições técnicas ou transações complementares; remover a primeira categoria é diferente

de descartar parte da demanda na segunda.

A dependência entre produtos e lojas e os dez agrupamentos M5 limitam inferências populacionais. Os intervalos não reajustam seletores nem simulam novas demandas. Perfis heurísticos, custos ilustrativos, horizonte, bloco parcial, efeito de borda e estoque inicial podem influenciar rankings. O uso de CV sobre as quantidades agregadas do código também requer cautela ao interpretar rótulos como aplicação literal de uma taxonomia baseada em tamanhos positivos.

A próxima validação deve congelar código e parâmetros, calcular filtros e perfis a partir de prefixos disponíveis, ajustar candidatos no treino, escolher a estratégia na validação e testar janelas posteriores. Deve incluir múltiplos períodos, atendimento ponderado e restrições locais, além de comparadores dimensionalmente consistentes. Uma eventual vantagem de GA–DQN deve ser examinada também contra GA e DQN isolados, nas mesmas séries e condições de avaliação, com o esforço computacional total informado. Só depois será possível avaliar um PSE supervisionado e comparar sua recomendação com as regras explícitas examinadas aqui. A escolha entre CPU e GPU deve ser orientada por medições do tempo total de execução; o hardware não substitui o desenho experimental.

8. Conclusão

A comparação entre uma rede brasileira e o M5 mostra que a política global de menor custo viável depende da base e da exigência de atendimento. Contudo, no limiar principal, os perfis examinados não estabelecem vantagem geral de custo: a seleção com exclusão de loja aumenta 0,58% na base brasileira e reduz 0,68% no M5, com intervalos condicionais que incluem zero. Aumentar o serviço altera os resultados e pode fazer os seletores convergirem para a mesma política.

O caso brasileiro permanece a evidência central, e o M5 amplia o contraste em outra origem de dados. A contribuição é distinguir heterogeneidade, utilidade do perfil e validação do seletor, reportando custo e atendimento conjuntamente. O estudo permanece retrospectivo e condicional às matrizes. Não comprova generalização temporal, reprodução exata de outro artigo ou benefício de um PSE implantado.

Disponibilidade de dados e código

Os dados transacionais brasileiros são proprietários e não são distribuídos nesta versão. O M5 é um conjunto público; sua transformação e o recorte devem acompanhar uma futura disponibilização reprodutível. Código de reanálise, tabelas e hashes são mantidos no projeto de pesquisa. Permissões de divulgação de derivados, repositório arquivado e identificadores públicos precisam ser confirmados antes de submissão.

Autoria, financiamento e interesses

A autoria indicada é provisória. Contribuições CRediT, coautoria, financiamento, agradecimentos e declaração de interesses serão confirmados pelo autor responsável. Não foram acrescentados orientadores como coautores sem essa definição. Esta é uma versão de trabalho em português; a submissão à revista requer adequação final ao idioma e às normas editoriais aplicáveis.

Uso de inteligência artificial na preparação do manuscrito

OpenAI Codex foi utilizado para auxiliar organização bibliográfica, leitura de código, preparação de análises e redação. A versão atual exige verificação e revisão do autor humano responsável, que deverá conferir fontes, cálculos e afirmações e assumir responsabilidade pelo texto final. Sistemas de IA não são autores.

Referências

[1] S. Axsäter, Inventory Control, 2nd Edition, Vol. 90 of International Series in Operations Research & Management Science, Springer US, New York, NY, USA, 2006. doi:10.1007/0-387-33331-2.

[2] J. R. Rice, The algorithm selection problem, in: Advances in Computers, Vol. 15, Academic Press, 1976, pp. 65–118. doi:10.1016/S0065-2458(08)60520-3.

[3] L. Kotthoff, Algorithm selection for combinatorial search problems: A survey, AI Magazine 35 (3) (2014) 48–60. doi:10.1609/aimag.v35i3.2460.

[4] Y. Tadayonrad, A. B. Ndiaye, A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality, Supply Chain Analytics 3 (2023) 100026. doi:10.1016/j.sca.2023.100026.

[5] O. Zabraoui, Y. Hmamou, A. Chafi, S. Kammouri Alami, A comparative study of multi-algorithm optimization for inventory analytics in supply chains, Supply Chain Analytics 12 (2025) 100154. doi:10.1016/j.sca.2025.100154.

[6] F. M. Theunissen, S. Alam, A. Sajjad, A topological analytics framework for preserving decision structure in supply chain inventory classification, Supply Chain Analytics 15 (2026) 100229. doi:10.1016/j.sca.2026.100229.

[7] A. A. Syntetos, J. E. Boylan, J. D. Croston, On the categorization of demand patterns, J. Oper. Res. Soc. 56 (5) (2005) 495–503. doi:10.1057/palgrave.jors.2601841.

[8] R. Pietukhov, M. Ahtamad, M. Faraji-Niri, T. El-Said, A hybrid forecasting model with logistic regression and neural networks for improving key performance indicators in supply chains, Supply Chain Analytics 4 (2023) 100041. doi:10.1016/j.sca.2023.100041.

[9] R. N. Boute, J. Gijsbrechts, W. van Jaarsveld, N. Vanvuchelen, Deep reinforcement learning for inventory control: A roadmap, European Journal of Operational Research 298 (2) (2022) 401–412. doi:10.1016/j.ejor.2021.07.016.

[10] S. Makridakis, E. Spiliotis, V. Assimakopoulos, M5 accuracy competition: Results, findings, and conclusions, International Journal of Forecasting 38 (4) (2022) 1346–1364. doi:10.1016/j.ijforecast.2021.11.013.