


Proposta de Dissertação de Mestrado

# Um Framework Adaptativo para Seleção de Políticas de Reposição em Regimes Operacionais Heterogêneos

Matheus Inácio Batista Santos
mibs@ic.ufal.br
Orientadores:

Dr. Rian Gabriel Santos Pinheiro
Dr. Bruno Costa e Silva Nogueira

Maceió

5 de junho de 2026

Matheus Inácio Batista Santos

# Um Framework Adaptativo para Seleção de Políticas de Reposição em Regimes Operacionais Heterogêneos

Uma proposta de dissertação submetida por Matheus Inácio Batista Santos como requisito parcial para qualificação no curso de Mestrado em Informática pela Universidade Federal de Alagoas, Instituto de Computação.

Orientadores:
Dr. Rian Gabriel Santos Pinheiro

Dr. Bruno Costa e Silva Nogueira

Maceió

5 de junho de 2026

Proposta de dissertação submetida por Matheus Inácio Batista Santos como requisito parcial para qualificação no curso de Mestrado em Informática pela Universidade Federal de Alagoas, Instituto de Computação, avaliada pela banca examinadora que assina abaixo.

---

Dr. Rian Gabriel Santos Pinheiro - Orientador
Instituto de Computação
Universidade Federal de Alagoas

---

Dr. Bruno Costa e Silva Nogueira - Orientador
Instituto de Computação
Universidade Federal de Alagoas

---

- Examinador(a)

---

- Examinador(a)

---

- Examinador(a)

Maceió
5 de junho de 2026

# Resumo

Redes varejistas precisam decidir quando e quanto repor estoque em séries de demanda heterogêneas. Uma regra pode preservar a disponibilidade de um produto e gerar excesso ou falta em outro. Esta dissertação propõe o *Adaptive Inventory Policy Engine* (AIPE), uma abordagem para investigar a seleção de políticas de reposição a partir de características operacionais de séries loja-produto. O *Policy Selection Engine* (PSE), seu componente supervisionado, permanece em desenvolvimento e validação.

A infraestrutura integra preparação dos dados, caracterização da demanda, sinais auxiliares de previsão e comparação de políticas em simulação. A avaliação exploratória utiliza dados de uma rede varejista brasileira: um piloto com 15 lojas da Paraíba e uma expansão com 145 séries da Bahia. O portfólio reúne políticas clássicas, meta-heurísticas e aprendizado por reforço. A escolha considera custo de inventário sob exigência de serviço, com indicadores de ruptura e estabilidade dos pedidos.

Os resultados históricos indicam diferenças entre políticas e perfis, mas não demonstram generalização do seletor. Reduções de custo dependem do comparador, do serviço e da versão experimental; escolhas retrospectivas não equivalem a ganhos futuros. A contribuição é a formulação e a infraestrutura de uma avaliação contextual rastreável. Uma avaliação externa reúne 2.408 séries do M5 e evidencia diferenças de custo e serviço entre as bases, condicionadas aos respectivos protocolos. Validação temporal e treinamento do PSE são necessários para estabelecer utilidade operacional.

**Palavras-chave**: Otimização de Inventário; Demanda Intermitente; Seleção Contextual de Políticas; Cadeia de Suprimentos.

# Sumário


Lista de Figuras . . . . . v
Lista de Tabelas . . . . . vi
Lista de Siglas . . . . . vii

**1 Introdução** **1**
1.1 Motivação . . . . . 1
1.1.1 Reposição em redes varejistas . . . . . 1
1.1.2 Da calibração à seleção de políticas . . . . . 2
1.2 Problema e questões de pesquisa . . . . . 2
1.3 Objetivos . . . . . 4
1.4 Contribuições e alcance da evidência . . . . . 4
1.5 Escopo e delimitações . . . . . 5

**2 Referencial Teórico** **6**
2.1 Formulação do Problema de Reposição . . . . . 6
2.1.1 Política de Reposição: Estado, Ação e Parâmetros . . . . . 6
2.1.2 Função Objetivo e Dinâmica de Estoque . . . . . 7
2.2 Famílias de Políticas de Reposição . . . . . 7
2.2.1 Políticas Clássicas . . . . . 7
2.2.2 Parametrização de Políticas via Meta-Heurísticas . . . . . 8
2.2.3 Políticas de Reposição via Aprendizado por Reforço . . . . . 9
2.2.4 Políticas Híbridas GA-RL . . . . . 9
2.3 Demanda Intermitente . . . . . 10
2.3.1 Taxonomia ADI e CV quadrado . . . . . 10
2.3.2 Efeitos na Reposição . . . . . 11
2.4 Métricas de Previsão . . . . . 11
2.4.1 Métricas Utilizadas . . . . . 11
2.5 Testes Estatísticos . . . . . 12
2.5.1 Teste de Wilcoxon . . . . . 12
2.5.2 Teste de Friedman e Nemenyi . . . . . 12
2.5.3 Tamanho de Efeito . . . . . 13

**3 Trabalhos Relacionados** **14**
3.1 Famílias de métodos . . . . . 14
3.2 Inventário e demanda intermitente . . . . . 14
3.3 Previsão e utilidade operacional . . . . . 15
3.4 Meta-heurísticas e aprendizado por reforço . . . . . 16
3.5 Seleção de políticas e meta-aprendizado . . . . . 16
3.6 Arquiteturas híbridas e posicionamento . . . . . 17

**4 Metodologia** **18**
4.1 Visão Geral do AIPE . . . 18
4.2 Instanciação Experimental do Problema de Inventário . . . 20
4.2.1 Decisão e Ambiente . . . 20
4.2.2 Métricas de Avaliação . . . 20
4.3 Camada de Entrada: Dados e Pré-Processamento . . . 21
4.3.1 Base de Dados . . . 21
4.3.2 Preparação das Séries . . . 22
4.4 Características e Perfis Operacionais . . . 22
4.4.1 Regras de Perfil . . . 23
4.5 Sinais Auxiliares de Previsão e Calibração . . . 24
4.6 Portfólio de Políticas Candidatas . . . 25
4.6.1 Composição e Referências . . . 25
4.6.2 Regras Analíticas e Heurísticas . . . 25
4.6.3 Busca de Parâmetros . . . 26
4.6.4 Agentes de Reforço e Arquitetura Híbrida . . . 26
4.6.5 Redundância e Classes de Rotulagem . . . 27
4.7 Simulação, Validação Temporal e Estatística . . . 27
4.7.1 Ambiente de Simulação . . . 27
4.7.2 Separação Temporal . . . 28
4.7.3 Inferência e Unidade Experimental . . . 29
4.8 Geração de Rótulos e PSE . . . 29
4.8.1 Problema de Seleção . . . 29
4.8.2 Treinamento e Avaliação Propostos . . . 30
4.8.3 Aplicação e Reavaliação . . . 30
4.9 Escopo Experimental e Rastreabilidade . . . 31

**5 Resultados Preliminares** **32**
5.1 Escopo dos Experimentos . . . 32
5.2 Experimento 1: Estudo Piloto na Paraíba . . . 33
5.2.1 Diferenças por Volume . . . 33
5.2.2 Aprendizado e Estabilidade . . . 34
5.3 Experimento 2: Expansão na Bahia . . . 34
5.3.1 Comparação Agregada . . . 34
5.3.2 Comparação por Perfil Operacional . . . 36
5.3.3 Política Única versus Seleção por Perfil . . . 36
5.4 Validação e Limites da Inferência . . . 37
5.5 M5: Evidência Externa Disponível após a Qualificação . . . 38
5.6 Previsão como Sinal Auxiliar . . . 39
5.7 Alcance e Continuidade . . . 40

**6 Conclusões** **41**
6.1 Síntese dos resultados . . . 41
6.2 Contribuições e limitações . . . 42
6.3 Implicações e continuidade . . . 42

**7 Plano de Continuidade e Cronograma** **43**
7.1 Consolidação da etapa empírica . . . . . 43
7.2 Validação temporal e estudos adicionais . . . . . 43
7.2.1 M5: consolidação dos experimentos públicos . . . . . 44
7.2.2 Expansão multiestado . . . . . 44
7.3 Treinamento e avaliação do PSE . . . . . 44
7.3.1 Calibração agrupada por perfil . . . . . 45
7.4 Sensibilidade e eficiência computacional . . . . . 45
7.5 Escrita e produção científica . . . . . 45
7.6 Sequência de trabalho . . . . . 45

**A Parâmetros e Resultados Complementares** **47**
A.1 Resultados Agregados do Piloto na Paraíba . . . . . 50

**Referências** **51**

# Lista de Figuras

1.1 Ilustração conceitual da motivação da dissertação. Em redes varejistas, diferentes séries loja-produto podem apresentar vendas regulares, intermitentes ou concentradas em picos. A aplicação uniforme de uma mesma regra de reposição pode gerar excesso de estoque, ruptura ou instabilidade nos pedidos. A proposta do AIPE é tratar essa diferença como um problema de seleção contextual de políticas de reposição. . . . . 3
4.1 Arquitetura conceitual do *framework* AIPE. A camada de entrada reúne dados transacionais preparados, parâmetros operacionais, características das séries e sinais auxiliares de previsão de demanda. O núcleo de seleção contextual utiliza essas entradas para avaliar políticas candidatas, gerar rótulos de política dominante, realizar validação estatística e treinar o *Policy Selection Engine*. A camada de aplicação utiliza o PSE para recomendar políticas a novas séries loja-produto e reavaliar periodicamente as recomendações conforme novos dados se acumulam. 19
4.2 Protocolo *walk-forward*: a janela de treinamento cresce incrementalmente e o modelo é avaliado apenas em dados futuros, respeitando a ordem das observações na divisão entre treino e avaliação. . . . . 28
5.1 Custo e serviço médios no recorte histórico BA. A comparação indica diferentes pontos de operação; não comprova desempenho de seleção em séries novas. . 35

# Lista de Tabelas


2.1 Quadrantes de Syntetos-Boylan: limiares e interpretações. . . . . 10
3.1 Papel das famílias de métodos na pesquisa. . . . . 15
3.2 Relação entre linhas da literatura e o foco da dissertação. . . . . 17
4.1 Regras hierárquicas dos Perfis Operacionais de Demanda. . . . . 23
5.1 Indicadores médios do recorte histórico BA: 12 políticas, 145 séries. As cinco repetições nominais não são tratadas como observações independentes. †DQN sem pedidos. . . . . 35
5.2 Política de menor CTI ajustado por perfil no recorte histórico BA, condicionada a NS médio $\geq 0{,}70$. Custos médios em R$. Grupos com menos de 20 séries são exploratórios. . . . . 36
5.3 Comparação histórica por CTI ajustado: penalidades de indisponibilidade e excesso. C é referência retrospectiva, sem garantia de implementação ou generalização. . . . . 37
5.4 M5: médias por política nos artefatos disponíveis. CTI relativo é a razão entre o CTI médio da política e o do EOQ, exclusivamente dentro do M5. . . . . 39
5.5 Métricas históricas de previsão sobre 145 séries BA. Os rótulos MASE/RMSSE usam a escala implementada no teste; não validam comparação convencional com previsão ingênua. sMAPE em %. . . . . 39
7.1 Continuidade da pesquisa por etapa e critério de conclusão. . . . . 46

A.1 Dados e ambiente de referência. . . . . 47
A.2 Regras e parâmetros das políticas clássicas e meta-heurísticas. . . . . 48
A.3 Agentes de reforço e híbrido: configurações documentadas. . . . . 48
A.4 Previsão auxiliar e seleção de políticas. . . . . 49
A.5 Rastreabilidade da reprodução. . . . . 49
A.6 Indicadores históricos do piloto PB:15 lojas do produto 48130. . . . . 50

# Lista de Siglas

| Sigla | Significado |
|---|---|
| AIPE | *Adaptive Inventory Policy Engine*; estrutura proposta para seleção contextual de políticas. |
| PSE | *Policy Selection Engine*; componente supervisionado de seleção. |
| POD | Perfil Operacional de Demanda. |
| CTI | Custo Total de Inventário. |
| NS | Nível de Serviço: fração da demanda atendida. |
| TR | Taxa de Ruptura: fração de ciclos com falta. |
| BE | *Bullwhip Effect*: razão entre variâncias de pedidos e demanda. |
| FP | Frequência de Pedidos. |
| ADI | *Average Demand Interval*: intervalo médio entre demandas positivas. |
| CV | Coeficiente de Variação; $CV^2$ é seu quadrado. |
| SKU | *Stock Keeping Unit*: unidade de produto para controle de estoque. |
| EOQ | *Economic Order Quantity*: lote econômico de compra. |
| GA | *Genetic Algorithm*: algoritmo genético. |
| SA | *Simulated Annealing*: recozimento simulado. |
| DQN | *Deep Q-Network*: rede de valores de ação. |
| PPO | *Proximal Policy Optimization*: otimização de política com recorte. |
| RL / DRL | Aprendizado por reforço / aprendizado por reforço profundo. |
| GA-DQN | Política híbrida que combina GA e DQN. |
| LSTM | *Long Short-Term Memory*: rede recorrente com memória. |
| ANN | *Artificial Neural Network*: rede neural artificial. |
| ARIMA | *Autoregressive Integrated Moving Average*. |
| MASE | *Mean Absolute Scaled Error*. |
| sMAPE | *Symmetric Mean Absolute Percentage Error*. |
| RMSSE | *Root Mean Squared Scaled Error*. |
| ASP | *Algorithm Selection Problem*: problema de seleção de algoritmos. |
| M5 | Competição de previsão baseada em vendas do Walmart. |

# 1

# Introdução

Uma rede varejista precisa decidir quando e quanto repor em cada loja. O problema se torna mais difícil quando um produto vende regularmente em uma unidade, mas passa vários ciclos sem venda em outra. Uma política que preserva disponibilidade no primeiro caso pode gerar excesso de estoque no segundo. Custos, faltas e variabilidade dos pedidos dependem da relação entre a regra de reposição e o comportamento da demanda (Axsäter, 2006; Syntetos and Boylan, 2005).

Esta dissertação investiga essa relação como um problema de seleção: dadas as características de uma série loja-produto e um portfólio de políticas, qual alternativa oferece menor custo sob uma exigência de serviço? A proposta recebe o nome de *Adaptive Inventory Policy Engine* (AIPE). Seu componente supervisionado, o *Policy Selection Engine* (PSE), permanece em desenvolvimento e validação.

## 1.1 Motivação

### 1.1.1 Reposição em redes varejistas

Diferenças de consumo, sazonalidade e condições logísticas dificultam o ajuste manual de estoques em redes com muitas lojas. Cada unidade decide sua reposição, mas seus pedidos também afetam o armazém. Lotes elevados podem reduzir a frequência de compra e aumentar o estoque; pedidos frequentes podem preservar disponibilidade e elevar custos fixos. A decisão envolve manutenção, falta, pedido e prazo de entrega (Axsäter, 2006; Zipkin, 2000).

A instabilidade dos pedidos acrescenta outra preocupação. Variações nas vendas podem produzir oscilações ainda maiores nas encomendas enviadas aos fornecedores, fenômeno conhecido como efeito chicote (Lee et al., 1997). Medir essa amplificação ajuda a avaliar consequências a montante, embora não substitua a análise conjunta de custo e serviço.

Considere dois históricos: um produto vende quantidades semelhantes a cada ciclo; outro apresenta a sequência “0, 0, 0, 50, 0, 0, 30”. No segundo caso, manter estoque para cobrir todos os picos pode ser caro, enquanto dimensioná-lo pela média pode aumentar as faltas. A demanda intermitente combina intervalos sem venda com ocorrências positivas; quando estas variam muito de tamanho, o padrão é chamado de *lumpy* (Croston, 1972; Syntetos and Boylan, 2005; Boylan and Syntetos, 2008).

Essas diferenças motivam comparar regras, mas não demonstram que um seletor por perfil será melhor que uma política única bem calibrada. A vantagem depende do portfólio, dos custos, do serviço exigido e da informação disponível antes da decisão. Uma escolha retrospectiva favorável pode desaparecer ao avaliar lojas ou períodos não usados no ajuste.

### 1.1.2 Da calibração à seleção de políticas

Políticas clássicas, meta-heurísticas e aprendizado por reforço oferecem formas distintas de decidir reposição. Uma meta-heurística pode ajustar o ponto de pedido e o lote de uma regra; um agente de reforço pode aprender ações a partir do estado do estoque. Antes desses ajustes, permanece a escolha de qual família utilizar (Syntetos et al., 2012; Boute et al., 2022).

O AIPE organiza essa escolha em quatro etapas: caracterizar a demanda, comparar políticas em um simulador comum, identificar alternativas viáveis segundo custo e serviço e investigar se essas diferenças orientam recomendações para novas séries. A formulação se aproxima da seleção de algoritmos, na qual características de uma instância ajudam a escolher um método (Rice, 1976; Kotthoff, 2014).

A previsão fornece informação auxiliar. Antecipar a demanda não determina automaticamente quando ou quanto pedir. Um modelo mais preciso tampouco garante menor custo de inventário. A avaliação principal deve ocorrer sobre as decisões de reposição e suas consequências operacionais.

A Figura 1.1 sintetiza a proposta: partir de séries heterogêneas, comparar um portfólio e avaliar a seleção contextual. O caminho entre essas etapas é uma hipótese a testar, não uma garantia de melhoria.

## 1.2 Problema e questões de pesquisa

A unidade de análise é a série de vendas de um produto em uma loja, agregada por ciclo comercial. As políticas decidem reposição sob condições comuns de demanda, custos e prazo. O critério de referência é o menor custo entre alternativas que atendam ao nível de serviço mínimo. Quando a restrição usa a média de um grupo, ela não garante atendimento mínimo para cada série.

A questão principal é: *características operacionais da demanda permitem selecionar políticas de reposição com melhor compromisso entre custo e serviço do que uma política única*




Figura 1.1: Ilustração conceitual da motivação da dissertação. Em redes varejistas, diferentes séries loja-produto podem apresentar vendas regulares, intermitentes ou concentradas em picos. A aplicação uniforme de uma mesma regra de reposição pode gerar excesso de estoque, ruptura ou instabilidade nos pedidos. A proposta do AIPE é tratar essa diferença como um problema de seleção contextual de políticas de reposição.

*aplicada à rede?* A investigação se divide em três perguntas:

1. O desempenho relativo das políticas varia entre séries e perfis operacionais?
2. Características observadas antes da decisão permitem aprender uma relação útil entre perfil e política?
3. Essa relação mantém desempenho em novas lojas, produtos ou períodos?

A primeira pergunta trata de heterogeneidade; a segunda, de aprendizagem; a terceira, de generalização. Elas exigem evidências distintas. Encontrar vencedores diferentes na própria amostra não valida o PSE nem demonstra economia futura. Diferenças estatísticas entre políticas também não substituem a comparação entre estratégias de seleção.

As hipóteses correspondentes são que existe heterogeneidade operacional relevante, que parte dela é capturada pelas características das séries e que um seletor pode aproveitar essa informação fora da amostra. As duas últimas permanecem em avaliação. Os resultados da

qualificação são exploratórios e motivam testes adicionais; não autorizam concluir que a seleção contextual supera sempre a melhor política global.

## 1.3 Objetivos

### Objetivo geral

Propor e avaliar o AIPE como abordagem de seleção contextual de políticas de reposição para séries loja-produto, considerando custo de inventário, serviço e estabilidade dos pedidos em dados de uma rede varejista brasileira e em um recorte público do M5.

### Objetivos específicos

1. Construir um ambiente comum para comparar políticas clássicas, meta-heurísticas, aprendizado por reforço e combinações desses métodos (Law, 2015; Talbi, 2009).

2. Preparar históricos e extrair características de intermitência, variabilidade, volume e comportamento temporal para análise por perfil.

3. Comparar política única e seleção por perfil, informando custo, serviço, casos inviáveis e sensibilidade às condições experimentais.

4. Desenvolver e validar o PSE com separação entre ajuste, escolha e avaliação, e comparar suas decisões com referências simples.

5. Examinar a validade externa em dados públicos de varejo e em recortes adicionais da base brasileira, preservando a rastreabilidade.

O piloto da Paraíba avaliou 15 lojas e um produto. A etapa da Bahia ampliou a análise para 145 séries. Esses recortes constituem a base histórica da qualificação. A comparação M5 já dispõe de resultados; sua consolidação e a expansão multiestado examinam os limites desses recortes. O estado das atividades é apresentado no Capítulo 7.

## 1.4 Contribuições e alcance da evidência

A contribuição metodológica é formular a escolha de políticas como seleção contextual apoiada por um portfólio avaliado em condições comuns. A contribuição empírica é estudar essa escolha em séries reais do varejo brasileiro, com forte intermitência. A contribuição computacional é integrar preparação, caracterização, simulação e análise em um fluxo configurável.

GA, SA, DQN, PPO e suas combinações são métodos conhecidos. Sua presença no portfólio não constitui novidade algorítmica; a arquitetura GA–DQN já aparece em Zabraoui et al.

(2025). O interesse está em entender quando uma alternativa oferece vantagem e se essa informação sustenta uma recomendação verificável.

A infraestrutura implementada não equivale à validação completa do sistema proposto. O PSE ainda exige resultados fora da amostra. Artefatos de versões diferentes do portfólio precisam ser identificados, pois mudanças nas políticas e no código alteram a comparação. Números de rodadas distintas não devem ser combinados como um único experimento.

O protocolo histórico prevê cinco execuções por série e política, mas isso não basta para afirmar independência. Saídas determinísticas ou praticamente idênticas não aumentam a evidência empírica. A série e suas dependências por loja devem orientar a análise, como discutido nos capítulos de metodologia e resultados.

## 1.5 Escopo e delimitações

A pesquisa trata cada série loja-produto como uma decisão de reposição. Não modela substituição entre produtos, capacidade conjunta nem coordenação multiagente entre lojas e armazéns. O efeito chicote é um indicador complementar de variabilidade, não evidência de otimização de toda a rede.

O simulador avalia políticas sobre históricos preparados. Custos e abastecimento são parâmetros do cenário; roteamento, transporte e integração transacional com ERP ficam fora do escopo. A recomendação proposta é periódica e não troca de política a cada transação. Aprendizado por reforço multiagente, como o discutido por Liu et al. (2025), também não é implementado como coordenação da rede.

Os dados proprietários limitam a divulgação pública. A rastreabilidade depende de código, parâmetros e identificação dos artefatos e recortes. Vendas podem não representar toda a demanda quando há falta de estoque, e ciclos ausentes exigem tratamento cuidadoso. Essas limitações impedem interpretar automaticamente a simulação como ganho econômico realizável.

O Capítulo 2 apresenta os fundamentos; o Capítulo 3, a literatura; e o Capítulo 4, a implementação. O Capítulo 5 reúne os resultados exploratórios. As conclusões estão no Capítulo 6, e a continuidade no Capítulo 7.

# 2

# Referencial Teórico

A seleção de políticas de reposição exige distinguir três objetos: o processo de demanda, a regra que produz pedidos e o critério usado para comparar seus resultados. Este capítulo define esses objetos e apresenta os métodos de previsão e inferência utilizados no trabalho. A descrição operacional dos experimentos fica no Capítulo 4.

## 2.1 Formulação do Problema de Reposição

### 2.1.1 Política de Reposição: Estado, Ação e Parâmetros

Uma política $\pi$ transforma o estado observado $\mathbf{s}_t$ em uma quantidade de pedido não negativa:

$$\pi : \mathcal{S} \to \mathcal{A}, \qquad Q_t = \pi(\mathbf{s}_t; \boldsymbol{\theta}).$$

O estado reúne estoque disponível, pedidos em trânsito e informações de demanda disponíveis até a decisão. Os parâmetros $\boldsymbol{\theta}$ podem ser limiares e lotes, no caso de regras analíticas, ou pesos de uma rede neural. Meta-heurísticas ajustam parâmetros de uma regra; aprendizado por reforço ajusta a própria representação da decisão. Todas essas alternativas precisam ser avaliadas sob a mesma dinâmica de estoque.

É necessário separar estoque físico de posição de estoque. O primeiro determina o atendimento imediato; a segunda acrescenta os pedidos em trânsito e evita solicitar novamente unidades já encomendadas. Uma previsão de demanda pode integrar o estado, mas não substitui essas informações. Um vetor reduzido também não garante que o processo seja Markoviano: essa propriedade depende de representar informação suficiente para suas transições.

### 2.1.2 Função Objetivo e Dinâmica de Estoque

Para um horizonte finito $T$, o problema conceitual consiste em minimizar o custo esperado:

$$\min_{\pi} \mathbb{E}\left[\sum_{t=1}^{T}\left(hI_t + c_s S_t + c_o^{\text{fix}}\mathbf{1}(Q_t > 0) + c_o^{\text{var}} Q_t\right)\right]. \tag{2.1}$$

$I_t$ é o estoque após atendimento, $S_t$ a demanda perdida, $h$ o custo de manutenção por unidade e ciclo, $c_s$ o custo por unidade não atendida e $c_o^{\text{fix}}$, $c_o^{\text{var}}$ os custos fixo e variável de pedido. A esperança representa incerteza da demanda ou do treinamento; repetir uma trajetória determinística não estima essa distribuição.

Se $B_t$ é o estoque antes da chegada e $A_t$ a quantidade recebida no ciclo, a dinâmica de vendas perdidas é

$$S_t = \max(0, D_t - B_t - A_t), \quad I_t = \max(0, B_t + A_t - D_t), \quad B_{t+1} = I_t. \tag{2.2}$$

A demanda não atendida não se acumula como encomenda pendente. A convenção de chegada deve acompanhar a equação: um modelo com prazo efetivo $\ell$ usa $A_t = Q_{t-\ell}$, enquanto o simulador deste estudo usa uma fila de tamanho $L+1$, com chegada em $t+L+1$ para pedido feito em $t$. Essa diferença é explicitada na metodologia.

Minimizar custo sem restrição pode favorecer uma política que quase nunca repõe. Por isso, o trabalho acrescenta um nível mínimo de serviço. A escolha do limiar expressa um compromisso operacional e deve anteceder a comparação. Custos e serviço precisam ser apresentados conjuntamente, pois uma economia obtida com menor atendimento não caracteriza dominância.

## 2.2 Famílias de Políticas de Reposição

### 2.2.1 Políticas Clássicas

As políticas clássicas oferecem referências interpretáveis. Sob demanda constante média $\mu$ por ciclo, custo fixo $K$ por pedido e manutenção $h$ por unidade e ciclo, o lote econômico é

$$Q^* = \sqrt{2K\mu/h}.$$

Demanda e manutenção devem usar a mesma unidade temporal. A EOQ define o tamanho do lote; um ponto de pedido separado estabelece quando solicitá-lo. Com estoque de segurança, esse ponto pode ser $s = \mu L + z\sigma\sqrt{L}$, sob aproximações sobre demanda e prazo. A implementação histórica será distinguida dessa fórmula porque emprega uma demanda acumulada no horizonte.

A política $(s,S)$ observa a posição de estoque $P_t$ e pede $\max(0,S-P_t)$ quando $P_t \leq s$. O limiar inferior evita pedidos a cada pequena redução de estoque; o superior determina a recomposição. A concentração de pedidos em lotes pode amplificar a variabilidade a montante, fenômeno associado ao efeito chicote (Lee et al., 1997). A intensidade desse efeito depende dos parâmetros e da demanda, não apenas do nome da política.

O modelo do Jornaleiro determina uma quantidade de período único pelo quantil de demanda associado à razão crítica entre falta e excesso. Na aproximação normal, escreve-se $Q^* = \mu + z_\alpha \sigma$. Essa expressão é ótima somente sob as hipóteses do modelo e com $\alpha$ derivado dos custos pertinentes. Usar $z = 1.28$ como parâmetro fixo em uma regra multiperíodo constitui uma heurística inspirada no modelo, não uma garantia de otimalidade.

Regras analíticas podem receber parâmetros específicos por série e, portanto, não pressupõem necessariamente uma única parametrização para toda a rede. Sua simplicidade é uma vantagem comparativa relevante: um método mais complexo precisa demonstrar ganho além do obtido por calibração adequada de uma referência simples.

### 2.2.2 Parametrização de Políticas via Meta-Heurísticas

Meta-heurísticas procuram vetores $\boldsymbol{\theta}$ em um espaço de busca. Cada candidato induz uma política, cuja execução simulada fornece custo e serviço. Essa abordagem dispensa uma expressão diferenciável para o desempenho, mas continua sujeita a sobreajuste ao histórico usado na busca. O objetivo, os limites dos parâmetros e o orçamento de avaliações devem ser controlados na comparação.

O Algoritmo Genético (GA) mantém uma população de candidatos e alterna seleção, cruzamento e mutação (Holland, 1992; Talbi, 2009). Em reposição, cromossomos podem codificar ponto de pedido e lote; a avaliação associa cada vetor à trajetória resultante (Yuna et al., 2023). Não há garantia geral de ótimo global em orçamento finito.

O Recozimento Simulado (SA) parte de uma solução e explora vizinhos. Uma piora $\Delta C$ pode ser aceita com probabilidade $\exp(-\Delta C/T_k)$, em que $T_k$ é a temperatura (Kirkpatrick et al., 1983). Seu resfriamento controla a passagem de exploração para busca local. O resultado depende da escala da função objetivo, da vizinhança e do número de iterações.

Na Otimização por Enxame de Partículas (PSO), cada posição representa um candidato; velocidade, melhor posição individual e melhor posição coletiva orientam a atualização (Kennedy and Eberhart, 1995). A Evolução Diferencial (DE) gera candidatos pela combinação de diferenças entre vetores e aplica cruzamento e seleção (Storn and Price, 1997). Ambos são alternativas para espaços contínuos, mas não constituem, por si, regras operacionais distintas de reposição.

Mesmo quando duas buscas ajustam a mesma regra, seus custos computacionais e soluções podem diferir. A comparação deve identificar qual parte do ganho decorre do algoritmo de busca e qual decorre da regra parametrizada. Otimizar cada série também é diferente de

selecionar, entre políticas já calibradas, qual deve ser aplicada a uma nova série.

### 2.2.3 Políticas de Reposição via Aprendizado por Reforço

O aprendizado por reforço representa o controle como um processo de decisão $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$. O agente escolhe pedidos, recebe uma recompensa e observa a transição do inventário. Com recompensa $r_t = -C_t$, busca maximizar o retorno descontado $\sum_t \gamma^t r_t$ (Sutton and Barto, 2018). Uma restrição de serviço não é automaticamente satisfeita por essa recompensa: precisa de tratamento explícito ou verificação posterior.

DQN aproxima a função de valor $Q_\theta(s,a)$ por uma rede neural, usando memória de experiências e rede-alvo (Mnih et al., 2015). Sua aplicação requer ações discretizadas. A resolução dessa discretização limita os lotes disponíveis; episódios adicionais sobre a mesma série aumentam interações simuladas, mas não acrescentam novas realizações independentes de demanda.

PPO atualiza uma política por gradiente com uma razão de probabilidades limitada por *clipping* (Schulman et al., 2017). Pode ser formulado com ações contínuas ou discretas; essa propriedade precisa ser informada para cada implementação. Comportamentos como pedidos excessivos ou ausência de reposição podem resultar da recompensa, da escala dos estados, da exploração ou do treinamento. A observação de uma trajetória degenerada não identifica isoladamente sua causa.

SARSA atualiza valores seguindo a própria política:

$$Q(s,a) \leftarrow Q(s,a) + \eta[r + \gamma Q(s',a') - Q(s,a)].$$

A versão tabular exige discretizar o estado; Expected SARSA substitui o próximo valor pela esperança sobre ações. A adequação de cada representação depende da informação preservada e do tamanho do problema, e não permite concluir antecipadamente que uma família será superior nas séries estudadas.

### 2.2.4 Políticas Híbridas GA-RL

Uma arquitetura híbrida usa a busca evolutiva para obter parâmetros ou experiências iniciais e depois ajusta uma política por reforço. No GA–DQN, transições geradas com a política do GA podem preencher a memória do agente antes do refinamento. Trata-se de uma hipótese de melhoria da inicialização; seu benefício exige comparação com os componentes isolados e controle dos respectivos orçamentos.

A inicialização não elimina o risco de sobreajuste. Se busca e aprendizado observarem a mesma trajetória usada na avaliação, o resultado descreve adaptação ao histórico, não generalização. Além disso, avaliações completas de candidatos do GA e transições armazenadas

no DQN são quantidades diferentes. O trabalho trata o híbrido como candidato do portfólio; o problema de pesquisa é a seleção contextual entre candidatos.

## 2.3 Demanda Intermitente

Uma série intermitente alterna ciclos sem demanda e ocorrências positivas, cujos tamanhos também podem variar (Croston, 1972; Boylan and Syntetos, 2008). Frequência e magnitude são dimensões distintas. Para $D_t \geq 0$, definem-se

$$n_+ = |\{t : D_t > 0\}|, \tag{2.3}$$

$$\mu = T^{-1}\sum_t D_t, \qquad \sigma^2 = (T-1)^{-1}\sum_t (D_t - \mu)^2. \tag{2.4}$$

A média sobre todos os ciclos descreve o volume por período, mas pode ocultar longos intervalos sem venda. Uma sequência com valores positivos estáveis e muitos zeros é operacionalmente diferente de outra igualmente esparsa, porém com grandes picos.

### 2.3.1 Taxonomia ADI e $CV^2$

A classificação de Syntetos and Boylan (2005) combina intervalo médio entre demandas e variação dos tamanhos positivos:

$$\mathrm{ADI} = T/n_+, \tag{2.5}$$

$$\mathrm{CV}_+^2 = (\sigma_+/\mu_+)^2. \tag{2.6}$$

Aqui, $\mu_+$ e $\sigma_+$ são calculados apenas nas observações positivas, diferentemente da média e variância da Equação 2.4. Os limiares 1.32 e 0.49 delimitam quatro categorias, resumidas na Tabela 2.1 (Syntetos et al., 2012).

Tabela 2.1: Quadrantes de Syntetos-Boylan: limiares e interpretações.

| Regime | ADI | $CV^2$ | Interpretação operacional |
|---|---|---|---|
| *Smooth* (Regular) | $< 1.32$ | $< 0.49$ | Alta frequência, demanda estável. |
| *Erratic* (Errático) | $< 1.32$ | $\geq 0.49$ | Alta frequência, magnitude irregular. |
| *Intermittent* (Intermitente) | $\geq 1.32$ | $< 0.49$ | Muitos zeros, magnitude relativamente estável. |
| *Lumpy* (Grumoso) | $\geq 1.32$ | $\geq 0.49$ | Muitos zeros e magnitude altamente irregular. |

A implementação disponível também calcula uma medida de $CV^2$ incluindo zeros. Essa medida é útil como característica, mas não reproduz exatamente a definição original dos tamanhos positivos. As categorias dos artefatos são mantidas como rótulos operacionais, com essa ressalva; uma comparação entre taxonomias exige recalcular explicitamente ambos os índices.

### 2.3.2 Efeitos na Reposição

Demanda esparsa dificulta estimar taxas de ocorrência; tamanhos irregulares ampliam o custo de errar lotes e estoques de segurança. Croston separa a estimação dos tamanhos positivos e dos intervalos entre ocorrências. Isso pode melhorar a previsão, mas não estabelece qual regra de reposição minimiza custo sob um prazo e uma restrição de serviço específicos.

Os quadrantes fornecem uma descrição inicial, não uma prescrição de política. Séries no mesmo quadrante podem diferir em volume, tendências, sequências de zeros e concentração de picos. A hipótese do AIPE é que essas diferenças adicionais possam auxiliar a escolha; sua utilidade precisa ser medida contra uma política global bem calibrada, não inferida da classificação.

## 2.4 Métricas de Previsão

Erros absolutos e quadráticos dependem da escala da série; o MAPE é indefinido quando a demanda observada é zero. O estudo emprega métricas escaladas e sMAPE, com convenções explícitas para denominadores nulos (Hyndman and Koehler, 2006; Makridakis et al., 2020). Nenhuma métrica de previsão substitui a avaliação do efeito da decisão sobre custo e serviço.

### 2.4.1 Métricas Utilizadas

Sejam $e_t = D_t - \hat{D}_t$ os erros em $m$ pontos de avaliação e $d_1, \ldots, d_n$ o treinamento. O MASE compara o erro absoluto com a variação da referência ingênua:

$$\mathrm{MASE} = \frac{m^{-1} \sum_t |e_t|}{(n-1)^{-1} \sum_{j=2}^{n} |d_j - d_{j-1}|}. \tag{2.7}$$

Valores menores que um indicam erro inferior à escala ingênua (Hyndman and Koehler, 2006). A escala deve vir do treino; séries constantes requerem registro de indefinição ou regularização declarada. A presença de zeros, isoladamente, não impede o cálculo.

O sMAPE usa demanda e previsão simetricamente (Makridakis, 1993):

$$\mathrm{sMAPE} = \frac{200}{m} \sum_t \frac{|D_t - \hat{D}_t|}{|D_t| + |\hat{D}_t|} \,\%. \tag{2.8}$$

Adota-se contribuição zero quando ambos os termos do denominador são nulos. Seu intervalo é de zero a 200%, mas pequenas demandas podem produzir valores elevados; por isso é interpretado junto ao MASE.

A versão quadrática escalada é

$$\mathrm{RMSSE} = \sqrt{\frac{m^{-1}\sum_t e_t^2}{(n-1)^{-1}\sum_{j=2}^{n}(d_j - d_{j-1})^2}}. \tag{2.9}$$

Ela dá maior peso a erros grandes e também requer escala de treino não nula. O RMSSE complementa o diagnóstico; o MASE permanece a referência principal de comparação de previsão no estudo.

O viés médio, $\mathrm{MBE} = \overline{D} - \overline{\hat{D}}$, diferencia subestimação de superestimação. O U de Theil compara RMSE do modelo e da previsão ingênua (Theil, 1966). Esses indicadores auxiliam a interpretação, sem determinar a política vencedora. Uma relação entre menor erro e melhor reposição é hipótese empírica: depende da assimetria de custos, do prazo e da regra de decisão.

## 2.5 Testes Estatísticos

A comparação usa observações pareadas porque as políticas atendem às mesmas séries. Testes não paramétricos evitam exigir normalidade dos KPIs, mas não dispensam atenção à independência das unidades. Produtos da mesma loja e lojas expostas às mesmas condições podem ser dependentes. Repetições idênticas não aumentam o tamanho efetivo da amostra.

### 2.5.1 Teste de Wilcoxon

Para diferenças $\Delta_i = X_i^A - X_i^B$, a soma de postos com sinal é

$$W = \sum_{i:\Delta_i \neq 0} \mathrm{sgn}(\Delta_i) R_i, \tag{2.10}$$

em que $R_i$ é o posto de $|\Delta_i|$. O teste de Wilcoxon (1945) avalia uma hipótese de localização sob condições sobre a distribuição das diferenças. Sua leitura como teste da mediana requer, em particular, simetria. Empates e diferenças nulas devem receber tratamento documentado.

### 2.5.2 Teste de Friedman e Nemenyi

Com $K$ políticas avaliadas nas mesmas $N$ instâncias, o teste de Friedman (1940) compara postos médios:

$$\chi_F^2 = \frac{12N}{K(K+1)} \sum_{j=1}^{K} \left( \bar{r}_j - \frac{K+1}{2} \right)^2. \tag{2.11}$$

A rejeição não identifica sozinha os pares diferentes. O procedimento de Nemenyi usa uma diferença crítica (Nemenyi, 1963):

$$\mathrm{DC} = q_\alpha \sqrt{\frac{K(K+1)}{6N}}. \tag{2.12}$$

Postos separados por mais que DC são distinguidos sob as condições do procedimento. Um posto favorável em custo não representa necessariamente serviço aceitável; as métricas e os limiares precisam permanecer visíveis.

### 2.5.3 Tamanho de Efeito

A diferença padronizada de médias é reportada como descrição complementar (Cohen, 1988):

$$d = \frac{\bar{X}_A - \bar{X}_B}{s_{\mathrm{pooled}}}, \qquad s_{\mathrm{pooled}} = \sqrt{\frac{(N_A-1)s_A^2 + (N_B-1)s_B^2}{N_A + N_B - 2}}. \tag{2.13}$$

Essa forma não utiliza a covariância do pareamento; medidas baseadas nas diferenças podem ser mais apropriadas para inferência pareada. Faixas convencionais de efeito pequeno, médio ou grande não substituem a diferença de custo em unidades operacionais e sua repercussão no serviço.

O conjunto de testes, efeitos e gráficos descreve a heterogeneidade observada. Não transforma uma escolha retrospectiva de vencedor em evidência de generalização. Essa distinção orienta o protocolo de validação do próximo capítulo: a avaliação de uma política e a avaliação do mecanismo que a seleciona são etapas diferentes.

# 3

# Trabalhos Relacionados

A literatura fornece métodos para prever demanda, calibrar regras e aprender decisões de reposição. A questão desta dissertação é como escolher entre essas alternativas para uma série loja-produto. A revisão distingue o desempenho de uma política da capacidade de um seletor de reconhecer quando utilizá-la.

## 3.1 Famílias de métodos

Políticas clássicas têm formulações interpretáveis e constituem referências necessárias, mesmo quando se avaliam métodos de aprendizado (Axsäter, 2006; Zipkin, 2000). Meta-heurísticas exploram seus parâmetros; agentes de reforço aprendem ações sequenciais; e a seleção de algoritmos escolhe métodos a partir de características das instâncias. São níveis complementares, não substitutos automáticos.

A Tabela 3.1 resume seu papel no problema estudado. As limitações indicadas são questões de avaliação: não significam que toda implementação de uma família apresente o mesmo comportamento.

## 3.2 Inventário e demanda intermitente

Clark and Scarf (1960) estabelecem resultados de decomposição para sistemas multi-escalão sob hipóteses específicas. Os textos de Axsäter (2006) e Zipkin (2000) consolidam políticas, custos e medidas de serviço. Para estoques de segurança em redes, o modelo de serviço garantido e suas extensões oferecem outra linha de planejamento (Graves and Willems, 2000; Eruguz et al., 2016; Achkar et al., 2024). Esses resultados não dispensam verificar se demanda, abastecimento e coordenação correspondem ao caso aplicado.

Tabela 3.1: Papel das famílias de métodos na pesquisa.

| Família | Decisão ou informação produzida | Questão de avaliação |
|---|---|---|
| Políticas clássicas | Quando e quanto pedir por uma regra explícita | Adequação e calibração ao cenário |
| Previsão | Estimativa de demanda ou de sua distribuição | Efeito da previsão sobre custo e serviço |
| Meta-heurísticas | Parâmetros de uma política escolhida | Custo de busca e validade fora do ajuste |
| Aprendizado por reforço | Ação condicionada ao estado | Recompensa, estabilidade e generalização |
| Seleção de políticas | Escolha de um membro do portfólio | Ganho incremental frente à referência global |

A demanda intermitente requer atenção à frequência e ao tamanho das ocorrências. Croston (1972) separam esses componentes na previsão. A classificação ADI$\times$CV$^2$ diferencia padrões suaves, erráticos, intermitentes e *lumpy* (Syntetos and Boylan, 2005). Essa descrição organiza séries, mas não determina a política de menor custo: o resultado depende também de prazo, custos e serviço exigido.

A revisão de de Kok et al. (2018) mostra a diversidade de estruturas consideradas na otimização multi-escalão. Nesta dissertação, porém, as séries são simuladas como decisões locais. Não se reivindica a otimização conjunta de uma rede geral, nem se transfere uma garantia teórica de otimalidade para um cenário que não atende às hipóteses originais.

## 3.3 Previsão e utilidade operacional

Históricos com muitos zeros tornam problemático o uso de erros relativos divididos pela demanda observada. O MASE permite comparação entre escalas quando seu denominador é definido, mas séries constantes também exigem tratamento (Hyndman and Koehler, 2006). Métricas de previsão devem ser acompanhadas de convenções para casos degenerados, sem substituir a avaliação de inventário.

Estudos em varejo mostram que o desempenho preditivo depende da granularidade, dos dados e da forma de treinamento (Makridakis et al., 2020; Nasseri et al., 2023). Não há razão para supor que uma rede LSTM será sempre superior a modelos simples em históricos curtos. Um resultado de competição de previsão tampouco demonstra vantagem em custo de reposição.

Tadayonrad and Ndiaye (2023) aproximam a avaliação preditiva de custos e serviço. Essa conexão orienta o AIPE: previsões e seus erros fornecem sinais auxiliares, mas a seleção deve ser julgada pelas consequências da decisão. Para evitar informação futura, previsão, características e calibração precisam respeitar o mesmo corte temporal da avaliação.

## 3.4 Meta-heurísticas e aprendizado por reforço

Meta-heurísticas procuram soluções em espaços de parâmetros difíceis de tratar analiticamente (Talbi, 2009). Em inventário, permitem ajustar ponto de pedido e lote. Yuna et al. (2023) estudam otimização de parâmetros em demanda intermitente, enquanto Erkayman et al. (2025) combinam modelagem da demanda e busca de parâmetros. O ganho permanece condicionado à política e ao cenário de calibração.

Aprendizado por reforço formula reposição como decisão sequencial. Oroojlooyjadid et al. (2022) estudam DQN no *Beer Game*; Gijsbrechts et al. (2022) discutem aplicações de aprendizado profundo a inventário; e Vanvuchelen et al. (2020) aplicam PPO à reposição conjunta. Outros trabalhos investigam topologias e coordenação descentralizada (Geevers et al., 2024; Liu et al., 2025).

Esses estudos mostram possibilidades de controle adaptativo, mas a aplicação depende de estado, ação, recompensa e dinâmica do simulador. Um agente pode obter serviço elevado emitindo pedidos excessivos ou reduzir custo deixando de atender demanda. Custo, serviço e comportamento das ações precisam ser examinados em conjunto.

Históricos curtos restringem a avaliação, embora o número de ciclos observados não seja igual ao número possível de interações simuladas. Repetir episódios pode ampliar treinamento sem adicionar novos processos de demanda. Comportamento degenerado em uma implementação não demonstra incapacidade geral do algoritmo: pode refletir recompensa, orçamento, parametrização ou erro de código. Essa cautela importa ao interpretar resultados antigos após correções do ambiente.

## 3.5 Seleção de políticas e meta-aprendizado

Rice (1976) formalizam a escolha de um algoritmo a partir das características de uma instância. Revisões posteriores descrevem seletores supervisionados e sua avaliação (Kotthoff, 2014; Kerschke et al., 2019). No AIPE, a instância é a série loja-produto, o portfólio reúne políticas e a medida de desempenho combina custo e viabilidade de serviço.

A analogia separa três objetos: o melhor método global, o melhor método conhecido para cada instância e o método escolhido pelo seletor. O segundo é uma referência retrospectiva; não é implementável quando sua escolha exige conhecer resultados futuros. O terceiro deve ser avaliado em dados que não determinaram os rótulos ou o ajuste.

O teorema *No Free Lunch* trata de médias sobre classes de problemas sob condições próprias (Wolpert and Macready, 1997). Ele não prova que haverá troca de vencedores neste recorte varejista nem que as características escolhidas permitirão aprendê-la. Essas são questões empíricas. Características de instância podem ajudar na seleção (Kerschke and Trautmann, 2019), mas sua utilidade precisa ser verificada no problema aplicado.

Hiper-heurísticas selecionam ou geram heurísticas, inclusive durante a resolução (Drake

et al., 2020; Dokeroglu et al., 2024). O AIPE tem escopo mais restrito: propõe recomendar periodicamente uma política por série. Não troca controladores a cada estado do estoque nem coordena agentes em tempo real. Trabalhos com *bandits* e contexto investigam outras formas de adaptação em inventário (Preil and Krapp, 2022; Sultana et al., 2024); abordagens integradas relacionam características e decisões em outros desenhos operacionais (Qi et al., 2023).

A consequência prática é comparar o seletor com uma referência global forte. A avaliação deve separar o ajuste das políticas da aprendizagem da escolha entre elas. Excluir uma loja do seletor, por exemplo, não elimina informação futura já usada para gerar seus resultados de simulação.

## 3.6 Arquiteturas híbridas e posicionamento

Zabraoui et al. (2025) combinam busca genética e aprendizado por reforço em um estudo de inventário com dados do Walmart M5. É uma referência próxima do portfólio adotado aqui. A arquitetura GA–DQN e combinações GA–RL não são apresentadas como invenções desta dissertação. Sua inclusão permite investigar se oferecem vantagem em determinados recortes e como se comparam a regras simples sob condições comuns.

A Tabela 3.2 situa o foco da pesquisa sem equiparar bases, contagens de políticas ou protocolos diferentes. Uma comparação quantitativa direta exigiria reproduzir custos, horizontes, demandas e critérios de serviço.

Tabela 3.2: Relação entre linhas da literatura e o foco da dissertação.

| Referência | Foco | Relação com esta pesquisa |
|---|---|---|
| Oroojlooyjadid et al. 2022 | Aprender controle sequencial | Política candidata, não seletor validado |
| Yuna et al. 2023 | Calibrar em demanda intermitente | Busca de parâmetros dentro do portfólio |
| Zabraoui et al. 2025 | Comparação e combinação de algoritmos | Referência das arquiteturas avaliadas |
| Rice 1976; Kotthoff 2014 | Selecionar métodos por instância | Base conceitual do PSE |
| Esta dissertação | Seleção contextual em varejo brasileiro | Comparar seleção e referência global |

O espaço de investigação está na avaliação dessa seleção em séries reais do recorte brasileiro e na integração de um protocolo rastreável. Não se afirma que selecionar políticas seja uma ideia inédita em inventário nem que a revisão esgote a literatura. O resultado deve ser uma evidência verificável sobre o ganho incremental da seleção, inclusive quando for pequeno ou ausente. O capítulo seguinte apresenta os dados, o ambiente e o protocolo para investigar essa questão.

# 4

# Metodologia

O AIPE organiza a comparação de políticas de reposição e propõe aprender quando cada alternativa deve ser recomendada. A metodologia liga séries de vendas, características operacionais, resultados de simulação e rótulos supervisionados. Os experimentos da Paraíba e da Bahia fornecem evidência sobre o portfólio; a generalização do *Policy Selection Engine* (PSE) permanece uma etapa a validar. Este capítulo distingue o procedimento proposto da execução documentada, para evitar atribuir aos resultados um alcance maior que o observado.

## 4.1 Visão Geral do AIPE

A unidade de decisão é a série loja–produto, identificada por armazém, loja e produto. O histórico preparado é transformado em um vetor de características, que descreve frequência, magnitude e estrutura temporal da demanda. Políticas candidatas são ajustadas e executadas no mesmo simulador. Seus custos e níveis de serviço fornecem rótulos para um meta-modelo de seleção. A Figura 4.1 reúne essas etapas.

Há dois usos distintos de aprendizado: agentes de reforço aprendem uma regra de pedido dentro do portfólio; o PSE procura aprender qual regra escolher para uma série. Melhorar um controlador não demonstra automaticamente utilidade do seletor. Da mesma forma, encontrar vencedores diferentes por série não prova que suas identidades sejam previsíveis em dados futuros. A comparação do AIPE precisa incluir a melhor política global viável e referências simples bem calibradas.

A previsão é um sinal auxiliar, não o critério de escolha final. O custo total de inventário (CTI) é minimizado sob uma restrição de nível de serviço (NS). Ruptura, variabilidade dos pedidos e frequência de reposição complementam a leitura. Essa organização permite investigar heterogeneidade, mas não antecipa uma vantagem para políticas complexas nem para seleção por perfil.

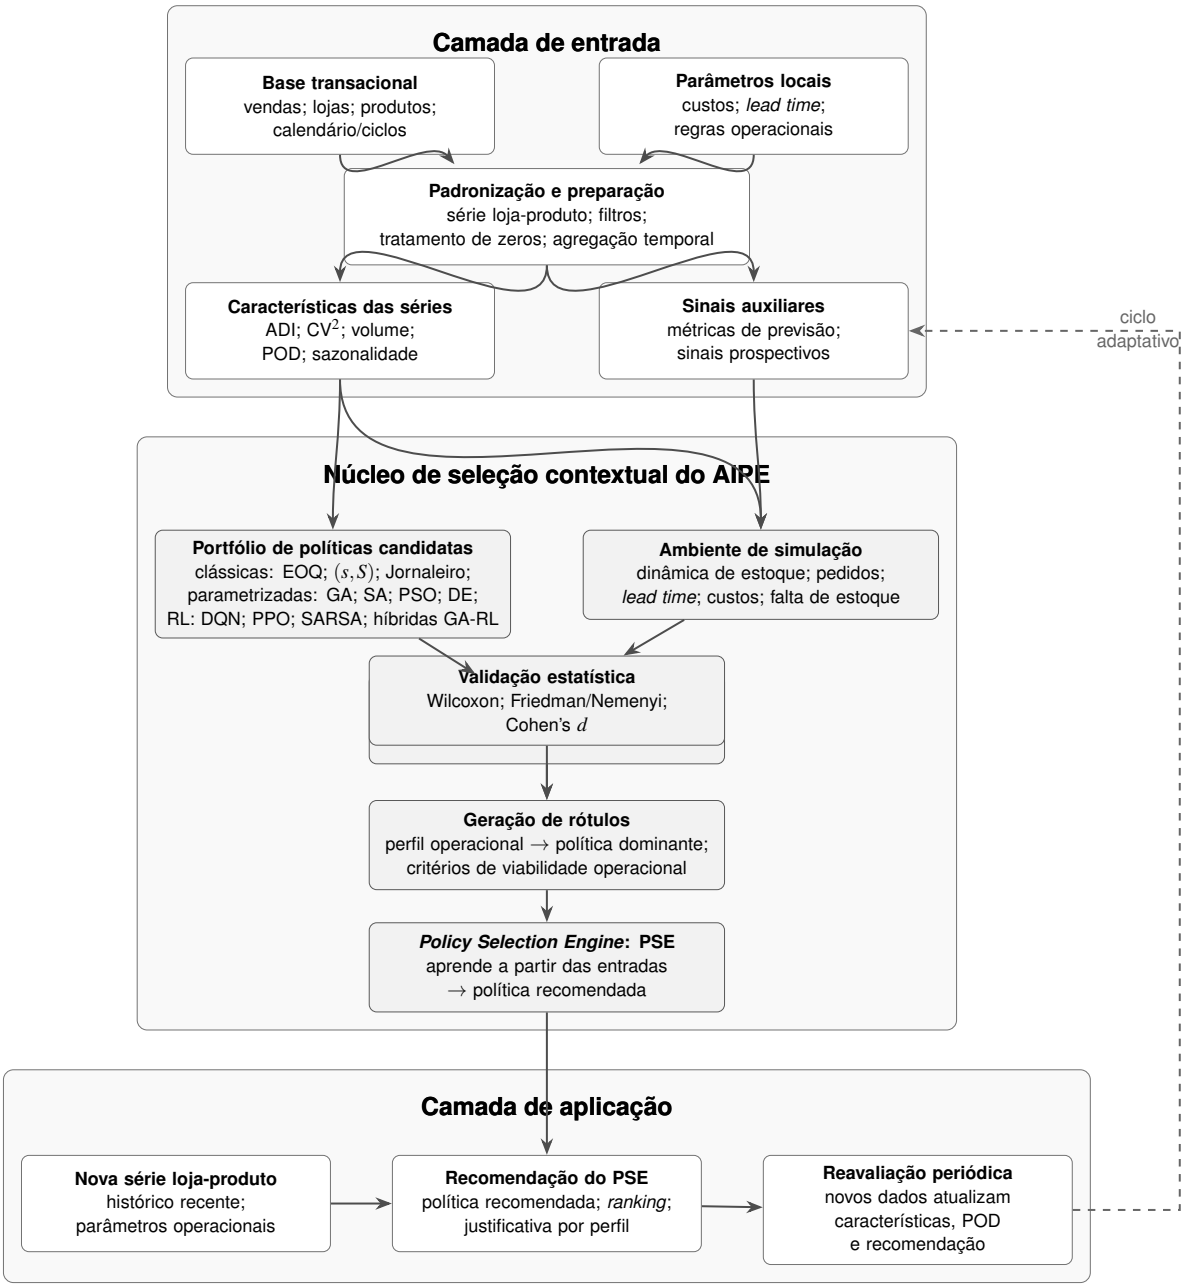



Figura 4.1: Arquitetura conceitual do *framework* AIPE. A camada de entrada reúne dados transacionais preparados, parâmetros operacionais, características das séries e sinais auxiliares de previsão de demanda. O núcleo de seleção contextual utiliza essas entradas para avaliar políticas candidatas, gerar rótulos de política dominante, realizar validação estatística e treinar o *Policy Selection Engine*. A camada de aplicação utiliza o PSE para recomendar políticas a novas séries loja-produto e reavaliar periodicamente as recomendações conforme novos dados se acumulam.

## 4.2 Instanciação Experimental do Problema de Inventário

### 4.2.1 Decisão e Ambiente

Para cada série $i$ e ciclo $t$, a política retorna $Q_{t,i} \geq 0$ a partir do estoque, da fila de pedidos e da informação passada de demanda. Regras de limiar usam a posição de estoque; agentes aprendidos recebem uma representação numérica do estado. A ação produz custos de ordenação no ciclo em que é emitida e altera o estoque disponível somente quando chega. A dinâmica de vendas perdidas segue a Equação 2.2.

O cenário empresarial inclui um armazém regional e lojas revendedoras com vários produtos. Entretanto, o simulador avalia cada série separadamente: não otimiza estoque compartilhado do armazém, capacidade de transporte ou competição entre lojas por suprimento. Os identificadores hierárquicos servem à rastreabilidade e à agregação. Medir variabilidade dos pedidos das lojas não equivale a validar um modelo integrado de múltiplos escalões.

**Definição 4.2.1 (Seleção Contextual de Política)** *Dado um portfólio $\Pi$, a representação $\phi$ e séries $\mathbf{d}_i$, o PSE proposto estima $f : \mathbb{R}^p \to \Pi$, com $f(\phi(\mathbf{d}_i)) = \hat{\pi}_i$. A referência de treinamento é a política de menor custo observado entre as que cumprem o serviço mínimo. Sua aplicação a novas séries depende de validação separada da construção desses rótulos.*

Os custos configurados são $h = 1$, $c_s = 5$, $c_o^{\text{fix}} = 50$ e $c_o^{\text{var}} = 0.5$. Esses valores definem um cenário experimental uniforme. A razão entre falta e manutenção expressa a penalização adotada, mas não comprova custos monetários reais da empresa. Sem calibração econômica, diferenças de CTI devem ser interpretadas como diferenças no objetivo simulado, mesmo quando os relatórios históricos usam a identificação de reais.

### 4.2.2 Métricas de Avaliação

Além do CTI definido na Equação 2.1, registram-se

$$\text{NS} = \frac{\sum_t (D_t - S_t)}{\sum_t D_t}, \qquad \text{TR} = \frac{\#\{t : S_t > 0\}}{T}, \qquad \text{FP} = \frac{\#\{t : Q_t > 0\}}{T},$$

e $\text{BE} = \text{Var}(Q)/\text{Var}(D)$. NS é a fração das unidades demandadas que foi atendida, não a probabilidade de um ciclo sem falta. TR mede a frequência de faltas; FP, a frequência de pedidos; BE, a amplificação da variância dos pedidos em relação à demanda. Variância de demanda nula exige uma convenção registrada, pois o quociente deixa de ter interpretação direta.

O limiar principal é $\alpha_{\min} = 0.70$. Na rotulagem por série, a restrição incide sobre o serviço daquela série; na escolha de uma política global ou por perfil, incide sobre a média do grupo. Essas regras não são equivalentes. Um grupo com NS médio acima do limiar pode conter

muitas séries abaixo dele. As tabelas devem informar média, distribuição e número de violações individuais, além do custo agregado.

Também se examina, de forma complementar,

$$J(\pi, g) = \mathrm{CTI}_{\mathrm{norm}}(\pi, g) + \lambda_{BE}\mathrm{BE}_{\mathrm{norm}}(\pi, g).$$

A normalização min–max precisa fixar o conjunto de políticas e o escopo usado para calcular extremos. Com $\lambda_{BE} = 0$, a ordenação equivale ao custo; pesos positivos favorecem estabilidade. Esse índice não tem unidade monetária e não substitui o CTI. A sensibilidade ajuda a mostrar como a preferência muda, sem demonstrar que um peso escolhido após observar resultados seja adequado à operação.

Uma interpretação conjunta é essencial: baixo custo com baixo NS pode refletir pouca reposição, e BE pequeno pode ocorrer porque quase não há pedidos. Esses padrões não são automaticamente descartados; são identificados nos indicadores e confrontados com restrições previamente definidas. Excluir um comportamento depois de observar seu desempenho mudaria o portfólio e precisaria de justificativa explícita.

## 4.3 Camada de Entrada: Dados e Pré-Processamento

### 4.3.1 Base de Dados

A fonte é uma base proprietária de vendas de uma rede varejista brasileira, organizada em ciclos comerciais. Os recortes avaliados compreendem 15 lojas da Paraíba para um produto e 145 combinações loja–produto da Bahia. O horizonte documentado contém 38 ciclos, de 202301 a 202504, com 17 ciclos comerciais por ano. Essa codificação deve ser convertida em uma ordem temporal consistente; não representa um calendário mensal comum.

Vendas observadas são usadas como aproximação da demanda. Se a loja ficou sem produto, a venda registrada pode ser menor que a intenção de compra. A simulação não reconstrói essa demanda censurada. Também é necessário diferenciar ausência de transação, ausência de registro e indisponibilidade da loja. Tratar todos esses casos como zero produz séries uniformes, mas introduz uma hipótese que afeta frequência, variância e perfis.

Os dados brutos não são disponibilizados publicamente. A reprodução depende de autorização para acesso ou de artefatos derivados permitidos, além de código, parâmetros e versão do ambiente. Resultados agregados preservam a descrição científica, mas não tornam uma análise integralmente reproduzível quando suas entradas continuam restritas. O estudo explicita esse limite, em vez de substituir disponibilidade de dados por uma lista de bibliotecas.

### 4.3.2 Preparação das Séries

O preparo consolida transações por armazém, loja, produto e ciclo. São removidos valores negativos ou registros incompatíveis com o recorte, conforme a configuração da execução. Quantidades repetidas entre arquivos precisam ser agregadas, não mantidas como observações distintas. O resultado é uma tabela de demanda por ciclo, acompanhada de metadados da série e do registro das exclusões aplicadas.

As séries são ordenadas e reindexadas nos ciclos do horizonte. Ciclos sem venda recebem zero na preparação histórica. Antes de usar essa convenção, verificam-se a cobertura da fonte e a distinção entre loja inativa e demanda nula. Séries inteiramente sem vendas não permitem comparar serviço pela razão de unidades atendidas. Sua exclusão, quando aplicada, é registrada como critério de amostragem, sem ocultar que altera a população analisada.

Critérios de atividade, volume, número de demandas positivas e variabilidade delimitam os cenários. Os filtros evoluíram entre execuções, portanto não se presume que uma descrição única, como CV mínimo, identifique todos os recortes. O manifesto deve registrar a condição efetivamente aplicada e a contagem antes e depois de cada filtro. A representação dos regimes e a distribuição geográfica dos cenários avaliados aparecem no Capítulo 5.

Para avaliação futura, critérios de inclusão precisam depender apenas do passado. Exigir produto ativo nos últimos ciclos do horizonte completo, por exemplo, usa informação que não estaria disponível no início da decisão. Mesmo que o modelo seja treinado em um prefixo, uma coorte selecionada com o futuro continua retrospectiva. Essa distinção é relevante para interpretar qualquer extensão temporal do experimento.

## 4.4 Características e Perfis Operacionais

O vetor de entrada resume a série sem substituir sua trajetória na simulação. Intermitência é representada por ADI, proporção de zeros e comprimentos de sequências sem demanda. Volume e dispersão incluem média, desvio-padrão, CV, quantidade de ciclos e de ocorrências positivas. Assimetria e curtose dos valores positivos descrevem tamanhos extremos; tendência, autocorrelação e entropia acrescentam informação sobre organização temporal e distribuição.

A implementação reúne cerca de 17 características principais, além de metadados e codificação do perfil; a dimensão final depende da seleção de colunas. Não se deve afirmar dimensão fixa depois de acrescentar atributos ou indicadores de previsão. As estatísticas são calculadas na mesma unidade de ciclo da série e suas convenções, incluindo amostra ou população no desvio-padrão, precisam acompanhar o vetor salvo.

Para intervalos $\tau$ entre demandas positivas, a concentração de ocorrências é resumida por

$$B = \frac{s_\tau - \bar{\tau}}{s_\tau + \bar{\tau}},$$

com regularização numérica quando necessária (Goh and Barabási, 2008). Valores positivos indicam intervalos mais variáveis que a média; negativos, maior regularidade. Poucos eventos não sustentam uma estimativa estável. A entropia $H = -\sum_k p_k \log_2 p_k$ usa um histograma de dez classes sobre todos os ciclos; não é calculada somente sobre demandas positivas.

A tendência é a inclinação de uma regressão temporal simples dividida pela média. A sazonalidade é resumida pela autocorrelação de lag 17, correspondente a um ano comercial. Uma janela de 17 ciclos não permite estimar essa autocorrelação com segurança; no código, janelas insuficientes recebem zero. O resultado significa ausência de estimativa, não demonstra ausência de sazonalidade.

Como explicado na Seção 2.3.1, a característica $CV^2$ do código inclui ciclos zero, enquanto a classificação original usa a dispersão dos tamanhos positivos. Mantêm-se os rótulos já arquivados para rastrear os resultados, mas sem apresentar equivalência exata entre as definições. Essa diferença também impede interpretar os limiares originais como uma validação automática da classificação operacional implementada.

### 4.4.1 Regras de Perfil

A Tabela 4.1 define cinco Perfis Operacionais de Demanda (POD). As regras são aplicadas na ordem apresentada: a primeira satisfeita determina o perfil. Uma série não enquadrada nas condições recebe a classe residual Sparse High Impact. Por esse motivo, nomes como “alta sazonalidade” e “tendência instável” são descritores heurísticos; não garantem que todas as séries do grupo possuam exatamente aquela propriedade.

Tabela 4.1: Regras hierárquicas dos Perfis Operacionais de Demanda.

| Perfil | Primeira condição satisfeita |
|---|---|
| Sparse High Impact | ADI $\geq 1.32$, $CV^2 \geq 0.49$ e maior sequência de zeros $\geq 5$ |
| High Volatility Seasonal | Autocorrelação de lag 17 $\geq 0.25$ ou $B \geq 0.30$ |
| Unstable Trend | Tendência normalizada absoluta $\geq 0.05$ ou $H \geq 2$ |
| Low Volume Stable | Média $\leq 2$ e $CV^2 < 0.49$ |
| Fast Moving | ADI $< 1.32$ |

O perfil organiza a análise e pode ser codificado como entrada do PSE. Não é uma recomendação fixa de controlador. A associação inicial entre nomes de perfis e políticas no código não substitui a seleção pela matriz de custo e serviço. Essa separação evita interpretar uma regra previamente atribuída, como “perfil sazonal recebe PPO”, como uma descoberta empírica do experimento.

Na Bahia, os artefatos de perfil apresentam 116 séries Sparse High Impact, 18 Unstable Trend e 11 High Volatility Seasonal. Essa concentração limita a informação disponível sobre grupos pequenos. Os limiares não foram aprendidos de uma grande população independente e

devem ser submetidos a sensibilidade. Se forem ajustados usando os mesmos resultados que avaliam o seletor, a comparação deixa de representar validação independente da representação.

## 4.5 Sinais Auxiliares de Previsão e Calibração

O projeto contempla Croston, ARIMA, redes neurais e XGBoost como fontes de previsão. Croston estima ocorrência e tamanho separadamente (Croston, 1972); modelos autorregressivos descrevem dependência temporal; modelos supervisionados utilizam janelas recentes. A configuração determina quais candidatos são executados em cada versão. Não se presume que todos tenham sido avaliados em cada recorte apenas porque estão disponíveis no código.

A comparação emprega MASE como métrica principal e sMAPE e RMSSE como complementares, conforme as definições do Capítulo 2. Nos artefatos históricos, a função de métricas usa diferenças da própria sequência avaliada como escala e exclui pares demanda/previsão ambos zero do sMAPE; essa convenção difere das definições de referência. A escolha do modelo deve ocorrer antes do bloco usado para avaliar a política, ou em validação interna. Se o erro de previsão integrar o PSE, ele precisa ser produzido sem observar a demanda que será usada para medir o resultado final da recomendação.

Também é necessário verificar o consumo desse sinal. A presença de um arquivo de previsões não prova que ele foi fornecido ao simulador. Quando nenhuma previsão externa é recebida, o ambiente usa uma referência ingênua baseada na demanda anterior, com inicialização por média. A metodologia distingue a previsão efetivamente usada, as métricas calculadas como diagnóstico e as entradas previstas para versões futuras do seletor.

Os valores de referência de reposição são derivados da média $\hat{\mu}$, do desvio $\hat{\sigma}$, do parâmetro $L$ e de $z = 1.28$:

$$I_0 = \hat{\mu}L + z\hat{\sigma}\sqrt{L}, \tag{4.1}$$

$$Q_{\text{ref}} = \sqrt{2\hat{\mu}T_{\text{cal}}c_o^{\text{fix}}/h}, \tag{4.2}$$

$$s_{\text{ref}} = \hat{\mu}L + z\hat{\sigma}\sqrt{L}. \tag{4.3}$$

$T_{\text{cal}}$ é a quantidade de ciclos usados na calibração do lote legado. A primeira expressão corresponde à escala do pipeline disponível; outros estoques iniciais aparecem em versões históricas e devem ser identificados pela execução. A expressão de $Q_{\text{ref}}$ acumula demanda no horizonte, embora $h$ seja por ciclo: não é a EOQ dimensionalmente uniforme $\sqrt{2\hat{\mu}c_o^{\text{fix}}/h}$. A diferença permanece registrada, sem reatribuir resultados antigos a uma fórmula corrigida.

Estoque inicial, limites de ação e região de busca afetam fortemente o desempenho em séries curtas. Um estoque inicial amplo pode elevar serviço sem exigir aprendizado, e um limite baixo de pedido pode impedir atendimento de picos. Em validação temporal, essas escalas

devem ser calculadas somente no treino. Usar média e desvio da série completa, mesmo mantendo o ajuste da política em um prefixo, introduz informação futura na avaliação.

## 4.6 Portfólio de Políticas Candidatas

### 4.6.1 Composição e Referências

O portfólio inicial contém EOQ, $(s,S)$, Jornaleiro, GA, SA, PSO, DE, DQN, PPO, SARSA, GA–DQN e GA–PPO. A configuração posterior mantém doze alternativas, porém substitui PSO, DE, SARSA e GA–PPO por CappedBaseStock, BigDataNewsvendor, FixedInterval e VendorResponsive. A contagem de políticas, isoladamente, não identifica um experimento: tabelas, configurações e arquivos precisam concordar sobre a lista de candidatos.

A revisão da composição busca referências competitivas e diversidade de decisões, em vez de aumentar o número de algoritmos semelhantes. CappedBaseStock é motivada por Xin (2021) e pelas comparações com aprendizado profundo discutidas por Temizöz et al. (2025). O Jornaleiro orientado a características se relaciona à otimização de decisão de Ban and Rudin (2019). A formulação PIL de van Jaarsveld and Arts (2024) é uma referência da literatura disponível para extensão, não um candidato do portfólio final de doze.

FixedInterval e VendorResponsive são interpretações das descrições de Zabraoui et al. (2025). A primeira usa revisão periódica e reposição até um alvo; a segunda ajusta a proteção de estoque pelo serviço passado. Como o artigo-base não fornece todos os detalhes numéricos dessas regras, a implementação local precisa declarar suas equações e parâmetros. Preservar o nome de uma política não comprova reprodução exata de outro estudo.

A redução do portfólio é uma escolha de escopo. Não permite afirmar inexistência de literatura sobre SARSA, PSO ou DE em inventário, nem que seus resultados seriam sempre redundantes. As versões excluídas permanecem disponíveis para análises futuras. O Apêndice A registra parâmetros e identificadores, enquanto o Capítulo 5 apresenta a composição associada a cada conjunto de resultados.

### 4.6.2 Regras Analíticas e Heurísticas

EOQ legado pede $Q_{\text{ref}}$ quando a posição de estoque cai até $s_{\text{ref}}$. A política $(s,S)$ utiliza esse mesmo limiar e alvo $S = s_{\text{ref}} + Q_{\text{ref}}$, pedindo até o alvo. Ambas herdam a escala de lote discutida na Equação 4.2. Uma comparação com a EOQ canônica precisa corrigir a unidade temporal antes de interpretar diferenças como vantagem de aprendizado.

O Jornaleiro implementado utiliza $\max(0, \hat{\mu} + 1.28\hat{\sigma})$ como lote e um ponto de pedido baseado em $\hat{\mu}L$. Trata-se de uma regra recorrente inspirada no quantil normal, não do ótimo de um problema de período único com razão crítica estimada. As versões CappedBaseStock e BigDataNewsvendor acrescentam alternativas de calibração, mas sua fidelidade à referência depende

de comparar hipóteses e procedimentos, não apenas o rótulo.

No FixedInterval, a revisão ocorre a cada três ciclos e o alvo cobre revisão mais reposição, com proteção proporcional à variabilidade. No VendorResponsive, o fator de segurança aumenta quando o serviço acumulado fica abaixo da meta interna e diminui quando fica acima. Essas regras oferecem referências simples adaptáveis. Nenhuma delas deve ser removida porque supera um método proposto; sua função é tornar a comparação exigente.

### 4.6.3 Busca de Parâmetros

GA e SA ajustam uma regra de ponto de pedido e lote, representada por $\boldsymbol{\theta} = (s, Q)$. O problema de referência é

$$\boldsymbol{\theta}_i^* = \arg\min_{\boldsymbol{\theta} \in \Theta_i} \mathrm{CTI}(\pi_{\boldsymbol{\theta}}, i) \quad \text{sujeito a } \mathrm{NS}(\pi_{\boldsymbol{\theta}}, i) \geq \alpha_{\min}. \tag{4.4}$$

A execução pode representar a restrição por penalidade ou usar uma soma ponderada de custo e serviço. Esses objetivos não são idênticos: uma solução favorecida pela aptidão ainda precisa ter a viabilidade verificada no critério de rotulagem. Os pesos e termos adicionais de risco fazem parte da versão experimental e não podem ser omitidos ao atribuir desempenho ao algoritmo.

A configuração recente do GA emprega 100 indivíduos e 50 gerações, seleção por torneio, cruzamento uniforme e mutação adaptativa. O artigo-base motiva esses operadores (Zabraoui et al., 2025), mas a regra local de redução da mutação é uma escolha de implementação. O SA usa temperatura inicial 1000, resfriamento 0.95 e 500 iterações. Os detalhes de espaço de busca, sementes e operadores estão no apêndice; não são repetidos como uma descrição de módulos computacionais.

O orçamento dessas buscas difere do orçamento de agentes de reforço. Avaliar milhares de candidatos completos não é equivalente a milhares de passos do simulador. A comparação deve registrar avaliações e tempo, além dos KPIs finais, especialmente quando a inicialização híbrida incorpora trabalho prévio do GA. Sem esse controle, um resultado favorável pode refletir maior esforço computacional.

### 4.6.4 Agentes de Reforço e Arquitetura Híbrida

O estado disponível reúne estoque, previsão ou demanda recente, pedidos em trânsito, média e dispersão recentes e posição no horizonte. Na implementação atual, DQN usa uma arquitetura Double DQN (van Hasselt et al., 2016) com componentes dueling (Wang et al., 2016); PPO usa estimação generalizada de vantagem (Schulman et al., 2016). A recompensa parte do custo negativo, podendo incorporar penalidades na versão específica.

Os parâmetros recentes incluem duas camadas de 64 unidades, memória de 10.000 transições e mil episódios para DQN, com exploração 0.2. PPO também usa mil episódios e clipping 0.2. O projeto atual discretiza quantidades admissíveis; não se atribui a esses resultados a

propriedade de ações contínuas apenas porque PPO permite essa formulação. Sementes, resolução de ações, taxas de aprendizado e atualização de alvos acompanham a configuração de reprodução.

GA–DQN utiliza a parametrização evolutiva para gerar experiências iniciais e depois refina o agente, com referência de mil transições e 200 episódios na configuração híbrida. As 5.000 avaliações candidatas do GA não equivalem ao tamanho da memória. A arquitetura é uma especialista do portfólio, motivada pelo artigo-base (Zabraoui et al., 2025); não constitui a novidade principal da seleção contextual.

Correções de operadores, penalidades e treinamento ocorreram durante o projeto. A descrição do código recente não prova que esse mesmo código gerou uma tabela anterior. Resultados associados a agentes degenerados são mantidos com sua versão; explicar sua causa exige ablações controladas. Episódios repetidos na demanda observada são interações sintéticas, não novas amostras de vendas nem validação de generalização.

### 4.6.5 Redundância e Classes de Rotulagem

Políticas muito semelhantes podem gerar rótulos instáveis quando pequenas diferenças numéricas decidem o vencedor. A análise prevista compara correlação de Spearman dos custos e diferença mediana relativa; correlação acima de 0.98 e diferença abaixo de 5% sinalizam possível redundância. Esse diagnóstico não basta para unir classes: é necessário conferir também serviço, regra de decisão e estabilidade em outros períodos.

Agrupar candidatos é uma decisão do conjunto de treinamento, não uma alteração retrospectiva dos resultados reportados. Se aplicado, o mapa de classes precisa ficar explícito e ser definido sem olhar o desempenho do teste. Uma política redundante em custo pode ser distinta em serviço; ocultar essa diferença enfraqueceria a interpretação do seletor.

## 4.7 Simulação, Validação Temporal e Estatística

### 4.7.1 Ambiente de Simulação

O simulador recebe demanda fixa, estoque inicial, fila vazia, custos e uma política. Em cada ciclo, a política decide usando o estado anterior à chegada. A primeira quantidade da fila é recebida e o novo pedido acrescentado; a demanda do ciclo é atendida com o estoque disponível; faltas são perdidas; manutenção incide sobre o saldo após demanda. Pedido fixo e variável são cobrados na emissão. Não há crédito pelo estoque ou pelos pedidos em trânsito ao final.

A fila contém $L+1$ posições. Assim, o parâmetro $L=2$ implica chegada do pedido de $t$ em $t+3$ nessa indexação. Não corresponde a uma entrega efetiva em dois ciclos, apesar da nomenclatura histórica. Manter a convenção entre candidatos favorece comparabilidade

interna, mas não elimina a necessidade de verificar sua aderência ao prazo real. Horizonte curto, estoque inicial e efeito terminal podem determinar parcela relevante do resultado.

Cada trajetória produz custos de manutenção, falta e pedido, além dos KPIs e históricos de estoque e ações. A decomposição permite conferir se os componentes somam o CTI. As políticas compartilham demanda e condições operacionais, mas seus procedimentos de calibração podem diferir. A execução também precisa registrar falhas de candidatos; excluir silenciosamente séries com erro rompe a matriz pareada.

### 4.7.2 Separação Temporal

Para previsão, uma avaliação de origem crescente usa apenas o prefixo anterior ao alvo:

$$\mathcal{S}_t = ((d_1, \ldots, d_t), d_{t+1}), \qquad t = T_{\min}, \ldots, T-1. \tag{4.5}$$

Essa divisão é necessária, mas não suficiente para prevenir vazamento. Normalização, imputação, perfis, estoque inicial, limites de ação e escolha de hiperparâmetros também precisam usar somente a informação disponível antes da avaliação. Uma figura de janelas não comprova que todas essas etapas respeitaram o protocolo.

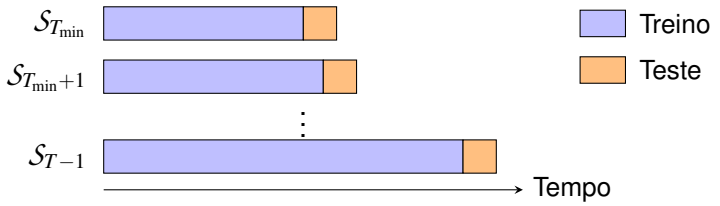



Figura 4.2: Protocolo *walk-forward*: a janela de treinamento cresce incrementalmente e o modelo é avaliado apenas em dados futuros, respeitando a ordem das observações na divisão entre treino e avaliação.

A documentação inicial menciona treino mínimo de 12 ciclos e até 26 alvos de previsão. A configuração posterior adota 17 ciclos e oferece tanto divisão única quanto ajuste por origem crescente. Esses modos não devem ser confundidos com uma única avaliação de controle. Os KPIs da matriz atual são compatíveis com um bloco de 21 ciclos após 17 de treino; a identificação final depende da configuração arquivada, não do número nominal de ciclos da série.

Há limitações residuais na execução histórica: escalas podem vir de metadados da série completa, perfis podem usar os 38 ciclos e o estado do ambiente pode normalizar pelo próprio bloco avaliado. Por isso, não se afirma avaliação integralmente livre de informação futura para as tabelas existentes. Uma nova execução rigorosa deve restringir todas as etapas ao passado e preservar um bloco final que não participe da escolha do seletor.

O treinamento de controladores, a seleção de uma política e a avaliação da recomendação exigem papéis temporais separados. O primeiro ajusta parâmetros; o segundo usa validação

para comparar candidatos; o último mede o resultado em demanda futura intocada. Avaliar o seletor com a mesma matriz que define seus rótulos mede ajuste retrospectivo. Mesmo a exclusão de uma loja da rotulagem não corrige informação futura já incorporada à calibração de suas políticas.

### 4.7.3 Inferência e Unidade Experimental

Wilcoxon compara pares de políticas nas mesmas séries; Friedman e Nemenyi comparam postos entre candidatos; tamanhos de efeito e diferenças absolutas descrevem relevância prática, conforme a Seção 2.5. Os testes usam nível nominal de 5%, com procedimento de comparações múltiplas identificado na execução. Estratificações exploratórias não devem produzir muitas declarações isoladas de significância sem considerar sua multiplicidade.

A unidade de observação é a série loja–produto. Séries da mesma loja e lojas que compartilham produtos ou condições comerciais podem ser dependentes. A análise deve reconhecer essa estrutura, por exemplo, mediante reamostragem por loja e verificações de sensibilidade. Não se obtém independência multiplicando o número de séries por repetições determinísticas.

O segundo experimento registra cinco avaliações nominais por política e série. O código treina ou otimiza o candidato antes de repetir a trajetória, e os desvios registrados de CTI são essencialmente nulos. Portanto, essas avaliações não são cinco treinamentos independentes nem justificam uma alegação de *common random numbers* como fonte de poder adicional. Para medir variabilidade de aprendizado, seriam necessárias sementes distintas de treinamento e resultados separados por semente.

## 4.8 Geração de Rótulos e PSE

### 4.8.1 Problema de Seleção

A formulação segue o problema de seleção de algoritmos de Rice (1976): descrever uma instância e escolher uma alternativa do portfólio. A discussão de portfólios (Huberman et al., 1997) motiva diversidade de candidatos. Os resultados de Wolpert and Macready (1997) não demonstram que qualquer perfil específico melhorará decisões; a utilidade da representação precisa ser testada na população estudada.

O alvo conceitual é

$$\hat{\pi}_i^* = \arg\min_{\pi \in \Pi} \mathbb{E}[\mathrm{CTI}(\pi, i)] \quad \text{sujeito a } \mathbb{E}[\mathrm{NS}(\pi, i)] \geq \alpha_{\min}. \tag{4.6}$$

Na matriz disponível, a esperança é aproximada pelo resultado registrado, não por uma distribuição comprovadamente estimada. O rótulo identifica a melhor candidata observada sob o limiar, não um ótimo universal. Se nenhuma atende ao serviço, registra-se inviabilidade; uma escolha

pelo maior NS é apenas fallback, com o déficit informado.

Custos empatados devem receber regra estável, preferindo serviço e, depois, um identificador fixo. Quando diferenças são muito pequenas, um conjunto de candidatas equivalentes pode ser mais adequado que uma classe rígida. A estabilidade dos rótulos diante de sementes, custos e períodos é parte da validação: acurácia alta ao reproduzir rótulos arbitrários não garante melhora operacional.

### 4.8.2 Treinamento e Avaliação Propostos

O conjunto supervisionado reúne $(\phi(\mathbf{d}_i), \hat{\pi}_i^*)$. XGBoost é o classificador principal previsto (Chen and Guestrin, 2016), com referência de 300 árvores, profundidade seis, taxa 0.05 e amostragem 0.8. LightGBM (Ke et al., 2017) e RandomForest são alternativas. A presença dessas implementações e de artefatos de ajuste não equivale à validação do PSE em escala nacional ou em produção.

A avaliação deve separar lojas e períodos, evitando que produtos da mesma loja apareçam simultaneamente no treino e no teste sem justificativa. Validação estratificada pode ser usada quando todas as classes têm suporte suficiente, mas não resolve dependência entre instâncias. Classes raras exigem estratégia explícita; excluí-las da validação e depois reportar desempenho global de treino ocultaria seu efeito.

Acurácia balanceada, F1-macro e F1 ponderado ajudam a interpretar desbalanceamento, mas o resultado principal do seletor deve ser custo e serviço das políticas recomendadas. Uma classe incorreta pode ter desempenho praticamente igual ao rótulo, enquanto uma escolha correta pode não cumprir o serviço no futuro. A comparação deve incluir o melhor candidato global escolhido na mesma validação, EOQ com unidades consistentes e seleção sem a variável de perfil.

O estudo também precisa separar métricas após ajuste em toda a amostra das métricas fora do ajuste. Probabilidades do classificador não são probabilidades calibradas de viabilidade de serviço. A importância das características pode indicar associações, mas não prova causalidade nem estabilidade entre períodos. Essas verificações integram a continuidade do trabalho, descrita no Capítulo 7.

### 4.8.3 Aplicação e Reavaliação

O produto previsto é uma política recomendada, um ranking de alternativas e um indicador de incerteza. Quando disponíveis, custos e serviços simulados acompanham a decisão como evidência condicionada ao cenário. Recomendações incertas ou inviáveis exigem nova análise; um limiar de confiança, como 0.50, é uma regra de triagem a calibrar, não comprovação de que o risco esteja controlado.

A adaptação proposta consiste em recalcular características e consultar o seletor em intervalos definidos, por exemplo a cada seis ciclos. Essa consulta não equivale a retreinar o modelo, e não há evidência de implantação contínua dessa rotina nos experimentos apresentados. Uma aplicação real também depende de disponibilidade da política no sistema, restrições empresariais e monitoramento do serviço realizado.

## 4.9 Escopo Experimental e Rastreabilidade

O piloto da Paraíba fornece 180 combinações de 15 lojas e 12 políticas, sob a versão inicial. A expansão da Bahia reúne 145 séries e um portfólio posterior também de 12 candidatas, com composição distinta. Os resultados pertencem a essas versões e recortes. Não são uma validação nacional, um experimento independente para cada repetição ou uma aplicação conjunta de todos os controladores implementados.

Cada execução deve associar dados, lista de políticas, parâmetros, semente, divisão temporal e versão do código. Arquivos de características, perfis, KPIs e recomendações têm funções diferentes; o relatório precisa indicar qual foi usado em cada tabela. Hashes de entrada e manifesto de execução ajudam a detectar troca de arquivos, mas não certificam, isoladamente, ausência de informação futura ou fidelidade do algoritmo.

O Apêndice A concentra a matriz de parâmetros e os artefatos necessários à reprodução. As fontes de vendas e PDFs de referência são preservadas. Correções recentes de código não sobrescrevem resultados históricos nem autorizam reinterpretá-los como novos experimentos. Uma comparação entre versões requer reexecução explícita sob protocolo congelado.

Há também resultados preservados para a base pública M5, discutidos no Capítulo 5. Eles constituem uma execução distinta, cuja configuração, horizonte, portfólio e validação precisam ser auditados antes de combinar suas conclusões com as da base real. A existência dos arquivos não implica reprodução do protocolo da Bahia nem validação independente do PSE. A expansão multiestado e novas avaliações temporais permanecem no plano de continuidade. O critério de avanço é demonstrar melhora em avaliação separada, com custo, serviço, incerteza e referências competitivas apresentados conjuntamente.

# 5

# Resultados Preliminares

Este capítulo reúne os experimentos da qualificação — piloto com 15 lojas da Paraíba e expansão para 145 séries da Bahia — e uma avaliação externa com 2.408 séries M5. A pergunta é se diferenças de demanda justificam escolher políticas distintas, considerando conjuntamente custo total de inventário (CTI), nível de serviço (NS), ruptura (TR), amplificação dos pedidos (BE) e frequência de reposição (FP). A diversidade de resultados motiva essa pergunta, mas não demonstra, por si só, que um seletor de políticas generaliza para séries novas.

A apresentação mantém os resultados históricos da qualificação e distingue seus critérios de comparação. CTI bruto, CTI acrescido de penalidades por indisponibilidade e excesso, e objetivo normalizado com penalização de BE são medidas diferentes. Os experimentos complementares desenvolvidos para o novo artigo não substituem esses resultados: utilizam outro portfólio e outro protocolo. A síntese abaixo privilegia as evidências decisivas e explicita as pendências de consistência que impedem interpretar todo o acervo como um único experimento reproduzido.

## 5.1 Escopo dos Experimentos

O piloto considera o produto 48130 em 15 lojas da Paraíba; a expansão abrange 145 combinações loja–produto da Bahia. Ambos usam horizonte de 38 ciclos comerciais e prazo configurado $L = 2$. A cobertura geográfica efetivamente avaliada restringe-se a esses estados. Mapas da rede nacional descrevem a disponibilidade potencial de dados, não uma validação do AIPE em escala nacional.

Na Bahia, as séries distribuem-se entre Calçada, Cajazeiras e Lauro de Freitas e seis segmentos comerciais. Calçada concentra 104 séries, aproximadamente 72% da amostra. Essa concentração limita a representatividade da média estadual: diferenças entre segmentos podem refletir volume e composição de produtos, além da política aplicada. Por isso, a interpretação

central usa os perfis de demanda, sem atribuir às filiais efeitos causais que o desenho não identifica.

Os documentos do Experimento 2 registram cinco repetições nominais por série e 12 políticas, totalizando 8.700 avaliações nominais. Isso não equivale a 8.700 observações independentes. A auditoria dos artefatos encontrou dispersão de custo praticamente nula entre repetições; logo, o número configurado de sementes não comprova variabilidade efetiva de treinamento ou de demanda. A unidade empírica continua sendo a série, com dependência possível entre produtos da mesma loja. Essa ressalva orienta a leitura dos testes históricos.

A descrição dos recortes também exige cuidado. O texto metodológico caracteriza a amostra avaliada como *Lumpy*, enquanto uma tabela-resumo anterior informava percentuais de 67% e 71%, incompatíveis com essa caracterização integral. Esses percentuais não são utilizados aqui. Permanecem pendentes a reconciliação dos filtros e a documentação do cálculo de ADI e $CV^2$, sobretudo da inclusão ou exclusão dos ciclos de demanda zero. As conclusões ficam restritas ao recorte operacional documentado, sem pressupor uma reprodução exata da taxonomia original.

## 5.2 Experimento 1: Estudo Piloto na Paraíba

O piloto foi usado para verificar o ambiente e identificar diferenças entre as políticas em séries de alta intermitência, com CV entre 2,5 e 5,4. A tabela completa permanece no Apêndice A, Tabela A.6; os resultados não foram transferidos para novos anexos nesta revisão. Nesse recorte, o GA-DQN apresentou CTI até 48% menor que $(s, S)$, ruptura 55% menor e BE de 5,0, contra 119,4. O NS foi 82,1%, frente a 84,3%: houve pequena perda de serviço, e não melhoria simultânea de todas as dimensões.

O percentual de 48% é um contraste específico do piloto, não um ganho médio do AIPE nem uma previsão de economia em outras lojas. Na Bahia, o GA-DQN apresenta custo maior e serviço menor que o EOQ na média. Essa mudança é relevante: o desempenho favorável de um híbrido em um produto não permite adotá-lo como solução padrão da rede. Também não comprova que o refinamento por perfil consiga antecipar corretamente o vencedor fora da amostra.

### 5.2.1 Diferenças por Volume

A estratificação das 15 lojas separou cinco de alto volume ($\hat{\mu} > 500$), seis de volume médio ($50 < \hat{\mu} \leq 500$) e quatro de baixo volume ($\hat{\mu} \leq 50$). Nas primeiras, o estoque inicial sustentou NS próximo de um para quase todas as políticas. O custo médio do EOQ foi R$ 85.956, contra R$ 45.739 para alternativas de menor frequência de pedidos. Como a condição inicial já oferece ampla cobertura, esse contraste deve ser lido também como sensibilidade à inicialização e ao horizonte, não somente como qualidade intrínseca dos algoritmos.

No estrato intermediário, o registro do GA-DQN combina NS de 0,933 e CTI de R$ 10.854. Nas lojas de menor volume, três não ultrapassam NS de 0,42 com as políticas avaliadas. O Jornaleiro é mais econômico nesse grupo, mas seu baixo custo não resolve a insuficiência de serviço. A amostra pequena e o uso da própria trajetória para análise impedem transformar esses padrões em regras universais de recomendação.

### 5.2.2 Aprendizado e Estabilidade

O piloto registrou PPO emitindo pedidos em 98% dos ciclos e SARSA sem reposição. Esses comportamentos apontam problemas de treinamento, recompensa ou implementação que precisam ser examinados antes de comparar famílias de algoritmos. Não constituem prova de que RL seja inadequado à demanda intermitente. A necessidade de muitas interações em estudos de inventário, discutida por Oroojlooyjadid et al. (2022), ajuda a situar o orçamento experimental, mas não identifica a causa dessas falhas locais.

A combinação com GA procurou fornecer uma configuração inicial mais favorável. O relato histórico associa a inicialização a 5.000 avaliações simuladas e treinamento de 200 episódios. Esses números descrevem o procedimento registrado; não isolam causalmente o efeito da inicialização. Seria necessária uma ablação com o mesmo orçamento, sementes verificadas e separação entre ajuste e avaliação. Também não se deve equiparar avaliações de soluções pelo GA a transições reais independentes nem tratar PPO e DQN como se compartilhassem o mesmo mecanismo de treinamento.

O BE complementa custo e serviço, mas requer interpretação conjunta. Pedir pouco pode reduzir sua variância enquanto aumenta faltas; pedir em grandes lotes pode garantir cobertura e amplificar a demanda a montante. Portanto, o BE menor de GA-DQN ou DQN não demonstra antecipação de picos sem examinar as trajetórias de estoque, demanda atendida e pedidos. O piloto cumpriu seu papel de diagnóstico e motivou a expansão, mantendo abertas as questões de robustez.

## 5.3 Experimento 2: Expansão na Bahia

### 5.3.1 Comparação Agregada

A Tabela 5.1 preserva os valores do portfólio histórico de 12 políticas. Ela descreve médias sobre as séries, não o efeito de um seletor aprendido. Os nomes correspondem às implementações avaliadas; não certificam, por si, a reprodução de uma política ótima de referência. A comparação precisa considerar as condições de estoque inicial, prazo, custos e calibração comuns ao recorte.

O menor CTI pertence ao DQN, que apresenta FP igual a zero e NS de 0,23. Trata-se de uma solução de baixo atendimento, inadequada ao limiar médio de 0,70 adotado. O Jornaleiro

Tabela 5.1: Indicadores médios do recorte histórico BA: 12 políticas, 145 séries. As cinco repetições nominais não são tratadas como observações independentes. †DQN sem pedidos.

| Política | CTI (R$) | NS | TR | BE | FP |
|---|---|---|---|---|---|
| DQN† | **126.73** | 0.23 | 0.40 | 1.87 | **0.00** |
| Jornaleiro | 289.92 | 0.54 | 0.29 | 0.71 | 0.18 |
| Vendor-Responsive | 433.31 | 0.77 | 0.16 | 1.14 | 0.30 |
| Fixed Interval | 457.81 | 0.84 | 0.11 | 2.13 | 0.30 |
| Capped Base-Stock | 561.87 | 0.64 | 0.24 | 0.43 | 0.43 |
| Jornaleiro (*Big Data*) | 582.11 | 0.72 | 0.19 | 3.50 | 0.37 |
| **EOQ** | 628.42 | 0.94 | 0.05 | 55.43 | 0.05 |
| $(s, S)$ | 654.86 | 0.94 | 0.05 | 58.62 | 0.05 |
| SA | 1.147,86 | 0.86 | 0.10 | 21.70 | 0.90 |
| GA-DQN (Híbrido) | 1.175,79 | 0.73 | 0.19 | 0.16 | 0.98 |
| GA | 1.265,38 | 0.90 | 0.07 | 0.16 | 0.97 |
| PPO | 5.112,75 | **0.96** | **0.02** | 14.12 | 0.97 |

também fica abaixo desse limiar, com NS de 0,54. Em contrapartida, *Vendor-Responsive* e *Fixed Interval* combinam custos inferiores ao EOQ com menor serviço. Ambas ultrapassam 0,70 na média global; isso não garante que cada série cumpra a restrição.

O EOQ e $(s, S)$ alcançam NS próximo de 0,94, acompanhados de BE elevado. O PPO oferece o maior NS reportado, 0,96, com custo muito superior. GA e GA-DQN têm BE próximo de 0,16, mas essa estabilidade não compensa automaticamente seu custo. Na média da tabela, o GA-DQN custa mais e atende menos que o EOQ: nessas duas dimensões, é desfavorecido, e não representa um compromisso vantajoso. Sua eventual utilidade precisaria aparecer em outro indicador ou estrato devidamente justificado.

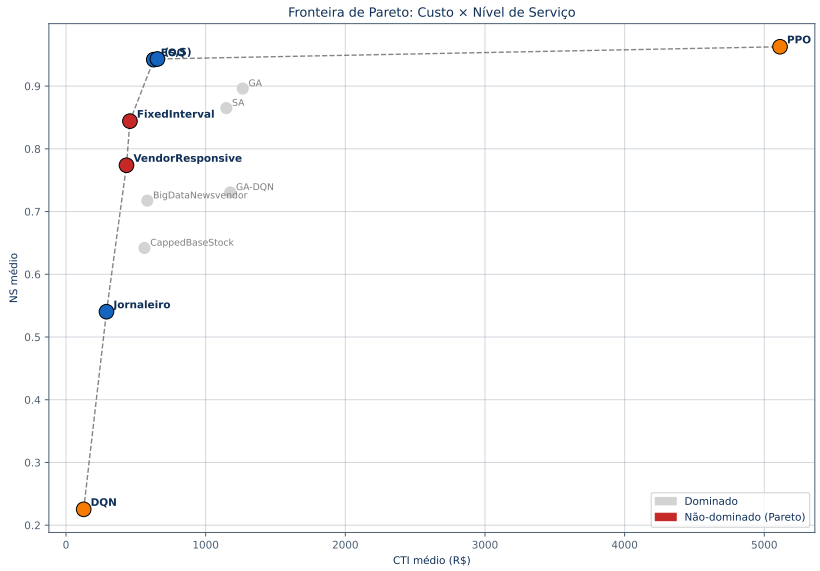



Figura 5.1: Custo e serviço médios no recorte histórico BA. A comparação indica diferentes pontos de operação; não comprova desempenho de seleção em séries novas.

A Figura 5.1 sintetiza esses pontos de operação. Nenhuma política reúne o menor custo e o maior serviço da tabela, mas isso não implica que todas sejam eficientes nem que cada série necessite de uma política diferente. A escolha depende da exigência de atendimento e da métrica econômica adotada. Em particular, comparar um método com uma referência de serviço mais alto pode produzir economia aparente sem melhorar a fronteira custo–serviço.

### 5.3.2 Comparação por Perfil Operacional

O refinamento por Perfis Operacionais de Demanda (POD), descrito na Seção 4.4, separa 116 séries *Sparse High Impact*, 18 *Unstable Trend* e 11 *High Vol. Seasonal*. Os dois últimos grupos são exploratórios. Os perfis *Low Vol. Stable* e *Fast Moving* não aparecem nesse recorte. A Tabela 5.2 usa o CTI ajustado por indisponibilidade e excesso, entre candidatos cujo NS médio no perfil atinge 0,70.

Tabela 5.2: Política de menor CTI ajustado por perfil no recorte histórico BA, condicionada a NS médio $\geq 0{,}70$. Custos médios em R$. Grupos com menos de 20 séries são exploratórios.

| Perfil | $n$ | Política | CTI | CTI ajustado | NS |
|---|---|---|---|---|---|
| Sparse High Impact | 116 | EOQ | 632,51 | 908,05 | 0,939 |
| Unstable Trend | 18 | EOQ | 607,95 | 836,73 | 0,947 |
| High Vol. Seasonal | 11 | Fixed Interval | 422,93 | 426,12 | 0,907 |

O EOQ é selecionado em 134 das 145 séries, por meio dos dois primeiros perfis. A diferença de escolha concentra-se nas 11 séries *High Vol. Seasonal*. Esse resultado é mais restrito que afirmar uma ampla especialização do portfólio: no critério ajustado, a estratificação modifica uma fração pequena das decisões. A denominação do perfil também não comprova sazonalidade observável; ela deriva das regras de caracterização, cuja estabilidade precisa ser avaliada em históricos curtos.

O Jornaleiro tem custo bruto inferior, mas seu serviço médio insuficiente o exclui da seleção viável. Já a alteração de vencedor entre CTI bruto e ajustado decorre de uma mudança explícita de objetivo: as penalidades acrescentam informação sobre indisponibilidade e excesso. Não se pode comparar as duas ordenações como se uma corrigisse estatisticamente a outra. A interpretação deve informar sempre o custo utilizado e o nível no qual a viabilidade é imposta.

### 5.3.3 Política Única versus Seleção por Perfil

A estratégia A1 escolhe a política global de menor custo ajustado entre as viáveis; A2 fixa EOQ como referência. No recorte desta tabela, ambas coincidem. A estratégia B aplica o vencedor de cada perfil, e C escolhe retrospectivamente por série dentro do portfólio. O percentual de redução é calculado em relação à referência global, preservando a distinção entre custo médio e total.

Tabela 5.3: Comparação histórica por CTI ajustado: penalidades de indisponibilidade e excesso. C é referência retrospectiva, sem garantia de implementação ou generalização.

| Estratégia | CTI ajustado total | Média | NS médio | Redução |
|---|---|---|---|---|
| A1: melhor única viável | 129.791,42 | 895,11 | 0,942 | 0,0% |
| A2: EOQ | 129.791,42 | 895,11 | 0,942 | 0,0% |
| B: seleção por perfil | 125.082,77 | 862,64 | 0,938 | 3,6% |
| C: oráculo por série | 64.007,39 | 441,43 | 0,700 | 50,7% |

A redução descritiva de 3,6% da estratégia B resulta da substituição do EOQ por *Fixed Interval* no grupo de 11 séries. O NS médio passa de 0,942 para 0,938. A variação pequena não autoriza concluir ausência de perda, equivalência de serviço ou ganho líquido garantido. Como as políticas e os perfis são escolhidos com resultados do próprio conjunto, a tabela mede ajuste retrospectivo. Não mede transferência da recomendação a uma loja ou período ainda não observado.

O oráculo amplia a redução aparente, mas opera com NS médio de 0,700. É uma referência ex post dentro do portfólio, condicionada ao objetivo e à restrição utilizados; não é um limite teórico do problema de inventário. Seu desempenho não pode ser atribuído ao PSE, que ainda precisa ser treinado e validado. Tampouco a distância até esse oráculo mede um ganho que um modelo supervisionado necessariamente alcançaria.

Para uma aplicação operacional, a restrição também precisaria expressar a exigência da rede. NS médio de um perfil pode ser aceitável para uma análise exploratória e insuficiente para itens críticos de uma loja específica. As médias da tabela não mostram quantas séries ficam abaixo do alvo, nem o volume de demanda associado a essas faltas. Uma avaliação futura deve registrar ambos e distinguir média por série de atendimento ponderado pelo volume. Assim, a regra de viabilidade pode ser julgada pelo objetivo empresarial, sem escolher o limiar depois de observar a economia. A qualificação adota 0,70 como parâmetro de análise, não como garantia universal de serviço adequado.

Há três conjuntos de números no acervo que devem permanecer separados. O resumo de validação anterior reportava redução de 6,2% em CTI bruto; a tabela aqui preservada reporta 3,6% em CTI ajustado; a sensibilidade por estabilidade normaliza CTI e BE e varia $\lambda_{BE}$. São versões ou objetivos distintos. As diferenças de portfólio e de função objetivo exigem reconciliação de código, parâmetros e dados antes de se apresentar uma estimativa única consolidada. Esta revisão textual não preenche essa lacuna com resultados de outro experimento.

## 5.4 Validação e Limites da Inferência

Os artefatos incluem testes de Wilcoxon com correção de Holm, tamanhos de efeito e agrupamentos de Friedman–Nemenyi. Sua interpretação exige identificar a unidade pareada, a dependência entre observações e a versão exata dos resultados. Repetições numericamente

idênticas não ampliam o tamanho amostral efetivo. Além disso, comparar séries de uma mesma loja como independentes pode subestimar incerteza; a correção de múltiplos testes não resolve esse problema de dependência.

A tabela histórica de estratégias registra $p_{\mathrm{Holm}} = 0{,}020$ para CTI bruto e ajustado e 0,111 para NS. Entretanto, a narrativa anterior também afirmava ausência de diferença significativa em custo e diferenças significativas de serviço, leitura incompatível com essa tabela. Por isso, os testes não são utilizados aqui como confirmação de benefício operacional. É necessário regenerá-los a partir de uma única versão, com pareamento e hipóteses documentados. Ausência de significância em NS tampouco prova preservação de atendimento.

As proporções históricas de testes significativos para GA-DQN e GA-PPO foram retiradas da síntese porque misturavam candidatos e versões diferentes do portfólio da Tabela 5.1. Contar rejeições de hipóteses, mesmo após ajuste, não informa se o método é melhor na direção relevante nem se a diferença tem utilidade econômica. Da mesma forma, um efeito padronizado grande pode representar custo maior e serviço menor. As médias preservadas permitem reconhecer essa direção sem transformar significância em ranking de qualidade.

A principal evidência disponível é, portanto, descritiva: as políticas ocupam pontos distintos de custo e serviço, e a seleção por perfil altera poucas decisões no critério ajustado. Para sustentar generalização, será necessário separar treinamento, escolha do seletor e avaliação temporal, preservando agrupamentos de loja e verificando a variabilidade real dos métodos. Essa etapa é diferente de repetir a mesma simulação ou calcular novos testes sobre a mesma matriz.

## 5.5 M5: Evidência Externa Disponível após a Qualificação

Além dos recortes brasileiros, os artefatos M5 disponíveis contêm 2.408 séries de 287 produtos *FOODS*, em dez lojas dos estados CA, TX e WI, com 93 ciclos por série e 28.896 pares série–política. A classificação armazenada inclui 2.350 séries *Lumpy*, 33 *Erratic*, 24 *Smooth* e uma *Intermittent*. A base pública complementa a evidência regional proprietária, sem substituí-la.

A configuração atual agrega vendas diárias em blocos de 21 dias, seleciona *FOODS* com filtro de CV e aplica truncamento superior por $1{,}5 \times \mathrm{IQR}$. Declara separação de 19 ciclos de treino e restante de avaliação. Contudo, suavização e seleção consultam a série completa; a correspondência integral entre configuração e execução histórica precisa ser fixada por versão. O recorte não reproduz exatamente o experimento de Zabraoui et al. (2025): compartilhar o M5 não iguala frequência, filtros, custos ou treinamento.

Somente SA e PPO superam NS médio de 0,70 nessa tabela; o atendimento baixo das demais políticas impede interpretar seus menores custos como vantagem. Os contrastes diferem dos brasileiros e reforçam a necessidade de auditar o protocolo, sem demonstrar transferência do PSE. Não comparamos custos absolutos entre bases: horizontes, escalas e parametrização

Tabela 5.4: M5: médias por política nos artefatos disponíveis. CTI relativo é a razão entre o CTI médio da política e o do EOQ, exclusivamente dentro do M5.

| Política | CTI relativo ao EOQ | NS médio |
|---|---|---|
| Jornaleiro | 0,892 | 0,084 |
| Vendor-Responsive | 0,898 | 0,100 |
| Capped Base-Stock | 0,928 | 0,098 |
| Fixed Interval | 0,942 | 0,100 |
| DQN | 0,993 | 0,076 |
| EOQ | 1,000 | 0,133 |
| $(s, S)$ | 1,004 | 0,134 |
| Jornaleiro (Big Data) | 1,005 | 0,096 |
| GA | 1,190 | 0,231 |
| GA-DQN | 1,271 | 0,467 |
| SA | 3,127 | 0,852 |
| PPO | 3,563 | 0,985 |

divergem. As repetições também apresentam dispersão praticamente nula. Esses resultados externos já existem; permanecem pendentes sua reprodução independente e uma avaliação temporal sem informação futura no pré-processamento.

Em 2.213 das 2.408 séries (91,9%), os primeiros 19 ciclos não têm demanda, embora todas tenham demanda na avaliação: predomina partida sem histórico positivo. Os orçamentos também divergem: M5/BA usam GA de 500/50 gerações, SA de 100/500 iterações e híbrido de 30/200 episódios. O contraste não isola transferência entre bases nem prova falha universal dos algoritmos.

## 5.6 Previsão como Sinal Auxiliar

O módulo de previsão fornece características de previsibilidade, não a regra final de reposição. A Tabela 5.5 preserva médias históricas. O código escala MASE/RMSSE por diferenças da própria série de teste, não pela referência ingênua de treino; sMAPE exclui casos $0/0$. Valores abaixo de um não comprovam superioridade sobre uma referência convencional validada.

Tabela 5.5: Métricas históricas de previsão sobre 145 séries BA. Os rótulos MASE/RMSSE usam a escala implementada no teste; não validam comparação convencional com previsão ingênua. sMAPE em %.

| Modelo | MASE | sMAPE (%) | RMSSE |
|---|---|---|---|
| LSTM | 0.76 | 193.5 | 0.86 |
| XGBoost | 1.05 | 148.8 | 0.99 |
| ANN | 1.12 | 135.8 | 0.99 |

O LSTM apresenta os menores indicadores rotulados MASE e RMSSE; o ANN, e não o XGBoost, tem o menor sMAPE. Não há superioridade do LSTM em todas as métricas. Em

séries esparsas, sMAPE próximo de 200% exige atenção ao tratamento de zeros e não deve ser chamado de pouco sensível à intermitência.

Esses números pertencem às implementações históricas. Alterações posteriores no código de previsão não validam retroativamente as métricas, e o nome LSTM não basta para garantir equivalência entre versões. A reprodução deve fixar implementação, janelas, escala, hiperparâmetros e política de atualização. Mesmo uma previsão superior não demonstra melhor decisão de estoque sem avaliar o custo e o serviço decorrentes. Por isso, os resultados auxiliares não são usados como prova da eficácia do PSE.

## 5.7 Alcance e Continuidade

Os experimentos ampliaram o diagnóstico de um produto na Paraíba para 145 séries na Bahia, mas a diversidade regional, temporal e de regime permanece limitada. Os 38 ciclos disponíveis dificultam avaliar sazonalidade, mudanças estruturais e aprendizado persistente. O estoque inicial, a ausência ou presença de valor terminal e a convenção de prazo podem afetar os resultados. O parâmetro $L = 2$ deve ser interpretado pela ordem de eventos do simulador, não automaticamente como dois ciclos efetivos de espera.

Custos de falta, manutenção e pedido controlam o compromisso observado. Os valores parametrizados não demonstram economia monetária efetivamente realizada pela empresa; relações diferentes podem alterar o vencedor. Além disso, vendas observadas podem omitir demanda não atendida, e completar ciclos ausentes com zeros pode confundir falta de registro com ausência de demanda. Essas limitações atingem tanto a caracterização dos perfis quanto a comparação das políticas.

A contribuição empírica atual é organizar alternativas conhecidas sob um problema operacional comum e identificar condições em que suas escolhas divergem. A evidência não confirma uma vantagem geral do GA-DQN, um seletor supervisionado pronto ou economias nacionais. A consolidação do M5 já disponível e a expansão multiestado, discutidas no Capítulo 7, exigem protocolo próprio e critérios de validação definidos antes da análise de teste.

O próximo passo científico é congelar um conjunto coerente de dados, código, portfólio e objetivos, regenerar indicadores e testar decisões em períodos não usados na escolha. Isso permitirá distinguir três questões hoje parcialmente sobrepostas: qual política funciona melhor, se o perfil prevê essa diferença e se a recomendação preserva o atendimento desejado. Uma resposta negativa à segunda questão também é informativa e deve ser relatada sem adaptar o critério para recuperar um ganho.

# 6

# Conclusões

Esta dissertação propõe o AIPE para investigar a escolha de políticas de reposição a partir das características de séries loja-produto. O trabalho reúne preparação de dados, perfis operacionais e comparação de políticas em um ambiente comum. Seu componente supervisionado, o PSE, permanece em desenvolvimento e avaliação; os experimentos não validam um recomendador implantado nem garantem vantagem em novas séries.

## 6.1 Síntese dos resultados

O piloto avaliou 15 lojas da Paraíba e um produto. A expansão para a Bahia abrangeu 145 séries. Os dois recortes mostram que custo, serviço e variabilidade dos pedidos reagem de forma diferente à política utilizada. Essa observação motiva a seleção contextual, mas não prova que um seletor supera uma política única bem escolhida.

No piloto, a redução de custo de até 48% atribuída ao GA–DQN é um resultado histórico de uma comparação e implementação específicas, acompanhado por um compromisso de serviço. Não representa economia média para toda a rede nem permite separar automaticamente o efeito da arquitetura dos parâmetros e do ambiente. Resultados de diferentes versões do portfólio exigem identificação dos artefatos antes de qualquer comparação.

A análise por perfil depende do serviço exigido. Uma política pode ser barata porque atende menos demanda; permanecer acima de um limiar médio não garante atendimento mínimo em cada série. Ganhos precisam ser apresentados com variação do serviço, casos abaixo do limiar e uma referência global competitiva. Diferenças estatísticas não eliminam essas condições de interpretação.

A avaliação externa do M5 reúne 2.408 séries de alimentos. Apenas SA e PPO atendem ao limiar médio de serviço de 0,70 nesse recorte. O contraste com a Bahia é condicionado pela ausência de demanda no prefixo de ajuste de 91,9% das séries M5 e pelos diferentes orçamentos dos algoritmos.

A dominância por perfil da Tabela 5.2 descreve o recorte avaliado. Os perfis menores têm alcance exploratório, e a concentração no regime *lumpy* limita a generalização. O protocolo de cinco execuções não equivale a cinco amostras independentes quando os resultados são determinísticos ou praticamente iguais. A evidência está ligada às séries e às dependências entre elas, não apenas ao total de linhas produzidas.

## 6.2 Contribuições e limitações

A primeira contribuição é a formulação de uma avaliação contextual: caracterizar a série, comparar alternativas viáveis e testar se a representação ajuda a escolher uma política. A segunda é o estudo empírico em dados proprietários de varejo brasileiro. A terceira é a infraestrutura integrada para preparar dados, executar simulações e organizar resultados com configurações rastreáveis.

Políticas clássicas, meta-heurísticas e aprendizado por reforço são componentes conhecidos. As arquiteturas híbridas GA–RL também não são contribuições algorítmicas originais. O valor do portfólio depende da implementação, da força dos comparadores e da transparência sobre treinamento e avaliação.

A reprodutibilidade exige congelar versões, parâmetros e entradas. Uma correção no código atual não comprova retrospectivamente saídas anteriores. Uma tabela de política dominante calculada no próprio histórico também não valida o PSE. Essa etapa requer separar dados usados na calibração, na escolha e no teste.

Outras limitações decorrem do horizonte curto, de vendas possivelmente censuradas por falta e de custos definidos para simulação. A análise trata produtos separadamente e não otimiza capacidade, transporte ou coordenação entre escalões. Dados proprietários restringem verificação externa. Os artefatos M5 disponíveis ampliam a possibilidade de replicação, mas precisam de auditoria do protocolo antes de fundamentar conclusões de validade externa.

## 6.3 Implicações e continuidade

O uso operacional exige decidir primeiro qual serviço preservar e em qual nível: média do grupo, média ponderada pela demanda ou garantia por série. A escolha deve ser comparada com a melhor alternativa global disponível, observando custo, estabilidade e faltas. Uma melhoria frente a uma referência fraca pode decorrer apenas de menor atendimento.

A próxima etapa é validar a seleção em períodos futuros, ajustando características e políticas apenas sobre o passado. O M5 permite examinar dados públicos; recortes brasileiros adicionais podem testar diferenças regionais. Nenhuma expansão confirma antecipadamente a hipótese. O plano do Capítulo 7 prioriza consolidação dos artefatos, validação temporal e treinamento do PSE antes de atribuir ao AIPE um benefício operacional generalizável.

# 7

# Plano de Continuidade e Cronograma

A continuidade prioriza transformar a comparação exploratória da qualificação em uma avaliação verificável da seleção de políticas. Isso exige identificar quais resultados pertencem a cada versão experimental, separar escolha retrospectiva de teste futuro e avaliar o PSE com comparadores fortes. Ampliar a base só será útil se essas condições forem preservadas.

## 7.1 Consolidação da etapa empírica

Os estudos da Paraíba e da Bahia estabeleceram o ambiente inicial, o processamento em Kedro e as análises por perfil. Antes de novas conclusões, será consolidado um manifesto com entradas, versões do código, políticas ativas, parâmetros e saídas. Tabelas de portfólios diferentes não serão combinadas. Resultados que não possam ser recompostos permanecerão identificados como históricos.

A auditoria verificará eventos do simulador, custos, estoque inicial e terminal, unidades de tempo e serviço em séries sem demanda. O número de execuções não substituirá a demonstração de variabilidade entre sementes. Políticas determinísticas serão avaliadas como tais. Correções exigirão novas execuções antes de atribuir os resultados à versão corrigida.

## 7.2 Validação temporal e estudos adicionais

O protocolo seguinte separará calibração, validação e teste em ordem temporal. Perfis, previsões e parâmetros serão calculados apenas no passado disponível. A validação servirá à escolha de políticas e hiperparâmetros; o teste permanecerá reservado à avaliação. Múltiplos cortes poderão reduzir a dependência de uma janela curta.

A comparação principal será entre seleção contextual e a melhor política global viável na mesma validação. Referências tradicionais e escolhas retrospectivas por série terão funções

distintas: as primeiras situam o desempenho; as últimas indicam uma oportunidade idealizada, sem serem tratadas como políticas implantáveis. Custo e serviço serão reportados conjuntamente, com frequência de violações individuais.

### 7.2.1 M5: consolidação dos experimentos públicos

O M5 oferece dados reais de varejo e uma referência próxima ao estudo de Zabraoui et al. (2025). O projeto já dispõe de artefatos experimentais M5, produzidos após a etapa inicial da qualificação. Sua consolidação deve conferir recorte, políticas, custos, frequência temporal e tratamento das séries. Usar a mesma base de outro artigo não garante comparação direta quando esses elementos diferem.

O recorte documentado de 2.408 séries de alta intermitência será confrontado com as saídas disponíveis antes de integrar conclusões. A concentração em um perfil também precisa ser considerada: muitas séries não compensam baixa diversidade de contextos. O conjunto público permite que terceiros examinem o protocolo e reproduzam uma versão independente do experimento. Sua disponibilidade não significa que o PSE já tenha sido validado.

### 7.2.2 Expansão multiestado

A expansão brasileira será feita em recortes documentados por estado, produto e atividade, respeitando memória e tempo de execução. O objetivo é avaliar estabilidade entre contextos, não maximizar cobertura geográfica. Filtros e quantidades serão registrados sem confundir transações, combinações potenciais e séries realmente simuladas.

Estados ou lojas reservados para teste não participarão do ajuste do seletor. Dependências por produto e loja serão consideradas na interpretação. Dados proprietários permanecerão sujeitos às permissões de uso e divulgação; ampliar sua cobertura não elimina vieses da mesma fonte de coleta.

## 7.3 Treinamento e avaliação do PSE

O PSE receberá características calculadas antes da decisão. Seus rótulos serão derivados de custo e serviço apenas nos dados destinados ao ajuste. A avaliação incluirá acerto de escolha, arrependimento de custo e violações de serviço: prever um rótulo corretamente não garante uma diferença econômica relevante.

Modelos supervisionados serão comparados com política global, regras por perfil e modelos simples. A separação respeitará tempo e agrupamento por loja. Seleção de variáveis, hiperparâmetros e interpretação não usarão o teste. Perfis com poucas séries exigirão agrupamento, fallback explícito ou interpretação exploratória.

### 7.3.1 Calibração agrupada por perfil

Agrupar séries para calibrar parâmetros é uma pergunta diferente de selecionar uma política por perfil. Análises preliminares dessa calibração serão mantidas separadas, com seus artefatos conferidos. A comparação usará os mesmos cortes e orçamentos para ajuste individual e agrupado, reportando custo, serviço e sensibilidade por família.

Um resultado favorável não será descrito como robustez geral. Inversões entre janelas, pouca representação e alterações do algoritmo devem aparecer no relatório. Só após essa verificação será possível avaliar se o agrupamento reduz variância de estimação ou favorece apenas determinado recorte.

## 7.4 Sensibilidade e eficiência computacional

Custos de falta e manutenção, prazo, estoque inicial, tratamento terminal, limiares dos perfis e serviço mínimo serão variados de forma documentada. A análise distinguirá média por série, atendimento ponderado pela demanda e exigências individuais. Um mapa de recomendação indicará condições favoráveis e situações sem evidência suficiente.

A otimização em janela móvel atualizará parâmetros apenas com observações disponíveis. GPU poderá acelerar redes e avaliações vetoriais quando houver benefício mensurável; heurísticas pequenas poderão continuar em CPU. Orçamento, tempo e hardware serão registrados para não confundir velocidade com qualidade decisória.

## 7.5 Escrita e produção científica

A versão final consolidará resultados auditados e limites de generalização. O material do SBPO foi arquivado e não integra o plano ativo de submissão. O novo artigo para *Supply Chain Analytics* é uma frente própria, apoiada por revisão metodológica, científica e editorial. Seus resultados não serão transferidos automaticamente para a dissertação sem identificar protocolo e versão.

## 7.6 Sequência de trabalho

A Tabela 7.1 organiza prioridades por dependência, sem fixar datas ainda não acordadas. Validar o seletor depende de um benchmark confiável; expansão e redação final devem acompanhar essa ordem.

Tabela 7.1: Continuidade da pesquisa por etapa e critério de conclusão.

| Etapa | Critério de conclusão |
|---|---|
| Auditoria dos experimentos | Manifesto de versões, métricas e resultados recompostos |
| Validação temporal | Cortes documentados, comparadores comuns e teste preservado |
| Estudos M5 e multiestado | Recortes auditados e limites de transferência identificados |
| Treinamento do PSE | Avaliação fora da amostra contra referências simples |
| Sensibilidade | Estabilidade e falhas de serviço reportadas por cenário |
| Redação e defesa | Resultados, contribuições e pendências coerentes com a evidência |

# Apêndice A

# Parâmetros e Resultados Complementares

Este apêndice reúne as configurações de referência e a tabela do piloto. Configuração vigente e resultado armazenado não são a mesma evidência: sem um registro da versão executada, os parâmetros não autenticam retrospectivamente cada controlador. As diferenças de horizonte, portfólio e pré-processamento entre PB, BA e M5 devem ser mantidas na reprodução.

Tabela A.1: Dados e ambiente de referência.

| **Componente** | **Configuração** |
|---|---|
| Base real | PB: 15 séries do produto 48130; BA:145 séries,115 lojas e9 produtos. Horizonte de38 ciclos. |
| Base M5 | 2.408séries FOODS, 10 lojas,287 produtos e93 ciclos, após os filtros da configuração M5. |
| Ciclo | Agregação em blocos de aproximadamente21 dias. O último bloco M5 pode ser incompleto. |
| Filtros BA | Produto ativo, exclusão de brindes, preenchimento de ciclos ausentes com zero; filtro de atividade e variabilidade conforme configuração. |
| Filtros M5 | FOODS, CV$\geq 1,5$ e suavização superior por $Q_3 + 1,5\,IQR$ na série agregada. Filtro e suavização usam o histórico completo. |
| Entrega | Configuração $L = 2$; no simulador atual, pipeline com $L+1$ posições entrega um pedido de $t$ em $t+3$. |
| Estoque inicial | $I_0 = \hat{\mu}L + 1,28\hat{\sigma}\sqrt{L}$, escalado por série. A estimação pelo histórico completo limita a interpretação temporal. |
| Custos | Manutenção1/unidade/ciclo, falta5/unidade, pedido fixo50 e variável0,5/unidade; cenário simulado, sem calibração econômica independente. |
| Avaliação | Divisão configurada BA: 17 ciclos iniciais e M5: 19; cinco avaliações nominais por política. Repetições determinísticas não são treinamentos independentes. |
| Semente | Referência42; a independência exige novos treinamentos e controle dos geradores aleatórios. |

Tabela A.2: Regras e parâmetros das políticas clássicas e meta-heurísticas.

| **Política** | **Configuração de referência** |
|---|---|
| EOQ legado | $Q = \sqrt{2\hat{\mu}TK/h}$; $s = \hat{\mu}L + z\hat{\sigma}\sqrt{L}$, $z = 1,28$. Demanda e manutenção devem usar a mesma unidade temporal; o fator $T$ requer revisão. |
| $(s, S)$ | Mesmo ponto de pedido, nível-alvo $S = s + Q$. Herda a escala do lote EOQ. |
| Jornaleiro | Implementação heurística $Q = \max(0, \hat{\mu} + 1,28\hat{\sigma})$, quando a posição de estoque não excede $\hat{\mu}L$; não equivale automaticamente ao quantil ótimo de período único. |
| GA | População100, 50 gerações no recorte BA e 500 na configuração M5; cruzamento0,8, torneio3, mutação inicial0,05 com redução linear até20% dessa taxa. |
| SA | Temperatura inicial1.000, resfriamento0,95 e 500 iterações; o código atual usa busca vetorizada com aceitação de Metropolis. |
| Aptidão | Configuração ponderada $\mathrm{NS} - 0,0001\,\mathrm{CTI}$ e variantes penalizadas; a seleção final usa menor custo entre candidatos com serviço viável. Não confundir aptidão de treino com critério de escolha. |

Tabela A.3: Agentes de reforço e híbrido: configurações documentadas.

| **Componente** | **Configuração** |
|---|---|
| Estado | Seis componentes: estoque, previsão, pedidos em trânsito, média e dispersão recentes e posição no horizonte, normalizados conforme o simulador. |
| Recompensa | Negativo do custo de manutenção, falta e pedido. Variantes incorporam penalidades de serviço e estabilidade; a versão precisa ser registrada. |
| Ações | 20 quantidades discretas; limite escalado pela demanda média. |
| DQN | $\gamma = 0,95$, $\varepsilon = 0,2$, lote64, memória10.000, rede-alvo atualizada a cada10 episódios, taxa0,001. Configuração de referência:1.000 episódios. |
| PPO | $\gamma = 0,99$, recorte0,2, quatro épocas por atualização, taxa0,0003. A implementação atual usa ator-crítico e GAE; os resultados antigos não são regenerados por essa alteração. |
| GA-DQN | Inicialização pelo GA, memória pré-populada com1.000 transições e200 episódios de refinamento na configuração híbrida; horizonte e orçamento variam entre experimentos. |
| Arquiteturas | Estado de dimensão 6; duas camadas ocultas na configuração dos agentes. A versão exata é definida nos arquivos de parâmetros, não inferida dos KPIs. |

Tabela A.4: Previsão auxiliar e seleção de políticas.

| **Componente** | **Configuração** |
|---|---|
| Previsão | LSTM, ANN, XGBoost, Croston e ARIMA; janela de entrada6 ciclos, treinamento mínimo 17 e previsão de um ciclo. |
| LSTM / ANN | LSTM:64 unidades,50 épocas, lote 16 e taxa0,001; ANN:camadas 64/32, máximo200 iterações, parada antecipada e validação0,1. |
| XGBoost | Previsão:200 árvores, profundidade 6, taxa0,05 e subamostragem0,8. |
| Croston / ARIMA | Suavização0,1 / ordem$(1, 1, 1)$. |
| POD | ADI 1,32, $CV^2$0,49, maior silêncio5, burstiness0,30, autocorrelação0,25, tendência0,05 e entropia2; regras de prioridade descritas na metodologia. |
| Rótulos | Menor CTI entre políticas com NS$\geq 0,70$; esse filtro não assegura serviço individual quando aplicado a médias de perfil. |
| PSE proposto | XGBoost:300 árvores, profundidade 6, taxa0,05, subamostragem e seleção de colunas0,8; validação de cinco partições prevista. A existência da configuração não demonstra validação do seletor. |

Tabela A.5: Rastreabilidade da reprodução.

| **Evidência** | **Local e interpretação** |
|---|---|
| Dados preparados | `experiment/data/03_primary/`, com diretório próprio para M5. |
| Características | `experiment/data/04_feature/`; registrar se foram estimadas antes ou depois da separação temporal. |
| Configurações | `experiment/conf/base/parameters/` e `experiment/conf/m5/`; versões diferentes podem gerar portfólios com o mesmo número de políticas. |
| KPIs | `experiment/data/07_model_output/`; chave loja-produto-política e contagem de séries verificadas antes de agregar. |
| Análises | `experiment/data/08_reporting/`; distinguir tabelas históricas, critérios penalizados e reanálises posteriores. |
| Software | Ambiente Python definido em `experiment/pyproject.toml`. Código atual e histórico devem ser identificados separadamente por versão e hash. |
| Inferência | Comparações pareadas por série, controle de multiplicidade e dependência entre séries; cinco repetições de um episódio determinístico não ampliam a amostra. |

## A.1 Resultados Agregados do Piloto na Paraíba

A Tabela A.6 preserva o piloto de15 lojas. O ganho de48% do GA-DQN frente a$(s, S)$ é $(35.589 - 18.502)/35.589$, acompanhado de NS0,821 contra0,843. Não é ganho universal nem validação do PSE. Resultados de outros portfólios não são combinados com os da Bahia ouM5.

Tabela A.6: Indicadores históricos do piloto PB:15 lojas do produto 48130.

| Política | CTI | NS | TR | BE | FP |
|---|---|---|---|---|---|
| SARSA | 16.139 | 0.785 | 0.200 | 0.00 | 0.00 |
| Jornaleiro | 16.402 | 0.794 | 0.111 | 0.003 | 0.27 |
| DQN | 17.974 | 0.806 | 0.078 | 4.1 | 0.37 |
| GA-DQN | 18.502 | 0.821 | 0.050 | 5.0 | 0.31 |
| PSO | 19.100 | 0.819 | 0.056 | 6.2 | 0.31 |
| GA-PPO | 19.801 | 0.833 | 0.050 | 6.6 | 0.35 |
| GA | 20.015 | 0.825 | 0.061 | 19.7 | 0.30 |
| DE | 20.252 | 0.813 | 0.056 | 31.0 | 0.27 |
| SA | 20.967 | 0.820 | 0.056 | 36.4 | 0.27 |
| EOQ | 31.034 | 0.840 | 0.050 | 23.0 | 0.20 |
| PPO | 34.637 | 0.848 | 0.039 | 15.9 | 0.98 |
| $(s, S)$ | 35.589 | 0.843 | 0.050 | 119.4 | 0.15 |

# Referências


Victoria G. Achkar, Braulio B. Brunaud, Héctor D. Pérez, Rami Musa, Carlos A. Méndez, and Ignacio E. Grossmann. Extensions to the guaranteed service model for industrial applications of multi-echelon inventory optimization. *European Journal of Operational Research*, 313(1):192–206, 2024. **DOI** 10.1016/j.ejor.2023.08.013.

Sven Axsäter. *Inventory Control*, volume 90 of *International Series in Operations Research & Management Science*. Springer US, New York, NY, USA, 2 edition, 2006. ISBN 9780387332505. **DOI** 10.1007/0-387-33331-2.

Gah-Yi Ban and Cynthia Rudin. The big data newsvendor: Practical insights from machine learning. *Operations Research*, 67(1):90–108, 2019. **DOI** 10.1287/opre.2018.1757.

Robert N. Boute, Joren Gijsbrechts, Willem van Jaarsveld, and Nathalie Vanvuchelen. Deep reinforcement learning for inventory control: A roadmap. *European Journal of Operational Research*, 298(2):401–412, 2022. **DOI** 10.1016/j.ejor.2021.07.016.

John E. Boylan and Aris A. Syntetos. Forecasting for inventory management of service parts. In Khairy A. H. Kobbacy and D. N. Prabhakar Murthy, editors, *Complex System Maintenance Handbook*, pages 479–506. Springer, London, UK, 2008. **DOI** 10.1007/978-1-84800-011-7_20.

Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794. ACM, 2016. **DOI** 10.1145/2939672.2939785.

Andrew J. Clark and Herbert Scarf. Optimal policies for a multi-echelon inventory problem. *Management Science*, 6(4):475–490, 1960. **DOI** 10.1287/mnsc.6.4.475.

Jacob Cohen. *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, USA, 2 edition, 1988. ISBN 9780805802832.

J. D. Croston. Forecasting and stock control for intermittent demands. *Operational Research Quarterly*, 23(3):289–303, 1972. **DOI** 10.1057/jors.1972.50.

Ton de Kok, Christopher Grob, Marco Laumanns, Stefan Minner, Jörg Rambau, and Konrad Schade. A typology and literature review on stochastic multi-echelon inventory models. *European Journal of Operational Research*, 269(3):955–983, 2018. **DOI** 10.1016/j.ejor.2018.02.047.

Tansel Dokeroglu, Tayfun Kucukyilmaz, and El-Ghazali Talbi. Hyper-heuristics: A survey and taxonomy. *Computers and Industrial Engineering*, 187:109815, 2024. **DOI** 10.1016/j.cie.2023.109815.

John H. Drake, Ahmed Kheiri, Ender Özcan, and Edmund K. Burke. Recent advances in selection hyper-heuristics. *European Journal of Operational Research*, 285(2):405–428, 2020. **DOI** 10.1016/j.ejor.2019.07.073.

Burak Erkayman, Ferhat Yuna, and Mustafa Yılmaz. Markov approach for inventory control with meta-heuristics in intermittent demand environment. *PLOS ONE*, 20:e0325658, 2025. **DOI** 10.1371/journal.pone.0325658.

Ayse Sena Eruguz, Evren Sahin, Zied Jemai, and Yves Dallery. A comprehensive survey of guaranteed-service models for multi-echelon inventory optimization. *International Journal of Production Economics*, 172:110–125, 2016. **DOI** 10.1016/j.ijpe.2015.11.017.

Milton Friedman. A comparison of alternative tests of significance for the problem of $m$ rankings. *The Annals of Mathematical Statistics*, 11(1):86–92, 1940. **DOI** 10.1214/aoms/1177731944.

Kevin Geevers, Lotte van Hezewijk, and Martijn R. K. Mes. Multi-echelon inventory optimization using deep reinforcement learning. *Central European Journal of Operations Research*, 32 (3):653–683, 2024. **DOI** 10.1007/s10100-023-00872-2.

Joren Gijsbrechts, Robert N. Boute, Jan A. Van Mieghem, and Dennis J. Zhang. Can deep reinforcement learning improve inventory management? performance on lost sales, dual-sourcing, and multi-echelon problems. *Manufacturing & Service Operations Management*, 24(3):1349–1368, 2022. **DOI** 10.1287/msom.2021.1064.

Kwang-Il Goh and Albert-László Barabási. Burstiness and memory in complex systems. *EPL (Europhysics Letters)*, 81(4):48002, 2008. **DOI** 10.1209/0295-5075/81/48002.

Stephen C. Graves and Sean P. Willems. Optimizing strategic safety stock placement in supply chains. *Manufacturing & Service Operations Management*, 2(1):68–83, 2000. **DOI** 10.1287/msom.2.1.68.23267.

John H. Holland. *Adaptation in Natural and Artificial Systems*. MIT Press, Cambridge, MA, USA, 1992. ISBN 9780262581111.

Bernardo A. Huberman, Rajan M. Lukose, and Tad Hogg. An economic approach to hard computational problems. *Science*, 275(5296):51–54, 1997. **DOI** 10.1126/science.275.5296.51.

Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006. **DOI** 10.1016/j.ijforecast.2006.03.001.

Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017.

James Kennedy and Russell Eberhart. Particle swarm optimization. In *Proceedings of ICNN'95 — International Conference on Neural Networks*, volume 4, pages 1942–1948, 1995. **DOI** 10.1109/ICNN.1995.488968.

Pascal Kerschke and Heike Trautmann. Automated algorithm selection on continuous black-box problems by combining exploratory landscape analysis and machine learning. *Evolutionary Computation*, 27(1):99–127, 2019. **DOI** 10.1162/evco_a_00236.

Pascal Kerschke, Holger H. Hoos, Frank Neumann, and Heike Trautmann. Automated algorithm selection: Survey and perspectives. *Evolutionary Computation*, 27(1):3–45, 2019. **DOI** 10.1162/evco_a_00242.

S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983. **DOI** 10.1126/science.220.4598.671.

Lars Kotthoff. Algorithm selection for combinatorial search problems: A survey. *AI Magazine*, 35(3):48–60, 2014. **DOI** 10.1609/aimag.v35i3.2460.

Averill M. Law. *Simulation Modeling and Analysis*. McGraw-Hill Education, 5 edition, 2015. ISBN 9780073401324.

Hau L. Lee, V. Padmanabhan, and Seungjin Whang. Information distortion in a supply chain: The bullwhip effect. *Management Science*, 43(4):546–558, 1997. **DOI** 10.1287/mnsc.43.4.546.

Xiaotian Liu, Ming Hu, Yijie Peng, and Yaodong Yang. Multi-agent deep reinforcement learning for multi-echelon inventory management. *Production and Operations Management*, 34(7): 1836–1856, 2025. **DOI** 10.1177/10591478241305863.

Spyros Makridakis. Accuracy measures: Theoretical and practical concerns. *International Journal of Forecasting*, 9(4):527–529, 1993. **DOI** 10.1016/0169-2070(93)90079-3.

Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. The m4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1): 54–74, 2020. **DOI** 10.1016/j.ijforecast.2019.04.014.

Volodymyr Mnih, Koray Kavukcuoglu, David Silver, Andrei A. Rusu, Joel Veness, Marc G. Bellemare, Alex Graves, Martin Riedmiller, Andreas K. Fidjeland, Georg Ostrovski, Stig Petersen, Charles Beattie, Amir Sadik, Ioannis Antonoglou, Helen King, Dharshan Kumaran, Daan Wierstra, Shane Legg, and Demis Hassabis. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015. **DOI** 10.1038/nature14236.

Mehran Nasseri, Taha Falatouri, Patrick Brandtner, and Farzaneh Darbanian. Applying machine learning in retail demand prediction—a comparison of tree-based ensembles and long short-term memory-based deep learning. *Applied Sciences*, 13(19):11112, 2023. **DOI** 10.3390/app131911112.

Peter Nemenyi. *Distribution-Free Multiple Comparisons*. PhD thesis, Princeton University, 1963.

Afshin Oroojlooyjadid, MohammadReza Nazari, Lawrence V. Snyder, and Martin Takáč. A deep q-network for the beer game: Deep reinforcement learning for inventory optimization. *Manufacturing & Service Operations Management*, 24(1):285–304, 2022. **DOI** 10.1287/msom.2020.0939.

Deniz Preil and Michael Krapp. Bandit-based inventory optimisation: Reinforcement learning in multi-echelon supply chains. *International Journal of Production Economics*, 252:108595, 2022. **DOI** 10.1016/j.ijpe.2022.108595.

Meng Qi, Yuanyuan Shi, Yongzhi Qi, Chenxin Ma, Rong Yuan, Di Wu, and Zuo-Jun Max Shen. A practical end-to-end inventory management model with deep learning. *Management Science*, 69(2):759–773, 2023. **DOI** 10.1287/mnsc.2022.4564.

John R. Rice. The algorithm selection problem. *Advances in Computers*, 15:65–118, 1976.

John Schulman, Philipp Moritz, Sergey Levine, Michael I. Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations (ICLR)*, 2016.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017. **DOI** 10.48550/arXiv.1707.06347.

Rainer Storn and Kenneth Price. Differential evolution — a simple and efficient heuristic for global optimization over continuous spaces. *Journal of Global Optimization*, 11(4):341–359, 1997. **DOI** 10.1023/A:1008202821328.

Nadia Sultana, David Canca, and Alejandro Zarzo. Contextual reinforcement learning for supply chain management. *Expert Systems with Applications*, 255:124068, 2024. **DOI** 10.1016/j.eswa.2024.124068.

Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, Cambridge, MA, USA, 2 edition, 2018. ISBN 9780262039246.

Aris A. Syntetos and John E. Boylan. On the categorization of demand patterns. *Journal of the Operational Research Society*, 56(5):495–503, 2005. **DOI** 10.1057/palgrave.jors.2601841.

Aris A. Syntetos, John E. Boylan, and Stephen M. Disney. Forecasting for inventory planning: A 50-year review. *Journal of the Operational Research Society*, 63(10):1397–1406, 2012. **DOI** 10.1057/jors.2012.158.

Yasin Tadayonrad and Alassane Balle Ndiaye. A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality. *Supply Chain Analytics*, 3:100026, 2023. **DOI** 10.1016/j.sca.2023.100026.

El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. John Wiley & Sons, Hoboken, NJ, USA, 2009. ISBN 9780470278581. **DOI** 10.1002/9780470496916.

Tarkan Temizöz, Christina Imdahl, Remco Dijkman, Douniel Lamghari-Idrissi, and Willem van Jaarsveld. Deep controlled learning for inventory control. *European Journal of Operational Research*, 324(1):104–117, 2025. **DOI** 10.1016/j.ejor.2025.01.026.

Henri Theil. *Applied Economic Forecasting*. North-Holland, Amsterdam, 1966.

Hado van Hasselt, Arthur Guez, and David Silver. Deep reinforcement learning with double Q-learning. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 30, pages 2094–2100, 2016.

Willem van Jaarsveld and Joachim Arts. Projected inventory-level policies for lost sales inventory systems: Asymptotic optimality in two regimes. *Operations Research*, 72(5): 1790–1805, 2024. **DOI** 10.1287/opre.2021.0032.

Nathalie Vanvuchelen, Joren Gijsbrechts, and Robert N. Boute. Use of proximal policy optimization for the joint replenishment problem. *Computers in Industry*, 119:103239, 2020. **DOI** 10.1016/j.compind.2020.103239.

Ziyu Wang, Tom Schaul, Matteo Hessel, Hado van Hasselt, Marc Lanctot, and Nando de Freitas. Dueling network architectures for deep reinforcement learning. In *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, pages 1995–2003, 2016.

Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945. **DOI** 10.2307/3001968.

David H. Wolpert and William G. Macready. No free lunch theorems for optimization. *IEEE Transactions on Evolutionary Computation*, 1(1):67–82, 1997. **DOI** 10.1109/4235.585893.

Linwei Xin. Technical note—understanding the performance of capped base-stock policies in lost-sales inventory models. *Operations Research*, 69(1):61–70, 2021. **DOI** 10.1287/opre.2020.2019.

Ferhat Yuna, Burak Erkayman, and Mustafa Yılmaz. Inventory control model for intermittent demand: A comparison of metaheuristics. *Soft Computing*, 27:6487–6505, 2023. **DOI** 10.1007/s00500-023-07871-0.

Oussama Zabraoui, Yahya Hmamou, Anas Chafi, and Salaheddine Kammouri Alami. A comparative study of multi-algorithm optimization for inventory analytics in supply chains. *Supply Chain Analytics*, 12:100154, 2025. **DOI** 10.1016/j.sca.2025.100154.

Paul H. Zipkin. *Foundations of Inventory Management*. McGraw-Hill/Irwin, Boston, MA, USA, 2000. ISBN 9780256113792.