Seleção de políticas de reposição por perfil de demanda: avaliação temporal em uma rede varejista

Matheus Inácio Batista Santos[a]

[a]*Instituto de Computação, Universidade Federal de Alagoas, Brasil*

Abstract

A heterogeneidade da demanda motiva selecionar políticas de reposição por perfil, mas essa complexidade só se justifica se melhorar a decisão em períodos posteriores. Este estudo compara seleção por perfil e política global em 145 séries loja-produto de uma rede varejista brasileira, distribuídas em 115 lojas e nove produtos. Avaliamos seis políticas principais e DQN como controle adicional, em duas origens temporais, com blocos separados de treino, validação e teste. Os métodos estocásticos usam três sementes, totalizando 4.350 ajustes. Em cada origem, a escolha minimiza custo entre candidatas que atingem atendimento médio mínimo de 0,70 na validação das demais lojas; o desempenho é medido no teste da loja reservada. A seleção por perfil aumenta o custo médio em 1,93% e o atendimento em 3,89 pontos percentuais. Os casos abaixo da meta diminuem de 119 para 100 entre 283 casos série–origem com demanda positiva; sete casos têm atendimento indefinido. O intervalo condicional de 95% para o aumento de custo é de $[-0{,}32; 4{,}16]\%$. A diferença concentra-se na primeira origem; na segunda, ambos os seletores escolhem a mesma política. Os resultados mostram serviço adicional com custo maior, sem economia geral da seleção contextual. A coorte retrospectiva e duas janelas curtas parcialmente sobrepostas limitam a generalização. Matrizes históricas da Bahia e de 2.408 séries M5 complementam o contexto, com protocolos distintos da avaliação principal.

Keywords: Gestão de estoques, Demanda intermitente, Seleção de políticas, Nível de serviço, Varejo, M5

1. Introdução

Uma rede varejista precisa decidir quando e quanto repor para muitas combinações de loja e produto. Uma regra que funciona para vendas frequen-

tes pode produzir excesso de estoque em séries esparsas; outra, econômica em média, pode não cobrir picos relevantes. O problema não se resume a prever demanda: envolve escolher uma regra de decisão e ajustar seus parâmetros sob custos e exigências de atendimento [1].

Comparações de algoritmos ampliam o conjunto de alternativas disponíveis. Políticas analíticas, heurísticas, busca por parâmetros e aprendizado por reforço oferecem diferentes compromissos entre custo, serviço e esforço computacional. Entretanto, a existência de um portfólio não resolve a escolha operacional. O gestor precisa saber se vale aplicar uma política uniforme ou distinguir grupos de séries, e se a distinção oferece ganho suficiente para justificar maior complexidade.

Essa pergunta pode ser formulada como seleção de algoritmos: características de uma instância ajudam a escolher um método de um conjunto candidato [2, 3]. Em inventário, a instância é uma série loja-produto e o resultado depende da política, do ambiente e do serviço exigido. A proposta Adaptive Inventory Policy Engine (AIPE) organiza essa avaliação em caracterização, comparação e seleção. Seu componente supervisionado, Policy Selection Engine (PSE), é uma extensão ainda não validada neste artigo; a análise presente utiliza regras explícitas de escolha por perfil.

Trabalhos publicados em *Supply Chain Analytics* relacionam previsão e desempenho operacional [4], comparam algoritmos de controle [5] e examinam a informação decisória preservada por critérios de classificação [6]. Esses enfoques motivam avaliar o que a seleção por perfil acrescenta ao portfólio: distinguir padrões de demanda só justifica uma regra mais complexa se a distinção melhorar a decisão em relação a uma referência global competitiva.

A pesquisa parte dos experimentos da qualificação de mestrado com dados de uma rede brasileira. O caso central deste artigo é a avaliação temporal de 145 séries da Bahia. Os estudos históricos da Bahia e do M5 são preservados no Apêndice Apêndice A, como antecedentes com protocolos próprios. O M5 oferece uma origem pública adicional, mas sua nova execução ainda não integra a evidência principal.

Investigamos se a seleção por perfil oferece um compromisso entre custo e atendimento mais favorável que uma política global escolhida com a mesma informação passada. A análise distingue o desempenho de cada candidata, o resultado das estratégias de seleção e sua variação entre períodos. Sua contribuição é avaliar o ganho incremental da escolha contextual com comparação entre lojas e teste temporal, incluindo diferenças de serviço, casos sem demanda e situações sem alternativa viável.

2. Trabalhos relacionados e posicionamento

A classificação da demanda organiza diferenças de frequência e tamanho das ocorrências. A taxonomia ADI–CV^2 é uma referência para distinguir demanda suave, errática, intermitente e *lumpy* [7]. Uma classe estatística, porém, não identifica sozinha a melhor política: custo de falta, prazo, estado inicial e requisito de atendimento também influenciam a decisão.

Tadayonrad e Ndiaye [4] aproximam a avaliação de previsão dos custos de inventário e do serviço. Pietukhov et al. [8] estudam previsão de indicadores de desempenho em um contexto empírico. A conexão com este trabalho é avaliar consequências operacionais, sem transformar precisão preditiva em substituto de custo e atendimento. Na avaliação principal, previsão especializada não é uma intervenção experimental; a escolha é julgada pelas decisões e pelo serviço obtido.

Zabraoui et al. [5] comparam famílias de algoritmos de inventário e apresentam combinações de algoritmos genéticos (GA) e aprendizado por reforço com dados M5. A arquitetura GA–DQN, que combina GA e uma rede Q profunda (DQN, do inglês deep Q-network), e a ideia de portfólio já estão, portanto, na literatura da revista. Nosso foco não é propor a mesma combinação como novidade, mas avaliar a camada de escolha entre alternativas. As heurísticas inspiradas naquele estudo envolvem decisões de implementação próprias, e custos, filtros e granularidade não constituem uma reprodução exata de seus experimentos.

A análise de critérios de Theunissen et al. [6] destaca a diferença entre importância estatística e utilidade decisória. Não implementamos seu método topológico. Testamos uma consequência próxima: mesmo um perfil interpretável pode ser pouco útil se recomendar praticamente a mesma política global ou se suas mudanças elevarem custo sem benefício de serviço relevante.

Revisões de aprendizado por reforço em inventário discutem a importância do ambiente, da recompensa e da avaliação [9]. Uma baixa taxa de atendimento ou frequência de pedidos extrema não caracteriza, isoladamente, uma família algorítmica. Os resultados abaixo descrevem implementações e matrizes específicas. Corrigir um controlador atual não valida retrospectivamente uma saída armazenada de outra versão.

O M5 documenta uma competição de previsão sobre vendas reais de varejo [10]. Neste artigo, seus dados são agregados e usados em simulação de reposição. Os resultados não são classificações da competição nem uma comparação com seus vencedores. A comparação adicional examina retros-

pectivamente se o mesmo procedimento de seleção apresenta comportamento semelhante em outro conjunto, mantendo claras as restrições da transformação e do recorte.

3. Dados e protocolo temporal da Bahia

A avaliação principal utiliza 145 séries loja-produto da Bahia, em 115 lojas e nove produtos, com 38 ciclos comerciais disponíveis. O objetivo é comparar uma política global com a escolha por perfil em períodos posteriores aos usados no ajuste e na seleção. Os identificadores da coorte provêm do estudo histórico; a preparação e o protocolo desta execução são descritos a seguir. Os resultados históricos da Bahia e do M5 têm função complementar e não são concatenados à avaliação temporal.

3.1. Protocolo e cobertura

Os registros complementares de vendas são somados por chave, sem descartar transações apenas por compartilharem loja, produto e ciclo. A coorte mantém os identificadores históricos; em cada origem, exige ao menos três ciclos positivos no treino. As 145 séries são elegíveis nos dois prefixos, de 17 e 23 ciclos. Cada prefixo é seguido por sete ciclos de validação e sete de teste. Na numeração iniciada em um, os testes abrangem os ciclos 25–31 e 31–37: compartilham um ciclo e representam medidas repetidas das mesmas séries.

Perfis, escalas dos estados e parâmetros são calculados no treino. O prazo efetivo de entrega é de dois ciclos, e EOQCycle utiliza demanda e manutenção na mesma unidade temporal. Custos de manutenção, falta, emissão e quantidade permanecem, respectivamente, em 1 por unidade e ciclo, 5 por unidade não atendida, 50 por pedido e 0,5 por unidade pedida. São unidades do cenário, sem equivalência monetária calibrada. O custo soma manutenção, falta e pedidos no bloco de teste, sem crédito pelo estoque final. Estados iniciais comuns são obtidos por uma política EOQ de referência: um aquecimento no passado precede a validação, e sua trajetória na validação determina o estado inicial do teste. O teste não continua o estoque particular de cada candidata.

O portfólio principal contém EOQCycle, sSCycle, CappedBaseStock, GA, PPO e GA–DQN; DQN é o controle adicional do híbrido. As três primeiras políticas têm um ajuste por série e origem. GA, PPO, GA–DQN e DQN usam sementes 11, 29 e 47, totalizando 4.350 ajustes e 8.700 registros de validação ou teste. A matriz está completa, sem casos excluídos por falta de política ou

semente. Cinquenta e quatro ajustes compatíveis foram reaproveitados com proveniência registrada. O GA usa população de 100 indivíduos e 50 gerações. DQN e PPO têm orçamento mínimo de 20 mil transições, arredondado para episódios completos: 20.009 e 20.010 nas duas origens. GA–DQN acrescenta busca genética e mil transições de demonstração; seu esforço total é maior que o do DQN isolado. A variante avaliada mantém o mesmo gatilho e piso de pedido nas demonstrações, no treinamento e na inferência.

As sementes são primeiro promediadas dentro de cada série, origem e política. Para cada loja excluída, as políticas global e por perfil são escolhidas na validação das demais lojas e avaliadas no teste da loja reservada. O limiar principal continua em 0,70. Escolher uma alternativa viável na validação não garante repetir seu atendimento no futuro. Se nenhuma candidata cumpre a meta, a escolha de maior serviço é registrada como alternativa de contingência, sem classificá-la como viável.

4. Seleção e protocolo de comparação

4.1. Referência global e escolha por perfil

Para um conjunto A de séries usadas na escolha, definimos custo e atendimento médios por política:

$$\bar{C}_{\pi,A} = |A|^{-1} \sum_{i \in A} C_{i\pi}, \qquad \bar{F}_{\pi,A} = |A|^{-1} \sum_{i \in A} F_{i\pi}. \tag{1}$$

Cada série recebe o mesmo peso. A média de fill rates não é o atendimento ponderado pelo volume total da rede. Seja Π o portfólio de políticas. A política global é

$$\widehat{\pi}_A = \arg \min_{\pi \in \Pi : \bar{F}_{\pi,A} \geq \alpha} \bar{C}_{\pi,A}. \tag{2}$$

A seleção por perfil aplica a mesma regra separadamente a A_g, o subconjunto associado ao perfil g. Se nenhuma política atende à restrição, escolhe-se maior atendimento médio, com custo como desempate, e registra-se fallback. Esse caso é explicitado: não é uma escolha viável que cumpriu o limiar. Entre candidatas viáveis com mesmo custo, preferimos maior serviço; no fallback empatado em serviço, menor custo. Empates restantes usam ordem alfabética do identificador. Um perfil ausente nas lojas de escolha utiliza a regra global.

A restrição é média e específica do conjunto usado para escolher. Não exige $F_{i\pi} \geq \alpha$ em toda série. Também não garante a média da loja excluída.

Além disso, exigir viabilidade em cada perfil é diferente de exigi-la apenas no agregado. Uma política global viável pode ser inviável em um grupo; a escolha por perfil não precisa apresentar menor custo mesmo na avaliação retrospectiva.

O limiar principal é $\alpha = 0{,}70$, herdado da investigação original. Ele não representa recomendação de meta comercial. Avaliamos também 0,80, 0,85, 0,90 e 0,95, sem escolher a conclusão pelo limiar mais favorável. A diferença relativa de custo é

$$R = 100\frac{\bar{C}_{\text{global}} - \bar{C}_{\text{perfil}}}{\bar{C}_{\text{global}}}. \tag{3}$$

$R > 0$ indica redução; $R < 0$, aumento. Diferenças de atendimento são dadas em pontos percentuais. Custo menor acompanhado por atendimento menor não é chamado de dominância.

4.2. Perfis operacionais e informação disponível

Os perfis são regras heurísticas ordenadas, não clusters aprendidos nem políticas previamente validadas. A prioridade é Sparse High Impact, High Volatility Seasonal, Unstable Trend, Low Volume Stable e Fast Moving. A primeira regra utiliza ADI elevado, CV^2 elevado e sequência longa de zeros; a segunda, autocorrelação sazonal ou concentração de ocorrências; a terceira, tendência ou entropia. Os perfis de baixo volume estável e venda frequente não aparecem nos prefixos avaliados da Bahia. Para tornar a regra reproduzível, usamos $a = n/\max(n_+, 1)$, $c^2 = [s/(\mu + 10^{-9})]^2$ e Z, maior sequência de zeros. Aqui, n é o número de ciclos do prefixo de treino, n_+ é a quantidade de ciclos com demanda positiva, μ é a média sobre todos os ciclos e s é o desvio-padrão amostral, incluindo zeros. Essa variância difere da calculada apenas sobre os tamanhos positivos da demanda na taxonomia original. A Tabela 1 apresenta os cortes, aplicados na ordem indicada; uma série sem correspondência recebe Sparse High Impact.

Burstiness é $(s_\Delta - \mu_\Delta)/(s_\Delta + \mu_\Delta + 10^{-9})$, em que μ_Δ e s_Δ são a média e o desvio-padrão dos intervalos Δ entre ocorrências positivas; recebe zero com menos de dois intervalos. Tendência é a inclinação estimada por mínimos quadrados ordinários (OLS) sobre o índice de ciclo, dividida por $\mu + 10^{-9}$. Entropia é $-\sum_j p_j \log_2(p_j + 10^{-12})$, em que p_j é a frequência relativa na classe j de um histograma com dez intervalos de mesma largura. Autocorrelação é a covariância na defasagem 17 dividida pela variância global; recebe zero se a série tem até 18 ciclos ou variância desprezível. Os rótulos descrevem regras locais, não sazonalidade ou impacto econômico empiricamente validados.

Tabela 1: Regras operacionais de perfil: primeiro corte satisfeito determina o grupo.

Perfil	Condição
Sparse High Impact	$a \geq 1{,}32$, $c^2 \geq 0{,}49$ e $Z \geq 5$
High Volatility Seasonal	Autocorrelação na defasagem 17 $\geq 0{,}25$ ou burstiness $\geq 0{,}30$
Unstable Trend	Módulo da tendência normalizada $\geq 0{,}05$ ou entropia ≥ 2
Low Volume Stable	$\mu \leq 2$ e $c^2 < 0{,}49$
Fast Moving	$a < 1{,}32$

Na avaliação temporal, essas características são calculadas exclusivamente no prefixo de treino. Os nomes dos perfis identificam regras locais; não validam sazonalidade ou impacto econômico. A eventual associação de um nome de perfil a uma política no código não determina a escolha: custo e serviço na validação definem a recomendação.

4.3. Avaliação e incerteza

As regras global e por perfil usam a validação das demais lojas e são aplicadas ao teste da loja reservada. Cada política é ajustada apenas no treino da respectiva série; o seletor usa resultados de validação, sem consultar o teste para escolher. As sementes são promediadas dentro de cada caso série–origem antes das comparações. Custos incluem todos os casos; médias de atendimento excluem os denominadores nulos, contabilizados separadamente. Origens são medidas repetidas, com um ciclo de teste compartilhado.

A incerteza de custo é descrita por intervalos percentis de 95%, obtidos em 5.000 reamostragens pareadas das 115 lojas. Cada loja sorteada leva todas as suas séries e origens. Controladores e seletores permanecem fixos nos sorteios; os intervalos são condicionais às escolhas e aos treinamentos realizados. A dependência entre lojas que compartilham produtos permanece uma limitação.

5. Resultados da avaliação temporal

5.1. Custo e atendimento no teste

A Tabela 2 resume os 290 casos série–origem. Sete casos não têm demanda no teste: um na primeira origem e seis na segunda. Seus custos permanecem na média dos 290 casos; o atendimento médio utiliza os 283

casos com denominador positivo. O atendimento ponderado é a razão entre a soma das unidades atendidas e a soma da demanda nos blocos avaliados, após a média das sementes. As origens repetidas não ampliam a amostra para 290 séries independentes.

Tabela 2: Bahia, protocolo temporal: médias no teste de sete ciclos. Custo em unidades do cenário, calculado nos 290 casos. Atendimento médio e contagem abaixo da meta consideram os 283 casos com demanda positiva; sete casos têm atendimento indefinido.

Política	Custo	Atendimento	Ponderado	Abaixo de 0,70
EOQCycle	166,77	0,7787	0,6265	101
sSCycle	164,23	0,8037	0,6802	90
CappedBaseStock	218,11	0,6631	0,4948	148
GA	143,85	0,6953	0,5457	140
PPO	134,23	0,5514	0,4189	171
GA–DQN	145,75	0,6802	0,5248	144
DQN (controle)	164,88	0,5718	0,4033	164

PPO tem o menor custo descritivo, acompanhado do menor atendimento médio. Apenas EOQCycle e sSCycle superam 0,70 no conjunto dos testes; nenhuma política alcança essa meta no atendimento ponderado. Entre essas duas referências, sSCycle apresenta menor custo e maior atendimento médio. Essa comparação é um diagnóstico do teste, não uma escolha retrospectiva a ser atribuída ao seletor.

GA–DQN custa 11,60% menos que DQN e aumenta o atendimento médio de 0,5718 para 0,6802. Frente ao GA isolado, porém, custa 1,32% mais e atende menos, com média de 0,6953 para o GA. O refinamento híbrido não oferece vantagem agregada nessas duas dimensões sobre seu componente evolutivo. A diferença varia entre origens: na segunda, seu custo é ligeiramente menor que o do GA, também com menor atendimento. A comparação não isola causalmente o benefício das demonstrações ou do gatilho e não justifica excluir o híbrido antes de consolidar a avaliação M5.

5.2. Seleção global e por perfil

Na primeira origem, a regra global escolhe GA para todas as séries. Por perfil, as escolhas são GA em 65 casos, sSCycle em 75 e EOQCycle em cinco. O maior atendimento custa mais, e ambas as estratégias ficam abaixo da meta no teste. Na segunda origem, os dois seletores escolhem sSCycle em

Tabela 3: Escolha na validação das demais lojas e avaliação no teste da loja reservada, com meta 0,70. Há 145 casos por linha; atendimento definido em 144 casos na origem 17 e 139 na origem 23.

Treino	Estratégia	Custo	Atendimento	Abaixo de 0,70
17 ciclos	Global	180,58	0,5711	101
17 ciclos	Perfil	186,79	0,6475	82
23 ciclos	Global	142,03	0,9073	18
23 ciclos	Perfil	142,03	0,9073	18

todos os casos. A Tabela 3 evidencia, portanto, tanto mudança temporal da escolha global quanto ausência de diferenciação contextual na segunda janela.

No conjunto das origens, o custo médio passa de 161,31 na estratégia global para 164,41 por perfil: aumento de 1,93%. O atendimento médio cresce de 0,7362 para 0,7751, diferença de 3,89 pontos percentuais; o ponderado passa de 0,5750 para 0,6395. Os casos abaixo da meta diminuem de 119 para 100, entre os 283 com atendimento definido. Não há redução de custo, mas há melhora de serviço, concentrada na primeira origem. Essa melhora não assegura atendimento mínimo individual nem equivale a cumprir uma meta ponderada de 0,70.

Uma reamostragem exploratória pareada de 115 lojas, com 5.000 sorteios e todas as origens e produtos de cada loja preservados, produz intervalo condicional de 95% de $[-0{,}32; 4{,}16]\%$ para o aumento de custo por perfil. Os controladores e seletores permanecem fixos nos sorteios. O intervalo inclui zero e não representa incerteza de novos treinamentos ou de novas trajetórias de demanda; dependência entre lojas que compartilham produtos também permanece possível.

A sensibilidade reforça a distinção entre meta de escolha e serviço futuro. Em 0,80, todas as escolhas da segunda origem são contingências por ausência de candidata viável na validação, apesar do serviço posterior de 0,9073. Em 0,90 e 0,95, ambas as estratégias usam contingências nos 290 casos. Atendimento futuro alto não torna retroativamente viável uma escolha que descumpria o critério na validação.

5.3. Perfis e variação entre origens

Os perfis calculados no prefixo diferem dos rótulos do histórico completo. Com 17 ciclos, há 65 séries Sparse High Impact e 80 Unstable Trend; com

23, são 60, 69 e 16 High Volatility Seasonal. Essa mudança reflete a janela e as regras de caracterização, inclusive a indisponibilidade da autocorrelação na primeira origem. Não demonstra mudança de regime econômico em todas essas séries.

6. Discussão e implicações operacionais

A avaliação temporal responde à pergunta central com um compromisso: os perfis aumentam o atendimento, mas também o custo. A melhora concentra-se na primeira origem, enquanto a segunda reproduz integralmente a escolha global. Não há evidência de economia geral que justifique, por si só, a complexidade adicional da seleção contextual.

Essa interpretação é diferente de comparar apenas as políticas individuais. GA–DQN melhora custo e atendimento frente ao DQN, mas não frente ao GA no conjunto dos testes. Mesmo que um controlador fosse superior em média, ainda seria necessário demonstrar que as características permitem identificar quando recomendá-lo. A distinção entre qualidade dos candidatos e utilidade do seletor aproxima o problema da seleção de algoritmos [2, 3].

A comparação conceitual com Zabraoui et al. [5] situa o portfólio e a arquitetura híbrida na literatura. Recortes, implementações e orçamentos distintos impedem confirmar ou refutar seu ranking com os valores deste estudo. O foco em consequências operacionais também se relaciona à avaliação de custo e serviço discutida por Tadayonrad e Ndiaye [4]. Precisão de previsão ou identidade do algoritmo não substituem essa comparação.

A agregação temporal exige atenção. Na primeira origem, ambas as estratégias ficam abaixo de 0,70 no teste; reunir as origens produz médias acima desse valor. O atendimento ponderado permanece inferior à média por série, indicando que o serviço não se distribui uniformemente pelo volume de demanda. Uma decisão empresarial precisa definir se a meta se aplica à média das séries, às unidades demandadas ou a itens críticos individualmente.

Os resultados históricos do Apêndice Apêndice A oferecem antecedentes, mas não estimam o ganho do protocolo temporal. A troca de VendorResponsive por outros vencedores acompanha mudanças de portfólio, preparação e horizonte. Seu valor é mostrar por que a seleção precisa de avaliação própria, e não servir de referência numérica direta para quantificar melhora entre versões.

7. Limitações e continuidade

O ajuste e os perfis usam apenas o passado da origem, mas a coorte mantém identificadores escolhidos retrospectivamente. Os testes cobrem sete ciclos e compartilham um ciclo entre origens. Séries da mesma loja e produtos presentes em várias lojas podem ser dependentes. A reamostragem por loja preserva parte dessa estrutura, sem representar novos treinamentos ou novas realizações da demanda.

As vendas podem omitir demanda censurada por falta de estoque. Custos são unidades do cenário e não demonstram economia monetária realizada. O estado inicial comum é produzido por uma política de referência; o teste não mede a continuação do estoque particular de cada candidata. Estoque terminal sem crédito, horizonte curto e valores de custos podem alterar o compromisso observado. Essas condições precisam acompanhar a interpretação dos resultados.

A nova execução M5 deverá ampliar a comparação sob o protocolo temporal, mantendo separadas as bases. A continuidade inclui mais períodos, menor sobreposição dos testes, sensibilidade econômica e restrições de serviço por série. O PSE supervisionado permanece uma extensão a validar frente às regras explícitas de seleção e à melhor referência global.

8. Conclusão

Em 145 séries da Bahia, a seleção por perfil acrescenta 1,93% ao custo e 3,89 pontos percentuais ao atendimento médio, reduzindo as violações de 119 para 100 entre 283 casos definidos. O efeito varia entre períodos e desaparece como diferenciação de escolha na segunda origem. A evidência sustenta avaliar o valor do serviço adicional, sem afirmar economia geral ou superioridade do seletor.

A contribuição é separar desempenho dos controladores, escolha da política e avaliação temporal da recomendação. O resultado permanece condicional à coorte, às janelas e ao cenário. A consolidação do M5 e a validação do PSE são necessárias antes de generalizar a recomendação para outros contextos.

Disponibilidade de dados e código

Os dados transacionais brasileiros são proprietários e não são distribuídos nesta versão. O M5 é um conjunto público; sua transformação e o recorte

devem acompanhar uma futura disponibilização reprodutível. Código de reanálise, tabelas e hashes são mantidos no projeto de pesquisa. Permissões de divulgação de derivados, repositório arquivado e identificadores públicos precisam ser confirmados antes de submissão.

Autoria, financiamento e interesses

Autoria, contribuições CRediT, financiamento, agradecimentos e declaração de interesses permanecem sujeitos à confirmação dos autores responsáveis. Esta versão de trabalho em português requer consolidação dessas informações e adequação ao idioma e às normas editoriais antes da submissão.

Uso de inteligência artificial na preparação do manuscrito

OpenAI Codex foi utilizado para auxiliar organização bibliográfica, leitura de código, preparação de análises e redação. A versão atual exige verificação e revisão do autor humano responsável, que deverá conferir fontes, cálculos e afirmações e assumir responsabilidade pelo texto final. Sistemas de IA não são autores.

Apêndice A. Resultados históricos e contexto M5

Este apêndice preserva a reanálise das matrizes anteriores. Seu objetivo é documentar os antecedentes da avaliação temporal, não acrescentar observações ao teste principal. As mesmas 145 séries da Bahia e 2.408 séries de alimentos do M5 foram avaliadas com doze políticas. Características, preparação, episódios e orçamentos diferem do protocolo principal. Assim, a diferença entre custos históricos e atuais não estima o efeito isolado de uma mudança de método.

O M5 histórico agrega vendas em 93 blocos de 21 dias, incluindo um bloco final parcial. O filtro local FOODS com CV de 1,5 por produto, sobre lojas e ciclos, e a suavização superior por intervalo interquartil usam a trajetória completa. O recorte foi inspirado em Zabraoui et al. [5], que não publicam identificadores e corte numérico suficientes para certificar uma amostra idêntica. A nova execução M5 utiliza protocolo próprio e permanece em andamento.

Tabela A.4: Coortes verificadas nas matrizes analisadas. Prefixo indica o corte de ajuste configurado no código, não uma garantia de independência temporal de toda a preparação.

Característica	Rede brasileira (BA)	M5 FOODS
Séries	145	2.408
Lojas	115	10
Produtos	9	287
Ciclos disponíveis	38	93
Prefixo configurado	17	19
Prefixo sem demanda	0	2.213
Menos de 3 ciclos positivos no prefixo	0	2.237
Sparse High Impact	116	2.350
Unstable Trend	18	40
High Volatility Seasonal	11	18
Políticas na matriz	12	12

Os prefixos configurados têm 17 ciclos na Bahia e 19 no M5. No M5, 2.213 séries (91,90%) não registram demanda no prefixo e todas têm demanda posteriormente. Isso não comprova lançamento dos produtos ou indisponibilidade real de histórico. As diferenças de inicialização, orçamento e frequência limitam a comparação entre bases. Na dinâmica histórica, $L = 2$ corresponde a chegada em $t + 3$; na avaliação principal, o prazo efetivo é de dois ciclos. A heurística EOQ histórica também usa uma escala de lote distinta da EOQ por ciclo.

As matrizes registram cinco avaliações nominais por série e política, com desvios de custo praticamente nulos. Essas avaliações não são cinco treinamentos independentes. O portfólio completo da Tabela A.5 mostra que baixo custo pode acompanhar atendimento insuficiente; seus denominadores relativos são específicos de cada base.

Apêndice A.1. Seleção retrospectiva entre lojas

Na reanálise, a política global e as escolhas por perfil são determinadas excluindo a loja avaliada, mas consultando as saídas históricas já armazenadas. A exclusão da loja não elimina informação futura incorporada aos perfis ou à geração das matrizes. Esse desenho difere da escolha na validação e avaliação em teste posterior empregadas no corpo principal.

Em 0,70, os perfis aumentam o custo em 0,576% na Bahia e reduzem em 0,681% no M5, com diferenças de atendimento de 0,779 e −0,122 ponto per-

Tabela A.5: Portfólio histórico completo: custo relativo à melhor global viável em $\alpha = 0{,}70$ e serviço médio. BA: denominador VendorResponsive; M5: denominador SA.

	BA		M5	
Política	Custo relativo	Serviço	Custo relativo	Serviço
BigDataNewsvendor	1,343	0,717	0,322	0,096
CappedBaseStock	1,297	0,642	0,297	0,098
DQN	0,292	0,225	0,318	0,076
EOQ	1,450	0,942	0,320	0,133
FixedInterval	1,057	0,844	0,301	0,100
GA	2,920	0,896	0,381	0,231
GA–DQN	2,714	0,731	0,406	0,467
Newsvendor	0,669	0,540	0,285	0,084
PPO	11,799	0,963	1,139	0,985
SA	2,649	0,865	1,000	0,852
VendorResponsive	1,000	0,774	0,287	0,100
(s, S)	1,511	0,943	0,321	0,134

Tabela A.6: Seleção com exclusão da loja avaliada, em $\alpha = 0{,}70$. A coluna abaixo do limiar conta séries individualmente, não médias de perfil. Custos não são comparáveis entre bases.

Base	Estratégia	Custo médio	Fill rate	Abaixo do limiar
Brasileira	Global	433,31	0,7738	40
Brasileira	Perfil	435,80	0,7816	39
M5	Global	19.500,54	0,8521	270
M5	Perfil	19.367,73	0,8509	274

centual. Os intervalos condicionais de redução de custo são $[-1{,}442; 0{,}153]\%$ e $[-1{,}190; 2{,}402]\%$, respectivamente. Usam 5.000 reamostragens pareadas de lojas, sem reajustar escolhas; no M5, existem apenas dez lojas. Não demonstram equivalência nem vantagem geral dos perfis. A Tabela A.6 informa também as violações individuais, que não desaparecem quando a média do grupo é viável.

A sensibilidade histórica das Figuras A.1 e A.2 ilustra mudanças de vencedor com o serviço exigido. No M5, ambas as estratégias convergem para PPO em 0,90 e 0,95. Na Bahia, o aparente ganho de custo em 0,95 acompanha menor atendimento e escolhas de contingência em grupos sem alternativa viável. Esses diagnósticos motivam a separação temporal adotada no estudo principal; não determinam um limiar comercial ótimo.

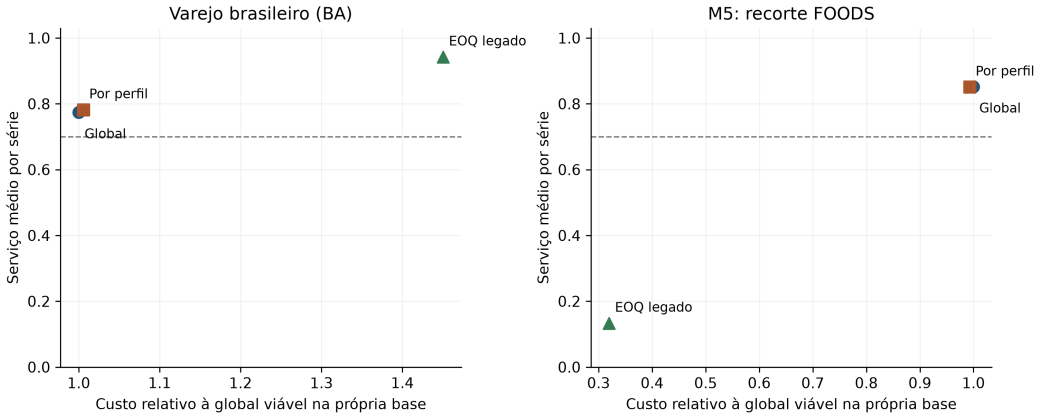


Figura A.1: Custo e atendimento das políticas e estratégias nas duas bases. Os painéis possuem escalas próprias: diferenças absolutas de custo entre Brasil e M5 não têm interpretação econômica comum.

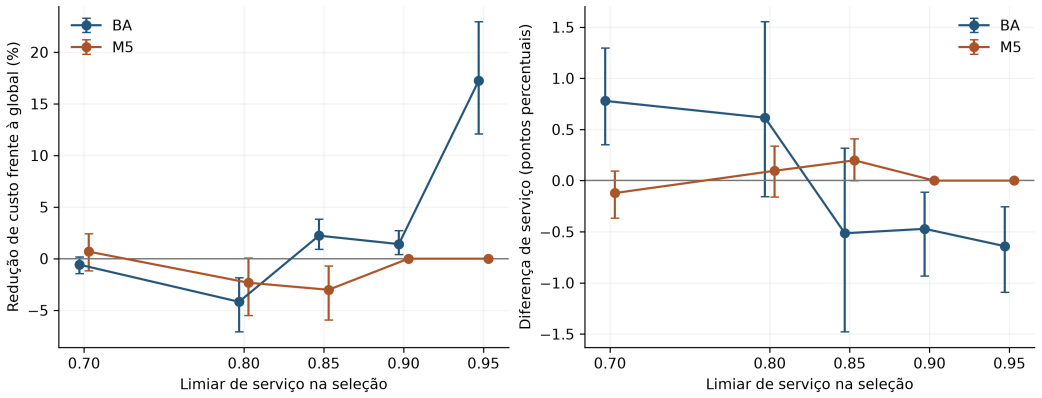


Figura A.2: Contraste de seleção por perfil e global com exclusão de loja em diferentes limiares. Reduções de custo são interpretadas com diferenças de atendimento; intervalos são condicionais ao procedimento e às matrizes.

Referências

[1] S. Axsäter, Inventory Control, 2nd Edition, Vol. 90 of International Series in Operations Research & Management Science, Springer US, New York, NY, USA, 2006. doi:10.1007/0-387-33331-2.

[2] J. R. Rice, The algorithm selection problem, in: Advances in Computers, Vol. 15, Academic Press, 1976, pp. 65–118. doi:10.1016/S0065-2458(08)60520-3.

[3] L. Kotthoff, Algorithm selection for combinatorial search problems: A survey, AI Magazine 35 (3) (2014) 48–60. doi:10.1609/aimag.v35i3.2460.

[4] Y. Tadayonrad, A. B. Ndiaye, A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality, Supply Chain Analytics 3 (2023) 100026. doi:10.1016/j.sca.2023.100026.

[5] O. Zabraoui, Y. Hmamou, A. Chafi, S. Kammouri Alami, A comparative study of multi-algorithm optimization for inventory analytics in supply chains, Supply Chain Analytics 12 (2025) 100154. doi:10.1016/j.sca.2025.100154.

[6] F. M. Theunissen, S. Alam, A. Sajjad, A topological analytics framework for preserving decision structure in supply chain inventory classification, Supply Chain Analytics 15 (2026) 100229. doi:10.1016/j.sca.2026.100229.

[7] A. A. Syntetos, J. E. Boylan, J. D. Croston, On the categorization of demand patterns, J. Oper. Res. Soc. 56 (5) (2005) 495–503. doi:10.1057/palgrave.jors.2601841.

[8] R. Pietukhov, M. Ahtamad, M. Faraji-Niri, T. El-Said, A hybrid forecasting model with logistic regression and neural networks for improving key performance indicators in supply chains, Supply Chain Analytics 4 (2023) 100041. doi:10.1016/j.sca.2023.100041.

[9] R. N. Boute, J. Gijsbrechts, W. van Jaarsveld, N. Vanvuchelen, Deep reinforcement learning for inventory control: A roadmap, European Journal of Operational Research 298 (2) (2022) 401–412. doi:10.1016/j.ejor.2021.07.016.

[10] S. Makridakis, E. Spiliotis, V. Assimakopoulos, M5 accuracy competition: Results, findings, and conclusions, International Journal of Forecasting 38 (4) (2022) 1346–1364. doi:10.1016/j.ijforecast.2021.11.013.