AIPE: uma metodologia modular para seleção contextual de políticas de reposição

Matheus Inácio Batista Santos[a]

[a]*Instituto de Computação, Universidade Federal de Alagoas, Brasil*

Abstract

A gestão de estoques exige reconhecer quando adaptar a reposição ao contexto da demanda e quando conservar uma política de referência. Este artigo propõe o Adaptive Inventory Policy Engine (AIPE), uma metodologia modular de apoio ao gerente nessa decisão, buscando reduzir custos evitáveis sem deterioração relevante do atendimento. O procedimento conecta a caracterização da demanda, a avaliação de políticas candidatas e a recomendação contextual, com critérios explícitos para intervir e avaliar suas consequências. Seu módulo de seleção admite associação por perfil ou estimação por série. Um diagnóstico retrospectivo distingue falhas de seleção, insuficiência do portfólio e inviabilidade física do atendimento. Avaliamos essas escolhas em aplicações separadas com vendas de uma rede varejista brasileira e uma coorte histórica da base pública da quinta competição de previsão Makridakis (M5), com vendas do Walmart, sob condições simuladas. Na aplicação brasileira, a seleção por perfil amplia o atendimento com custo adicional, enquanto a regra conservadora de intervenção mantém a referência. No M5, prever a classe vencedora aumenta custo e reduz atendimento; prever consequências com recuo à referência reduz o custo médio em 1,96% e acrescenta 0,32 ponto percentual de atendimento, sem eliminar deteriorações individuais. O AIPE oferece um procedimento verificável para examinar o valor de contextualizar a escolha e localizar os componentes que precisam de revisão. Sua utilidade depende da instanciação e das consequências operacionais; a avaliação não constitui evidência de economia financeira realizada ou confirmação independente de todas as escolhas desenvolvidas.

Keywords: Inventory methodology, Modular decision support, Policy selection, Demand heterogeneity, Service level

1. Introdução

O gerente de logística e estoques precisa evitar custos desnecessários sem comprometer o atendimento. Selecionar políticas adequadas ao contexto da demanda é uma das decisões que podem apoiar esse objetivo. Vendas frequentes, intervalos sem demanda e picos ocasionais podem favorecer regras diferentes. A vantagem de contextualizar a escolha, porém, depende de reconhecer essas diferenças antes da decisão e convertê-las em resultados operacionais posteriores [1].

A escolha da família de política constitui uma decisão distinta da calibração de seus parâmetros. Uma referência global pode usar a mesma família em toda a rede e ainda ajustar lotes e limiares ao histórico de cada série. A seleção de algoritmos fornece uma formulação para ir além dessa referência: características da instância orientam a escolha de um método de um portfólio [2, 3]. No inventário, essa escolha precisa considerar tanto o custo quanto a viabilidade do atendimento.

A seleção contextual exige conectar três decisões: como representar a demanda, que evidência usar para recomendar e quando substituir a política de referência. Comparar candidatas retrospectivamente esclarece o potencial do portfólio; antecipar a melhor escolha requer informação disponível antes do teste. A avaliação também precisa identificar a origem de uma falha: erro do seletor, ausência de candidata viável ou impossibilidade física de atender ao alvo. Esse diagnóstico determina se a revisão deve incidir sobre a escolha, o portfólio ou as condições do sistema.

Propomos o *Adaptive Inventory Policy Engine* (AIPE), uma metodologia modular para organizar essa decisão. O procedimento especifica o problema, representa o contexto, constrói uma matriz comparável de consequências, recomenda pelo *Policy Selection Engine* (PSE) e avalia a escolha em dados reservados. O PSE admite associação por perfil ou estimação por série. Uma regra de intervenção explicita quando a candidata substitui a referência. Contratos de entrada, saída e informação permitem substituir métodos e reavaliar suas consequências mantendo o problema de decisão definido.

A contribuição principal é o AIPE como metodologia modular e rastreável de apoio ao gerente na escolha de políticas de reposição. O objetivo operacional é reduzir custos evitáveis sem deterioração relevante do atendimento. Três contribuições sustentam essa formulação:

1. **Seleção contextual.** Integrar o PSE por perfil e por estimação com contratos de informação, referência e escopo da restrição de serviço

explícitos.

2. **Diagnóstico das limitações.** Distinguir falhas de seleção, insuficiência do portfólio e inviabilidade física do atendimento por limites retrospectivos condicionais ao cenário.
3. **Avaliação empírica.** Examinar a utilidade e as limitações do procedimento em vendas reais brasileiras e na base pública da quinta competição de previsão Makridakis (M5), com vendas do Walmart [4], em análises separadas.

Essas contribuições se apoiam em métodos conhecidos. A integração entre classificação e inventário possui antecedentes; a comparação empírica com as integrações mais próximas permanece necessária para avaliar o diferencial do AIPE.

Examinamos o procedimento em vendas de uma rede varejista brasileira e em uma coorte histórica da base pública Walmart M5. As duas aplicações avaliam associação por perfil e estimação por série, com consequências simuladas e calibração harmonizada. Na Bahia, a seleção por perfil acrescenta atendimento com custo maior, enquanto o recuo por consequências mantém a referência. No M5, prever consequências com recuo reduz custo e aumenta atendimento médio, enquanto a classificação da família vencedora deteriora essas duas dimensões. As análises distinguem executar o procedimento, melhorar uma recomendação e demonstrar benefício de uso gerencial.

2. Trabalhos relacionados

O intervalo médio entre demandas (*average demand interval*, ADI) e o coeficiente de variação (CV) fundamentam a classificação ADI–CV^2, em que CV^2 é o quadrado do coeficiente. Essa classificação organiza padrões de frequência e tamanho da demanda [5]. Entretanto, classes estatísticas não determinam sozinhas a melhor reposição: custos, prazo, estoque inicial e atendimento também importam. Mohammaditabar et al. [6] integram classificação e escolha de políticas; Sheikh-Zadeh et al. [7] propõem classificação orientada ao desempenho em sistemas de múltiplos itens e escalões. O AIPE parte dessa relação entre classificação e desempenho e integra em seu procedimento uma regra explícita de intervenção e um diagnóstico das perdas frente ao portfólio e à viabilidade física. A avaliação deste artigo compara suas implementações internas; os métodos desses antecedentes permanecem fora da comparação empírica.

Na literatura da revista, Tadayonrad e Ndiaye [8] aproximam previsão e consequências operacionais. Theunissen et al. [9] discutem a informação decisória preservada pela classificação. Essa perspectiva orienta nossa avaliação pelo custo e pelo atendimento obtidos, em complemento à concordância entre famílias recomendadas. O método topológico discutido por esses autores oferece um antecedente conceitual, sem implementação nesta avaliação.

Zabraoui et al. [10] comparam algoritmos de inventário e combinações de busca genética e aprendizado por reforço com dados M5. A combinação de algoritmo genético (*genetic algorithm*, GA) e rede Q profunda (*deep Q-network*, DQN), denominada GA–DQN, integra nosso portfólio, com seus componentes como controles, sem ser apresentada como contribuição algorítmica. Granularidade, filtros, custos e implementação local impedem uma reprodução exata de seu ranking.

Políticas limitadas de estoque-base oferecem outra referência para vendas perdidas [11]. Suas propriedades teóricas não garantem desempenho para nossa calibração. Os resultados de reforço também dependem do estado, da recompensa e do orçamento [12]. O AIPE separa essas implementações da escolha entre candidatas. A avaliação do seletor precisa, ainda, separar desenvolvimento e teste para evitar otimismo após escolher configurações [13].

Francuz e Bányai [14] integram escolha de família e parâmetros em otimização multiobjetivo, usando aprendizado para aproximar o simulador. A aplicação tem demanda sintética sazonal e pedidos pendentes. Aprendizado orientado à consequência [15], predição com rejeição [16] e recuo à referência em aprendizado por reforço (*reinforcement learning*, RL) [17] também possuem antecedentes. O AIPE reúne essas ideias em um procedimento de seleção de famílias sob vendas perdidas, com referência calibrada e decomposição retrospectiva das falhas. A contribuição proposta é um procedimento verificável que registra a referência calibrada, a autorização para intervir e o diagnóstico das falhas de seleção, do portfólio e da viabilidade física. Classificação, predição de consequências e recuo fornecem os métodos constituintes. As aplicações examinam essa articulação na reposição com vendas perdidas; seus resultados não demonstram superioridade frente às integrações próximas, que permanecem sem confronto empírico neste estudo.

3. AIPE: metodologia modular

3.1. Objeto e procedimento

O AIPE apoia o gerente na escolha de uma família de reposição e de sua parametrização para um contexto de estoque, usando informação disponível antes da decisão. As séries loja–produto identificam contextos de demanda; diferenças entre elas não são interpretadas como medidas de eficiência dos gerentes ou das lojas. A aplicação começa pela definição de históricos e contexto, portfólio, ambiente de estoque, objetivo operacional e desenho de avaliação. A entrega pretendida reúne recomendação, parâmetros de aplicação, referência, alternativas, consequências esperadas e suporte da escolha, deixando a decisão de uso ao gerente. O registro distingue estimativas disponíveis na escolha e resultados conhecidos somente depois do horizonte de avaliação. Quando nenhuma candidata é viável, o registro conserva essa condição mesmo que uma contingência permita emitir a recomendação.

O procedimento tem cinco etapas: (1) especificar unidade, ambiente, objetivo e referência; (2) preparar históricos e representar o contexto; (3) calibrar candidatas e construir evidência de validação; (4) recomendar pelo PSE e aplicar a regra de intervenção; (5) avaliar em dados reservados e diagnosticar perdas. A Figura 1 apresenta o procedimento e sua extensão opcional de contexto; a Tabela 1 explicita os contratos metodológicos. Cada contrato define o que uma implementação recebe, o que entrega e quais informações pode usar.

O módulo opcional amplia as entradas do PSE preditivo com atributos disponíveis antes da decisão. O gestor pode fixar atributos, indicar candidatos à seleção ou excluí-los. A seleção interna busca redução de custo sob restrições de atendimento e limite de atributos. A variante ampliada preserva os fixos, mas sua adoção depende da comparação interna com o PSE básico. Essa escolha da representação antecede a regra de intervenção entre políticas. O benefício dessa ampliação deve ser verificado em cada aplicação. Um estudo adicional, separado da avaliação dos seletores, compara versões com e sem atributos adicionais sob o mesmo modelo e a mesma regra de intervenção.

3.2. Informação e configuração temporal

A aplicação declara produto, local, datas e unidades, histórico de demanda ou vendas, custos, prazo e meta de atendimento. Saldo, compromissos e pedidos em trânsito são necessários para orientar a próxima compra real;



Figura 1: Visão metodológica do Adaptive Inventory Policy Engine (AIPE). O Policy Selection Engine (PSE) admite associação por perfil ou estimação por série. A faixa tracejada representa o módulo opcional de contexto: escolhas do gestor, seleção interna de candidatos e comparação com o PSE básico. A regra de intervenção decide entre candidata e referência. O benefício do módulo adicional deve ser verificado em cada aplicação. Os históricos são ilustrativos.

na avaliação de políticas, podem ser substituídos por condições de cenário identificadas. Lotes mínimos, calendários e demais restrições aplicáveis delimitam as ações admissíveis. Cada entrada deve identificar origem observada, informada, estimada ou assumida em cenário, além de qualidade, transformações e disponibilidade temporal. Ausência de registro exige tratamento explícito.

O perfil pode ser fornecido ao PSE ou derivado do histórico admissível. Nas aplicações deste artigo, todos os perfis são derivados. A recomendação deve permitir consultar alternativas e rastrear a escolha até dados, regras e versões. Esse contrato é mais amplo que a persistência experimental atual, que ainda não reúne parâmetros finais de todas as políticas e trajetórias completas; os resultados não constituem ordens de compra executáveis.

Tabela 1: Contratos dos módulos do AIPE. Trocar o método preserva a responsabilidade e as restrições de informação.

Módulo	Entrada e saída	Contrato e instanciação avaliada
Especificação	Requisitos → cenário e regra	Definir custo, serviço e referência; aqui, vendas perdidas e prazo fixo
Contexto	Histórico → características ou perfil	Usar informação anterior à escolha; descritores e regras fixas
Evidência	Cenário e candidatas → consequências	Ajustar no treino e medir na validação; sete candidatas clássicas, GA e RL
PSE	Contexto e evidência → recomendação	Preservar objetivo e corte temporal; perfil, classe vencedora ou consequências previstas
Avaliação	Recomendação fixada → comparação e diagnóstico	Teste reservado, referência competitiva e perdas identificáveis

A configuração distingue período básico de observação e ação, ciclo de análise, cadência de revisão do PSE, horizonte de planejamento, janela histórica e frequência de atualização dos modelos. A cadência informada para a empresa-fonte é uma reavaliação por ciclo comercial; essa é uma configuração de aplicação. Rever a recomendação pode conservar a família e os parâmetros, sem retreinar o seletor. Mudar a escala temporal exige compatibilizar agregação, incidência dos custos e prazo com a informação disponível. A flexibilidade proposta exige validação em cada configuração examinada.

3.3. Substituição dos métodos e decisão de intervenção

A modularidade permite avaliar uma alternativa em uma etapa mantendo definido o problema das demais. Um controlador recebe o estado disponível e produz um pedido válido; um descritor resume o histórico anterior à escolha; um seletor recomenda uma família do portfólio. A comparação preserva custos, definição do serviço, cronologia e unidades de análise. Quando uma alternativa exige outras ações ou informações, a adaptação de seu contrato precisa ser verificada antes da comparação.

Seja Π o portfólio, x_i a descrição do treino e g_i o perfil. O PSE por perfil recomenda $m(g_i)$; o preditivo recomenda $f(x_i, g_i)$ ou $f(x_i)$. Aprender um rótulo ou estimar consequências por candidata são variantes da abordagem por estimação, não abordagens adicionais do PSE. A referência global mantém a família, com parâmetros calibrados individualmente. A regra de intervenção escolhe entre candidata $\widehat{\pi}_i$ e referência π_i^{ref}:

$$\pi_i^{\mathrm{AIPE}} = \begin{cases} \widehat{\pi}_i, & a_i = 1, \\ \pi_i^{\mathrm{ref}}, & a_i = 0. \end{cases}$$

O indicador a_i registra a decisão de intervir. Na implementação direta, toda recomendação é aplicada; na conservadora, a substituição exige o critério de benefício definido no desenvolvimento. Essa separação permite avaliar a candidata proposta e a regra que autoriza seu uso. Confiança de classe e serviço previsto são sinais para decidir, sujeitos a erro no atendimento realizado.

A avaliação exercita a substituição de controladores e seletores, mantendo a representação de contexto e o simulador. Nas séries avaliadas, todas as candidatas são calibradas exclusivamente no prefixo de treino. Suas trajetórias posteriores no teste permitem medir as recomendações e construir os oráculos retrospectivos. Essa despesa experimental difere do uso pretendido, em que evidências anteriores orientariam a família a calibrar; eventual economia computacional de implantação requer avaliação própria. A adaptação aqui estudada é a escolha por contexto entre origens; dentro de cada bloco de teste, a família permanece fixada por sete ciclos. As ações da política ao longo do bloco não constituem novas revisões do PSE.

A integridade da comparação exige uma matriz completa de candidatas, sementes e blocos. Imputação e codificação usam somente a partição de treinamento; recomendações, referências e intervenções são fixadas antes de medir o teste. A identificação de dados, configuração e código permite verificar quais resultados pertencem à mesma avaliação.

3.4. Custo, serviço e escolha

Para demanda d_t, quantidade atendida v_t, saldo I_t e pedido q_t, avaliamos

$$C = \sum_t [hI_t + p(d_t - v_t) + K\mathbf{1}(q_t > 0) + cq_t], \qquad F = \frac{\sum_t v_t}{\sum_t d_t}. \tag{1}$$

Os coeficientes h e p representam, respectivamente, custo de manutenção por unidade e ciclo e custo por unidade não atendida. O custo de emissão é K por pedido, acrescido de c por unidade pedida. O atendimento F corresponde ao *fill rate*, a fração da demanda atendida. Diferenças entre taxas de atendimento são expressas em pontos percentuais (p.p.). Com demanda zero, permanece indefinido; o custo continua contabilizado. Na instanciação, usamos $h = 1$, $p = 5$, $K = 50$ e $c = 0{,}5$, sem equivalência monetária calibrada.

As barras indicam médias aritméticas por caso série–origem, após agregar as sementes de cada candidata; serviços indefinidos são excluídos da média de atendimento. Na validação A, a regra global minimiza $\bar{C}_{\pi,A}$ entre candidatas com $\bar{F}_{\pi,A} \geq \alpha$, com $\alpha = 0{,}70$. A meta média permite casos individualmente abaixo do alvo. O PSE por perfil aplica essa regra a cada grupo A_g. Casos sem demanda não entram na média de serviço. Sem candidata viável, escolhe-se maior serviço e menor custo, registrando contingência. Perfis sem suporte usam a global. Empates no custo viável são resolvidos pelo identificador da política. Contingências empatadas em serviço preferem menor custo e depois identificador. A mesma convenção é aplicada às duas bases.

O rótulo supervisionado aplica a restrição à própria série de validação: menor custo viável ou, sem viável, maior serviço e menor custo. Se todas as opções têm serviço indefinido, utiliza menor custo e mantém a marcação de demanda zero. Classificador e seletores agregados não impõem a mesma distribuição da restrição. Incluímos a moda dos rótulos como controle para não atribuir toda diferença à capacidade preditiva.

3.5. Características e perfis

O preditivo recebe 17 descritores: ADI, CV^2, intermitência, proporção de zeros, maior e média das sequências de zeros, *burstiness*, assimetria, curtose, entropia, tendência, autocorrelação, média, desvio-padrão, CV, extensão e número de ciclos positivos. O perfil categórico deriva desses descritores, sem constituir informação independente.

Os perfis usam regras ordenadas e fixas: esparso (ADI $\geq 1{,}32$, $\mathrm{CV}^2 \geq 0{,}49$, sequência de zeros ≥ 5); volatilidade/sazonalidade (autocorrelação $\geq 0{,}25$ ou burstiness $\geq 0{,}30$); tendência instável (tendência absoluta $\geq 0{,}05$ ou entropia ≥ 2); baixo volume estável (média ≤ 2 e $\mathrm{CV}^2 < 0{,}49$); e venda frequente (ADI $< 1{,}32$). A primeira regra satisfeita define o perfil; o residual é esparso. ADI é $n/\max(n_+, 1)$ e CV^2 inclui zeros, diferindo da taxonomia original baseada em tamanhos positivos. Os nomes são heurísticos.

Burstiness compara o desvio e a média dos intervalos positivos pela razão de sua diferença e soma, com regularização numérica. Tendência é a inclinação ajustada por mínimos quadrados ordinários dividida pela média; entropia usa dez classes de mesma largura. A autocorrelação na defasagem 17 recebe zero com até 18 ciclos ou variância desprezível. Essa convenção denota estimativa indisponível, não ausência de sazonalidade; com 23 ciclos, há somente seis pares.

4. Desenho experimental

A avaliação acompanha as decisões apoiadas pelo AIPE, sem medir adoção ou eficácia do uso por gerentes, em três perguntas. A seleção por perfil melhora o compromisso entre custo e atendimento frente à referência global? A estimação por série acrescenta valor e a regra de intervenção preserva esse valor? As falhas de atendimento decorrem da seleção, do portfólio ou de restrições físicas? As duas bases permitem examinar as três perguntas, incluindo a substituição do preditivo por classe por um seletor de consequências na mesma matriz de controladores.

4.1. Bases e unidades de análise

A Tabela 2 distingue as avaliações. Na Bahia, transações complementares são somadas por loja, produto e ciclo; a preparação preenche com zero células sem agregado registrado. Esse preenchimento pressupõe cobertura das vendas e não comprova demanda nula. A coorte retrospectiva contém 145 séries, 115 unidades comerciais e nove produtos. As unidades correspondem aos revendedores identificados na fonte e são denominadas lojas nesta avaliação. Os 38 ciclos disponíveis, de 202301 a 202504, são unidades comerciais da fonte, não meses.

O M5 é uma fonte pública de vendas associada a uma competição de previsão [4]. A avaliação utiliza uma coorte histórica local de 2.408 identificadores loja–produto da categoria de alimentos (`FOODS`), nas dez lojas de Califórnia, Texas e Wisconsin. Os códigos CA, TX e WI identificam esses estados; por exemplo, CA_2 identifica uma loja da Califórnia. Usamos ciclos completos de 21 dias, sem remover picos por regras baseadas no intervalo interquartil. A elegibilidade é reavaliada no prefixo de cada origem: 885 séries aos 50 ciclos, 2.033 aos 64 e 2.408 aos 78.

A elegibilidade exige três ciclos positivos no prefixo, dentro dos identificadores históricos disponíveis. O recorte não representa todas as séries FOODS

Tabela 2: Matrizes completas analisadas. Casos série–origem e sementes não são séries independentes.

Dimensão	Bahia	M5
Séries / lojas	145 / 115	2.408 / 10
Origens de treino (ciclos)	17 e 23	50, 64 e 78
Validação / teste por origem	7 / 7	7 / 7
Casos série–origem	290	5.326
Ajustes de políticas	4.350	79.890
Testes sem demanda	7	188
Seletores	Perfil e estimação	Perfil e estimação

do M5. É inspirado no contexto de Zabraoui et al., sem afirmar identidade com sua amostra. As 5.326 observações série–origem repetem identificadores: custo usa todos os casos e atendimento médio os 5.138 com demanda positiva no teste. Há 69, 106 e 13 casos sem demanda nas respectivas origens. Um piloto anterior de 30 séries orientou o desenvolvimento dos seletores; a ampliação não constitui, por si, confirmação independente.

4.2. Simulador, portfólio e calibração

O prazo exato é de dois ciclos. A política observa o estado anterior ao recebimento; entregas chegam antes da demanda. Quantidades podem ser fracionárias. Faltas são vendas perdidas, sem pedidos pendentes. Manutenção incide no saldo após demanda e o pedido é custeado na emissão, sem crédito terminal.

Validação e teste começam em estados comuns às candidatas, produzidos por uma referência de lote econômico de compra (*economic order quantity*, EOQ): seis ciclos passados aquecem o sistema, e sua trajetória na validação determina estoque e pipeline do teste. Esses estados usam o passado, mas não representam a continuação particular de cada candidata. Escalas são calculadas no treino.

O portfólio contém EOQCycle, sSCycle, CappedBaseStock, GA, otimização proximal de políticas (*proximal policy optimization*, PPO), GA–DQN e DQN. Denotamos por μ e σ a média e o desvio-padrão da demanda no prefixo de treino. EOQCycle usa lote $\max(1, \sqrt{2\mu K/h})$ e ponto de pedido $2\mu+1{,}28\sigma\sqrt{2}$; sSCycle repõe até o ponto acrescido do lote. CappedBaseStock limita a quantidade da reposição até um alvo e calibra alvo e teto em grade 20×12. GA ajusta gatilho, lote e proteção com população 100 e 50 gerações.

DQN usa Double DQN dueling; PPO usa otimização proximal. Ambos têm duas camadas de 64 unidades, 20 ações e no mínimo 20 mil transições, arredondadas ao episódio completo. GA–DQN acrescenta busca genética e mil demonstrações, mantendo gatilho e piso iguais nas demonstrações, treino e inferência.

Os quatro métodos estocásticos usam sementes 11, 29 e 47; as três referências determinísticas têm um ajuste. As sementes são promediadas antes da avaliação por caso. O híbrido tem esforço superior ao DQN, sem equivalência de orçamento.

Os objetivos de calibração incluem penalidades de atendimento, distintas do custo C reportado. GA minimiza $C + 30 \max(0; 0{,}70 - F) \max(C; 1)$ no treino. DQN, PPO e GA–DQN recebem recompensa de custo negativo e penalidade terminal $30 \max(0; 0{,}70 - F)S$, com escala fixa $S = \max(p \sum_t d_t; 1)$ calculada na demanda do episódio de treino.

A CappedBaseStock minimiza custo acrescido da penalidade de atendimento com escala fixa. Os pesos adicionais de ruptura e amplificação de pedidos são zero nas duas bases. Penalidades orientam a calibração sem garantir o alvo; a seleção aplica depois a viabilidade observada na validação. A harmonização conserva a definição do objetivo entre bases, sem tornar suas demandas e condições equivalentes.

4.3. Avaliação dos seletores

Em cada origem, uma loja inteira fica fora do conjunto que define a escolha. O PSE usa a validação das demais lojas e recomenda para o teste da loja reservada. A família global é comum às séries recomendadas nessa partição e origem; pode mudar entre lojas reservadas e entre origens. Controladores continuam calibrados no histórico da própria série: avaliamos transferência do seletor com histórico disponível, não implantação sem dados prévios.

O preditivo por classe utiliza XGBoost com 200 árvores, profundidade três, taxa 0,05, sem subamostragem e com semente fixa. Imputação, codificação categórica e definição das classes são ajustadas dentro de cada partição de treinamento. Classes raras não são removidas; treinos de classe única usam classificador constante. A ablação sem perfil mantém os demais componentes. O tamanho de treino depende da origem e da loja excluída; não se usam origens posteriores para recomendar em uma origem anterior.

O piloto anterior foi usado para desenvolver alternativas de aprendizagem e recuo. Na avaliação consolidada, as implementações são aplicadas às matrizes completas das duas bases. As recomendações são gravadas antes

da pontuação no teste, mas esse procedimento não elimina o uso prévio do piloto no desenvolvimento [13].

A comparação por consequências reutiliza cada matriz e substitui a implementação do PSE, sem repetir ajustes de controladores. Duas florestas ExtraTrees estimam custo e serviço por candidata: 64 árvores, profundidade quatro, mínimo de três observações por folha e semente fixa. Custo usa $\log(1+C)$, transformado de volta; serviço exclui alvos indefinidos. A seleção direta escolhe o menor custo previsto viável; sem viável, prioriza serviço e depois custo.

A variante com recuo à global exige serviço previsto $\geq 0{,}70$, não inferior ao previsto da referência, e economia acima de uma margem em $\{0; 0{,}02; 0{,}05; 0{,}10; \infty\}$. A margem minimiza custo em validação interna, sujeita a serviço médio não inferior à referência. Em cada origem, uma loja externa fica reservada e as demais são divididas em cinco grupos internos de lojas; cada grupo recebe previsões produzidas sem suas observações. A margem é fixada antes da recomendação externa. Um classificador ExtraTrees com a mesma regularização controla a aprendizagem por rótulo, e uma ablação retira perfil do seletor por consequências sem recuo. A comparação permanece uma avaliação de desenvolvimento, sem garantia de atendimento futuro.

Na Bahia, os testes compartilham um ciclo; no M5, ocupam os ciclos 58–64, 72–78 e 86–92, sem sobreposição. Origens repetem séries. Intervalos exploratórios usam bootstrap pareado por loja, preservando séries e origens, com 5.000 sorteios em cada base. Seletores e controladores permanecem fixos; a incerteza é condicional, sem novos treinamentos. O M5 mantém somente dez lojas, limitando a precisão dos intervalos apesar do maior número de séries.

4.4. Oráculos e informação perfeita

O melhor controlador único no teste é um diagnóstico retrospectivo. O oráculo do portfólio escolhe, por série–origem, a candidata de menor custo viável nas médias de teste entre sementes. Essas escolhas não fornecem rótulos ao treinamento. O acerto exige serviço mínimo e empate numérico no menor custo; não exige identidade nominal da política.

Nas duas bases, um programa linear inteiro misto (*mixed-integer linear programming*, MILP) conhece toda a demanda de teste e otimiza pedidos sob os mesmos custos, prazo e condições iniciais. Quantidades são contínuas; variáveis binárias representam emissão e complementaridade entre saldo e falta.

É um ótimo determinístico condicional, não um controlador estocástico implantável. Se 0,70 for fisicamente impossível antes das primeiras entregas, maximiza atendimento e depois minimiza custo. Soluções são reexecutadas no simulador e somente as comprovadamente ótimas recebem essa denominação.

A eficiência de custo é $100C^*/C_{\mathrm{PSE}}$. Aqui, C^* denota o custo da referência retrospectiva considerada: o mínimo viável do portfólio ou o ótimo do MILP, conforme a comparação. Calculamos a razão apenas quando referência e recomendação satisfazem o mesmo critério de serviço; ambos os custos zero equivalem a 100%. Serviço insuficiente não recebe crédito por custo baixo. A comparação com o MILP usa cada realização de treinamento viável: uma média entre sementes pode satisfazer o alvo sem que todas o satisfaçam. Repetir políticas determinísticas nessa análise não gera novas observações independentes.

5. Resultados da avaliação unificada

Tabela 3: Bahia: resultados por caso série–origem. Custo: 290 casos; atendimento: 283 casos definidos. Custo em unidades de cenário.

Implementação	Custo médio	Atendimento	Viáveis	Trocas
Referência global	161,31	73,62%	164	0
PSE por perfil	164,41	77,51%	183	80
PSE por classe (XGBoost)	166,57	70,04%	155	206
Classe: floresta de controle	155,79	68,16%	154	143
Consequências	159,05	72,77%	165	106
Consequências sem perfil	161,65	74,07%	170	90
Consequências com recuo	161,31	73,62%	164	0

Trocas indicam política diferente da referência global; viáveis têm atendimento $\geq 0{,}70$.

5.1. Consequências da seleção e da intervenção

Na Bahia, o perfil acrescenta 3,89 pontos percentuais de atendimento com custo 1,93% maior que a global (Tabela 3). Recupera 19 casos abaixo da meta, sem criar novas violações, mas não entrega redução de custo. O preditivo por classe custa 3,26% mais e perde 3,58 pontos de atendimento. A previsão direta de consequências reduz custo em 1,40%, com perda de 0,86

Tabela 4: M5: resultados por caso série–origem. Custo: 5326 casos; atendimento: 5138 casos definidos. Custo em unidades de cenário.

Implementação	Custo médio	Atendimento	Viáveis	Trocas
Referência global	779,46	68,27%	2448	0
PSE por perfil	780,80	68,49%	2471	411
PSE por classe (XGBoost)	811,31	65,37%	2255	4259
Classe: floresta de controle	812,42	63,99%	2177	4299
Consequências	760,45	68,08%	2456	3629
Consequências sem perfil	761,77	67,92%	2440	3655
Consequências com recuo	764,20	68,59%	2472	679

Trocas indicam política diferente da referência global; viáveis têm atendimento $\geq 0{,}70$.

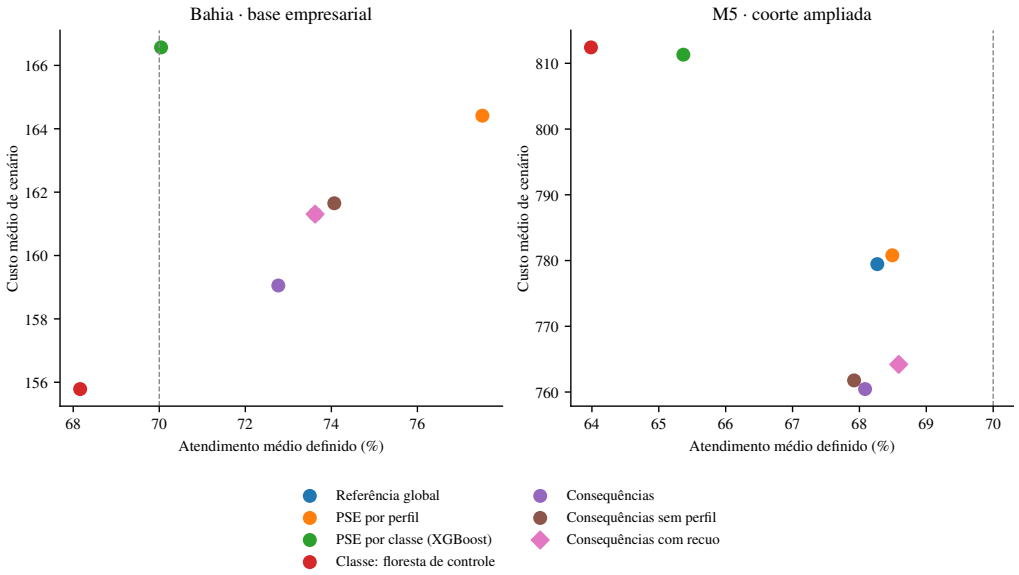


Figura 2: Custo e atendimento nas duas aplicações. As médias não mostram a distribuição individual nem constituem fronteira de dominância por série.

ponto; seu recuo conserva a global nos 290 casos. As diferenças mostram que contextualização, previsão e intervenção têm consequências distintas.

No M5, o perfil permanece próximo da global, com custo 0,17% maior e acréscimo de 0,22 ponto de atendimento (Tabela 4). O preditivo por classe custa 4,09% mais e perde 2,90 pontos; a floresta de classe também apresenta maior custo e menor serviço. A previsão direta de consequências reduz custo

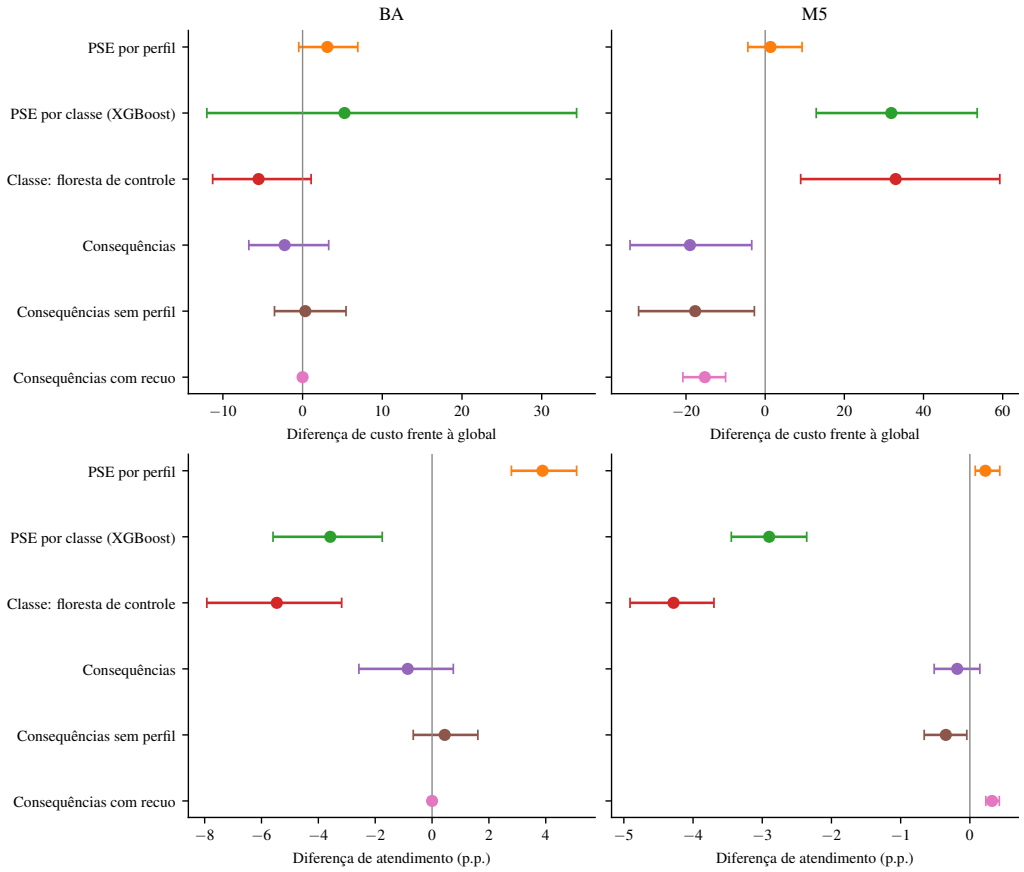


Figura 3: Diferenças pareadas frente à referência global. Intervalos condicionais por loja, preservando produtos e origens; dez lojas limitam a precisão no M5.

em 2,44%, mas perde 0,18 ponto de atendimento. Com recuo, reduz custo em 1,96% e aumenta atendimento em 0,32 ponto. O atendimento médio resultante é 68,59%, abaixo de 70%: a melhora frente à referência não equivale ao cumprimento do alvo.

O recuo modifica 679 das 5.326 escolhas M5, frente a 3.629 da previsão direta. A diferença média de custo é $-15{,}25$ unidades do cenário, com intervalo condicional de 95% $[-20{,}79; -10{,}01]$; a de serviço é 0,32 ponto, com intervalo $[0{,}23; 0{,}43]$ (Figura 3). Há economia em 560 casos, mas também 97 casos com custo maior e 149 com atendimento menor. São 19 novas violações do alvo e 43 recuperações, elevando os casos viáveis de 2.448 para 2.472. A maior economia individual corresponde a 1,84% das economias positivas. Es-

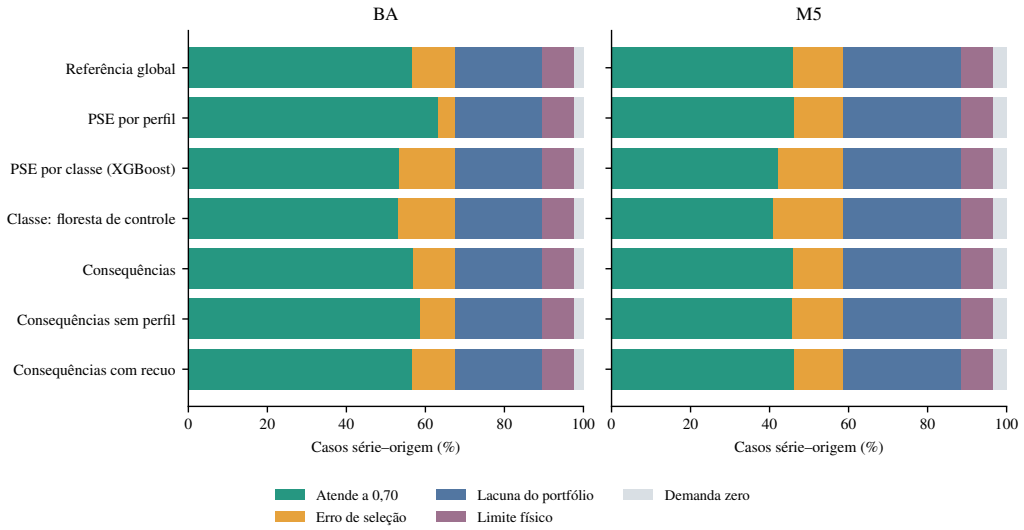


Figura 4: Diagnóstico retrospectivo dos casos. A classificação distingue falha de seleção, cobertura do portfólio e restrição física inicial; demanda zero mantém atendimento indefinido.

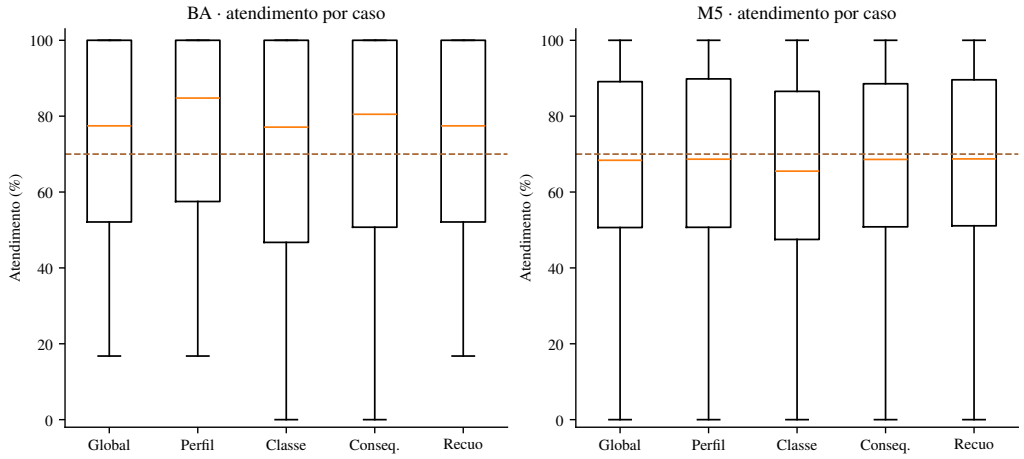


Figura 5: Distribuição do atendimento nos casos com demanda positiva; linha horizontal indica 70%. Extremos são omitidos da exibição dos boxplots, mas permanecem nos cálculos.

ses resultados caracterizam benefício médio acompanhado de deteriorações, sem garantia por série.

5.2. Distância às referências retrospectivas

A previsão por consequências com recuo iguala o menor custo viável do portfólio em 417 dos 2.472 casos M5 comparáveis, com eficiência média condicional de 69,77%. Os conjuntos comparáveis dependem da recomendação satisfazer o alvo; suas médias não constituem comparação no mesmo subconjunto. Das 5.326 instâncias com informação perfeita, todas têm otimalidade comprovada. Na variante com recuo, 3.005 realizações de treinamento permitem comparar custo sob serviço compatível: 122 igualam o ótimo determinístico e a eficiência média é 47,56%. Realizações e casos são denominadores diferentes; sementes não ampliam a população independente. Essas distâncias delimitam oportunidades condicionais, sem estimar economia disponível a uma política que desconhece a demanda futura.

Na decomposição M5 do recuo, 2.472 casos atendem ao alvo, 649 têm alternativa viável não escolhida, 1.586 não têm candidata viável apesar de possibilidade física, 431 apresentam restrição física inicial e 188 não têm demanda (Figura 4). Na Bahia, o recuo conserva as 32 falhas de seleção da referência; outras 64 falhas decorrem da cobertura do portfólio e 23 das condições iniciais. A Figura 5 complementa as médias com a dispersão do atendimento individual.

5.3. Avaliação do contexto adicional

Tabela 5: Incremento do contexto adicional em relação ao PSE básico da mesma instância. Variação negativa de custo indica economia; atendimento em pontos percentuais. Nesta rodada, selecionada e protegida coincidem em todas as recomendações.

Base	Instância	Δ custo (%)	Δ atendimento (p.p.)
Bahia	Classe	-1,176	-1,265
Bahia	Consequências	+0,000	+0,000
M5	Classe	-0,204	+0,337
M5	Consequências	-0,035	-0,003

O módulo adicional foi avaliado reutilizando as matrizes de políticas, sem novos ajustes dos controladores. Foram comparados o PSE básico, todos os atributos admissíveis, a seleção interna de atributos e sua ativação protegida,

separadamente nas instâncias por classe e por consequências. Os contrastes usam florestas de 32 árvores com os mesmos parâmetros entre variantes; portanto, suas referências básicas não se confundem com o classificador XGBoost nem com as variantes canônicas de 64 árvores. Não houve atributos adicionais impostos pelo gestor: a variante de atributos fixos coincide com a básica.

Na Bahia, idade, segmento comercial e filial foram incorporados sob a premissa declarada pelo autor de que o cadastro foi extraído diretamente do banco no mesmo período. Essa confirmação não substitui um histórico de alterações por campo. No M5, foram usados departamento do produto, preço histórico, indicação estadual do Supplemental Nutrition Assistance Program (SNAP), programa norte-americano de assistência alimentar, e eventos do último bloco completo de 21 dias do prefixo. Nenhuma informação futura foi usada; o preço funciona como contexto e não altera os custos unitários do ambiente.

A redução de custo por classe na Bahia (1,176%) veio acompanhada de queda de 1,265 ponto percentual no atendimento. Assim, o ganho de custo não satisfaz isoladamente a finalidade gerencial do AIPE. A instância por consequências manteve exatamente as decisões básicas. No M5, os efeitos selecionados foram pequenos: 0,204% de economia e 0,337 ponto percentual adicional por classe; por consequências, 0,035% de economia e variação de -0,003 ponto percentual.

O bootstrap pareado de 5.000 reamostragens por loja/revendedor, preservando produtos e origens no mesmo grupo, produziu para a variação de custo os intervalos condicionais de 95% [-2,895; 0,371] na Bahia por classe e [-0,684; 0,345] no M5 por classe. Para o atendimento, os respectivos intervalos foram [-2,423; -0,339] e [0,122; 0,609] pontos percentuais. Esses intervalos descrevem os modelos congelados, sem refazer a seleção ou o ajuste; no M5 há somente dez lojas.

Usar todos os atributos também não assegurou vantagem da seleção. No M5 por classe, todos os atributos reduziram o custo em 0,540%, ante 0,204% com seleção, mas com menor incremento de atendimento (0,132 ante 0,337 ponto percentual). Na Bahia por classe, todos os atributos elevaram o custo em 0,044% e reduziram o atendimento. Os contrastes sustentam a necessidade de avaliar informação adicional pelo efeito operacional, sem estabelecer superioridade geral da seleção de atributos ou garantia de atendimento da regra de ativação.

A rodada constitui desenvolvimento: os resultados canônicos já eram co-

nhecidos, as partições de treino dos seletores se sobrepõem e não se realizou confirmação independente. A ampliação permanece opcional; eventuais economias devem ser examinadas com as deteriorações por caso e a relevância definida pelo gestor.

A Figura 6 apresenta os contrastes de custo e atendimento e sua incerteza condicional.

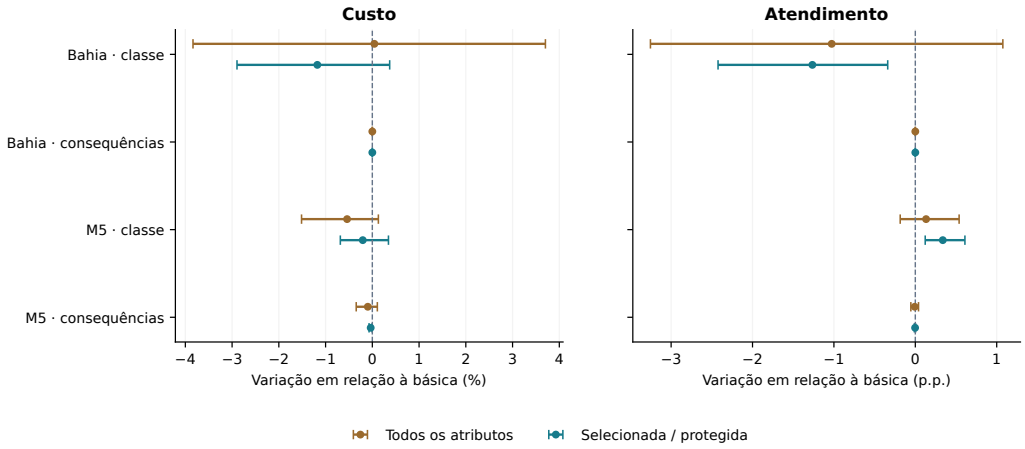


Figura 6: Efeito incremental do contexto sobre custo (esquerda) e atendimento (direita), perante o PSE básico da mesma instância. Pontos: variações observadas; barras: intervalos condicionais de 95% de 5.000 reamostragens pareadas por loja/revendedor, mantendo produtos e origens agrupados. Custo negativo indica economia. Seleção e ativação protegida coincidiram nesta rodada. O bootstrap não refaz os ajustes; o M5 possui dez lojas.

6. Discussão

A relevância prática depende do contexto do gerente, da escala dos custos evitados e do atendimento preservado, sem exigir um percentual mínimo universal de economia. A avaliação deve fornecer magnitude, incerteza, deteriorações e rastreabilidade para esse julgamento. Ausência de diferença estatisticamente detectável não demonstra equivalência ou não inferioridade; uma garantia desse tipo exigiria margem e desenho próprios. Custos de cenário não autorizam converter diferenças em economia realizada em reais.

As duas aplicações mostram por que o AIPE avalia a seleção contextual frente a uma referência calibrada por série. A variação das vencedoras do portfólio oferece oportunidades de escolha, enquanto os resultados dos

seletores revelam quanto desse potencial é efetivamente aproveitado. A compatibilidade entre módulos permite realizar essas comparações; o benefício operacional depende das consequências da recomendação em dados reservados.

Na Bahia, a seleção por perfil acrescenta atendimento com custo pontualmente maior; na segunda origem, coincide com a escolha global. Esse comportamento mostra que a utilidade da segmentação depende da janela e do critério operacional. A base brasileira fortalece a relevância aplicada da avaliação ao preservar heterogeneidade observada em vendas empresariais, enquanto a simulação e a possível censura por ruptura delimitam a interpretação econômica.

A coorte M5 amplia o suporte disponível para aprender recomendações, mas mantém somente dez lojas e forte concentração em um perfil. A previsão de consequências com recuo melhora custo e atendimento médios, enquanto os classificadores avaliados deterioram essas dimensões. Aumento do número de séries, diversidade do contexto e escolha do alvo de aprendizagem são questões diferentes. O controle por floresta de classe torna a comparação mais informativa, mas não constitui ablação de todas as escolhas de modelo e regularização.

A regra de intervenção torna explícito quanto o PSE modifica a referência e com que consequência. Na Bahia, a variante por consequências com recuo reproduz a global nos 290 casos; no M5, intervém em 679 casos e melhora as médias, acompanhada de novas violações individuais. Conservar a referência é uma saída admitida quando a validação interna não justifica substituí-la, sem demonstrar valor adicional do preditivo. A intervenção seletiva apresenta utilidade na instanciação M5 avaliada, sem garantir preservação futura do atendimento.

O diagnóstico retrospectivo distingue falhas de seleção, insuficiência do portfólio e inviabilidade física, sob as hipóteses do simulador. Essa classificação identifica oportunidades de revisão; não estabelece causas de rupturas observadas na empresa. Havendo candidata viável, cabe revisar a escolha; sem candidata viável, deve-se examinar o portfólio e sua calibração; diante de inviabilidade física, é necessário rever as condições do sistema. A distinção orienta qual componente do AIPE merece revisão e evita atribuir toda ruptura ao modelo preditivo.

O suporte do contexto também limita a transferência das recomendações. Na primeira origem M5, 826 das 885 séries elegíveis são esparsas, 57 têm tendência e duas pertencem ao grupo volatilidade/sazonalidade. A concentração

persiste nas origens seguintes: 1.977 de 2.033 e 2.360 de 2.408 séries são esparsas. O maior volume de dados não elimina a baixa cobertura dos demais perfis. A avaliação precisa considerar esse suporte e o objetivo de atendimento: meta média, atendimento ponderado e garantia por série expressam exigências distintas. A comparação entre módulos só é interpretável quando conserva essa definição.

7. Limitações e próximos testes

Vendas podem omitir demanda censurada por falta. Coortes históricas, elegibilidade por origem e horizontes de sete ciclos restringem população e período. Produtos compartilhados entre lojas podem gerar dependência não capturada inteiramente pelo bootstrap.

Não se trata de experimento causal de implantação nem de avaliação com usuários. A fotografia de estoque brasileiro disponível em maio de 2025 é posterior aos testes e não fornece seus saldos iniciais históricos. Custos não são financeiramente calibrados, não há suprimento conjunto e o estado inicial comum não reproduz trajetórias particulares. Os esforços desiguais de ajuste limitam comparações entre algoritmos; a harmonização da CappedBaseStock não elimina diferenças de demanda, escala ou cobertura entre as bases.

O piloto orientou as extensões com recuo; a aplicação às matrizes completas não constitui confirmação independente. A substituição foi exercitada nas candidatas e no PSE, sem ablação de todas as representações e ambientes. A portabilidade integral permanece uma hipótese de uso. Sensibilidades de custo, prazo e horizonte e comparação com integrações próximas da literatura são necessárias para ampliar o alcance da evidência. A confirmação requer escolhas fixadas antes de examinar testes reservados. Uma avaliação com revisão do PSE a cada ciclo deverá manter a trajetória própria de estoque e pedidos em trânsito de cada estratégia, inclusive ao mudar de família. Ela exige desenho sequencial adicional, pois os blocos atuais não validam essa rotina.

O módulo opcional de contexto requer disponibilidade anterior à decisão e separação entre seleção de atributos e pontuação externa. Seu estudo adicional é de desenvolvimento e utiliza uma floresta de 32 árvores e uma regra de intervenção fixa, compartilhadas entre as variantes comparadas. Portanto, seus contrastes medem a inclusão de contexto dentro desse estudo; diferenças frente aos seletores de 64 árvores ou ao XGBoost da avaliação principal não

podem ser atribuídas somente aos atributos. No caso brasileiro, a correspondência do cadastro com o período é informada pelo autor, sem histórico de alterações por campo, limitando a verificação retrospectiva.

8. Conclusão

O AIPE propõe uma metodologia modular de apoio ao gerente de logística e estoques para examinar custos evitáveis e atendimento. Organiza a seleção contextual em cinco etapas, desde a especificação do problema até o diagnóstico dos resultados. A metodologia vincula a representação da série loja–produto à evidência de validação, à recomendação do PSE e à decisão de substituir a referência. A seleção por perfil e por estimação, o diagnóstico retrospectivo e as aplicações complementares sustentam essa contribuição central. Os resultados exercitam a substituição de controladores e seletores; a rastreabilidade completa da entrega gerencial permanece pendente.

A avaliação delimita onde essas escolhas ajudam. Na Bahia, o perfil acrescenta 3,89 pontos percentuais de atendimento com aumento de custo de 1,93%, enquanto o recuo por consequências conserva a referência. No M5, a estimação por consequências com recuo reduz custo em 1,96% e acrescenta 0,32 ponto de atendimento; a classificação da família vencedora deteriora ambos. Os ganhos médios coexistem com novas falhas individuais e não atingem atendimento médio de 70%. A evidência sustenta a execução, a utilidade diagnóstica e um benefício operacional condicionado à instanciação, sem demonstrar vantagem universal ou economia financeira realizada.

A confirmação requer avaliação da regra de intervenção em dados reservados, excluídos do desenvolvimento, e sensibilidades das condições de uso. O critério decisivo será a capacidade de reconhecer quando uma recomendação contextual compensa e quando preservar a referência, considerando serviço, custo e deteriorações.

Disponibilidade de dados e código

Os dados brasileiros são proprietários e não são redistribuídos; o M5 é público. Código, configurações e fontes estão em `https://github.com/matheus013/msc`. Dados, bancos e modelos ficam fora da versão atual do repositório. Manifestos e snapshots locais identificam as matrizes; pacote arquivado e derivados autorizados deverão acompanhar a submissão. Não se promete acesso aos registros restritos mediante solicitação.

Autoria, financiamento e interesses

Autoria, contribuições dos autores, financiamento, agradecimentos e interesses devem ser confirmados pelos autores responsáveis. O manuscrito em português requer tradução, revisão humana e fechamento das declarações antes da submissão.

Uso de inteligência artificial na preparação do manuscrito

OpenAI Codex auxiliou organização bibliográfica, leitura de código, análise, visualização e redação. A figura conceitual usa desenhos vetoriais programáticos; os gráficos quantitativos derivam das matrizes identificadas. Conferência e responsabilidade pelo texto final cabem aos autores humanos. Sistemas de inteligência artificial não são autores.

Referências

[1] S. Axsäter, Inventory Control, 2nd Edition, Vol. 90 of International Series in Operations Research & Management Science, Springer US, New York, NY, USA, 2006. doi:10.1007/0-387-33331-2.

[2] J. R. Rice, The algorithm selection problem, in: Advances in Computers, Vol. 15, Academic Press, 1976, pp. 65–118. doi:10.1016/S0065-2458(08)60520-3.

[3] L. Kotthoff, Algorithm selection for combinatorial search problems: A survey, AI Magazine 35 (3) (2014) 48–60. doi:10.1609/aimag.v35i3.2460.

[4] S. Makridakis, E. Spiliotis, V. Assimakopoulos, M5 accuracy competition: Results, findings, and conclusions, International Journal of Forecasting 38 (4) (2022) 1346–1364. doi:10.1016/j.ijforecast.2021.11.013.

[5] A. A. Syntetos, J. E. Boylan, J. D. Croston, On the categorization of demand patterns, J. Oper. Res. Soc. 56 (5) (2005) 495–503. doi:10.1057/palgrave.jors.2601841.

[6] D. Mohammaditabar, S. H. Ghodsypour, C. O'Brien, Inventory control system design by integrating inventory classification and policy selection, International Journal of Production Economics 140 (2) (2012) 655–659. doi:10.1016/j.ijpe.2011.03.012.

[7] A. Sheikh-Zadeh, M. D. Rossetti, M. A. Scott, Performance-based inventory classification methods for large-scale multi-echelon replenishment systems, Omega 101 (2021) 102276. doi:10.1016/j.omega.2020.102276.

[8] Y. Tadayonrad, A. B. Ndiaye, A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality, Supply Chain Analytics 3 (2023) 100026. doi:10.1016/j.sca.2023.100026.

[9] F. M. Theunissen, S. Alam, A. Sajjad, A topological analytics framework for preserving decision structure in supply chain inventory classification, Supply Chain Analytics 15 (2026) 100229. doi:10.1016/j.sca.2026.100229.

[10] O. Zabraoui, Y. Hmamou, A. Chafi, S. Kammouri Alami, A comparative study of multi-algorithm optimization for inventory analytics in supply chains, Supply Chain Analytics 12 (2025) 100154. doi:10.1016/j.sca.2025.100154.

[11] L. Xin, Technical note—understanding the performance of capped base-stock policies in lost-sales inventory models, Operations Research 69 (1) (2021) 61–70. doi:10.1287/opre.2020.2019.

[12] R. N. Boute, J. Gijsbrechts, W. van Jaarsveld, N. Vanvuchelen, Deep reinforcement learning for inventory control: A roadmap, European Journal of Operational Research 298 (2) (2022) 401–412. doi:10.1016/j.ejor.2021.07.016.

[13] G. C. Cawley, N. L. C. Talbot, On over-fitting in model selection and subsequent selection bias in performance evaluation, Journal of Machine Learning Research 11 (2010) 2079–2107.
URL https://www.jmlr.org/papers/v11/cawley10a.html

[14] Á. Francuz, T. Bányai, Metaheuristic-based model selection framework for eoq and inventory policies using machine learning and multi-objective optimization, Algorithms 19 (5) (2026) 415. doi:10.3390/a19050415.

[15] A. N. Elmachtoub, P. Grigas, Smart predict, then optimize, Management Science (2022). doi:10.1287/mnsc.2020.3922.

[16] Y. Geifman, R. El-Yaniv, Selectivenet: A deep neural network with an integrated reject option, in: Proceedings of the 36th International Conference on Machine Learning, Vol. 97, 2019, pp. 2151–2159.
URL https://proceedings.mlr.press/v97/geifman19a.html

[17] R. Laroche, P. Trichelair, R. Tachet des Combes, Safe policy improvement with baseline bootstrapping, in: Proceedings of the 36th International Conference on Machine Learning, Vol. 97, 2019, pp. 3652–3661.
URL https://proceedings.mlr.press/v97/laroche19a.html