AIPE: uma metodologia modular para seleção contextual de políticas de reposição

Matheus Inácio Batista Santos[a]

[a]*Instituto de Computação, Universidade Federal de Alagoas, Brasil*

Abstract

A heterogeneidade da demanda motiva selecionar políticas de reposição por contexto, mas a diversidade de vencedoras não assegura recomendações melhores. Propomos o Adaptive Inventory Policy Engine (AIPE), uma metodologia modular que vincula representação do contexto, evidência operacional, seleção e avaliação. Seu Policy Selection Engine (PSE) associa perfis a famílias de políticas ou estima recomendações por série, com uma regra explícita para substituir ou conservar a referência. Avaliamos sete candidatas em duas aplicações separadas. Na Bahia, 145 séries em duas origens totalizam 4.350 ajustes; a seleção por perfil aumenta o atendimento em 3,89 pontos percentuais e o custo em 1,93% frente à referência global. No piloto Walmart M5, 30 séries de dez lojas em três origens totalizam 1.350 ajustes. O preditivo por classe apresenta custo 13,9% maior e atendimento 4,11 pontos inferior. Uma extensão exploratória por consequências previstas, com recuo à referência, reduz custo em 1,56% e aumenta atendimento em 0,27 ponto; apenas três de 90 decisões mudam, e uma série concentra cerca de 92% da economia. A metodologia permite distinguir ganhos da seleção, limitações do portfólio e restrições físicas do atendimento. As aplicações mostram compromissos distintos entre custo e serviço, sem estabelecer superioridade geral; a extensão desenvolvida no piloto exige confirmação independente.

Keywords: Inventory methodology, Modular decision support, Policy selection, Demand heterogeneity, Service level

1. Introdução

Selecionar uma política de reposição para cada combinação de loja e produto exige conciliar custo e atendimento sob demandas heterogêneas. Vendas

frequentes, intervalos sem demanda e picos ocasionais podem favorecer regras diferentes. A vantagem de contextualizar a escolha, porém, depende de reconhecer essas diferenças antes da decisão e convertê-las em resultados operacionais posteriores [1].

A escolha da família de política constitui uma decisão distinta da calibração de seus parâmetros. Uma referência global pode usar a mesma família em toda a rede e ainda ajustar lotes e limiares ao histórico de cada série. A seleção de algoritmos fornece uma formulação para ir além dessa referência: características da instância orientam a escolha de um método de um portfólio [2, 3]. No inventário, essa escolha precisa considerar tanto o custo quanto a viabilidade do atendimento.

A seleção contextual exige conectar três decisões: como representar a demanda, que evidência usar para recomendar e quando substituir a política de referência. Comparar candidatas retrospectivamente esclarece o potencial do portfólio; antecipar a melhor escolha requer informação disponível antes do teste. A avaliação também precisa identificar a origem de uma falha: erro do seletor, ausência de candidata viável ou impossibilidade física de atender ao alvo. Esse diagnóstico determina se a revisão deve incidir sobre a escolha, o portfólio ou as condições do sistema.

Propomos o *Adaptive Inventory Policy Engine* (AIPE), uma metodologia modular para organizar essa decisão. O procedimento especifica o problema, representa o contexto, constrói uma matriz comparável de consequências, recomenda pelo *Policy Selection Engine* (PSE) e avalia a escolha em dados reservados. O PSE admite associação por perfil ou estimação por série. Uma regra de intervenção explicita quando a candidata substitui a referência. Contratos de entrada, saída e informação permitem substituir métodos e reavaliar suas consequências mantendo o problema de decisão definido.

A contribuição do AIPE é formular essa sequência como um procedimento verificável: a evidência sustenta a recomendação, a regra de intervenção define sua aplicação e o diagnóstico identifica onde aperfeiçoá-la. Os controladores e seletores concretizam responsabilidades substituíveis dentro desse procedimento. Avaliamos tanto a compatibilidade entre essas implementações quanto sua utilidade incremental frente à referência global. A integração entre classificação e inventário possui antecedentes; o posicionamento do trabalho depende da articulação proposta e das decisões que ela permite examinar.

Examinamos o procedimento em vendas de uma rede varejista brasileira e em um piloto da base pública Walmart M5. A Bahia permite avaliar a seleção

por perfil em condições empresariais observadas; o M5 permite comparar implementações preditivas em um referencial público. As duas aplicações são analisadas separadamente, com consequências simuladas e calibrações identificadas. Os resultados revelam atendimento adicional com custo maior na Bahia, deterioração do preditivo por classe no M5 e melhoria concentrada quando a previsão de consequências é combinada com recuo à referência. Esse conjunto orienta a análise de quando intervir e de qual componente revisar.

2. Trabalhos relacionados

O intervalo médio entre demandas (*average demand interval*, ADI) e o coeficiente de variação (CV) fundamentam a classificação ADI–CV^2, em que CV^2 é o quadrado do coeficiente. Essa classificação organiza padrões de frequência e tamanho da demanda [4]. Entretanto, classes estatísticas não determinam sozinhas a melhor reposição: custos, prazo, estoque inicial e atendimento também importam. Mohammaditabar et al. [5] integram classificação e escolha de políticas; Sheikh-Zadeh et al. [6] propõem classificação orientada ao desempenho em sistemas de múltiplos itens e escalões. O AIPE parte dessa relação entre classificação e desempenho e integra em seu procedimento uma regra explícita de intervenção e um diagnóstico das perdas frente ao portfólio e à viabilidade física. A avaliação deste artigo compara suas implementações internas; os métodos desses antecedentes permanecem fora da comparação empírica.

Na literatura da revista, Tadayonrad e Ndiaye [7] aproximam previsão e consequências operacionais. Theunissen et al. [8] discutem a informação decisória preservada pela classificação. Essa perspectiva orienta nossa avaliação pelo custo e pelo atendimento obtidos, em complemento à concordância entre famílias recomendadas. O método topológico discutido por esses autores oferece um antecedente conceitual, sem implementação nesta avaliação.

Zabraoui et al. [9] comparam algoritmos de inventário e combinações de busca genética e aprendizado por reforço com dados M5. A combinação de algoritmo genético (*genetic algorithm*, GA) e rede Q profunda (*deep Q-network*, DQN), denominada GA–DQN, integra nosso portfólio, com seus componentes como controles, sem ser apresentada como contribuição algorítmica. Granularidade, filtros, custos e implementação local impedem uma reprodução exata de seu ranking.

Políticas limitadas de estoque-base oferecem outra referência para vendas perdidas [10]. Suas propriedades teóricas não garantem desempenho para nossa calibração. Os resultados de reforço também dependem do estado, da recompensa e do orçamento [11]. O AIPE separa essas implementações da escolha entre candidatas. A avaliação do seletor precisa, ainda, separar desenvolvimento e teste para evitar otimismo após escolher configurações [12].

Francuz e Bányai [13] integram escolha de família e parâmetros em otimização multiobjetivo, usando aprendizado para aproximar o simulador. A aplicação tem demanda sintética sazonal e pedidos pendentes. Aprendizado orientado à consequência [14], predição com rejeição [15] e recuo à referência em aprendizado por reforço (*reinforcement learning*, RL) [16] também possuem antecedentes. O AIPE reúne essas ideias em um procedimento de seleção de famílias sob vendas perdidas, com referência calibrada e decomposição retrospectiva das falhas. Essa formulação delimita o objeto da avaliação; originalidade frente às integrações mais próximas e garantias de melhoria exigem evidência adicional.

3. AIPE: metodologia modular

3.1. Objeto e procedimento

O AIPE organiza a escolha de uma família de reposição para a série loja–produto a partir da informação disponível antes da decisão. A aplicação começa pela definição de históricos e contexto, portfólio, ambiente de estoque, objetivo operacional e desenho de avaliação. Ao final, produz uma recomendação acompanhada da referência, dos parâmetros de aplicação, do suporte da escolha e da identificação da configuração. Quando nenhuma candidata é viável, o registro conserva essa condição mesmo que uma contingência permita emitir a recomendação.

O procedimento tem cinco etapas: (1) especificar unidade, ambiente, objetivo e referência; (2) preparar históricos e representar o contexto; (3) calibrar candidatas e construir evidência de validação; (4) recomendar pelo PSE e aplicar a regra de intervenção; (5) avaliar em dados reservados e diagnosticar perdas. A Figura 1 sintetiza a motivação; a Tabela 1 explicita os contratos metodológicos. Cada contrato define o que uma implementação recebe, o que entrega e quais informações pode usar.



Figura 1: AIPE: o contexto orienta a seleção de políticas. O PSE associa um perfil informado a uma família ou estima uma recomendação por série. Famílias A/B/C são ilustrativas; o benefício é avaliado operacionalmente.

3.2. Substituição dos métodos e decisão de intervenção

A modularidade permite avaliar uma alternativa em uma etapa mantendo definido o problema das demais. Um controlador recebe o estado disponível e produz um pedido válido; um descritor resume o histórico anterior à escolha; um seletor recomenda uma família do portfólio. A comparação preserva custos, definição do serviço, cronologia e unidades de análise. Quando uma alternativa exige outras ações ou informações, a adaptação de seu contrato precisa ser verificada antes da comparação.

Seja Π o portfólio, x_i a descrição do treino e g_i o perfil. O PSE por perfil recomenda $m(g_i)$; o preditivo recomenda $f(x_i, g_i)$ ou $f(x_i)$. Ele pode aprender um rótulo ou estimar consequências por candidata. A referência global mantém a família, com parâmetros calibrados individualmente. A regra de intervenção escolhe entre candidata $\widehat{\pi}_i$ e referência π_i^{ref}:

$$\pi_i^{\mathrm{AIPE}} = \begin{cases} \widehat{\pi}_i, & a_i = 1, \\ \pi_i^{\mathrm{ref}}, & a_i = 0. \end{cases}$$

O indicador a_i registra a decisão de intervir. Na implementação direta, toda recomendação é aplicada; na conservadora, a substituição exige o critério

Tabela 1: Contratos dos módulos do AIPE. Trocar o método preserva a responsabilidade e as restrições de informação.

Módulo	Entrada e saída	Contrato e instanciação avaliada
Especificação	Requisitos → cenário e regra	Definir custo, serviço e referência; aqui, vendas perdidas e prazo fixo
Contexto	Histórico → características ou perfil	Usar informação anterior à escolha; descritores e regras fixas
Evidência	Cenário e candidatas → consequências	Ajustar no treino e medir na validação; sete candidatas clássicas, GA e RL
PSE	Contexto e evidência → recomendação	Preservar objetivo e corte temporal; perfil, classe vencedora ou consequências previstas
Avaliação	Recomendação fixada → comparação e diagnóstico	Teste reservado, referência competitiva e perdas identificáveis

de benefício definido no desenvolvimento. Essa separação permite avaliar a candidata proposta e a regra que autoriza seu uso. Confiança de classe e serviço previsto são sinais para decidir, sujeitos a erro no atendimento realizado.

A avaliação exercita a substituição de controladores e seletores, mantendo a representação de contexto e o simulador. Todas as candidatas são ajustadas nas unidades de teste para medir as consequências das recomendações e construir os oráculos. Essa despesa experimental difere do uso pretendido, em que evidências anteriores orientariam a família a calibrar; eventual economia computacional de implantação requer avaliação própria. A adaptação aqui estudada é a escolha por contexto e sua reavaliação documentada, com alcance restrito às interfaces exercitadas.

A integridade da comparação exige uma matriz completa de candidatas, sementes e blocos. Imputação e codificação usam somente a partição de treinamento; recomendações, referências e intervenções são fixadas antes de medir o teste. A identificação de dados, configuração e código permite

verificar quais resultados pertencem à mesma avaliação.

3.3. Custo, serviço e escolha

Para demanda d_t, quantidade atendida v_t, saldo I_t e pedido q_t, avaliamos

$$C = \sum_t [hI_t + p(d_t - v_t) + K\mathbf{1}(q_t > 0) + cq_t], \qquad F = \frac{\sum_t v_t}{\sum_t d_t}. \tag{1}$$

O atendimento F corresponde ao *fill rate*, a fração da demanda atendida. Diferenças entre taxas de atendimento são expressas em pontos percentuais (p.p.). Com demanda zero, permanece indefinido; o custo continua contabilizado. Na instanciação, usamos $h = 1$, $p = 5$, $K = 50$ e $c = 0{,}5$, sem equivalência monetária calibrada.

Na validação A, a regra global minimiza $\bar{C}_{\pi,A}$ entre candidatas com $\bar{F}_{\pi,A} \geq \alpha$, com $\alpha = 0{,}70$. O PSE por perfil aplica essa regra a cada grupo A_g. Casos sem demanda não entram na média de serviço. Sem candidata viável, escolhe-se maior serviço e menor custo, registrando contingência. Perfis sem suporte usam a global. Na Bahia, empate no custo viável prefere maior serviço e depois identificador; no M5, prefere identificador. Contingências empatadas em serviço preferem menor custo. Essas convenções são preservadas por base e registradas no código.

O rótulo supervisionado aplica a restrição à própria série de validação: menor custo viável ou, sem viável, maior serviço e menor custo. Se todas as opções têm serviço indefinido, utiliza menor custo e mantém a marcação de demanda zero. Classificador e seletores agregados não impõem a mesma distribuição da restrição. Incluímos a moda dos rótulos como controle para não atribuir toda diferença à capacidade preditiva.

3.4. Características e perfis

O preditivo recebe 17 descritores: ADI, CV^2, intermitência, proporção de zeros, maior e média das sequências de zeros, *burstiness*, assimetria, curtose, entropia, tendência, autocorrelação, média, desvio-padrão, CV, extensão e número de ciclos positivos. O perfil categórico deriva desses descritores, sem constituir informação independente.

Os perfis usam regras ordenadas e fixas: esparso (ADI $\geq 1{,}32$, $\mathrm{CV}^2 \geq 0{,}49$, sequência de zeros ≥ 5); volatilidade/sazonalidade (autocorrelação $\geq 0{,}25$ ou burstiness $\geq 0{,}30$); tendência instável (tendência absoluta $\geq 0{,}05$ ou entropia ≥ 2); baixo volume estável (média ≤ 2 e $\mathrm{CV}^2 < 0{,}49$); e venda

frequente (ADI $<$ 1,32). A primeira regra satisfeita define o perfil; o residual é esparso. ADI é $n/\max(n_+, 1)$ e CV^2 inclui zeros, diferindo da taxonomia original baseada em tamanhos positivos. Os nomes são heurísticos.

Burstiness compara o desvio e a média dos intervalos positivos pela razão de sua diferença e soma, com regularização numérica. Tendência é a inclinação ajustada por mínimos quadrados ordinários dividida pela média; entropia usa dez classes de mesma largura. A autocorrelação na defasagem 17 recebe zero com até 18 ciclos ou variância desprezível. Essa convenção denota estimativa indisponível, não ausência de sazonalidade; com 23 ciclos, há somente seis pares.

4. Desenho experimental

A avaliação acompanha as decisões do AIPE em três perguntas. A seleção por perfil melhora o compromisso entre custo e atendimento frente à referência global? A estimação por série acrescenta valor e a regra de intervenção preserva esse valor? As falhas de atendimento decorrem da seleção, do portfólio ou de restrições físicas? A Bahia investiga a primeira pergunta; o piloto M5 permite examinar as três, incluindo a substituição do preditivo por classe por um seletor de consequências na mesma matriz de controladores.

4.1. Bases e unidades de análise

A Tabela 2 distingue as avaliações. Na Bahia, transações complementares são somadas por loja, produto e ciclo; ciclos sem venda recebem zero. A coorte retrospectiva contém 145 séries, 115 lojas e nove produtos. Os 38 ciclos disponíveis, de 202301 a 202504, são unidades comerciais da fonte, não meses.

O M5 é uma fonte pública de vendas associada a uma competição de previsão [17]. Os códigos de lojas preservados do M5 combinam o estado e um identificador local: CA designa Califórnia, TX designa Texas e WI designa Wisconsin; por exemplo, CA_2 identifica uma loja da Califórnia. O piloto sorteia 30 séries da categoria de alimentos (`FOODS`), três por loja nas dez lojas. Na primeira origem, o volume médio do treino define três estratos por loja, com uma escolha em cada estrato e semente 20261015. As séries são mantidas nas três origens. Usamos ciclos completos de 21 dias, sem remover picos por regras baseadas no intervalo interquartil.

A elegibilidade exige três ciclos positivos no prefixo. O sorteio M5 usa 885 séries elegíveis na primeira origem de uma coorte histórica de 2.408 identifica-

Tabela 2: Matrizes completas analisadas. Casos série–origem e sementes não são séries independentes.

Dimensão	Bahia	Piloto M5
Séries / lojas	145 / 115	30 / 10
Origens de treino (ciclos)	17 e 23	50, 64 e 78
Validação / teste por origem	7 / 7	7 / 7
Casos série–origem	290	90
Ajustes de políticas	4.350	1.350
Testes sem demanda	7	4
Seletores	Global e por perfil	Global, por perfil e preditivo

dores. Não representa todas as FOODS nem séries elegíveis somente depois. O recorte é inspirado no contexto de Zabraoui et al., sem afirmar identidade com sua amostra. As conclusões quantitativas deste artigo se restringem ao piloto descrito.

4.2. Simulador, portfólio e calibração

O prazo exato é de dois ciclos. A política observa o estado anterior ao recebimento; entregas chegam antes da demanda. Quantidades podem ser fracionárias. Faltas são vendas perdidas, sem pedidos pendentes. Manutenção incide no saldo após demanda e o pedido é custeado na emissão, sem crédito terminal.

Validação e teste começam em estados comuns às candidatas, produzidos por uma referência de lote econômico de compra (*economic order quantity*, EOQ): seis ciclos passados aquecem o sistema, e sua trajetória na validação determina estoque e pipeline do teste. Esses estados usam o passado, mas não representam a continuação particular de cada candidata. Escalas são calculadas no treino.

O portfólio contém EOQCycle, sSCycle, CappedBaseStock, GA, otimização proximal de políticas (*proximal policy optimization*, PPO), GA–DQN e DQN. EOQCycle usa lote $\max(1, \sqrt{2\mu K/h})$ e ponto de pedido $2\mu + 1{,}28\sigma\sqrt{2}$; sSCycle repõe até o ponto acrescido do lote. CappedBaseStock limita a quantidade da reposição até um alvo e calibra alvo e teto em grade 20×12. GA ajusta gatilho, lote e proteção com população 100 e 50 gerações. DQN usa Double DQN dueling; PPO usa otimização proximal. Ambos têm duas camadas de 64 unidades, 20 ações e no mínimo 20 mil transições, arredondadas ao

episódio completo. GA–DQN acrescenta busca genética e mil demonstrações, mantendo gatilho e piso iguais nas demonstrações, treino e inferência.

Os quatro métodos estocásticos usam sementes 11, 29 e 47; as três referências determinísticas têm um ajuste. As sementes são promediadas antes da avaliação por caso. O híbrido tem esforço superior ao DQN, sem equivalência de orçamento. A calibração pode penalizar déficit de serviço. Na matriz Bahia reportada, CappedBaseStock também penaliza frequência de ruptura e amplificação dos pedidos com pesos unitários; no M5, ambos os pesos são zero. Essa diferença impede atribuir contrastes entre bases somente à demanda. Cada matriz e código arquivado identificam a instanciação avaliada.

4.3. Avaliação e desenvolvimento do piloto

Em cada origem, uma loja inteira fica fora do conjunto que define a escolha. O PSE usa a validação das demais lojas e recomenda para o teste da loja reservada. Controladores continuam calibrados no histórico da própria série: avaliamos transferência do seletor com histórico disponível, não implantação sem dados prévios.

No M5, XGBoost tem 200 árvores, profundidade três, taxa 0,05, sem subamostragem e com semente fixa. Imputação, codificação categórica e definição das classes são ajustadas dentro de cada partição de treinamento. Classes raras não são removidas; treinos de classe única usam classificador constante. Cada treinamento reúne 27 exemplos. A ablação sem perfil mantém os demais componentes. Não se usam origens posteriores para recomendar em uma origem anterior.

Uma implementação com recuo usa o PSE por perfil se o maior escore de classe for inferior a 0,60 ou a classe prevista tiver menos de três exemplos de treino. Não há busca de limiares no teste, mas a motivação veio dos resultados observados. Seu desempenho é exploratório, e o piloto passa a ser conjunto de desenvolvimento [12]. O escore não é probabilidade calibrada de viabilidade.

A comparação reduzida adicional reutiliza a matriz M5 e substitui a implementação do PSE. Duas florestas ExtraTrees estimam custo e serviço por candidata: 64 árvores, profundidade quatro, mínimo de três observações por folha e semente fixa. Custo usa $\log(1+C)$, transformado de volta; serviço exclui alvos indefinidos. A seleção direta escolhe o menor custo previsto viável; sem viável, prioriza serviço e depois custo.

A variante com recuo à global exige serviço previsto $\geq 0{,}70$, não inferior ao previsto da referência, e economia acima de uma margem em $\{0; 0{,}02; 0{,}05; 0{,}10; \infty\}$. A margem minimiza custo em validação interna por loja, sujeita a serviço médio não inferior à referência. Cada origem exclui uma loja externa; dentro das nove restantes, ajusta em oito e valida na nona. A margem é fixada antes da recomendação externa. Um classificador ExtraTrees com a mesma regularização controla a aprendizagem por rótulo, e uma ablação retira perfil do seletor por consequências sem recuo. Recomendações são gravadas antes da pontuação do teste, mas o piloto já orientou o desenvolvimento: a comparação permanece exploratória.

Na Bahia, os testes compartilham um ciclo; no M5, ocupam os ciclos 58–64, 72–78 e 86–92, sem sobreposição. Origens repetem séries. Intervalos exploratórios usam bootstrap pareado por loja, preservando séries e origens: 5.000 sorteios na Bahia, 2.000 na comparação de perfil e classe no M5 e 5.000 na comparação por consequências. Seletores e controladores permanecem fixos; a incerteza é condicional, sem novos treinamentos. Dez lojas do piloto limitam sua precisão.

4.4. Oráculos e informação perfeita

O melhor controlador único no teste é um diagnóstico retrospectivo. O oráculo do portfólio escolhe, por série–origem, a candidata de menor custo viável nas médias de teste entre sementes. Essas escolhas não fornecem rótulos ao treinamento. O acerto exige serviço mínimo e empate numérico no menor custo; concordância nominal é informada separadamente.

No M5, um programa linear inteiro misto (*mixed-integer linear programming*, MILP) conhece toda a demanda de teste e otimiza pedidos sob os mesmos custos, prazo e condições iniciais. Quantidades são contínuas; variáveis binárias representam emissão e complementaridade entre saldo e falta. É um ótimo determinístico condicional, não um controlador estocástico implantável. Se 0,70 for fisicamente impossível antes das primeiras entregas, maximiza atendimento e depois minimiza custo. Soluções são reexecutadas no simulador e somente as comprovadamente ótimas recebem essa denominação.

A eficiência de custo é $100C^*/C_{\mathrm{PSE}}$, apenas quando referência e recomendação satisfazem o mesmo critério de serviço; ambos os custos zero equivalem a 100%. Serviço insuficiente não recebe crédito por custo baixo. A comparação com o MILP usa cada realização de treinamento viável: uma média entre

sementes pode satisfazer o alvo sem que todas o satisfaçam. Repetir políticas determinísticas nessa análise não gera novas observações independentes.

5. Resultados na Bahia: PSE por perfil

As sete candidatas foram avaliadas em 290 casos série–origem. O custo médio usa todos os casos e o atendimento os 283 com demanda positiva; sete têm serviço indefinido. Somente EOQCycle e sSCycle superam 0,70 em média; nenhuma supera esse alvo no atendimento ponderado pelas unidades demandadas.

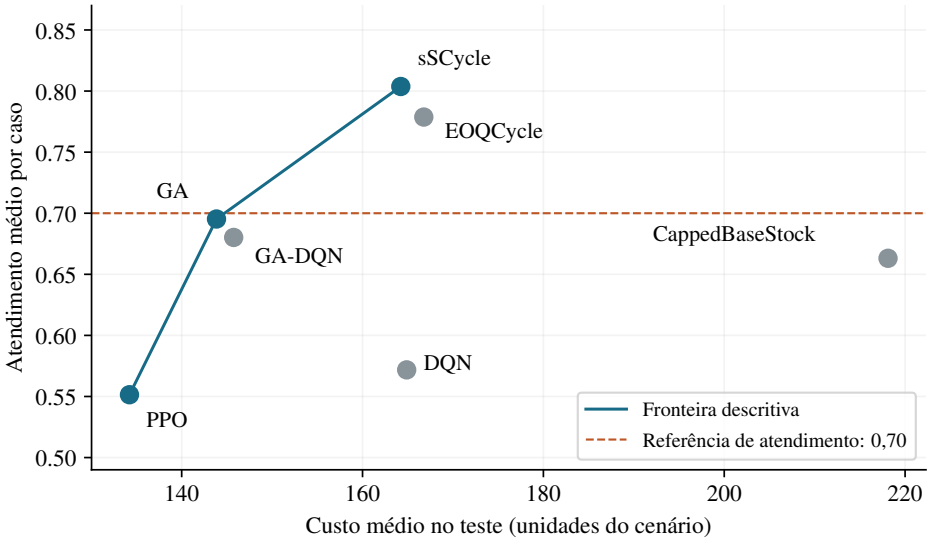


Figura 2: Portfólio na Bahia: custo médio em 290 casos e atendimento em 283 com demanda positiva. A fronteira é retrospectiva e descritiva; não é usada para escolher no teste.

PPO tem menor custo e menor atendimento. GA–DQN reduz custo em 11,60% frente ao DQN e eleva atendimento de 0,5718 para 0,6802; frente ao GA, custa 1,32% mais e atende menos. O híbrido não domina seu componente evolutivo no agregado, e seu esforço adicional impede atribuir o contraste apenas à combinação algorítmica.

Na primeira origem, a global escolhe GA em todos os casos. O PSE por perfil escolhe GA em 65, sSCycle em 75 e EOQCycle em cinco. Na segunda, ambos escolhem sSCycle nos 145 casos. A Figura 3 localiza essa diferenciação: perfis distintos não implicam recomendações distintas em todo período.

Tabela 3: Escolha na validação das demais lojas; teste da loja reservada. Custo em 145 casos por linha; atendimento em 144 casos na origem 17 e 139 na origem 23.

Treino	Seleção	Custo	Atendimento	Abaixo de 0,70
17 ciclos	Global	180,58	0,5711	101
17 ciclos	PSE por perfil	186,79	0,6475	82
23 ciclos	Global	142,03	0,9073	18
23 ciclos	PSE por perfil	142,03	0,9073	18

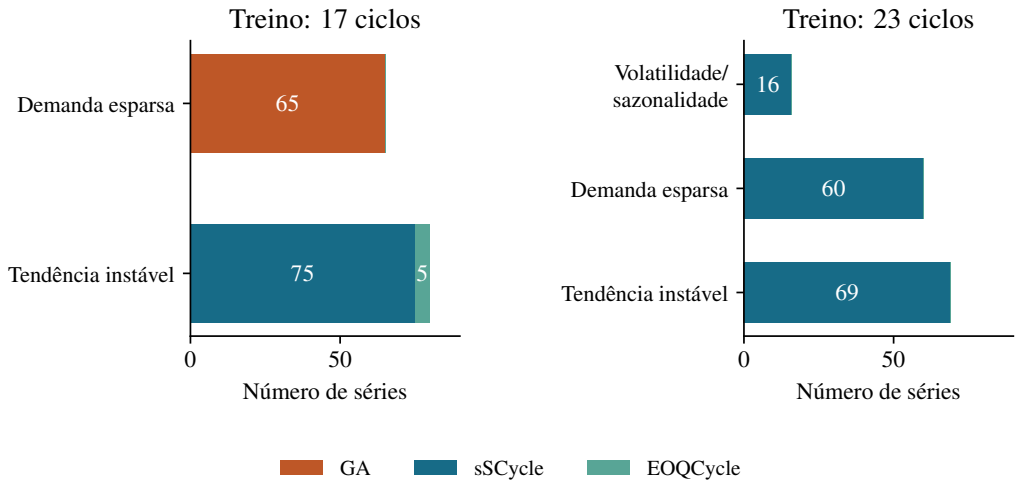


Figura 3: Escolhas do PSE por perfil na Bahia, com meta 0,70. Há 145 recomendações por origem. A segunda reproduz a seleção global.

Reunindo origens, o custo passa de 161,31 para 164,41, aumento de 1,93%; o atendimento cresce de 0,7362 para 0,7751, diferença de 3,89 pontos percentuais. O ponderado passa de 0,5750 para 0,6395. Casos abaixo de 0,70 diminuem de 119 para 100 entre 283 definidos. O resultado é serviço adicional com custo pontualmente maior, concentrado na primeira origem.

O bootstrap condicional de 115 lojas produz intervalos de 95% de $[-0{,}32; 4{,}16]\%$ para custo e $[2{,}78; 5{,}07]$ pontos para atendimento. Incluir zero no intervalo de custo não prova equivalência. Variar o limiar sem recalibrar o portfólio também não preserva o benefício: em 0,80, o PSE por perfil custa mais e atende ligeiramente menos; em 0,85, ambos escolhem sSCycle em todos os casos; em 0,90 e 0,95, todas as escolhas são contingências na validação.

6. Resultados no M5: duas abordagens do PSE

6.1. Custo e atendimento das recomendações

O piloto completa os 1.350 ajustes das 30 séries em três origens. As recomendações são avaliadas em 90 casos, com atendimento definido em 86. Não são 90 séries independentes. A Tabela 4 inclui dois controles: moda dos rótulos de treino e escolha individual da vencedora de validação. O último examina a transferência temporal do próprio rótulo, sem representar um limite superior para os seletores.

Tabela 4: M5: custo em 90 casos; atendimento e contagem de viáveis em 86 com demanda positiva. O recuo é exploratório, desenvolvido após o diagnóstico do piloto.

Seleção	Custo	Atendimento	Casos $\geq 0{,}70$
Global	1.086,97	0,7146	47
PSE por perfil	1.094,02	0,7091	46
PSE preditivo com perfil	1.238,30	0,6735	39
PSE preditivo sem perfil	1.238,30	0,6735	39
Moda dos rótulos	1.096,65	0,6885	42
Individual na validação	1.185,13	0,6838	44
Preditivo com recuo	1.087,26	0,6996	46

O preditivo custa 13,9% mais e atende 4,11 pontos percentuais menos que a global. O contraste desfavorável aparece nas três origens e nos dois perfis. WI_3 e TX_2 respondem por 65,4% da diferença líquida de custo. O PSE por perfil permanece próximo da global: maior custo e serviço ligeiramente menor, sem benefício agregado neste piloto.

O recuo é acionado em 62 casos e muda a política em 48. Frente ao preditivo, reduz custo em 12,2% e aumenta serviço em 2,62 pontos. Frente à global, custa 0,026% mais e atende 1,49 ponto menos; o atendimento permanece abaixo de 0,70. O intervalo exploratório para a diferença de custo frente à global é $[-39{,}83; 39{,}30]$ unidades do cenário; para serviço, $[-2{,}87; -0{,}23]$ pontos. Proximidade de custo não comprova equivalência.

6.2. O que explica a dificuldade do preditivo?

Cada fold tem 27 exemplos para até sete classes. O modelo reproduz 100% dos rótulos do treino, mas somente 19 dos 90 rótulos de validação das lojas excluídas. Dois rótulos pertencem a classes ausentes no respectivo

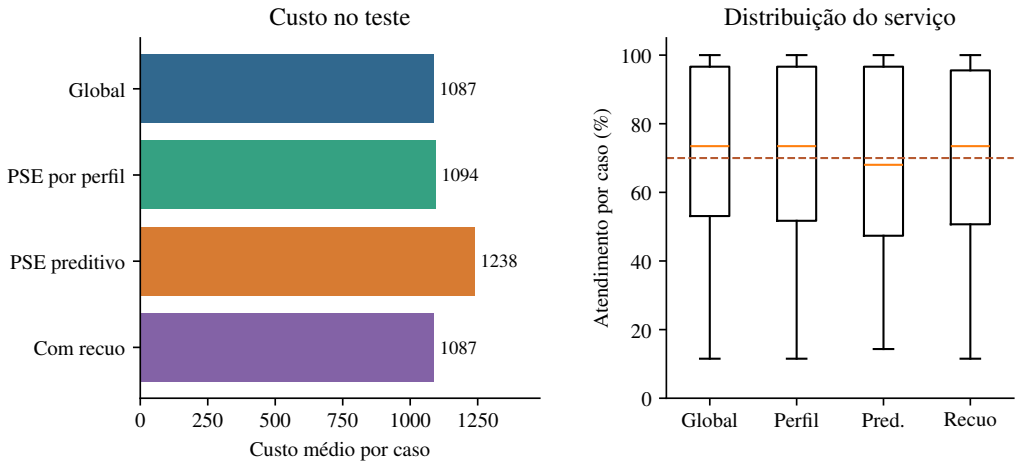


Figura 4: Piloto M5: custo e atendimento médios são apresentados separadamente. Caixas descrevem o serviço nos 86 casos definidos; linha em 0,70. O recuo foi desenvolvido no piloto, sem confirmação independente.

treinamento. Esses resultados são consistentes com sobreajuste, sem provar que mais dados, isoladamente, resolvam o problema.

A vencedora nominal da validação permanece vencedora no teste em 29/90 casos; admitindo empates no objetivo completo, em 33/90. Com demanda positiva nos dois blocos, a concordância nominal é 26/83. As vencedoras diferem entre sementes em 39/90 casos. O alvo categórico é sensível tanto ao período quanto ao treinamento. Escolher individualmente na validação aumenta os casos viáveis frente ao preditivo, mas não supera a global em custo ou atendimento médio.

Cada origem contém 26 séries esparsas e quatro de tendência, sem transição de perfil na amostra. As colunas de perfil têm importância por ganho zero em todos os folds; com e sem elas, as 90 recomendações coincidem. Redundância com as características numéricas e baixa diversidade ajudam a explicar a ausência de efeito, sem demonstrar inutilidade dos perfis em outras populações.

6.3. Distância aos melhores resultados e fontes das falhas

O preditivo iguala o menor custo viável do portfólio em 11 dos 39 casos nos quais sua recomendação é viável. Sua eficiência média condicional é 74,2%. A global acerta 15/47 e o PSE por perfil 12/46, com eficiências de

80,8% e 79,5%. Os denominadores diferem: não se avalia eficiência sobre um mesmo subconjunto.

Os 90 problemas com informação perfeita têm otimalidade comprovada. Nas 118 realizações de treinamento em que o preditivo satisfaz o alvo, iguala o ótimo determinístico em 14 e apresenta eficiência média de 54,6%. As realizações repetem séries e, para políticas determinísticas, a mesma trajetória; não ampliam a amostra independente. Mede-se distância ao planejamento com demanda conhecida, não a um controlador estocástico implantável.

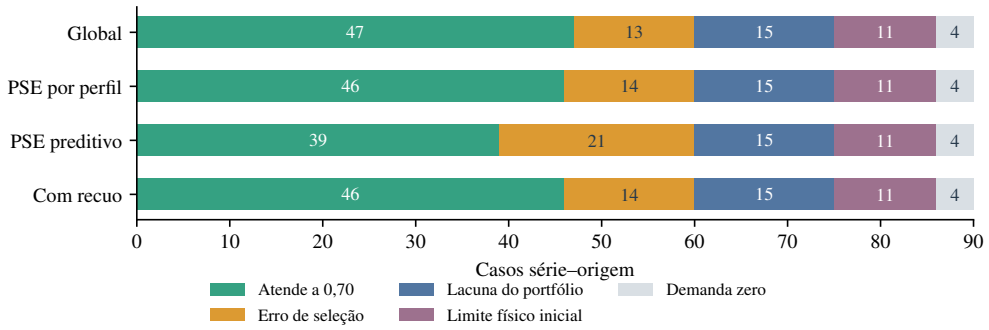


Figura 5: Decomposição dos 90 casos M5. Erro de seleção: outra candidata atende. Lacuna do portfólio: nenhuma candidata atende, mas o planejamento perfeito permite atender. Limite físico: condições iniciais impedem atingir 0,70. Demanda zero mantém serviço indefinido.

No preditivo, 39 casos atendem ao alvo; 21 falham apesar de existir política viável; 15 falham sem candidata viável, embora o planejamento perfeito permita atender; 11 têm restrição física inicial; e quatro têm demanda zero. O recuo reduz os erros de seleção de 21 para 14. Melhorar o seletor não resolve sozinho todas as faltas: a Figura 5 separa intervenções sobre escolha, controle e abastecimento inicial.

6.4. Instanciação do PSE por consequências e recuo

A substituição do seletor na mesma matriz permite comparar implementações sem refazer os controladores (Tabela 5). A floresta por consequências sem recuo reduz o custo em 0,33%, mas perde 2,09 pontos de atendimento frente à global. O controle por classe vencedora também reduz custo e perde serviço, limitando atribuir a melhora frente ao XGBoost somente ao alvo de aprendizagem.

Tabela 5: Variantes do PSE na mesma matriz M5: 90 casos de custo e 86 de serviço definido. Referências global, por perfil e preditiva por classe constam da Tabela 4.

Variante	Custo	Serviço	Casos $\geq 0{,}70$
Classe vencedora: floresta de controle	1.074,17	68,97%	40
Consequências sem recuo	1.083,36	69,37%	38
Consequências sem perfil e sem recuo	1.148,09	69,25%	38
Consequências com recuo	1.070,03	71,72%	47

Com recuo, o custo médio fica 1,56% abaixo da global e o serviço 0,27 ponto acima (Figura 6). Somente três decisões mudam: uma de CappedBaseStock para GA em CA_2 e duas de EOQCycle para sSCycle em TX_2. Uma série concentra aproximadamente 92% da economia. Duas intervenções permanecem abaixo de 70% apesar de viabilidade prevista. São mantidos os mesmos 47 casos que atendem ao alvo, sem novas falhas ou recuperações frente à global.

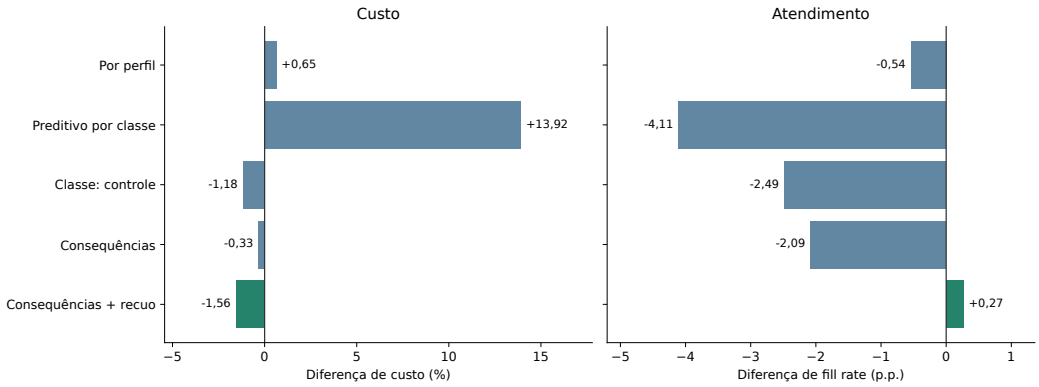


Figura 6: Diferenças médias frente à global. O recuo limita intervenções, mas o benefício observado concentra-se em duas lojas e não demonstra transferência.

Intervalos exploratórios de 95%, por bootstrap pareado de dez lojas, são $[-48{,}10; 0{,}00]$ para diferença de custo e $[0{,}000; 0{,}734]$ ponto para serviço. Alcançam zero, condicionam-se aos ajustes fixos e não corrigem multiplicidade. A comparação favorece investigar intervenção seletiva, com confirmação em dados que não tenham orientado essa revisão.

7. Discussão

As duas aplicações mostram por que o AIPE avalia a seleção contextual frente a uma referência calibrada por série. A variação das vencedoras do portfólio oferece oportunidades de escolha, enquanto os resultados dos seletores revelam quanto desse potencial é efetivamente aproveitado. A compatibilidade entre módulos permite realizar essas comparações; o benefício operacional depende das consequências da recomendação em dados reservados.

Na Bahia, a seleção por perfil acrescenta atendimento com custo pontualmente maior; na segunda origem, coincide com a escolha global. Esse comportamento mostra que a utilidade da segmentação depende da janela e do critério operacional. A base brasileira fortalece a relevância aplicada da avaliação ao preservar heterogeneidade observada em vendas empresariais, enquanto a simulação e a possível censura por ruptura delimitam a interpretação econômica.

O piloto M5 evidencia a dificuldade de aprender a identidade da melhor família com pouco suporte. O XGBoost perde para a referência em custo e atendimento. A previsão de consequências preserva a magnitude operacional dos erros de escolha, mas sua implementação direta também perde serviço; o controle por classe com outra floresta altera os resultados. Portanto, a comparação não isola todo o efeito do alvo de aprendizagem.

A regra de intervenção torna explícito quanto o PSE modifica a referência e com que consequência. A variante por consequências conserva a global em 87/90 casos, melhora pontualmente custo e serviço e concentra cerca de 92% da economia em uma série. A média favorável, portanto, depende de poucas decisões e deve ser lida junto à concentração do ganho e às deteriorações individuais. Esse resultado exploratório sustenta testar intervenções seletivas em dados externos ao desenvolvimento.

Os oráculos mostram que corrigir o seletor é apenas uma das intervenções possíveis. Havendo candidata viável, a escolha pode ser aprimorada; sem candidata viável, deve-se examinar o portfólio e sua calibração; diante de inviabilidade física, é necessário rever as condições do sistema. A distinção orienta qual componente do AIPE merece revisão e evita atribuir toda ruptura ao modelo preditivo.

O suporte do contexto também limita a transferência das recomendações. Na primeira origem M5, 826/885 séries elegíveis são esparsas, 57 têm tendência e duas pertencem ao grupo volatilidade/sazonalidade. Uma amostra

maior pode manter essa concentração. A avaliação deve considerar o suporte de cada grupo e o objetivo de atendimento adotado: meta média, atendimento ponderado e garantia por série expressam exigências distintas. A comparação entre módulos só é interpretável quando conserva essa definição.

8. Limitações e próximos testes

Vendas podem omitir demanda censurada por falta. Coortes históricas, elegibilidade na primeira origem e horizontes de sete ciclos restringem população e período. Produtos compartilhados entre lojas podem gerar dependência não capturada inteiramente pelo bootstrap.

Não se trata de experimento causal de implantação. Custos não são financeiramente calibrados, não há suprimento conjunto e o estado inicial comum não reproduz trajetórias particulares. A calibração distinta da CappedBaseStock e os esforços desiguais limitam comparações entre algoritmos e bases.

As extensões com recuo foram desenvolvidas no piloto; suas métricas não confirmam independentemente a melhoria. A substituição foi exercitada nas candidatas e no PSE, sem ablação de todas as representações e ambientes. Assim, a portabilidade integral permanece uma hipótese de uso. A avaliação ampliada precisa examinar suporte por perfil e classe, restrições de serviço comparáveis e validação interna por loja para ajustes do seletor. Séries reservadas devem ficar fora dessas decisões. Harmonização da calibração e sensibilidades de custo, prazo e horizonte precedem conclusões mais amplas.

Uma avaliação ampliada, ainda fora dos resultados deste artigo, conserva as 145 séries brasileiras e os 2.408 identificadores históricos do M5. Nesse recorte, 885, 2.033 e 2.408 séries são elegíveis nas respectivas origens. O desenho usa pesos zero para ruptura e amplificação na calibração da CappedBaseStock em ambas as bases e cinco grupos internos de lojas na escolha da margem de recuo. Essas mudanças podem alterar as recomendações e exigem nova análise. Separar as séries do piloto das demais identifica o uso prévio dos dados, sem estabelecer independência por si só.

9. Conclusão

O AIPE organiza a seleção contextual de políticas de reposição em cinco etapas, desde a especificação do problema até o diagnóstico dos resultados. A metodologia vincula a representação da série loja–produto à evidência de validação, à recomendação do PSE e à decisão de substituir a referência. Essa

estrutura permite localizar tanto o benefício de uma implementação quanto o componente a revisar quando o atendimento falha.

A avaliação delimita onde essas escolhas ajudam. Na Bahia, o perfil acrescenta 3,89 pontos de atendimento com aumento de custo de 1,93%. No piloto M5, a estimação por classe perde para a global; consequências com recuo reduzem custo em 1,56% e acrescentam 0,27 ponto de atendimento, com apenas três intervenções e benefício concentrado. Assim, a evidência sustenta a execução e a utilidade diagnóstica do procedimento, enquanto seu benefício operacional permanece condicionado à instanciação.

A confirmação requer calibrações harmonizadas e avaliação da regra de intervenção em dados reservados, excluídos do desenvolvimento. O critério decisivo será a capacidade de reconhecer quando uma recomendação contextual compensa e quando preservar a referência, considerando serviço, custo e deteriorações.

Disponibilidade de dados e código

Os dados brasileiros são proprietários e não são redistribuídos; o M5 é público. Código, configurações e fontes estão em `https://github.com/matheus013/msc`. Dados, bancos e modelos ficam fora da versão atual do repositório. Manifestos e snapshots locais identificam as matrizes; pacote arquivado e derivados autorizados deverão acompanhar a submissão. Não se promete acesso aos registros restritos mediante solicitação.

Autoria, financiamento e interesses

Autoria, contribuições dos autores, financiamento, agradecimentos e interesses devem ser confirmados pelos autores responsáveis. O manuscrito em português requer tradução, revisão humana e fechamento das declarações antes da submissão.

Uso de inteligência artificial na preparação do manuscrito

OpenAI Codex auxiliou organização bibliográfica, leitura de código, análise, visualização e redação. A figura conceitual usa desenhos vetoriais programáticos; os gráficos quantitativos derivam das matrizes identificadas. Conferência e responsabilidade pelo texto final cabem aos autores humanos. Sistemas de inteligência artificial não são autores.

Referências

[1] S. Axsäter, Inventory Control, 2nd Edition, Vol. 90 of International Series in Operations Research & Management Science, Springer US, New York, NY, USA, 2006. doi:10.1007/0-387-33331-2.

[2] J. R. Rice, The algorithm selection problem, in: Advances in Computers, Vol. 15, Academic Press, 1976, pp. 65–118. doi:10.1016/S0065-2458(08)60520-3.

[3] L. Kotthoff, Algorithm selection for combinatorial search problems: A survey, AI Magazine 35 (3) (2014) 48–60. doi:10.1609/aimag.v35i3.2460.

[4] A. A. Syntetos, J. E. Boylan, J. D. Croston, On the categorization of demand patterns, J. Oper. Res. Soc. 56 (5) (2005) 495–503. doi:10.1057/palgrave.jors.2601841.

[5] D. Mohammaditabar, S. H. Ghodsypour, C. O'Brien, Inventory control system design by integrating inventory classification and policy selection, International Journal of Production Economics 140 (2) (2012) 655–659. doi:10.1016/j.ijpe.2011.03.012.

[6] A. Sheikh-Zadeh, M. D. Rossetti, M. A. Scott, Performance-based inventory classification methods for large-scale multi-echelon replenishment systems, Omega 101 (2021) 102276. doi:10.1016/j.omega.2020.102276.

[7] Y. Tadayonrad, A. B. Ndiaye, A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality, Supply Chain Analytics 3 (2023) 100026. doi:10.1016/j.sca.2023.100026.

[8] F. M. Theunissen, S. Alam, A. Sajjad, A topological analytics framework for preserving decision structure in supply chain inventory classification, Supply Chain Analytics 15 (2026) 100229. doi:10.1016/j.sca.2026.100229.

[9] O. Zabraoui, Y. Hmamou, A. Chafi, S. Kammouri Alami, A comparative study of multi-algorithm optimization for inventory analytics in supply

chains, Supply Chain Analytics 12 (2025) 100154. doi:10.1016/j.sca.2025.100154.

[10] L. Xin, Technical note—understanding the performance of capped base-stock policies in lost-sales inventory models, Operations Research 69 (1) (2021) 61–70. doi:10.1287/opre.2020.2019.

[11] R. N. Boute, J. Gijsbrechts, W. van Jaarsveld, N. Vanvuchelen, Deep reinforcement learning for inventory control: A roadmap, European Journal of Operational Research 298 (2) (2022) 401–412. doi:10.1016/j.ejor.2021.07.016.

[12] G. C. Cawley, N. L. C. Talbot, On over-fitting in model selection and subsequent selection bias in performance evaluation, Journal of Machine Learning Research 11 (2010) 2079–2107.
URL https://www.jmlr.org/papers/v11/cawley10a.html

[13] Á. Francuz, T. Bányai, Metaheuristic-based model selection framework for eoq and inventory policies using machine learning and multi-objective optimization, Algorithms 19 (5) (2026) 415. doi:10.3390/a19050415.

[14] A. N. Elmachtoub, P. Grigas, Smart predict, then optimize, Management Science (2022). doi:10.1287/mnsc.2020.3922.

[15] Y. Geifman, R. El-Yaniv, Selectivenet: A deep neural network with an integrated reject option, in: Proceedings of the 36th International Conference on Machine Learning, Vol. 97, 2019, pp. 2151–2159.
URL https://proceedings.mlr.press/v97/geifman19a.html

[16] R. Laroche, P. Trichelair, R. Tachet des Combes, Safe policy improvement with baseline bootstrapping, in: Proceedings of the 36th International Conference on Machine Learning, Vol. 97, 2019, pp. 3652–3661.
URL https://proceedings.mlr.press/v97/laroche19a.html

[17] S. Makridakis, E. Spiliotis, V. Assimakopoulos, M5 accuracy competition: Results, findings, and conclusions, International Journal of Forecasting 38 (4) (2022) 1346–1364. doi:10.1016/j.ijforecast.2021.11.013.