



Master's Thesis Proposal

Matheus Inácio Batista Santos
mibs@ic.ufal.br

Advisers:

Dr. Rian Gabriel Santos Pinheiro

Maceió
June 18, 2020

Matheus Inácio Batista Santos

Uma dissertação submetida por Matheus Inácio Batista Santos como requisito parcial para a obtenção do grau de Mestre em Informática pela Universidade Federal de Alagoas, Instituto de Computação.

Advisers:

Dr. Rian Gabriel Santos Pinheiro

Maceió
June 18, 2020

Dissertação submetida por Matheus Inácio Batista Santos como requisito parcial para a obtenção do grau de Mestre em Informática pela Universidade Federal de Alagoas, Instituto de Computação, aprovada pela banca examinadora que assina abaixo.

- Adviser

Dr. Rian Gabriel Santos Pinheiro - Adviser
Computing Institute
Federal University of Alagoas

- Examiner

Maceió
June 18, 2020

Abstract

A gestão eficiente do abastecimento em redes varejistas geograficamente distribuídas representa um desafio central na engenharia de operações, especialmente quando múltiplos centros de estoque, fábricas e lojas interagem sob restrições logísticas e demanda estocástica. Esse problema se enquadra no domínio de Multi-Echelon Inventory Optimization (MEIO), no qual decisões de produção, transferência e reposição devem ser coordenadas entre diferentes níveis da cadeia de suprimentos para minimizar custos operacionais e garantir níveis adequados de serviço.

Esta dissertação investiga a formulação e avaliação de métodos para otimização do abastecimento em redes varejistas multi-escalon representadas por grafos direcionados, considerando múltiplos produtos, restrições de capacidade e custos logísticos associados à distância e ao tempo de transporte. Inicialmente, é proposta uma formulação baseada em programação inteira mista (MILP/ILP) que integra decisões de produção e fluxo de itens na rede, servindo como modelo de referência para análise e interpretação das decisões logísticas.

Devido à elevada escala dos dados e à complexidade combinatória do problema em ambientes reais, são investigadas abordagens complementares para melhoria de escalabilidade e desempenho computacional. Entre essas abordagens, incluem-se metaheurísticas clássicas, como Genetic Algorithm (GA), GRASP e Simulated Annealing (SA), além de métodos baseados em Deep Reinforcement Learning (DRL) e extensões multiagentes para decisão sequencial em ambientes dinâmicos.

O estudo também incorpora um ambiente de simulação para avaliação de políticas em cenários multi-período sob demanda estocástica, utilizando um paradigma de horizonte rolante (rolling horizon) que integra previsão de demanda, otimização e execução operacional. Por meio de experimentos controlados e instâncias de grande escala, a pesquisa busca comparar o desempenho das diferentes abordagens segundo métricas operacionais e computacionais, incluindo custo total, nível de serviço e eficiência computacional.

Espera-se que os resultados contribuam para a compreensão dos trade-offs entre métodos exatos, heurísticos e baseados em aprendizado de máquina no contexto de redes de abastecimento complexas, além de fornecer evidências empíricas sobre a aplicabilidade de técnicas modernas de aprendizado por reforço em problemas de otimização logística em larga escala.

Keywords: Multi-Echelon Inventory Optimization, Supply Chain Optimization, Mixed Integer Linear Programming, Metaheuristics, Deep Reinforcement Learning, Logistics Networks.

Contents

Figure List	v
Table List	vi
Algorithm List	vii
1 Introduction	1
1.1 Motivation	1
1.1.1 Contexto, relevância e lacuna científica	1
1.1.2 MEIO e porquê da coordenação	2
1.1.3 Problema de pesquisa, modelo de referência e escopo	2
1.1.4 Escala, viabilidade computacional e motivação para métodos aproximados	3
1.1.5 Coerência custo–tempo e definição do trade-off	4
1.1.6 Questões de pesquisa e hipótese metodológica	5
1.2 Related Work	8
1.2.1 MEIO sob incerteza: fundamentos, tipologias e modelos de nível de serviço	8
1.2.2 Modelagem por redes e programação matemática: produção, distribuição e restrições logísticas	9
1.2.3 Escalabilidade: metaheurísticas, simulação e programação estocástica	9
1.2.4 Previsão de demanda e métricas alinhadas a custo/serviço	10
1.2.5 DRL/MARL para inventários e MEIO: evidências, limitações e tendência de escalabilidade	10
1.3 General and Specific Objectives	11
2 Tecnologias e Conceitos	13
2.1 Visão geral do arcabouço tecnológico do projeto	13
2.2 Programação matemática e modelagem em redes	14
2.2.1 ILP, MILP e MIP: definição formal, interpretação e complexidade	14
2.2.2 Fluxos em redes e fluxo multi- <i>commodity</i>	14
2.2.3 Formulação base deste projeto e extensão multi-período/estocástica	15
2.3 Solvers e bibliotecas de otimização	16
2.3.1 OR-Tools: MPSolver e CP-SAT	16
2.3.2 Gurobi: fundamentos, API e parametrização	17
2.4 Metaheurísticas para MEIO: GA, GRASP, SA e NSGA-II	18
2.4.1 Genetic Algorithm (GA)	18
2.4.2 GRASP	19
2.4.3 Simulated Annealing (SA)	19
2.4.4 NSGA-II para multiobjetivo	20
2.5 Simulação: eventos discretos e Monte Carlo	20
2.5.1 Simulação de eventos discretos (DES)	20
2.5.2 Simulação Monte Carlo	21

2.6	Previsão de demanda: modelos, métricas e alinhamento com decisão	21
2.6.1	Modelos estatísticos e de aprendizado	21
2.6.2	Métricas: erro preditivo e impacto operacional	22
2.7	Programação estocástica e modelos de nível de serviço	22
2.8	DRL, MARL e políticas para MEIO	22
2.8.1	MDP e formulação de RL	22
2.8.2	DQN: Q-learning profundo	23
2.8.3	PPO: policy gradient com clipping	23
2.8.4	MARL/IMARL e escalabilidade	23
2.8.5	Ambiente tipo Gymnasium: esqueleto para simulação e RL	23
2.8.6	Treinamento PPO com Stable-Baselines3: parâmetros e loop	24
2.9	Métricas de avaliação e protocolo experimental	25
2.9.1	Métricas: previsão, operação, otimização e aprendizado	25
2.9.2	Protocolo, seeding e testes estatísticos	25
2.10	Engenharia de software para experimentos: Kedro, Docker, Git e reprodutibilidade	25
2.10.1	Kedro: conceitos, Data Catalog, pipelines e visualização	25
2.10.2	MLflow e rastreamento de experimentos	26
2.10.3	Docker: isolamento, builds reprodutíveis e boas práticas	26
2.10.4	Git: versionamento e rastreabilidade	26
2.10.5	Checklist de reprodutibilidade (recomendado)	26
2.11	Tabelas comparativas e configurações iniciais recomendadas	27
2.11.1	Comparação entre famílias de métodos	27
2.11.2	Configurações iniciais (pontos de partida)	27
3	Metodologia	29
3.1	Objetivos experimentais, hipóteses e suposições	29
3.2	Dados, pré-processamento e geração de instâncias	30
3.2.1	Dados e esquema mínimo	30
3.2.2	Pré-processamento e particionamento temporal	30
3.2.3	Geração de instâncias	30
3.3	Métodos avaliados e parametrização	30
3.3.1	ILP/MILP (benchmark) e solver	30
3.3.2	Metaheurísticas (GA/GRASP/SA/NSGA-II)	31
3.3.3	Simulação (Monte Carlo / eventos discretos)	31
3.3.4	DRL/MARL (PPO/DQN/IMARL)	31
3.4	Ambiente de simulação e API tipo Gym	31
3.4.1	Estado, ação, transição e recompensa	31
3.4.2	Rolling horizon	31
3.5	Protocolo experimental, métricas e testes	32
3.5.1	Sementes e splits	32
3.5.2	Métricas	32
3.5.3	Inferência	32
3.6	Reprodutibilidade e engenharia experimental	32
3.7	Tabelas e matriz experimental	33
	References	35

List of Figures

1.1	Estrutura simplificada da rede de abastecimento multi-echelon.	6
1.2	Pipeline de solução e avaliação.	6
1.3	Framework iterativo de previsão e otimização em horizonte rolante.	7
2.1	Ciclo de decisão em horizonte rolante: dados → previsão → otimização → execução → realimentação.	14

List of Tables

2.1	Comparação qualitativa de métodos no contexto MEIO.	27
2.2	Configurações iniciais recomendadas para experimentos (valores “não especificado” devem ser definidos no protocolo).	28
3.1	Comparação resumida de famílias (MEIO).	33
3.2	Matriz recomendada; H e cv varrem cenários.	33

List of Algorithms

Introduction

1.1 Motivation

1.1.1 Contexto, relevância e lacuna científica

A gestão integrada do abastecimento em redes varejistas geograficamente dispersas constitui um problema central de engenharia de operações, pois condiciona simultaneamente (i) o nível de serviço percebido na ponta (disponibilidade de produtos, frequência de ruptura e tempo de reposição) e (ii) a estrutura de custos logísticos e produtivos (transporte, produção, manutenção e perdas por falta). [Simchi-Levi et al. \(2009\)](#); [Chopra \(2022\)](#); [Ballou \(2006\)](#)¹ Em termos sistêmicos, a dificuldade decorre do fato de que decisões tomadas localmente (p. ex., políticas de reposição e expedição em cada instalação) podem induzir externalidades relevantes sobre outros nós da rede, amplificando variabilidade à montante e deteriorando desempenho global. A literatura clássica formaliza esse efeito como distorção informacional e amplificação de variância (*bullwhip effect*), fenômeno que tende a elevar estoques de segurança, custos e instabilidade operacional em cadeias multiestágio. [Lee et al. \(1997\)](#)

Embora existam formulações consagradas para controle de estoques e planejamento logístico, frequentemente baseadas em hipóteses estruturais e regimes de escala bem delimitados, redes varejistas contemporâneas combinam características que tensionam tais premissas: portfólios extensos (múltiplos itens/SKUs), heterogeneidade regional, restrições operacionais de capacidade em transporte e produção, além de demanda com forte componente estocástico e sazonal. [Axsater \(2006\)](#); [Zipkin \(2000\)](#) Em consequência, emerge uma lacuna metodológica recorrente: conciliar (a) modelos de otimização com rastreabilidade e interpretabilidade suficientes para subsidiar decisão gerencial e (b) métodos computacionais que permaneçam viáveis sob topologias gerais e volumes de dados realistas, sem reduzir o problema a abstrações excessivamente simplificadoras. [Shapiro \(2001\)](#); [Ahuja et al. \(1993\)](#); [Boute et al. \(2022\)](#)

¹Texto revisto e enriquecido em 15/03/2026 (America/Maceio).

1.1.2 MEIO e porquê da coordenação

O problema desta dissertação insere-se no domínio de *Multi-Echelon Inventory Optimization* (MEIO), no qual múltiplos escalões (*echelons*) mantêm estoque e realizam movimentações ao longo do tempo (p. ex., fábricas, centros de distribuição/estoque e lojas), exigindo coordenação explícita entre níveis para que metas de serviço sejam atingidas ao menor custo sistêmico. [Clark and Scarf \(1960\)](#); [Axsäter \(2006\)](#); [Zipkin \(2000\)](#) A razão fundamental para a coordenação decorre da interdependência entre escalões: estoques e políticas em um nível alteram o risco de ruptura e a necessidade de estoque em outros níveis, de modo que otimizações locais (*single-echelon*) podem induzir redundância de capital (estoque excessivo em um elo) simultaneamente a insuficiência de disponibilidade em outro. [Simchi-Levi et al. \(2009\)](#); [Chopra \(2022\)](#)

A literatura fundacional mostra que, mesmo em topologias seriadas (cadeias em série), a obtenção de políticas ótimas ou quase ótimas demanda estruturas analíticas e hipóteses específicas, evidenciando complexidade intrínseca do multi-escalão. [Clark and Scarf \(1960\)](#) No entanto, redes de abastecimento em ambientes varejistas frequentemente extrapolam o caso seriado e assumem topologias divergentes e gerais, com múltiplas origens e destinos, transbordo entre centros e possibilidade de múltiplos caminhos logísticos. Essa generalidade topológica é compatível com a representação de redes por grafos e com a tradição de modelagem por fluxos, na qual cadeias seriadas e divergentes surgem como casos particulares de uma rede com conjunto de arcos factíveis. [Ahuja et al. \(1993\)](#); [Shapiro \(2001\)](#) Para MEIO em aplicações industriais, abordagens centradas em nível de serviço e alocação de *safety stock* (p. ex., modelos de serviço garantido e suas extensões) reforçam que o posicionamento de estoques e o cumprimento de metas de serviço devem ser tratados de forma integrada ao longo da rede, sobretudo sob incerteza. [Achkar et al. \(2024\)](#)

1.1.3 Problema de pesquisa, modelo de referência e escopo

Esta pesquisa considera uma rede composta por fábricas F , centros de estoque S e lojas M , na qual a ponta do sistema (lojas) enfrenta demanda esperada por item, denotada por $O_m(i)$. A decisão operacional consiste em determinar, de forma coordenada, quantidades a produzir e quantidades a transferir entre nós, respeitando limitações de disponibilidade, capacidade produtiva e restrições logísticas (capacidade de transporte e viabilidade de rotas), com objetivo de minimizar custos e penalidades associadas ao tempo de transporte.

Como formulação de referência, adota-se o modelo base fornecido pelo autor (formulação determinística de um período), no qual $x_{a,b,i}$ representa a quantidade do item i transferida do nó a para o nó b , e $y_{f,i}$ representa a quantidade do item i produzida na fábrica f . Em termos de modelagem em rede, é conveniente explicitar um conjunto de nós $N := F \cup S \cup M$ e um conjunto de arcos factíveis $A \subseteq N \times N$, obtido por pré-processamento das restrições de viabilidade (p. ex., filtragem de rotas inviáveis em função de limites operacionais de distância/tempo), de modo a

evitar restrições redundantes e tornar explícita a estrutura do grafo. [Ahuja et al. \(1993\)](#); [Shapiro \(2001\)](#)

Adicionalmente, embora o problema esteja formulado no baseline como determinístico e de um período, o contexto operacional real de abastecimento é inerentemente dinâmico, pois decisões são reiteradas ao longo de ciclos, com atualização periódica de informações de vendas, demanda estimada e disponibilidade. Conforme apresentação do autor, há uma linha do tempo em ciclos $t_1, t_2, t_3, \dots$ com atualização recorrente de histórico e demanda entre ciclos, o que é consistente com uma lógica de *rolling horizon*: resolve-se um subproblema de planejamento em cada ciclo com dados atualizados, aplica-se a decisão de curto prazo e replaneja-se em seguida. Tal enquadramento é particularmente relevante para justificar extensões multi-período e avaliações por simulação. [Law \(2015\)](#)

No que tange ao escopo, alguns parâmetros estruturais permanecem *não especificados* no enunciado (por exemplo: horizonte H , granularidade temporal e aderência do termo de tempo no objetivo). Para fins de rigor e reprodutibilidade, propõe-se explicitar alternativas razoáveis na formalização estendida (por exemplo, planejamento diário com $H \in \{14, 28, 56\}$ dias, ou planejamento semanal com $H \in \{8, 12\}$ semanas; valores finais *não especificados* e dependentes do contexto de aplicação). A extensão multi-período e estocástica pode ser estruturada tanto via programação estocástica por cenários quanto via avaliação por simulação Monte Carlo, o que encontra suporte formal no arcabouço clássico de programação estocástica. [Birge and Louveaux \(2011\)](#); [Law \(2015\)](#)

1.1.4 Escala, viabilidade computacional e motivação para métodos aproximados

Em aplicações realistas de MEIO, a escala do problema tende a ser o principal fator limitante para abordagens estritamente exatas. Conforme apresentação do autor, o estudo de caso motivador envolve um *dataset* com aproximadamente 48 milhões de registros, 12 mil produtos únicos e 3 milhões de entidades de demanda (revendedoras), ilustrando um cenário em que o número de combinações potenciais de decisões cresce de forma massiva. (Conforme apresentação do autor; números exatos do recorte operacional adicional *não especificados*.) Em termos computacionais, isso se manifesta em duas dimensões complementares: (i) o crescimento combinatorial do espaço de decisões em modelos discretos (p. ex., decisões de expedição multi-itens em múltiplos nós) e (ii) a explosão do espaço de estados quando o problema é tratado como decisão sequencial sob incerteza, caracterizando a chamada *maldição da dimensionalidade*. [Boute et al. \(2022\)](#); [Geevers et al. \(2024\)](#); [Ziegner et al. \(2025\)](#)

A apresentação do autor indica a existência de uma solução inicial baseada em programação linear inteira que atua como *benchmark* para parte do problema, sugerindo quantidades ideais de reposição a partir de histórico de vendas e restrições logísticas; ainda assim, para viabilizar a execução nesse ambiente de dados, foram necessárias agregações e/ou simplifi-

cações de variáveis devido ao volume de “milhões de decisões possíveis” (conforme apresentação do autor). Essa evidência fortalece a posição metodológica da dissertação: modelos exatos (MILP/ILP) são essenciais como referência interpretável e como instrumento de auditoria de qualidade em instâncias reduzidas ou agregadas, mas não são, por si só, uma solução universal quando se preserva fidelidade operacional em grande escala. [Shapiro \(2001\)](#); [Ahuja et al. \(1993\)](#)

Nesse cenário, métodos aproximados tornam-se metodologicamente justificáveis e, em muitos casos, necessários. Metaheurísticas oferecem um compromisso entre qualidade de solução e custo computacional, sobretudo quando se pretende explorar rapidamente regiões promissoras do espaço de busca e incorporar restrições operacionais complexas. [Talbi \(2009\)](#) Conforme apresentação do autor, o plano experimental inclui a comparação entre um baseline linear/inteiro e metaheurísticas como *Genetic Algorithm* (GA), GRASP e *Simulated Annealing* (SA), além da incorporação de uma abordagem de aprendizado por reforço multiagente inspirada por IMARL. (Conforme apresentação do autor; parâmetros finais de execução *não especificados*.) Observa-se que tais escolhas são coerentes com a literatura: GA e SA são paradigmas amplamente utilizados em otimização combinatória para balancear exploração e intensificação; GRASP combina construções gulosas randomizadas com busca local; e abordagens multiagentes tentam decompor decisões e endereçar escalabilidade em MEIO. [Talbi \(2009\)](#); [Ziegner et al. \(2025\)](#); [Geevers et al. \(2024\)](#)

Por fim, a escala também impõe requisitos de engenharia experimental e reprodutibilidade. Conforme apresentação do autor, pretende-se consolidar um pipeline automatizado (p. ex., Kedro) que execute múltiplas abordagens e gere relatórios padronizados (custo total, tempo de execução, uso de memória, estabilidade), viabilizando análises multicritério e testes de robustez em diferentes escalas de dados. (Conforme apresentação do autor.) Esse ponto é particularmente relevante quando se avaliam métodos estocásticos (metaheurísticas e DRL), para os quais a análise estatística por múltiplas sementes e a padronização de métricas são condições necessárias para inferências confiáveis. [Law \(2015\)](#); [Boute et al. \(2022\)](#)

1.1.5 Coerência custo–tempo e definição do trade-off

O objetivo do modelo base combina componentes de custo e um termo associado ao tempo de transporte. Para evitar ambiguidade de unidades e garantir interpretabilidade econômica, adota-se explicitamente um parâmetro de ponderação $\lambda_t \geq 0$ que converte a penalidade temporal em unidade monetária, interpretável como “valor econômico do tempo logístico” (por exemplo, R\$ por unidade de tempo, possivelmente escalonado por unidade transportada). Assim, uma escrita formal e unitariamente consistente do objetivo é:

$$\min_{x,y} \sum_{(a,b) \in A} \sum_{i \in I_a \cap I_b} c d(a,b) x_{a,b,i} + \sum_{f \in F} \sum_{i \in I_f} p_f(i) y_{f,i} + \lambda_t \sum_{(a,b) \in A} \sum_{i \in I_a \cap I_b} t(a,b) x_{a,b,i}. \quad (1.1)$$

Nesta expressão, c é um custo unitário de transporte por unidade de distância (por unidade transportada), $d(a,b)$ representa distância (por exemplo, em km), $t(a,b)$ representa tempo (por exemplo, em horas) e $p_f(i)$ o custo unitário de produção. O parâmetro λ_t pode ser calibrado de duas formas complementares: (i) como um coeficiente econômico (p. ex., custo de capital imobilizado no trânsito, penalidade por atraso ou custo de oportunidade associado a tempo), ou (ii) por normalização, escalonando os termos de custo e tempo em faixas comparáveis (por exemplo, normalização por máximos/percentis) e interpretando λ_t como parâmetro adimensional de preferência. [Simchi-Levi et al. \(2009\)](#); [Chopra \(2022\)](#)

Adicionalmente, uma leitura MEIO admite que tempo logístico é frequentemente um *proxy* de nível de serviço (quanto maior o tempo de trânsito, maior exposição a falta no ponto de demanda), o que permite modelagens alternativas: converter parte do critério em restrições de serviço (p. ex., probabilidade de atendimento, janelas) ou em custo esperado de ruptura via modelos estocásticos. [Axsater \(2006\)](#); [Achkar et al. \(2024\)](#); [Birge and Louveaux \(2011\)](#) No contexto desta dissertação, a opção por um objetivo ponderado com λ_t é adequada como baseline e facilita análises de sensibilidade: ao variar λ_t em uma grade (valores *não especificados*), pode-se observar a fronteira empírica custo–tempo e comparar métodos sob a mesma noção de preferência operacional. [Talbi \(2009\)](#)

1.1.6 Questões de pesquisa e hipótese metodológica

À luz dos elementos anteriores, esta dissertação organiza-se em torno de quatro questões de pesquisa. Primeiramente, investiga-se como especificar, de forma formal e auditável, uma formulação integrada produção–transferência em rede, multi-itens, que respeite capacidades e restrições logísticas sem sacrificar interpretabilidade (QP1). Em seguida, busca-se caracterizar regimes de escala em que modelos exatos/semiexatos permanecem úteis como referência e como instrumento decisório, e regimes em que métodos aproximados e políticas aprendidas passam a ser necessários (QP2). Na sequência, avalia-se comparativamente o desempenho de MILP/ILP, metaheurísticas e políticas por RL/DRL (inclusive multiagentes) sob métricas operacionais e computacionais padronizadas (QP3). Por fim, ao estender o problema para multi-período e demanda estocástica sob *rolling horizon*, examina-se a robustez e a capacidade de generalização de políticas aprendidas em ambiente simulado (QP4). [Birge and Louveaux \(2011\)](#); [Law \(2015\)](#); [Boute et al. \(2022\)](#); [Geevers et al. \(2024\)](#); [Ziegner et al. \(2025\)](#)

A hipótese metodológica central é que a combinação de (i) um baseline de otimização em rede para instâncias controladas/agregadas, (ii) metaheurísticas para regimes de maior escala e (iii) DRL para regimes dinâmicos/estocásticos constitui uma estratégia cientificamente consis-

tente e empiricamente testável para MEIO em redes gerais. [Shapiro \(2001\)](#); [Ahuja et al. \(1993\)](#); [Talbi \(2009\)](#); [Boute et al. \(2022\)](#) Essa hipótese é particularmente pertinente quando se considera que DRL, embora promissor para decisão sequencial, demanda desenho cuidadoso de estados, recompensas e protocolos de avaliação; e que abordagens multiagentes têm sido propostas especificamente para mitigar gargalos de dimensionalidade em MEIO realista. [Geevers et al. \(2024\)](#); [Ziegner et al. \(2025\)](#); [Schulman et al. \(2017\)](#); [Oroojlooyjadid et al. \(2022\)](#)

Esquemático da rede de abastecimento




Figure 1.1: Estrutura simplificada da rede de abastecimento multi-echelon.

Pipeline de solução e avaliação




Figure 1.2: Pipeline de solução e avaliação.




Figure 1.3: Framework iterativo de previsão e otimização em horizonte rolante.

Encaminhamento para trabalhos relacionados, objetivos e contribuições

A motivação apresentada delimita um problema MEIO em topologia de rede geral, com decisões integradas de produção e transferência, cujo tratamento exige tanto fundamentação teórica (multi-echelon, estocasticidade e redes) quanto uma estratégia metodológica comparativa que enderece simultaneamente qualidade, interpretabilidade e escalabilidade. Em consequência, a Seção *Related Work* sistematiza os fundamentos de inventário multi-echelon e variabilidade, a tradição de modelagem por programação matemática e fluxos em redes, e o estado recente de DRL/MARL, simulação e previsão de demanda em cadeias multi-escala. Na sequência, a seção de objetivos traduz essas motivações em metas verificáveis e um plano experimental reproduzível.

As contribuições esperadas desta dissertação podem ser resumidas, em alto nível, como:

1. uma formalização unificada e auditável do problema de abastecimento em rede varejista multi-escala, com representação explícita de arcos factíveis e trade-off custo-tempo via λ_t ;
2. um *benchmark* ILP/MILP e um conjunto de metaheurísticas (GA/GRASP/SA) adequados a regimes de escala distintos, com protocolo de comparação padronizado;
3. uma extensão multi-período/estocástica sob *rolling horizon* e respectiva infraestrutura de simulação para avaliação robusta;
4. a investigação de políticas por DRL/MARL (incluindo IMARL) como alternativa escalável para MEIO realista, com análise de estabilidade e generalização;
5. evidências empíricas, em instâncias controladas e em dados de grande porte (conforme apresentação do autor), que caracterizem limites de aplicabilidade e trade-offs entre custo, tempo computacional e recursos de memória.

1.2 Related Work

1.2.1 MEIO sob incerteza: fundamentos, tipologias e modelos de nível de serviço

A literatura de MEIO se desenvolveu sobre a constatação de que políticas e decisões de inventário em sistemas multi-escala são estruturalmente interdependentes e, portanto, inadequadas para tratamento estritamente local se o objetivo é minimizar custo sistêmico sob metas de serviço. O resultado fundador de Clark e Scarf estabelece, para um sistema seriado sob hipóteses específicas, decomposições e propriedades estruturais que influenciaram décadas de pesquisa subsequente. [Clark and Scarf \(1960\)](#) Textos clássicos de controle de inventário consolidados na Pesquisa Operacional detalham a formalização de custos de posse e ruptura, políticas-base e medidas de serviço, e são essenciais para transpor conceitos de SEIO para MEIO com rigor. [Axsater \(2006\)](#); [Zipkin \(2000\)](#)

Em ambientes industriais, uma família particularmente influente de formulações para MEIO é associada aos *guaranteed-service models* (GSM), que transformam certas fontes de incerteza e variabilidade em compromissos de tempo de serviço e alocação estratégica de estoques de segurança. O trabalho clássico de Graves e Willems propõe um arcabouço em rede (sob hipóteses específicas, como políticas *base-stock* e demanda limitada) e desenvolve algoritmos para posicionamento de *safety stock*, com validação aplicada. [Graves and Willems \(2000\)](#) Revisões de alto impacto mostram que GSM e suas extensões constituem uma área extensa, variando hipóteses (demanda, lead times, capacidades, políticas) e métodos de solução, além de concentrar aplicações industriais relevantes. [Eruguz et al. \(2016\)](#) Extensões recentes incorporam características típicas de prática industrial (p. ex., nós híbridos, MOQ, múltiplas métricas de serviço e reformas computacionais), evidenciando que a modelagem realista frequentemente induz não-linearidades e desafios computacionais adicionais. [Achkar et al. \(2024\)](#)

Uma síntese moderna e influente da pesquisa em MEIO sob demanda estocástica é proposta por de Kok et al., que desenvolvem uma tipologia para classificar modelos (assunções, objetivos e metodologias), analisam clusters de escolhas de modelagem e destacam lacunas que emergem quando se busca representar redes gerais e restrições operacionais reais. [de Kok et al. \(2018\)](#) Tal referência é particularmente relevante para esta dissertação, pois o problema investigado incorpora rede geral (com possibilidade de transbordo e múltiplos caminhos), múltiplos itens, custos logísticos e um componente temporal explícito no objetivo, indo além do foco exclusivo em estoque de segurança.

1.2.2 Modelagem por redes e programação matemática: produção, distribuição e restrições logísticas

A integração de produção e distribuição em modelos otimizáveis é tradicionalmente tratada por programação matemática, frequentemente com representações em rede, decomposições e formulações por fluxo. Shapiro sistematiza a modelagem de cadeias com decisões de produção, estoque e transporte, articulando hipóteses e estruturas de formulação que orientam tanto a construção do modelo quanto a interpretação de soluções. [Shapiro \(2001\)](#) Em paralelo, a teoria de fluxos em redes fundamenta representações (N, A) e fornece linguagem e resultados úteis para compreender escalabilidade, restrições de capacidade e estruturas especiais (seriadas, divergentes e redes gerais) como casos particulares de grafos dirigidos. [Ahuja et al. \(1993\)](#)

No problema desta dissertação, a presença simultânea de (i) decisões de produção $y_{f,i}$, (ii) fluxos multi-itens $x_{a,b,i}$, (iii) capacidades $C_{a,b}$ e (iv) viabilidade de rotas e *lead times*/tempos $t(a,b)$ aproxima a formulação de um planejamento integrado em rede com restrições operacionais. Do ponto de vista de Pesquisa Operacional, isso justifica a adoção de MILP/ILP como baseline rigoroso em instâncias reduzidas/agregadas, tanto para inferência de gargalos quanto para calibração de heurísticas e políticas aprendidas. [Shapiro \(2001\)](#); [Ahuja et al. \(1993\)](#)

1.2.3 Escalabilidade: metaheurísticas, simulação e programação estocástica

A escalabilidade é um dos principais fatores que motivam abordagens aproximadas. Metaheurísticas formam uma família de métodos de propósito geral para otimização em espaços combinatórios e/ou não convexos, e sua adequação a problemas com múltiplas restrições práticas (capacidade, janelas, políticas) decorre da flexibilidade de representação e de mecanismos de penalização/viabilidade. [Talbi \(2009\)](#) A escolha de GA/GRASP/SA, conforme apresentada pelo autor, é compatível com esse arcabouço: GA privilegia exploração global via recombinação; SA organiza uma trajetória com critério probabilístico de aceitação; e GRASP oferece um compromisso entre construção gulosa randomizada e intensificação por busca local.

Sob incerteza, a literatura oferece dois instrumentos metodológicos complementares, ambos relevantes para este trabalho. Em um eixo mais formal, programação estocástica fornece modelagens por cenários e decisões de recourse para sistematizar a incorporação de demanda aleatória, custos esperados e, se necessário, medidas de risco. [Birge and Louveaux \(2011\)](#) Em um eixo experimental-operacional, simulação descreve e avalia sistemas dinâmicos e estocásticos, permitindo comparar políticas sob métricas de custo e nível de serviço, bem como validar aproximações e simplificações impostas por modelos otimizáveis. [Law \(2015\)](#) Essa combinação é particularmente alinhada ao paradigma de *rolling horizon* adotado nesta dissertação, no qual previsão, otimização e execução se alternam, realimentando continuamente o estado do sistema.

1.2.4 Previsão de demanda e métricas alinhadas a custo/serviço

A previsão de demanda é um elemento crítico quando se pretende operacionalizar decisões multi-período e/ou sob incerteza, pois alimenta tanto parâmetros de modelos determinísticos (como $O_m(i)$ em curto prazo) quanto distribuições/cenários em formulações estocásticas. Evidência empírica recente em previsão no varejo indica que métodos de *ensemble* baseados em árvores podem superar redes LSTM em determinados contextos e categorias de produtos, mesmo em dados reais de grande escala, reforçando que “mais complexidade” em modelo de previsão nem sempre resulta em melhor desempenho preditivo para fins de decisão. [Nasseri et al. \(2023\)](#) Complementarmente, Tadayonrad e Ndiaye argumentam que métricas clássicas de erro (p. ex., MAE/MAPE) não capturam diretamente impacto em custos de inventário e propõem um KPI que incorpora custo e nível de serviço via confiabilidade e sazonalidade, aproximando avaliação preditiva de objetivos operacionais. [Tadayonrad and Ndiaye \(2023\)](#)

1.2.5 DRL/MARL para inventários e MEIO: evidências, limitações e tendência de escalabilidade

O avanço recente de DRL em controle de inventário decorre da capacidade de representar políticas para decisão sequencial em ambientes estocásticos, aproximando-se do que ocorre em operação real (p. ex., decisões repetidas em $t = 1, 2, \dots$). Entretanto, sua adoção exige escolhas de projeto (estado, ação, recompensa, arquitetura e protocolos de avaliação) que impactam substancialmente estabilidade e confiabilidade; Boute et al. sintetizam essas escolhas, discutem trade-offs e fornecem um roadmap para aplicação e avaliação rigorosa em inventários. [Boute et al. \(2022\)](#)

Evidência diretamente conectada ao recorte MEIO é apresentada por Geevers et al., que aplicam PPO a três estruturas de rede (linear, divergente e geral) e reportam desempenho superior ao benchmark nos três casos, situando as limitações e sugerindo caminhos futuros. [Geevers et al. \(2024\)](#) A literatura também oferece avaliações comparativas em problemas de inventário “clássicos e intratáveis”, incluindo configurações multi-echelon, propondo protocolos de comparação com heurísticas e ADP; um exemplo influente reporta que DRL pode alcançar desempenho competitivo em diferentes estruturas, embora com custos de treinamento e cuidados de generalização. [Gijsbrechts et al. \(2022\)](#) Em ambientes explicitamente multiagentes e descentralizados, a linha do Beer Game é representativa por conectar DRL à dinâmica do bull-whip e a decisões locais com informação parcial, além de explorar mecanismos como *transfer learning*. [Oroojlooyjadid et al. \(2022\)](#)

Quanto à escalabilidade, a maldição da dimensionalidade permanece como restrição decisiva para DRL em cenários realistas. Ziegner et al. discutem esse ponto no contexto de MEIO e propõem IMARL, combinando MARL, técnicas com grafos e uma estratégia iterativa para ampliar aplicabilidade em cenários com maior complexidade estrutural, reportando ganhos

de robustez e desempenho frente a benchmarks. [Ziegner et al. \(2025\)](#) Assim, o estado da arte sugere que DRL/MARL é promissor, porém depende de (i) ambientes de simulação fidedignos, (ii) desenho experimental rigoroso e (iii) técnicas explícitas de escalabilidade para redes gerais.

1.3 General and Specific Objectives

Objetivo geral

Desenvolver, implementar e avaliar comparativamente um arcabouço de decisão para o problema de otimização do abastecimento em uma rede de lojas com múltiplos centros de estoque e fábricas, fundamentado na formulação base (produção $y_{f,i}$ e fluxos $x_{a,b,i}$ em rede) e estendido para um ambiente multi-período/estocástico em *rolling horizon*, de modo a minimizar custo total e penalidades temporais (via λ_t) preservando restrições logísticas e metas de serviço.

Objetivos específicos

1. **Refinar e validar a formulação base em rede.** Consolidar conjuntos, parâmetros e restrições, explicitando o grafo (N, A) , o pré-processamento de arcos factíveis, e a interpretação unitária do objetivo com λ_t , garantindo consistência matemática e rastreabilidade. [Ahuja et al. \(1993\)](#); [Shapiro \(2001\)](#)
2. **Construir um pipeline reprodutível de dados e instâncias.** Definir um esquema de dados e rotinas de geração/extração para instâncias controladas (tamanho *não especificado*; propor $|M| \in \{20, 50, 100\}$, $|S| \in \{2, 5, 10\}$, $|I| \in \{50, 200, 500\}$) e, quando possível, instâncias em escala real (conforme apresentação do autor), padronizando relatórios e logs.
3. **Implementar um benchmark ILP/MILP.** Resolver instâncias pequenas/agregadas com ILP/MILP, reportando *gap* (quando disponível), decomposição de custo (produção vs transporte vs penalidade temporal) e sensibilidade a capacidades $C_{a,b}$ e Q_f . [Shapiro \(2001\)](#)
4. **Projetar e calibrar metaheurísticas para escala.** Implementar GA/GRASP/SA (conforme apresentação do autor) com tratamento explícito de restrições e análise estatística por múltiplas sementes, visando instâncias de maior porte e regimes em que ILP/MILP se torna impraticável. [Talbi \(2009\)](#)
5. **Incorporar previsão de demanda no ciclo decisório.** Implementar um módulo de previsão para alimentar $O_m(i)$ (base) e/ou $D_{m,i,t}$ (extensão), avaliando modelos com métricas

tradicionais e métricas alinhadas a custo/serviço; quando pertinente, comparar *ensembles* de árvores e LSTM em dados com sazonalidade e variáveis exógenas. [Nasseri et al. \(2023\)](#); [Tadayonrad and Ndiaye \(2023\)](#)

6. **Estender para multi-período e demanda estocástica sob rolling horizon.** Introduzir índice temporal t , estoques $I_{n,i,t}$ e variáveis de ruptura (backorder ou lost sales, *não especificado*), modelando cenários/Monte Carlo para demanda e, opcionalmente, lead times; justificar e documentar hipóteses. [Birge and Louveaux \(2011\)](#); [Law \(2015\)](#)
7. **Construir e validar um simulador para avaliação de políticas.** Desenvolver um ambiente de simulação coerente com o modelo e com o ciclo de reotimização, permitindo comparar políticas sob métricas de custo esperado, nível de serviço (fill rate/cycle service), variância e robustez. [Law \(2015\)](#)
8. **Investigar DRL/MARL como política escalável.** Implementar uma política DRL (p. ex., PPO) e, se aplicável, extensões MARL/IMARL (conforme apresentação do autor), avaliando generalização, estabilidade e custo computacional em comparação com benchmarks e metaheurísticas. [Boute et al. \(2022\)](#); [Geevers et al. \(2024\)](#); [Ziegner et al. \(2025\)](#); [Schulman et al. \(2017\)](#); [Oroojlooyjadid et al. \(2022\)](#)

Observação de coerência entre objetivos e entregáveis do capítulo

Os objetivos acima estruturam naturalmente a transição da Introdução para o restante do texto: a Seção *Related Work* sustenta as escolhas de formulação e método; o capítulo de modelagem formaliza o problema em nível de tese; os capítulos metodológicos implementam ILP/MILP, metaheurísticas, simulação e DRL/MARL; e os capítulos experimentais apresentam evidência quantitativa e análise multicritério, com destaque para sensibilidade em λ_t e para limites de escalabilidade em dados realistas.

2

Tecnologias e Conceitos

2.1 Visão geral do arcabouço tecnológico do projeto

O sistema alvo pode ser representado por um grafo dirigido (N, A) , onde $N := F \cup S \cup M$ reúne fábricas F , centros de estoque S e lojas M , e $A \subseteq N \times N$ descreve rotas factíveis. [Ahuja et al. \(1993\)](#); [Shapiro \(2001\)](#) Os produtos i compõem um conjunto I (não especificado; tipicamente I pode variar de dezenas a milhares de SKUs), e a demanda nas lojas é tratada, no baseline, como $O_m(i)$ (determinística/esperada), com extensão natural para $D_{m,i,t}$ (multi-período e estocástica) sob *rolling horizon*. [Axster \(2006\)](#); [Birge and Louveaux \(2011\)](#)

O ciclo computacional recomendado, em consonância com a apresentação e com o pipeline implementado nos códigos anexados, estrutura-se como: **(a)** ingestão e consolidação de dados históricos até t (janela $[t - w, t]$, w não especificado), **(b)** estimação de demanda futura em $t + 1 : t + H$ (H não especificado; alternativas razoáveis: $H \in \{14, 28, 56\}$ dias ou $H \in \{8, 12\}$ semanas), **(c)** otimização das decisões, **(d)** execução e coleta de novos dados, **(e)** realimentação e repetição do ciclo. Esse paradigma suporta tanto decisões pontuais (1 período) quanto decisões sequenciais em horizonte rolante. [Law \(2015\)](#)

Arquiteturas de pipeline: visão conceitual (Mermaid)

flowchart TD

```
A[Dados observados até t: vendas, estoque, lead time, custos] --> B[Preparação e features]
B --> C[Previsão de demanda:  $\hat{D}_{t+1:t+H}$ ]
C --> D[Otimização: MILP/ILP + heurísticas]
D --> E[Plano de ação: produção, transferências, reposição]
E --> F[Execução + observação do sistema]
F --> A
```

Arquitetura esquemática (TikZ)




Figure 2.1: Ciclo de decisão em horizonte rolante: dados → previsão → otimização → execução → realimentação.

2.2 Programação matemática e modelagem em redes

2.2.1 ILP, MILP e MIP: definição formal, interpretação e complexidade

Uma *programação inteira mista* (MIP) é um problema de otimização em que parte das variáveis deve assumir valores inteiros. Quando todas as funções são lineares e há variáveis inteiras e contínuas, obtém-se um *MILP*; quando todas as variáveis são inteiras, um *ILP*. Em forma padrão:

$$\min \quad c^\top x \quad (2.1)$$

$$\text{sujeito a} \quad Ax \leq b, \quad (2.2)$$

$$x_j \in \mathbb{Z} \quad \forall j \in I, \quad (2.3)$$

$$x_k \in \mathbb{R} \quad \forall k \notin I, \quad (2.4)$$

onde I indexa as variáveis inteiras e A, b, c são dados. [Shapiro \(2001\)](#) Problemas MIP/MILP são, em geral, *NP-difíceis*, e solvers modernos usam variantes de *branch-and-bound/branch-and-cut* apoiadas em relaxações lineares, cortes válidos, heurísticas internas e pré-processamento. [Gurobi Optimization LLC \(2024a\)](#)

No contexto MEIO, a vantagem do MILP é fornecer: (i) rastreabilidade (cada restrição e variável possui interpretação operacional), (ii) capacidade de impor restrições rígidas (capacidade, atendimento, políticas), e (iii) *benchmarks* com limites de otimalidade (gap). A limitação central é escalabilidade: a cardinalidade de variáveis cresce com $|A| \times |I|$ (e, em multi-período, $|T|$), levando a instâncias com milhões de variáveis/coeficientes, sobretudo quando se evita agregação. [Ahuja et al. \(1993\)](#); [Shapiro \(2001\)](#); [Geevers et al. \(2024\)](#)

2.2.2 Fluxos em redes e fluxo multi-*commodity*

Um problema de *fluxo em rede* considera um grafo dirigido (N, A) e decide fluxos $f_{a,b}$ em arcos $(a, b) \in A$, respeitando conservação de fluxo e capacidades. A formulação típica é:

$$\min \sum_{(a,b) \in A} \kappa_{a,b} f_{a,b} \quad (2.5)$$

$$\text{sujeito a } \sum_{(u,v) \in A: v=n} f_{u,n} - \sum_{(n,w) \in A} f_{n,w} = s_n \quad \forall n \in N, \quad (2.6)$$

$$0 \leq f_{a,b} \leq C_{a,b} \quad \forall (a,b) \in A, \quad (2.7)$$

onde s_n representa oferta/demanda líquida. [Ahuja et al. \(1993\)](#)

No abastecimento multi-itens, o modelo naturalmente se torna um *fluxo multi-commodity*: para cada item $i \in I$, define-se $x_{a,b,i}$ e impõem-se conservações e capacidades agregadas. Uma estrutura canônica (simplificada) é:

$$\sum_{(u,n) \in A} x_{u,n,i} - \sum_{(n,w) \in A} x_{n,w,i} = s_{n,i} \quad \forall n \in N, \forall i \in I, \quad (2.8)$$

$$\sum_{i \in I} x_{a,b,i} \leq C_{a,b} \quad \forall (a,b) \in A, \quad (2.9)$$

$$x_{a,b,i} \geq 0. \quad (2.10)$$

Em MEIO, $s_{n,i}$ pode representar produção líquida, disponibilidade inicial ou demanda agregada. [Shapiro \(2001\)](#) A versão totalmente fracionária (contínua) é um LP de grande porte; já a versão inteira (fluxos inteiros por lote/unidade) é *NP-difícil*. [Ahuja et al. \(1993\)](#)

2.2.3 Formulação base deste projeto e extensão multi-período/estocástica

A formulação base do projeto define decisões de transporte $x_{a,b,i}$ e produção $y_{f,i}$, minimizando custos e penalidade temporal. A escrita do objetivo com parâmetro explícito λ_t (valor econômico do tempo) é:

$$\min_{x,y} \sum_{(a,b) \in A} \sum_{i \in I_a \cap I_b} c d(a,b) x_{a,b,i} + \sum_{f \in F} \sum_{i \in I_f} p_f(i) y_{f,i} + \lambda_t \sum_{(a,b) \in A} \sum_{i \in I_a \cap I_b} t(a,b) x_{a,b,i}. \quad (2.11)$$

A adoção de λ_t é fundamental para coerência dimensional (custo vs tempo) e permite análises de sensibilidade na fronteira custo–tempo. [Simchi-Levi et al. \(2009\)](#); [Chopra \(2022\)](#)

A extensão multi-período (com $t \in \{1, \dots, H\}$, H não especificado) adiciona variáveis de estoque $I_{n,i,t}$ e (opcionalmente) ruptura por *backorder* $B_{m,i,t}$ ou *lost sales* $L_{m,i,t}$. A forma geral do balanço em loja (com backorder) é:

$$I_{m,i,t} - B_{m,i,t} = I_{m,i,t-1} - B_{m,i,t-1} + \sum_{(u,m) \in A} \text{Arrive}_{u,m,i,t} - D_{m,i,t}, \quad (2.12)$$

$$I_{m,i,t} \geq 0, \quad B_{m,i,t} \geq 0, \quad (2.13)$$

onde $\text{Arrive}_{u,m,i,t}$ incorpora *lead times* $\ell_{u,m}$ (não especificados) via $\text{Arrive}_{u,m,i,t} = x_{u,m,i,t-\ell_{u,m}}$. [Axsater \(2006\)](#) Para demanda estocástica, $D_{m,i,t}$ pode ser modelada por cenários $\omega \in \Omega$ com probabilidades p_ω , minimizando custo esperado e/ou risco, conforme programação estocástica. [Birge and Louveaux \(2011\)](#)

2.3 Solvers e bibliotecas de otimização

2.3.1 OR-Tools: MPSolver e CP-SAT

O Google OR-Tools fornece interfaces para otimização linear e inteira (via MPSolver) e um solver dedicado para programação por restrições e IP baseada em SAT, o CP-SAT. [Google Optimization Team \(2024b,a\)](#) A documentação oficial recomenda CP-SAT para muitos problemas inteiros, observando que ele é projetado para problemas de programação inteira e pode ser mais rápido que o MPSolver em várias classes; entretanto, exige modelagem em inteiros, requerendo escalonamento quando há coeficientes reais. [Google Optimization Team \(2024a\)](#)

Implementação mínima (MIP com OR-Tools/MPSolver). A estrutura típica em MPSolver consiste em declarar solver, variáveis, restrições, objetivo e chamar `Solve()`. [Google Optimization Team \(2024b\)](#)

```
# OR-Tools (MPSolver) - esqueleto mínimo (Python)
from ortools.linear_solver import pywraplp

solver = pywraplp.Solver.CreateSolver("SCIP") # ou "CBC", etc.
x = solver.IntVar(0, solver.infinity(), "x")
y = solver.IntVar(0, solver.infinity(), "y")

# restrição: x + 2y <= 14
solver.Add(x + 2*y <= 14)

# objetivo: maximizar 3x + 4y
solver.Maximize(3*x + 4*y)

status = solver.Solve()
```

```
if status in (pywraplp.Solver.OPTIMAL, pywraplp.Solver.FEASIBLE):
    print(x.solution_value(), y.solution_value(), solver.Objective().Value())
```

Notas de uso em MEIO. Para instâncias MEIO com grande número de variáveis, recomenda-se: (i) configuração de limites de tempo e tolerâncias (quando disponível na API), (ii) modelagem cuidadosa para reduzir simetria e redundância, (iii) pré-processamento do conjunto de arcos A por viabilidade $d(a,b) \leq T_{a,b}$ e por política (p.ex., associação E_m), (iv) agregação quando apropriado (p.ex., por famílias de itens), preservando rastreabilidade. [Ahuja et al. \(1993\)](#); [Shapiro \(2001\)](#)

2.3.2 Gurobi: fundamentos, API e parametrização

O Gurobi é um solver comercial de referência para MILP/MIP e LP, com documentação detalhando que muitos problemas são resolvidos por algoritmos baseados em *branch-and-bound/branch-and-cut*, com técnicas avançadas de cortes, heurísticas e pré-processamento. [Gurobi Optimization LLC \(2024a\)](#) A API Python organiza o fluxo de modelagem em torno do objeto `Model`, no qual se adicionam variáveis, restrições e função objetivo. [Gurobi Optimization LLC \(2024d\)](#)

Parâmetros essenciais. Do ponto de vista experimental, é crucial controlar parâmetros que afetam reprodutibilidade, comparação e custo computacional. A documentação do manual de referência do Gurobi lista parâmetros e diretrizes; em particular, encerramento por `TimeLimit` e por `MIPGap` são escolhas padrão, e `Threads` define paralelismo. [Gurobi Optimization LLC \(2024c,b\)](#)

```
# Gurobi (gurobipy) - esqueleto mínimo (Python)
import gurobipy as gp
from gurobipy import GRB

m = gp.Model("mip_example")
x = m.addVar(vtype=GRB.INTEGER, lb=0, name="x")
y = m.addVar(vtype=GRB.INTEGER, lb=0, name="y")

m.addConstr(x + 2*y <= 14, name="c1")
m.setObjective(3*x + 4*y, GRB.MAXIMIZE)

# parâmetros típicos p/ experimento
m.Params.TimeLimit = 300.0 # 5 minutos
m.Params.MIPGap = 0.01     # 1% de gap
m.Params.Threads = 1       # p/ reprodutibilidade (opcional)
```

```
m.optimize()
if m.Status in (GRB.OPTIMAL, GRB.SUBOPTIMAL):
    print(x.X, y.X, m.ObjVal)
```

Notas de uso em MEIO. Para comparação entre métodos, recomenda-se relatar: (i) status (OPTIMAL, FEASIBLE, TIME_LIMIT), (ii) *best bound*, *incumbent* e MIPGap, (iii) tempo total e, quando possível, tempo em presolve e em *root node*, (iv) tamanho do modelo (número de variáveis/constraints). Inconsistências e inviabilidades devem ser diagnosticadas com relaxações ou IIS (quando aplicável), evitando comparações injustas. [Gurobi Optimization LLC \(2024c,b\)](#)

2.4 Metaheurísticas para MEIO: GA, GRASP, SA e NSGA-II

Metaheurísticas são estratégias de busca de propósito geral para problemas combinatórios e/ou de grande escala, úteis quando (a) MILP/ILP não escala em tempo viável e/ou (b) deseja-se explorar fronteiras multicritério (p.ex., custo vs tempo vs emissões). [Talbi \(2009\)](#) No MEIO, elas são especialmente atraentes quando se preserva estrutura realista (muitos itens, muitos nós, restrições práticas), pois permitem encodar regras de negócio e operar com avaliação por simulação.

2.4.1 Genetic Algorithm (GA)

Definição. GA é um método populacional inspirado em evolução, que mantém uma população de soluções (cromossomos), aplica operadores de seleção, cruzamento e mutação, e utiliza uma função de aptidão para guiar a busca. [Talbi \(2009\)](#); [Holland \(1992\)](#)

Pseudocódigo (alto nível).

```
Inicialize população P0 com soluções factíveis (ou penalizadas)
Para g = 1..G:
    Avalie fitness de cada indivíduo
    Selecione pais (torneio/roleta) proporcional ao fitness
    Recombine (crossover) e aplique mutação com prob. pm
    Repare ou penalize violações de restrição
    Forme nova população Pg (elitismo opcional)
Retorne melhor solução encontrada
```

Complexidade. Se P é tamanho da população, G número de gerações e C_{eval} custo de avaliar uma solução, o custo típico é $O(P \cdot G \cdot C_{\text{eval}})$. Em MEIO, C_{eval} pode incluir simulação, tornando o método computacionalmente intenso.

Hiperparâmetros comuns. Tamanho da população P , taxa de crossover p_c , taxa de mutação p_m , pressão seletiva (torneio), elitismo, critério de parada (gerações sem melhora), e tratamento de restrição (reparo vs penalização). [Talbi \(2009\)](#)

Prós/cons em MEIO. GA tende a explorar bem espaços grandes e multimodais, admite paralelismo natural, mas pode exigir calibração extensa e pode ter dificuldade em restrições rígidas sem mecanismos de reparo/viabilidade.

2.4.2 GRASP

Definição. GRASP (*Greedy Randomized Adaptive Search Procedure*) é uma metaheurística multi-início: cada iteração constrói uma solução por uma heurística gulosa randomizada (via *Restricted Candidate List*, controlada por α) e, em seguida, aplica busca local para refinar a solução. [Feo and Resende \(1995\)](#)

Pseudocódigo.

```
Para k = 1..K:  
    s <- Construção gulosa randomizada (parâmetro )  
    s <- Busca local(s) a partir de s  
    Atualize melhor solução s*  
Retorne s*
```

Complexidade. O custo é $O(K \cdot (C_{\text{construct}} + C_{\text{ls}}))$. Em MEIO, C_{ls} pode ser elevado se movimentos (swap, relocate, reallocation) exigirem recomputar custos e checar restrições.

Hiperparâmetros. $\alpha \in [0, 1]$ (grau de aleatoriedade na construção), número de iterações K , vizinhanças na busca local, critérios de parada (tempo, iterações sem melhora). [Feo and Resende \(1995\)](#)

2.4.3 Simulated Annealing (SA)

Definição. SA é um método de busca estocástica que aceita pioras com probabilidade controlada por uma “temperatura” T , permitindo escapar de ótimos locais; o algoritmo é inspirado no processo físico de recozimento. [Kirkpatrick et al. \(1983\)](#)

Critério de aceitação (Metropolis). Dado custo $f(s)$, vizinho s' e $\Delta = f(s') - f(s)$, aceita-se s' se $\Delta \leq 0$ ou com probabilidade $\exp(-\Delta/T)$ caso contrário. [Kirkpatrick et al. \(1983\)](#)

Pseudocódigo.

```

s <- solução inicial; s* <- s; T <- T0
Enquanto T > Tmin e não parar:
  Para r = 1..R (repetições por temperatura):
    s' <- vizinho(s)
    Se f(s') <= f(s) então s <- s'
    Senão aceitar com prob exp(-(f(s')-f(s))/T)
    Atualize s* se necessário
  T <- alpha * T    (alpha < 1)
Retorne s*

```

Hiperparâmetros. Temperatura inicial T_0 , esquema de resfriamento α , repetições por temperatura R , temperatura mínima $T_{\min}$, definição de vizinhança. [Kirkpatrick et al. \(1983\)](#)

2.4.4 NSGA-II para multiobjetivo

Definição. NSGA-II é um algoritmo evolutivo multiobjetivo elitista que combina ordenação por dominância (*non-dominated sorting*) e diversidade por distância de aglomeração, produzindo aproximações de fronteiras de Pareto. [Deb et al. \(2002\)](#)

Complexidade. O artigo original discute complexidade $O(MN^2)$ para N indivíduos e M objetivos sob ordenação e crowding. [Deb et al. \(2002\)](#)

Uso em MEIO. Em MEIO, NSGA-II é indicado quando objetivos concorrentes são explicitados (p. ex., custo total, tempo total e/ou emissões), evitando a necessidade de escolher λ_t a priori. Em contrapartida, aumenta custo computacional e exige definição de avaliação/viabilidade multicritério.

2.5 Simulação: eventos discretos e Monte Carlo

Simulação é um eixo metodológico essencial quando se estende o problema para multi-período e demanda estocástica, pois permite medir custo esperado, nível de serviço e robustez sob variabilidade, além de servir como ambiente de treinamento/avaliação para DRL. [Law \(2015\)](#)

2.5.1 Simulação de eventos discretos (DES)

Conceito. Em DES, o estado do sistema muda em instantes discretos associados a eventos (chegada de demanda, recebimento de transferência, produção concluída, ruptura). Um *event list* ordenado por tempo é processado sequencialmente. [Law \(2015\)](#)

Uso em MEIO. DES é especialmente útil quando tempos de transporte/produção são explícitos, há filas/capacidades, e o impacto de atrasos e janelas interessa ao nível de serviço e custo.

2.5.2 Simulação Monte Carlo

Conceito. Monte Carlo estima métricas esperadas por amostragem repetida de variáveis aleatórias (demanda, lead times, falhas). [Law \(2015\)](#)

Pseudocódigo.

Para $r = 1..R$ replicações:

 Inicialize estoques e estado

 Para $t = 1..H$:

 Amostre demanda $D_{\{t\}} \sim \text{Distribuição (ou cenário)}$

 Aplique política/decisão (MILP/heurística/RL) p/ o período t

 Atualize estoques, backorders e custos

 Armazene métricas da replicação r

Compute média, variância e intervalos de confiança das métricas

Notas práticas. Recomenda-se R suficiente para reduzir variância (não especificado; valores iniciais típicos: $R \in [30, 200]$), uso de sementes controladas e, para comparar políticas, *common random numbers* (mesmas amostras de demanda para todos os métodos) a fim de reduzir ruído comparativo. [Law \(2015\)](#)

2.6 Previsão de demanda: modelos, métricas e alinhamento com decisão

2.6.1 Modelos estatísticos e de aprendizado

No pipeline anexado (Kedro), há implementação de *walk-forward (rolling-origin)* para avaliação fora-da-amostra, com modelos como *naive*, Holt-Winters, SARIMAX, XGBoost com defasagens e Prophet, registrando métricas (MAE, RMSE, MAPE) e parâmetros por execução (inclusive via MLflow). (Conforme códigos anexados; ver estrutura `conf/base/catalog.yml` e `pipelines/forecasting`.) Essa prática está alinhada a recomendações de avaliação temporal: evitar vazamento de informação e medir desempenho em horizonte relevante.

Em literatura recente, Nasser et al. analisam previsão de demanda no varejo e mostram, em contexto com milhões de registros e variáveis externas, que ensembles baseados em árvores podem superar LSTM em métricas clássicas; o resultado é relevante para este projeto porque sugere que, em certos regimes, modelos mais simples e robustos podem produzir previsões competitivas para decisão operacional. [Nasser et al. \(2023\)](#)

2.6.2 Métricas: erro preditivo e impacto operacional

Embora MAE/RMSE/MAPE sejam úteis para comparar algoritmos de previsão, existe consenso prático de que o erro preditivo deve ser interpretado à luz do objetivo operacional. Tadayonrad e Ndiaye propõem um KPI que incorpora confiabilidade da rede e sazonalidade e argumentam que minimizar erro não necessariamente minimiza custo de estoque; seu enfoque é diretamente aplicável ao MEIO, no qual previsões alimentam decisões de reposição e *safety stock*. [Tadayonrad and Ndiaye \(2023\)](#)

Recomendação metodológica. Além de MAE/RMSE/MAPE, recomenda-se avaliar previsões por métricas *decision-centric*, p. ex.: custo total resultante quando $\hat{D}$ alimenta o modelo de decisão, fill rate, custo de ruptura e excesso de inventário.

2.7 Programação estocástica e modelos de nível de serviço

Programação estocástica fornece um arcabouço formal para modelar incerteza via cenários e decisões de *recourse*. [Birge and Louveaux \(2011\)](#) Em MEIO, isso pode se materializar em: (i) modelos multiestágio, (ii) modelos de dois estágios com recourse, ou (iii) aproximações híbridas (cenários + rolling horizon). A principal limitação é o crescimento do modelo com $|\Omega| \times |T|$, o que frequentemente exige amostragem (SAA), decomposição e/ou simulação.

No âmbito de nível de serviço e estoques de segurança, abordagens do tipo GSM e suas extensões industriais permanecem relevantes quando se deseja garantir metas explícitas e reduzir capital em inventário; Achkar et al. discutem generalizações do GSM e validação por simulação, fornecendo evidência de aplicabilidade industrial e ganhos computacionais via reformulações. [Achkar et al. \(2024\)](#)

2.8 DRL, MARL e políticas para MEIO

2.8.1 MDP e formulação de RL

RL modela o problema como um *Markov Decision Process* (MDP) $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$, em que um agente observa um estado $s \in \mathcal{S}$, escolhe ação $a \in \mathcal{A}$, recebe recompensa $r = R(s, a)$ e transita via $P(s'|s, a)$. [Sutton and Barto \(2018\)](#) Em MEIO multi-período, s_t deve codificar, minimamente, estoques atuais, demandas recentes, pipeline de pedidos (lead time) e capacidades; a_t codifica decisões de produção/transferência e/ou políticas parametrizadas.

2.8.2 DQN: Q-learning profundo

DQN aproxima a função-valor $Q_{\theta}(s, a)$ com redes neurais e atualiza parâmetros por minimização de erro temporal-diferencial. O artigo seminal demonstra controle em nível humano em Atari e formaliza componentes como *experience replay* e *target network*. [Mnih et al. \(2015\)](#) Em inventário, DQN costuma ser aplicado quando ações são discretas e espaço de ação é controlável (p. ex., níveis de reposição discretizados), mas enfrenta limites quando a dimensionalidade da ação explode (multi-itens e rede grande).

2.8.3 PPO: policy gradient com clipping

PPO é um algoritmo de *policy gradient* que maximiza uma função objetivo *surrogate* com *clipping* para restringir a distância entre a política nova e a antiga, estabilizando treinamento. [Schulman et al. \(2017\)](#) Em MEIO, PPO é frequentemente preferido quando ações são contínuas (quantidades) ou quando se deseja modelar decisões como vetores contínuos e depois projetar/arriscar para viabilidade. Geevers et al. reportam aplicação de PPO a diferentes estruturas MEIO (linear, divergente e rede geral), observando desempenho superior a *benchmark* nos cenários estudados, o que justifica PPO como candidato no presente projeto. [Geevers et al. \(2024\)](#)

2.8.4 MARL/IMARL e escalabilidade

Em redes gerais, uma estratégia para escalabilidade é modelar decisões por nó/elo como agentes distintos (MARL) ou decompor a política. Ziegner et al. propõem IMARL como abordagem iterativa multiagente voltada a MEIO, relatando ganhos de escalabilidade e desempenho em comparação com benchmarks, o que o torna uma referência natural para a trilha de pesquisa do projeto (conforme apresentação do autor). [Ziegner et al. \(2025\)](#)

2.8.5 Ambiente tipo Gymnasium: esqueleto para simulação e RL

A recomendação prática é implementar um ambiente com API compatível com Gymnasium (`reset`, `step`), permitindo: (i) simulação para avaliação de políticas e (ii) treino com bibliotecas DRL. A documentação oficial descreve requisitos de `reset()` e `step()` e recomenda inicializar RNG com `super().reset(seed=seed)` para reprodutibilidade. [Foundation \(2023\)](#)

```
# Esqueleto Gym-like (pseudo-Python) para MEIO multi-período
import gymnasium as gym
import numpy as np

class MEIOEnv(gym.Env):
    def __init__(self, instance, horizon, seed=0):
```

```

self.instance = instance
self.H = horizon
self.t = 0
self.state = None
self.action_space = ...      # definir (Box/Discrete)
self.observation_space = ...  # definir (Box/Dict)
self.rng = np.random.default_rng(seed)

def reset(self, seed=None, options=None):
    super().reset(seed=seed)  # recomendado pelo Gymnasium p/ seeding correto
    self.t = 0
    self.state = self._init_state()
    return self._get_obs(), {}

def step(self, action):
    # 1) converter action -> decisões (produção/transferências)
    # 2) simular demanda e lead times
    # 3) atualizar estoques e custos
    reward = - self._cost_increment()
    self.t += 1
    terminated = (self.t >= self.H)
    return self._get_obs(), reward, terminated, False, {}

def _get_obs(self):
    return ...

```

2.8.6 Treinamento PPO com Stable-Baselines3: parâmetros e loop

Para treinamento, uma opção prática é Stable-Baselines3, cuja documentação descreve hiperparâmetros relevantes de PPO, como *n_steps*, *batch_size*, *n_epochs* e γ . Raffin et al. (2021) Uma configuração inicial (não especificada; sugerida como ponto de partida) é: *n_steps* $\in \{512, 1024, 2048\}$, *batch_size* $\in \{64, 128, 256\}$, $\gamma \in [0.95, 0.999]$, com busca posterior por *tuning*.

```

# PPO (Stable-Baselines3) - esqueleto mínimo (Python)
from stable_baselines3 import PPO

env = MEIOEnv(instance=inst, horizon=H, seed=123)
model = PPO("MlpPolicy", env,
            n_steps=2048, batch_size=128, n_epochs=10,
            gamma=0.99, learning_rate=3e-4, clip_range=0.2,

```

```
verbose=1)  
model.learn(total_timesteps=2_000_000)
```

2.9 Métricas de avaliação e protocolo experimental

2.9.1 Métricas: previsão, operação, otimização e aprendizado

A avaliação deve separar: (i) qualidade preditiva, (ii) desempenho operacional e (iii) custo computacional. Em previsão, métricas clássicas incluem MAE/RMSE/MAPE (também usadas no pipeline Kedro anexado) e devem ser complementadas por métricas alinhadas ao impacto em inventário e nível de serviço. [Nasseri et al. \(2023\)](#); [Tadayonrad and Ndiaye \(2023\)](#) Em MEIO, métricas operacionais recomendadas incluem: custo total, custo de transporte, custo de produção, custo de estoque, custo de ruptura (backorder/lost sales), nível de serviço (cycle service level, fill rate), estoque médio e variância. [Axsater \(2006\)](#); [Zipkin \(2000\)](#)

Em otimização exata, reporta-se status, melhor solução, melhor limite e *gap*, além de *runtime* e uso de memória quando mensurável. Em DRL, mede-se retorno médio e sua dispersão, estabilidade por sementes, taxa de violação de restrições (quando aplicável) e generalização para instâncias não vistas. [Boute et al. \(2022\)](#); [Geevers et al. \(2024\)](#)

2.9.2 Protocolo, seeding e testes estatísticos

O protocolo experimental recomendado segue princípios de comparação justa em ambientes estocásticos: múltiplas sementes, *common random numbers* para simulações comparativas, e agregação por estatísticas robustas (média, mediana, intervalos de confiança). [Law \(2015\)](#) Para comparar métodos, sugere-se ao menos: (i) teste pareado (t-test quando plausível ou Wilcoxon quando não), (ii) estimativas por bootstrap para diferenças de médias/medianas, e (iii) correção para múltiplas comparações quando necessário.

2.10 Engenharia de software para experimentos: Kedro, Docker, Git e reprodutibilidade

2.10.1 Kedro: conceitos, Data Catalog, pipelines e visualização

Kedro provê uma estrutura para projetos de ciência de dados baseada em: *nós* (funções com entradas/saídas nomeadas), *pipelines* (ordenação e dependências) e um *Data Catalog* (registro de datasets em `catalog.yml`). [Kedro Project \(2024a,b\)](#) Esses conceitos aparecem concretamente no projeto anexado: o arquivo `conf/base/catalog.yml` registra datasets por camadas

(01_raw, 02_intermediate, 03_primary, etc.), e o pipeline de previsão implementa *rolling-origin forecast* sem vazamento do futuro. (Conforme códigos anexados.)

Kedro-Viz é uma ferramenta oficial para visualização interativa do grafo de pipeline, útil para auditoria e comunicação de experimentos. [Kedro Project \(2024c\)](#) No fluxo do projeto, isso favorece governança experimental e reduz risco de inconsistência entre versões.

2.10.2 MLflow e rastreamento de experimentos

MLflow fornece APIs para registrar parâmetros, métricas e artefatos de experimento, permitindo comparações e auditoria. [MLflow Project \(2024\)](#) O projeto anexado inclui integração `kedro-mlflow` (conforme `conf/base/mlflow.yml` e datasets de métricas), o que recomenda-se manter quando se evoluir para múltiplos modelos de previsão e múltiplas políticas (heurísticas e DRL).

2.10.3 Docker: isolamento, builds reprodutíveis e boas práticas

A containerização com Docker reduz *drift* de ambiente (dependências e SO) e facilita re-execução dos experimentos. Boas práticas oficiais incluem *multi-stage builds* e organização do Dockerfile para minimizar tamanho e maximizar reprodutibilidade. [Docker Inc. \(2024\)](#) Para este projeto, recomenda-se: (i) fixar versões (Python e bibliotecas críticas), (ii) capturar `requirements.txt/pyproject.toml`, e (iii) registrar hashes de dataset e configurações.

2.10.4 Git: versionamento e rastreabilidade

Versionamento em Git é requisito prático para uma dissertação reprodutível: garante histórico, ramos experimentais e rastreabilidade de mudanças em código e configurações. O livro oficial *Pro Git* é uma referência consolidada e acessível para práticas recomendadas (commits pequenos, branching, merges, tags). [Chacon and Straub \(2014\)](#)

2.10.5 Checklist de reprodutibilidade (recomendado)

Para orientar a execução experimental, recomenda-se adotar, no mínimo, o seguinte checklist:

- **Ambiente:** versão do Python e pacotes fixados; container Docker (quando aplicável) com instruções de build.
- **Dados:** hashes (ou versões) de arquivos, dicionário de dados, política de tratamento de faltantes/outliers.
- **Seeding:** sementes globais registradas (NumPy, bibliotecas ML, ambiente Gym), múltiplas sementes por experimento.

- **Configuração:** hiperparâmetros e parâmetros de solver/versionamento por arquivo YAML/JSON controlado por Git.
- **Rastreamento:** MLflow (ou equivalente) registrando métricas, parâmetros e artefatos (modelos e relatórios).
- **Relatório:** tabelas de resultados com ICs, testes estatísticos e descrição do protocolo.

2.11 Tabelas comparativas e configurações iniciais recomendadas

2.11.1 Comparação entre famílias de métodos

Método	Escalabilidade	Interpretabilidade	Dados necessários	Custo comput.	Tratamento de restrições
ILP/MILP (solver)	média–baixa (cresce rápido)	alta	baixo–médio	alto (pior caso)	nativo (exato)
Fluxo em rede (LP)	alta (quando contínuo)	alta	baixo–médio	médio	nativo (linear)
Metaheurísticas (GA/GRASP/SA)	alta (paralelizável)	média	baixo–médio	médio–alto	penalização/reparo
Simulação (DES/MC)	alta (paralelizável)	alta (modelo explícito)	médio–alto	médio–alto	avalia políticas; não “impõe”
DRL (PPO/DQN)	média (treino custoso)	baixa–média	alto (interação)	alto	indireto (penalização/máscara)
MARL/IMARL	média (infra mais complexa)	baixa	alto	alto	indireto; decomposição por agentes

Table 2.1: Comparação qualitativa de métodos no contexto MEIO.

2.11.2 Configurações iniciais (pontos de partida)

Componente	Parâmetros iniciais	Justificativa/nota
MILP (solver)	<code>TimeLimit = 300s;</code> <code>MIPGap = 1%; Threads = 1</code>	Comparabilidade e controle de custo; ajustar por escala. Gurobi Optimization LLC (2024b)
OR-Tools CP-SAT	<code>max_time_in_seconds</code> (não especificado; p.ex. 60–600)	Terminação por tempo é recomendada para evitar execuções longas. Google Optimization Team (2024a)
GA	$P = 100, G = 200, p_c = 0.8,$ $p_m = 0.05$	Ponto de partida; calibrar por instância e custo de avaliação. Talbi (2009)
GRASP	$\alpha = 0.2$ e $K = 500$ iterações	α controla aleatoriedade; aumenta diversidade; calibrar. Feo and Resende (1995)
SA	T_0 por escala de custo; $\alpha = 0.95;$ $R = 100$	Esquema clássico; calibrar para taxas de aceitação. Kirkpatrick et al. (1983)
NSGA-II	$N = 200, G = 200,$ elitismo ligado	Multiobjetivo custo/tempo; custo computacional maior. Deb et al. (2002)
Previsão	XGB com defasagens $L = 6$ (baseline) e Holt-Winters/SARIMAX	Coerente com pipeline anexado; comparar com ensembles e LSTM. Nasseri et al. (2023)
PPO (SB3)	$n_steps = 2048, batch = 128, \gamma = 0.99, lr = 3 \cdot 10^{-4}$	Defaults usuais; ajustar por estabilidade e custo. Raffin et al. (2021)

Table 2.2: Configurações iniciais recomendadas para experimentos (valores “não especificado” devem ser definidos no protocolo).

3

Metodologia

3.1 Objetivos experimentais, hipóteses e suposições

Metas rastreáveis aos OE1–OE7

O desenho experimental valida: (OE1) consistência do modelo base em rede; (OE2) geração de instâncias controladas e uso de dados de grande escala (conforme apresentação do autor); (OE3) *benchmark* ILP/MILP; (OE4) escalabilidade por GA/GRASP/SA e, quando multiobjetivo, NSGA-II; (OE5–OE6) extensão multi-período/estocástica em *rolling horizon*; (OE7) políticas DRL/MARL (PPO/DQN/IMARL) em ambiente simulado.

Hipóteses

(H1) ILP/MILP fornece referência com *gap* controlado em instâncias pequenas/médias, mas escala de forma limitada com $|A| \times |I| \times |T|$. [Shapiro \(2001\)](#) (H2) Em instâncias grandes, metaheurísticas atingem soluções competitivas com menor *runtime* e robustez sob múltiplas sementes. [Talbi \(2009\)](#) (H3) Em multi-período estocástico, DRL/MARL supera abordagens estáticas ao aprender políticas adaptativas, desde que o ambiente/recompensa estejam bem definidos. [Boute et al. \(2022\)](#); [Geevers et al. \(2024\)](#); [Ziegner et al. \(2025\)](#) (H4) A previsão de demanda explica variação relevante em custo e nível de serviço; métricas alinhadas à decisão são mais informativas que erro puro. [Nasseri et al. \(2023\)](#); [Tadayonrad and Ndiaye \(2023\)](#)

Suposições explícitas (itens não especificados)

Horizon H (propor $H \in \{14, 28, 56\}$ dias ou $H \in \{8, 12\}$ semanas), política de ruptura (backorder ou lost sales), lead time $\ell_{a,b}$ (determinístico ou discreto em $\{0, 1, 2, 3\}$) e ruído de demanda (coeficiente $cv \in \{0, 0.2, 0.5\}$). [Axsater \(2006\)](#); [Birge and Louveaux \(2011\)](#)

3.2 Dados, pré-processamento e geração de instâncias

3.2.1 Dados e esquema mínimo

Conforme apresentação do autor, o caso motivador possui escala aproximada de 48M registros, 12k produtos únicos e 3M entidades de demanda, implicando necessidade de agregação e/ou amostragem em experimentos controlados. No pipeline Kedro anexado, camadas `01_raw-08_reporting` organizam limpeza, enriquecimento e previsão; a tabela de vendas enriquecida inclui ao menos `date`, `cycle`, `qty`, receitas, canais, chaves `rev_id/prod_id` e atributos de revendedor/produto; o módulo de previsão compara *naive*, Holt-Winters, SARIMAX, XGBoost e Prophet sob validação *rolling-origin* e métricas MAE/RMSE/MAPE (conforme implementação). [Nasseri et al. \(2023\)](#)

3.2.2 Pré-processamento e particionamento temporal

As transformações incluem padronização de chaves, remoção de PII, deduplicação e agregação por ciclo (parâmetros em YAML; semente global `random_seed=123` conforme configuração). O particionamento treino/val/teste é temporal: treino até t_{train} , validação em $t_{\text{train}}+1:t_{\text{val}}$ e teste nos últimos H ciclos (não especificado). O mesmo princípio é aplicado à avaliação de políticas em *rolling horizon* para evitar vazamento de informação futura.

3.2.3 Geração de instâncias

Instâncias controladas são definidas por $|M|, |S|, |F|, |I|$, horizonte H e ruído cv . Protocolo: amostrar subconjuntos de nós/itens; gerar distâncias $d(a, b)$ (não especificado; p.ex. coordenadas 2D) e filtrar arcos por viabilidade $d(a, b) \leq T_{a,b}$; definir $C_{a,b}$ e Q_f proporcionais à demanda média; gerar demanda base e cenários $D_{m,i,t}$ via (i) bootstrap do histórico ou (ii) $D = \mu(1 + \varepsilon)$ com $\varepsilon \sim \mathcal{N}(0, cv)$ truncado. [Ahuja et al. \(1993\)](#); [Shapiro \(2001\)](#)

3.3 Métodos avaliados e parametrização

3.3.1 ILP/MILP (benchmark) e solver

O baseline resolve o problema de um período com $x_{a,b,i}$ e $y_{f,i}$ e objetivo com penalidade temporal λ_t (grade não especificada; sugerir $\{0, 0.1, 1, 10\}$ após normalização). [Shapiro \(2001\)](#) Configurações padrão: `TimeLimit=300 s`, `MIPGap=1%`, `Threads=1`; reportam-se *incumbent*, *best bound* e *gap*.

3.3.2 Metaheurísticas (GA/GRASP/SA/NSGA-II)

GA (codificação “1 gene por item”) minimiza custo de transporte + produção adicional; parâmetros iniciais $ngen=50$, $pop=80$, $cspb=0.7$, $mutpb=0.2$, torneio = 3 (conforme implementação e apresentação do autor). GRASP usa construção randomizada com α (propor $\alpha \in \{0.1, 0.3, 0.5\}$) e busca local; SA usa resfriamento geométrico $T_{k+1} = \alpha T_k$ (propor $\alpha=0.95$). [Talbi \(2009\)](#) NSGA-II é usado quando custo e tempo são objetivos separados (alternativa ao ajuste de λ_t), produzindo aproximação empírica de fronteiras de Pareto.

3.3.3 Simulação (Monte Carlo / eventos discretos)

A avaliação multi-período é feita por simulação: para cada replicação $r = 1, \dots, R$ (R não especificado; sugerir $R = 30$), amostram-se demandas e (opcionalmente) lead times; aplica-se decisão por período via MILP/heurística ou política RL; acumula-se custo e nível de serviço. Para reduzir variância comparativa, usa-se *common random numbers* (mesmas sementes/cenários por método). [Law \(2015\)](#); [Birge and Louveaux \(2011\)](#)

3.3.4 DRL/MARL (PPO/DQN/IMARL)

O ambiente é modelado como MDP; ações representam reposição/transferências (vetor contínuo ou discretizado). PPO é o baseline de política em rede geral (treino com Stable-Baselines3); DQN é avaliado apenas quando o espaço de ação é discretizado; IMARL é considerado como extensão multiagente voltada à escalabilidade em MEIO realista. [Schulman et al. \(2017\)](#); [Oroojlooyjadid et al. \(2022\)](#); [Geevers et al. \(2024\)](#); [Ziegner et al. \(2025\)](#)

3.4 Ambiente de simulação e API tipo Gym

3.4.1 Estado, ação, transição e recompensa

O estado s_t inclui estoques $I_{n,i,t}$, pipeline (pedidos em trânsito), demanda recente/prevista e capacidades residuais; a ação a_t define $x_{a,b,i,t}$ e $y_{f,i,t}$ (diretamente ou via parametrização). A transição aplica lead time ℓ , realiza demanda $D_{m,i,t}$ e atualiza balanços; a recompensa é $-\Delta\text{custo}$, incluindo transporte, produção, holding, ruptura e termo temporal ponderado por λ_t . [Axsater \(2006\)](#); [Boute et al. \(2022\)](#)

3.4.2 Rolling horizon

Para cada época t : consolidar $[t - w, t]$ (w não especificado), prever $\hat{D}_{t+1:t+H}$, decidir para o próximo período (MILP/heurística ou RL), executar e registrar novos dados; repetir até H . [Law \(2015\)](#)

3.5 Protocolo experimental, métricas e testes

3.5.1 Sementes e splits

Todas as execuções registram sementes (Python/NumPy/ambiente) e, quando necessário, fixam paralelismo. Previsão e avaliação são temporais; DRL treina em instâncias de treino e reporta desempenho em instâncias *hold-out*. Para comparações estocásticas, utiliza-se CRN (mesmas amostras por método) e múltiplas seeds.

3.5.2 Métricas

Operacionais: custo total e decomposição, fill rate, backorders/lost sales, estoque médio, violações; computacionais: runtime, memória (quando disponível), *gap* (MILP), retorno médio e estabilidade por sementes (RL). [Axster \(2006\)](#); [Law \(2015\)](#)

3.5.3 Inferência

Comparações pareadas usam Wilcoxon (ou t-teste se adequado), com $\alpha = 0.05$; intervalos de confiança por bootstrap são opcionais. [Law \(2015\)](#)

3.6 Reprodutibilidade e engenharia experimental

O pipeline é orquestrado em Kedro (pipelines `data_clean`, `data_enrich`, `forecasting`, `reporting`) com parâmetros em YAML e rastreamento de métricas/artefatos via MLflow (conforme código anexado). A reprodutibilidade é garantida por: versionamento Git (tags por experimento), hashes de datasets/configs, logs estruturados (JSON) e containerização via Docker (dependências fixadas).

Diagrama: fluxo de dados e de experimentos (Mermaid)

flowchart TD

```
R[01_raw: vendas/ruptura] --> C[data_clean]
C --> E[data_enrich: fatos + dimensões]
E --> F[forecasting: MAE/RMSE/MAPE + \hat{D}]
F --> O[otimização: MILP + metaheurísticas]
O --> S[simulação/RL: rolling horizon]
S --> P[08_reporting: métricas + gráficos]
```

flowchart LR

```
A[Instâncias × seeds] --> B[MILP]
A --> C[GA/GRASP/SA/NSGA-II]
```

```

A --> D[Simulação (R rep.)]
D --> E[RL treino]
B --> Z[Relatório]
C --> Z
E --> Z

```

3.7 Tabelas e matriz experimental

Método	Escala	Interpret.	Custo comp.	Restrições
MILP	M-B	Alta	Alto	Exato
GA/GRASP/SA	Alta	Média	Médio	Penal./reparo
Simulação	Alta	Alta	Médio-alto	Avalia
PPO/DQN/IMARL	M	Baixa	Alto	Indireto

Table 3.1: Comparação resumida de famílias (MEIO).

Classe	(M , S , F , I)	Métodos	Seeds/Rep.
S	(20,2,1,50)	MILP+meta	10
M	(50,5,2,200)	MILP+meta	10
L	(100,10,5,500)	meta+RL	10 / $R=30$

Table 3.2: Matriz recomendada; H e cv varrem cenários.

Snippets de implementação (documentação)

OR-Tools/Gurobi (esqueleto MIP)

```

# declarar solver/model; criar x[a,b,i], y[f,i]
# add: atendimento, capacidade, produção; objetivo com lambda_t
# set TimeLimit/MIPGap/Threads; resolver; salvar incumbent/bound/gap

```

GA/GRASP (pseudocódigo)

```

GA: população -> avaliar -> seleção(torneio) -> crossover(2pt) -> mutação -> elitismo.
GRASP: construir (RCL com ) -> busca local -> atualizar melhor; repetir K iterações.

```

Gym-like env (esqueleto)

```

reset(seed): t=0; inicializa estoques/pipeline; retorna obs.
step(a): aplica decisão; amostra demanda/lead time; atualiza estado e custo;
return obs, reward=-custo_inc, terminated=(t>=H).

```

PPO (loop)

```
model = PPO("MlpPolicy", env, n_steps=2048, batch_size=128, gamma=0.99, lr=3e-4)
model.learn(total_timesteps=2_000_000); avaliar em seeds e instâncias hold-out.
```

Kedro node (exemplo)

```
def prepare_series(vendas_enrich):
    return vendas_enrich.groupby("cycle")["qty"].sum().sort_index()
```

Dockerfile (esboço)

```
FROM python:3.11-slim
WORKDIR /app
COPY requirements.txt ./
RUN pip install -r requirements.txt
COPY . .
CMD ["kedro", "run"]
```

References

- Victoria G. Achkar, Braulio B. Brunaud, H'ector D. P'erez, Rami Musa, Carlos A. M'endez, and Ignacio E. Grossmann. Extensions to the guaranteed service model for industrial applications of multi-echelon inventory optimization. *European Journal of Operational Research*, 313(1):192–206, 2024. DOI 10.1016/j.ejor.2023.08.013. URL <https://www.sciencedirect.com/science/article/pii/S0377221723006173>. Vers ao preprint: arXiv:2306.10961.
- Ravindra K. Ahuja, Thomas L. Magnanti, and James B. Orlin. *Network Flows: Theory, Algorithms, and Applications*. Prentice Hall, Upper Saddle River, NJ, USA, 1993. ISBN 9780136175490. URL <https://dl.acm.org/doi/10.5555/137406>.
- Sven Axstr"ater. *Inventory Control*, volume 90 of *International Series in Operations Research Management Science*. Springer US, New York, NY, USA, 2 edition, 2006. ISBN 9780387332505. DOI 10.1007/0-387-33331-2. URL https://books.google.com/books/about/Inventory_Control.html?id=RyzrngEACAAJ.
- Ronald H. Ballou. *Gerenciamento da Cadeia de Suprimentos: Log'istica Empresarial*. Bookman, Porto Alegre, RS, Brazil, 5 edition, 2006. ISBN 9788536305912. URL <https://www.amazon.com.br/Gerenciamento-Cadeia-Suprimentos-LogC3ADstica-Empresarial/dp/8536305916>. Ediç ao em portugu"es(tradu ao);afichapodelistarosobrenomecomo"Ballou".
- John R. Birge and Franois Louveaux. *Introduction to Stochastic Programming*. Springer Series in Operations Research and Financial Engineering. Springer, New York, NY, USA, 2 edition, 2011. ISBN 9781461402367. DOI 10.1007/978-1-4614-0237-4. URL <https://link.springer.com/book/10.1007/978-1-4614-0237-4>.
- Robert N. Boute, Joren Gijsbrechts, Willem van Jaarsveld, and Nathalie Vanvuchelen. Deep reinforcement learning for inventory control: A roadmap. *European Journal of Operational Research*, 298(2):401–412, 2022. DOI 10.1016/j.ejor.2021.07.016. URL <https://www.sciencedirect.com/science/article/pii/S0377221721006111>. Invited Review; Open Access.

- Scott Chacon and Ben Straub. *Pro Git*. Apress, 2014. URL <https://git-scm.com/book>.
- Sunil Chopra. *Supply Chain Management: Strategy, Planning, and Operation*. Pearson, 7 edition, 2022. ISBN 9780137502844. URL <https://www.pearson.com/en-us/subject-catalog/p/supply-chain-management-strategy-planning-and-operation/P200000005863/9780137502844>. Cat'alogo Pearson (eTextbook): publicado em 14 Jul 2021; © 2022; eText ISBN 9780137502844.
- Andrew J. Clark and Herbert Scarf. Optimal policies for a multi-echelon inventory problem. *Management Science*, 6(4):475–490, 1960. DOI 10.1287/mnsc.6.4.475. URL <https://dl.acm.org/doi/10.1287/mnsc.6.4.475>.
- Ton de Kok, Christopher Grob, Marco Laumanns, Stefan Minner, Jörg Rambau, and Konrad Schade. A typology and literature review on stochastic multi-echelon inventory models. *European Journal of Operational Research*, 269(3):955–983, 2018. DOI 10.1016/j.ejor.2018.02.047. URL <https://www.sciencedirect.com/science/article/pii/S0377221718301802>.
- Kalyanmoy Deb, Amrit Pratap, Sameer Agarwal, and T. Meyarivan. A fast and elitist multiobjective genetic algorithm: Nsga-ii. *IEEE Transactions on Evolutionary Computation*, 6(2):182–197, 2002. DOI 10.1109/4235.996017.
- Docker Inc. Docker build best practices. <https://docs.docker.com/develop/dev-best-practices/>, 2024.
- Ayşe Sena Eruguz, Evren Sahin, Zied Jemai, and Yves Dallery. A comprehensive survey of guaranteed-service models for multi-echelon inventory optimization. *International Journal of Production Economics*, 172:110–125, 2016. DOI 10.1016/j.ijpe.2015.11.017. URL <https://www.sciencedirect.com/science/article/pii/S0925527315005162>.
- Thomas A. Feo and Mauricio G. C. Resende. Greedy randomized adaptive search procedures. *Journal of Global Optimization*, 6:109–133, 1995. DOI 10.1007/BF01096763.
- Farama Foundation. Gymnasium: A standard api for reinforcement learning environments. <https://gymnasium.farama.org/>, 2023.
- Kevin Geevers, Lotte van Hezewijk, and Martijn R. K. Mes. Multi-echelon inventory optimization using deep reinforcement learning. *Central European Journal of Operations Research*, 32(3):653–683, 2024. DOI 10.1007/s10100-023-00872-2. URL <https://link.springer.com/article/10.1007/s10100-023-00872-2>. Publicado online em 19 Jul 2023; ediç ao impressa em 2024.

- Joren Gijsbrechts, Robert N. Boute, Jan A. Van Mieghem, and David J. Zhang. Can deep reinforcement learning improve inventory management? performance on lost sales, dual-sourcing, and multi-echelon problems. *Manufacturing & Service Operations Management*, 24(3):1349–1368, 2022. DOI [10.1287/msom.2021.1064](https://doi.org/10.1287/msom.2021.1064). URL <https://pubsonline.informs.org/doi/abs/10.1287/msom.2021.1064>.
- Google Optimization Team. Google or-tools cp-sat solver. <https://developers.google.com/optimization>, 2024a.
- Google Optimization Team. Or-tools mixed integer programming examples. <https://developers.google.com/optimization/mip>, 2024b.
- Stephen C. Graves and Sean P. Willems. Optimizing strategic safety stock placement in supply chains. *Manufacturing & Service Operations Management*, 2(1):68–83, 2000. DOI [10.1287/msom.2.1.68.23267](https://doi.org/10.1287/msom.2.1.68.23267). URL <https://pubsonline.informs.org/doi/10.1287/msom.2.1.68.23267>.
- Gurobi Optimization LLC. Mixed integer programming primer. <https://www.gurobi.com/resources/>, 2024a.
- Gurobi Optimization LLC. Guidelines for tuning gurobi parameters. <https://www.gurobi.com/documentation/>, 2024b.
- Gurobi Optimization LLC. Gurobi parameter reference. <https://www.gurobi.com/documentation/current/refman/>, 2024c.
- Gurobi Optimization LLC. Gurobi optimizer python api reference. <https://www.gurobi.com/documentation/>, 2024d.
- John H. Holland. *Adaptation in Natural and Artificial Systems*. MIT Press, 1992.
- Kedro Project. Kedro documentation: Concepts. <https://docs.kedro.org>, 2024a.
- Kedro Project. Kedro data catalog configuration. https://docs.kedro.org/en/stable/data/data_catalog.html, 2024b.
- Kedro Project. Kedro-viz documentation. <https://kedro-viz.readthedocs.io>, 2024c.
- S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi. Optimization by simulated annealing. *Science*, 220(4598):671–680, 1983. DOI [10.1126/science.220.4598.671](https://doi.org/10.1126/science.220.4598.671).
- Averill M. Law. *Simulation Modeling and Analysis*. McGraw-Hill Education, 5 edition, 2015. ISBN 9780073401324. URL <https://www.mheducation.com/highered/product/simulation-modeling-and-analysis-law.html>.

- Hau L. Lee, V. Padmanabhan, and Seungjin Whang. Information distortion in a supply chain: The bullwhip effect. *Management Science*, 43(4):546–558, 1997.
DOI [10.1287/mnsc.43.4.546](https://pubsonline.informs.org/doi/10.1287/mnsc.43.4.546). URL <https://pubsonline.informs.org/doi/10.1287/mnsc.43.4.546>.
- MLflow Project. MLflow tracking documentation.
<https://mlflow.org/docs/latest/tracking.html>, 2024.
- Volodymyr Mnih, Koray Kavukcuoglu, David Silver, et al. Human-level control through deep reinforcement learning. *Nature*, 518:529–533, 2015. **DOI** [10.1038/nature14236](https://doi.org/10.1038/nature14236).
- Mehran Nasseri, Taha Falatouri, Patrick Brandtner, and Farzaneh Darbanian. Applying machine learning in retail demand prediction—a comparison of tree-based ensembles and long short-term memory-based deep learning. *Applied Sciences*, 13(19):11112, 2023.
DOI [10.3390/app131911112](https://doi.org/10.3390/app131911112). URL <https://www.mdpi.com/2076-3417/13/19/11112>. MDPI; Open Access.
- Afshin Oroojlooyjadid, MohammadReza Nazari, Lawrence V. Snyder, and Martin Tak’ač. A deep q-network for the beer game: Deep reinforcement learning for inventory optimization. *Manufacturing Service Operations Management*, 24(1):285–304, 2022.
DOI [10.1287/msom.2020.0939](https://doi.org/10.1287/msom.2020.0939). URL <https://pubsonline.informs.org/doi/10.1287/msom.2020.0939>. Acesso ao site do editor pode requerer assinatura institucional.
- Antonin Raffin et al. Stable baselines3 documentation.
<https://stable-baselines3.readthedocs.io/>, 2021.
- John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
DOI [10.48550/arXiv.1707.06347](https://doi.org/10.48550/arXiv.1707.06347). URL <https://arxiv.org/abs/1707.06347>.
- Jeremy F. Shapiro. *Modeling the Supply Chain*. Brooks/Cole–Thomson Learning, Pacific Grove, CA, USA, 1 edition, 2001. ISBN 9780534373634. URL <https://archive.org/details/modelingsupplych0000shap>.
- David Simchi-Levi, Philip Kaminsky, and Edith Simchi-Levi. *Cadeia de Suprimentos: Projeto e Gest ao: Conceitos, Estrat’egias e Estudos de Caso*. Bookman, Porto Alegre, RS, Brazil, unspecified edition, 2009. ISBN 9788577806638. URL https://books.google.com/books/about/Cadeia_de_Suprimentos_Projeto_e_GestC3A3o.html?id=haBqqsKjzTkC.
- Richard S. Sutton and Andrew G. Barto. *Reinforcement Learning: An Introduction*. MIT Press, 2 edition, 2018.

- Yasin Tadayonrad and Alassane Balle Ndiaye. A new key performance indicator model for demand forecasting in inventory management considering supply chain reliability and seasonality. *Supply Chain Analytics*, 3:100026, 2023. DOI 10.1016/j.sca.2023.100026. URL <https://www.sciencedirect.com/science/article/pii/S2949863523000250>. Elsevier; Open Access.
- El-Ghazali Talbi. *Metaheuristics: From Design to Implementation*. John Wiley Sons, Hoboken, NJ, USA, 2009. ISBN 9780470278581. DOI 10.1002/9780470496916. URL <https://onlinelibrary.wiley.com/doi/book/10.1002/9780470496916>. Online ISBN (DOI): 9780470496916.
- Georg Ziegner, Michael Choi, Hung Mac Chan Le, Sahil Sakhuja, and Arash Sarmadi. Iterative multi-agent reinforcement learning: A novel approach toward real-world multi-echelon inventory optimization. *arXiv preprint arXiv:2503.18201*, 2025. DOI 10.48550/arXiv.2503.18201. URL <https://arxiv.org/abs/2503.18201>.
- Paul H. Zipkin. *Foundations of Inventory Management*. McGraw-Hill/Irwin, Boston, MA, USA, 1 edition, 2000. ISBN 9780256113792. URL https://books.google.com/books/about/Foundations_of_Inventory_Management.html?id=rjzbnQEACAAJ.